Kurs: **EA2003 Självständigt arbete i musikproduktion, 30 hp**

VT 2026

Masterexamen i musik

Institutionen för Musik- och medieproduktion

Handledare: Hans Gardemar, Hans Lindetorp

Examinatorer: David Thyrén, Johan Ramström

Oliwer Simonsson

HueGaze: The Art of Scientific Mapping

Cross-modal Sonification of Images

Skriftlig reflektion inom självständigt arbete
Till dokumentationen hör även följande video: **Gazing**

KMH Kungl. Musikhögskolan

Abstract

This master's thesis explores the relationship between vision and hearing by investigating how cross-modal correspondences can serve as a framework for musical composition through sonification. Central to this project is the question of how the mapping process is shaped by the interplay between artistic and technical decision-making within a sonification framework. An algorithm was designed and evaluated, titled HueGaze, which translates visual attributes from digital images into musical parameters grounded in human perception. Developed in Python and SuperCollider, the algorithm uses the CIELAB colour space to extract perceptual data such as colours, lightness and entropy from an image. These values are mapped to acoustic parameters such as pitch, amplitude, and timbre, inspired by established cross-modal correspondences. Research through Design was applied as the overarching methodology, enabling theory, technical implementation, and artistic reflection to interact iteratively throughout the process. The results demonstrated that the algorithm transformed static images into dynamic musical compositions, realizing the project's concept of the image as a visual score. In doing so, a central tension surfaced between the scientific objectivity traditionally required by sonification and the artistic judgment inherent in compositional decision-making. More broadly, this reflects a methodological challenge within cross-modal research, where neither strict empirical nor purely artistic approaches alone can adequately address questions rooted in shared subjective experience. The primary contribution of this work is to frame this tension, not as a limitation to overcome, but as the working ground in which cross-modal design takes place. Through what is articulated as the aesthetic filter, this project presents a set of design principles for navigating the interplay between technical and artistic judgment. By applying these principles, the image is treated less as raw data, and more as a musical score to be read.

Keywords: sonification, cross-modal correspondence, CIELAB, algorithmic composition, Research through Design, music production, HueGaze

Abstract

Denna masteruppsats undersöker relationen mellan syn och hörsel genom att studera hur tvärmodala korrespondenser kan agera som ett ramverk för musikalisk komposition via sonifiering. Centralt för detta projekt är frågan om hur mappningsprocessen formas av samspelet mellan konstnärligt och tekniskt beslutsfattande inom ett sonifieringsramverk. En algoritm vid namn HueGaze utformades och utvärderades som översätter visuella attribut från digitala bilder till akustiska parametrar förankrade i mänsklig perception. Algoritmen, utvecklad i Python och SuperCollider, använder färgrymden CIELAB för att extrahera perceptuella data, såsom färger, ljushet och entropi ur en bild. Dessa värden mappas till akustiska parametrar såsom tonhöjd, amplitud och klangfärg, inspirerade av etablerade tvärmodala korrespondenser. Metodologin Research Through Design tillämpades som övergripande metod, vilket möjliggjorde att teori, teknisk implementering och konstnärlig reflektion kunde samverka iterativt under hela processen. Resultatet visade att algoritmen omvandlade statiska bilder till dynamiska musikaliska kompositioner och därigenom realiserade projektets idé om bilden som ett visuellt partitur. I denna process framträdde dock en central spänning mellan den vetenskapliga objektiviteten som sonifiering traditionellt kräver och det konstnärliga omdöme som är inneboende i kompositoriskt beslutsfattande. I ett vidare perspektiv speglar detta en metodologisk utmaning inom tvärmodal forskning, där varken strikt empiriska eller renodlade konstnärliga ansatser på egen hand kan besvara frågor som är rotade i en delad subjektiv erfarenhet. Arbetets främsta bidrag är att rama in denna spänning, ej som en begränsning att överkomma, utan som den grund där tvärmodal design äger rum. Genom det som formuleras som det estetiska filtret presenterar projektet en uppsättning designprinciper för att navigera i samspelet mellan tekniskt och konstnärligt omdöme. Genom att tillämpa dessa principer behandlas bilden mindre som rådata och mer som ett musikaliskt partitur att läsa.

Nyckelord: sonifiering, tvärmodal korrespondens, CIELAB, algoritmisk komposition, Research Through Design, musikproduktion, HueGaze

Innehållsförteckning

1 Inledning ... 1

1.1 Syfte ... 2

1.1.1 Frågeställningar ... 2

1.1.2 Avgränsningar ... 2

1.2 Terminologi ... 3

1.2.1 Kodexempel ... 4

2 Bakgrund ... 6

2.1 Tvärmodal korrespondens ... 6

2.1.1 Attribut, dimensioner samt egenskaper ... 6

2.1.2 Tvärsensorisk mappning ... 7

2.2 CIELAB ... 8

2.3 Sonifiering ... 10

2.3.1 Sonifieringsverktyg ... 11

3 Metod ... 13

3.1 Urval av visuellt material ... 14

3.2 Etiska överväganden ... 14

4 Utförande: Bildanalys ... 15

4.1 Förarbete: Visuell tolkning samt dataurval ... 15

4.2 Implementation: Python ... 16

4.3 Utvärdering: Bildanalys ... 20

5 Utförande: Sonifiering ... 21

5.1 Förarbete: Mappningsstrategi ... 21

5.1.1 Mikroparametrar ... 22

5.1.2 Makroparametrar ... 23

5.2 Implementation: SuperCollider ... 24

5.2.1 System och dataimport ... 25

5.2.2 Mikroparametrar ... 26

5.2.3 Makroparametrar ... 28

5.2.4 Sequencer ... 29

5.3 Utvärdering: Sonifiering ... 31

6 Resultat 33
6.1 Audiovisuellt musikstycke: Gazing 33
6.1.1 Analys av visuellt material 34
6.1.2 Summering av data 42
6.1.3 Arrangering 42
6.2 Viktiga iterationsmoment 44
6.2.1 Val av tonhöjdsparameter 44
6.2.2 Sequencerimplementation 44
6.2.3 Skalning av rådata 45
7 Diskussion 46
7.1 Tvärvetenskaplig metodologi 46
7.2 Konsten att mappa vetenskapligt 46
7.2.1 Det 'estetiska filtret' 47
7.2.2 Komplexa stimuli 48
7.3 Roller inom projektet 49
7.3.1 Konstnären 49
7.3.2 Forskaren 49
7.3.3 Designern 50
7.4 Framtida forskning 51
7.4.1 Huegaze.com 52
8 Slutsats 53
9 Referenslista 56

1 Inledning

”Hur låter färgen röd?” är en frågeställning som vid första anblick kan verka motsägelsefull, då färg och ljud tolkas av olika sinnen och saknar en självklar gemensam nämnare. För många skapar den förvirring, för andra en omedelbar association. Även, om en association faktiskt väcks till liv, varierar svaren från person till person. Samma röda färg kan för en person upplevas som ”lågt och tungt”, men för någon annan som ”ljust och lätt”. Bakom dessa skillnader ligger variabler som uppväxt, kultur, ålder och även sinnesstämning, som alla färgar tolkningen, vare sig det sker medvetet eller ej.

Det finns dock mönster i dessa svar. Dessa mönster tar form genom systematiska associationer mellan olika sinnesintryck, så som kopplingar mellan ljud och färg. Omfattande forskning (se bland annat Marks, 1987; Ramachandran & Hubbard, 2001; Motoki, Marks, & Velasco, 2024; Liu & Lupyan, 2026) påvisar att det rör sig om konsekventa korrespondenser som delas av en bred majoritet av befolkningen.

Detta projekt skalar upp den inledande frågan: i stället för att fråga hur en enskild färg låter, undersöks hur en hel bild kan översättas till musik via sonifiering, där visuella attribut kopplas till associerade ljudparametrar. Resultatet av denna process är en algoritm som läser av en bild och genererar en musikalisk komposition. Arbetet drivs av en strävan att utmana ett traditionellt musikskapande och hitta nya sätt att komponera på, där bilden i sig själv är det musikaliska partituret.

Min ingång till projektet är förankrad i en bakgrund inom spelutveckling, där jag har läst en kandidatutbildning i spelmusik samt kontinuerligt varit delaktig i flertalet spelprojekt. Inom spelindustrin, eller tvärmodala medier överlag, så har jag alltid upplevt att musiken aldrig agerar i isolation, det är kombinationen av allting som händer samtidigt som resulterar i spelarens upplevelse. Musiken är ej något som fyller ut tystnaden, den har en funktion som interagerar med spelaren lika mycket som ens val av dialog, eller väg att gå. Denna utgångspunkt, att ljud och bild är i ständig kollaboration som en odelbar helhet, utgör fundamentet för att nu utforska den direkta översättningen mellan dessa två sinnen.

1.1 Syfte

Syftet med detta projekt är att utforska tvärmodala korrespondenser mellan bild och ljud som grund för musikkomposition via sonifiering. För att möjliggöra detta designas ett algoritmiskt instrument där analyserade bilddata kopplas samman med musikaliska parametrar utifrån tvärsensoriska principer. Genom att systematiskt översätta visuella egenskaper, i form av färg, ljushet samt komplexitet till ljud, undersöks konceptet att låta en bild fungera som ett direkt visuellt partitur. Den konstnärliga drivkraften bakom arbetet är att utmana traditionella metoder för musikskapande och praktiskt pröva hur syn och hörsel kan samverka. Målet är att skapa en sammanflätad upplevelse, där den genererade musiken och det visuella källmaterialet uppfattas som en gemensam ljudbild.

1.1.1 Frågeställningar

Utifrån det presenterade syftet så har projektet utformats för att utforska följande huvudfråga:

- **Hur påverkas mappningsprocessen utav samspelet mellan konstnärliga och tekniska val i utformningen av en sonifieringsmodell?**

För att konkretisera och besvara denna fråga så har även följande underfråga formulerats:

- **Hur kan färg, ljus och visuell textur från en bild översättas till musikalisk komposition via sonifiering?**

1.1.2 Avgränsningar

Detta projekt är avgränsat till följd av den valda metodologi och de resurser som funnits tillgängliga. Inom Research through Design sker kunskapsproduktionen genom designprocessen och reflektionen kring artefakten snarare än genom empirisk testning, vilket gör att detta projekt ej är en empirisk studie och ej inkluderar några egna användarstudier. Resursmässigt har bildanalysen avgränsats till fysiska och perceptuella mätvärden så som färgkoordinater, ljushet och entropi. Ingen semantisk objektigenkänning utförs då det skulle kräva omfattande kodimplementation samt testning som projektet ej innehaver i tid. Ytterligare, så utgår sonifieringen enbart från det mänskligt synliga färgspektrumet, vilket innebär att frekvenser utanför detta, så som nära infrarött ljus, exkluderas.

Resultatet av detta projekt, i form av kod och algoritm, är i första hand betraktade som fungerande prototyper för projektets teoretiska samt konstnärliga mål. De är designade för att svara till ett specifikt syfte och/eller behov, och är därmed ej fullt optimerad eller formad för

bruk av externa användare. För eventuell utomstående testning krävs det i nuläget en måttlig kunskap i miljön SuperCollider samt externt tillägg (skapad i samband med detta arbete), mer om detta i avsnitt 7.4.1.

1.2 Terminologi

I detta arbete ingår många tekniska termer som är kopplade till programmering, perception, sonifiering och kolorimetri. Nedan följer en lista med korta definitioner av relevanta termer samt begrepp som har en specifik betydelse inom projektets sammanhang. De är sorterade efter relevans samt användning.

Sonifiering: Översättning av data till icke-talat ljud med syfte att representera information via hörselsystemet. Ett sonifieringssystem syftar på hela processen från data till ljud, vilket innefattar flertalet olika typer av *mappningar*.

Mappning / att mappa: Den generella metod eller funktion som kopplar samman eller transformerar en eller flera inparametrar (enskilda mätbara värden, exempelvis ljushet eller mättnad) till en eller flera utparametrar (exempelvis volym eller diskant). Till skillnad från sonifiering, som är bundet till att resultatet blir ljud, är mappning ett generellt begrepp för att relatera parametrar till varandra oberoende av format eller syfte.

Absolut mappning: En mappning där kopplingen mellan in- och utparameter är fast och oberoende av kontext. Exempelvis genererar en specifik nyans av rött alltid samma exakta tonhöjd, oavsett vilka andra färger som finns i bilden.

Relativ mappning: En mappning där kopplingen anpassas i relation till andra närvarande mappningar. Samma röda nyans kan då generera olika tonhöjder beroende på vilka övriga färger som ingår i bilden.

Topologi: Strukturen för hur en mappning är uppbyggd, det vill säga hur många in- och utparametrar som ingår. Tre olika topologier används inom detta projekt: “One-to-one" innebär att en inparameter styr en utparameter; “One-to-many" innebär att en inparameter styr flera utparametrar; “Many-to-one" innebär att flera inparametrar tillsammans styr en utparameter.

Tvärmodala korrespondenser: De undermedvetna och konsekventa associationerna mellan olika sinnesintryck. Begreppet syftar på hur egenskaper inom ett sinne naturligt upplevs passa

ihop med egenskaper i ett annat sinne, exempelvis hur hög tonhöjd tenderar att associeras med ljusa färger.

Komplexa stimuli: Sinnesintryck som består av flera sammansatta attribut, exempelvis en bild eller ett musikstycke. Bearbetas främst som en kontextuell helhet snarare än som flertalet individuella sinnesintryck.

Entropi: Ett mått på hur jämnt informationen är fördelad i en bild. Entropi är synonymt till ’kaos eller oordning’, där hög entropi uppnås via blandade och varierade färger samt hög mängd kontrast, skärpa, brus och så vidare.

Centroid och **K-means clustering**: Den punkt som representerar ett färgklusters genomsnittliga position i en tredimensionell CIELAB-rymd. Centroiden hämtas via algoritmen K-means, vilket delar in datapunkter i ett bestämt antal kluster baserat på deras likhet. I detta projekt motsvarar varje färgklusters centroid en så kallad *röst* i sonifieringssystemet. *Röst* syftar på en enskild ljudinstans i sonifieringssystemet.

Perceptuell: Syftar på hur objektet i fråga upplevs, snarare än dess teoretiska förankring eller giltighet. Begreppet förekommer vid beskrivning av exempelvis mappningar eller vid utvärdering av ett ljud.

1.2.1 Kodexempel

I kapitel 4 (Utförande: Bildanalys) samt kapitel 5 (Utförande: Sonifiering) dyker det upp flertalet kodblock som är hämtade från de algoritmer som utvecklats under detta projekt. De är infogade för att demonstrera tekniken som utför bildanalysen och sonifieringen samt för att bidra med en djupare förståelse i projektets process.

De programmeringsspråk som används är Python för bildanalys och SuperCollider för sonifiering. Skillnaden mellan språken och dess syntax är synlig genom Pythons begränsade användning av symboler, medan SuperCollider ofta använder klamrar ’{}’, semikolon ’;’ och andra symboler. Kodblocken inleder med texten ’Kodblock’ följt av ett kapitelbaserat nummer vilket används som referens i den löpande texten (se Kodblock 1.1 samt 1.2 nedan). Inkluderat i respektive kodblock finnes även kommentarer, dessa är färgade i mörkgrönt och skrivs med ’#’ i Python eller ’//’ i SuperCollider. Nedan är exempel på kodblock i respektive språk.

Python:

Kodblock 1.1: Python Exempel

```python
# Detta är en kommentar i PYTHON
def rgb_image_to_lab(rgb):
cs = colour.models.RGB_COLOURSPACES['sRGB']
```

SuperCollider:

Kodblock 1.2: SuperCollider exempel

```
// Detta är en kommentar i SUPERCOLLIDER
SynthDef(\atmosGazer, {
  valEntropy = In.kr(entropyBus, 1).lag(2);
  input = In.ar(inBus, 2);
  });
```

2 Bakgrund

Detta kapitel redogör de teoretiska utgångspunkterna och tekniska ramverken för arbetet. Inledande är en genomgång av fenomenet tvärmodal korrespondens och viktiga begrepp som används för att strukturera sensorisk information. Därefter presenteras färgrymdsmodellen *CIELAB* och dess matematiska funktionalitet i koppling till mänsklig perception och *kromatisk adaption*. Vidare förklaras fältet *sonifiering* med särskilt fokus på *Parameter Mapping Sonification* och de system som styr det algoritmiska förhållandet mellan data och ljud. Avslutningsvis ges en översikt över sonifieringsverktyg och dess kategorisering, följt av en teknisk genomgång av arkitekturen och funktionaliteten i programmeringsmiljön *SuperCollider*.

2.1 Tvärmodal korrespondens

Tvärmodal korrespondens kan beskrivas som konsekventa associationer mellan attribut, dimensioner eller egenskaper över olika sinnen (Motoki et al., 2024). Dessa associationer kan exempelvis vara relationen mellan tonhöjd och storlek, där högre tonhöjd tenderar att associeras med små objekt och vice versa. Tvärmodal korrespondens syftar på att beskriva hur olika sinnen tolkar grundläggande egenskaper hos stimuli och att det finns systematiska associationer mellan dem. Till skillnad från synestesi, som är ett liknande neurologiskt fenomen, så är dessa korrespondenser delat av en stor majoritet av människor.

2.1.1 Attribut, dimensioner samt egenskaper

De centrala begreppen som används för att precisera vad som sammankopplas mellan olika sinnen är enligt Motoki et al. (2024) *attribut, dimension* samt *egenskap*. Dessa begrepp syftar på att kategorisera den sensoriska informationen utifrån ‘var’ den kommer ifrån och dess perceptuella komplexitet. *Dimension* beskriver det spektrum som ett sinnesintryck befinner sig inuti och kan förklaras som en form av mätvariabel. Den består av två typer: Kvantitativ, och Kvalitativ. En kvantitativ dimension mäter magnitud eller intensitet (’hur mycket’), vilket innebär att det som mäts kan rangordnas på en skala: exempelvis storlek, ljusstyrka, temperatur eller längd. En kvalitativ dimension ämnar i stället att definiera skillnader i karaktär eller typ (’vilken sort’). Detta innebär att den kvalitativa dimensionens värden ej nödvändigtvis kan rangordnas, utan utgör olika ‘identiteter’ i form av exempelvis färgton eller sött/salt.

Attribut samt *egenskap* (original: feature) används för att beskriva själva innehållet i dessa dimensioner. Ett attribut är en singulär beståndsdel som ett sinnesintryck kan innehålla, medan egenskap är själva fenomenet som våra hjärnor upplever av, bland annat, dessa attribut. *Egenskaper* benämns däremot i form av en underkategorisering som kallas låg- och högnivåegenskap, detta för att understryka på vilken kognitiv nivå som sinnesintrycket upplevs. En egenskap på lägre nivå består av ett enskilt attribut som ensam utgör en upplevelse, medan en hög nivå är helheten av flertalet attribut eller andra intryck som tillsammans utgör en upplevelse (Motoki et al., 2024). Tonhöjd, som exempel, skulle klassificeras som en lågnivåegenskap som består utav ett enskilt attribut. Detta för att vi ej kan bryta ned tonhöjd i mindre perceptuella element, utan den står enskilt som det sinnesintryck som hjärnan tolkar. Ett högnivåexempel kan då vara musik, som består av flertalet tonhöjder, men också en eventuell mängd av andra intryck så som rytmik, dynamik och text. Hjärnan tolkar ej dessa attribut var för sig i isolation, utan de bildar en sammansatt helhet som i sin tur utgör en upplevelse.

2.1.2 Tvärsensorisk mappning

Tvärsensorisk mappning syftar på principerna för *hur* hjärnan kopplar samman ett specifikt tillstånd hos en egenskap i ett sinne med ett motsvarande tillstånd i ett annat sinne. Walker & Walker (2016) förklarar att den tvärsensoriska mappningen av dessa tillstånd kan agera antingen *absolut* eller *relativt*, vilket i sin tur försöker definiera på vilken kognitiv nivå hjärnan bearbetar informationen. Absolut Mappning utgår från fasta, oberoende mätvärden hos en egenskap, vilka översätts direkt till ett specifikt värde hos en annan egenskap. Denna typ av mappning associeras främst med tidiga, sensorisk-perceptuella processer på låg nivå, alltså det första steget i hjärnans sinnesbearbetningsprocess. Walker & Walker argumenterar dock för att absolut mappning sällan är helt isolerad från sin relativa motsvarighet, utan ser ofta samverkan, beroende på associationen i fråga. Relativ mappning agerar i teorin som en kontextberoende motpol till den absoluta, där översättningen är dynamisk och ständigt anpassas utifrån vilka andra värden och stimuli som är närvarande. Denna typ av mappning kopplas till en konceptuell associationsnivå, som i förlängning innebär att den kräver en högre grad av kognitiv bearbetning, där *relationer* och *skillnader* mellan sinnesintryck är det som hjärnan tolkar och översätter.

2.2 CIELAB

CIELAB är en färgrymdsmodell som togs fram år 1976 av *Commission Internationale de l'Éclairage* (CIE), vilket är ett internationellt organ som ansvarar för standardisering inom färg och belysning. [1] CIE har delvis etablerat en vetenskaplig bas för att mäta färg och förutsäga färgmatchning, men jobbar också mot att ta fram modeller/metoder som är mer anpassade utifrån den mänskliga perceptionen utav färg, konträrt till enbart enhetsspecifika parametrar (RGB). Problematiseringen som CIE angriper är att numeriska färgvärden utan kontext ej kan förutsäga den mänskliga upplevelsen. För att motverka denna variabel så har 'Colour Appearance Models' (CAM) tagits fram, vilket kan, via inkluderingen av attributen ljushet (lightness), kroma (chroma) och färgton (hue), matematiskt beskriva färgers perceptuella utseende under varierande förhållanden (Fairchild, 2013). Dessa attribut är en del av de mekanismer som utgör 'kromatisk adaption', vilket är människans visuella systems förmåga att justera sin känslighet beroende på belysningens färg. Fairchild beskriver det som "*The term chromatic adaptation refers to the human visual system's capability to adjust to widely varying colors of illumination in order to approximately preserve the appearance of object colors.*" (2013, s. 156). Vidare förklarar han att detta är anledningen till att man uppfattar ett vitt papper som "vitt" både i blåaktigt dagsljus och i gulaktigt lampljus, då ögat kompenserar bort färgen från ljuskällan.

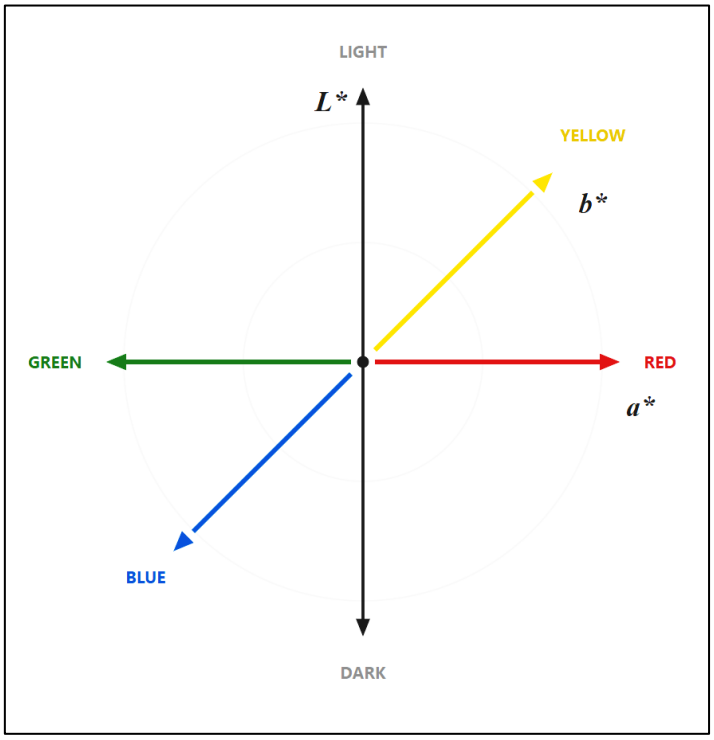
CIELAB togs fram som ett steg mot en mer avancerad kolorimetri (vetenskapen om färgmätning), men betraktas som en förenklad CAM då den använder simplare uträkningar av de tidigare nämnda attributen. Oavsett, så har denna modell sett mest universal användning inom mätningen av färgdifferans (Fairchild, 2013). CIELAB definieras utifrån dess användning av tre olika axlar: L*, a* samt b*. Dessa axlar utgår från opponentfärgteorin (opponent-colors theory) som baseras utifrån att det mänskliga seendet bearbetar färg i motsatspar. Enligt Fairchild härstammar denna teori från observationer gjorda av Ewald Hering under sent 1800-tal, vilka bygger på argumentet att människan ej kan uppfatta vissa färgkombinationer samtidigt:

> Hering noted that certain hues were never perceived to occur together. For example, a color perception is never described as reddish-green or yellowish-blue, while combinations of red and yellow, red and blue, green and yellow, and green and blue are readily perceived. This suggested to Hering that there was something fundamental about the red–green and yellow–blue pairs causing them to oppose one another. (Fairchild, 2013, s. 19)

[1] https://cie.co.at/

De tre axlarna i CIELAB utgår från samma logik, där motsatsparen utgör var sin axel (se Figur 1 nedan):

L* = ljushet på en skala från 0 (svart) till 100 (vitt).
a* = Representerar grönt (negativt värde) till rött (positivt värde).
b* = Representerar blått (negativt värde) till gult (positivt värde).



Figur 1: Graf över L* a* b* axlarna och dess representerade färger

En central egenskap hos CIELAB är strävan efter perceptuell enhetlighet. Modellen beräknas genom att ställa en färgs värden (X, Y, Z) i relation till en specifik referensvitt (skriven som X_n, Y_n, Z_n). Dessa värden kommer från en annan färgrymdsmodell (CIEXYZ) som CIELAB använder som referens, vilket fungerar, i kontrast till RGB, som en internationell enhetsoberoende standard för ögats ljusregistrering. Denna beräkning fungerar som en förenklad form av kromatisk adaption, då den efterliknar ögats anpassning av färgupplevelse utifrån omgivningens ljuskälla. Genom denna anpassning placeras värdena som kartesiska koordinater (L*, a*, b*) i en tredimensionell rymd. Detta öppnar upp för direkta matematiska korrelationer mellan det euklidiska avståndet mellan två punkter och den mänskligt uppfattade färgskillnaden (Fairchild, 2013).

2.3 Sonifiering

Hermann, Hunt & Neuhoff definierar Sonifiering som "*..the data-dependent generation of sound, if the transformation is systematic, objective and reproducible...*" (2011, s. 9), vilket innefattar att transformera relationer i data till ljud, där relationen är förståbar. Sonifiering syftar på själva algoritmen som utför arbetet mellan data, användaren och det resulterande ljudet (Hermann, 2008), och är i förlängning en del av forskningsfältet 'Auditory Display' som behandlar alla tekniker där ljud används för att medla information till en användare. Vidare, förklarar Hermann (2008), för att sonifiering skall få klassificeras som *vetenskaplig* så måste det uppfylla fyra krav som består av:

1. Ljudet skall reflektera objektiva egenskaper eller relationer i indatan.
2. Översättningen mellan data och ljud skall vara systematiskt definierad.
3. Det resulterande ljudet behöver vara strukturellt identiskt vid repeterad inmatning av samma data och interaktion.
4. Systemet skall kunna användas med olika datamängder, samt även upprepat med samma data.

Även om sonifiering traditionellt har definierats som ett vetenskapligt verktyg för objektiv dataanalys så argumenterar Barrass & Vickers (2011) för metodens estetiska och konstnärliga potential. De föreslår att sonifieringens definierande egenskap skall vara 'pragmatisk informationsestetik', vilket innebär en praktik som kombinerar funktionaliteten från ren informationsdesign med den konstnärliga känsligheten från ljudkonst. Denna definition härstammar från diskussioner angående gränsen mellan funktionellt syfte och estetisk upplevelse, där Barrass & Vickers belyser hur datadrivna verk kan sträcka sig förbi ren informationsdesign. Medan det funktionella syftet ofta är att generera analytisk insikt kan sonifiering i stället fungera fullt konstnärligt, där värdet uteslutande ligger i den estetiska upplevelsen.

En av de mest etablerade teknikerna inom sonifiering är Parameter Mapping Sonification (PMSon), vilket bygger på en mappningsfunktion som kopplar specifika dimensioner i en datamängd till specifika auditiva parametrar (Hermann et al., 2011, s. 363). I praktiken innebär detta att indatan delas in i ett bestämt set av parametrar, som i sin tur styr specifika parametrar i utdatan. Dessa mappningar kan utföras på olika sätt, samt på olika nivåer av komplexitet, men Hermann et al. hävdar att fokuset bör ligga på att finna en

mappningstopologi som uttrycker den perceptuella upplevelsen effektivast. Dessa topologier består utav:

- **One-to-one mapping:** Datadimensioner sorteras efter informationsinnehåll som sedan överförs till respektive synteskanal innehållande en liknande andel perceptuell saliens (sorterad efter dess perceptuellt upplevda nivå).

- **One-to-many mapping:** En datadimension styr flertalet parametrar samtidigt. Detta kan effektivt skapa en större märkbar effekt på ljudet, även fast parameterförändringarna är små.

- **Many-to-one mapping:** Flertalet datadimensioner samverkar för att styra en singulär ljudparameter. Kan vara användbart för att skapa en mer komplex ljudkaraktär, men blir även svårare att isolera vad varje datadimension uttrycker individuellt.

2.3.1 Sonifieringsverktyg

För att sonifiering skall kunna utföras, eller realiseras, så krävs det en teknisk miljö som kan hantera hela processen ‘data-till-ljud'. Ett effektivt sonifieringsverktyg ämnar uppfylla de tidigare nämnda teoretiska kraven: systematiskt, objektivt och reproducerbart, med mål att ge utrymme för utforskning samt utvärdering (Hermann et al., 2011). Dessa miljöer kategoriseras ofta utifrån ett spektrum mellan flexibilitet och tillgänglighet, där hög flexibilitet innebär maximal kontroll samt möjlighet för skräddarsydda system, och tillgänglighet prioriterar användarvänlighet men ofta begränsade till specifika användningsområden. Detta, så kallade spektrum (Phillips & Cabrera, 2019), syftar på generella programmeringsspråk (C++, Python) som flexibla och dedikerade applikationer med grafiska gränssnitt (xSonify, Sonification Sandbox) som tillgängliga. I mitten av detta spektrum befinner sig dock de populäraste sonifieringsverktygen: domänspecifika språk (DSL). Dessa kan beskrivas som en balansgång mellan flexibilitet och tillgänglighet, där full kontroll över system går att uppnå, samtidigt som att man använder ett skräddarsytt programmeringsspråk som erbjuder stor effektivitet vid utförandet av sonifieringen.

SuperCollider (SC), ett av de populäraste DSL-verktygen, är en miljö och ett programmeringsspråk för algoritmiskt skapande och realtids-ljudsyntes.[2] Systemet är

[2] https://supercollider.github.io/

utvecklat för att hantera komplexa ljudprocesser med så hög precision som möjligt, samtidigt som det är fullt modifierbart via öppen källkod och en engagerad användarbas.

Arkitekturen bakom SC är uppbyggd via en klient och en server som kommunicerar med varandra. Servern (kallad ‘scsynth’) står för ljudgenerering och signalprocessering, och klienten (som i förlängning är själva språket, ‘sclang’) är miljön som användaren programmerar inuti. Klienten och servern kommunicerar via ett nätverksprotokoll som heter Open Sound Control (OSC) vilket bidrar till att flertalet klienter kan vara uppkopplade till samma server utan diverse tredjepartstillägg, samtidigt som att systemet behåller en systematisk precision och reproducerbarhet vilket är ett krav för sonifieringen (Hermann, 2008). De komponenter som utgör det grundläggande ljudskapandet i SC är Unit Generators (UGens) samt Synth Definitions (SynthDefs):

- **UGens**: Detta är grunden för all ljudprocessering som sker på servern. UGens genererar och/eller bearbetar ljud- eller kontrollsignaler i realtid. Dessa fungerar som moduler i en synth, där varje specifik UGen kontinuerligt utför en egen matematisk uträkning eller process. Dessa processer utgår från en förutbestämd beräkningshastighet som vanligtvis består av antingen Audio Rate (ar) för högupplösta ljudsignaler, eller Control Rate (kr) för kontrollsignaler. Skillnaden på dem är att ‘ar’ opererar vid systemets samplingshastighet, exempelvis 44.1 kHz, och ‘kr’ utförs mer sällan, vanligtvis var 64:e sampling. Detta möjliggör en balans mellan hög precision och effektiv resursanvändning. Exempel på UGens kan vara en oscillator för ljudgenerering (ar) eller en envelope/LFO som styr parametrar över tid (kr).

- **SynthDefs**: Detta är definitionen av instrumentet, bestående av UGens, som skickas från klienten för att lagras i servern. Det är här som argument (variabler) definieras, vilket är ingången för externa data. Fördelen med SynthDefs är att de definierar diverse argument vid skapandet av instrumentet samtidigt som att argumentens värden är modifierbara när man spelar upp dem. Detta medför en effektiv resurshantering eftersom hårdvaran kör en färdigkompilerad algoritm och endast behöver uppdatera de specifika värden som ändras i realtid.

3 Metod

För att besvara projektets frågeställningar tillämpas metodologin Research through Design (RtD) (Zimmerman et al., 2007). Metodologin, som ursprungligen formulerats av Frayling (1993), kännetecknas av en iterativ process där teoretiskt förarbete, teknisk implementation och utvärdering integreras för att utveckla och designa en artefakt. I detta projekt utgörs artefakten av ett sonifieringssystem, vilket fungerar som ett algoritmiskt instrument som genererar en musikalisk komposition. RtD tillämpas eftersom forskningsfrågan förutsätter en metod där det konstnärliga uttrycket och den tekniska utvecklingen av en algoritm samverkar som analytiska element. Enligt Zimmerman et al. (2007) genereras kunskap inom denna metodologi primärt genom själva designprocessen och reflektionen kring den framtagna artefakten. I detta projekt operationaliseras detta genom en systematisk cykel som består av att konstruera algoritmen, utvärdera mot etablerad teori samt det egna konstnärliga omdömet, och därefter justera koden. Inom denna ram utgör sonifiering den primära metoden för att praktiskt testa teorier inom tvärmodala korrespondenser.

Eftersom den iterativa designprocessen inom RtD till stor del är utforskande och kontextbunden struktureras dokumentationen utifrån metoden *annotated portfolio* (Gaver & Bowers, 2012). Genom en forskningsdagbok kontextualiseras designval kring artefaktens utveckling, där tekniska problem, konstnärliga beslut och perceptuella utvärderingar antecknas efter varje iteration. Iterationerna följer en systematisk cykel bestående av tre faser: **förarbete**, där det teoretiska ramverket och konceptuella förberedelser formuleras; **implementation**, där ramverket operationaliseras i kod; samt **utvärdering**, där det genererade ljudet granskas mot det teoretiska designramverket och det egna konstnärliga omdömet. Identifierade brister återförs till förarbetesfasen och driver nästa iteration framåt.

Forskningsdagboken analyseras för att spåra arbetets viktiga iterationsmoment, specifikt situationer där spänningar mellan ett konstnärligt och tekniskt val har uppstått. Dessa moment grupperas sedan utifrån deras omfattning, från specifika designval inom en enskild fas till moment som i efterhand visat sig påverka projektets riktning. De specifika designvalen presenteras i respektive utvärderingsavsnitt 4.3 samt 5.3, medan de större momenten presenteras i avsnitt 6.2 (Resultat): **Viktiga iterationsmoment**.

Som ett komplement till den skriftliga redovisningen arrangeras ett urval av artefaktens genererade kompositioner till ett sammanhängande audiovisuellt musikstycke (titulerat ’*Gazing’)*. Arrangeringen utgår från en dramaturgisk kurva där bildernas kontrasterande

egenskaper styr ordning och dynamik, med syfte att demonstrera instrumentets fulla omfång. Detta för att möjliggöra en direkt koppling mellan varje bilds visuella egenskaper och dess sonifiering, vilket är centralt för att förstå instrumentets funktion.

3.1 Urval av visuellt material

Det visuella materialet som presenteras i detta projekt är ett urval av de bilder som används för utvecklingen av bildanalysalgoritmen. Urvalet är motiverat utifrån projektets syfte samt avgränsningar, där variation i form av färgnyans, ljushet, informationsdensitet samt mättnad är prioriterat. Dessa är de primära parametrarna som algoritmen analyserar. Vidare, i enlighet med projektets avgränsningar gällande semantisk objektigenkänning, har specifika fysiska objekt och tydligt föreställande motiv exkluderats. Fokuset har i stället befunnit sig i abstrakta och strukturella bilder för att säkerställa att algoritmen enbart utvärderar utifrån färgegenskaper samt perceptuella mätvärden, i stor del oberoende av bildens eventuellt kontextuella betydelse.

3.2 Etiska överväganden

Projektet utgör konstnärlig forskning och omfattas ej av etikprövningslagen, men följer principerna för god forskningssed som presenteras av Vetenskapsrådet (2024) gällande tillförlitlighet, ärlighet, respekt och ansvar. Det förekommer inga externa samarbeten eller undersökningar med människor. Samtliga bilder som används inom projektets ramar ingår inom en ’Free to Use’-licensering. Varje bild har även en infogad fotnot med direktlänk till källan. Generativ AI har använts i enlighet med KMH:s riktlinjer för studenter gällande användning av generativ AI. *Claude* och *Gemini* har använts som stöd gällande grammatik, strukturella förslag och/eller stavningskontroll under den skrivande processen. Under kodimplementeringen har *GitHub Copilot* använts, vilket är integrerat i Visual Studio Code, för felsökning samt verifiering av kodlogik.

4 Utförande: Bildanalys

Utförandets disposition är utformad för att systematiskt presentera den iterativa designprocessen. Detta kapitel redogör för den första fasen i systemets utveckling: **bildanalys**. Syftet med denna fas är att extrahera och strukturera visuella egenskaper från en bild och sedan paketera det inför sonifiering.

För att tydliggöra hur arbetet har rört sig mellan teori, kodning och utvärdering är kapitlet strukturerat i tre underkategorier som speglar Research through Design-metodens kretslopp:

- **Förarbete**: Redogör för det teoretiska ramverket och de konceptuella förberedelserna kring dataurvalet.
- **Implementation**: Förklarar operationaliseringen av ramverket och den tekniska utvecklingen av analysskriptet i Python.
- **Utvärdering**: Utgör den primära analysen av fasen, där extraherade data kritiskt granskas utifrån sin perceptuella relevans för att vägleda nästa iteration.

4.1 Förarbete: Visuell tolkning samt dataurval

För att extrahera relevant information från bilder så behövdes ett dataurval som speglar den mänskliga perceptionen av färg. Av den anledningen valdes färgrymdsmodellen CIELAB, som beskriver färg i en tredimensionell rymd och anpassad för hur färger reflekteras i olika förhållanden utifrån den mänskliga perceptionen. Funktioner som bidrar till detta är bland annat modellens matematiska förmåga att efterlikna kromatisk adaption, som syftar på det mänskliga visuella systemets förmåga att justera ögats känslighet utifrån omgivningens belysning. Ytterligare, så är kroma (C*) ett centralt attribut i rymden, som definierar färgens intensitet i relation till en neutral gråskala. Kroma symboliseras även matematiskt med det euklidiska avståndet mellan punkterna a* och b* (respektive färgaxel, grön - röd och blå - gul), vilket skall korrelera med den färgskillnaden ögat faktiskt uppfattar.

Till skillnad från konventionell RGB så är den största fördelen med CIELAB att modellen isolerar ljushet (L*) från färgkoordinaterna (a* och b*), i enlighet med opponentsfärgseende (Fairchild, 2013). Denna separering gör det möjligt att mycket mer effektivt och precist extrahera data kring bildens form, djup och textur, vilket är egenskaper som primärt bygger på variationer i ljus och skugga, oberoende av färg.

Vidare konstruerades ett konceptuellt ramverk för vilka attribut samt egenskaper som skulle analyseras utifrån denna data. Syftet var att fånga en helhet av bilden, och samtidigt begränsa icke-perceptuell, eller 'osynlig' data. Dessa delades in i tre grupperingar:

1. **Kolorimetri**: Bildens specifika färgkoordinater, ljushet och kroma. Här är största beståndsdelen av synliga attribut.

2. **Luminansstruktur**: Egenskaper i form av kontrast, skärpa och visuellt brus (noise), som enbart hämtas ur ljusdimensionen (L*).

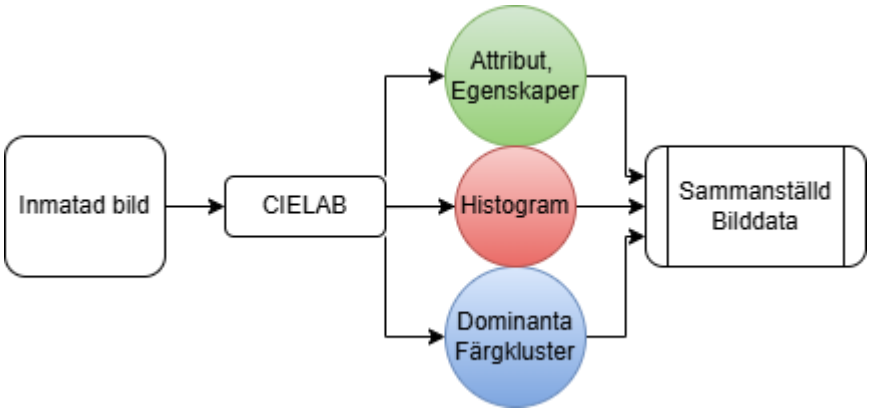
3. **Komplexitet**: Egenskaper i form av bildens övergripande detaljrikedom, komplexitet och variation. Vidare definierat som 'entropi'.

Följt av ramverkets definition, som bestod av 'vad', så gick arbetet vidare mot 'hur' data skall hämtas. Ett tidigt försök till detta var att beräkna ett färggenomsnitt av alla pixlar i en bild, men då det ej överensstämmer med den mänskliga upplevelsen så övergavs denna metod. För att algoritmen skall kunna efterlikna mänsklig perception så användes därav 'lokal adaption' (Fairchild, 2013) som utgångspunkt. Lokal adaption handlar om hur perceptionen anpassas efter lokala färgfält i komplexa stimuli. Det innebär att en specifik röd färg ej upplevs likadant överallt i bilden, utan att upplevelsen påverkas av den närmaste omgivningen. Detta ledde vidare till att använda färgkluster som huvudsaklig mätning, där de mest frekventa och dominanta lokala färgnyanserna tas ut och tilldelas en proportionell vikt baserat på hur stor andel av bildytan de utgör.

4.2 Implementation: Python

För att operationalisera det konceptuella ramverket och extrahera data så utvecklades ett analysskript i programmeringsspråket Python.[3] Koden bygger på en så kallad sekventiell pipeline, vilket innebär en strukturerad och linjär process där utdata från en rutin blir indata till nästa. Detta händelseförlopp består utav att mata in en bild, konvertera RGB till CIELAB-värden, gruppera visuella attribut och sedan sammanställa dem (Figur 2). Den utnyttjar även olika etablerade bildbehandlingsbibliotek så som 'scikit-image', 'scikit-learn' samt 'colour-science'.

[3] https://www.python.org/



Figur 2: Skiss över händelseförloppet i 'Bildanalys'

Pipelinen är indelad i flera steg, där det första består av att konvertera en inmatad bilds RGB-värden till färgrymden CIELAB. Som tidigare behandlat i **Bakgrund** så består denna process av RGB till CIE XYZ (i relation till ett referensvitt (X_n,Y_n,Z_n) till L*a*b*. Detta resulterar i att varje pixel nu har en plats på färgaxlarna a* och b* samt en definierad ljushet via L*. Denna konvertering utförs via biblioteket colour-science (kodblock 4.1).

Kodblock 4.1: Konvertering via colour-science

```
def rgb_image_to_lab(rgb):
  cs = colour.models.RGB_COLOURSPACES['sRGB']

  # Konvertera RGB till XYZ med sRGB referensvitt
  xyz = colour.RGB_to_XYZ(
    rgb,
    colourspace=cs,
    illuminant_RGB=cs.whitepoint,
    illuminant_XYZ=cs.whitepoint
  )
  # Konvertera XYZ till CIELAB
  lab = colour.XYZ_to_Lab(xyz, illuminant=cs.whitepoint)
  return lab
```

Steg två är att identifiera bildens dominanta färgfält (se kodblock 4.2 nedan). Detta bearbetas via maskininlärningsalgoritmen K-Means som grupperar pixlarna i ett förutbestämt antal kluster baserat på det minsta euklidiska avståndet mellan färgerna i L*a*b*-rymden.

Kodblock 4.2: Hämta kluster

```
# Applicera K-Means på lab_flat (a* och b* axlarna)
km = KMeans(n_clusters=k_eff, random_state=0, n_init=10).fit(lab_flat)

# Hämtar klustrens centralpunkter (Centroids) och etiketter
cents = km.cluster_centers_
labels = km.labels_
```

Vidare, för varje kluster så beräknas en centralpunkt (Centroid) som representerar fältets mest dominanta färg (kodblock 4.3). Utifrån centralpunkten så beräknas därefter färgton (hue) samt kroma (C*), därefter räknas antalet pixlar som utgör varje kluster för att definiera dess proportionella vikt (weight).

Kodblock 4.3: Hämta centroid, hue och kroma

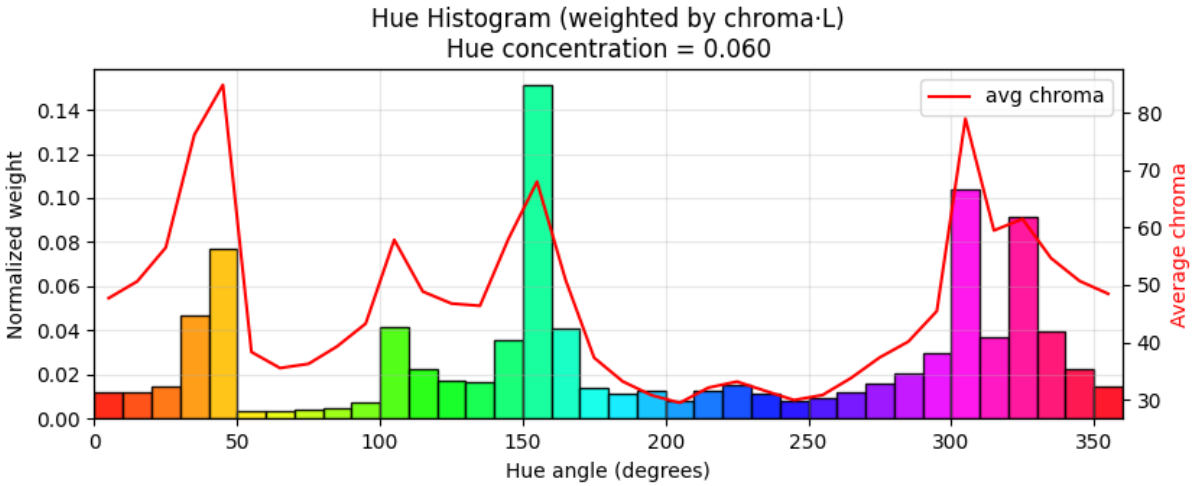
```
# Beräkna antalet pixlar per kluster för vikt
counts = np.bincount(labels, minlength=k_eff)
weights = counts / counts.sum()

# Applicera beräkning av hue och chroma för varje centroid
for i in range(k_eff):
    Lc, ac, bc = cents[i]

    # Cirkulär beräkning av färgton (0-360 grader)
    hue = (np.degrees(np.arctan2(bc, ac)) + 360.0) % 360.0

    # Chroma via pythagoras (euklidiska avståndet från mitten)
    chroma = float(np.hypot(ac, bc))
```

Utöver K-means så analyseras även bildens övergripande färgdistribution genom ett viktat histogram (se Figur 3 nedan). Eftersom färgtoner definieras i grader (0-360°) så går det ej att använda ett medelvärde för denna uträkning, i stället vägs varje pixel utifrån kroma och ljushet. Histogrammet består av 36 stycken vikter (staplar) som individuellt representerar färgdistributionen i form av 10° på färgcirkeln.



Figur 3: Histogramexempel med staplar i respektive färgrepresentation

Det tredje steget består av att isolera ljusdimensionen (L*) för att analysera bildens övergripande egenskaper och komplexitet (kodblock 4.4). Detta steg använder scikit-image samt SciPy biblioteken för att beräkna kontrast, skärpa och entropi. Kontrast definieras genom ljusvärdenas standardavvikelse och skärpa identifieras genom att lägga på ett 'Laplace-filter' som mäter variansen av snabba ljusförändringar. Laplace-filter fungerar likt ett high-pass filter som letar efter kanter via aggressiva förändringar i ljushet.[4] Entropi beräknas via 'Shannon entropy' som kvantifierar det genomsnittliga informationsvärdet i varje pixel och vidare illustrerar bildens helhetliga oförutsägbarhet.

Kodblock 4.4: Hämta data ur L*

```
# Isolerar ljusdimensionen (L*)
L_image = lab[:,:,0]
gray_uint8 = np.clip((L_image / 100.0) * 255.0, 0, 255).astype(np.uint8)

# Kontrast via standardavvikelse
rms_contrast = float(np.std(L))

# Entropi samt skärpa (via Laplace-varians)
ent = float(shannon_entropy(gray_uint8))
lap = ndimage.laplace(gray_uint8.astype(float))
var_lap = float(np.var(lap))
```

[4] Laplace-filter kan även fånga upp texturer och kornighet i bilder, vilket kan resultera i att suddiga, men texturrika, bilder har ett högre skärpvärde. Värt att ha i åtanke vid tolkning av enskilda mätvärden.

Slutligen sammanställs och struktureras all extraherad data inuti en JSON-fil (JavaScript Object Notation), samt en bifogad csv-fil med centralpunkterna (Centroids), vilket utgör underlaget för sonifieringen.

4.3 Utvärdering: Bildanalys

Utvärderingen av bildanalysen skedde löpande under utvecklingen av Pythonkoden, där det primära fokuset var att säkerställa att extraherade data var perceptuellt relevant, men likaså tillräckligt individuell för att ej överflöda antalet parametrar som hämtades. Av denna anledning så delades data in i olika grupper (kolorimetri, luminansstruktur och komplexitet) för att överskådligt separera attribut från egenskaper, men likaså för att tydligt kartlägga *varifrån* den hämtas från. Argumentet bakom detta bestod av att skapa en pedagogisk tydlighet kopplat till Motoki et al.:s (2024) beskrivning av stimuli och dess dimensioner. Ytterligare, så medförde grupperingen en mer praktisk lösning vid den kommande översättningen till ljud, då ljudparametrar kunde grupperas på ett motsvarande vis för att etablera ett makro- samt mikroperspektiv på mappningen.

De specifika mätvärden som valdes utgick primärt från CIELAB:s kapacitet och styrkor, vilket delvis består av beslutet att använda kroma (C*) snarare än mättnad (eng. Saturation). En tidig teoretisk iteration som utvärderade mättnad för att styra färgintensitet visade sig bli otydlig i relationerna mellan olika färgnyanser. Detta beror på att mättnad definierar en färgs intensitet enbart i proportion till dess egen ljushet, vilket skapar mätvärden som ej uttrycker intensitet i relation till bilden, i stället enbart till en specifik punkt. Den resulterande mättnaden kunde därav indikera att fyra olika färgområden hade samma intensitet, oberoende av vilken faktisk färg de bestod av, vilket blev motsägande gentemot opponentfärgsteorin som detta projekt samt CIELAB utgår från.

5 Utförande: Sonifiering

Detta kapitel behandlar den andra och avslutande fasen i systemets utveckling: sonifiering. Syftet med sonifieringen är att översätta extraherade bilddata till en tvärsensoriskt associerad ljuddomän, i enlighet med tvärsensorisk mappning (Walker & Walker, 2016) och PMSon (Hermann et al., 2011) för att till slut generera en musikkomposition.

Likt föregående kapitel struktureras processen utifrån tre iterativa underkategorier för att tydliggöra designbesluten:

- **Förarbete**: Beskriver strategin bakom tvärsensorisk mappning och hur systemets mikro- och makroparametrar planerades.

- **Implementation**: Redogör för uppbyggnaden av ljudmotorn och den algoritmiska sequencern i programmeringsmiljön SuperCollider.

- **Utvärdering**: Reflekterar över och analyserar hur väl de genererade ljuden perceptuellt och tvärmodalt representerar det visuella källmaterialet, vilket utgör grunden för slutresultatet.

5.1 Förarbete: Mappningsstrategi

Sonifieringen i detta arbete bygger på Parameter Mapping Sonification (Hermann et al., 2011), där specifika datadimensioner kopplas systematiskt till akustiska parametrar. Detta tillämpas med tvärmodala korrespondenser som designramverk, med syfte att koppla samman den mänskliga upplevelsen av färg och andra visuella attribut till en tvärmodalt associerad ljuddomän. Litteraturen som utgör projektets teoretiska ramverk beskriver dock sällan specifika effekter eller tekniker inom musikproduktion som tvärmodala associationer, utan snarare abstrakta dimensioner så som intensitet, skärpa eller ljushet. Mappningsstrategin utgår således delvis från forskarens eget designomdöme, där mer generella korrespondenser tolkats i konkreta produktionstekniska riktningar. Mappningarnas teoretiska förankring varierar därmed i precision, från konkreta belägg till konstruerade associationskedjor. Detta ramverk är designat i första hand för komplexa stimuli (bilder), vilket innebär att den perceptuella helheten är överordnad individuella och isolerade stimuli. Detta likt logiken i CIELAB, där färgdifferans samt de spatiala relationerna utgör grunden för beräkningen av färgspektrumet.

Regelverket för mappningen utgår från parametrar på mikro- samt makronivå, där mikroparametrar står för individuella akustiska signaler eller funktioner, och makroparametrar påverkar mastersignalen. Vidare, så tillämpas en variation av mappningstopologier definierat inom PMSon, delvis för att undvika strama och linjära översättningar men även för att återspegla egenskaperna i respektive stimuli. Detta innebär en kombination av att låta specifika data styra enskilda funktioner, samtidigt som mer komplexa data tillåts konvergera eller divergera för att tillsammans påverka större sammanhang.

5.1.1 Mikroparametrar

Resultatet av bildanalysens K-means-algoritm genererade åtta dominanta färgpunkter (centroids).[5] Dessa allokeras till var sin oberoende syntesröst inuti SuperCollider.[6] Detta innebär att en bild representeras av åtta samverkande röster, där varje rösts egenskaper i form av bland annat tonhöjd, intensitet samt textur dikteras av dess specifika koordinater i CIELAB-rymden enligt följande mappningsstruktur:

- **Ljushet (L*) --> Tonhöjd**: *Röstens 'pitch'*.
  Översätts exponentiellt inom ett frekvensspann på 60 Hz till 2000 Hz. Detta grundas teoretiskt från den etablerade tvärmodala korrespondensen där visuellt mörka objekt uppfattas tunga (låga frekvenser), och ljusa objekt korrelerar med lätthet (höga frekvenser) (Marks, 1987).

- **Kroma (C*) --> Amplitud och modulering**: *Röstens volym samt modulering.*
  Kroma styr intensiteten av varje röst, där den rösten med högst kroma låter mest samt får en adderad 'detuner'-effekt. Relationen baseras på att en hög färgintensitet korrelerar med hög ljudintensitet (Spence, 2011).[7]

- **Grön-röd axel (a*) --> Distorsion och övertonsmättnad**: *Relationer i klangfärgens karaktär*.
  Mappningen utgår från en konstruerad associationskedja, bestående av perceptuell intensitet som gemensam nämnare. Färgen röd associeras med hög energi (Valdez & Mehrabian, 1994), och distorsionsliknande kvaliteter i ljud associeras med hög

[5] Antalet kluster bestämdes till åtta som en avvägning mellan rimlig upplösning och resurshantering. Färre kluster riskerar att förbigå meningsfull färgvariation, medan fler röster riskerar att inkludera färger som är knappt synliga.

[6] 'Syntesröst' samt 'röst' används som namn för algoritmens genererade instrument och det ljud den skapar.

[7] Likt den mer generella korrespondensen 'magnitude matching' (Liu & Lupyan, 2026), men Spence (2011) visar på en mer specifik korrelation mellan färg- och ljudintensitet.

perceptuell energi (Arnal et al., 2015). Vid grön sida av axeln tillämpas ett filter som dämpar övertoner samt transformerar ljudvågen mot en ren sinusvåg, som ett kontrasterande moment.

- **Blå-gul axel (b*) --> Spektral ljushet**: *Filtrering av frekvensinnehållet via lågpassfilter.*
  Baserat på fenomenet "Kiki/Bouba" (Ramachandran & Hubbard, 2001) kombinerat med tvärmodal forskning kring färg och formkorrespondenser (Adeli et al., 2014). Gult spektrum, associerat med skarpa och kantiga former (Kiki), behåller vassa frekvenser, medan det blå spektrumet, kopplat till dova och runda former (Bouba), filtrerar bort höga frekvenser för att skapa en mjukare klang.[8]

- **Färgvinkel (h°) och weight --> Panorering och mixbalans**: *Spatial placering och yta*.
  Färgvinkeln, som består av en punkt i en cirkulär graf (360 grader), bestämmer röstens placering i stereobilden. Sedan avgör färgklustrets procentuella yta i bilden (weight) röstens mixbalans i förhållande till resterande röster. Detta är baserat på korrelationen mellan storlek och 'loudness', delvis inom tvärmodal forskning (Spence, 2011), men även kopplat till principer inom PMSon, där relationen mellan datamängd och genererat ljud ska kunna uppfattas proportionellt samt hierarkiskt till källmaterialet (Hermann, et al., 2011).

- **Weight --> Tonlängd**: *Rösternas notlängd*.
  Färgklustrets ytfördelning kopplas även till de individuella rösternas notlängd. Detta medför att visuellt dominanta färger tar proportionellt upp lika stor plats i tid som de gör i bildytan.

5.1.2 Makroparametrar

Makroparametrarna styr mastersignalen i form av en global effektkedja samt en sequencer. Den data som styr dessa parametrar är i detta moment ansedda som komplexa mätvärden då de är extraherade från bildens helhet, och ej specifika kluster. Till skillnad från mikroparametrarna, saknar makroparametrarna direkta korrespondenser i projektets teoretiska

[8] Den föreslagna associationskedjan mellan korrespondenserna: Gult → skarp form (Adeli et al., 2014); skarp form → ljus klangfärg (Ramachandran & Hubbard, 2001).

ramverk.[9] Fokus skiftar därmed från direkt tvärsensorisk översättning till sammanhållning mellan rösterna.

- **Entropi --> Reverb**: *Global reverb-effekt*.[10]
  Låg entropi resulterar i en torr ljudbild, medan hög entropi genererar ett blött och diffust reverb. Detta ämnar associera visuellt med ljudande 'kaos'.

- **Entropi och genomsnittlig ljushet --> BPM**: *Rösternas grundtempo*.
  Entropivärdet utgör ett initialt tempo som därefter moduleras av bildens genomsnittliga ljushet. En ljus och komplex bild resulterar i ett högre tempo i kontrast till en mörk och minimalistisk bild.

- **Histogram --> Vågform**: *Rösternas grundläggande ljudvåg*.
  Histogrammets 36 olika vikter används för att rita upp en unik ljudvåg som skickas till oscillatorn som var röst använder som grund. Detta används för att bidra med ett unikt 'DNA' som är direkt kopplat till en bilds färgdistribution.

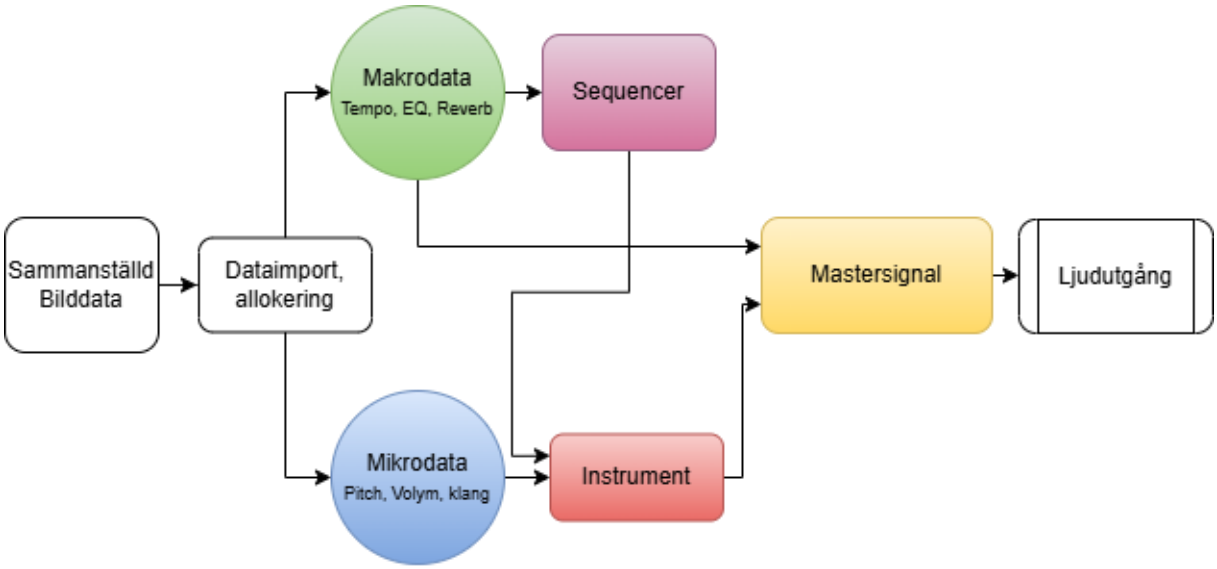
- **Brus och skärpa (Noise och Laplace) --> Brus och EQ**: *Global Pink Noise-effekt*.
  Mer visuellt brus översätts till spektralt brus via en Pink Noise generator som bländas in i mastersignalen. Bildens skärpa definierar i sin tur en global High-shelf EQ som intensifierar diskanten på skarpa bilder och reducerar den vid suddiga bilder.

5.2 Implementation: SuperCollider

Den praktiska implementationen av sonifieringssystemet utvecklades i ljudprogrammeringsmiljön SuperCollider. För att bygga upp en effektiv och lättläslig kodmiljö strukturerades koden utifrån fyra sekventiella moduler som består av "System och dataimport", "Mikroparametrar", "Makroparametrar" samt "Sequencer". Händelseförloppet består utav att importera samt allokera bilddata till antingen mikro- eller makroparametrar, definiera tempo och vikter för en sequencer samt tonhöjd och textur för instrumentet, verkställa reverb samt global EQ i mastersignalen och sedan spela upp (se Figur 4 nedan).

[9] Motoki et al. (2024) noterar även att tvärmodal forskning primärt undersöker lågnivåegenskaper framför komplexa stimuli (helheten). Vidare diskuterat i avsnitt 7.2.2.

[10] Specifikt 'FreeVerb' som är en digital reverb-effekt i SC.



Figur 4: Skiss över händelseförloppet i 'Sonifiering'

5.2.1 System och dataimport

Den första modulen hanterar den tekniska övergången mellan bildanalysen och ljudmotorn (se kodblock 5.1 nedan). De exporterade datafilerna från bildanalysen importeras samt tolkas inuti en egenkonstruerad klass, namngiven ‘HueGaze’, med ändamål att försäkra att SuperCollider läser samt tolkar data korrekt utan potentiella formateringsfel. Efter att datafilerna är importerade så placeras deras innehåll inuti en ‘Dictionary’, vilket fungerar som en kollektion av variabler där definitioner av data kan lagras samt hämtas med minimal påverkan på prestanda.[11]

Därefter allokeras dedikerade bussar samt grupper på ljudservern. Eftersom SuperCollider bygger på en klient-till-server-arkitektur måste algoritmen reservera och strukturera diverse resurser som servern ska utnyttja på förhand. Avslutningsvis allokeras minne för bildens histogramvikter, vilka laddas in i en egen ljudbuffer och konverteras till en vågform (wavetable) via metoden ‘.sine1’.[12]

[11] Liknande funktion som en ’array’, men utan numrering och ordning.

[12] ’.sine1’ är en specifik metod i SC som fyller en buffer med en serie av sinus-övertoner baserat på amplitud.

Kodblock 5.1: Initiera dataimportering

```
// Initiera formateringsklassen
~hueTool = HueGaze.new(s);

~loadNewImage = { |jsonPath, csvPath| {
        // Rensa servern och läs in ny data till 'Dictionary'
         s.freeAll;
         ~hueTool.loadData(jsonPath, csvPath);
         ~labData = ~hueTool.labData;
         s.sync;

        // Allokera bussar och grupper
         ~voiceBus = Bus.audio(s, 2);
         ~grpVoices = Group.new;
         ~grpAtmos = Group.after(~grpVoices);

         // Allokera minne för wavetable
         ~timbreBuf = Buffer.alloc(s, 2048, 1);
         s.sync;

         // Fyll wavetable med data från histogrammet
         if(~labData[\histWeights].numFrames > 0, {
             ~labData[\histWeights].loadToFloatArray(action: { |arr|
                 ~timbreBuf.sine1(arr);
         });
```

5.2.2 Mikroparametrar

Den primära ljudgenereringen för sonifieringen utgörs av en SynthDef namngiven \synthGazer, vilket fungerar som en musikalisk representation av de isolerade färgcentroiderna. Syftet med \SynthGazer är att agera som en matematisk mall, där varje centroid placerar sina respektive mätvärden inuti parametrar som styr var sin oscillator (se kodblock 5.2 nedan). För att sedan översätta CIELAB-koordinater till akustiska egenskaper så behöver alla mätvärden skalas om för att förbli logiska till diverse ljudmoduler. Detta utförs genom att tillämpa linjära ('linlin') samt exponentiella ('linexp') skalningsfunktioner, beroende på vilken typ av egenskap som översätts.

Kodblock 5.2: Skalning av data

```
SynthDef(\synthGazer, {

 // Dataskalning: CIELAB till akustiska parametrar
 freq = lVal.linexp(0, 100, 60, 2000); // L* --> tonhöjd (Hz)
 baseAmp = (cVal.linlin(0, 100, 0.05, 0.15) +
 (weight * 0.2)).clip(0.05, 0.2); // C* + Weight --> volymindex
 detuneAmt = cVal.linlin(0, 100, 0, 0.04); // C* --> detune-effekt
 pan = hVal.linlin(0, 360, -1.0, 1.0); // hue angle --> panorering
```

För att återskapa ‘energi’ till det grön-röda spektrumet så konstruerades två parallella ljudlager som filtreras in eller ut beroende på centroidens punkt på a*-axeln (se kodblock 5.3). Det första lagret, ‘sigPure’, utgörs av en ren oscillator (‘Osc.ar’) som läser av och itererar bildens histogram-wavetable. Det andra, ‘sigCloud’, består av fem sågtandsvågor (‘Saw.ar’) som drivs genom en matematisk saturering (‘.tanh’).[13] Beroende på a*-punktens position så filtreras ‘sigCloud’ in eller ut i kombination med ‘sigPure’ för att skapa en distorsionsliknande effekt (energi). Den resulterande signalen leds därefter genom ett lågpassfilter som dikteras av den blå-gula axeln (b*).

Kodblock 5.3: Konstruktion av ljudlager

```
  // Första lagret: Ren signal från histogrammets wavetable
  sigPure = Osc.ar(buf, freq);

  // Andra lagret: 5 distorderade saw waves
  sigCloud = Mix.fill(5, {
      var drift = LFNoise1.kr(0.1).range(1.0 - detuneAmt, 1.0 + detuneAmt);
      Saw.ar(freq * drift);
  });
  // Dämpa skarp diskant innan saturering appliceras
  sigCloud = LPF.ar(sigCloud, freq * 3);
  sigCloud = (sigCloud * 1.5).tanh;

  // Cross-fade mellan Pure och Cloud signalerna utifrån a*
  mixKnob = aVal.linlin(-128, 128, -1.0, 1.0);
  sig = XFade2.ar(sigPure, sigCloud, mixKnob);

  // Low-passfilter via b*
  toneColor = bVal.linlin(-128, 128, 1000, 6000).clip(1000, 6000);
  sig = LPF.ar(sig, toneColor);
```

[13] ’.tanh’ betyder ’hyperbolisk tangent’ vilket avrundar ljudvågens toppar för att skapa harmoniska övertoner.

5.2.3 Makroparametrar

Makroparametrarna består av en master-effektkedja som påverkar alla röster. Denna utgörs av en SynthDef kallad ‘\atmosGazer’ som är designad för att kontinuerligt ta emot och processera output-signalerna som \synthGazer skickar (se kodblock 5.4). Parallellt läser den även av makroparametrar från bildanalysen via de etablerade kontrollbussarna från dataimporten.

Kodblock 5.4: Koppla samman makroparametrar

```
SynthDef(\atmosGazer, {

    // Läser in makroparametrar från bildanalys
    valEntropy = In.kr(entropyBus, 1).lag(2);
    valNoise = In.kr(noiseBus, 1).lag(2);
    valSharp = In.kr(sharpnessBus, 1).lag(2);

    // Koppla \synthGazer output till \atmosGazer input
    input = In.ar(inBus, 2);
```

De effekter som \atmosGazer inkluderar är baserade på makroparametrarna entropi, brus och skärpa (se kodblock 5.5 nedan). Visuellt brus mappades direkt till ett akustiskt brus, där ett högt noise-värde i bilden adderar en proportionerlig mängd högfrekvent ‘Pink Noise’ till signalen. Skärpa appliceras i form av en ‘BHiShelf’ EQ, där skarpa bilder förstärker diskanten och suddiga bilder dämpar samma register. Denna EQ är centrerad runt 3000 Hz för att fokusera på övertonsregistret som sågtandsvågorna innehaver samt eventuellt brus. Avslutningsvis kopplas bildens entropi till både effektnivån (‘mix’) samt storleken (‘room’) av ett ‘FreeVerb2’ reverb, där låg entropi resulterar i ett torrt och litet rum och högre värden skapar större och blötare reverbklang. Dessa parametrar kalkyleras genom en linjär skalfunktion (‘linlin’) där ett teoretiskt minimum- samt maximumvärde för ingångsdata definieras och sedan översätts till ett intervall som stämmer överens med den effekt som påverkas. De slutgiltigt processade signalerna är samlad i variabeln ‘wet’ som sedan kopplas till ‘Out.ar’, vilket är den sista utgången för signalen.

Kodblock 5.5: Makroeffekter

```
// Input-signaler från \synthGazer adderas med PinkNoise (brus)
wet = input + (PinkNoise.ar(valNoise.linlin(0, 50, 0, 0.2)) * 0.5);
// Lägg till EQ (skärpa)
wet = BHiShelf.ar(wet, 3000, 1.0, valSharp.linlin(0, 100, -6, 6));

// Reverb (entropi) skalas om för mix samt room
wet = FreeVerb2.ar(wet[0], wet[1],
    mix: valEntropy.linlin(3, 8, 0.2, 0.5).clip(0, 1),
    room: valEntropy.linlin(3, 8, 0.3, 0.95).clip(0, 1));

// Summera output-signalen
Out.ar(out, Normalizer.ar(wet, 0.3, 0.1));
```

5.2.4 Sequencer

Den sista modulen består av en algoritmisk sequencer (kodblock 5.6), vars syfte är att strukturera de genererade ljuden över tid via manipulering av tempo, notlängd samt tonföljd, för att sedan spela upp dem. Modulen inleder med att sortera de olika centroiderna i en hierarkisk ordning baserat på deras weight inuti en 'array'.[14] Därefter etableras ett globalt tempo via en many-to-one-mappning baserat på bildens entropi samt genomsnittliga ljushet. Entropi genererar ett initialt bastempo mellan 30 och 300 BPM som sedan multipliceras med ett modifieringsindex baserat på bildens genomsnittliga ljushet (L*).

Kodblock 5.6: Allokera data till sequencer

```
// Sortera centroider efter weight
sortedData = ~hueTool.labData[\centroids].copy.sort
({ |a, b| a[\weight] > b[\weight] });
// Beräkna bastempo utifrån bildens Entropi
valEntropy = ~hueTool.labData[\entropy];
baseTempo = valEntropy.getSynchronous.linlin(0, 8, 30, 300);
// Beräkna genomsnittlig ljushet och skala om till modifieringsindex
avgL = sortedData.collect({|d| d[\L]}).mean;
lMod = avgL.linlin(0, 100, 0.07, 1.2);
// Modulera tempot baserat på L*
finalTempo = baseTempo * lMod;
~tClock = TempoClock.new(finalTempo / 60);
```

[14] 'array' är en ordnad lista av element där varje värde kan smidigt hämtas via ett numrerat index.

Efter att tempot är etablerat övergår systemet till ljudgenereringen. SuperColliders ‘Pbind’-klass utgör systemets notgenerator, vilket iterativt skapar mönster och dynamik via ett kontinuerligt händelseförlopp:

1. Algoritmen väljer ut en färgcentroid från storlekssorteringen.

2. Centroidens färgkoordinater extraheras och appliceras inuti en ny instans av \synthGazer. Detta är själva ‘rösten’.

3. Rösten genererar en signal som kopplas samt skickas till den dedikerade ljudbussen ‘~voiceBus’.

4. \atmosGazer processar signalen från ‘~voiceBus’ med modulation från makroparametrarna och skickar vidare den slutgiltiga mixen till ljudkortet.

5. Repetera.

Vilken specifik färgcentroid som väljs i det första steget dikteras av en ‘Pbrown’-slumpgenerator.[15] ‘Pbrown’ är en matematisk funktion inuti SuperCollider som är baserad på ‘brownian motion’, vilket innebär att varje nytt slumpgenererat värde är beroende av dess föregående tillstånd.[16] Exempelvis, av de åtta centroider som befinner sig i ‘array’ (index 0 till 7) väljs den initiala startpunkten helt slumpmässigt. Om algoritmen initialt landar på index 4 så tvingas nästa genererade värde att utgå från position 4 och addera eller subtrahera med ett maximalt tillåtet stegvärde, vilket i denna implementation är inställt på +/- 1. Detta resulterar i att nästa valda färgcentroid enbart kan bli index 3, 4 eller 5. Hastigheten som avgör hur snabbt ‘Pbrown’ väljer en ny centroid är baserad på det etablerade tempot i föregående steg. Slumpgeneratorn är även tillförsedd med en ’seed’-funktion, vilket gör att systemet kan återskapa en tidigare randomisering identiskt.[17]

Avslutningsvis definieras rösternas notlängd (‘\dur’) via deras weight-värde (se kodblock 5.7 nedan). Detta innebär att en färgcentroid med hög procentuell weight klingar i upp till tre taktslag innan nästkommande röst inträder, medan mindre dominanta centroider resulterar i korta impulser. För att undgå potentiellt staccato så tillämpas även en extern modifiering som

[15] Dokumentation av Pbrown i SC: https://docs.supercollider.online/Classes/Pbrown.html

[16] ’Brownian motion’ är även känt som ’Wiener motion’, eller ’Wiener process’.

[17] Detta för att uppfylla Hermanns (2008) reproducerbarhetskrav.

skapar överlappning mellan rösterna (‘\legato’). \legato har ett fast värde på 1.5, vilket innebär att en röst med \dur: 3 kommer klinga i 4.5 sekunder (3 x 1.5).

Kodblock 5.7: Notlängd samt legato

```
\dur, Pkey(\weight).linlin(0, 0.4, 0.25, 3.0), // Röstens duration via vikt
\legato, 1.5 // \dur * 1.5
```

5.3 Utvärdering: Sonifiering

Utvärderingen av sonifieringsprocessen skedde löpande under kodimplementationen i SuperCollider. Fokuset låg primärt på att säkerställa att den etablerade mappningsstrategin, baserad på Parameter Mapping Sonification (Hermann et al., 2011), resulterade i systematiska relationer mellan in- och utdata.

Ett av de teoretiska grundkraven för algoritmisk sonifiering är systemets reproducerbarhet, vilket förutsätter en konsekvent och objektiv hantering av inmatade data. Trots att SuperCollider tillhandahåller inbyggda funktioner samt resurser för dataavläsning, uppkom det vid tidiga iterationer att osynliga formateringsavvikelser i den exporterade data orsakade inkonsekvent tolkning i ljudmotorn. För att åtgärda detta, och garantera dataintegriteten, utvecklades den skräddarsydda klassen ‘hueGaze’. Inuti denna implementerades specifika formateringslösningar, däribland ett ASCII-filter som exkluderar icke-standardiserade karaktärer innan data tillåts påverka algoritmen.

Mappningstopologin, både i förankring till PMSon (Hermann et al., 2011) samt tvärsensorisk mappning (Walker & Walker, 2016), summerades i en hybrid av strategier för att delvis vara systematiskt konsekvent samt behålla stadgade tvärmodala relationer. En tidig utvärdering av de enskilda rösterna visade att en uteslutande absolut mappning, via one-to-one och one-to-many-topologier, var funktionell för att representera isolerade centroider som enskilda perceptuella lågnivåegenskaper. Senare iterationer påvisade dock att när flertalet röstinstanser genererades samtidigt så maskerades dessa egenskaper. Motoki et al. (2024) beskriver dock denna problematisering i form av att en bild eller målning (komplexa stimuli) utgör i grunden en perceptuell högnivåegenskap, där enskilda attribut ej tolkas i isolation, utan bearbetas som en kontextuell helhet. Då sonifieringsalgoritmen i detta skede uteslutande förlitade sig på en oberoende röststruktur så misslyckades systemet att etablera denna högnivåegenskap. För att åtgärda detta så utvärderades integrationen av systemets makroparametrar, med mål att finna en relation mellan ljuddomänens makroparametrar och bildens makroperspektiv. Modulen

\atmosGazer skapades i primärt syfte att binda samman dessa domäner, som i kombination med sequencern etablerade en övergripande many-to-one-topologi. Detta genom att låta bildens entropi, genomsnittliga ljushet, skärpa samt brusnivå binda samman den gemensamma klangen och tempot, vilket i sin tur tvingade den tvärsensoriska makroupplevelsen att övergå till en kontextberoende, relativ mappning.

Ett konkret exempel på nödvändigheten av relativ mappning framkom under utvärderingen av uppspelningstempot. Tempot var initialt enbart påverkat av bildens entropivärde, vilket grundades teoretiskt i ‘magnitude matching’ (Liu & Lupyan, 2026) som föreslår att hög magnitud i en sensorisk domän associeras med en hög magnitud i en annan. Eftersom hög entropi representerar en stor mängd visuell information mappades detta tvärmodalt till en proportionerligt hög mängd musikalisk information, i form av ett snabbt uppspelningstempo. Detta visade sig dock perceptuellt problematiskt på bilder med exempelvis låg ljushet samt hög entropi. I algoritmen generar en låg ljushet en låg tonhöjd, vilket tvärmodalt associeras med tunga och långsamma objekt (Marks, 1987), samtidigt som den höga entropin skapade ett högt tempo. För att sammanfoga den kontextuella helheten så integrerades bildens genomsnittliga ljushet som ett modifieringsindex på tempot som entropi genererade. Dock, eftersom ljushet är en lågnivåegenskap isolerat så hade det därmed varit strukturellt inkonsekvent, men genom att beräkna genomsnittet på alla centroider så omvandlas det till en högnivåegenskap, då det är i relation till hela bilden. Det finns även teoretiska belägg för att ljushet är direkt kopplat till musikaliskt tempo (Liu & Lupyan, 2026).

6 Resultat

I detta kapitel presenteras det stycke musik (’*Gazing’*) som arrangerats utifrån den utvecklade artefakten, samt ett urval viktiga iterationsmoment ur forskningsdagboken som i enlighet med Research through Design utgör projektets kunskapsproduktion.

6.1 Audiovisuellt musikstycke: Gazing

Gazing består av ett urval av sju kontrasterande bildsonifieringar. Urvalet prioriterar variation i de parametrar som har störst auditiv påverkan: entropi, färgkoncentration, skärpa samt genomsnittlig ljushet och kroma. Bilderna är valda för att demonstrera instrumentets kapacitet att respondera på ytterligheter, från monokroma och lågentropiska bilder till färgspridda och komplexa. För att kontextualisera de värden som kommer att presenteras i bildanalyserna nedan redogör Tabell 1 för de teoretiska min- och maxvärdena för respektive parameter, samt vad ett högt kontra lågt värde innebär.

Tabell 1: Min/maxvärde för entropi, färgkoncentration, genomsnittlig ljushet och kroma, samt skärpa.

Parameter	Min	Max	Tolkning
Entropi	0	8	Lågt (cirka 0–2) = enkel, förutsägbar pixelfördelning. Högt (cirka 5+) = komplex, oförutsägbar textur.
Färgkoncentration	0	1	Lågt (cirka 0–0.3) = jämn spridning över hela färgspektrumet. Högt (cirka 0.8+) = dominans av en enskild färgton.
Ljushet L*	0	100	0 = absolut svart. 100 = absolut vitt.
Kroma C*	0	181	0 = neutral grå. 0–20 = låg mättnad. 20–50 = normal färgstyrka. 50+ = kraftig mättnad. Teoretiskt maximum 181 uppnås sällan.
Skärpa	0	∞	Inget fast maximum. Under 100 = suddigt. 100–1000 = normalt. Över 1000 = mycket skarpt.

6.1.1 Analys av visuellt material

Utifrån detta ramverk presenteras nedan de sju bilderna med tillhörande bildanalys samt dess resulterande ljudkaraktär. Varje bild beskrivs utifrån de parametrar som tydligast särskiljer den från övriga i urvalet, följt av en samlad redovisning i Tabell 2. Infogat är även notationer som visar de åtta centroidernas frekvenser omräknade till närmaste tempererade tonhöjd, sorterade efter vikt.[18] Tonhöjderna anges enligt *Scientific Pitch Notation*, där oktavnumret skiftar vid varje C. Intervallet sträcker sig mellan ~B1 (61 Hz) till ~B6 (1975 Hz). För läsbarhetens skull hålls notationen på samma notsystem samt klav, där oktaveringstecken (***8*** och ***15***) markerar att en not ska spelas en eller två oktaver högre eller lägre än vad som står skrivet.

[18] De tempererade tonhöjderna presenteras enbart av pedagogiska skäl. Mer om detta i Diskussion, avsnitt 7.3.3.

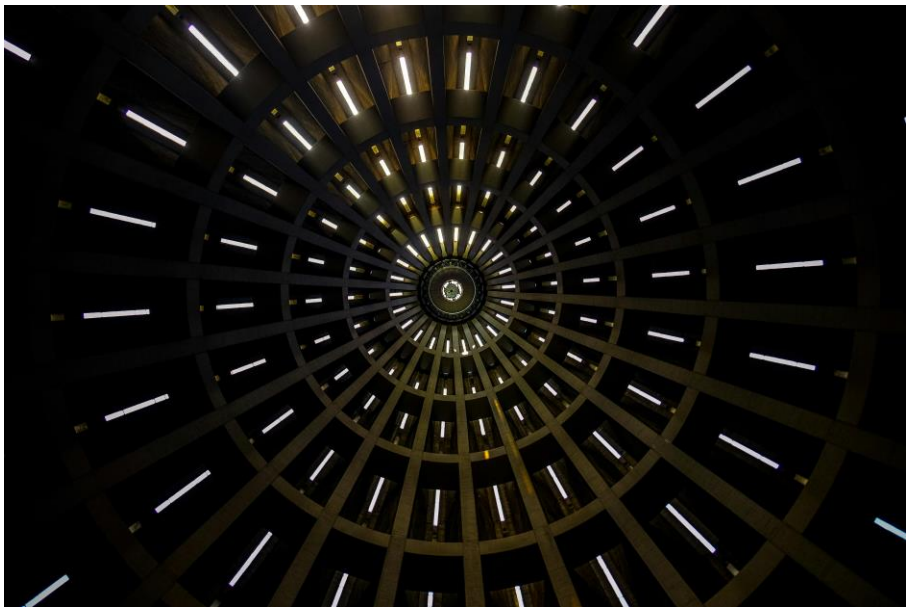
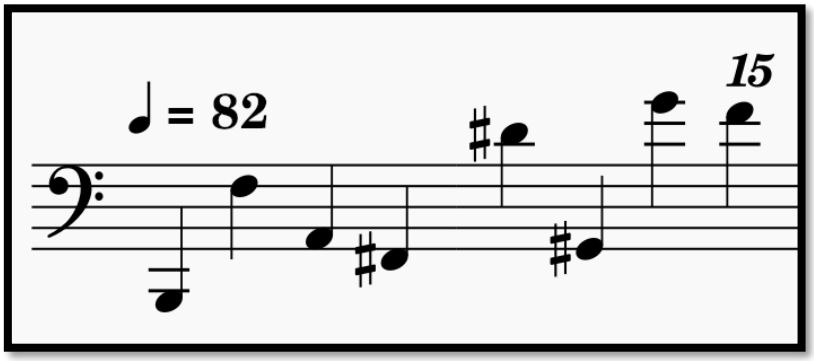


Bild 1: Entropi 5.37; Färgkonc. 0.88; Ljushet 28; Kroma 8; Skärpa 1219

Bildanalys: Bild 1 har lägst entropi (5.37) av urvalet samt högst färgkoncentration (0.88). Detta innebär att den har lägre visuellt kaos samtidigt som att den är nästan helt monokrom. Centroiderna består av sju mörka punkter och en ljus, med generellt lägst kroma.[19]



Notation 1: B1, F3, G#2, F#2, D#4, G#2, G4, F6

Ljudkaraktär: Röster i allmänt lågt frekvensregister med en utstickare på 1374 Hz. Rösterna består av sinusvågor med minimal distorsion och smal stereobild.

[19]Länk till bild 1: https://www.pexels.com/photo/low-angle-photography-of-tunnel-96381/

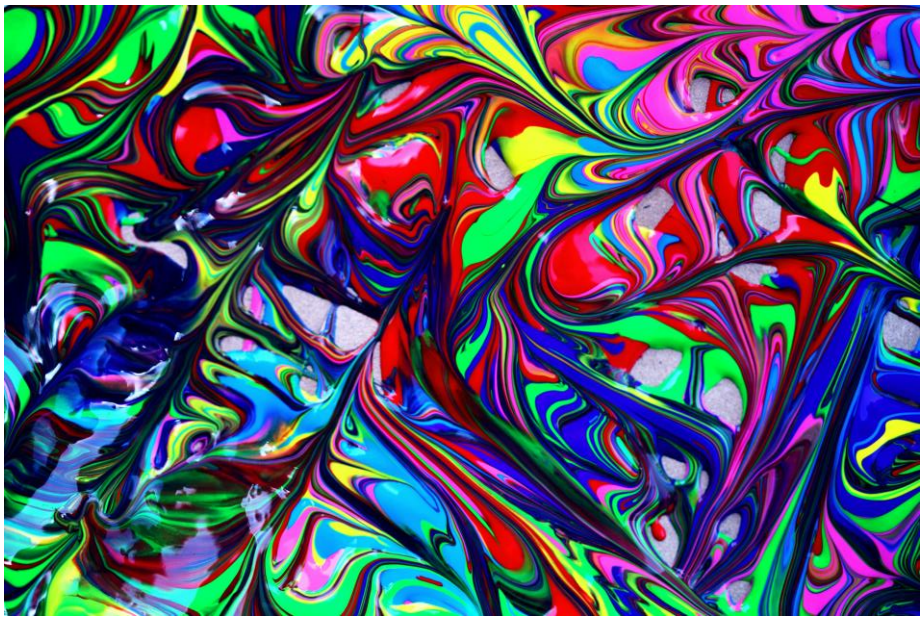
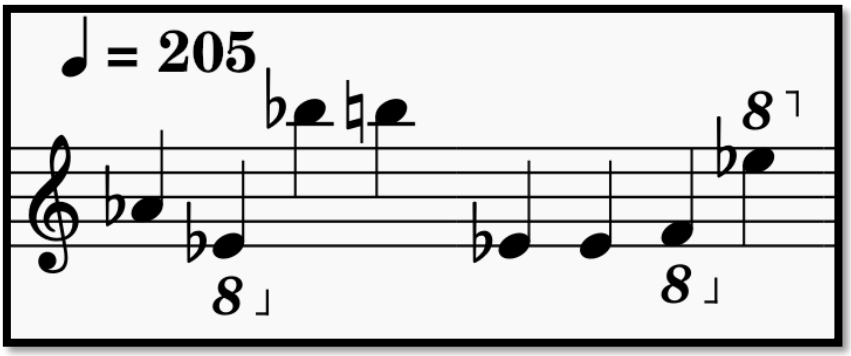


Bild 2: Entropi 7.76; Färgkonc. 0.06; Ljushet 56; Kroma 65; Skärpa 772

Bildanalys: Bild 2 består av en jämn färgspridning över hela färgspektrumet. Den har lägst färgkoncentration (0.06) men högst entropi (7.76) samt centroider med väldigt hög kroma (65).[20]



Notation 2: Ab4, Eb3, Bb5, B5, Eb4, Eb4, F3, Eb6

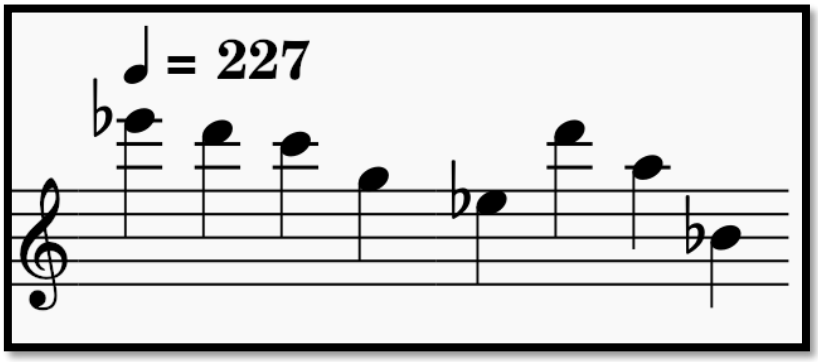
Ljudkaraktär: Frekvensregister spritt mellan 156–1268 Hz. Kroma genererar kraftig distorsion och tillsammans med en låg färgkoncentration skapas det en bred stereobild med spridd panorering.

[20] Länk till bild 2: https://www.pexels.com/sv-se/foto/1149019/



Bild 3: Entropi 6.26; Färgkonc. 0.49; Ljushet 77; Kroma 28; Skärpa 156

Bildanalys: Bild 3 har en tydlig blå och gul dominans med färgpunkterna nästan helt koncentrerade längs med b*-axeln. Centroiderna har relativt hög ljushet (77), medel entropi (6.26) samt låg skärpa (156).[21]



Notation 3: Eb6, D6, C6, G5, Eb5, D6, A5, Bb4

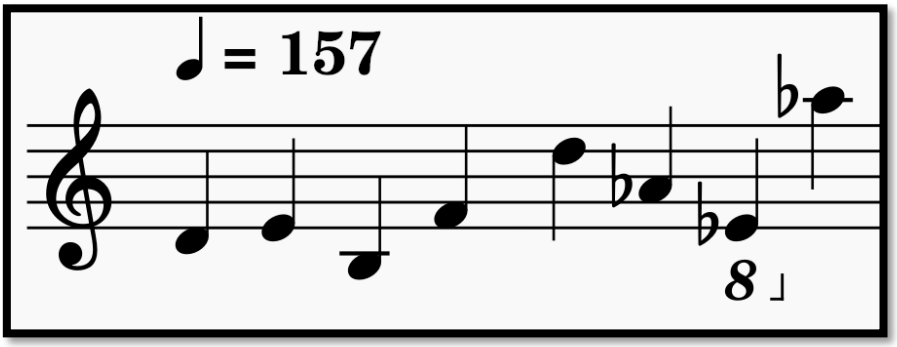
Ljudkaraktär: Frekvensregister mellan 459–1216 Hz. Blå/gul dominans bidrar till variation mellan dova och rena röstfilter. Låg skärpa dämpar diskanten globalt.

[21] Länk till bild 3: https://www.magnific.com/free-photo/glimmering-wavy-blue-yellow-abstract-background_5127506.htm



Bild 4: Entropi 6.85; Färgkonc. 0.56; Ljushet 47; Kroma 22; Skärpa 29

Bildanalys: Bild 4 har lägst skärpa av urvalet (29), men bred färgspridning med större andel mot det röda spektrumet. Jämnt fördelade mörka och ljusa centroider.[22]



Notation 4: D4, E4, B3, F4, D5, Ab4, Eb3, Ab5

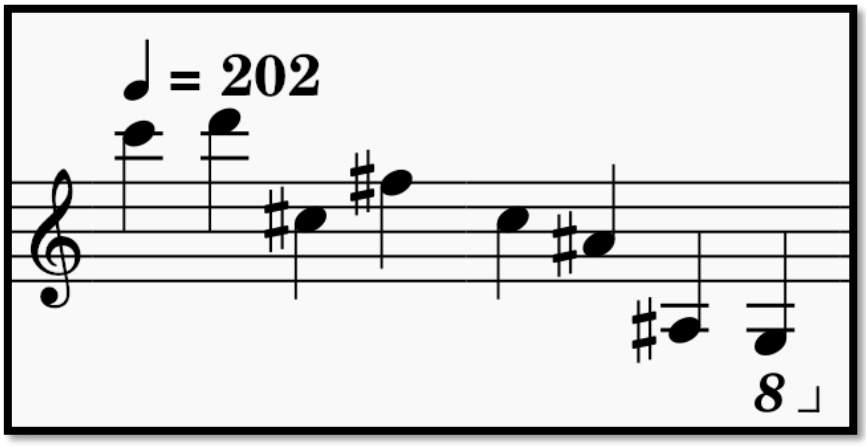
Ljudkaraktär: Frekvensregister spritt mellan 169–1129 Hz. Skärpa dämpar diskanten markant. Röda centroider är tydligt distorderade, men varierar kraftigt mellan rösterna.

[22] Länk till bild 4: https://www.pexels.com/sv-se/foto/35025859/



Bild 5: Entropi 7.13; Färgkonc. 0.33; Ljushet 60; Kroma 25; Skärpa 790

Bildanalys: Bild 5 har en tydlig färgspridning och starka inslag från både det blå samt det röda spektrumet. Hög skärpa (790) samt högst entropi bland de ljusa bilderna (7.13).[23]



Notation 5: C6, D6, C#5, F#5, C5, A#4, A#3, G2

Ljudkaraktär: Frekvensregister allmänt högt men har en låg ton (96–1157 Hz). Jämn balans mellan distorderade och dova röster. Ökad diskant via hög skärpa.

[23] Länk till bild 5: https://www.pexels.com/sv-se/foto/konst-textur-borste-borsta-25185235/

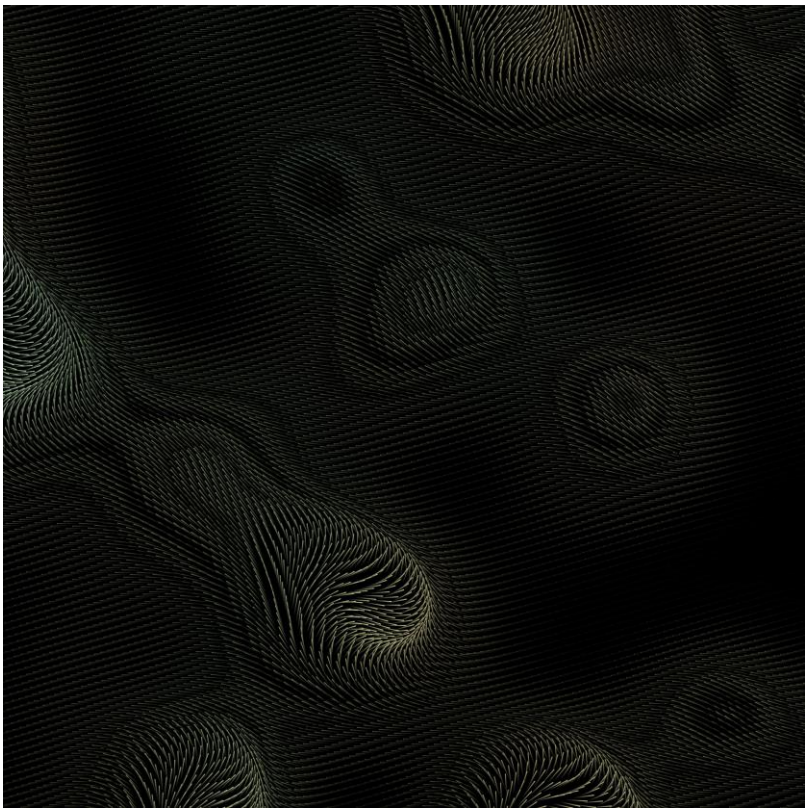
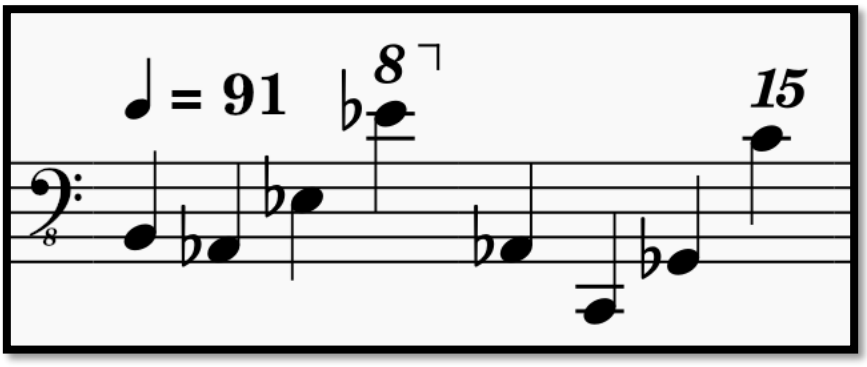


Bild 6: Entropi 6.28; Färgkonc. 0.95; Ljushet 27; Kroma 7; Skärpa 14662

Bildanalys: Bild 6 är nästintill akromatisk, med en genomsnittlig kroma på 7 samt högst färgkoncentration på 0.953. Centroiderna är allmänt mörka med få inslag av medel ljushet i några gröna punkter. Överlägset högst skärpa (14662).[24]



Notation 6: B1, Ab1, Eb2, Eb4, Ab1, C1, Gb1, C5

Ljudkaraktär: Lågt frekvensregister mellan 62–509 Hz. Uteslutande rena sinusvågor utan distorsion, dock med kraftig global diskantboost. Panorering är väldigt centrerad.

[24] Länk till bild 6: https://www.pexels.com/sv-se/foto/narbild-av-en-textur-8168566/

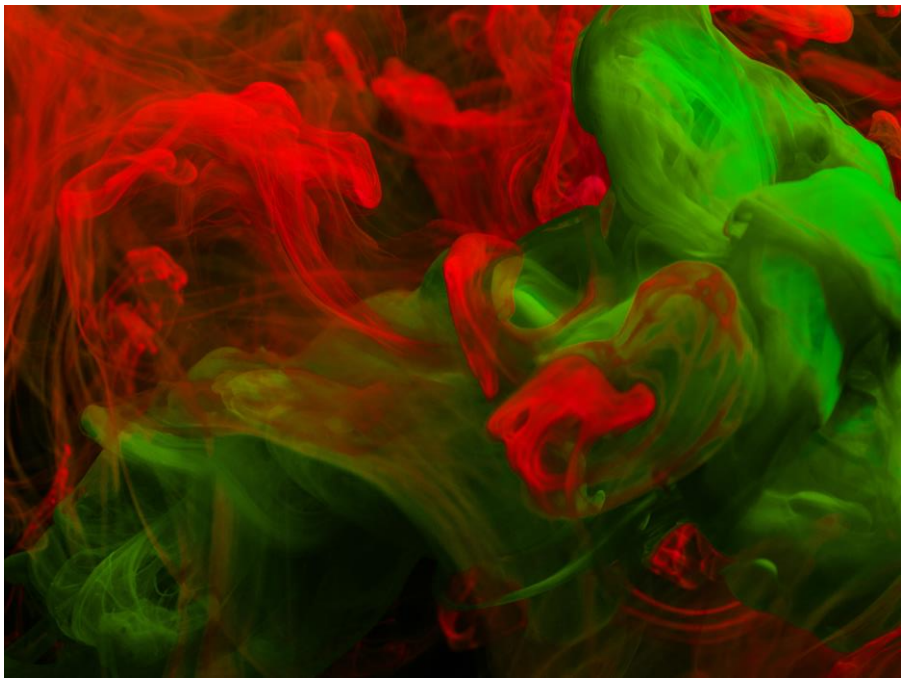
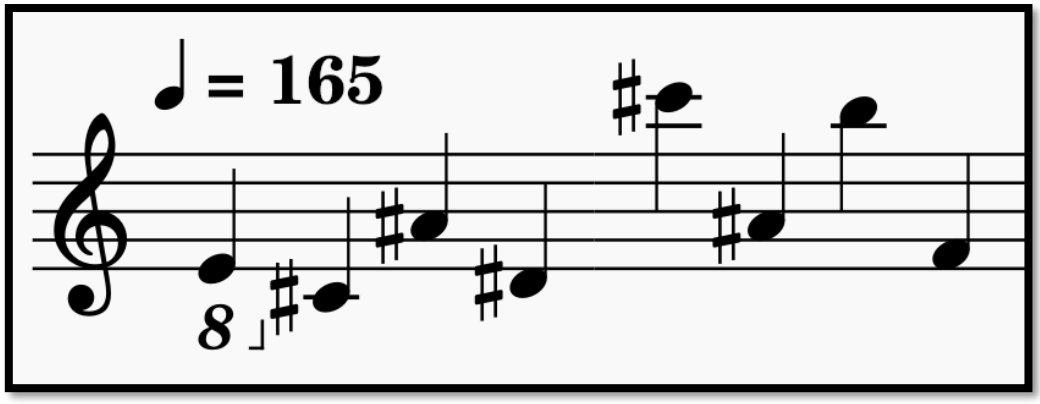


Bild 7: Entropi 6.92; Färgkonc. 0.86; Ljushet 49; Kroma 62; Skärpa 69

Bildanalys: Bild 7 består av grön/röd färgdominans, med bred närvaro på a*-axeln samt gula sidan av b*-axeln. Hög färgkoncentration på 0.858 samt låg skärpa (69).[25]



Notation 7: E3, C#4, A#4, D#4, C#6, A#4, B5, F4

Ljudkaraktär: Kraftig varians mellan distorderade röster och rena sinusvågor via mycket röda och gröna nyanser. Globalt dämpad diskant via låg skärpa.

[25] Länk till bild 7: https://www.pexels.com/sv-se/foto/konst-kreativ-vatten-vag-14822859/

6.1.2 Summering av data

Urvalet visar en betydande variation i samtliga parametrar (se Tabell 2 nedan), där entropi varierar mellan 5.37 och 7.76, färgkoncentration mellan 0.06 och 0.95, genomsnittlig ljushet mellan 27 och 77, genomsnittlig kroma mellan 7 och 65, samt skärpa mellan 29 och 14662. De tydligaste motpolerna utgörs av bild 1 och bild 2, som representerar ytterligheter i både entropi och färgkoncentration, samt bild 4 och bild 6 som har skärpa som skiljer sig markant.[26]

Tabell 2: Summering av samtliga bilders parametervärden. Pil upp indikerar ett högt värde och pil ned indikerar ett lågt värde.

Figur	Entropi	Färgkonc.	Ljushet	Kroma	Skärpa
Bild 1	5.37↓	0.88↑	28↓	8↓	1219
Bild 2	7.76↑	0.06↓	56	65↑	772
Bild 3	6.26	0.49	77↑	28	156↓
Bild 4	6.85	0.56	47	22	29↓
Bild 5	7.13↑	0.33	60	25	790
Bild 6	6.28	0.95↑	27↓	7↓	14662↑
Bild 7	6.92	0.86↑	49	62↑	69↓

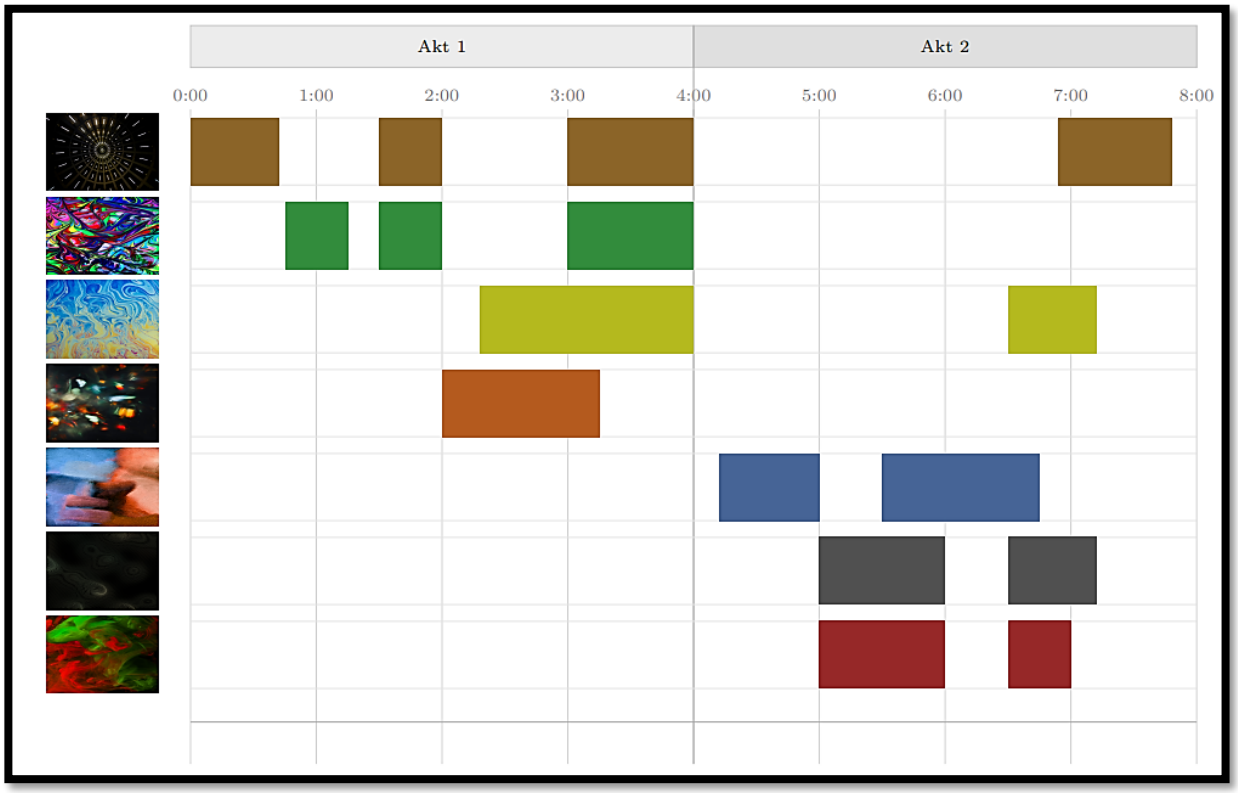
6.1.3 Arrangering

Gazing består av sju sonifieringar inspelade i realtid från SuperCollider. Då systemet genererar i princip en ändlös sonifiering så länge den körs så utgör varje inspelning ett utvalt segment ur det kontinuerliga ljudförloppet. Bildernas sonifieringar fungerar i arrangemanget som egna instrument, där visuella attribut dikterar respektive bilds notregister och karaktär. De individuella ljudfilerna är sammanställda inuti musikprogrammet Cubase, där de arrangerats i en linjär tidslinje med en total spellängd på 7 minuter och 46 sekunder (se Figur 5 nedan). Arrangemanget är indelat i två akter som består av första och andra halvan av stycket. Dessa är uppdelade efter komplexitet samt kontrasterande egenskaper, där akt 1 primärt består av motpoler i färgkoncentration och akt 2 i visuell komplexitet så som entropi

[26] Då skärpa mäts via ett Laplace-filter, vilket kan generera ett obegränsat värde, så reflekteras ej den perceptiva skillnaden i skärpa mellan bild 4 och 6 linjärt med intervallet i värdet som filtret analyserar. Efter en viss gräns (1000) är det svårt att tolka skillnader i skärpa mellan bilder med högt värde.

och skärpa. Bild 1 och 3 är återkommande i båda akterna för deras respektive låga och höga genomsnittliga ljushet och den dynamiska spänning som det skapar.

I regel så inträder bilderna successivt, med syfte att låta lyssnaren få höra varje sonifiering i isolation, innan de kombineras med ytterligare bilder. Den totala spellängden resulterade i cirka 8 minuter för att följa detta upplägg, där varje bild får utrymme att etablera sin ljudkaraktär innan nästa träder in.



Figur 5: Tidslinje över 'Gazing' med bildsekvens

Arrangemanget inleder med motpolsbilderna 1 och 2 isolerat i korta sekvenser för att sedan introducera dem tillsammans. Vid 2 minuter tillkommer bild 4 samt bild 3 kort därefter för att sedan bilda en helhet med bild 1 och 2. Efter 4 minuter inträder bild 5, 6 och 7 sekventiellt och markerar övergången till akt 2. Den sista akten agerar som mer dissonant och påträngande i jämförelse med den första då bilderna antingen innehaver extremvärden eller står på var sin sida av färgspektrumet mot sina motparter. Avslutningsvis återkommer bild 1, delvis för att demonstrera skillnaden på två väldigt mörka bilder (bild 1 och 6), men även för att binda ihop stycket till det elementet som inledde det.

6.2 Viktiga iterationsmoment

Forskningsdagboken har agerat som primär dokumentationsmetod för projektets iterativa förlopp, från tidig konceptualisering till det slutgiltiga systemet. Medan mindre iterationer kring enskilda design- och teknikval presenteras i respektive utvärderingsavsnitt (se 4.3 samt 5.3), lyfts i detta kapitel de tre iterationsmoment som identifierats som viktiga vägval för projektet i helhet. Följande avsnitt är strukturerat utefter dessa moment och innehåller bifogade citat hämtade direkt från dagboken.

6.2.1 Val av tonhöjdsparameter

Ett tidigt designval i dagboken kopplade b*-axeln (blå till gul) direkt till tonhöjd. Detta var grundat i färgtonernas association till värme eller kyla, vilket intuitivt kunde kopplas linjärt till frekvens via absolut mappning. Efter implementation samt praktisk testning visade sig dock denna mappning perceptuellt inkonsekvent: ”*Tonhöjd kopplad till b* axeln vart alldeles för vag och utelämnade ljushet.* […] *Antingen behöver jag använda flera parametrar kopplade till tonhöjd eller enbart använd ljushet och sen låta b* och a* påverka tontextur”*. En blå färg med hög ljushet genererade en identisk tonhöjd som en blå färg med låg ljushet, trots att de visuellt uppfattas som fundamentalt olika. Detta resulterade i insikten att b*-axeln ej innehåller tillräckligt med data för att återspegla den perceptuella informationen som tonhöjd förmedlar, och behövde därav antingen ingå i en many-to-one-mappning eller omarbetas. Skiftet till L* (ljushet) som tonhöjdsaxel dokumenterades ej som en teknisk justering, utan en teoretisk omvärdering av vilken CIELAB-dimension som var mest lämpad med den tvärmodala korrespondensen till frekvens, i enlighet med Marks (1987) koppling mellan ljushet och perceptuell vikt.

6.2.2 Sequencerimplementation

Halvvägs in i projektet dokumenterades att centroiderna placerades i en sequencer ordnad efter weight, vilket beskrivs som ”*Rösterna bildar nu melodi-liknande mönster istället för platta ljudväggar”.* Tidigare iterationer spelade upp centroiderna simultant, vilket delvis gav insikt i samspelet av dem på makronivå, men det var ohållbart för utvärderingen av mikroparametrar då de maskerades av varandra. Det noterades även att sequencern introducerade en tidslig dimension som oavsiktligt speglade den hierarkiska perceptuella bearbetningen utav låg- kontra högnivåegenskaper enligt Motoki et al. (2024): ”*Mängden variabler som påverkas är även många fler”*; *”* […] *även ett intuitivt samband mellan olika egenskapstyper när jag kan separera dem i en tidslig och en konstant dimension”*.

6.2.3 Skalning av rådata

Det identifierades en problematik inför den första implementationen kring skalning av rådata till ljudparametrar, specifikt angående SuperColliders linjära eller exponentiella skalningsmetoder. Problemet bestod utav att båda metoderna förutsätter ett fördefinierat minimum- och maximumintervall som ej ännu var definierat, samt vilket som egentligen var mest lämpat för respektive mappning: ”*en nackdel är att jag behöver veta InputMax samt InputMin, vilket jag i nuläget inte vet”*; *”Det tekniska och perceptuella måste gå hand i hand för att det ska funka, och vill helst ej göra stora kompromisser”.* Lösningen för de definierade intervallen framkom under själva implementationen av CIELAB, där modellens matematiska struktur redan bestod av universellt definierade intervall för samtliga axlar: L* mellan 0 och 100, a* samt b* vanligtvis mellan –128 och 128, vilket direkt kunde användas inuti skalningsfunktionerna: ”*CIELAB använder fördefinierade intervall som är perceptuellt förankrade enligt Fairchild”.* Vidare, så visade sig valet av skalningsmetod vara ett perceptuellt ställningstagande lika mycket som ett tekniskt: ”*Det visar sig dock att stimuli upplevs exponentiellt eller linjärt […] ljushet -> logaritmiskt, hue -> linjärt skalbart”.* Exempelvis, en exponentiell skalning mellan ljushet och tonhöjd kunde motiveras utav hur det mänskliga hörselsystemet uppfattar tonhöjd logaritmiskt, där lika stora steg i Hz ej upplevs proportionerligt. Övriga parametrar kunde däremot använda sig utav linjära metoder, motiverat utav CIELAB:s definierade perceptuella enhetlighet, där förändringar i färgvärde är kalibrerat att korrespondera med lika stora perceptuella skillnader.

7 Diskussion

I detta kapitel diskuteras de val som gjorts i designprocessen och deras relation till projektets teoretiska ramverk. Vidare beskrivs även den friktion som uppstått mellan teori och praktik, val som omformulerats under processen och de avslutande insikterna som projektet bär med sig in i framtida forskning.

7.1 Tvärvetenskaplig metodologi

I detta projekt har jag använt ett tvärsensoriskt ramverk för att mappa visuella attribut till ljud. Den utvecklade algoritmen är systematisk och reproducerbar i enlighet med Hermanns (2008) grundkriterier för vetenskaplig sonifiering, men kravet på objektiv dataöversättning visade sig mer komplext i praktiken. Delvis är detta en konsekvens av tvärmodala korrespondenser som forskningsområde, då det per definition behandlar subjektiva upplevelser som delas av en stor majoritet. Detta skapar en metodologisk utmaning där varken en ren vetenskaplig objektivitet eller konstnärlig subjektivitet ensamt kan hantera forskningsområdets komplexitet. En strikt empirisk studie hade kunnat ge statistik om pålitligheten för projektets mappningsstrategi, men hade samtidigt riskerat att hämma den konstnärliga aspekten som var central för projektet. Metoden Research through Design har visat sig lämplig för precis denna typ av studie, där kunskapen ej enbart ligger i artefakten som slutprodukt, utan i den iterativa processen som formade den. Flera av projektets mest betydelsefulla fynd uppstod ej ur teoretiska förutsägelser, utan ur testning och oavsiktliga upptäckter. Mappningen mellan b*-axeln och tonhöjd, som presenterades i avsnitt 6.2.1, är ett sådant exempel på ett tidigt designval som visade sig perceptuellt otillräckligt och behövde omarbetning. Detta fynd påvisade vikten av iteration och reflektion som drivande kraft i designprocessen, en insikt som blir tydlig först när forskaren befinner sig inuti processen.

7.2 Konsten att mappa vetenskapligt

Ur forskningsdagboken analyserades det att visuella data måste struktureras och bearbetas för att uppnå en sammanhängande musikalisk form, samtidigt som den behåller tvärsensorisk relevans. Detta innebär att kartlägga samt gruppera data utifrån dess kognitiva nivå, från enskilda stimuli som hjärnan bearbetar isolerat (lågnivå), till den helhetliga kontexten där flera intryck integreras (högnivå), i enlighet med Motoki et al. (2024). Detta synliggjorde en friktion mellan vetenskaplig objektivitet och konstnärlig gestaltning. Vid en strikt tillämpning av de traditionella kriterierna för sonifiering (Hermann, 2008), vilket kräver objektiv

dataöversättning oberoende av konstnärligt omdöme, uppenbarades begränsningarna i en sådan strikt objektivitet. Om algoritmen enbart tillämpar absoluta one-to-one-topologier förblir resultatet teoretiskt korrekt på en mikronivå, men relationerna mellan olika stimuli blir svårtolkade på makronivå. Designprocessen gav dock möjlighet att iterera mellan de olika topologierna, vilket påvisade att en dynamisk samverkan mellan dessa var avgörande för att skapa en musikalisk helhet. Detta gav upphov till en relativ mappningsstrategi (Walker & Walker, 2016) på både mikro- och makronivå, där de isolerade rösterna anpassades utifrån varandra, samtidigt som den övergripande bilddynamiken förenade dem. Värt att notera är även att denna relativa mappningsstrategi ej påverkar reproducerbarhetskriteriet (Hermann, 2008) på systemet. Det relativa avser hur en parameter förhåller sig till andra parametrar *inom* samma sonifiering, ej hur sonifieringen varierar mellan olika genereringar. Det slutgiltiga sonifieringssystemet förblir deterministiskt och reproducerbart med samma inmatade data.

7.2.1 Det ‘estetiska filtret’

Barrass & Vickers (2011) argument för ‘pragmatisk informationsestetik’ inom sonifiering adresserar denna spänning mellan objektivitet och subjektivitet. De föreslår att sonifiering ska kombinera funktionaliteten i informationsdesign med den känslighet som finns inom ljudkonst, snarare än att betrakta dem som motsatser. Det är denna balansgång som den relativa mappningsstrategin i detta projekt ska symbolisera, och de tydligaste spåren av hur den växte fram finns i dagboken. Tonhöjdsbytet från b* till L*, integrationen av makroparametrar via \atmosGazer och valet av exponentiell skalning för ljushet är tre sådana exempel: den teoretiska mappningen var giltig, men det lät fel i den musikaliska kontexten. Det som dessa justeringar har gemensamt är att de uppfattades som otillräckliga och behövde anpassas till helheten framför sin isolerade logik. Det är denna utvärderande process som jag kallar för det estetiska filtret.

Filtret innebär att en mappning utvärderas både i isolation och i sin musikaliska kontext. En mappning kan vara teoretiskt korrekt och musikaliskt motiverad i isolation, men förlorar sin perceptuella relevans när den konkurrerar med eller maskeras av omgivande röster. Inom Hermanns ramverk (2008) är detta ej ett systematiskt problem eftersom mappningsreglerna är konsekvent tillämpade, men det skapar potentiella perceptionsproblem. Eftersom kärnan i sonifiering enligt Hermann et al. (2011, s. 1) är att göra information *tillgänglig* via hörselsystemet, uppstår en intern spänning i kriteriet. Spänningen rör det som händer med objektiviteten när gränserna suddas ut mellan individuella data, och den objektiva informationen ej förmedlas till användaren längre.

För att hantera denna spänning tilläts en mappning att ibland avvika från det förutbestämda teoretiska ramverket, för att i stället forma sig efter den musikaliska kontext den verkar i. Den tvärsensoriska kärnan bevaras, men dess uttryck anpassas så att mappningen uppfattas som en egen röst i kompositionen. Dessa avvikelser är i detta projekt motiverade utifrån egen bedömning, där jag som forskare och lyssnare spelar en central roll i RtD:s reflektiva designprocess. Att det estetiska filtret faller utanför Hermanns objektivitetskriterier (2008) är därmed ingen begränsning i detta projekt, utan en egenskap hos projektets tvärvetenskapliga karaktär. Den vetenskapliga systematiken och det konstnärliga omdömet samverkar genom reflektionen, snarare än att utesluta varandra.

7.2.2 Komplexa stimuli

En central spänningspunkt som detta projekt berör är att den litteratur som ligger till grund för mappningsstrategin främst behandlar enskilda kopplingar mellan syn och hörsel. De källor som primärt informerat olika mappningar, bland annat Spence (2011), Liu & Lupyan (2026) och Marks (1987), undersöker hur *enskilda* färger, ljus eller texturer associeras med *specifika* ljudegenskaper. Problematiken, eller spänningen som detta skapar, är att korrespondenserna ej är undersökta i sammanhang där flera attribut samverkar som komplexa stimuli, vilket är förutsättningen i detta projekt. Detta diskuteras även av Motoki et al., som med en överblick på fältet noterar att tidigare tvärmodala undersökningar har ett tydligt fokus på specifikt lågnivåegenskaper: ”most previous research on cross-modal correspondences focused on low-level stimulus properties but could be also applied to higher-level stimulus properties (i.e., cognitive associations between concepts and complex stimuli)” (2024, s. 11). Ytterligare diskuterar Motoki et al. (2024, s. 17) att ett par komplexa stimuli är mindre sannolikt att integreras till ett gemensamt sensoriskt uttryck än enklare attribut. De föreslår att *affekt* kan spela en större roll vid tolkningen av komplexa stimuli, men formulerar det samtidigt som en öppen fråga för framtida forskning.

Dessa aspekter, att forskningen i hög grad fokuserar på isolerade attribut samt att affekt kan spela en större roll vid utvärderingen av komplexa stimuli, kan indikera en kunskapslucka inom tvärmodala korrespondenser. Då detta projekt varken utför en empirisk undersökning om komplexa stimuli eller specifikt behandlar affekt så kan denna lucka ej adresseras direkt, men det *estetiska filtret* kan ses som projektets sätt att hantera dessa två aspekter inifrån designprocessen. När en mappning utvärderas inuti en helhet snarare än isolation så är det integrationen av flera samverkande attribut som filtret bedömer, vilket är likt det Motoki et al. (2024) efterlyser för framtida forskning. Den upplevda bedömningen huruvida helheten

’stämmer’ eller ej är en form av värderingsgrund som implicit påverkas av en persons affekt, även fast det ej uttryckligen definieras som det. Det estetiska filtret kan ej ersätta den empiriska forskningen som kunskapsluckan efterfrågar, men kan verka som ett medel för konstnärlig reflektion och dess relevans när dessa svar saknas.

7.3 Roller inom projektet

Projektets utvärdering har bestått av att balansera olika roller, där alla ska lyssna på sonifieringen samt utvärdera den utifrån vad varje roll efterfrågar. Detta avsnitt reflekterar över dessa roller enskilt, bestående av konstnären som komponerar ’*Gazing’*, forskaren som utvärderar det teoretiska ramverket och designern som formar den tvärsensoriska upplevelsen.

7.3.1 Konstnären

Den konstnärliga rollen har handlat om vad projektet vill vara som musik, oberoende av sin teoretiska motivering. *Gazing* representerar enbart en bråkdel av det resultat som algoritmen har genererat, men utgör samtidigt den mest direkta tillämpningen av projektets konstnärliga och tekniska intentioner. Genom att variera mellan isolerade bildsonifieringar och kombinationer av dem har jag använt tvärsensoriska upplevelser som grund för vidare konstnärligt uttryck. Huruvida detta konstnärliga uttryck upplevs som tvärsensoriskt kopplat eller ej är dock upp till lyssnaren att avgöra, då det i detta skede är paketerat som musik. Detta innebär att lyssnaren ej är tilldelad instruktioner för hur bilderna *ska* upplevas, i stället är ambitionen att det ska få tolkas fritt. Det är vidare motiverat av att sonifiering, vars funktion är att belysa tvärsensoriska associationer, ej nödvändigtvis behöver kommunicera funktionen explicit för att vara meningsfull. Detta lutar dock mer mot ett ställningstagande än ett val, där *Gazing* sätter musikalisk intention före informationsförmedling som musikens primära funktion. Detta är i linje med Barrass & Vickers (2011) argument om att sonifiering kan ha värde uteslutande som estetisk upplevelse, vilket är det resonemanget som konstnärsrollen vilar på.

7.3.2 Forskaren

Forskarrollen riktar uppmärksamheten mot de individuella sonifieringarna och deras teoretiska underlag. Till skillnad från musikstycket *Gazing* är dessa utvecklade utifrån ett ramverk där tvärsensoriska kopplingar mellan bild och ljud är centrala. Det finns dock här en komplexitet av att jag som forskare även är projektets primära lyssnare, vilket oundvikligen färgar utvärderingen av resultatet. Som diskuteras i avsnitt 7.2 bearbetas högnivåegenskaper

som en kontextuell helhet snarare än som summan av isolerade attribut, vilket innebär att lyssnarens kontext blir avgörande för hur sonifieringen tolkas. En fördel med detta är att designbesluten fattas utifrån en djupare inblick i källmaterialet och med det teoretiska ramverket som referenspunkt vid utvärdering. Samtidigt innebär det även en tydlig bias, då forskarens kunskap inom fältet ger förutfattade förväntningar på hur det teoretiskt ska låta, vilket gör det svårt att bedöma hur en extern lyssnare upplever resultatet. Detta är dock den strukturella definitionen av metodologin Research through Design, vilket för detta projekt har gett upphov till en skräddarsydd operationalisering av det teoretiska ramverkets flera dimensioner.

7.3.3 Designern

Designerns roll intogs när det tvärsensoriska uttrycket skulle formas och bearbetas till den helhetliga kontexten, både i form av att visuella attribut skulle vara identifierbara och att de har en tydlig koppling till sina associerade ljudparametrar. En central problematik som denna roll identifierade är att en potentiell extern population bär på egna förutfattade associationer som kan påverka den tvärsensoriska upplevelsen. Som Motoki et al. (2024) argumenterar har människor redan etablerade kopplingar mellan ljud och färg, vilket gör det svårt att kontrollera denna variabel inifrån sonifieringssystemet. Jag gjorde dock två val i designprocessen som ett försök att motverka några av dessa förutfattade associationer, både hos mig som lyssnare och hos en potentiell extern publik. Det första var att låta tonhöjden utgå från rena Hertz-värden snarare än tempererade intervall, som ett försök att skapa distans till västerländsk musikteori och dess inbyggda känslomässiga associationer kring dur- och mollintervall. Dessa intervall uppstår dock oundvikligen i sonifieringen och är svåra att förbigå. Som Motoki et al. påpekar är det omöjligt att skapa en upplevelse som är helt fri från kulturellt betingade associationer. Det andra valet var att uteslutande använda abstrakta bilder som källmaterial, för att undvika potentiella semantiska associationer från igenkännbara objekt eller motiv. Detta återkopplar dock till samma problematik, där tvärmodala korrespondenser varierar mellan kulturer och individer, vilket innebär att exempelvis färg och form innehåller associationer som ej är generellt applicerbara (Motoki et al., 2024). Valet är därmed gjort för att minimera de tydligast västerländska associationerna, men utesluter dem ej helt.

Att de västerländska associationerna ej fullt ut kan undgås är något som blivit synligt genom arbetet med detta projekt. Det är av vikt att lyfta fram, men jag är samtidigt försiktig med att dra slutsatser om hela tvärmodala fältet utifrån en enskild artefakt. De korrespondenser som

projektets ramverk bygger på har dock visat sig bära kulturella förankringar som ej är direkt synliga i källitteraturen. För designerrollen är detta en pågående problematik, men öppnar samtidigt upp för framtida forskning och nya iterationscykler som specifikt undersöker dessa kulturella förankringar.

7.4 Framtida forskning

Sonifieringssystemet är i nuläget en fungerande prototyp med syftet att utforska projektets frågor och allmänna sonifieringskoncept, men är långt ifrån slutfört för en bredare användning. Jag har i detta projekt demonstrerat ett sätt att låta bilder fungera som komponerande underlag och nästa steg borde därav undersöka hur en population upplever dessa tvärsensoriska kopplingar mellan bild och ljud. En empirisk studie med externa lyssnare skulle direkt adressera den metodologiska begränsning som diskuterats i avsnitt 7.1, samt ge insikt i hur väl projektets mappningsstrategi faktiskt kommunicerar visuella egenskaper. Jag ser dock ett värde i att behålla en tvärvetenskaplig metodologi liknande RtD, men med användartestning integrerat som ett aktivt steg i iterationscykeln. Detta skulle möjliggöra att externa användare är med och informerar designprocessen, som ett ytterligare underlag för utvärdering, utan att det konstnärliga omdömet går förlorat. Vidare kan systemet utvidgas på ännu flera sätt:

- **Semantisk objektigenkänning**: Detta avgränsades på grund av tid och resurser, men skulle tillföra ett kontextuellt lager till bildanalysen.

- **Ytterligare bildparametrar**: CIELAB fungerade för detta projekt, men det finns andra CAM-modeller som kalkylerar visuella attribut mer utförligt och därmed kan hantera många fler parametrar.

- **Videoformat**: I stället för stillbilder så kan systemet utvidgas till rörlig bild. Rörelse kan då vara direkt mappat till sequencern och därmed introducera en tidsdimension i den visuella analysen.

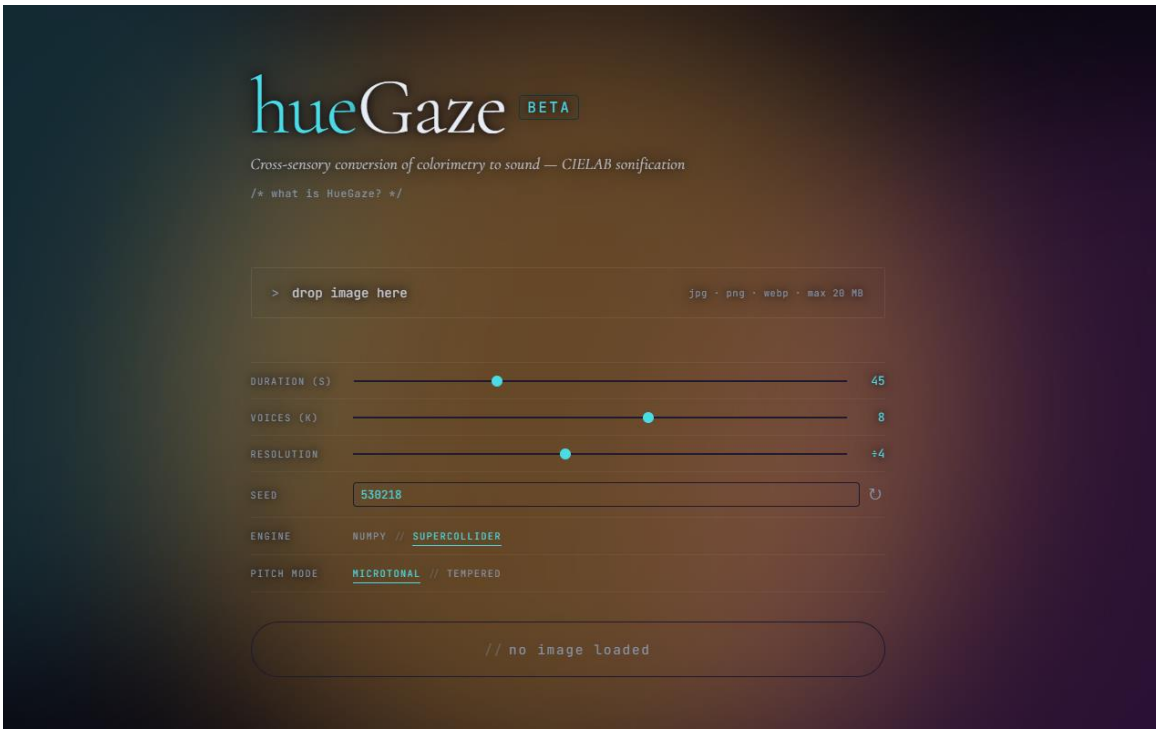
- **Realtidsbearbetning**: Utveckla algoritmen så att den kan rendera ljud i realtid. Detta skulle öppna upp för interaktiva eller performativa tillämpningar.

- **Kulturell variation**: Som diskuterat i 7.3.3 är mappningen färgad av västerländska perceptuella tendenser, men en jämförande studie över kulturella sammanhang skulle kunna kalibrera ramverket för bredare relevans.

- **Spektrum bortom synligt ljus**: Ytterligare en av de avgränsningar som detta projekt hade var frekvenser utanför det synliga spektrumet. En inkludering av dessa skulle utvidga sonifieringsändamålet till hur bilder faktiskt låter, eller informera lyssnaren hur de faktiskt ser ut.

7.4.1 Huegaze.com

Som ett komplement till projektets akademiska arbete har sonifieringssystemet publicerats online och är fritt tillgängligt via huegaze.com (se Figur 6 nedan). Då detta ligger utanför projektets forskningsbidrag är syftet primärt pedagogiskt, då jag har skapat ett mer lättillgängligt gränssnitt där användaren ej behöver behärska programmering. Detta är dock direkt kopplat till framtida forskning, då det skapar möjligheter för både konstnärliga och vetenskapliga tillämpningar bortom detta projekt. Vare sig det agerar som ett verktyg för komposition, perceptuella experiment eller enbart som en plattform för vidare utforskning av bildbaserad ljudgenerering, är ändamålet att låta användaren uppleva och tolka resultatet på egna villkor.[27]



Figur 6: Projektets sonifieringssystem online, Huegaze.com

[27] Plattformen sparar inga användardata och uppladdade bilder raderas direkt efter behandling.

8 Slutsats

Inledningsvis var detta projekt ett försök till ett tvärsensoriskt kompositionsverktyg, där musik och bild ej är separerade. Denna ambition lever kvar ännu, men visade sig bära på flera komplexa frågor och spänningar som dök upp först när jag befann mig inuti processen. De handlar bland annat om det tekniska och det konstnärliga, systematik och omdöme, funktion kontra konst. Förutom att hantera och adressera dessa spänningsområden så har jag även intagit olika roller för att tillämpa olika perspektiv på respektive fråga, samt att alltid ha i åtanke vad själva syftet med projektet är: en sammanflätad upplevelse, där bilder används som partitur för musiken. *Gazing* representerar resultatet av bilder som partitur, men mina genererade kunskaper från sonifieringssystemet representerar en djupare insikt i det som krävs och den problematik som följer med en förenad tvärsensorisk upplevelse.

Med detta i åtanke återgår jag till projektets frågeställningar:

- **Huvudfråga**: Hur påverkas mappningsprocessen utav samspelet mellan konstnärliga och tekniska val i utformningen av en sonifieringsmodell?

- **Underfråga**: Hur kan färg, ljus och visuell textur från en bild översättas till musikalisk komposition via sonifiering?

Underfrågan har besvarats genom själva sonifieringssystemets utformning, vars konkreta mappningsstrategi finns dokumenterad i avsnitt 5.1, men kan sammanfattas på följande sätt: Via CIELAB-modellen analyseras visuella attribut som sedan mappas till ljud i SuperCollider. Dessa mappningar består av ljus till tonhöjd och tempomodulering, kroma till volym och modulering, a*- och b*-axlarna (färg) till distorsion respektive spektralfilter, färgvinkel till stereoplacering, och bildens komplexa egenskaper (entropi, brus och skärpa) till reverb samt grundtempo, noise och EQ. Dessutom styr bildens histogram instrumentens initiala vågform och varje färgklusters storlek påverkar dess relativa volym och tonlängd.

Mappningsprocessen, som huvudfrågan handlar om, påverkas på tre konkreta sätt som identifierats genom projektets designprocess:

- För det första så bryter komplexa stimuli (bilder) den annars linjära relationen mellan datadimension och ljudparameter. När åtta röster spelas samtidigt maskerar de varandra, vilket motiverar ett byte från absolut till relativ mappning på makronivå.

Exempelvis formades de globala mastereffekterna för att föra samman det gemensamma *soundet* och rösterna kalibrerades utifrån relationen mellan varandra.

- För det andra förblir vissa CIELAB-dimensioner perceptuellt otillräckliga som ensam källa för en ljudparameter. Tonhöjd kunde ej hämtas ur b*-axeln eftersom den ej bar tillräcklig perceptuell vikt, vilket ledde vidare till en omformulering av det teoretiska underlaget, ej enbart en kodjustering.

- För det tredje fungerade vissa dataintervall först när de skalades exponentiellt snarare än linjärt, vilket ej avgjordes av tekniska överväganden, utan snarare av hur mänsklig perception bearbetar respektive sinnesintryck. Tonhöjd, till exempel, hörs logaritmiskt och måste därför mappas exponentiellt från en linjär dataaxel för att uppfattas perceptuellt naturlig.

Min slutsats är att tekniska och konstnärliga val ej är två separata domäner, varje mappningsbeslut bär båda samtidigt. Det estetiska filtret (avsnitt 7.2.1) operationaliserar detta genom hybridtopologier som låter mappningarna avvika från isolerad teoretisk logik och i stället forma sig efter den musikaliska helheten. De principer som vuxit fram ur designprocessen är en direkt produkt av detta arbete och utgör projektets bidrag till framtida forskning inom fältet:

- *Utvärdera varje mappning i relation till helheten, ej i isolation.*

- *Identifiera vilka parametrar som är perceptuellt dominanta och ge dem företräde.*

- *Utnyttja relativ mappning där absolut mappning förlorar sin perceptuella relevans i relation till helheten.*

- *Bevara den tvärsensoriska kärnan, men forma den efter det musikaliska utrymmet.*

Resultatet har därmed demonstrerat att bilder kan fungera som visuella partitur, samt att gränsen mellan ett funktionellt sonifieringssystem och ett konstnärligt uttryck är flytande snarare än absolut. Att mappningen förutsätter ett omdöme som faller utanför de objektiva sonifieringskriterierna anser jag dock ej som en svaghet, utan som en fundamental egenskap i projektets tvärvetenskapliga grund. Detta arbete har därmed funnit sin egen plats, distinkt från både informationsdesign och ljudkonst, men likväl beroende av båda.

… och det är kanske ett sådant tvärvetenskapligt omdöme, där tekniska och konstnärliga val ej separeras, som kan ge ett meningsfullt svar på frågan "*hur låter färgen röd?*".

9 Referenslista

Adeli, M., Rouat, J., & Molotchnikoff, S. (2014). Audiovisual correspondence between musical timbre and visual shapes. *Frontiers in Human Neuroscience, 8*, Article 352. doi:10.3389/fnhum.2014.00352

Arnal, L. H., Flinker, A., Kleinschmidt, A., Giraud, A.-L., & Poeppel, D. (2015). Human screams occupy a privileged niche in the communication soundscape. *Current Biology, 25*(15), 2051-2056. doi:10.1016/j.cub.2015.06.043

Barrass, S., & Vickers, P. (2011). Sonification design and aesthetics. i T. Hermann, A. Hunt, & J. G. Neuhoff (Red.), *The sonification handbook* (ss. 145-172). Logos Verlag.

Fairchild, M. D. (2013). *Color appearance models* (3rd uppl.). John Wiley & Sons.

Frayling, C. (1993). Research in art and design. *Royal College of Art Research Papers, 1*(1), 1-5.

Gaver, W., & Bowers, J. (2012). Annotated portfolios. *Interactions, 19*(4), ss. 40-49. doi:10.1145/2212877.2212889

Hermann, T. (2008). Taxonomy and definitions for sonification and auditory display. *Proceedings of the 14th International Conference on Auditory Display (ICAD 2008).* Paris: International Community for Auditory Display. Hämtat från https://www.icad.org/Proceedings/2008/Hermann2008.pdf

Hermann, T., Hunt, A., & Neuhoff, J. G. (2011). *The sonification handbook.* Logos Verlag.

Liu, Q., & Lupyan, G. (2026). The unity of sense and mind: A review of cross-domain mapping. *Psychonomic Bulletin & Review, 33*(1), Article 25. doi:10.3758/s13423-025-02805-3

Marks, L. E. (1987). On cross-modal similarity: Auditory-visual interactions in speeded discrimination. *Journal of Experimental Psychology: Human Perception and Performance, 13*(3), 384-394. doi:10.1037/0096-1523.13.3.384

Motoki, K., Marks, L. E., & Velasco, C. (2024). Reflections on cross-modal correspondences: Current understanding and issues for future research. *Multisensory Research, 37*(1), 1-23. doi:10.1163/22134808-bja10114

Phillips, S., & Cabrera, A. (2019). Sonification workstation. *Proceedings of the 25th International Conference on Auditory Display (ICAD 2019).* Newcastle upon Tyne: Northumbria University. doi:10.21785/icad2019.056

Ramachandran, V. S., & Hubbard, E. M. (2001). Synaesthesia: A window into perception, thought and language. *Journal of Consciousness Studies, 8*(12), 3-34.

Spence, C. (2011). Crossmodal correspondences: A tutorial review. *Attention, Perception, & Psychophysics, 73*(4), 971-995. doi:10.3758/s13414-010-0073-7

Valdez, P., & Mehrabian, A. (1994). Effects of color on emotions. *Journal of Experimental Psychology: General, 123*(4), 394-409. doi:10.1037/0096-3445.123.4.394

Vetenskapsrådet. (2024). *God forskningssed.* Vetenskapsrådet. Hämtat från https://www.vr.se/analys/rapporter/vara-rapporter/2024-10-02-god-forskningssed-2024.html

Walker, L., & Walker, P. (2016). Cross-sensory mapping of feature values in the size-brightness correspondence can be more relative than absolute. *Journal of Experimental Psychology: Human Perception and Performance, 42*(1), 138-150. doi:10.1037/xhp0000128

Zimmerman, J., Forlizzi, J., & Evenson, S. (2007). Research through design as a method for interaction design research in HCI. *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems* (ss. 493-502). Association for Computing Machinery. doi:10.1145/1240624.1240704