DESIGNPRINCIPER FÖR AUTOMATISK KLASSIFICERING AV GDPR-KÄNSLIGHET I SVENSK FRITEXT

– EN DESIGNFORSKNINGSSTUDIE AV EN LAGERBASERAD KLASSIFICERINGSARTEFAKT

Kandidatuppsats i Informatik

Abdulla Mehdi
Johanna Gull

2026KANI24



HÖGSKOLAN
I BORÅS

Svensk titel: Designprinciper för automatisk klassificering av GDPR-känslighet i svensk fritext – en designforskningsstudie av en lagerbaserad klassificeringsartefakt

Engelsk titel: Design Principles for Automatic Classification of GDPR Sensitivity in Swedish Free Text – A Design Science Study of a Layered Classification Artifact

Utgivningsår: 2026

Författare: Abdulla Mehdi, Johanna Gull

Handledare: Johannes Sahlin

Abstract

[Background] Organizations that handle large volumes of unstructured text face a practical problem: sensitive personal data appears in free text without markup, and judging what counts as sensitive falls on the individual employee. The General Data Protection Regulation (GDPR) separates ordinary personal data (article 4) from special categories of sensitive data (article 9), with different legal consequences for each. Existing technical approaches are either grounded in generic categories of personally identifiable information (PII) without legal precision, or built for narrow document types and languages other than Swedish. No prior study addresses automatic classification of general organizational free text in Swedish with the article 4 / article 9 distinction as its primary design criterion.

[Aim] This study generates design knowledge about how Swedish free text can be automatically classified according to GDPR 's sensitivity categories, and how traceability can be built into the classification as an inherent property, motivated by the regulation's accountability principle. The knowledge takes form through the design, implementation and evaluation of an IT artifact named Aegis.

[Method] The study follows the Action Design Research method, carried out together with participating organizations across three iterative design cycles of building, intervention and evaluation.

[Results] The artifact is a layered classification pipeline of four detection layers: deterministic pattern and entity recognition for article 4 data, language-model-based detection for article 9 data, and a combination layer that judges the mosaic effect under recital 26. Recall, which the artifact prioritizes, stayed above 89 percent across all three cycles, while precision moved from around 90 percent with only the deterministic layers active, down to 64 percent when the interpretive layers were added, and back to roughly 83 percent after the third cycle. The study formalizes six design principles and a two-dimensional representation model that separates identifiability from data class.

[Discussion and Conclusion] The study contributes artefactual, theoretical and empirical knowledge: a runnable classifier, six design principles formulated as nascent design theory for the problem class, and a documented performance and assessment profile across three design cycles. The results are valid within a bounded scope of three organizations, a synthetic Swedish test dataset and an artifact at prototype maturity, and should be read as a demonstration of feasibility rather than broadly generalizable results. A layered architecture is shown to carry the task even in a less structured text domain than earlier work has tested.

Keywords: GDPR classification, sensitive data detection, design principles, design science research, Action Design Research, natural language processing, layered architecture, Swedish free text

Sammanfattning

[Bakgrund] Organisationer som hanterar stora mängder ostrukturerad text står inför ett praktiskt problem: känsliga personuppgifter förekommer i fritext utan markeringar, och bedömningen av vad som är känsligt hamnar på den enskilda medarbetaren. Dataskyddsförordningen (GDPR) skiljer mellan allmänna personuppgifter (artikel 4) och särskilda kategorier av känsliga uppgifter (artikel 9), med olika rättsliga konsekvenser för respektive kategori. Befintliga tekniska ansatser är antingen förankrade i generiska PII-kategorier utan juridisk precision, eller anpassade för avgränsade dokumenttyper och andra språk än svenska. Ingen tidigare studie behandlar automatisk klassificering av generell organisatorisk fritext på svenska med distinktionen mellan artikel 4 och artikel 9 som primärt designkriterium.

[Syfte] Studien genererar designkunskap om hur svensk fritext automatiskt kan klassificeras enligt GDPR:s känslighetskategorier, och om hur spårbarhet kan byggas in i klassificeringen som en inneboende egenskap, motiverad av förordningens princip om ansvarsskyldighet. Kunskapen tar form genom design, implementering och utvärdering av en IT-artefakt benämnd Aegis.

[Metod] Studien följer metoden Action Design Research och genomfördes tillsammans med deltagande verksamheter i tre iterativa designcykler av konstruktion, intervention och utvärdering.

[Resultat] Artefakten är en lagerindelad klassificeringspipeline med fyra detektionslager: deterministisk mönster- och entitetsigenkänning för artikel 4-data, språkmodellbaserad detektion för artikel 9-data, och ett kombinationslager som bedömer pusselbitseffekten enligt skäl 26. Recall, som artefakten prioriterar, låg över 89 procent i samtliga tre designcykler, medan precisionen rörde sig från omkring 90 procent med enbart de deterministiska lagren, ned till 64 procent när de tolkande lagren tillfördes, och tillbaka till knappt 83 procent efter den tredje cykeln. Studien formaliserar sex designprinciper och en tvådimensionell representationsmodell som skiljer identifierbarhet från dataskyddsklass.

[Diskussion och slutsats] Studien bidrar med artefaktuell, teoretisk och empirisk kunskap: en körbar klassificerare, sex designprinciper formulerade som begynnande designteori för problemklassen, och en dokumenterad prestanda- och bedömningsprofil över tre designcykler. Resultaten är giltiga inom en avgränsad ram av tre verksamheter, ett syntetiskt svenskspråkigt testdataset och en artefakt med prototypmognad, och ska läsas som en demonstration av genomförbarhet snarare än som brett generaliserbara resultat. En lagerindelad arkitektur visas bära uppgiften även i en mindre strukturerad textdomän än tidigare arbeten prövat.

Nyckelord: GDPR-klassificering, identifiering av känsliga uppgifter, designprinciper, designvetenskaplig forskning, Action Design Research, natural language processing, lagerbaserad arkitektur, svensk fritext

Förord

Vi vill tacka vår handledare Johannes Sahlin. Hans vägledning har hjälpt oss att hålla riktningen genom hela arbetet, särskilt i de metodval där vägen framåt inte var självklar.

Vi vill också tacka de verksamheter och personer som ställde upp i studien. De gav oss av sin tid och delade med sig av sin kunskap genom hela utvärderingsarbetet, och deras synpynkter har format artefaken på ett sätt vi inte hade nått på egen hand.

Borås, juni 2026
Abdulla Mehdi och Johanna Gull

Innehållsförteckning

1 Inledning ..... - 6 -
1.1 Bakgrund ..... - 6 -
1.2 Forskningsöversikt ..... - 6 -
1.3 Problemdiskussion ..... - 7 -
1.4 Problemformulering ..... - 8 -
1.5 Syfte och forskningsfråga ..... - 8 -
1.6 Målgrupp för arbetet ..... - 9 -
1.7 Disposition av uppsatsen ..... - 9 -
2 Metod ..... - 11 -
2.1 Forskningsparadigm ..... - 11 -
2.2 Forskningsmetod ..... - 11 -
2.3 Ramverk för utvecklingsarbetet ..... - 11 -
2.3.1 Fas 1: Problemformulering ..... - 12 -
2.3.2 Fas 2: Konstruktion, Intervention och Utvärdering ..... - 12 -
2.3.3 Fas 3: Reflektion och lärande ..... - 14 -
2.3.4 Fas 4: Formalisering av lärande ..... - 15 -
2.4 Datainsamling ..... - 16 -
2.4.1 Litteraturinsamlingsmetod ..... - 16 -
2.4.2 Kartläggning av intressenter ..... - 19 -
2.4.3 Dokumentation under BIE-cyklerna ..... - 20 -
2.4.4 Datainsamling för utvärdering ..... - 20 -
2.5 Dataanalys ..... - 21 -
2.5.1 Analys och representation av arkitektur ..... - 21 -
2.5.2 Kvantitativ analys av teknisk prestanda ..... - 22 -
2.5.3 Analys av intressentbedömning enligt FEDS ..... - 23 -
2.5.4 Formalisering av designprinciper ..... - 23 -
2.6 Metodreflektion ..... - 24 -
2.6.1 Val av forskningsansats och undersökningsstrategi ..... - 24 -
2.6.2 Reflektion kring utvärdering och dataanalys ..... - 24 -
2.6.3 Forskningskvalitet i designforskning ..... - 25 -
2.6.4 Etiska överväganden ..... - 26 -
2.7 Användning av AI-verktyg ..... - 27 -
3 Teoretisk kunskapsbas ..... - 28 -
3.1 Definition och kategorisering av personuppgifter enligt GDPR ..... - 28 -
3.1.1 Allmänna personuppgifter (artikel 4) ..... - 28 -

3.1.2 Särskilda kategorier av personuppgifter (artikel 9) ... - 28 -
3.1.3 Ansvarsskyldighet ... - 29 -
3.1.4 Inbyggt dataskydd ... - 29 -
3.2 Tidigare forskning om identifiering av personuppgifter ... - 30 -
3.3 Sammanfattande teoretiska utgångspunkter ... - 31 -
4 Teknisk och arkitektonisk kunskapsbas ... - 32 -
4.1 Tekniska byggblock för automatiserad detektion ... - 32 -
4.1.1 Regelbaserad mönsterigenkänning och reguljära uttryck ... - 32 -
4.1.2 Igenkänning av namngivna entiteter ... - 32 -
4.1.3 Kontextuell analys ... - 33 -
4.1.4 Prompts och prompt engineering ... - 34 -
4.2 Arkitekturmönster för flerstegsdetektion ... - 34 -
4.2.1 Pipeline-mönstret ... - 35 -
4.2.2 Lageruppdelning ... - 35 -
4.2.3 Utbytbara komponenter ... - 36 -
4.2.4 Sammansatta fynd ... - 36 -
4.2.5 Spårbarhet och dataursprung ... - 37 -
4.2.6 Principer för objektorienterad design ... - 37 -
4.3 Sammanfattande tekniska designimplikationer ... - 38 -
5 Genomförande ... - 39 -
5.1 Arbetssätt och konstruktionsmetoder ... - 39 -
5.1.1 Generering av testdata ... - 40 -
5.1.2 Promptkonstruktion ... - 41 -
5.1.3 Utvecklingsarbete med agentisk AI ... - 43 -
5.2 Problematiseringscykel ... - 44 -
5.3 Designcykel 1 ... - 45 -
5.3.1 Problemformulering ... - 45 -
5.3.2 Konstruktion, intervention och utvärdering ... - 45 -
5.3.3 Lärdomar och insikter ... - 47 -
5.4 Designcykel 2 ... - 49 -
5.4.1 Problemformulering ... - 49 -
5.4.2 Konstruktion, intervention och utvärdering ... - 50 -
5.4.3 Reflektion och lärande ... - 55 -
5.5 Designcykel 3 ... - 56 -
5.5.1 Problemformulering ... - 56 -
5.5.2 Konstruktion, intervention och utvärdering ... - 57 -
5.5.3 Reflektion och lärande ... - 61 -

5.6 Formalisering av lärande ..... - 62 -
6 Artefakten Aegis ..... - 64 -
6.1 Teknisk stack ..... - 64 -
6.2 Klassificerare ..... - 65 -
6.3 Arkitekturbeskrivningar ..... - 67 -
6.3.1 Övergripande klassdiagram ..... - 68 -
6.3.2 Lagerprotokollet och dess realisering ..... - 69 -
6.3.3 Aggregatorn och härledning av klassificering ..... - 70 -
6.3.4 Klassificeringsobjektets dimensioner och deras härledning ..... - 73 -
6.3.5 Tillämpade arkitekturmönster ..... - 73 -
7 Artefaktutvärdering ..... - 76 -
7.1 Teknisk prestanda ..... - 76 -
7.1.1 Resultat över designcyklerna ..... - 76 -
7.1.2 Per-lager-precisionsbidrag ..... - 77 -
7.1.3 Per-kategori-noteringar ..... - 78 -
7.1.4 Kvarstående begränsningar ..... - 80 -
7.2 Verksamhetsrepresentanternas bedömning ..... - 81 -
7.2.1 Demonstrationsgränssnitt ..... - 81 -
7.2.2 Nytta ..... - 83 -
7.2.3 Ändamålsenlighet ..... - 85 -
7.2.4 Organisatorisk passform ..... - 87 -
7.2.5 Syntes ..... - 89 -
8 Designprinciper ..... - 91 -
8.1 Designprincip 1: Design för recall-prioritering som fail-safe ..... - 91 -
8.2 Designprincip 2: Design för utbytbarhet via smalt lagerprotokoll ..... - 92 -
8.3 Designprincip 3: Design för lokal språkmodellexekvering med utbytbar provider - 94 -
8.4 Designprincip 4: Design för tvåstegsdetektion av kombinatorisk identifierbarhet . - 95 -
8.5 Designprincip 5: Design för spårbar härledning av klassificeringsbeslut ..... - 96 -
8.6 Designprincip 6: Design för tvådimensionell representation av juridisk klassificering .- 98 -
9 Diskussion och slutsatser ..... - 101 -
9.1 Resultaten i relation till tidigare forskning ..... - 101 -
9.2 Studiens kunskapsbidrag ..... - 103 -
9.2.1 Artefaktuellt bidrag ..... - 103 -
9.2.2 Teoretiskt bidrag ..... - 104 -
9.2.3 Empiriskt bidrag ..... - 106 -
9.3 Implikationer ..... - 107 -

9.3.1 Implikationer för praktiker ..... - 107 -
9.3.2 Implikationer för forskare ..... - 108 -
9.3.3 Etiska och hållbarhetsmässiga implikationer ..... - 109 -
9.4 Reflektion över metodens genomförande ..... - 109 -
9.5 Studiens trovärdighet ..... - 111 -
9.5.1 Trovärdighet ..... - 112 -
9.5.2 Överförbarhet ..... - 112 -
9.5.3 Pålitlighet ..... - 113 -
9.5.4 Bekräftelsebarhet ..... - 113 -
9.6 Begränsningar ..... - 114 -
9.7 Framtida forskning ..... - 115 -
9.8 Slutsatser ..... - 117 -
Referenser ..... - 119 -
Bilaga A - Annoteringsguider ..... - 125 -
A.1 Annoteringsguide för Article9Layer (Lager 3) ..... - 125 -
1. Syfte och avgränsning ..... - 125 -
2. Juridisk grund ..... - 125 -
3. Kategorier ..... - 125 -
4. Övergripande gränsdragningsprinciper ..... - 126 -
5. Tillämpning vid granskning ..... - 127 -
6. Begränsningar ..... - 127 -
7. Källor ..... - 127 -
A.2 Annoteringsguide för CombinationLayer (Lager 4) ..... - 128 -
1. Syfte och avgränsning ..... - 128 -
2. Juridisk grund ..... - 128 -
3. Signaltyper och specificitetsnivåer ..... - 128 -
4. Identifierbarhetsbedömning ..... - 129 -
5. Tillämpning vid granskning ..... - 130 -
6. Begränsningar ..... - 130 -
7. Källor ..... - 130 -
Bilaga B - Data statements ..... - 131 -
B.1 Gemensamma egenskaper ..... - 131 -
B.2 Artikel 9-datasetet ..... - 131 -
B.3 CombinationLayer-datasetet ..... - 132 -
B.4 Kända begränsningar ..... - 133 -
Bilaga C - Promptversioner ..... - 135 -
C.1 Article9Layer v5 ..... - 135 -

C.2 CombinationLayer v5 ..... - 145 -
Bilaga D - Utvärderingssessioner ..... - 153 -
D.1 Demomanus ..... - 153 -
Designcykel 1 (v0.1.1) ..... - 153 -
Designcykel 2 (v0.2.0) ..... - 154 -
Designcykel 3 (v0.3.0) ..... - 155 -
D.2 Intervjuguider ..... - 157 -
Designcykel 1 ..... - 157 -
Designcykel 2 ..... - 159 -
Designcykel 3 ..... - 160 -

1 Inledning

I detta avsnitt presenteras en bakgrund till det problem studien adresserar, följt av en översikt av befintlig forskning på området. Därefter identifieras den kunskapslucka som motiverar studien, och studiens syfte och forskningsfrågor formuleras. Avslutningsvis beskrivs arbetets målgrupp och uppsatsens disposition.

1.1 Bakgrund

Automatiserad identifiering av känslig information i text har blivit ett praktiskt problem för organisationer som hanterar stora mängder ostrukturerad data (Karras et al. 2025; Mishra, Pagare & Sharma 2025). När AI-verktyg används för att hantera intern kommunikation, ärendeloggar och dokument ökar mängden ostrukturerad text som kan innehålla personuppgifter, och problemet växer med användningen.

Dataskyddsförordningen (GDPR) reglerar behandlingen av personuppgifter och skiljer mellan två kategorier (Europaparlamentets och rådets förordning [EU] 2016/679). Artikel 4 definierar personuppgifter som varje upplysning som avser en identifierad eller identifierbar fysisk person. Artikel 9 avgränsar en särskild kategori av känsliga uppgifter vars behandling som utgångspunkt är förbjuden. Eftersom de rättsliga konsekvenserna av en felaktig behandling skiljer sig åt mellan kategorierna har distinktionen direkt praktisk betydelse för alla som hanterar fritext i sitt arbete.

Privata företag med kundkommunikation, offentliga förvaltningar med medborgardialog och mindre verksamheter utan dedikerade dataskyddsresurser delar samma grundläggande utmaning. Känslig information förekommer i ostrukturerad text utan fördefinierade markeringar, och ansvaret för att avgöra vad som är känsligt hamnar på den enskilda medarbetaren. Att förlita sig på manuell bedömning vid hög textvolym begränsar den praktiska tillämpbarheten och är inte skalbart (Mishra, Pagare & Sharma 2025).

1.2 Forskningsöversikt

Tekniska ansatser för automatiserad identifiering av känslig data i text har vuxit fram som ett etablerat forskningsfält inom natural language processing (NLP). Den grundläggande arkitekturella insikten är välbelagd. Mishra, Pagare och Sharma (2025) visar i en hybridpipeline för finansiella dokument att regelbaserade reguljära uttryck kombinerade med en anpassad modell för named entity recognition (NER) och maskininlärning uppnår hög precision vid detektion av personuppgifer (*personally identifiable information, PII*). Karras et al. (2025) rekommenderar liknande flerstegsarkitekturer i säkerhetskänsliga miljöer. Dessa arbeten utgår dock från tekniska kategorier snarare än från GDPR:s juridiska indelning.

En annan linje i forskningen tar GDPR:s kategorier som utgångspunkt. Petrolini, Cagnoni och Mordonini (2022) bygger transformer-baserade klassificerare för känsliga kategorier (politik, religion, hälsa och sexuell läggning) som motsvarar artikel 9, i ostrukturerad text som mejl och recensioner. Pilán et al. (2022) introducerar Text Anonymization Benchmark (TAB), ett annoterat korpus av Europadomstolsdomar där textelement klassificeras som direkta identifierare och kvasiidentifierare (motsvarande artikel 4) respektive konfidentiella attribut som hälsa, etnicitet och sexuell läggning (motsvarande artikel 9). Lorè et al. (2023) bygger INTREPID, ett ramverk för italienska myndighetsdokument som kombinerar regelbaserade

ordlistor, SpaCy NER och klassificerare baserade på maskininlärning (ML) för att identifiera entiteter på artikel 4-nivå (person, plats, organisation) och hälsodata på artikel 9-nivå. Löbner, Serna, Tronnier, Tesfay och Rannenberg (2025) tillämpar en liknande kombination av regex, lexikon och BERT-NER för att identifiera och avidentifiera artikel 4- och artikel 9-data i CV-dokument.

På designkunskapssidan finns metodologiska prejudikat från angränsande problemklasser. Bergström, Karlsson och Åhlfeldt (2021) genomför en svensk studie inom designvetenskaplig forskning (DSR) i fem iterationer som formulerar explicita designprinciper för en organisatorisk informationsklassificeringsmetod. Li, Werner, Ernst och Damian (2022) tillämpar Design Science Methodology för att operationalisera GDPR-principer som testbara krav, men för IT-infrastruktur snarare än textanalys. Översikten visar därmed ett fält som konvergerat tekniskt, men där den juridiska förankringen och formaliseringen av designkunskap ser olika ut mellan studierna.

1.3 Problemdiskussion

Forskningen visar att fältet har rört sig i rätt riktning men stannat före den kombination som organisatorisk GDPR-efterlevnad kräver.

Den första begränsningen gäller räckvidd och kontext. De studier som tar GDPR:s juridiska kategorier på allvar är domänspecifika eller dokumentspecifika. Petrolini, Cagnoni och Mordonini (2022) fokuserar sin klassificering på artikel 9-kategorierna och behandlar artikel 4 endast som ett villkor för att ett dokument ska räknas som känsligt. Lorè et al. (2023) hanterar båda artikelnivåerna men är konstruerat för att upptäcka otillåtet röjande av känsliga uppgifter i italienska myndighetsdokument inför publicering, inte för att klassificera generell organisatorisk fritext. Pilán et al. (2022) tillhandahåller ett riktvärde på engelska juridiska domar. Löbner et al. (2025) täcker artikel 4 och artikel 9 men i ett specifikt dokumentformat, CV:n baserade på Europass-mallen. Ingen av studierna adresserar den typ av ostrukturerad fritext, alltså mejl, chattmeddelanden, ärendeloggar och interna dokument, som utgör det faktiska klassificeringsproblemet i organisatorisk praktik, och samtliga är dessutom utvecklade för andra språk än svenska.

Den andra begränsningen gäller arkitekturens juridiska motivering. Hybridpipelines med regelbaserade lager och NER är etablerade tekniskt. Mishra, Pagare & Sharma (2025), Lorè et al. (2023) och Löbner et al. (2025) visar alla att kombinationen fungerar. Det som saknas är att lagrens utformning motiveras av GDPR:s juridiska struktur. Artikel 4-data som personnummer, e-postadresser och IBAN har en deterministisk, strukturerad form som är lämplig för regelbaserad hantering. Artikel 9-data som religiös övertygelse, politisk åsikt och hälsotillstånd förekommer implicit och kontextuellt i fritext och kräver semantisk analys. Ingen befintlig studie designar arkitekturen med denna juridiska motivering som explicit utgångspunkt.

Den tredje begränsningen är avsaknaden av designkunskap. DSR används framgångsrikt i angränsande problemklasser, av Bergström, Karlsson & Åhlfeldt (2021) för organisatorisk informationsklassificering och av Li et al. (2022) för GDPR-efterlevnad i IT-infrastruktur. Löbner et al. (2025) rör sig mot en designvetenskaplig ansats men formulerar inga generaliserbara designprinciper. Det saknas publicerade designprinciper för hur ett system för automatisk GDPR-klassificering av fritext bör utformas, vilka arkitekturella val som motiveras av juridiska krav, och hur spårbarhet byggs in som konsekvens av GDPR:s princip om ansvarsskyldighet (artikel 5.2).

Det litteraturgap som ringats in av räckvidd, juridisk motivering och avsaknad av designkunskap motsvarar det behov som verksamhetsrepresentanter formulerade självständigt under studiens problematiseringsfas, vilket redovisas i Sektion 5.2.

1.4 Problemformulering

Befintliga tekniska ansatser för automatisk identifiering av känslig data i text är antingen förankrade i generiska PII-kategorier utan juridisk precision, eller domänspecifikt anpassade för avgränsade dokumenttyper och språkkontexter. Ingen befintlig studie adresserar automatisk klassificering av generell organisatorisk fritext på svenska med GDPR:s juridiska distinktion mellan artikel 4 och artikel 9 som primärt designkriterium. Det saknas designkunskap om hur en lagerbaserad klassificeringsartefakt bör utformas för att operationalisera distinktionen mellan artikel 4 och artikel 9. Spårbarhet behöver dessutom byggas in som en inneboende egenskap, motiverad av GDPR:s princip om ansvarsskyldighet.

1.5 Syfte och forskningsfråga

Syftet med studien är att generera designkunskap om hur svensk fritext automatiskt kan identifieras och klassificeras enligt GDPR:s känslighetskategorier, och om hur spårbarhet i klassificeringsbesluten byggs in som en inneboende egenskap, motiverad av förordningens princip om ansvarsskyldighet. Denna kunskap tar form genom design, implementering och utvärdering av en IT-artefakt, i uppsatsen benämnd Aegis, som analyserar ostrukturerad text och klassificerar den utifrån juridiskt definierade känslighetskategorier. Studien följer Action Design Research-metodiken (Sein, Henfridsson, Purao, Rossi & Lindgren 2011) och genomförs i samverkan med deltagande verksamheter i tre iterativa designcykler.

Eftersom studiens primära syfte är att designa en ny IT-artefakt faller arbetet inom designvetenskapens ram. Konstruktion av artefakter och kunskapsgenerering behandlas inte som separata aktiviteter. Artefakten utgör ofta i sig forskningsbidraget, förutsatt att den löser tidigare olösta problem (Hevner, March, Park & Ram 2004, s. 87).

Forskningsfråga: *Hur kan en IT-artefakt designas för att automatiskt identifiera och klassificera svensk fritext baserat på juridiskt definierade känslighetskategorier enligt GDPR?*

- *Delfråga 1: Vad är den arkitekturella lösningen av ett sådant system?*
- *Delfråga 2: Vad är den tekniska prestandan av en sådan artefakt?*
- *Delfråga 3: Hur bedömer verksamhetsrepresentanter artefaktens nytta, ändamålsenlighet och organisatoriska passform?*
- *Delfråga 4: Vad är designprinciperna för ett sådant system?*

Forskningsbidraget är av tre slag (Ågerfalk & Karlsson 2020). Det första är artefaktuellt: en IT-artefakt som klassificerar svensk fritext enligt GDPR:s känslighetskategorier, konkretiserad i en arkitekturell lösning (delfråga 1). Det andra, och primära, är teoretiskt: den designkunskap artefakten ger upphov till, i form av designprinciper som beskriver hur ett sådant system bör utformas (delfråga 4). Designprinciper i denna mening fungerar som en abstrakt ritning eller arkitektur som beskriver IT-artefakten (Gregor & Jones 2007, s. 322), vilket gör bidraget generaliserbart bortom den specifika implementationen. Mer precist motsvarar denna designkunskap den komponent som dessa författare benämner principer för form och funktion,

en av de åtta komponenterna i deras anatomi för designteori. Det tredje är empiriskt: artefaktens uppmätta tekniska prestanda (delfråga 2) och de deltagande verksamheternas bedömning av dess nytta, ändamålsenlighet och organisatoriska passform (delfråga 3).

1.6 Målgrupp för arbetet

Arbetet riktar sig till forskare inom informationssystem (IS) och designvetenskap med intresse för hur tekniska artefakter kan operationalisera juridiska eller regulatoriska ramverk. Designprinciperna och den arkitekturella lösningen är inte bundna till GDPR som specifikt regelverk utan tillhör en bredare systemklass, det vill säga ett system som automatiskt klassificerar textinnehåll utifrån normativt definierade kategorier. Själva artefakten och den empiriska utvärderingen är avgränsade till svensk fritext, medan designprinciperna och den arkitekturella lösningen formuleras som generaliserbara lösningskoncept, avsedda att bäras vidare bortom den specifika kodbasen och de instansbundna modellvalen. Forskning om liknande system, exempelvis frågor om systemets konsekvenser i organisatorisk kontext eller hur systemklassen kan beskrivas i termer av en fullständig IS-designteori (Gregor & Jones 2007), lämnas till framtida studier.

En sekundär målgrupp är praktiker, systemarkitekter, dataskyddsombud och informationssäkerhetsansvariga i organisationer som hanterar personuppgifter och söker tekniskt stöd för GDPR-efterlevnad.

1.7 Disposition av uppsatsen

Uppsatsen är indelad i nio kapitel och följer det dispositionsschema för designvetenskaplig forskning som Gregor och Hevner (2013) föreslår, anpassat efter studiens omfång. Schemats delar, inledning, kunskapsbas, metod, artefaktbeskrivning, utvärdering, diskussion och slutsatser, återfinns alla, men kunskapsbasen är fördelad på två kapitel och metoden placeras före kunskapsbasen. Gregor och Hevner (2013) anger att antalet komponenter och ordningen mellan dem kan variera mellan studier, vilket motiverar dessa val.

Kapitel 1 inleder med bakgrund, forskningsöversikt, problemdiskussion samt studiens syfte och forskningsfråga. Kapitel 2 redogör för det metodologiska ramverket med forskningsparadigm, Action Design Research med dess faser, datainsamling, dataanalys per delfråga, en metodreflektion och en redovisning av AI-verktygsanvändningen.

Kapitel 3 och 4 utgör tillsammans studiens kunskapsbas, som Gregor och Hevner (2013) delar i en beskrivande del (Ω), det som är känt om problemet, och en föreskrivande del (Λ), det som vägleder hur en lösning byggs. Kapitel 3 är studiens Ω-kunskap och behandlar GDPR:s rättsliga ramverk och tidigare forskning om identifiering av personuppgifter. Kapitel 4 är studiens Λ-kunskap och behandlar tekniker för automatiserad detektion, arkitekturmönster och objektorienterade designprinciper. De är åtskilda i var sitt kapitel eftersom båda är omfattande i denna studie.

Kapitel 5 redovisar genomförandet, det praktiska utvecklingsarbetet i en problematiseringscykel följd av tre designcykler. Kapitel 6 beskriver den färdiga artefakten Aegis, dess tekniska stack och arkitekturella lösning, och besvarar delfråga 1. Kapitel 7 utvärderar artefakten genom den tekniska prestandan över designcyklerna (delfråga 2) och verksamhetsrepresentanternas bedömning enligt ramverket Framework for Evaluation in Design Science, FEDS (delfråga 3). Kapitel 8 formaliserar de sex designprinciper som abstraherats ur designcyklerna och besvarar delfråga 4.

Kapitel 9 diskuterar resultaten i förhållande till tidigare forskning, redogör för studiens bidrag, reflekterar över hur forskningsansatsen bar studien och behandlar begränsningar och fortsatt forskning. Kapitlet avslutas med de slutsatser som sammanfattar i vilken utsträckning forskningsfrågan besvarats.

2 Metod

Detta kapitel redogör för och motiverar de metodologiska val som gjorts för att besvara studiens forskningsfrågor. Eftersom arbetet strävar efter att designa och utvärdera en IT-artefakt ställs specifika krav på forskningsansatsen. Först presenteras studiens övergripande vetenskapliga paradigm, följt av den undersökningsstrategi som valts för att framställa och utvärdera artefakten. Därefter beskrivs ramverket för utvecklingsarbetet, metoderna för datainsamling och dataanalys. Sedan förs en reflektion kring de metodologiska valen, och avslutningsvis redovisas hur AI-verktyg använts i arbetet.

2.1 Forskningsparadigm

Studien utgår från designvetenskap (design science) som det övergripande vetenskapliga paradigmet. Inom IS-forskning skiljer March och Smith (1995) designvetenskap från ett kompletterande förklarande paradigm, en distinktion som Hevner, March, Park och Ram (2004) konsoliderade och benämnde beteendevetenskap (behavioral science) och designvetenskap (design science). Det första, beteendevetenskap, syftar till att utveckla och verifiera teorier om mänskligt och organisatoriskt beteende, medan det andra, designvetenskap, syftar till att utöka mänskliga och organisatoriska förmågor genom att skapa nya artefakter (Hevner et al. 2004, s. 75). Medan beteendevetenskap söker förklara och förutsäga, strävar designvetenskap efter att förändra, genom att konstruera artefakter som löser praktiska problem (Hevner et al. 2004, s. 84). Designvetenskap är det paradigm som studiens frågeställning kräver, då syftet är att designa och utvärdera en IT-artefakt som löser ett praktiskt problem (Hevner et al. 2004; Johannesson & Perjons 2014).

Den ansats som präglar arbetet är abduktiv. I stället för att deduktivt testa förutsägelser härledda från befintliga teorier, eller induktivt samla empiri utan förhandsantaganden, innebär abduktiv slutledning en härledning till den bästa förklaringen (Wieringa 2014). Varje designcykel inleds med en konkret problembeskrivning, genererar en arkitekturell designhypotes och utvärderar denna mot uppmätt prestanda och intressentbedömning och är därför abduktiv i sin natur (Gregor, Chandra Kruse & Seidel 2020).

2.2 Forskningsmetod

Den specifika forskningsmetod och undersökningsstrategi som tillämpas i denna studie är Action Design Research (ADR). Till skillnad från designforskningsmodeller där byggande och utvärdering separeras i sekventiella faser (March & Smith 1995; Sein et al. 2011, s. 39), organiserar ADR forskningsprocessen som iterativa cykler av byggande och utvärdering. I varje cykel samspelar artefaktens tekniska utformning med den organisatoriska kontexten, vilket innebär att praktikens krav och insikter kontinuerligt kan fångas upp och omsättas i nästa designcykel (Sein et al. 2011, s. 37). ADR bedöms därför vara den mest lämpade forskningsmetoden för studiens syfte.

2.3 Ramverk för utvecklingsarbetet

Genomförandet av ADR är strukturerat utifrån fyra iterativa faser, vilka var och en vägleds av totalt sju underliggande principer (Sein et al. 2011, s. 40). En central aspekt av metoden är att dessa faser inte genomförs som en strikt linjär sekvens. Istället utgör de två första faserna problemformulering (*Problem Formulation*) samt konstruktion, intervention och utvärdering (*Building, Intervention and Evaluation*, BIE) en iterativ kärna där utvecklingen av artefakten

ständigt vävs samman med den organisatoriska kontexten. Den tredje fasen, reflektion och lärande, är inte ett efterföljande steg utan en löpande aktivitet som pågår parallellt med de övriga faserna. Forskningsprocessen avslutas därefter i den fjärde fasen formalisering av lärande (*Formalization of Learning*), där de kontextbundna resultaten och reflektionerna sammanfattas och formaliseras till generella designprinciper. Nedan följer en beskrivning av dessa faser och deras tillhörande principer, samt anknytning till detta arbete.

I denna studie konkretiseras faserna i en inledande problematiseringscykel och tre efterföljande designcykler. Problematiseringscykeln utgör en första genomgång av Fas 1 och etablerar studiens problemklass (Sektion 5.2). Varje designcykel genomför därefter Fas 1, 2 och 3 i följd. Cykeln inleds med en problemformulering som avgränsar dess konstruktionsmål, övergår i konstruktion, intervention och utvärdering, och avslutas med en reflektion vars lärdomar ligger till grund för nästa cykels problemformulering. Reflektionen är samtidigt en löpande aktivitet genom hela cykeln, i enlighet med att Fas 3 inte är ett efterföljande steg.

2.3.1 Fas 1: Problemformulering

Den inledande fasen drivs av ett problem som upplevts eller förutsätts i praktiken. Enligt Sein et al. (2011, s. 40) styrs denna fas av två principer. Den första principen, *Practice-Inspired Research*, innebär att forskningen inspireras av ett specifikt fältproblem men syftar till att skapa kunskap för den bredare klass av problem som fältproblemet exemplifierar. Den andra principen, *Theory-Ingrained Artifact*, innebär att den framtagna artefakten informeras och grundas i existerande teorier, vilka utgör basen för den initiala systemdesignen.

Fas 1 förekommer i studien dels i den inledande problematiseringscykeln (Sektion 5.2), dels som planeringssteget i var och en av de tre designcyklerna (Sektion 5.3.1, 5.4.1 och 5.5.1). *Practice-Inspired Research* tillämpades genom att studien utgick från tre verksamheters behov och därifrån härledde en bredare problemklass, vilket redovisas i Sektion 5.2.

Theory-Ingrained Artifact tillämpades genom att artefaktens initiala design grundades i GDPR:s rättsliga struktur. Skillnaden mellan strukturerade artikel 4-uppgifter och kontextberoende artikel 9-uppgifter motiverade uppdelningen i separata detektionslager. Etablerade arkitekturmönster för flerstegsdetektion (se Sektion 4.2) låg till grund för hur denna uppdelning omsattes i en konkret systemarkitektur.

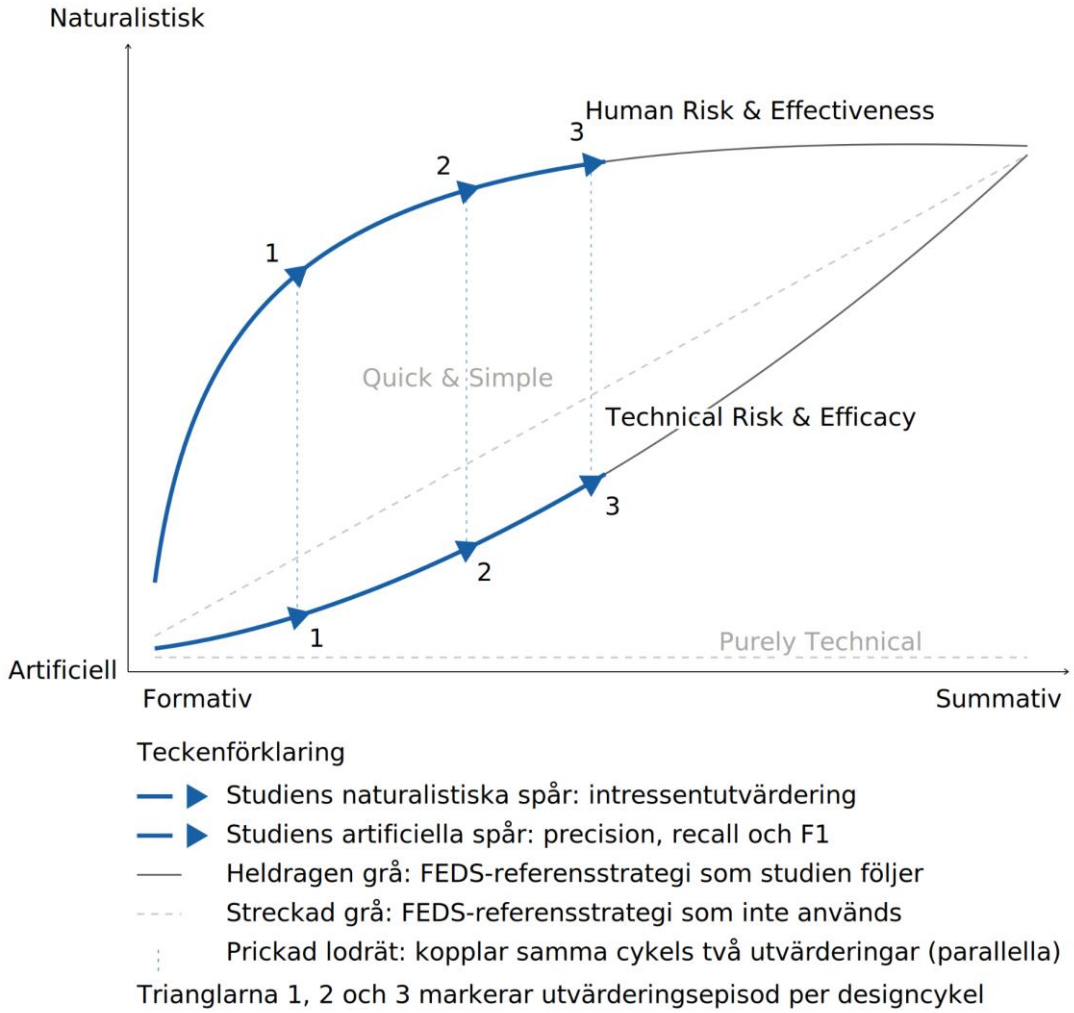
2.3.2 Fas 2: Konstruktion, Intervention och Utvärdering

Den andra fasen är den process där artefakten formas genom iterativ interaktion med den organisatoriska kontexten, och bygger på tre principer (Sein et al. 2011, s. 42–43). *Reciprocal Shaping* betonar att IT-artefakten och den organisatoriska kontexten är oskiljaktiga och påverkar varandra ömsesidigt under designprocessen. *Mutually Influential Roles* belyser att både forskare och praktiker bidrar med sina perspektiv under utvecklingen. *Authentic and Concurrent Evaluation* fastslår att utvärderingen inte är ett separat, efterföljande steg, utan sker integrerat och löpande samtidigt som artefakten byggs.

Fas 2 genomförs i var och en av studiens tre designcykler. Konstruktion och utvärdering sker växelvis inom cykeln, och den formativa utvärderingen blir direkt underlag för designbeslut och förfiningar av artefakten (Hevner 2007, s. 90–91; Sein et al. 2011, s. 43–44).

Interventionsmomentet i BIE-fasen har begränsats utifrån projektets tidsramar och artefaktens utvecklingsstadium. Studien följer det Sein et al. (2011, s. 42) benämner IT-dominant BIE, där tidiga versioner av artefakten utgör *light-weight interventions* i en begränsad organisatorisk kontext. Verksamhetsrepresentanterna från V1, V2 och V4 deltar genom demonstrationer i varje designcykel och bedömer artefakten utifrån sitt organisatoriska perspektiv. Det är denna återkommande interaktion under den naturalistiska utvärderingen som utgör interventionen i studien. Däremot omfattar studien inte instansiering av artefakten i respektive verksamhets egen driftsmiljö, vilket skulle motsvara den mer omfattande intervention med en betaversion som Sein et al. (2011, s. 42) beskriver, där artefakten utvärderas i en bredare organisatorisk användningsmiljö. Interventionen är därmed nedtonad i förhållande till denna mer omfattande form, men inte frånvarande, och dess utformning är anpassad till det stadium artefakten befinner sig i.

För att strukturera utvärderingen efter varje cykel tillämpas ramverket FEDS, som kategoriserar utvärdering utifrån dess funktionella syfte (formativ eller summativ) och dess paradigm (artificiell eller naturalistisk) (Venable, Pries-Heje & Baskerville 2016, s. 77). Eftersom studien ämnar utvärdera både artefaktens tekniska precision och dess nytta för organisationen kombineras artificiella och naturalistiska metoder i enlighet med ramverkets rekommendationer (Venable, Pries-Heje & Baskerville 2016, s. 87). Av de fyra utvärderingsstrategier ramverket identifierar (Venable, Pries-Heje & Baskerville 2016, s. 81) realiserar studien två parallellt och löpande över designcyklerna, nämligen *Human Risk & Effectiveness* för den intressentbaserade utvärderingen och *Technical Risk & Efficacy* för den tekniska mätningen. Valet motiveras av att artefaktens nytta behöver bedömas både mot organisatorisk relevans och mot dokumenterad teknisk prestanda, två kriterier som inte kan reduceras till varandra. Den naturalistiska utvärderingen struktureras i sin tur efter tre utvärderingskriterier som lyfts fram i FEDS-ramverket (Venable, Pries-Heje & Baskerville 2016, s. 79), nämligen nytta (*utility*), alltså i vilken grad artefakten är användbar för intressentens behov, ändamålsenlighet (*efficacy*), alltså i vilken grad artefakten åstadkommer det den är avsedd att göra, och organisatorisk passform (*fit with the organization*), alltså hur väl artefakten fungerar i intressentens organisatoriska sammanhang. Den tekniska mätningen i den sista cykeln är den mest summativa, eftersom den avslutar det artificiella utvärderingsspåret, men förblir indikativ med tanke på datavolymen. Den intressentbaserade utvärderingen är formativ genomgående, eftersom den bygger på demonstration och bedömning snarare än på artefaktens användning i drift. Studiens placering i ramverket, med de två strategierna och utvärderingsepisoderna per designcykel, visas i Figur 1.



Figur 1: Studiens utvärderingsstrategi placerad i FEDS-ramverket (Venable, Pries-Heje & Baskerville 2016, s. 81). Trianglarna markerar utvärderingsepisoder per designcykel.

2.3.3 Fas 3: Reflektion och lärande

Reflektion och lärande sker löpande under hela designcykeln, parallellt med konstruktion och utvärdering. Fasen styrs av principen *Guided Emergence*, som betonar att den slutgiltiga artefakten inte enbart speglar forskarnas initiala design, utan successivt växer fram och förfinas genom organisatorisk användning, intressenternas perspektiv och de löpande utvärderingarna (Sein et al. 2011, s. 44). Den löpande reflektionen dokumenteras i studiens loggbok (se Sektion 2.4.3).

Vid varje designcykels slut, när artefaktversionen är färdigställd och utvärderingsmötena med samarbetspartnerna är genomförda, sammanställs reflektionen i ett strukturerat steg. Sammanställningen utgår från tre frågor, nämligen hur artefakten presterade, vilka insikter om problemet som framträdde, och vilka konsekvenser detta får för nästa designcykel. Lärdomarna från både den tekniska utvärderingen och intressenternas återkoppling ligger sedan till grund för nästa designcykels problemformulering.

2.3.4 Fas 4: Formalisering av lärande

Det övergripande målet med ett ADR-projekt är inte enbart att lösa det specifika situerade problemet, utan att formalisera lärdomarna till generella lösningskoncept. Detta åstadkoms genom principen *Generalized Outcomes* (Sein et al. 2011, s. 44). I denna avslutande fas abstraheras kunskapen från den specifika instansen av artefakten och formuleras som generella designprinciper. Detta steg är centralt för att besvara studiens delfrågor om arkitektur (delfråga 1) och designprinciper (delfråga 4).

För att strukturera analysen och formaliseringen av designprinciperna (DP) tillämpas Gregor, Chandra Kruse och Seidels (2020) *Design Principle Schema*. Schemat valdes framför tidigare formuleringar eftersom det integrerar deras gemensamma kärnkomponenter, nämligen syfte (*aim*), kontext (*context*) och mekanism (*mechanism*), och kompletterar dessa med aktörsrollerna implementerare (*implementer*), användare (*user*) och aktör (*enactor*) samt möjligheten att hantera komplexitet genom dekomponering till underordnade designprinciper (Gregor, Chandra Kruse & Seidel 2020, s. 1633). De svenska benämningarna används genomgående i resten av uppsatsen. Schemats komponenter sammanfattas i Tabell 1.

Struktur	**Komponenter**
För att *Implementerare I* ska uppnå *Syfte S* för *Användare A*	Syfte, implementerare och användare
I *Kontext K*	Kontext: avgränsande villkor, implementeringsmiljö, ytterligare användarkarakteristika
Tillämpa *Mekanism M1, M2, M3* genom *Aktörer E1, E2, E3*	Mekanism: handlingar, aktiviteter, processer, form/struktur/arkitektur. Aktör: den komponent eller person som utför mekanismen. Underordnade komponenter kan ha egna designprinciper.
Motiverat av *R*	Motivering: teoretisk eller empirisk motivering för designprincipen

Tabell 1: Komponenter i *Design Principle Schema* (anpassad från Gregor, Chandra Kruse & Seidel 2020, s. 1633).

Den praktiska analysprocedur som översätter projektets dokumenterade underlag, det vill säga arkitekturen, loggbokens designbeslut och verksamhetsrepresentanternas feedback från BIE-cyklerna, till färdiga principer enligt schemat presenteras i Sektion 2.5.4.

Arkitekturen representeras parallellt genom klassdiagram i Unified Modeling Language (UML). Klassdiagrammen utgör den preskriptiva representationen av artefaktens principer för form och funktion, som Gregor och Jones (2007) beskriver som en abstrakt ritning eller arkitektur som kan avbildas i diagram. De är samtidigt ett av underlagen för formaliseringen av designprinciperna. Den arkitekturanalys som diagrammen sammanfattar är en av de tre källor som principformuleringen i Sektion 2.5.4 vilar på. Klassdiagram och designprinciper är därmed inte två fristående representationer, utan diagrammen ligger till grund för de principer som abstraheras ur arkitekturen.

2.4 Datainsamling

Studiens datainsamling tjänar två syften: att bygga den kunskapsbas som artefakten vilar på och att samla in den empiri som ADR-cyklerna kräver. Den teoretiska och tekniska kunskapsbasen (kapitel 3 och 4) identifierades genom en strukturerad litteraturinsamling, som redovisas först. Den empiriska datainsamlingen följer av ADR:s iterativa struktur. Designens framväxt under BIE-cyklerna behöver dokumenteras löpande för att kunna abstraheras i formaliseringsfasen, samtidigt som utvärderingsdata behöver samlas in efter varje cykel för att informera nästa. Datainsamlingen är därför uppdelad i fyra delar: litteraturinsamling för kunskapsbasen, kartläggning av intressenter, dokumentation under designcyklerna via loggbok, samt insamling av utvärderingsdata.

2.4.1 Litteraturinsamlingsmetod

För att identifiera den litteratur som behandlas i kunskapsbasen användes en kartläggande litteraturöversikt (scoping study) enligt Arksey och O'Malley (2005). Valet av en kartläggande översikt framför en fullständig systematisk översikt motiveras av studiens syfte. En sådan översikt belyser ett forskningsområdes bredd, identifierar centrala teman och visar var kunskapsluckor finns, snarare än att aggregera evidens från ett snävt avgränsat metodologiskt urval (Arksey & O'Malley 2005, s. 20–21). Studien behöver förankra sin arkitektoniska lösning i flera angränsande kunskapsområden, från dataskyddsförordningens juridiska struktur till tekniker för textbehandling, mjukvaruarkitektoniska mönster och designvetenskapliga prejudikat. Ansatsen svarar därför mot studiens behov.

Översikten följde de fem faser Arksey och O'Malley (2005, s. 22) anger: formulering av frågeställning, identifiering av relevanta studier, urval, kartläggning av data och sammanställning av resultat. Frågeställningen som styrde sökningarna var hur befintlig forskning hanterar kombinationen av juridiskt grundad textklassificering, lagerbaserad arkitektur och designkunskap inom GDPR-kontext. I linje med Arksey och O'Malleys (2005, s. 22) beskrivning av processen som iterativ snarare än linjär förfinades söktermerna efter hand som litteraturbilden klarnade, och urvalskriterierna preciserades parallellt med att fältets omfång blev tydligare. Detta är ett medvetet metodval, inte en eftergift. Metoden förutsätter att sökningen utvecklas reflexivt och att studier som framträder under arbetets gång hanteras på samma sätt som de som fångas i den inledande sökningen.

Identifieringen av studier var begreppsdriven och iterativ. Sökningarna utgick från de tre begreppsfält som sammanfattas i tabell 2 och genomfördes på engelska i Google Scholar, som indexerar den konferens- och tidskriftslitteratur fältet domineras av, kompletterat med citatspårning från centrala artiklar. Att följa referenser och citat från centrala studier lyfter Arksey och O'Malley (2005, s. 24) fram som ett värdefullt komplement till databassökning. Begreppsfälten beskriver den vokabulär sökningarna byggde på, inte fasta söksträngar med reproducerbara träfflistor, eftersom termerna kombinerades och förfinades efter hand. Varje källa som togs vidare lokaliserades därefter i Högskolan i Borås databasportal Primo och kontrollerades med avseende på publiceringstyp, granskningsstatus och tillgänglighet. Primo fungerade alltså som åtkomst- och verifieringslager. De etablerade arkitektur- och designvetenskapliga kärnkällorna söktes som primärlitteratur snarare än via begreppsfälten, och lagtext, rättsfall och teknisk dokumentation för artefaktens verktyg hämtades direkt som primär- och referenskällor, inte som resultat av litteratursökningen.

Begreppsfält	Centrala begreppstermer	Källa (urval)
Dataskydd, PII-detektion och anonymisering	GDPR, personal data, sensitive data, PII detection, data anonymisation, de-identification, information classification	Mishra, Pagare & Sharma (2025), Petrolini, Cagnoni & Mordonini (2022), Lorè et al. (2023), Löbner et al. (2025), Pilán et al. (2022), Lison, Pilán, Sanchez, Batet & Øvrelid (2021), Bergström, Karlsson & Åhlfeldt (2021), Li et al. (2022)
Textklassificering, NLP och entitetsigenkänning	text classification, named entity recognition, NER, transformer, relation extraction, synthetic data generation	He, Zhang, Liu, Sun & Zhang (2024), Shi et al. (2024)
Prompt engineering och in-context learning	prompt engineering, in-context learning, few-shot, chain-of-thought, zero-shot, large language model	Brown et al. (2020), Wei et al. (2022), Liu et al. (2023), Kojima, Gu, Reid, Matsuo & Iwasawa (2022)

Tabell 2: Begreppsfält och centrala söktermer för litteratursökningen.

Urvalet styrdes av de inklusions- och exklusionskriterier som sammanfattas i tabell 3. Studier om strukturerad data, rent juridiska analyser utan teknisk komponent och studier utanför EU:s eller motsvarande dataskyddsregelverks räckvidd föll utanför urvalet.

Dimension	Inkluderas	Exkluderas
Publiceringstyp	Kollegialt granskade artiklar och konferensbidrag samt vetenskapliga böcker	Icke granskade källor, med undantag för namngivna kärnteoretiska verk (se tabell 4)
Publiceringsår	2020 och framåt	Före 2020, med undantag för namngivna kärnteoretiska verk
Språk	Engelska och svenska	Övriga språk
Ämnesrelevans	Automatisk textklassificering, PII-detektion eller GDPR-efterlevnad via NLP eller maskininlärning, samt designvetenskaplig informationsklassificering	Strukturerad data, rent juridiska analyser utan teknisk komponent, studier utanför EU:s eller motsvarande dataskyddsregelverk

Tabell 3: Inklusions- och exklusionskriterier för urvalet.

Studiens forsknings- och evidensbas utgörs av kollegialt granskade tidskriftsartiklar och konferensbidrag. Konferensbidrag räknas här som granskade, eftersom de genomgår kollegial granskning inför antagning till sina vetenskapliga konferenser, även i de fall databasen inte

uttryckligen märker dem som granskade. Utöver dessa ingår ett avgränsat antal källor som inte är kollegialt granskade i traditionell mening, men som fyller bestämda roller utan att utgöra empiriskt stöd för studiens resultat. Dataskyddsförordningen, de två avgörandena från EU-domstolen och Integritetsskyddsmyndigheten utgör juridiska primärkällor och citeras som rättskälla och auktoritativ tolkning. Etablerade läroböcker för designmönster och designprinciper, de designvetenskapliga grundtexterna, Cavoukians (2009) ramverk för *Privacy by Design* och Luhns (1960) patent bär de teorier, mönster och algoritmer som designarbetet vilar på. ISO-standarderna för IBAN och betalkortsnummer samt dokumentationen för artefaktens verktyg citeras för tekniska specifikationer och implementationsdetaljer.

Tidsavgränsningen till 2020 och framåt motiveras av att fältets tekniska bas, särskilt transformerbaserade språkmodeller och promptbaserade metoder, utvecklats snabbt under perioden. Undantag gjordes för ett begränsat antal äldre källor som utgör kärnteoretisk grund för designarbetet och som inte ersätts av nyare litteratur. Dessa redovisas i tabell 4.

Källa	**År**	**Roll i designarbetet**
Luhn	1960	Algoritmisk validering av numeriska identifierare i lager 1
Gamma et al.	1994	Objektorienterade designmönster (GoF)
Buschmann et al.	1996	Arkitekturmönster (POSA)
Martin	2003	Objektorienterade designprinciper (SOLID)
Gregor och Jones	2007	Ramverk för justificatory knowledge
Cavoukian	2009	Inbyggt dataskydd (*Privacy by Design*) som designorientering
Cavoukian, Taylor och Abrams	2010	Ansvarsskyldighet i dataskyddsstyrning

Tabell 4: Kärnteoretiska källor som utgör undantag från tidsavgränsningen.

Materialet kartlades mot en analysram i fyra dimensioner: om artikeln behandlar automatisk klassificering av text utifrån dataskyddsförordningens juridiska kategorier, om den skiljer mellan artikel 4 och artikel 9, om den använder en lagerbaserad arkitektur som kombinerar mönsterigenkänning, NER och semantisk analys, och om den formulerar designprinciper via DSR eller ADR. Utifrån denna ram sorterades studierna i fyra grupper: direkt relevanta arbeten som täcker en eller flera dimensioner, partiellt överlappande studier från angränsande problemklasser, tangentiella källor med juridisk eller bakgrundskontext, och arbeten som låg utanför studiens omfång. Kompletterande sökningar och de avgöranden som gjordes under urvalet dokumenterades löpande i studiens loggbok, i enlighet med Arksey och O'Malleys (2005, s. 22) krav på transparent dokumentation, så att urvalsbesluten kan följas och granskas snarare än att enskilda sökträffar ska kunna återskapas.

Denna genomgång formade kunskapsbasens fortsatta struktur. Det rättsliga ramverket framträdde som en distinkt kunskapsbas och behandlas i kapitel 3. De tekniker som ingår i flerstegsdetektion av personuppgifter delades upp i tre tekniktraditioner med var sin litteratur och behandlas i kapitel 4, tillsammans med de arkitektoniska mönster som binder samman

lagren. Den empiriska konvergens som framträdde när flera oberoende studier visade sig nå snarlika tekniska kombinationer i olika domäner och språkkontexter behandlas i kapitel 3. Den kunskapslucka som motiverar studien är kombinationen av lagerbaserad arkitektur, juridiskt grundad taxonomi för både artikel 4 och artikel 9, formaliserade designprinciper genom designvetenskaplig metod och svenskspråkig generell organisatorisk fritext.

2.4.2 Kartläggning av intressenter

För att säkerställa att artefakten utgick från ett verkligt och generaliserbart problem, i enlighet med ADR:s princip om *Practice-Inspired Research* (Sein et al. 2011), inleddes datainsamlingen med utforskande möten och dialoger. Totalt har fyra verksamheter ingått i studien, men sammansättningen har förändrats mellan faserna. V1, V2 och V3 deltog i problematiseringsfasen. Urvalet eftersträvade en jämn fördelning mellan privat och offentlig sektor. V3, som företrädde offentlig sektor, deltog dock endast i problematiseringsfasen och återkom inte inför designcyklerna, och någon ersättare hann inte rekryteras inom projektets tidsram. De naturalistiska utvärderingarna genomfördes därför med V1 och V2 från privat sektor och V4 från offentlig sektor, vilket innebär att offentlig sektor företräds av en enda verksamhet. Vad detta innebär för underlagets bredd behandlas som en begränsning i Sektion 9.6. Verksamheterna skiljer sig åt i storlek, domän och bransch (se Tabell 5).

Organisation	**Storlek (Antal anställda)**	**Domän**	**Bransch**	**Intervjuade roller (Intressenter)**
V1	Medel (650+)	Privat	IT	Mjukvaruarkitekt, dataskyddsansvarig
V2	Liten (~30)	Privat	IT	Verksamhetschef, Informationssäkerhetskonsult
V3	Stor (~60 000)	Offentlig	Offentlig förvaltning	AI-strateg
V4	Stor (~60 000)	Offentlig	Offentlig förvaltning	AI-strateg

Tabell 5: Översikt över involverade organisationer och intressenter

Verksamheterna valdes enligt fyra kriterier. Det första var geografisk tillgänglighet. Verksamheterna behövde ligga inom rimligt avstånd från Högskolan i Borås för att möjliggöra personliga möten och demonstrationssessioner. Det andra var GDPR-relevans. Verksamheten behövde i sin löpande verksamhet hantera text som kan innehålla personuppgifter eller känsliga uppgifter enligt GDPR, oavsett bransch. Det tredje gällde rollernas relevans. Den eller de personer som representerade verksamheten behövde ha insyn i frågor om informationssäkerhet, dataskydd eller AI-tillämpning, inte nödvändigtvis som juridisk GDPR-specialist men med tillräcklig domänförståelse för att kunna bedöma artefaktens nytta och passform. Det fjärde var sektorsbredd. Urvalet eftersträvade variation längs två dimensioner, privat kontra offentlig sektor och liten kontra stor organisation, för att undvika att problembilden och utvärderingen blev sektorsspecifik.

Urvalsstrategin är ett strategiskt urval (Patton 2015) med ett inslag av bekvämlighetsurval för den geografiska dimensionen. Syftet var inte statistisk representativitet utan att säkerställa att de organisatoriska krav och bedömningar som formade artefakten kom från verksamheter med genuint behov och tillräcklig kompetens att utvärdera den. Datainsamlingen i problematiseringsfasen genomfördes som explorativa dialogmöten och dokumenterades i form av anteckningar. Dessa anteckningar utgör det empiriska underlaget för problematiseringscykeln, som redovisas i Sektion 5.2.

2.4.3 Dokumentation under BIE-cyklerna

Utvecklingen av artefakten genomfördes i tre iterativa designcykler. Eftersom ADR betonar att designen växer fram successivt, en princip Sein et al. (2011) benämner *Guided Emergence*, krävdes en systematisk metod för att spåra hur artefakten formades över tid. För detta ändamål användes en loggbok som det primära verktyget för datainsamling under designcyklerna. Loggboken fördes löpande och utan fördefinierad mall, för att fånga observationer, designbeslut och insikter allteftersom de uppstod utan att tvinga in dem i förutbestämda kategorier. Den utgör därmed den rådata som senare låg till grund för att extrahera och formalisera studiens designprinciper. Loggboken är ett löpande internt arbetsdokument av betydande omfattning som förts av författarna under hela arbetet. De designbeslut den dokumenterar redovisas för läsaren i genomförande- och arkitekturkapitlen och återges inte som bilaga.

2.4.4 Datainsamling för utvärdering

I enlighet med det valda FEDS-ramverket samlades utvärderingsdata in genom både naturalistiska och artificiella metoder efter de avslutade designcyklerna, för att mäta systemets förmåga att identifiera och klassificera känsligt innehåll.

Artificiell (kvantitativ) datainsamling. För att utvärdera artefaktens tekniska precision samlades kvantitativ prestandadata in under systemtester. Ett testdataset bestående av både känsliga och okänsliga textsträngar matades in i artefakten. Med känsliga avses här texter som innehåller personuppgifter enligt GDPR artikel 4, särskilda kategorier enligt artikel 9 eller kombinationer av uppgifter som tillsammans möjliggör identifiering enligt skäl 26. Datasetets sammansättning utvidgades stegvis mellan designcyklerna i takt med att artefakten utökades med nya detektionslager. Systemets klassificeringsbeslut loggades och fördes in i en konfusionsmatris på entitetsnivå. Mätningen per designcykel utgår från ett versionerat snapshot av artefakten som motsvarar den version intressenterna möter i den naturalistiska sessionen. Snapshotet är knutet till en specifik kommithash i utvecklingshistoriken, vilket gör mätningen reproducerbar mot exakt den artefaktversion som demonstrerades. Snapshot-rutinen infördes från och med designcykel 2; designcykel 1:s mätning är i stället reproducerbar genom en live-körning mot datasetet (se Sektion 7.1.1). Den insamlade datan bestod av antalet sanna positiva, falska positiva och falska negativa, vilket möjliggjorde beräkning av recall och precision. Den närmare definitionen av matchningsnivå och mätetal redovisas i Sektion 2.5.2.

Naturalistisk (kvalitativ) datainsamling. För att utvärdera artefaktens nytta och acceptans för verksamheten samlades kvalitativ data in genom demonstrationer och semistrukturerade intervjuer med de identifierade intressenterna (se Tabell 5). Varje session varade omkring 30 minuter, varav cirka tio minuter för demonstrationen och resterande tid för intervjun.

Intervjuguiden strukturerades tematiskt utifrån tre utvärderingskriterier som lyfts fram i FEDS-ramverket, nytta, ändamålsenlighet och organisatorisk passform (Venable, Pries-Heje &

Baskerville 2016, s. 79). Varje tematiskt block följde en gemensam mall, med en bred inledande fråga (introductory question) som öppnade temat, en eller flera specificerande frågor (specifying questions) som flyttade samtalet från generellt till specifikt, och förberedda fördjupande frågor (probing questions) för att utveckla svaren utan att styra dem. Frågetyperna följer Kvale och Brinkmanns (2015) typologi för semistrukturerade forskningsintervjuer. Mellan designcyklerna reviderades guiden i enlighet med ADR:s fas reflektion och lärande (Sein et al. 2011, s. 44), så att den följde med artefaktens och frågeställningarnas utveckling över cyklerna.

Genomförandet av intervjuerna följde Myers och Newmans (2007) riktlinjer för kvalitativa intervjuer inom informationssystemsforskning. Sessionerna genomfördes fysiskt på plats eller digitalt via Microsoft Teams, beroende på intressentens preferens och geografiska förutsättningar. Den ena författaren ledde samtalet medan den andra förde strukturerade anteckningar löpande, utifrån en mall organiserad efter de tre kriterierna. Fysiska möten spelades in och transkriberades med dikteringsfunktionen i Microsoft Word, digitala möten via Teams inbyggda funktion. Demonstrationen genomfördes av författarna med ett fast antal testtexter konstruerade för att isolera respektive lagers förmåga, så att intressentens bedömning kunde kopplas till specifika delar av arkitekturen snarare än till artefakten som helhet. Intressenterna kunde därutöver köra egna texter i systemets fritextfält och på så sätt testa formuleringar från sin egen verksamhetskontext.

Anteckningarna utgör det primära datamaterialet. Transkriberingarna användes som referensmaterial när en anteckning behövde verifieras eller kompletteras, eftersom den automatiska transkriberingskvaliteten varierade och inte bedömdes tillräcklig för att ensam bära analysen. Citat som används i rapporten är hämtade ur transkriberingarna och verifierade mot inspelningarna. Utelämnade ord eller fraser markeras med hakparenteser kring tre punkter, [...], medan utelämningar i början eller slutet av ett citat lämnas omarkerade.

2.5 Dataanalys

Dataanalysen i denna studie omfattar fyra spår, ett för varje delfråga. Arkitekturen analyseras genom de dokumenterade designvalen och representeras med UML. Den tekniska prestandan analyseras kvantitativt utifrån utfallet av den artificiella utvärderingen. Intressentbedömningen analyseras tematiskt enligt FEDS utvärderingskriterier. Designprinciperna formaliseras enligt Gregor, Chandra Kruse och Seidels (2020) schema med stöd av loggbok och intressentbedömning. De fyra spåren reflekterar att studiens forskningsfråga är uppdelad i fyra komplementära dimensioner som tillsammans karaktäriserar artefakten, nämligen dess form, dess prestanda, dess praktiska användbarhet och dess bakomliggande principer.

2.5.1 Analys och representation av arkitektur

För att besvara studiens första delfråga analyseras de tekniska vägval och integrationsmönster som dokumenterats under utvecklingsprocessen. Inom designteori fungerar principer för form och funktion som en abstrakt ritning (blueprint) över IT-artefaktens arkitektur (Gregor & Jones 2007). För att formalisera denna analys används UML för att sammanställa ett abstrakt klassdiagram, vilket åskådliggör systemets klasser, metoder och komponentrelationer i den underliggande klassificeringsmekanismen.

2.5.2 Kvantitativ analys av teknisk prestanda

För att besvara studiens andra delfråga analyseras den kvantitativa datan från den artificiella utvärderingen. Syftet är att bedöma artefaktens förmåga att korrekt identifiera och klassificera GDPR-känsligt innehåll. Utifrån systemets utfall registreras sanna positiva (True Positives, TP), falska positiva (False Positives, FP) och falska negativa (False Negatives, FN) på entitetsnivå i en konfusionsmatris (Sokolova & Lapalme 2009). Sanna negativa (True Negatives, TN) räknas på dokumentnivå som de texter vilkas facit saknar annoterade fynd och som artefakten korrekt lämnar oflaggade. Recall och precision används som primära mått i stället för accuracy, eftersom de känsliga entiteterna är många i förhållande till antalet helt okänsliga texter, och ett accuracy-mått därför skulle domineras av de korrekt oflaggade fallen (Sokolova & Lapalme 2009).

Recall är studiens primära mätvärde. Det anger andelen korrekt identifierade känsliga förekomster av samtliga faktiska känsliga förekomster i testdatan (Ekvation 1). Recall prioriteras eftersom artefakten verkar under en fail-safe-princip, där missad känslig data utgör en allvarligare felklassificering än överflaggning. En missad känslig uppgift motverkar det proaktiva integritetsskydd som *Privacy by Design* föreskriver som standard (Cavoukian 2009). Denna prioritering har stöd i anonymiseringslitteraturen, där recall behandlas som måttet på integritetsskydd och precision som måttet på bevarad datanytta, och där flera författare föreslår att recall ges dubbel vikt (F2) för att spegla att en missad uppgift väger tyngre än en felflaggning (Pilán et al. 2022, s. 1074).

	Faktiskt känslig entitet	**Faktiskt icke-känsligt innehåll**
Flaggad av artefakten	Sann positiv (TP)	Falsk positiv (FP)
Inte flaggad	Falsk negativ (FN)	Sann negativ (TN), på dokumentnivå

Tabell 6: Konfusionsmatrisens fyra utfall. TP, FP och FN räknas på entitetsnivå, TN på dokumentnivå.

En känslig entitet som artefakten flaggar räknas som sann positiv, en flaggning av icke-känsligt innehåll som falsk positiv, och en känslig entitet som inte flaggas som falsk negativ. En text utan känsligt innehåll som artefakten lämnar oflaggad räknas som sann negativ på dokumentnivå.

$$Recall = TP \div (TP + FN) \qquad \text{Ekvation 1}$$

Precision rapporteras som sekundärt mätvärde. Det anger andelen korrekt identifierade känsliga förekomster av samtliga som artefakten flaggat som känsliga (Ekvation 2), och indikerar därmed systemets benägenhet för överflaggning.

$$Precision = TP \div (TP + FP) \qquad \text{Ekvation 2}$$

F1-måttet är det harmoniska medelvärdet av precision och recall (Ekvation 3) och ger ett sammanvägt värde när de två behöver vägas mot varandra.

$$F1 = 2 \times (Precision \times Recall) \div (Precision + Recall)$$ Ekvation 3

2.5.3 Analys av intressentbedömning enligt FEDS

För att besvara studiens tredje delfråga analyseras intervjuanteckningarna genom tematisk analys (Braun & Clarke 2006) med en kombinerad deduktiv-induktiv ansats. Den deduktiva ramen utgörs av tre utvärderingskriterier som lyfts fram i FEDS-ramverket, nytta, ändamålsenlighet och organisatorisk passform (Venable, Pries-Heje & Baskerville 2016), medan induktiva teman tillåts framträda under analysarbetet för att fånga organisationsspecifika mönster. Analysen genomförs på semantisk nivå inom ett realistiskt paradigm, vilket innebär att intressenternas uttalade bedömningar tolkas direkt utifrån vad som sägs snarare än som uttryck för underliggande sociala konstruktioner.

Analysen genomförs gemensamt av båda författarna. För varje FEDS-kategori går författarna igenom anteckningarna från sessionerna och kontrasterar intressenternas bedömningar mot varandra, så att både konvergerande mönster och organisationsspecifika särdrag framträder. Dessa mönster och särdrag utgör underlaget för bedömningen av artefakten enligt FEDS utvärderingskriterier, och fungerar samtidigt som empiriskt underlag för formaliseringen av designprinciper i Sektion 2.5.4.

2.5.4 Formalisering av designprinciper

För att besvara studiens fjärde delfråga analyseras den kvalitativa datan från projektets loggbok samt demonstrationerna med intressenterna. I enlighet med ADR-metodikens sista fas, formalisering av lärande, abstraheras den situerade kunskapen från BIE-cyklerna för att härleda generaliserade designprinciper (Sein et al. 2011). För att systematisera processen tillämpas ramverket av Gregor, Chandra Kruse och Seidel (2020). Ramverket möjliggör en strikt formulering genom att bryta ner principerna i definierade komponenter, nämligen implementerare, syfte, användare, kontext, mekanism, aktör samt motivering, både teoretisk och empirisk. Genom att härleda principerna från artefaktens arkitektur och de designbeslut som dokumenterats i loggboken omvandlas studiens tekniska val till tydliga och generaliserbara lösningskoncept.

Underlaget för principformuleringen utgörs av tre källor med olika funktion i förhållande till schemat. Arkitekturanalysen (Sektion 2.5.1) bidrar med artefaktens form, alltså de mekanismer och strukturer som klassdiagrammet sammanfattar och som utgör principernas mekanismkomponent. De designbeslut som dokumenterats i loggboken bidrar med den teoretiska motiveringen, det vill säga förankringen i kernel theory och i GDPR samt de alternativ som övervägdes under designcyklerna. De konvergerande mönster som identifieras i intressentbedömningen (Sektion 2.5.3) bidrar med den empiriska motiveringen, alltså belägg för att mekanismerna är värdefulla i organisatorisk kontext. Principerna abstraheras därmed inte enbart från artefaktens tekniska form, utan också från den situerade kunskap som loggboken och BIE-cyklernas utvärderingar genererat.

2.6 Metodreflektion

Designvetenskaplig forskning förutsätter en löpande reflektion över metodvalen, dels för att forskaren samtidigt är konstruktör och utvärderare av artefakten (Sein et al. 2011), dels för att studiens forskningskvalitet behöver redovisas öppet (Hevner et al. 2004). Reflektionen följer metodkapitlets disposition, nämligen val av forskningsansats och undersökningsstrategi (Sektion 2.6.1), utvärdering och dataanalys (Sektion 2.6.2), studiens kvalitet enligt Hevner et al. (2004) dimensioner relevans, stringens och bidrag (Sektion 2.6.3), samt etiska överväganden (Sektion 2.6.4).

2.6.1 Val av forskningsansats och undersökningsstrategi

Valet att genomföra studien utifrån DSR och ADR motiverades av målet att ta fram en praktisk IT-artefakt för ett komplext och situerat problem. Ett alternativ hade varit en mer sekventiell DSR-metodik, exempelvis den process Peffers, Tuunanen, Rothenberger & Chatterjee (2007) beskriver, där utvärderingen utgör ett eget steg efter att artefakten konstruerats. En sådan ansats hade dock medfört en risk att artefakten utvecklades isolerat från användarnas faktiska behov. Genom att istället tillämpa ADR:s iterativa designcykler (Sein et al. 2011) kunde systemet kontinuerligt testas och omformas i samråd med intressenterna, vilket ökade artefaktens organisatoriska relevans. En inneboende utmaning med ADR är dock forskarens dubbla roll som både systemutvecklare och utvärderare, vilket medför en risk för partiskhet där utvärderingsdata omedvetet tolkas till den egna designens fördel.

För att motverka risken används tre mekanismer. Den artificiella utvärderingen ger kvantitativa mätvärden som inte tillåter tolkningsmässig efterhandsjustering och fungerar därmed som korrigeringsinstans mot den kvalitativa bedömningen. Den naturalistiska utvärderingen analyseras gemensamt av båda författarna, där konvergerande och divergerande mönster mellan intressenterna registreras systematiskt (Sektion 2.5.3). Loggboken dokumenterar designbesluten och deras motivering löpande under arbetet, vilket gör dem spårbara både internt under studiens gång och för utomstående granskning.

2.6.2 Reflektion kring utvärdering och dataanalys

För att hantera risken för partiskhet och skapa en robust utvärdering valdes ramverket FEDS (Venable, Pries-Heje & Baskerville 2016). Genom att kombinera artificiell och naturalistisk utvärdering minskades beroendet av enskilda subjektiva bedömningar: den kvantitativa mätningen gav ett mått på teknisk tillförlitlighet som inte var öppet för efterhandstolkning, medan den naturalistiska utvärderingen fångade hur intressenterna upplevde artefaktens nytta i sin egen kontext.

En svaghet i den naturalistiska utvärderingen är att urvalet är litet, tre verksamheter (V1, V2 och V4) deltog i utvärderingarna efter designcyklerna (se Tabell 7 i Sektion 5.1). Urvalet är dock konstruerat enligt principen om variationsbaserad sampling, där bredden i kontexter prioriteras framför antalet enheter (Patton 2015). De tre verksamheterna representerar tre distinkta kontexter inom problemklassen: privat IT i större skala (V1), privat IT i mindre skala (V2) och offentlig förvaltning (V4). Tillsammans täcker de privat och offentlig sektor samt olika storleksordningar, vilket bedöms tillräckligt för en formativ utvärdering som syftar till att driva fram en fungerande artefakt och extrahera generaliserbara designprinciper.

Den artificiella utvärderingen vilar på ett egenkonstruerat testdataset, vilket medför två validitetsrisker. Datasetet kan spegla författarnas egen förståelse av problemet och göra utvärderingen cirkulär, och ett syntetiskt dataset representerar inte nödvändigtvis den faktiska textdistributionen i organisatoriska sammanhang. Båda riskerna motverkas delvis genom en hybrid-metod där kandidater genererade av en stor språkmodell (LLM) granskas manuellt av båda författarna med konsensuskrav, en ansats inspirerad av Pilán et al. (2022) som kombinerar automatiskt framtagna annoteringsförslag med mänsklig granskning och revidering, och genom en data statement enligt Bender och Friedman (2018) som redovisar datasetets ursprung och begränsningar (Bilaga B). Begränsningen kvarstår ändå: en mer rigorös extern validering skulle kräva testdata från faktiska organisatoriska kontexter, vilket ligger utanför studiens omfattning och konfidentialitetsmässiga ramar.

Valet av recall som primärt mätvärde, motiverat i Sektion 2.5.2, innebär att den artificiella utvärderingens resultat ska läsas som ett system medvetet kalibrerat mot ett asymmetriskt felkostnadsförhållande, inte som ett balanserat klassificeringssystem. F1 rapporteras som komplement men ska tolkas mot denna asymmetri.

2.6.3 Forskningskvalitet i designforskning

Forskningskvaliteten i en designvetenskaplig studie vilar enligt Hevner et al. (2004) på tre dimensioner, nämligen studiens relevans för en faktisk problemklass, stringensen i konstruktion och utvärdering, och dess bidrag till kunskapsbasen.

Relevansen säkerställdes genom att problemformuleringen förankrades hos tre oberoende verksamheter redan i problematiseringsfasen (Sektion 2.6.1, 5.2), vilket gör att det problem artefakten löser är rotat i verkliga verksamhetsbehov.

Stringensen vilar på att konstruktion och utvärdering genomgående förankrats i etablerade metoder från kunskapsbasen. Forskningsmetod, utvärderingsramverk, intervjumetodik, urvalsstrategi och formalisering av designprinciper motiveras var för sig i Sektion 2.2 till 2.5, medan de tekniska metodvalen för prompt- och testdatakonstruktion motiveras i kapitel 5 (Sektion 5.1.1 och 5.1.2). Tillämpningen dokumenteras löpande i loggboken och redovisas för läsaren i rapportens genomförande- och arkitekturkapitel, vilket gör studiens tillvägagångssätt spårbart. Den artificiella utvärderingens reliabilitet vilar på att varje mätning utgår från ett versionerat snapshot knutet till en specifik kommithash (Sektion 2.4.4). Eftersom lager 3 och 4 anropar en språkmodell är utfallet inte strikt deterministiskt mellan körningar, men variationen är liten i förhållande till skillnaderna mellan designcyklerna och påverkar inte slutsatserna.

Studiens bidrag till kunskapsbasen riktas mot den kunskapslucka som identifierats i litteraturgenomgången, där lagerbaserad detektion, integrerad artikel 4- och artikel 9-taxonomi och formaliserade designprinciper för svenskspråkig generell organisatorisk fritext utgör en kombination som tidigare forskning inte adresserat. Genom ADR:s avslutande fas abstraheras studiens situerade lösning till två generaliserbara komponenter: ett arkitekturellt klassdiagram som representerar lagerstrukturen och dess relationer, och en uppsättning designprinciper formulerade enligt Gregor, Chandra Kruse och Seidel (2020). Bidraget är därmed både artefaktuellt, klassdiagrammet som ritning för en problemklass, och teoretiskt, designprinciperna som lösningsbeskrivning på abstrakt nivå. Studien bidrar däremot inte med en validerad produktionsfärdig artefakt eller en heltäckande GDPR-efterlevnadslösning, vilket ligger utanför syftet och adresseras i begränsningsdiskussionen.

2.6.4 Etiska överväganden

I de naturalistiska utvärderingarna informerades intressenterna tydligt om studiens syfte, och deras deltagande grundades på informerat samtycke. Muntligt informerat samtycke inhämtades innan den första intervjun. Eftersom datainsamlingen skedde digitalt kompletterades samtycket därefter skriftligt, daterat till den tidpunkt då det skriftliga samtycket inhämtades. Den verksamhet som endast deltog i problematiseringsfasen (V3) lämnade muntligt samtycke vid deltagandet och deltog därefter inte vidare i studien. De deltagande verksamheterna anonymiseras i rapporten med kodnamn (V1, V2 och V4), och varken organisationsnamn eller individuella roller redovisas på ett sätt som möjliggör återidentifiering.

Intervjuerna spelades in efter inhämtat samtycke och kompletterades med skriftliga anteckningar. Inspelningarna transkriberades med stöd av Microsoft 365-tjänster. Inspelningar, transkriberingar och anteckningar har hanterats med begränsad åtkomst för de två författarna och handledaren, och materialet raderas efter att examensarbetet har examinerats.

Den artificiella utvärderingen genomfördes med syntetiskt testdata. Personnamn och övriga personuppgifter i testkorpusen är fabricerade och avser inga verkliga personer, och de organisationsnamn som förekommer är offentliga och används som icke-individidentifierande exempel utan koppling till de berörda organisationerna. Testdatats karaktär redovisas i en data statement (Bilaga B). Inga verkliga personuppgifter eller företagshemligheter exponerades därmed i utvärderingen.

Artefaktens potentiella effekter för individer, organisationer och samhälle bör också beaktas. Systemet är utformat som ett kompletterande säkerhetslager snarare än en heltäckande lösning, vilket innebär att ansvaret för GDPR-efterlevnad kvarstår hos de organisationer som väljer att använda det. Felklassificeringar medför konsekvenser åt båda håll: missad känslig data riskerar lagöverträdelser och exponering av enskildas uppgifter, medan överklassificering skapar ökad arbetsbelastning och kostnader. Nyttan fördelas också ojämnt: en lokal och resurssnål klassificerare sänker framför allt tröskeln för mindre verksamheter som idag saknar tekniskt dataskyddsstöd, medan de vars uppgifter finns i texten gynnas av bättre upptäckt utan att själva möta systemet. Artefaktens etiska värde beror därför på vad den jämförs med. Där mänsklig granskning redan sker är artefakten ett beslutsstöd och inte ett självständigt avgörande. I textflöden som i dag inte granskas alls, exempelvis storskaliga automatiserade flöden där manuell genomläsning aldrig varit praktiskt möjlig, innebär en automatisk klassificering ett tillskott av skydd även när den är ofullständig. Artefaktens nytta är på så sätt som störst just där ingen kontroll annars skulle ske, förutsatt att dess begränsningar är kända för den som inför den.

En ytterligare etisk dimension rör implementationskontexten. Beroende på hur och var artefakten integreras finns en risk att den används för att övervaka enskilda medarbetares kommunikation, vilket inte är systemets avsedda syfte. Även frågor om datalagring och om systemets förmåga att inte behålla känslig information mellan sessioner är relevanta, men ligger utanför studiens scope och bör adresseras vid en faktisk driftsättning.

2.7 Användning av AI-verktyg

AI-verktyg har använts som stödjande resurs genom hela forskningsprocessen, både i utvecklingen av artefakten och i författandet av rapporten. Användningen redovisas här i enlighet med högskolans riktlinjer och krav på transparens kring AI-användning i examensarbeten.[1]

Tre kategorier av verktyg har använts. För arkitektoniskt och metodologiskt stöd, granskning av textutkast, formulering av strukturerade prompter och kontroll av studiens röda tråd har Claude (Anthropic) använts i en separat chattsession laddad med projektets dokumentation. För implementationsarbetet i kodbasen har agentbaserade kodningsverktyg använts under författarnas granskning; det arbetsflödet och de modeller som ingick redovisas närmare i Sektion 5.1.3. För källförankrade sammanställningar och faktagranskning mot litteraturen har NotebookLM (Google) använts, eftersom verktyget tillhandahåller utdrag från de specifika källor som matats in och därigenom möjliggör verifiering av påståenden mot ursprungstext. Utöver dessa stödverktyg användes en lokal språkmodell (gemma2:9b) (Google 2026) som en metodologisk komponent i konstruktionen av det syntetiska testdatasetet; den användningen och dess manuella granskningssteg redovisas i Sektion 5.1.1.

Ansvarsfördelningen mellan författare och verktyg har följt en konsekvent princip: alla forskningsfrågor, designbeslut, metodval och analytiska slutsatser har formulerats och beslutats av författarna. Uppsatsens huvudsakliga innehåll är författarnas eget arbete och återspeglar deras förståelse av ämnet, och inget avsnitt har genererats utan ett betydande eget bidrag. Verktygen har använts för att producera kandidatutkast, identifiera oklarheter, föreslå formuleringar och stödja granskning av text och kod. Samtliga textavsnitt har genomgått manuell granskning och redigering, och inga AI-genererade formuleringar har överförts till uppsatsen utan att ha bearbetats och godkänts av författarna.

Två moment har medvetet hållits utanför verktygens påverkan. Det första är de naturalistiska utvärderingarna, där intervjuanteckningarna förts manuellt under sessionerna och den tematiska kodningen genomförts av båda författarna gemensamt. Det andra är formuleringen av designprinciperna enligt Gregor, Chandra Kruse och Seidels (2020) schema, där den situerade kunskapen från BIE-cyklerna och dialogen med verksamhetsrepresentanterna utgör underlaget snarare än AI-genererade generaliseringar.

Kvalitetssäkring av verktygens output har skett på tre sätt. Faktapåståenden som rör litteraturen har verifierats mot de aktuella källorna, vid behov med stöd av NotebookLM. Citat och referenser har kontrollerats manuellt mot originalkällan. Implementationskod har validerats genom automatiserade tester och manuell genomgång innan integration i kodbasen.

[1] Tsertsidis, A. & Sjöström, J. (2026). *Riktlinjer för etisk användning av Generativ AI vid skrivande av kandidatuppsats*. Institutionen för informationsteknologi, Högskolan i Borås, kursen 21KI1C, VT2026. Internt kursdokument.

3 Teoretisk kunskapsbas

Detta kapitel redogör för den teoretiska kunskapsbas som artefakten vilar på. I designvetenskaplig mening utgör den beskrivande kunskap (Ω), alltså det som är känt om problemområdet: vad dataskyddsförordningen definierar som personuppgift, hur känslighet bedöms juridiskt, och vad tidigare forskning visat om hur sådana uppgifter kan identifieras i text (Gregor & Hevner 2013). Kapitlet behandlar först det rättsliga ramverkets centrala begrepp, som utgör artefaktens domänmässiga grund, och positionerar därefter studien mot den empiriska forskning där liknande detektionsansatser prövats i andra domäner och språkkontexter. Den tekniska och arkitektoniska kunskap som omsätter dessa förutsättningar i en konkret lösning behandlas separat i kapitel 4.

3.1 Definition och kategorisering av personuppgifter enligt GDPR

Europaparlamentets och rådets förordning (EU) 2016/679 (GDPR) fastställer de rättsliga definitioner som studiens kategorisering av personuppgifter utgår från (Europaparlamentets och rådets förordning [EU] 2016/679). En precis förståelse av definitionerna är en förutsättning för att utforma och utvärdera klassificeringen, eftersom gränsdragningen mellan allmänna och särskilt skyddsvärda uppgifter ställer olika krav på systemets precision och säkerhetsåtgärder. Avsnittet redogör för dessa definitioner, för principerna om ansvarsskyldighet och inbyggt dataskydd, och för de tekniska gränsdragningar som uppstår vid automatisk identifiering.

3.1.1 Allmänna personuppgifter (artikel 4)

Enligt dataskyddsförordningens artikel 4(1) definieras personuppgifter som varje upplysning som avser en identifierad eller identifierbar fysisk person (Europaparlamentets och rådets förordning [EU] 2016/679). Lagstiftningen tillämpar en vid tolkning av begreppet, vilket innebär att system för dataklassificering inte enbart behöver identifiera explicita markörer (som namn eller personnummer), utan även behöver ta hänsyn till indirekta identifierare såsom onlineidentifikatorer, däribland IP-adresser, eller kombinationer av faktorer som rör en persons fysiska, ekonomiska eller sociala identitet.

En central juridisk gränsdragning rör hur modifierade data hanteras. Pseudonymiserade uppgifter, där identifierande element har ersatts med en pseudonym men där kopplingen till en individ kan återupprättas med hjälp av en separat nyckel, utgör fortfarande personuppgifter i lagens mening och faller därmed inom ramen för vad ett klassificeringssystem behöver kunna detektera och flagga som skyddsvärd information (Europaparlamentets och rådets förordning [EU] 2016/679). Anonymiserade uppgifter däremot, där informationen har genomgått en irreversibel process så att individen inte längre kan identifieras med de medel som rimligen kan komma att användas (skäl 26), upphör att vara personuppgifter. Denna gränsdragning är central för automatiserad klassificering, eftersom ett system avsett för att identifiera personuppgifter behöver kunna skilja dem från anonymiserad data för att inte generera falska positiva resultat.

3.1.2 Särskilda kategorier av personuppgifter (artikel 9)

Vissa uppgifter anses vara till sin natur så integritetskänsliga att behandlingen av dem medför betydande risker för individens rättigheter och friheter. Dessa betecknas i artikel 9(1) som ”särskilda kategorier av personuppgifter” och omfattar data som avslöjar exempelvis ras eller etniskt ursprung, politiska åsikter, uppgifter om hälsa eller sexuell läggning (Europaparlamentets och rådets förordning [EU] 2016/679).

Medan allmänna personuppgifter ofta förekommer i en deterministisk form (exempelvis strukturerade mönster för personnummer), återfinns artikel 9-uppgifter ofta implicit i ostrukturerad text. För automatiserade system innebär detta en teknisk utmaning som kräver kontextuell och semantisk analys, eftersom huvudregeln för dessa uppgifter är att behandling är förbjuden om inte specifika undantag är uppfyllda. Precision i detekteringen av dessa kategorier är därför avgörande för systemets tillförlitlighet.

3.1.3 Ansvarsskyldighet

Utöver att definiera kategorierna av personuppgifter ställer dataskyddsförordningen långtgående krav på organisationers förmåga att bevisa regelefterlevnad. I artikel 5(2) lagfästs principen om ansvarsskyldighet (accountability), vilken stipulerar att den personuppgiftsansvarige ansvarar för att principerna efterlevs och uttryckligen måste kunna visa att så är fallet (Europaparlamentets och rådets förordning [EU] 2016/679). För att uppfylla detta krav krävs teknisk spårbarhet som gör databehandlingen transparent och granskningsbar. Detta krav har en konceptuell grund i accountability-baserad integritetsstyrning, där Cavoukian, Taylor och Abrams (2010) kopplar Privacy by Design-principerna till konkreta ansvarsskyldighetsmekanismer och visar att ansvar i praktiken förutsätter att en organisations integritetsbeslut kan dokumenteras och verifieras.

För att ett automatiserat klassificeringssystem ska uppfylla detta krav i praktiken räcker det inte att systemet de facto identifierar känsliga uppgifter. Det måste även erbjuda teknisk spårbarhet som gör förfarandet transparent och granskningsbart. Ansvarsskyldighetsprincipen utgör därmed en juridisk grund för att system av denna klass behöver byggas med inbyggd spårbarhet, så att det tekniskt registreras och motiveras vilka komponenter och vilka regler som ligger till grund för ett givet detektionsbeslut.

3.1.4 Inbyggt dataskydd

I artikel 25 lagfäster dataskyddsförordningen kravet på inbyggt dataskydd och dataskydd som standard (data protection by design and by default). Bestämmelsen kräver att dataskyddsprinciperna integreras i systemets utformning från utvecklingens början, inte som efterhandsåtgärder (Europaparlamentets och rådets förordning [EU] 2016/679). Den konceptuella grunden för detta krav återfinns i ramverket *Privacy by Design* (Cavoukian 2009), som beskriver sju grundprinciper för hur integritetsskydd ska byggas in i teknik, affärsprocesser samt fysisk och nätverksbaserad infrastruktur. Två av principerna är särskilt relevanta för en automatiserad GDPR-klassificerare. Den första är förebyggande snarare än reaktiv (proactive not reactive), som anger att integritetsrisker ska förebyggas innan de inträffar i stället för att hanteras i efterhand. Den andra är integritet som standardinställning (privacy as the default), som anger att systemet automatiskt ska leverera maximalt skydd utan att kräva aktivt agerande från användaren (Cavoukian 2009).

För en automatiserad GDPR-klassificerare aktualiseras integritet som standardinställning vid valideringsosäkerhet. När systemet är osäkert om en text innehåller känslig data finns två möjliga utfall: klassificering som känslig med risk för administrativ börda, eller klassificering som icke-känslig med risk för regelbrott. Cavoukians (2009) princip kräver att skyddet upprätthålls automatiskt, vilket innebär att osäkerhet bör tippa över till förmån för integritetsskydd. Det motsatta valet kräver aktiv mänsklig korrigering för att skyddet ska återupprättas, vilket motsäger principens premiss. Detta utgör den designteoretiska grunden för

att valideringslogiken i ett system av denna klass vid osäkerhet bör höja, snarare än sänka, den bedömda känslighetsnivån.

3.2 Tidigare forskning om identifiering av personuppgifter

Den forskning som introducerades i forskningsöversikten (Sektion 1.2) behandlas här mer ingående, som relaterade arbeten och tekniska ansatser. Syftet är att kartlägga hur fältet hittills har löst automatisk identifiering av personuppgifter i text, vilka arkitekturer som dominerar och hur den juridiska taxonomin hanteras, för att kunna avgränsa var studiens bidrag tillför något nytt.

Tekniskt konvergerar litteraturen mot flerstegsarkitekturer som kombinerar regelbaserad detektion, entitetsigenkänning och kontextuell analys. Mishra, Pagare & Sharma (2025) kombinerar regelbaserad NLP, maskininlärning och en anpassad NER-modell för PII-detektion i engelskspråkiga finansiella dokument och rapporterar en precision på 94,7 procent och en recall på 89,4 procent. Lorè et al. (2023) bygger med INTREPID, som är en pipeline för italienska myndighetsdokument där regelbaserade ordlistor och SpaCy-baserad NER fungerar som indata till maskininlärningsklassificerare som SVM och XGBoost. Löbner et al. (2025) tillämpar en parallell kombination av reguljära uttryck, lexikon och BERT-baserad NER för avidentifiering av CV-dokument. Pilán et al. (2022) jämför i Text Anonymization Benchmark generisk NER mot sekretessorienterade och finjusterade sekvensetiketteringsmodeller på en korpus av engelska rättsfall, och Petrolini, Cagnoni & Mordonini (2022) använder Transformer-baserade modeller för att fånga den kontext som enklare metoder missar. Karras et al. (2025) rekommenderar i en metaöversikt liknande flerstegsarkitekturer för säkerhetskänsliga miljöer, medan Lison et al. (2021, s. 4188) argumenterar för att enkel sekvensmärkning behöver kompletteras med explicita mått för röjanderisk. Den gemensamma nämnaren är att ingen enskild teknik räcker, utan att lagrade kombinationer krävs för att täcka spannet från strukturerade identifierare till implicit känsligt innehåll.

Där studierna skiljer sig åt är i hur den juridiska taxonomin operationaliseras. Flera arbeten lägger inte dataskyddsförordningens distinktion mellan artikel 4 och artikel 9 till grund för sin ansats (Karras et al. 2025; Mishra, Pagare & Sharma 2025). Andra avgränsar sig till en del av taxonomin. Petrolini, Cagnoni & Mordonini (2022) fokuserar sin klassificering på artikel 9-kategorier, och Lorè et al. (2023) inriktar sig på hälsouppgifter i en specifik dokumenttyp. Pilán et al. (2022) skiljer mellan direkta identifierare, kvasiidentifierare och konfidentiella attribut, en indelning som överlappar med artikel 4 och artikel 9 men inte är strukturerad enligt förordningens distinktion. Det är i praktiken endast arbeten i gränslandet mot designvetenskap, som Löbner et al. (2025), som uttryckligen särskiljer artikel 4 från artikel 9, och även där inom ett avgränsat dokumentformat.

En tredje grupp arbeten visar att traditionen att formalisera designkunskap genom designvetenskaplig forskning är etablerad, men inte tillämpad på denna problemklass. Bergström, Karlsson och Åhlfeldt (2021) genomför en svensk DSR-studie som mynnar ut i designprinciper för informationsklassificering, men på en manuell organisatorisk processnivå utan automatisk textanalys. Li et al. (2022) operationaliserar dataskyddsförordningens principer som testbara krav i en mjukvaruorganisations infrastruktur, utan textanalytisk komponent. De designvetenskapliga prejudikaten saknar alltså textdetektion, medan de tekniskt avancerade arbetena saknar designvetenskaplig förankring.

Skärningspunkten mellan dessa rörelser, en lagerbaserad detektion med integrerad artikel 4- och artikel 9-taxonomi, formaliserade designprinciper och svenskspråkig generell organisatorisk fritext, är det område där befintlig forskning inte räcker till. Vad detta innebär för studiens utgångspunkter sammanfattas i nästa avsnitt.

3.3 Sammanfattande teoretiska utgångspunkter

Sammantaget ger den teoretiska kunskapsbasen tre utgångspunkter för designarbetet. För det första kräver dataskyddsförordningens distinktion mellan artikel 4 och artikel 9 att en klassificerare hanterar både deterministiska och kontextberoende uppgifter, med olika krav på precision. För det andra ställer principerna om ansvarsskyldighet och inbyggt dataskydd krav på spårbarhet och på att osäkerhet hanteras till förmån för skydd. För det tredje visar genomgången av tidigare forskning (Sektion 3.2) att flerstegsdetektion är etablerad praxis, samtidigt som den specifika kombination studien adresserar saknas i fältet. Dessa utgångspunkter motiverar de tekniska och arkitekturella val som behandlas i nästa kapitel.

4 Teknisk och arkitektonisk kunskapsbas

Detta kapitel redogör för den tekniska och arkitektoniska kunskapsbas som artefakten bygger på. Till skillnad från den beskrivande kunskapen i kapitel 3 utgör detta preskriptiv designkunskap (Λ), alltså etablerad kunskap om hur artefakter av detta slag konstrueras, i form av tekniker, designmönster och principer (Gregor & Hevner 2013). Litteraturen behandlas här som *justificatory knowledge* (Gregor & Jones 2007), den kunskapsbas som rättfärdigar designvalen och gör dem prövbara mot etablerad praxis. Kapitlet redovisar först de tekniska byggblock som litteraturen identifierar för automatiserad detektion, deras styrkor och begränsningar, och därefter de arkitekturella mönster och designprinciper som behandlar hur sådana byggblock kan sammansättas i ett sammanhängande system.

4.1 Tekniska byggblock för automatiserad detektion

För att systematiskt kunna identifiera de olika kategorier av personuppgifter som dataskyddsförordningen definierar, krävs en kombination av tekniker. Följande avsnitt redogör för de tekniska byggblock som litteraturen identifierar för automatiserad detektion av personuppgifter, deras respektive styrkor, samt deras inneboende begränsningar.

4.1.1 Regelbaserad mönsterigenkänning och reguljära uttryck

Reguljära uttryck (regex) och regelbaserade system utgör en fundamental ansats för textanalys. Tekniken fungerar genom att söka efter exakta, fördefinierade mönster eller statiska strukturer i en textsträng (Löbner et al. 2025, s. 181–182; Mishra, Pagare & Sharma 2025, s. 1–2). Till detta kopplas ofta checksummevalidering, en etablerad metod för att upptäcka oavsiktliga fel i numeriska identifierare genom att beräkna en kontrollsiffra utifrån föregående siffror i sekvensen (Anderson 2020, s. 261–262). En av de mest utbredda algoritmerna för detta ändamål är Luhn-algoritmen (Luhn 1960), som ursprungligen utvecklades för att maskinellt verifiera identifikationsnummer. Kreditkortsnummer innehåller på motsvarande sätt en kontrollsiffra för att upptäcka inmatnings- och läsfel (Anderson 2020, s. 262).

Litteraturen visar att regelbaserad detektion är mycket effektiv och särskilt lämpad för att identifiera strukturerade dataelement med ett statiskt och förutsägbart format, såsom e-postadresser, telefonnummer och webbadresser (Löbner et al. 2025, s. 181–182). Samtidigt präglas tekniken av stor oflexibilitet. Deterministiska metoder har avsevärda begränsningar när de appliceras på ostrukturerade format, där de ofta producerar en hög grad av falska positiva (false positives) och därmed anses otillförlitliga för att ensamma hantera ostrukturerad text (Mishra, Pagare & Sharma 2025).

Sammantaget pekar litteraturen på att regelbaserad mönsterigenkänning är ett ändamålsenligt val för identifiering av personuppgifter med fast och förutsägbart format, särskilt när den kombineras med kontrollsifferbaserad validering (Anderson 2020) för att hantera den falska positiva-problematik som ostrukturerad text medför. För personuppgifter med varierande eller implicit form krävs däremot kompletterande tekniker.

4.1.2 Igenkänning av namngivna entiteter

För att överkomma begränsningarna hos statisk mönsterigenkänning används NER, ett delområde inom NLP. NER syftar till att lokalisera och klassificera namngivna entiteter i text till fördefinierade kategorier (Lorè et al. 2023, s. 545). Modellerna lär sig identifiera specifika

kategorier, såsom personnamn, organisationer och platser, genom iterativa träningsloopar på annoterade dataset (Lorè et al. 2023, s. 543; Mishra, Pagare & Sharma 2025, s. 7).

Trots att NER är utmärkt för att extrahera strukturerade data ur fritext, belyser litteraturen flera begränsningar. Generella NER-modeller presterar ofta sämre på nischad domäntext, exempelvis byråkratiskt språk inom offentlig förvaltning (Lorè et al. 2023, s. 546). Vidare tenderar NER att systematiskt övermaskera (falska positiva) genom att flagga ord enbart baserat på deras semantiska typ, oavsett om de i sin kontext faktiskt utgör en risk för att röja en identitet (Pilán et al. 2022, s. 1055, 1073). Dessutom missar tekniken ofta mer indirekta identifierare, så kallade kvasiidentifierare (*quasi-identifiers*) (Pilán et al. 2022, s. 1054).

Sammantaget visar litteraturen att NER är väl lämpat för att fånga de dynamiska och oförutsägbara identitetsmarkörer som regelbaserade mönster missar. Samtidigt indikerar begränsningarna i domänförståelse och svårigheterna med indirekta identifierare att NER inte räcker som sista steg i klassificering av ostrukturerad text, utan behöver kompletteras med kontextuell analys.

4.1.3 Kontextuell analys

För att hantera implicit och ostrukturerad text tillämpas kontextuell analys, vanligen byggd på neurala språkmodeller av varierande storlek och arkitektur. De flesta moderna ansatser bygger på Transformer-arkitekturen, från mindre modeller till stora språkmodeller (Large Language Model, LLM) med betydligt fler parametrar. Transformers använder en "attention"-mekanism som läser inmatningssekvenser bidirektionellt för att skapa en matematisk vektorrepresentation baserad på ordets omgivande sammanhang (Petrolini, Cagnoni & Mordonini 2022, s. 4–6). LLM:er är gigantiska varianter av dessa nätverk, tränade för att förstå semantik och genomföra logiska resonemang (Chaplia & Klym 2025, s. 720).

Denna förmåga att förstå implicit semantik gör tekniken extremt kraftfull för att upptäcka känsliga uppgifter enligt dataskyddsförordningens artikel 9 (exempelvis hälsa, politisk åsikt och sexuell läggning). AI-baserad kontextuell analys presterar bäst där data präglas av språklig tvetydighet och kan upptäcka att ett dokument är känsligt även när uppgiften och personnamnet befinner sig i olika meningar (Petrolini, Cagnoni & Mordonini 2022, s. 2, 7).

Tekniken är dock resursintensiv och svår att driftsätta lokalt (Mishra, Pagare & Sharma 2025, s. 5). Kommersiella LLM:er som körs i molnet medför allvarliga integritetsrisker rörande tredjelandsöverföring och dataläckage, vilket direkt kan bryta mot dataskyddsförordningen (Karras et al. 2025, s. 44, 46). Dessutom är de probabilistiska till sin natur, vilket medför en risk för "hallucinationer" om de används utan mänsklig tillsyn (Karras et al. 2025, s. 44). Hur språkmodellers utfall görs prövbart och replicerbart trots denna probabilistiska natur är en metodologisk fråga som behandlas i nästa avsnitt.

Spänningen mellan teknisk kapacitet och regulatorisk efterlevnad framstår i litteraturen som ett kvarstående designövervägande för system som tillämpar kontextuell analys på persondata. Karras et al. (2025) framhåller att kommersiella molnmodeller medför risker rörande tredjelandsöverföring, angrepp där känslig indata kan återskapas ur modellen och otillåten sekundär användning av prompter, medan lokala modeller minskar extern exponering men kräver omfattande resurser och kan kvarhålla interna risker (Chaplia & Klym 2025; Karras et al. 2025). Litteraturen ger inget allmängiltigt svar på avvägningen utan ramar in den som ett implementationsspecifikt val.

4.1.4 Prompts och prompt engineering

Att styra en språkmodell mot en specifik uppgift, som klassificering av ostrukturerad text, kräver en strukturerad inmatning, en prompt. Att dess utformning påverkar utfallet vilar på två mekanismer. Den första är probabilistisk. En förtränad modell modellerar sannolikheten för text, och promptens roll är att flytta sannolikhetsmassan mot önskad utdata utan att modellens vikter ändras (Liu et al. 2023). Den andra är in-context learning, där modellen tillämpar en ny uppgift enbart utifrån demonstrationer i prompten (Brown et al. 2020). Prompt engineering handlar därför inte om att skriva en sträng i taget, utan om att designa generaliserbara mallar som klarar varierad inmatning. Inom en sådan mall återkommer ett antal komponenter: en rollbeskrivning som situerar modellen, en uppgiftsformulering, kontext att luta sig mot, ett specificerat utdataformat och exempel som visar önskat beteende. He et al. (2024, s. 335) sammanfattar grundmönstret som "instruction + requirement + text" och argumenterar för att requirement-delen säkerställer att modellen genererar en stabil och väldefinierad datastruktur, exempelvis JSON-format.

Few-shot prompting innebär att modellen ges några exempel på uppgiften inuti prompten vid inferens, utan att vikterna uppdateras (Brown et al. 2020). One-shot och few-shot ligger konsekvent över zero-shot, vilket gör tekniken till förstahandsval när exempel kan formuleras kompakt. Kontextfönstret sätter den övre gränsen för antalet exempel. Urval och ordning påverkar resultatet kraftigt: Liu et al. (2023) beskriver att felaktigt valda exempel kan sänka prestandan mot slumpnivå, och att exempel kan väljas dynamiskt via semantisk likhet med den aktuella inmatningen.

Chain-of-thought (CoT) adresserar uppgifter som kräver flerstegsresonemang (Wei et al. 2022). Två förbehåll är dock centrala: tekniken är en emergent förmåga kopplad till modellskala, och Wei et al. (2022) rapporterar att effekten uppträder först runt 100 miljarder parametrar medan mindre modeller i stället riskerar att producera ologiska resonemangskedjor. Det andra förbehållet är att det inte finns någon garanti för att modellen resonerar korrekt även när slutsvaret är rätt. Kojima et al. (2022) visar att en del av effekten kan nås i en zero-shot-miljö genom instruktionen "Let's think step by step", vilket utvidgar tillämpningsområdet bortom strikt few-shot.

Hallucinationsrisken kan hanteras på promptnivå genom konfidensgrindar och förankring av svaret med källhänvisningar, vilket gör det möjligt att hantera avvikelser i stället för att förkasta hela svaret (Karras et al. 2025), medan retrieval-augmented generation utgör ett komplement där externa dokument förankrar svaret (Shi et al. 2024). Eftersom även små semantiska förändringar i prompten kan ge stora skillnader i utdata behöver skillnaden mellan modellens generella förmåga och promptens förmåga att konsekvent extrahera denna förmåga hållas isär analytiskt. Promptdesign styr därmed enskilda inferenssteg, medan frågan om hur sådana steg kombineras med regelbaserade och statistiska komponenter i en sammanhängande arkitektur är ämnet för nästa avsnitt.

4.2 Arkitekturmönster för flerstegsdetektion

Att kombinera flera detektionstekniker i ett sammanhållet system förutsätter en arkitektonisk struktur som hanterar både uppdelningen mellan tekniker och deras inbördes relation. Detta avsnitt redogör för fem etablerade mönster som tillsammans utgör *justificatory knowledge* för design av sådana system (Gregor & Jones 2007). Fyra av dem härstammar ur den klassiska

litteraturen kring objektorienterad och komponentbaserad arkitektur (Gamma, Helm, Johnson & Vlissides 1994; Buschmann, Meunier, Rohnert, Sommerlad & Stal 1996) och behandlar orkestreringsstruktur, lageruppdelning, utbytbarhet av komponenter och enhetlig hantering av sammansatta strukturer. Det femte mönstret berör spårbarhet och dataursprung, en egenskap som i litteraturen om AI-system och dataskyddsefterlevnad framhålls som en förutsättning för granskningsbarhet och regelefterlevnad (Barbudo Carrasco 2025; Thaldar 2025). Tillsammans bildar de fem mönstren ett arkitektoniskt ramverk för system av denna klass. Avsnittet avslutas med två generella principer för objektorienterad design som kompletterar mönstren genom att ange egenskaper koden bör ha snarare än färdiga strukturer.

4.2.1 Pipeline-mönstret

Pipeline-mönstret, formellt benämnt *Pipes and Filters* (Buschmann et al. 1996), strukturerar ett system där bearbetning av data sker som en sekvens av oberoende steg. Mönstret består av filter, som läser in data, transformerar den och skickar den vidare, och rör (pipes), som ansluter filtren och hanterar dataflödet mellan dem (Buschmann et al. 1996, s. 56–57). Det adresserar den arkitektoniska situation där en bearbetningsuppgift naturligt kan delas upp i flera steg, där systemkraven förväntas förändras över tid och där enskilda bearbetningssteg behöver kunna bytas ut eller kastas om (Buschmann et al. 1996, s. 53–54).

Mönstrets styrkor är flexibilitet och återanvändbarhet: filter kan bytas ut eller kombineras på nya sätt, pipelinen kan byggas ut stegvis, och flera filter kan potentiellt exekveras parallellt (Buschmann et al. 1996, s. 67–68). Avvägningarna gäller framför allt att dela tillstånd mellan filter, vilket är komplicerat, och att implementera systemövergripande felhantering i en pipeline (Buschmann et al. 1996, s. 68–69). Mönstret är väl etablerat för sekventiell textbearbetning och utgör grundstrukturen i bland annat kompilatorers analysfaser (Buschmann et al. 1996, s. 53, 56, 60).

För ett system som klassificerar text utifrån GDPR:s kategorier motiverar mönstrets avvägningar två designval. Att tillståndsdelning är kostsam motiverar att varje detektionssteg hålls statslöst, och att felhantering är svår att sprida över en pipeline motiverar att den centraliseras till en koordinerande komponent.

4.2.2 Lageruppdelning

Lageruppdelning, formellt benämnd *Layers* (Buschmann et al. 1996), strukturerar ett system i hierarkiska skikt där varje skikt utgör en distinkt abstraktionsnivå. Strukturellt tillhandahåller ett lager tjänster enbart till lagret ovanför och delegerar deluppgifter till lagret nedanför (Buschmann et al. 1996, s. 34–35). Mönstret är avsett för stora system som behöver dekomponeras efter abstraktionsnivå, där en ostrukturerad helhet ska ges tydliga ansvarsområden och strukturella gränser (Buschmann et al. 1996, s. 31–34).

Mönstrets styrkor är att hela lager kan återanvändas, att gränssnitten mellan dem standardiseras, och att ändringar i ett lager hålls lokala i stället för att fortplanta sig genom systemet. Mönstret stödjer dessutom utbytbarhet, genom att ett lager kan ersättas med en alternativ implementation utan att övriga lager påverkas (Buschmann et al. 1996, s. 48–49). Avvägningarna är att en ny funktion ibland kräver kaskaderande ändringar genom samtliga lager, och att rätt antal lager och rätt granularitet är svårt att fastställa i den initiala designen (Buschmann et al. 1996, s. 50–51). Buschmann et al. behandlar mönstret huvudsakligen för nätverksprotokoll, operativsystem och affärssystem, inte i textanalyssammanhang.

För GDPR-klassificering av fritext motiverar mönstret att detektionen delas upp efter abstraktionsnivå, från syntaktiska mönster i strukturerad text via entitetsidentifiering till semantisk analys av implicit innebörd. Utbytbarheten och de lokala ändringarna gör mönstret lämpat för en iterativ utvecklingsmodell där enskilda detektionsnivåer kan utvecklas och utvärderas oberoende av varandra. Avvägningen kring kaskaderande ändringar kan begränsas genom att lagren kommunicerar via ett gemensamt domänobjekt, vilket håller förändringar lokala till respektive lager.

4.2.3 Utbytbara komponenter

Mönstret för utbytbara komponenter, formellt benämnt *Strategy* (Gamma et al. 1994), definierar en familj av algoritmer, kapslar in varje algoritm i en egen komponent och gör dem inbördes utbytbara. Strukturellt består mönstret av ett gränssnitt som specificerar det gemensamma kontraktet, en eller flera konkreta implementationer som realiserar gränssnittet med varsin algoritm, och en kontext som håller en referens till den aktuella implementationen och kommunicerar med den enbart via gränssnittet (Gamma et al. 1994, s. 316–317). Mönstret är avsett för system där flera relaterade klasser skiljer sig åt enbart i sitt beteende, eller där en applikation behöver olika varianter av samma algoritm beroende på kontext eller resurskrav (Gamma et al. 1994, s. 316).

Mönstrets styrkor är att det erbjuder ett flexibelt alternativ till att skapa subklasser för varje algoritmvariant, eliminerar komplexa villkorssatser och tillåter systemet att växla mellan implementationer under körning (Gamma et al. 1994, s. 317–318). Avvägningarna är att klienten måste kunna skilja på algoritmerna för att välja rätt, och att antalet klasser i systemet ökar (Gamma et al. 1994, s. 318). Mönstret introduceras via just textanalys, där olika algoritmer för radbrytning kapslas in som utbytbara strategier (Gamma et al. 1994, s. 315–316).

I system av denna klass är mönstret tillämpbart på två nivåer. Inom regelbaserad mönsterdetektion kan varje typ av personuppgift hanteras av en egen igenkänningskomponent under ett gemensamt kontrakt, så att komponenter kan läggas till eller bytas ut oberoende av varandra. På systemnivå kan hela detektionsnivåer ses som utbytbara enheter, där exempelvis en entitetsigenkänningsmodul kan ersättas med en alternativ modell utan att övriga nivåer påverkas. Avvägningen om ökat antal klasser är en rimlig kostnad när designen prioriterar utbytbarhet och utvärderbarhet per komponent framför kompakthet.

4.2.4 Sammansatta fynd

Composite-mönstret (Gamma et al. 1994) gör det möjligt att behandla en sammansatt struktur och dess enskilda delar enhetligt genom ett gemensamt gränssnitt. Strukturellt definierar mönstret ett gränssnitt som är gemensamt för både enskilda objekt och sammansatta objekt, så att en klient kan hantera en grupp av objekt på samma sätt som ett enskilt objekt utan att känna till om strukturen är sammansatt eller inte (Gamma et al. 1994, s. 163–164). Mönstret är avsett för system där objekt naturligt bildar del-helhet-hierarkier och där klienter bör kunna bortse från skillnaden mellan en enskild del och en sammansättning av delar (Gamma et al. 1994, s. 164).

Den positiva konsekvensen är att klientkoden förblir enkel, eftersom den behandlar sammansatta och enskilda objekt likadant. Avvägningen är att den enhetliga behandlingen kan göra det svårare att begränsa vilka typer som får ingå i en sammansättning (Gamma et al. 1994,

s. 166). I system för flerstegsdetektion är mönstret tillämpbart där flera enskilda detektionssignaler tillsammans bildar ett sammansatt fynd som en koordinerande komponent ska kunna hantera utan att känna till dess inre sammansättning. Mönstret kompletterar därmed de tre föregående genom att hantera relationen mellan ett aggregerat fynd och dess beståndsdelar. När flera lager producerar överlappande eller delvis motstridiga signaler på samma textspann räcker det inte att samla dem under ett gemensamt gränssnitt, utan någon komponent måste också väga signalerna mot varandra. Behovet av en sådan koordinerande sammanvägning följer av konvergensen i Sektion 3.2, där litteraturen visar att ingen enskild detektionsteknik räcker utan att lagrade kombinationer krävs. Composite-mönstret ger den strukturella formen för aggregatet, medan den konkreta logiken för hur lagrens utfall vägs samman mot varandra utvecklas som designbidrag i genomförandet.

4.2.5 Spårbarhet och dataursprung

Spårbarhet och dataursprung (data provenance) avser ett systems förmåga att dokumentera databearbetningens livscykel, registrera ursprung och visa hur data transformeras genom systemets steg. Till skillnad från de föregående mönstren härstammar spårbarhet inte ur den klassiska arkitekturlitteraturen, utan ur forskningen om transparens och granskningsbarhet i AI-system. Barbudo Carrasco (2025, s. 187, 189) operationaliserar spårbarhet genom två kompletterande komponenter: metadata, som beskriver datas ursprung och kontext, och paradata, som dokumenterar de processer och beslut som tas när data samlas in, transformeras och analyseras. Thaldar (2025, s. 8) beskriver spännvidden i teknisk spårbarhet, från fullständig realtidsloggning till integritetsbevarande spårbarhet inbäddad direkt i de algoritmiska arbetsflödena.

Spårbarhetens styrkor är att den skapar formell granskningsbarhet, möjliggör upptäckt av algoritmisk bias och utgör tekniskt underlag för legala krav på ansvarsskyldighet, däribland GDPR:s artikel 5.2 (Barbudo Carrasco 2025, s. 186, 190–191; Thaldar 2025, s. 8). Avvägningen är att detaljerade loggar i sig kan utgöra integritetsrisker om de inte hanteras varsamt (Thaldar 2025, s. 8). Barbudo Carrasco (2025, s. 189–190) framhåller också att spårbarhet är särskilt central i system där data flödar genom sekventiella bearbetningssteg, eftersom paradata då fortlöpande dokumenterar de processuella stegen.

För ett system som klassificerar text utifrån GDPR:s kategorier motiverar mönstret att ursprunget till varje klassificeringsbeslut registreras: vilken komponent som producerat ett fynd, vilken konfidens som rapporterats och vilka fynd som överlappar i samma textavsnitt. Sådan spårbarhet är ett tekniskt svar på GDPR:s princip om ansvarsskyldighet (artikel 5.2, se Sektion 3.1.3) och gör det möjligt för en organisation att i efterhand granska och motivera systemets klassificeringar. Avvägningen kring integritetsrisker kan hanteras genom att enbart metadata om beslutsvägen registreras, utan att den känsliga datan dupliceras utanför sin bearbetningskontext.

4.2.6 Principer för objektorienterad design

Utöver mönstren vilar artefaktens struktur på två av de principer för objektorienterad design som Martin (2003, s. 99) sammanställer. Principerna är senare allmänt kända under akronymen SOLID, även om Martin själv inte använder den termen. Till skillnad från ett mönster, som anger en återkommande lösning på ett strukturellt problem, anger en princip en egenskap som koden bör ha. De två som är relevanta för ett system av denna klass är *Single Responsibility*

Principle och *Open-Closed Principle*. Dessa ska inte förväxlas med studiens egna designprinciper, DP1 till DP6, som formaliseras i kapitel 8.

Single Responsibility Principle anger att "a class should have only one reason to change" (Martin 2003, s. 95). Martin motiverar principen med att varje ansvarsområde utgör en egen orsak till förändring, och att en klass med flera ansvar kopplar samman dem så att en ändring i det ena kan skada det andra. Resultatet blir sköra designer som går sönder oväntat när koden modifieras (Martin 2003, s. 95–96). För ett flerlagerssystem motiverar principen att ett lager med två oberoende ansvar delas i två, så att varje detektionsmetodologi kan ändras isolerat.

Open-Closed Principle anger att programvaruentiteter "should be open for extension, but closed for modification" (Martin 2003, s. 99). Enligt Martin är abstraktion nyckeln, och ett stabilt abstrakt gränssnitt gör att nytt beteende läggs till genom nya implementationer i stället för genom ändringar i fungerande kod, vilket hindrar att en förändring fortplantar sig som en kaskad genom beroende moduler (2003, s. 99–100, 103). För en klassificerare motiverar principen att framtida detektionskategorier kan förberedas strukturellt utan att den befintliga koden skrivs om.

4.3 Sammanfattande tekniska designimplikationer

De tekniker och mönster som redovisats pekar tillsammans mot en specifik arkitektonisk inriktning. Inget enskilt byggblock räcker för att täcka spannet från deterministiska identifierare till implicit känslig text, vilket motiverar en lagerbaserad kombination där regelbaserad detektion, entitetsigenkänning och kontextuell analys hanterar var sin abstraktionsnivå. Mönstren för pipeline, lageruppdelning, utbytbarhet och sammansatta fynd anger hur dessa nivåer kan orkestreras med bibehållen utbytbarhet och granskningsbarhet, och principerna för objektorienterad design anger de egenskaper koden bör ha för att förbli ändringsbar. Hur dessa implikationer omsätts i artefaktens faktiska arkitektur redovisas i genomförandet och i artefaktkapitlet.

5 Genomförande

Detta kapitel redovisar studiens praktiska genomförande. Först beskrivs det konkreta arbetsupplägget. Därefter presenteras problematiseringscykeln, som motiverade inriktningen mot GDPR-klassificering. I de följande avsnitten redogörs för de tre designcyklerna, var och en med problemformulering, konstruktion och utvärdering samt reflektion. Avslutningsvis behandlas formaliseringen av lärande.

5.1 Arbetssätt och konstruktionsmetoder

Studiens genomförande organiserades i tre designcykler enligt ADR:s BIE-struktur (se Sektion 2.3.2). Designcykel 1 omfattade vecka 15 till 17, designcykel 2 vecka 17 till 19 och designcykel 3 vecka 19 till 21. Övergången mellan cyklerna skedde på torsdagar, då resultatet av föregående cykel analyserades och nästa cykel planerades. De två första cyklerna utvidgade artefaktens funktionalitet med nya detektionslager, medan den tredje cykeln fokuserade på förfining och empirisk kalibrering av befintliga lager. Innehållet i varje cykel beskrivs under respektive designcykelavsnitt nedan.

Inom varje designcykel följde arbetet ett återkommande mönster. Cykeln inleddes med planering där issues formulerades utifrån föregående cykels utvärderingsresultat och placerades på en Kanban-tavla i GitHub Projects, som användes för att synliggöra arbetsflödet och hantera både planerade uppgifter och oförutsedda insikter under arbetets gång. Därefter följde en utvecklingsperiod där författarna arbetade gemensamt eller parallellt med daglig kommunikation och löpande avstämningar, fram till att cykelns issues var stängda. Cykeln avslutades med utvärderingssessioner med intressenterna, tematisk analys av sessionerna och dokumentation av designbeslut i loggboken. Momenten motsvarar ADR:s tre första faser: problemformulering (planering), konstruktion och utvärdering (utvecklings- och utvärderingsperioden) och reflektion (analys och loggboksföring), så som de beskrivs i Sektion 2.3.

Intressenternas deltagande varierade mellan cyklerna, vilket framgår av Tabell 7. V1 och V2 deltog i samtliga faser av studien, V3 endast i problematiseringsfasen och V4 från och med designcykel 1. V4 togs in inför designcyklerna, men den eftersträvade jämna fördelningen mellan privat och offentlig sektor uppnåddes inte fullt ut (se Sektion 2.4.2). Inför designcykel 3 utökades kontakten med V1 till en ytterligare roll för att fördjupa den naturalistiska utvärderingen.

Org.	**Roll**	**Problematisering**	**Designcykel 1**	**Designcykel 2**	**Designcykel 3**
V1	Mjukvaruarkitekt	x	x	x	x
V1	Dataskyddsansvarig				x
V2	Verksamhetschef	x			
V2	Informationssäkerhetskonsult	x	x	x	x
V3	AI-strateg	x			
V4	AI-strateg		x	x	x

Tabell 7: Översikt över deltagande intressenter per fas och designcykel.

5.1.1 Generering av testdata

Hybridmetoden som beskrivs nedan introducerades inför designcykel 2 för att hantera de mer tolkningsberoende artikel 9- och kombinationsdataseten. Designcykel 1:s testdata för artikel 4-kategorierna konstruerades enligt en enklare ansats som beskrivs i Sektion 5.3.2.

Denna studie tillämpar en hybridmetod där en lokal språkmodell genererar syntetiska kandidattexter som därefter granskas oberoende av två annoterare med konsensuskrav. Ansatsen är besläktad med Pilán et al. (2022), som kombinerar maskinell pre-annotation av rättsfall med juridisk granskning, men tillämpas här i en annan modalitet: i stället för att pre-annotera verklig text genereras hela kandidatmaterialet syntetiskt. Valet att generera helt syntetiskt motiveras av *Privacy by Design* (Cavoukian 2009), eftersom inga riktiga personuppgifter då hanteras under utveckling. Henriques et al. (2026) visar att en sådan ansats kan producera annoterad data av tillräcklig kvalitet för domänspecifik utvärdering på lågresursspråk, en kategori som svenska kan placeras i för flera NLP-uppgifter.

Metoden är uppdelad i två faser. FAS A producerar ett kandidatmaterial genom maskinell generering. FAS B utgörs av oberoende manuell granskning, mätning av strikt enighet och konsensusupplösning. Den fullständiga redovisningen av varje testdataset, inklusive ursprung, sammansättning och kända begränsningar, dokumenteras enligt ramverket från Bender och Friedman (2018) och bifogas som Bilaga B. Ramverket valdes eftersom det strukturerat redovisar datasetets ursprung, språkliga karaktär, annoterarnas bakgrund och texternas egenskaper, och därigenom gör datasetets begränsningar synliga. Eftersom hela testdatasetet är syntetiskt konstruerat avser de personuppgifter som förekommer inga verkliga personer, medan organisationsnamn används som offentliga, icke-identifierande exempel. Detta deklareras synligt även i kodrepositoriet utöver i bilagans data statement.

FAS A: Maskinell kandidatgenerering. Kandidaterna genereras av en lokal språkmodell, gemma2:9b körd via Ollama, som tillhör en annan modellfamilj än artefaktens utvärderingsmodell. Genereringsprompten är konstruerad enligt samma komponentbaserade struktur som tillämpas för artefaktens egna LLM-baserade lager (se Sektion 4.1.4), det vill säga med en system-prompt som definierar modellens roll och kategoriernas avgränsningar, en task-instruktion som specificerar uppgift och förväntat output-format, samt few-shot-exempel som illustrerar målet (Brown et al. 2020). Annoteringsguiden injiceras i prompten tillsammans med spårbar versionsinformation, vilket gör det möjligt att retrospektivt koppla genererad data till de avgränsningar som var aktiva vid genereringstillfället.

Generations- och utvärderingsmodellen tillhör olika modellfamiljer. Asymmetrin införs eftersom LLM-baserade utvärderingsmodeller inte är neutrala bedömare. Anghel et al. (2025) visar att domslut från LLM-baserade utvärderare reverseras i 48,4 procent av fallen enbart genom variation i svarsordning, och refererar empiriska fynd om att språkmodeller systematiskt favoriserar sina egna genererade texter (self-preference). Eftersom modellfamiljer skiljer sig åt i arkitektur, alignment-metod och andra metodologiska val (Bhati, Fnu, Bandaru, Weber & Gajera 2026) reducerar separationen risken att utvärderingen mäter intern modellkonsistens snarare än artefaktens reella prestanda. He et al. (2024) tillämpar en motsvarande arkitektonisk separation där olika modeller hanterar generering respektive konsumtion av syntetisk data, där dataskyddet är ett kompletterande motiv eftersom ingen lokal data behöver lämna systemet.

Samma logik gäller här. Hela pipelinen körs lokalt, vilket både separerar modellfamiljerna och fyller det dataskyddssyfte som etablerats inledningsvis.

FAS B: Oberoende granskning, mätning och konsensus. De maskinellt genererade kandidaterna granskas oberoende av båda författarna. Inför granskningen konstruerade författarna två annoteringsguider, en för artikel 9-data och en för pusselbitseffekten (se Bilaga A). Guiderna översätter lagtext, Integritetsskyddsmyndighetens (IMY 2025) vägledning och refererad rättspraxis till operationella annoteringskriterier, vilket reducerar subjektiv bedömning vid konsensusupplösning och gör annoteringen reproducerbar för en oberoende granskare.

För varje dataset rapporteras strikt enighet (raw agreement), beräknad som andelen kandidater där båda annoterarna gjorde identisk klassificering vid den oberoende granskningen. Kandidater där en annoterare uttryckligen avstod från klassificering rapporteras separat och räknas inte in i basen för strikt enighet, eftersom måttet förutsätter att båda annoterarna avgav en bedömning. Måttet korrigerar inte för slumpmässig överenskommelse och kan därför inte direkt jämföras med tröskelvärden för kappa eller alpha (Artstein & Poesio 2008). Strikt enighet rapporteras eftersom måttet signalerar i vilken grad annoteringsguiden är tillräckligt entydig för att utfallet inte ska bero på enskild bedömares tolkning. Ett högt värde indikerar att guiden tolkas konsekvent av oberoende annoterare, ett lågt värde att guiden lämnar utrymme för tolkning som behöver hanteras genom konsensusupplösning eller revidering av guiden inför nästa cykel.

Avvikelser mellan annoterarna löses därefter genom strukturerad diskussion mot annoteringsguiden, lagtext och refererad rättspraxis. Konsensusupplösningen är en separat process avsedd att producera gold standard-data och utgör inte ett reliabilitetsmått (Artstein & Poesio 2008). Om en kategori blir underrepresenterad efter konsensusupplösningen tillåts manuell komplettering av datasetet med direkt span-verifiering av båda annoterarna. Detta är en avvikelse från FAS A:s automatiska generering och hanteras därför med samma konsensuskrav som FAS B:s ordinarie granskning, för att inte introducera den interna bedömningsrisk som hybridmetoden i övrigt motverkar.

5.1.2 Promptkonstruktion

Lager 3 (Article9Layer) och Lager 4 (CombinationLayer) använde båda en lokal språkmodell via en utbytbar LLMProvider-abstraktion. Att styra dessa lagers utfall krävde att modellen fick en strukturerad inmatning, vilket gjorde promptkonstruktionen till en central del av artefaktens beteende. De teoretiska grunderna för promptdesign redogörs för i Sektion 4.1.4. Detta avsnitt beskriver det arbetssätt som etablerades för att konstruera, dokumentera och förfina prompts. Faktiska prompttexter per lager och version, samt konkreta konfigurationer och utfall per designcykel, redovisas i respektive genomförandeavsnitt nedan och i Bilaga C.

Promptstruktur och assembly-ordning. Ett gemensamt YAML-schema med fem komponenter etablerades för båda lagren: task_instruction, context, reasoning_instructions, examples och output_format. Schemat assemblerades i denna ordning vid inferens, vilket gav en konsekvent sekvens från övergripande uppgiftsbeskrivning till strikt formatkrav. system_prompt hölls separat från det assemblerade promptobjektet och skickades via LLMProvider-abstraktionens systemfält. Komponentordningen konkretiserade den grundstruktur He et al. (2024) sammanfattar som "instruction + requirement + text".

Few-shot-exempel. Båda lagrens prompts inkluderade few-shot-exempel enligt det format som beskrivs av Brown et al. (2020), med fält för input och output per exempel. Varje exempel utökades därutöver med ett rationale-fält. Exempel konstruerades för att spänna över svårighetsgrader och inkluderade både positiva och negativa exempelpar, där de negativa visade formuleringar som inte skulle klassificeras. Beslut om antal exempel, om negativa exempelpar skulle användas och hur dessa skulle väljas, togs inom respektive designcykel utifrån observerade utfall. Exempelmängderna hölls statiska över alla testkörningar inom samma promptversion, vilket prioriterade reproducerbarhet framför maximal precision på enskilda inmatningar och utgjorde en medveten avvikelse från det dynamiska urval som Liu et al. (2023) beskriver.

Chain-of-thought. För uppgifter som krävde flerstegsresonemang övervägdes CoT-instruktioner enligt Wei et al. (2022). CombinationLayers uppgift, att bedöma pusselbitseffekten enligt GDPR skäl 26, identifierades som ett sådant flerstegsproblem där modellen behöver väga flera signaler mot varandra. Article9Layers uppgift identifierades som en mer direkt klassificering mot tydliga juridiska kriterier som inte kräver mellanliggande resonemangssteg. Eftersom Wei et al. (2022) kopplar CoT till modellskala och varnar för att mindre modeller kan generera ologiska resonemangskedjor, begränsades tekniken till kombinationslagrets genuina flerstegsproblem och behölls där enbart efter att den iterativa utvärderingen (se Sektion 5.1.1) visat att den inte försämrade utfallet. Att artikel 9-lagrets v6-experiment, som bland annat lade till en resonemangsinstruktion, i stället inducerade regression och rullades tillbaka (se Sektion 5.5.2), är konsistent med det förbehåll Wei et al. (2022) formulerar.

Strukturerad output och hallucinationshantering. Utdataformatet specificerades som strikt JSON med fördefinierade fält och tillåtna värdemängder, ett designval för att göra modellsvaren maskinellt tolkningsbara och robusta mot hallucinationer. Output-parsningen konstruerades för att hantera enskilda fält som var hallucinerade eller saknades, så att aggregat-fynd kunde returneras även om en enskild signal innehöll en okänd typ eller saknade ett obligatoriskt fält, så länge svarets övergripande struktur var välformad. Konstruktionen kompletterade de mekanismer för hallucinationshantering som beskrivs i Sektion 4.1.4 och förenade dataskyddsförordningens krav på inbyggt dataskydd (artikel 25) med kravet på operativ kontinuitet.

Iterativ förfining. Promptarbetet bedrevs i mät-analysera-justera-cykler. Varje ny promptversion utvärderades mot samma testdataset (se Sektion 5.1.1) innan den togs i bruk, med precision, recall och F1 registrerade per kategori. Konsensus mellan författarna krävdes innan versionsbyte. En omgång av förfining avslutades när en åtgärd antingen visade tecken på avtagande avkastning eller orsakade regression mot recall, i enlighet med den prioritetsordning mellan recall och precision som etablerats i Sektion 2.5.2.

Versionering och dokumentation. Varje promptversion sparades som en YAML-fil i en versionerad katalogstruktur (gdpr_classifier/prompts/{layer}/v{N}.yaml) tillsammans med ett metadata-block som dokumenterade versionsnummer, datum, författare, källreferenser och anmärkningar. Versionerna kopplades till motsvarande commit i artefaktens versionshanteringssystem, och varje testkörning loggade vilken promptversion som användes vid inferens. Detta motsvarar den dokumentationspraxis Anghel et al. (2025) argumenterar för i promptbaserade system och är en förutsättning för att resultat ska kunna jämföras över omgångar och designcykler.

5.1.3 Utvecklingsarbete med agentisk AI

Detta avsnitt beskriver hur agentisk AI användes i byggandet av artefakten och vilka kontroller som höll besluten kvar hos författarna. Den övergripande redovisningen av studiens AI-användning finns i metodkapitlet (se Sektion 2.7). Här ligger fokus på kodningsarbetet, som genom alla tre designcyklerna följde samma grundläggande arbetssätt. Arbetssättet bygger på en anpassning av Ralph-tekniken för agentiskt kodningsarbete (Huntley 2025). Där Ralph kör en agent autonomt i en oövervakad slinga, behöll författarna i stället granskning och godkännande i varje steg och körde en uppgift i taget under egen övervakning.

Arbetet organiserades kring två funktioner. Arkitektfunktionen sköttes i Claude Web (Claude Opus 4.7), laddad med projektets dokumentation, och ansvarade för att skriva strukturerade prompter till implementationsagenten, granska de planer som returnerades mot tre kriterier (att acceptanskriterierna täcktes, att implementationen inte avvek från specifikationen och att omfattningen inte växte utöver issuen), rimlighetsgranska resultat och flagga metodologiska risker innan implementation. I praktiken fylldes arkitektfunktionen av flera separata Claude Web-instanser under projektets gång, dels för att de två författarna körde var sin instans, dels för att parallella instanser ibland startades för att korsgranska olika spår.

Implementationsfunktionen sköttes av en AI-kodningsagent i utvecklingsmiljön, i ett planeringsläge (Plan Mode) och ett implementationsläge (Agent Mode). Planeringsläget var läsande och föreslog ändringar utan att göra dem, och varje kodändring krävde uttryckligt godkännande, i enlighet med den behörighetsmodell som dokumenteras för Claude Code (Anthropic u.å.). Vilken agent som användes växlade under projektet. I designcykel 1 var det främst Cursor (Claude Opus 4.7) och Antigravity (Gemini 3.1 Pro eller Claude Opus 4.6), och från designcykel 2 främst Claude Code (Claude Opus 4.7, senare Opus 4.6), med övriga agenter som komplement vid kapacitetsbegränsningar. Uppdelningen mellan arkitekt och agent fanns från designcykel 1 och formaliserades stegvis under projektets gång.

Arbetsenheten var en GitHub-issue i taget i ett återkommande arbetssteg. Arkitektinstansen formulerade en prompt för nästa issue, agenten returnerade en plan, och planen granskades mot de tre kriterierna. Resultatet rapporterades tillbaka och verifierades lokalt, varefter versionshanteringen sköttes manuellt med git (add, commit och push). Varje issue avslutades med en sessionspost i filen iteration_N_implementation.md i kodrepositoriet och med att designbeslutet fördes in i författarnas loggbok. Detta arbetssteg var normalfallet men inte undantagslöst. Triviala ändringar som dokumentationsstädning kördes utan planeringssteg, och det utforskande probe-arbetet kördes medvetet utanför det.

Den mänskliga kontrollen vilade på två återkommande moment i kodflödet: varje ändring godkändes manuellt innan den skrevs till kodbasen, och all versionshantering sköttes av författarna. Att kontrollen var reell syns bland annat i att en redan implementerad fix i ett fall reverterades sedan den underkänts i utvärderingen, i stället för att behållas. Granskningsunderlaget fördes löpande i tre källor. Sessionsloggarna ligger i filen iteration_N_implementation.md i kodrepositoriet och dokumenterar vad som faktiskt gjordes. Filen docs/arkitektur.md i samma repositorium är den enda auktoritativa källan för arkitekturen och hölls synkroniserad som en del av implementationen. Loggboken är en intern loggbok som förts av författarna genom hela arbetet och som inte ingår i det publicerade materialet; där dokumenteras varje designbeslut med övervägda alternativ, motivering och koppling till GDPR-krav eller empiriskt stöd.

Det här arbetssättet är centralt för studiens hederlighet. Författarna var beslutsfattarna. AI:n var ett verktyg och en accelerator, inte upphovet till designbesluten. Besluten, deras motivering och utvärderingen ägdes av författarna och dokumenterades i loggboken, medan agenterna utförde implementation under granskning. Inget av det arkitektinstansen eller implementationsagenten producerade infördes i artefakten eller rapporten utan att författarna granskat och godkänt det. Varje plan, kodändring och formulering passerade författarnas granskning innan den blev en del av arbetet; varken arkitektinstansen eller agenten utförde något självständigt. Tillsammans utgör sessionsloggarna, loggboken, den auktoritativa arkitekturkällan och den manuella versionshanteringen ett granskningsbart och reproducerbart underlag för det AI-stöttade arbetet. Det knyter an till DSR:s krav på stringens (Hevner et al. 2004) och till ADR:s dokumentation av designprocessen (Sein et al. 2011).

Det utforskande probe-arbetet skilde sig från den issuebaserade utvecklingen. Eftersom inriktningen växte fram under arbetet definierades vad som räknades som klart per kontrollpunkt i stället för per issue, och issuen hölls öppen tills hela frågan kunde besvaras. Probe-sessionerna producerade inga arkitekturbeslut, bara operativa körningsval. Två risker är värda att namnge. Den ena är att agenten gradvis rör sig bort från det som efterfrågades. Den andra är övertilltro, att en plan godkänns utan tillräcklig granskning. Båda begränsades av samma kontroller: planen granskades mot de tre kriterierna innan körning, och varje kodändring godkändes manuellt. Designbeslut och tolkning av utvärderingsresultat delegerades aldrig till agenten.

5.2 Problematiseringscykel

Med urvalet på plats (Sektion 2.4.2) inleddes studien med en problematiseringscykel vars syfte var att fastställa ett gemensamt och praktiskt grundat problemområde. Cykeln operationaliserar ADR:s princip om *Practice-Inspired Research* (Sein et al. 2011) genom att låta tre verksamheter självständigt formulera sina behov, så att den gemensamma kärnan kunde särskiljas från verksamhetsspecifika önskemål. Cykeln var inte en BIE-fas utan en serie explorativa möten i dialogform med representanter från V1, V2 och V3.

Studiens ursprungliga inriktning var en arkitektur för automatisk dirigering av AI-förfrågningar till lokal eller molnbaserad modell beroende på textinnehållets känslighet. V1 kontaktades först eftersom inriktningen ursprungligen formulerats tillsammans med V1. De tidiga samtalen rörde sig brett kring integritet, kontroll och frågan om vilken modell som passar vilken uppgift. I ett uppföljningsmöte preciserades problemet. Verksamheten hanterar inte personliga kunduppgifter i egentlig mening, men har känslig data i interna flöden inom ekonomi, HR och finans. En konkret observation var att medarbetare generellt undviker att skicka personnummer till externa system, medan kombinationer av lättare uppgifter som namn, adress, IP-adress och e-post oftare hanteras utan reflektion, trots att två sådana element tillsammans typiskt räcker för att identifiera en person. Denna identifierbarhetsproblematik benämns ofta pusselbitseffekten och har sin juridiska förankring i GDPR:s skäl 26, om att alla rimligt tillgängliga medel för identifiering ska beaktas vid bedömningen av om en uppgift är en personuppgift (Europaparlamentets och rådets förordning [EU] 2016/679).

V2 bidrog med ett renodlat informationssäkerhetsperspektiv. Samtalet berörde CIA-triaden, ansvarsfördelningen vid felklassificering och frågan om hur det kan säkerställas att även lokala modeller inte loggar konversationer. Det mest konkreta bidraget var observationen att befintliga Data Loss Prevention (DLP)-system tekniskt fungerar men är oproportionerligt kostsamma för små och medelstora företag. Behovet finns, men det saknas tillgängliga verktyg i rätt prisnivå.

Verksamheten identifierade också inkommande kommunikation, alltså e-post, chattmeddelanden och externa formulär, som ett mer prioriterat användningsområde än utgående AI-interaktioner. Motiveringen var att medarbetare i teorin redan vet att de inte ska skicka känslig data till externa modeller, medan inkommande textflöden saknar motsvarande mänskliga filter.

V3 lyfte ett mer situationsspecifikt behov. Maskering av mötestranskriberingar identifierades som en konkret användning, där känsliga uppgifter kan förekomma utan att transkriberaren märker det. Organisationen använde vid tillfället en manuell Adobe-baserad lösning utan AI-stöd. Den öppna organisatoriska frågan om vem som äger ett sådant system, IT, dataskyddsombudet eller verksamheten, lyftes utan att besvaras.

Vad som framträdde i jämförelsen var att styra vidare, alltså frågan om var en AI-förfrågan ska hanteras, inte var verksamheternas gemensamma problem. Det gemensamma behovet var att kunna fastställa vilken typ av känsliga uppgifter ett textstycke innehåller, oavsett om den efterföljande åtgärden var maskering (V3), blockering eller granskning (V2) eller arkitektonisk dirigering (det ursprungliga V1-fallet). Klassificering utgjorde alltså den gemensamma kärnan, medan de efterföljande åtgärderna var verksamhetsspecifika. Observationen föranledde en omorientering av studien från dirigering via en AI-gateway som forskningsobjekt till automatiserad GDPR-klassificering, vilket innebär en rörelse från instans till klass i den mening Sein et al. (2011, s. 40) beskriver som ett kännetecken för välformulerade problemklasser inom ADR.

5.3 Designcykel 1

Designcykel 1 utgjorde studiens första fullständiga BIE-fas och löpte från problemformulering till demonstration och utvärdering mot intressenter. Målet var att bygga en fungerande klassificeringspipeline för de två första detektionslagren och att genom naturalistisk utvärdering samla formativ återkoppling inför designcykel 2. Kontextlagret lämnades oimplementerat och planerades för designcykel 2.

5.3.1 Problemformulering

Inför designcykel 1 konkretiserades det problem som identifierats i den inledande problematiseringsfasen till ett avgränsat konstruktionsmål: att bygga en fungerande klassificeringspipeline för strukturerade personuppgifter enligt GDPR (artikel 4). Syftet var att därefter demonstrera lösningen för intressenter för att inhämta formativ återkoppling inför designcykel 2. Avgränsningen sattes medvetet till de två första detektionslagren, mönsterigenkänning och entitetsigenkänning (NER), medan det tredje lagret för kontextuell analys lämnades utan fullständig implementation i detta skede. Prioriteringen stöds av litteraturen, som konsekvent visar att regelbaserade system och NER behöver kompletteras med semantisk analys för att hantera implicit känslig data (Karras et al. 2025; Mishra, Pagare & Sharma 2025), men att de ändå utgör en nödvändig och testbar grund.

5.3.2 Konstruktion, intervention och utvärdering

Konstruktion. Det centrala designbeslutet var att dela upp systemet i tre oberoende detektionslager som alla fick samma originaltext som indata, snarare än att bilda en sekventiell kedja där ett lagers utdata överfördes till nästa. Den initiala designen operationaliserar ADR:s princip *Theory-Ingrained Artifact* (Sein et al. 2011) genom att grundas i GDPR:s rättsliga

struktur, där artikel 4:s strukturerade personuppgifter motiverade de två första lagrens avgränsning, och i de etablerade arkitekturmönster för flerstegsdetektion som redovisas i Sektion 4.2. Det första lagret implementerades med fem moduler för mönsterigenkänning: personnummer, e-postadresser, telefonnummer, IBAN och betalkortsnummer. Personnummer och betalkortsnummer validerades med Luhn-algoritmen och IBAN med mod 97-kontrollsiffror. Det andra lagret implementerades med SpaCy (sv_core_news_lg) för igenkänning av namngivna entiteter, med stöd för kategorierna person, plats och organisation. Kontextlagret lämnades som en stubb utan implementerad logik och planerades för designcykel 2. Artefakten exponerades via ett gränssnitt byggt i Dash med en rapportvy och en fritext-vy med inline-markeringar per fynd.

Artificiell utvärdering. Testdatasetet för designcykel 1 sattes samman manuellt av författarna mot kategorispecifika kvantitetskrav: minst tio personnummertexter, minst fem texter vardera för e-post, telefon, IBAN och betalkort, samt minst tio okänsliga kontrolltexter. Texterna är korta och mallartade exempel. För att säkerställa korrekta teckenpositioner och giltiga kontrollsummor (Luhn för personnummer och betalkort, mod 97 för IBAN) användes ett engångsskript som automatiserade indexberäkningen. Konstruktionen är ad hoc i jämförelse med hybridmetoden i Sektion 5.1.1, som infördes inför designcykel 2 efter lärdomar från denna cykels utvärdering.

Den artificiella utvärderingen genomfördes mot ett testdataset med 70 texter och 85 annoterade fynd på entitetsnivå. Av dessa identifierade artefakten 82 korrekt (TP), missade 3 (FN) och producerade 9 felaktiga identifieringar (FP). Recall uppgick till 96,47 procent, precision till 90,11 procent och F1 till 93,18 procent. Utfallet sammanfattas i Tabell 8.

	Faktiskt positiv (Entity)	Faktiskt negativ (No entity)
Förutspått positiv	TP: 82	FP: 9
Förutspått negativ	FN: 3	TN: 12 (dokumentnivå)

Tabell 8: Konfusionsmatris för designcykel 1. TP, FP och FN på entitetsnivå; TN på dokumentnivå (12 texter utan personuppgifter).

TN räknas på dokumentnivå som antalet texter med tom expected_findings-lista. Det inkluderar både allmänna kontrolltexter och funktionella gränsfall där deterministiska igenkännare korrekt inte producerar fynd, exempelvis en text med ett betalkortsnummer där Luhn-kontrollen ska fallera.

Mönsterlagret nådde 100 procents recall i samtliga fem kategorier (personnummer, e-post, telefonnummer, IBAN, betalkort) med en precision på 94,23 procent. Antalet annoterade fynd per kategori var dock begränsat, mellan tre och arton, vilket gör att recall-värdet säger mer om att artefakten inte missade något i de fall som ingick än om robusthet över bredare textdistributioner. Entitetslagret svarade för 33 sanna positiva och nådde 100 procents recall i namnkategorin (18 av 18), medan organisationskategorin landade på cirka 57 procent (4 av 7). Entitetslagrets precision var lägre än mönsterlagrets.

De tre falska negativa skedde uteslutande i kategorin organisationer, där Volvo AB och Skatteverket inte identifierades i specifika kontexter. De 9 falska positiva fördelade sig på 3 från mönsterlagret och 6 från entitetslagret. Mönsterlagrets samtliga FP orsakades av samma kollision. Telefonnummer-regexen matchade siffersegment inuti IBAN-strängar utan att

fyndets position kontrollerades mot omkringliggande tokens. Entitetslagrets FP fördelade sig på tre felmönster. I tre fall klassificerade SpaCy siffersekvenser från personnummer eller IBAN som plats- eller personentiteter, vilket pekar mot att sv_core_news_lg är tränad på svensk journalistisk text snarare än administrativa textformat. I två fall klassificerades e-postadresser som organisationer, sannolikt eftersom domännamnet (foretag.se, privat.se) formellt påminner om ett organisationsnamn. Det sista fallet rörde ett förnamn i en hälsningsfras (Mvh Anna), som flaggades utan att vara annoterat i facit.

Naturalistisk utvärdering. Den naturalistiska utvärderingen genomfördes enligt det upplägg som beskrivs i Sektion 2.4.4, med demonstration följd av semistrukturerad intervju. En session genomfördes med var och en av de tre verksamheterna V1, V2 och V4.

Inom temat ”nytta” bekräftade samtliga tre verksamheter att behovet är reellt, men med olika problembilder. De privata aktörerna beskrev personuppgiftshanteringen utifrån skilda perspektiv. V1 betonade att personuppgifter primärt finns i strukturerade interna system inom ekonomi, HR och finans, där den kritiska risken ligger i kombinationer mellan fält snarare än i enskilda uppgifter. V2 pekade i stället på ett mörkertal i mejlflöden som aldrig når ärendesystemet: "Det finns ett stort mörkertal [...] det som går direkt till personer i företaget. Det som aldrig hamnar i ärendesystemet." V4 beskrev konkreta användningsfall kring utlämning av offentliga handlingar och pseudonymisering av forskningsmaterial med intervjutranskript från patientgrupper, där identifierbar information i dag rensas manuellt.

Inom temat ”ändamålsenlighet” bedömde V1 och V2 att demonstrationstexterna var för korta och enkla i förhållande till de texttyper de faktiskt hanterar. V4 fokuserade i stället på en specifik begränsning i entitetslagret kring identifiering av organisationsnamn. V1 preciserade att det kritiska inte är enskilda datafält utan kombinationer: "För att sammanställa en fraktsedel eller en etikett som ska sättas på ett paket behöver vi namn plus adress och i många fall även telefonnumret." V2 återkom till längre mejlkonversationer med historik som den primära texttypen och noterade att systemet bör kunna hantera hela trådade konversationer, inte bara enskilda textsnippets. Både V1 och V4 pekade på att organisationsnamn inte alltid identifieras av entitetslagret och föreslog kompletterande regex-mönster för institutionella och juridiska suffix (myndighet, verk, AB) eller en alternativ språkmodell som komplement till SpaCy.

Inom temat ”organisatorisk passform” såg samtliga tre verksamheter systemet som ett kompletterande lager snarare än en ersättning för befintliga verktyg eller mänsklig bedömning. De privata aktörerna beskrev en tänkt modell med automatiserad flaggning i mejlflödet, analogt med hur en banner redan visas för mejl från externa avsändare, följd av att medarbetaren agerar snarare än att varje klassificeringsbeslut granskas manuellt. V4 hade en tydligare grundposition. En människa behöver skriva under på slutresultatet. Resonemanget var dock mer nyanserat än en ren avvisning av automatisering: "En människa som går igenom missar massa grejer också, säkert mer än vad ett automatiserat system missar." Den tänkta modellen var att systemet markerar problemområden och att en handläggare sedan bekräftar, snarare än granskar från grunden. Certifiering angavs som en förutsättning för det scenariot: hur utvärderar och kvalificerar man ett sådant system som produkt, och hur mäter man dess prestanda jämfört med manuell hantering?

5.3.3 Lärdomar och insikter

Den artificiella utvärderingen bekräftade att det tekniska fundamentet håller. Recall på 96,47 procent mot ett testdataset med 85 annoterade fynd, med noll missar i samtliga Luhn- och

mod97-validerade kategorier, visar att deterministisk mönsterigenkänning är ett pålitligt första lager för strukturerade personuppgifter. Felmönstren var analytiskt användbara. IBAN-kollisionen, där telefonnummermönstret matchade siffersekvenser inuti redan klassificerade IBAN-strängar, motiverade en inneslutningsregel inför designcykel 2. Entitetslagrets felmönster speglar en begränsning i sv_core_news_lg. Modellen är tränad på journalistisk text (Explosion AI u.å.) och hanterar varken svenska administrativa textformat med strukturerade siffersekvenser eller e-postadressers domännamn på ett sätt som passar artefaktens textdomän. Redundansfallet, där "Anna" i en hälsningsfras flaggades trots att det saknades i facit, illustrerar en spänning i testdesignen snarare än ett fel i artefakten.

Den naturalistiska utvärderingen gav ett mer differentierat resultat än enbart prestandasiffrorna antydde. Verksamheterna representerar genuint skilda problemkontexter, inte bara varierande instanser av samma problem, och återkopplingen inom nytta och ändamålsenlighet var konsistent på en punkt. Testdatan var för enkel. Det intressenterna faktiskt hanterar är längre mejlkonversationer med historik, ostrukturerade ärendeloggar och dokument utan definierade fält. Den syntetiska testdatan med korta textsegment speglar inte det arbetsflöde artefakten behöver fungera i. Det är en begränsning i testdesignen, inte i det tekniska lagret, men skillnaden är inte trivial. 96 procents recall på korta isolerade meningar säger lite om prestandan när samma kategorier förekommer utspridda i en femsidig mejltråd.

Designcykel 1 gav också en metodologisk lärdom som rörde testdatans konstruktion snarare än artefakten. Datasetet hade tagits fram med AI-genererade kandidater utan systematisk validering mot recognizers underliggande logik, vilket gav en initial recall på 50 procent eftersom de genererade personnummer och IBAN inte uppfyllde Luhn- respektive mod97-validering och därför korrekt avvisades. Felet kunde korrigeras retroaktivt, varefter mönsterlagrets recall steg till 95,45 procent (42 av 44 fynd) i en mönsterlagerkörning mot det dåvarande mindre testdatasetet. Efterföljande gränsfallsfixar i e-post- och telefon-recognizern och utvidgningen av testdatasetet till 85 annoterade fynd lyfte sedan mönsterlagret till 100 procents recall i samtliga fem kategorier (se Sektion 5.3.2 och Tabell 8). Lärdomen är att AI-baserad datagenerering kräver strukturerad granskning för att inte introducera systematiska brister som senare maskeras som artefaktproblem. Tillsammans med intressenternas observation om textlängd motiverade detta en mer rigorös metod för testdatakonstruktion inför designcykel 2, där generering och oberoende manuell granskning kombineras i en explicit hybridprocess (se Sektion 5.1.1).

Kontextuell känslighet framstod som den tydligaste tekniska luckan. Kombinationer av uppgifter som var för sig inte utgör personuppgifter men som sammantaget möjliggör identifiering, det vill säga den identifierbarhetsprincip som anges i GDPR:s skäl 26 och ofta benämns pusselbitseffekten, fångas inte av de två första lagren. V1 formulerade problemet konkret. Det kritiska är inte enskilda fält utan kombinationen namn, adress och telefonnummer samlad för att möjliggöra fraktsedlar. Den samstämmiga signalen om kontextuell känslighet gjorde att kontextlagret prioriterades till designcykel 2 snarare än att skjutas till ett senare skede. Prioriteringen är konsekvent med principen *Guided Emergence* i ADR:s fas reflektion och lärande (Sein et al. 2011), enligt vilken den slutgiltiga artefakten växer fram genom den situerade kunskap som genereras i tidigare cykler snarare än enbart speglar forskarnas initiala design.

Resultaten för organisatorisk passform visade en sektorsskillnad som inte var förutsedd i problemformuleringen. De privata aktörerna var öppna för automatiserat beslutsstöd med periodisk manuell granskning, analogt med hur befintliga varningar för externa mottagare

fungerar, alltså den notis ett mejlsystem visar när ett meddelande är på väg till en adress utanför organisationen. Den offentliga aktören ställde tydligare krav på kvalificerad infrastruktur, med hänvisning till patientsäkerhet och rättslig ansvarighet. V4 reste samtidigt frågan om hur ett system av det här slaget mäter sin prestanda mot manuell hantering, vilket understryker att kraven för verksamhetsnära användning är högre i offentlig sektor än i privat.

5.4 Designcykel 2

Designcykel 2 var studiens andra BIE-fas och vidareutvecklade artefakten utifrån den feedback utvärderingen från designcykel 1 hade genererat.

5.4.1 Problemformulering

Designcykel 1:s naturalistiska utvärdering identifierade kontextuell känslighet, alltså pusselbitseffekten enligt GDPR skäl 26, som artefaktens centrala tekniska lucka. Att cykelns inriktning sattes av artefaktens möte med de tre verksamheterna, snarare än av en på förhand fastlagd plan, är ett uttryck för ADR:s princip *Reciprocal Shaping* (Sein et al. 2011), där IT-artefakten och den organisatoriska kontexten formar varandra under designprocessen. V1 formulerade problemet konkret som att det kritiska inte är enskilda fält utan kombinationer av namn, adress och telefonnummer samlade för att möjliggöra fraktsedlar. Kombinationer av uppgifter som var för sig inte utgör personuppgifter men som tillsammans möjliggör identifiering kräver semantisk analys snarare än mönstermatchning och adresseras därför inte av lager 1 och 2.

Parallellt stod artikel 9-data utanför artefaktens dåvarande täckning. Uppgifter om hälsa, religiös övertygelse, politisk åskådning, sexuell läggning, etniskt ursprung, biometriska och genetiska data samt fackföreningsmedlemskap kräver tolkning av textens innehåll snarare än regelbaserad matchning. Att utvidga den rättsliga omfattningen från enbart artikel 4 till artikel 4, artikel 9 och skäl 26 var en del av studiens iterativa scope-utveckling och hade planerats sedan studiens inledning.

Den naturalistiska utvärderingen visade också att testdatan inte speglade de texttyper artefakten är avsedd att hantera. Datasetet bestod av 70 korta texter med explicita mönster, vilket gav stabila kvantitativa mätvärden men låg ekologisk validitet, det vill säga låg grad av överensstämmelse mellan utvärderingsmiljön och den verkliga användningsmiljön. Detta är en begränsning i utvärderingsdesignen, inte i artefakten, men den styrde omfattningen för testdataarbetet i denna designcykel.

Mot denna bakgrund formulerades cykelns mål i tre delar. För det första skulle pipelinen utökas med ett lager för direkt detektion av artikel 9-data och ett lager för bedömning av kombinerad identifierbarhet. För det andra skulle aggregatorn omarbetas till att mekaniskt validera kombinationsfynd och tilldela en utökad känslighetsskala med nivåerna ingen, låg, mellan och hög känslighet. För det tredje skulle testdatasetet utökas med artikel 9-texter, kombinationsfall och längre realistiska texter, så att utvärderingen i slutet av cykeln gav bättre underlag för bedömning av artefaktens användbarhet i intressenternas faktiska arbetsflöden.

Två moment låg utanför cykelns omfattning. Empirisk kalibrering av aggregatorns trösklar för mellan-bedömning, hög-konfidens-bypass och minsta evidensantal utfördes inte i designcykel 2. Initiala värden valdes för att möjliggöra en första baslinjekörning, och kalibrering mot

utvärderingsutfallet planerades till designcykel 3. Designcykel 2 etablerade arkitekturen och en första empirisk baslinje, inte de slutgiltiga parametrarna eller den abstraherade kunskapen.

5.4.2 Konstruktion, intervention och utvärdering

Konstruktion. Det centrala konstruktionsbeslutet var att dela det tidigare planerade kontextlagret i två separata detektionslager. Artikel 9-lagret ansvarar för direkt detektion av artikel 9-kategorier, kombinationslagret för bedömning av kombinerad identifierbarhet enligt skäl 26. Uppdelningen följde *Single Responsibility Principle* (Martin 2003). Ett monolitiskt kontextlager hade haft två oberoende anledningar att förändras, en ny artikel 9-kategori eller en ny kombinationssemantik, vilket motiverar arkitektonisk separation. Båda lagren följer det lagerprotokoll som etablerades i designcykel 1, vilket innebar att pipelinen och aggregatorn inte behövde ändras strukturellt för att hantera de nya komponenterna.

Artikel 9-lagret och kombinationslagret implementerades via Ollama som primär leverantör, med en utbytbar molnleverantör som icke-produktionskomponent för utveckling och test. Valet av lokal språkmodellexekvering motiverades av tre skäl. Mishra, Pagare & Sharma (2025) visar att en resurssnål NER-pipeline kan köras på standardhårdvara med konkurrenskraftig prestanda, till skillnad från transformermodeller och stora språkmodeller som kräver kraftfulla GPU:er. Karras et al. (2025) dokumenterar GDPR-implikationer av tredjelandsöverföring vid molnbaserad LLM-exekvering. V4 hade dessutom i utvärderingen av designcykel 1 uttryckt ett behov av lokal exekvering inom kvalificerad infrastruktur, vilket adresseras genom abstraktionen för språkmodellsleverantör. För att välja basmodell genomfördes en probe-körning mot tre kandidater på fjorton testprompter fördelade på JSON-validitet och svensk språkförståelse. Qwen2.5:7b-instruct presterade bäst på svenskspråkig artikel 9-detektion (8 av 9 korrekta) och valdes som baslinjemodell. Resultaten per kandidat sammanfattas i Tabell 9.

Modell	**Parametrar**	**Snittlatens**	**Antal korrekta klassificeringar**
llama3.1:8b	8B	1.11s	6 av 9
qwen2.5:7b-instruct	7B	1.72s	8 av 9
mistral-nemo:12b	12B	2.41s	5 av 9

Tabell 9: Sammanfattning av testade modeller.

Aggregatorns ansvar utvidgades från överlappsdetektion till bedömning av känslighetsnivå utifrån fyndens karaktär. Logiken implementerades i fyra utfall: hög vid förekomst av artikel 9-fynd, mellan vid kombinationsfynd som passerar antingen en hög-konfidens-bypass eller en regel om minsta antal evidence-fynd, låg vid enbart artikel 4-fynd, och ingen vid avsaknad av fynd. En justering som föranleddes av utvärderingen i designcykel 1 var att isolerade kontextuella fynd, exempelvis ett organisationsnamn utan andra signaler, inte längre höjer känslighetsnivån i sig. Kontextuella signaler bidrar enbart när de ingår i ett aggregerat kombinationsfynd. Detta är konsistent med GDPR skäl 26, där identifierbarhet uppstår genom kombination av uppgifter snarare än genom enskilda kontextuella signaler. *Privacy by Design* (Cavoukian 2009) tillämpades, i linje med kravet på inbyggt dataskydd i GDPR artikel 25. Vid valideringsosäkerhet höjs känsligheten och sänks aldrig. De tre tröskelvärdena (mellan-bedömning 0,7; hög-konfidens-bypass 0,85; minsta antal evidence-fynd 2) sattes till initiala defaultvärden med avsikt att kalibreras empiriskt mot utvärderingsutfallet i designcykel 3. Varje

kombinationsfynd åtföljs av en kort textuell motivering där kombinationslagret förklarar varför de bidragande signalerna sammantaget bedöms möjliggöra identifiering. Motiveringen operationaliserar GDPR:s princip om ansvarsskyldighet (artikel 5.2) genom att göra klassificeringsbeslutets resonemang granskningsbart.

Inför utvärderingen av de nya lagren konstruerades två dataset enligt hybridmetoden i Sektion 5.1.1, ett för artikel 9-detektion och ett för pusselbitsbedömning, vart och ett förankrat i en annoteringsguide grundad på lagtext, IMY:s vägledning och refererad EU-rättspraxis (Bilaga A). Artikel 9-datasetet utgick från 60 genererade kandidater och nådde 64,0 procents strikt enighet vid den oberoende granskningen, kombinationsdatasetet från 29 kandidater och 75,9 procent. Samtliga kandidater löstes till konsensus mot annoteringsguidernas kriterier, och underrepresenterade kategorier kompletterades manuellt med span-verifiering, vilket gav 52 respektive 27 texter. Kategorin etniskt ursprung utgör ett undantag. Samtliga genererade kandidater underkändes mot guidens princip att geografi och nationalitet inte avslöjar etnicitet, och kategorin kompletterades inte manuellt, vilket gör att den saknar facit-fynd i datasetet. Konsekvenserna för utvärderingen behandlas i Sektion 7.1.3 och Sektion 7.1.4. Designcykel 1:s testdataset utökades samtidigt från 70 till 80 texter med längre realistiska dokument, vilket gav ett sammanlagt dataset om 159 texter. Kandidaternas fullständiga disposition genom granskning och konsensus redovisas per dataset i Bilaga B.

Utöver de tre nya komponenterna hanterades ett antal kvarstående punkter från designcykel 1. Det överlapp mellan IBAN- och telefonnummermönster som identifierats som känd begränsning åtgärdades genom en regel i aggregatorn som tar bort telefonfynd vars textspan helt täcks av ett mod97-validerat IBAN-fynd. Regeln eliminerade de två falska positiva som överlappet gav upphov till. Artikel 9-lagret fick ett skydd mot felaktiga utdata från språkmodellen genom att varje föreslaget fynd valideras mot originaltexten innan det accepteras. Om det textspan modellen anger inte återfinns ordagrant i den ursprungliga texten kasseras fyndet, vilket förhindrar att språkmodellens hallucinationer propagerar genom systemet. Demonstrationsgränssnittet uppdaterades till att visa hela fyra-lagers-pipelinen tillsammans med en tabell som synliggör hur känslighetsbedömningen härleds från de bidragande mekanismerna, så att intressenterna under den naturalistiska utvärderingen kan följa systemets resonemang i realtid.

Artificiell utvärdering. Den första utvärderingen av den kompletta fyra-lagers-pipelinen genomfördes mot 159 texter sammanställda från designcykel 1:s testdataset (80 texter), de nya artikel 9-texterna (52) och de nya kombinationstexterna (27). Baslinjemätningen gav en precision på 43,46 procent, en recall på 88,56 procent och en F1 på 58,27 procent. Recall låg därmed på en jämförbar nivå med designcykel 1, i enlighet med designprincipen att recall prioriteras före precision, medan precisionsfallet behövde adresseras innan den slutgiltiga utvärderingen kunde genomföras. Precisionsfallet dominerades av tre källor: NER-modellen flaggade enkla förnamn utan efternamn som personuppgifter (106 falska positiva), kombinationslagret var liberalt i kontextkategorierna med en precision kring 27 till 29 procent, och artikel 9-lagret triggade på vaga formuleringar i hälso- och etnicitetskategorierna. En observation på aggregatornivå förtjänar att lyftas fram. Regeln om minsta antal evidence-fynd för en kombinationsbedömning aktiverades aldrig under körningen, eftersom regelordningen i aggregatorn innebar att hög-konfidens-bypass-tröskeln på 0,85 testades först och avgjorde fallen innan minsta-evidence-regeln hann tillämpas. Detta lämnar tröskelvärdena empiriskt outprövade och utgör en öppen fråga inom designcykelns omfattning.

Eftersom baslinjens precision låg betydligt under nivån från designcykel 1 genomfördes ett separat förbättringsarbete i tre omgångar utan ny arkitektur, enbart genom filter i befintliga lager och promptversioner. I första omgången introducerades ett entitetslagerfilter mot NER-modellens förnamns-fynd tillsammans med skärpta prompts för kombinationslagret och artikel 9-lagret. I andra omgången utökades kombinationsprompten med ett explicit förbud mot att tagga personnamn som signaler, och artikel 9-prompten förtydligade kategorigränser. I tredje omgången tillkom en inneslutningsregel i aggregatorn som tar bort kontext-fynd som helt täcks av ett artikel 9-fynd, vilket eliminerade dubbeltaggning utan att öka informationsvärdet. Tabell 10 sammanfattar utfallet per omgång. Beslutet att avsluta vid omgång 3 motiverades av att ytterligare optimering bedömdes ge avtagande avkastning och riskerade sänka recall, vilket strider mot designprincipen att recall prioriteras före precision.

Omgång	**Åtgärd**	**FP**	**Precision**	**Recall**	**F1**
0 (baslinje)	Initial fyra-lagers-pipeline	272	43,46 %	88,56 %	58,27 %
1	entitetslagerfilter mot förnamns-FP; combination v3; article9 v3	154	57,58 %	89,70 %	70,13 %
2	Combination v4 (namnförbud); article9 v4	144	59,55 %	90,99 %	71,99 %
3	Inneslutningsregel artikel 9 mot kontext; article9 v5	123	62,84 %	89,27 %	73,76 %
Reproduktion	Identisk konfiguration som omgång 3	117	64,00 %	89,27 %	74,55 %

Tabell 10: Pipeline-precisionsförbättring under designcykel 2.

En reproduktionskörning av samma pipeline-konfiguration genomfördes 2026-05-03 inför den naturalistiska utvärderingen (se nedersta raden i tabell 10). Recall var identisk mellan körningarna, medan antalet falska positiva varierade med sex fynd. Variationen är förväntad för LLM-baserade lager där fullständig determinism inte uppnås även vid temperatur noll, och slutpunkten bedöms därmed som stabil. Mätvärdena bör läsas mot den metodologiska reservation om kontextfönstret som redovisas i Sektion 5.5. Det är denna körning som utgör den artefaktversion intressenterna utvärderade. Utfallet sammanfattas i Tabell 11.

	Faktiskt positiv (Entity)	Faktiskt negativ (No entity)
Förutspått positiv	TP: 208	FP: 117
Förutspått negativ	FN: 25	TN: 18 (dokumentnivå)

Tabell 11: Konfusionsmatris för designcykel 2, reproduktionskörningen. TP, FP och FN på entitetsnivå; TN på dokumentnivå (18 texter utan annoterade fynd).

Per-kategori-resultaten gav flera observationer av betydelse för det fortsatta arbetet. Recall för sexuell läggning landade på 66,67 procent och för genetiska data på 71,43 procent, vilket pekar på att språkmodellen missar indirekta formuleringar i de kategorierna. Kontextkategorierna behöll lägre precision än artikel 4 och artikel 9 även efter de tre förbättringsomgångarna, medan

den strukturerade artikel 4-datan med kontrollsiffror låg kvar på full precision och recall. Den fullständiga per-kategori-nedbrytningen redovisas i Sektion 7.1.3. Att minsta-evidence-regeln förblev inaktiv genom hela förbättringsspåret bekräftade att tröskelkalibreringen var en empiriskt motiverad uppgift inför designcykel 3.

Naturalistisk utvärdering. Den naturalistiska utvärderingen följde upplägget i Sektion 2.4.4. Intervjuguiden reviderades inför designcykeln enligt ADR:s fas reflektion och lärande (Sein et al. 2011). Frågor som besvarats tillfredsställande i designcykel 1 utgick, och nya frågor riktades mot det som var specifikt nytt i designcykel 2, alltså artikel 9-lagrets förmåga att fånga implicit hälsoinformation, kombinationslagrets pusselbitsresonemang, den utökade känslighetsskalan, motiveringens roll i kombinationsfynd och valet av lokal språkmodellexekvering. De tre demotexterna valdes för att isolera respektive lager: ett exempel med personnummer, e-post och telefon för lager 1 och 2, en text om diabetesdiagnos utan namn för artikel 9-lagret, och en text om en gymnasielinje där kombinationen yrke, organisation och plats pekar ut en person utan att namnge denna för kombinationslagret. En session genomfördes med var och en av de tre verksamheterna V1, V2 och V4.

Ändamålsenlighet. Samtliga tre intressenter bekräftade att artefakten utför det den är avsedd att göra och att riktningen är korrekt. V1 bedömde systemets förmåga som hög och pekade på pusselbitslagret som den avgörande förbättringen sedan cykel 1: "Det som har saknats innan är ju pusselbitseffekten ... men nu när ni har pusselbitseffekten så får du ju en mycket högre nivå av förmåga att identifiera en person." V2 betonade värdet i att artefakten hittar de känsliga delarna även när full identifiering inte är möjlig: "att ni har kommit så långt så att den faktiskt identifierar de här känsliga uppgifterna är ändå bra. Konkret hur långt ni kommer, det är ju det som avgör om det blir användbart för en organisation i framtiden." V4 bedömde att artefakten "gör rätt saker" och att exemplen fungerade, men signalerade tveksamhet kring om pusselbitsproblemet låter sig lösas inom studiens ram: "Jag tror att det problemet är så pass svårt. Ni kommer ha väldigt svårt att komma i mål med det, men ni kanske kan presentera det på ett tydligt sätt istället."

På artikel 9-lagrets prestation i diabetestexten konvergerade alla tre på en huvudpunkt. Det är ett genuint framsteg jämfört med designcykel 1, eftersom regelbaserade och NER-baserade lager inte hade kunnat fånga uppgifterna, men samma begränsning identifierades av samtliga: informationen går inte att leda till en specifik person. Förslagen på hur begränsningen ska hanteras skilde sig åt verksamheterna. V1 föreslog ett extra detektionspass när artikel 9 hittas utan artikel 4, eller att specificitetsnivån för texten visas separat, så att en text med hög sensitivity men låg specificitet kan hanteras annorlunda än en text med båda höga. V4 föreslog att avgränsa problemet och låta människor fatta beslutet: "Det krävs ganska mycket tolkning för att veta vad som är tillräckligt mycket information för att identifiera en person, men frågan är om det är ett problem som ni ska lösa". V2 lyfte värdet i att artefakten hittar delarna även utan personkoppling, exempelvis för maskningsanvändning.

Pusselbitsexemplet med gymnasietexten gav den mest substantiella återkopplingen. Alla tre bekräftade att kombinationslogiken är meningsfull, men de pekade samtidigt på att artefakten kollapsar två separata dimensioner i en enda skala. V1 formulerade det som specificitet kontra känslighet och föreslog en beslutsmatris: "om specificitetsnivån är hög och känslighetsnivån är hög, då kanske du kan ta ett automatiskt beslut. Men om specificitetsnivån är låg och känslighetsnivån är hög, då kanske det är lite mer: OK, behöver vi göra någonting med det här eller ej?" V4 formulerade samma distinktion som identifierbarhet kontra känslighet i en tvåstegsstruktur. V2 formulerade den som sannolikhet kontra konsekvens från klassisk

riskanalys: "När det är personuppgifter så är det alltid känsligt ... Konsekvensen kommer alltid vara hög när det är personuppgifter oavsett, så det är ju bara sannolikheten som ni kan jobba med."

Alla tre prioriterade recall över precision men landade där från olika håll. V1 angav en konkret brytpunkt: "Någonstans runt 80 procent skulle jag nog säga brytpunkten går, för vad som skulle vara acceptabelt", och kopplade toleransen till verksamhetens datavolym, där flera miljoner instanser per timme gör 64 procents precision ohanterlig. V4 formulerade samma prioritering operativt: "Det är ju ett större problem att missa helt, för då får man ju ändå gå igenom hela texten." V2 nyanserade hållningen i kostnadstermer, där false positives är en direkt personalkostnad men false negatives ändå är värre: "Det är nog än värre om den skulle alltså säga att någonting är ok som inte är ok ... den måste ju träffa rätt". V2 tillade också att verksamheten inte hanterar privatpersoner direkt och att artefaktens nytta därför skulle vara störst på HR-avdelningen.

Nytta. Den utökade känslighetsskalan togs emot positivt. V1 såg den som direkt användbar för prioritering: "För de här nivåerna så ignorerar vi false positives på nivå låg och medium, medan vi manuellt kollar på hög." V2 utgick från att personuppgifter alltid är känsliga och att det är konsekvensen som varierar: "en hög känslighetsnivå, den har ingen relevans om du inte har någonting att koppla det till. Så kopplingen är det som är det viktiga". V4 ifrågasatte inte antalet nivåer utan etiketten: ordet "känslighetsnivå" passar inte för det som delvis är identifierbarhet.

Motiveringen som kombinationslagret producerar bekräftades av samtliga tre som värdefull för granskning men otillräcklig som självständig agerandebas. V1 placerade audit trail-funktionen i ett bredare branschperspektiv: "även om vi tittar utanför det här, så är den här sortens motivationslösningar ganska standardefterfrågan från kunderna när det kommer till system där man jobbar med någon form av audit", men sammanfattade samtidigt att värdet är "lågt för automatisering, så som det ser ut nu". V2 angav vad som saknas för att agera utan egen granskning: "det är relevans och konsekvenser". V4 nyanserade efter textlängd: highlighting räcker för korta texter, längre texter behöver anpassad presentation.

Organisatorisk passform. Lokal språkmodellexekvering togs emot positivt av samtliga tre, med kompletterande motiveringar. V1 pekade på affärsmässig risk: "en leverantör säger att ja, men vi gör all vår processing i EU. Men sen ändrar de sina terms of service utan att du kanske märker det, och helt plötsligt så kör de datan i Asien." V2 resonerade kring teknisk kontroll och formulerade ett krav på "100 procent koll" på leverantören vid hantering av känsliga personuppgifter, motiverat av sidoingångar, personalbehörigheter och bristande spårbarhet i molnmiljöer. V4 svarade kortast: organisationen har ett befintligt on-prem-beräkningskluster och hade använt det. Tillsammans täcker bedömningarna leverantörsrisk, infrastrukturkontroll och befintlig kapacitet, vilket ger empiriskt stöd för valet av lokal exekveringsmiljö.

Slutfrågan gav tre svar som tillsammans pekade på begränsningar i artefaktens nuvarande utformning. V1 och V2 fördjupade tvådimensionsobservationen från temat ändamålsenlighet. V1 återkom till beslutsmatrisen för automatisering som lyfts under temat ändamålsenlighet ovan, där specificitet och känslighet styr om ett beslut kan fattas automatiskt eller behöver mänsklig bedömning. V2 kopplade observationen till klassisk riskanalys: "om jag utvärderar ett system så går jag alltid på en riskanalys och då är det sannolikhet och konsekvens." V4 rekommenderade en pragmatisk avgränsning av pusselbitsproblemet: behandla det som ett demoproblem, visa att det fungerar i teori, och testa med en större modell via API för att separera modellegenskaper från uppgiftens inneboende svårighetsgrad. V2 förankrade

dessutom bedömningen i kostnad genom en jämförelse med traditionella DLP-system, som enligt V2 medför betydande start- och licenskostnader, och menade att en lokal LLM-baserad lösning på den grunden är attraktiv för SME-segmentet. Det är ett perspektiv V2 återkommit till sedan designcykel 1.

5.4.3 Reflektion och lärande

Den viktigaste lärdomen från designcykel 2 ligger på en annan nivå än cykelns konstruktionsmål. Designcykeln byggdes för att utöka pipelinen med två semantiska lager och visa att artefakten kan hantera artikel 9-data och pusselbitseffekten. Det målet uppnåddes tekniskt, men intressentåterkopplingen visade att artefaktens grundläggande modell, där känslighet är en funktion av identifierbarhet, är för enkel ur ett verksamhetsperspektiv. Tre intressenter med olika fackbakgrund formulerade samma observation från olika begreppsapparater: identifierbarhet och känslighet är två separata dimensioner som artefakten i nuvarande form kollapsar till en. Det är en lärdom om problemklassen, inte om implementationen, och den är därför särskilt tung. Att operationalisera distinktionen kräver tvådimensionell klassificering där dimensionerna rapporteras separat, vilket är designcykelns främsta empiriska underlag inför formaliseringen av designprinciperna.

På implementationsnivå bekräftade utvärderingen att två arkitekturella val håller. Lagerprotokollet från designcykel 1 hanterade uppdelningen av kontextlagret i två separata lager utan strukturella ändringar i pipeline eller aggregator, vilket är empirisk evidens för utbytbarhetsprincipen. Lokal språkmodellexekvering togs emot entydigt positivt och fick förankring i tre olika verksamhetsperspektiv: leverantörsrisk, infrastrukturkontroll och befintlig kapacitet. Tre observationer pekar samtidigt på begränsningar som kvarstår. En av kombinationsmekanismerna, regeln om minsta antal evidence-fynd, var i praktiken vilande vid den nuvarande tröskelkonfigurationen eftersom hög-konfidens-bypassen avgjorde fallen först (se Sektion 5.4.2). Recall för de tolkningsberoende artikel 9-kategorierna sexuell läggning och genetiska data (se Sektion 5.4.2) ligger lägst och pekar på att språkmodellen missar indirekta formuleringar där. Motiveringen som kombinationslagret producerar bedömdes av samtliga tre intressenter som värdefull för granskning men otillräcklig som självständig agerandebas, vilket öppnar frågan om vilken roll resonemanget kring ett klassificeringsbeslut ska ha i nästa designcykel.

En specifik metodologisk begränsning rör hur en del av kombinationsdatasetets aggregatfynd konstruerades. FAS A:s genereringsskript innehöll en regelmotor som auto-beräknade aggregatfynd för en delmängd av entries, baserat på de deduktivt formulerade identifierbarhetsregler som etablerats i annoteringsguiden. Vid oenighet mellan regelmotor och granskare i FAS B togs aggregatet bort. Denna delmängd av annoteringarna validerar därmed regelmotorns logik mot sig själv snarare än mot en oberoende juridisk referens. Den artificiella utvärderingens prestandavärden för dessa aggregat reflekterar konsistensen mellan modell och regelmotor snarare än mot en extern sanning. Begränsningen är en konsekvens av att en oberoende juridisk facit för pusselbitsbedömningar saknas i nuläget, och adresseras lämpligast genom framtida arbete med expertannoterad referensdata.

Designcykel 3 är därmed mer inriktad på att ta fram underlag än på att bygga nya komponenter. Det främsta bidraget är det empiriska underlag som tvådimensionsobservationen ger inför formaliseringen av designprinciperna. Själva formaliseringen hör till fas 4 och genomförs först efter att den sista designcykeln är avslutad. Empirisk kalibrering av aggregatorns trösklar och promptförbättringar för de svaga artikel 9-kategorierna är tekniska åtgärder som kan ge mätbara

förbättringar inom existerande arkitektur. V1:s indikation att 80 procent precision är en rimlig brytpunkt för att artefakten ska vara användbar i hög volym ger ett konkret kalibreringsmål. Pusselbitsproblemets inneboende svårighet, där bedömningen av identifierbarhet kräver mer kontextuell information än artefakten i nuvarande form har tillgång till, är en begränsning som hör hemma i framtida forskning snarare än i återstående designcykel.

5.5 Designcykel 3

Designcykel 3 var studiens tredje och sista BIE-fas. Cykeln vidareutvecklade artefakten utifrån den feedback utvärderingen från designcykel 2 hade genererat. Till skillnad från de två föregående cyklerna tillförde designcykel 3 inga nya detektionslager, utan riktade sig mot förfining av den befintliga arkitekturen genom riktade pipelineförbättringar, en utvidgning av klassificeringsobjektet med två separata dimensioner, och en undersökning av artefaktens prestandatak.

5.5.1 Problemformulering

Designcykel 3 tar avstamp i tre observationer från den naturalistiska utvärderingen av designcykel 2. Den första, och tyngsta, är konceptuell. Tre intressenter med olika fackbakgrund formulerade samma observation, att identifierbarhet och dataskyddsklass är två separata dimensioner som artefakten i designcykel 2 slår ihop till en sammanvägd känslighetsskala. De tre begreppsapparaterna bakom observationen redovisas i Sektion 5.4.2. Konvergensen handlar om problemklassen, inte om implementationen, och kräver därför mer än en justering av kalibreringen för att hanteras meningsfullt.

De övriga två observationerna är tekniska. Den avslutande mätningen i designcykel 2 gav en precision på 64,0 procent mot en recall på 89,3 procent, en obalans som V1 förankrade empiriskt i ett riktmärke om cirka 80 procents precision som rimlig brytpunkt för användbarhet i hög volym. Rotorsaksanalysen av de 117 falska positiva fynden pekade på tre dominerande mönster. Kombinationslagrets prompt överproducerade för signalerna context.yrke och context.organisation, matcher-skiktet saknade aliasing mellan article4.adress och context.plats, och aggregatorn deduplicerade inte fynd som överlappade samma kategori över olika lager. Vidare kvarstår det recall-gap i de tolkningsberoende artikel 9-kategorierna som redovisades i Sektion 5.4.2.

En metodologisk observation kompletterar bilden. Som redovisades i designcykel 2:s utvärdering (Sektion 5.4.2) aktiverades aldrig aggregatorns regel om minsta antal evidence-fynd, eftersom hög-konfidens-bypassen avgjorde fallen först. De tre trösklarna medium_threshold, high_confidence_bypass och min_evidence_count är därmed inte empiriskt motiverade utan baserade på de initiala default-värdena, vilket öppnar för empirisk kalibrering mot V1:s precisionsriktmärke.

Mot denna bakgrund formuleras cykelns mål i tre delar. För det första ska tvådimensionsobservationen operationaliseras genom att klassificeringsobjektet utökas med två separata enum-fält för identifierbarhet och dataskyddsklass, varvid den befintliga känslighetsnivån omvandlas till ett derivat av dessa två dimensioner. För det andra ska FP-baslinjen reduceras genom riktade åtgärder mot de fyra identifierade mönstren i rotorsaksanalysen, parallellt med promptförbättringar för de svaga artikel 9-kategorierna. För det tredje ska aggregatorns trösklar kalibreras empiriskt mot V1:s precisionsriktmärke, med villkoret att recall inte får falla under baslinjen från designcykel 2 på 89,3 procent.

Till skillnad från de två föregående cyklerna sker designcykel 3:s arbete i huvudsak inom befintlig arkitektur, snarare än genom tillägg av nya lager eller mekanismer, och cykelns viktigaste bidrag är det empiriska underlag som förs vidare till fas 4. Den tvådimensionella operationaliseringen är cykelns mest substantiella konstruktionsbidrag och samtidigt det primära empiriska underlaget för en eventuell sjätte designprincip om hur identifierbarhet och dataskyddsklass kan representeras separat i ett klassificeringssystem.

5.5.2 Konstruktion, intervention och utvärdering

Konstruktion. Konstruktionsarbetet i designcykel 3 löpte i tre delar. Den första delen bestod av fyra riktade pipelineförbättringar som adresserade dominerande mönster i designcykel 2:s rotorsaksanalys. Den andra delen var en utvidgning av klassificeringsobjektet med två separata dimensioner, vilket operationaliserade tvådimensionsobservationen från designcykel 2:s naturalistiska utvärdering. Den tredje delen var en undersökning av artefaktens prestandatak genom tre på varandra följande hypoteser om var det kvarstående precisionsgapet mot V1:s riktmärke kunde sitta. De fyra pipelineförbättringarna sammanfattas i Tabell 12.

Åtgärd	**Riktat mönster**	**Utfall**
Skärpt kombinationsprompt med negativa exempelpar	context.yrke och context.organisation (53 av 117 FP)	Bidrog till FP-reduktion från 117 till cirka 90
Matcher-aliasing mellan article4.adress och context.plats	Dubbelräknade fynd för samma adresspan	17 färre FP samt motsvarande FN-reduktion
Deduplicering på aggregatornivå	Överlappande fynd i samma kategori från olika lager	11 färre FP
Förstärkt artikel 9-prompt (v6)	Svag eller otestbar recall i hälsa, etniskt ursprung och religiös övertygelse	Strukturell regression; rollback till v5, bevarad som negativ empiri

Tabell 12: De fyra riktade pipelineförbättringarna i designcykel 3 och deras utfall. Delsiffrorna anger varje åtgärds ungefärliga bidrag och överlappar delvis, eftersom samma falska positiva kunde träffas av mer än en åtgärd. Det samlade utfallet av de tre verksamma åtgärderna var en reduktion av FP-baslinjen från 117 till 70 fynd, medan den fjärde åtgärden rullades tillbaka och lämnade utfallet oförändrat.

De tre första åtgärderna riktade sig mot designcykel 2:s falska positiva. Kombinationslagrets prompt skärptes med fyra negativa exempelpar enligt Brown et al. (2020), som visar modellen yrkes- och organisationsangivelser som förekommer utan att utgöra en identifierande pusselbit, exempelvis generiska tjänstebeskrivningar i policydokument. Matcher-aliasingen utgår från att en adress i texten känns igen av Lager 2:s SpaCy-baserade platsigenkänning som ett context.plats-fynd, medan facit förväntar sig kategorin article4.adress. Utan aliasing räknades samma adress därför både som en falsk positiv, ett context.plats-fynd utan motsvarande facit, och som en falsk negativ, en missad article4.adress. Regeln låter ett context.plats-fynd matcha mot en förväntad article4.adress vid utvärderingen, vilket tar bort båda felen. Dedupliceringen på aggregatornivå hanterar i stället samma kategori från olika lager, exempelvis när både artikel

9-lagret och kombinationslagret producerar överlappande fynd för article9.halsodata, och behåller då det fynd som har högst konfidens när span-överlappet överstiger en konfigurerbar tröskel.

Den fjärde åtgärden, en förstärkt artikel 9-prompt (v6) riktad mot de tolkningsberoende kategorierna hälsodata, etniskt ursprung och religiös övertygelse, producerade negativ empiri. v6 inducerade en strukturell regression i Article9Layer: total FP fördubblades från 7 till 14, recall för sexuell läggning sjönk 33 procentenheter och genetisk data tappade 14 procentenheter, som sidoeffekt av de utökade exemplen och CoT-instruktionen. Pipelinen rullades tillbaka till v5, designcykel 2:s slutversion, och experimentet behölls som negativ empiri (se Sektion 7.1.4 och Bilaga C).

Designcykelns mest substantiella konstruktionsbidrag var operationaliseringen av tvådimensionsobservationen från designcykel 2:s naturalistiska utvärdering (se Sektion 5.4.2). Arbetet löpte i två etapper. I den första utökades Classification-objektet med två separata enum-fält, identifiability och data_class, i en inledande fyra-nivåig form, och den befintliga sensitivity-skalan omdefinierades till ett härlett värde ur de två dimensionerna.

Den första utvärderingskörningen visade att den fyra-nivåiga formen var felkonstruerad. Skalorna blandade konfidens med juridisk kategori, och en av dataskyddsklassens nivåer visade sig vara en konsekvens av identifierbarhet utan känsligt material snarare än en självständig dataegenskap. Modellen reviderades därför inom cykeln till en helt kategorisk struktur med tre nivåer per dimension. Att en empirisk observation under cykeln ledde till en designrevision inom samma cykel, snarare än vid iterationsskifte, är ett konkret uttryck för ADR:s princip om kontinuerlig reflektion (Sein et al. 2011). Revisionen omkalibrerade vad sensitivity-skalan kommunicerar men lämnade konfusionsmatrisen oförändrad, eftersom den mäter fynd per kategori och inte aggregerad sensitivity. De färdiga dimensionerna och motiveringen för reduktionen beskrivs i Sektion 6.3.4, och härledningstabellen i Sektion 6.3.3.

Sedan de fyra pipelineförbättringarna och tvådimensionsoperationaliseringen var genomförda kvarstod ett betydande precisionsgap mot V1:s riktmärke om cirka 80 procent. Resten av cykelns konstruktionsarbete ägnades åt att lokalisera detta gap genom tre på varandra följande undersökningar: en konfigurationsfix av språkmodellens kontextfönster, ett försök till empirisk tröskelkalibrering, och en jämförelse mellan språkmodeller.

Den första undersökningen riktade sig mot en konfigurationsmiss i artefaktens lokala språkmodell. En riktad token-mätning visade att samtliga LLM-prompter i designcykel 2 låg över Ollamas implicita defaultvärde för kontextfönstret på 4 096 tokens. Article9Layer-prompterna mätte mellan 6 015 och 6 117 effektiva tokens, motsvarande 47 till 49 procent över defaulten, och CombinationLayer-prompterna mätte mellan 4 397 och 4 454 tokens, motsvarande 7 till 9 procent över. Mätningen indikerade att artefaktens utvärdering i designcykel 2 kan ha påverkats av tyst kontextfönstertrunkering. Fixen genomfördes genom att kontextfönstret sattes explicit till 16 384 tokens i artefaktens OllamaProvider, vilket lyfter det effektiva fönstret långt över de mätta promptlängderna. En kontrollerad omkörning mot samma kodbas och samma prompter, där enbart kontextfönstret ändrades, gav en F1-skillnad på cirka 0,15 procentenheter. Den isolerade effekten av kontextfönsterfixen är därmed marginell. Den retroaktiva metodologiska reservationen består dock, eftersom kontextfönstertrunkeringen rimligen påverkat hela designcykel 2:s utvärdering, även om de exakta mätvärdena inte gick att rekonstruera. Designcykel 2:s rapporterade slutmätvärden i Sektion 5.4 är därför oförändrade men bör läsas mot den metodologiska reservation som undersökningen tydliggör.

Den andra undersökningen riktade sig mot aggregatorns tröskelvärden. Cykelns problemformulering identifierade trösklarna medium_threshold, high_confidence_bypass och min_evidence_count som empiriskt outprövade, baserade på initiala defaultvärden från designcykel 2. Hypotesen var att en empirisk kalibrering mot V1:s precisionsriktmärke skulle reducera FP-baslinjen utan att kompromissa med recall. Ett tröskelrutnät om sexton giltiga konfigurationer testades sekventiellt mot det fullständiga testdatasetet. Efter fjorton av sexton körningar framträdde ett oväntat mönster. TP, FP och FN var konstanta över samtliga konfigurationer, vilket gjorde precision, recall och F1 invarianta. Rotorsaksanalysen visade att hypotesen var arkitekturellt felställd. Aggregatorns trösklar styr Classification.identifiability nedströms, medan utvärderingsramverkets matchning av fynd mot facit sker på finding-nivå innan aggregatorn kör; trösklarna kan därför per arkitektur inte påverka de fynd-nivå-mätvärden som hypotesen ville förbättra. Den arkitekturella egenskapen och de berörda aggregatorstegen beskrivs i Sektion 6.3.3. Det är en direkt konsekvens av *Single Responsibility Principle* (Martin 2003), som i designcykel 1 styrde uppdelningen av ansvar mellan lager och aggregator: lagren producerar fynd, aggregatorn fattar klassificeringsbeslut. Att samma princip nu gjorde tröskelkalibreringen prestandaneutral bekräftar arkitekturens robusthet, men hypotesen om empirisk kalibrering var inte konsistent med arkitekturen och borde ha prövats analytiskt innan empiriskt arbete inleddes. Den negativa empirin formaliserades som en metodologisk lärdom: designcyklernas hypoteser om var prestandaförbättringar kan ske bör i fortsatt arbete prövas mot arkitekturens ansvarsfördelning innan implementations- eller mätarbete inleds.

Den tredje undersökningen riktade sig mot artefaktens lokala språkmodell. Designcykel 2:s utvärdering hade lämnat ett kvarstående recall-gap i tolkningsberoende artikel 9-kategorier (66,67 procent recall för sexuell läggning och 71,43 procent för genetisk data), och promptbaserade åtgärder hade inte lyckats lyfta dessa kategorier utan att försämra andra. Hypotesen var att begränsningen låg i modellens kapacitet snarare än i promptkonstruktionen. För att pröva hypotesen byttes den lokala modellen från qwen2.5:7b-instruct till qwen3:14b, en större modell inom samma modellfamilj. Bytet implementerades genom en konfigurationsändring i artefaktens LLMProvider-abstraktion utan ingrepp i pipeline eller lager, vilket är konsistent med designprincipen om utbytbarhet i lager- och providerprotokollen.

Omkörningen mot det fullständiga testdatasetet visade en substantiell prestandavinst. Totalprestandan rörde sig från en precision på 75,18 procent och F1 på 82,33 procent (qwen2.5:7b-baslinje) till en precision på 82,88 procent och F1 på 86,94 procent. Recall var nästan platt (90,99 till 91,42 procent), vilket innebär att lyftet var precision-drivet genom en reduktion av antalet falska positiva från 70 till 44. Precisionsmålet om V1:s riktmärke på cirka 80 procent, som inte gick att uppnå genom tröskelkalibrering, nåddes alltså genom modellbytet. Per-kategori-rörelserna gav riktning åt tolkningen. För context.yrke och context.organisation, där den första pipelineförbättringens prompt-skärpning gett en blygsam förbättring, lyftes F1 med 23,1 respektive 7,0 procentenheter under modellbytet, vilket indikerar att den kvarvarande precisionsbristen i kontextkategorierna var modellbunden snarare än promptbunden. För article9.sexuell_laggning och article9.religios_overtygelse, där promptförstärkningarna inte hade lyckats utan att försämra andra kategorier, lyftes F1 från 80 till 100 procent respektive 83 till 100 procent, vilket är direkt empiri för den modellbegränsning som v6-rollbacken formulerat som arkitekturell lärdom. Inte alla kategorier förbättrades: context.plats sjönk 11,5 procentenheter F1, vilket pekar på att modellbytet medförde lokala regressioner i några kategorier samtidigt som det gav substantiella lyft i andra. Hälsodata och genetisk data hörde till de tolkningsberoende artikel 9-kategorier som modellbytet inte lyfte; båda låg kvar med en recall under 75 procent och kvarstår därmed som artefaktens svagaste artikel 9-kategorier på recall-axeln. För att verifiera att precisionslyftet inte var ett mät- eller aggregeringsfel

genomfördes en oberoende analys av de specifika fynd som försvunnit mellan körningarna, med slutsatsen att lyftet är genuint och inte ett artefakt av mätinstrumentet.

En kompletterande jämförelse genomfördes mot en större molnbaserad modell, Claude Opus 4.7, för att besvara V4:s rekommendation från designcykel 2 om att testa pusselbitsproblemet med en modell större än vad lokal hårdvara medger. Avsikten var inte att överväga en molnprovider för produktion, utan att isolera modellkapacitetens roll genom att ställa en strukturellt jämförbar men kapacitetsmässigt större modell mot qwen3:14b på samma kodbas, samma korpus och samma prompter. Opus 4.7 gav en F1 på 87,85 procent mot qwen3:14b:s 86,94 procent, en skillnad på 0,91 procentenheter i F1 (och 0,26 procentenheter i precision). Marginalen är försumbar och tyder på att Lager 3:s kapacitetstak ligger nära qwen3:14b:s prestanda för den aktuella uppgiften, och att kombinationslagrets pusselbitsbedömning kvarstår som delvis uppgiftsbunden snarare än enbart modellbunden. Den lokala konfigurationen behölls trots jämförelsen, motiverat av V4:s krav på lokal kvalificerad infrastruktur från designcykel 2, GDPR:s regler om tredjelandsöverföring (kapitel V) som komplicerar en molnprovider för produktion, och *Privacy by Design* som fail-safe-princip. Opus-jämförelsen utgör därmed ett bidrag till diskussionen om modellkapacitetens roll i artikel 9-lagret och kombinationslagret, inte underlag för en arkitekturändring.

Artificiell utvärdering. Den slutgiltiga artificiella utvärderingen genomfördes mot samma testdataset som i designcykel 2, alltså 159 texter sammanställda från designcykel 1:s ursprungliga testset (80 texter), artikel 9-datasetet (52 texter) och kombinationsdatasetet (27 texter). Inga ändringar gjordes i testdatasetet under designcykel 3, vilket innebär att jämförelser mellan designcykel 2:s och designcykel 3:s mätvärden är direkt giltiga. Slutmätningen gav TP=213, FP=44 och FN=20, motsvarande en precision på 82,88 procent, en recall på 91,42 procent och en F1 på 86,94 procent (se Tabell 13). Recall-villkoret att inte falla under designcykel 2:s 89,27 procent uppfylldes, och V1:s precisionsriktmärke om cirka 80 procent nåddes.

	Faktiskt positiv (Entity)	Faktiskt negativ (No entity)
Förutspått positiv	TP: 213	FP: 44
Förutspått negativ	FN: 20	TN: 18 (dokumentnivå)

Tabell 13: Konfusionsmatris för designcykel 3, reproduktionskörningen. TP, FP och FN på entitetsnivå; TN på dokumentnivå (18 texter utan annoterade fynd).

Lyftet följer av cykelns konstruktionsarbete. Pipeline- och aggregatoråtgärderna reducerade FP-baslinjen från 117 till 70 fynd, och det efterföljande modellbytet till qwen3:14b reducerade den vidare till 44. Den fullständiga prestandaanalysen, med per-lager- och per-kategori-nedbrytning samt jämförelsen över de tre designcyklerna, redovisas i Sektion 7.1. De artificiella resultaten kompletteras i nästa avsnitt av den naturalistiska utvärderingen, som inhämtar intressentbedömningar mot praktiknära förutsättningar.

Naturalistisk utvärdering. Den naturalistiska utvärderingen följde upplägget i Sektion 2.4.4. Intervjuguiden reviderades inför cykeln med frågor riktade mot det som var nytt i designcykel 3, alltså tvådimensionsmodellen med separat identifierbarhet och dataskyddsklass, derivatfunktionen som härleder känslighetsnivån, precisionslyftet från designcykel 2, modelluppgraderingen till qwen3:14b och frågan om hur en slutanvändare utan djup GDPR-

kompetens kan värdera systemets utfall. De tre demotexterna valdes för att täcka identifierbarhetsaxeln: ett HR-ärende med direkt identifierbar person och artikel 9-innehåll (härledd känslighet HÖG), en visselblåsartext där en person pekas ut indirekt utan att namnges (MEDEL) och en fallbeskrivning med artikel 9-substans men ingen identifierbar person (LÅG). En session genomfördes med var och en av verksamheterna V1, V2 och V4. V1:s deltagande utökades inför cykeln med en dataskyddsansvarig vid sidan av mjukvaruarkitekten.

Samtliga tre intressenter bekräftade att uppdelningen i identifierbarhet och dataskyddsklass fångar den distinktion de lyft i designcykel 2, vilket stänger det empiriska underlaget för DP6:s tvådimensionella kärna. Derivatfunktionen, som väger samman de två dimensionerna till en härledd känslighetsnivå, mötte däremot konvergent kritik, tydligast mot LOW-nivån som samlar fall med olika rättslig karaktär. Precisionsmässigt nåddes V1:s riktmärke om cirka 80 procent, men intressenterna bedömde samstämmigt att motivering och spårbarhet är nödvändiga men inte tillräckliga som användarstöd. Den fullständiga longitudinella bedömningen av nytta, ändamålsenlighet och organisatorisk passform redovisas i Sektion 7.2.

5.5.3 Reflektion och lärande

Designcykel 3 var studiens sista BIE-cykel, och dess konstruktionsmål uppnåddes tekniskt. De fyra pipelineförbättringarna och modellbytet lyfte precisionen från 64,0 till 82,9 procent samtidigt som recall bibehölls, och V1:s riktmärke om cirka 80 procent från designcykel 2 nåddes. Tvådimensionsoperationaliseringen, cykelns mest substantiella konstruktionsbidrag, implementerades och kunde för första gången bedömas av intressenterna i praktiken. Den naturalistiska utvärderingen bekräftade att uppdelningen i identifierbarhet och dataskyddsklass fångar den distinktion som de tre verksamheterna lyft från var sin begreppsapparat i designcykel 2. På den punkten stänger designcykel 3 det empiriska underlaget för DP6.

Samtidigt framträdde en ny observation på samma nivå som designcykel 2:s tvådimensionsinsikt, alltså på problemklassens nivå snarare än på implementationens. Derivatfunktionen, som väger samman de två dimensionerna till en härledd känslighetsnivå, mötte konvergent kritik från samtliga tre intressenter. Invändningen är att en sammanvägd skala ovanpå två separata dimensioner återinför just den hopslagning som tvådimensionsuppdelningen var tänkt att lösa, tydligast i att LOW-nivån samlar fall med olika rättslig karaktär. V4 förespråkade att den härledda skalan tas bort, V2 att en separat icke-GDPR-kategori införs, och V1 ifrågasatte derivatfunktionens utfall när ingen identifierbar person finns. Lärdomen är att tvådimensionsmodellen är riktig men att försöket att ändå leverera ett enda sammanfattande värde underminerar den. Detta är ett direkt underlag för hur DP6 formuleras i fas 4 och för diskussionen om framtida arbete i Sektion 9.6.

Två ytterligare lärdomar bör föras vidare. Jämförelsen mot en större molnmodell visade att ett steg upp i modellkapacitet bortom den lokala qwen3:14b inte gav någon påtaglig prestandavinst, eftersom molnmodellen endast låg marginellt över den. Den kvarvarande prestandabegränsningen ligger därmed i prompt och uppgift snarare än i ytterligare modellkapacitet. Det stärker det empiriska underlaget för DP3, eftersom valet av lokal exekvering därmed inte innebär en prestandakostnad i förhållande till en molnbaserad lösning. Den andra lärdomen kommer ur fit-materialet. Intressenternas samstämmiga bedömning att motiveringen och spårbarheten är nödvändiga men inte tillräckliga som användarstöd problematiserar DP5 i dess nuvarande form och pekar mot att principen behöver formuleras med ett presentationslager och organisatorisk kompetens som en del av sin rationale. Eftersom

designcykel 3 var den sista cykeln förs dessa lärdomar inte vidare till en ny problemformulering utan in i fas 4, formalisering av lärande, där designprinciperna och artefaktens arkitektur formaliseras utifrån det samlade underlaget från de tre designcyklerna.

5.6 Formalisering av lärande

Med designcykel 3 avslutad är studiens tre BIE-cykler genomförda, och arbetet övergår i ADR:s fjärde och sista fas. Där designcyklerna löste ett situerat problem i samverkan med tre specifika verksamheter är syftet med formaliseringen av lärande att lyfta lärdomarna från den situerade nivån till generella lösningskoncept (Sein et al. 2011, s. 44). De beskriver denna rörelse, från det specifika och unika till det generiska och abstrakta, på tre nivåer: generalisering av probleminstansen, generalisering av lösningsinstansen, och härledning av designprinciper ur designforskningens utfall. De följande styckena redovisar de två första nivåerna och anvisar var den tredje, tillsammans med arkitekturrepresentationen, behandlas i sin helhet.

Generaliseringen av probleminstansen genomfördes redan i problematiseringscykeln (Sektion 5.2), då studien gick från en instans, behovet av att hantera känslig text hos tre enskilda verksamheter, till en problemklass: automatisk identifiering och kategorisering av textinnehåll utifrån GDPR:s känslighetskategorier. Det steget har de tre designcyklerna gett empiriskt stöd. V1, V2 och V4 skiljer sig åt i storlek, sektor och bransch, men deras bedömningar konvergerade genomgående kring samma kärnbehov, att kunna avgöra om en text innehåller känsliga personuppgifter innan den lagras, vidarebefordras eller behandlas vidare. Att tre så olika verksamheter återkommande bekräftade samma behov är belägg för att problemklassen håller och inte är ett särdrag hos en enskild verksamhets situation.

Generaliseringen av lösningsinstansen skiljer artefakten Aegis, så som den ser ut i version 0.3.0, från det lösningskoncept den instansierar. Artefaktens konkreta form, exempelvis den svenska spaCy-modellen, den lokala språkmodellen qwen3:14b och de empiriskt satta tröskelvärdena, är instansbundna val styrda av studiens kontext och tidsram. Lösningskonceptet är mer abstrakt: en lagerindelad klassificeringspipeline där deterministisk mönsterigenkänning, entitetsigenkänning, språkmodellbaserad detektion av särskilda kategorier och en kombinatorisk pusselbitsbedömning körs mot samma originaltext, och där utfallet representeras tvådimensionellt som identifierbarhet och dataskyddsklass. Det är detta koncept, inte den specifika kodbasen, som är överförbart till andra projekt inom problemklassen.

Den tredje nivån, härledningen av designprinciper, utgör tillsammans med arkitekturrepresentationen studiens formaliserade kunskapsbidrag. Eftersom formaliseringen vilar på en analys som löper tvärs över de tre designcyklerna, med arkitekturen, loggbokens designbeslut och verksamheternas återkoppling som de tre underlagskällorna (se Sektion 2.5.4), presenteras de formaliserade utfallen i analyskapitlet snarare än här. Arkitekturen representeras genom UML-klassdiagram i Sektion 6.3, vilket konkretiserar den princip om form och funktion som Gregor och Jones (2007) anger för en designteori, och besvarar delfråga 1 om den arkitekturella lösningen. Designprinciperna formuleras enligt Gregor, Chandra Kruse och Seidels (2020) schema i kapitel 8 och besvarar delfråga 4. Sex principer abstraherades ur designcyklernas samlade underlag: recall-prioritering som fail-safe (DP1), utbytbarhet via ett smalt lagerprotokoll (DP2), lokal språkmodellexekvering med utbytbar provider (DP3), tvåstegsdetektion av kombinatorisk identifierbarhet (DP4), spårbar härledning av klassificeringsbeslut (DP5) och tvådimensionell representation av juridisk klassificering (DP6). Principerna är formulerade som generaliserbara lösningskoncept men har inte prövats empiriskt

utanför denna studie, och deras status som prövbara påståenden behandlas i diskussionens avsnitt om begränsningar och framtida forskning.

6 Artefakten Aegis

Artefakten som studien utvecklat är en klassificerare för ostrukturerad svensk text under GDPR. Den tar emot en textsträng och returnerar en klassificering som består av en sammanvägd känslighetsnivå, två separata dimensionsvärden för identifierbarhet och dataskyddsklass, samt en lista över de textavsnitt som motiverar bedömningen. Indata kan vara e-post, dokument, chattmeddelanden eller prompter till språkmodeller, alltså den typ av material där känsliga personuppgifter ofta förekommer utan att avsändaren tänker på det. Avsedda användare är dataskyddsansvariga och informationssäkerhetsroller i organisationer som omfattas av GDPR. Den version som beskrivs här är v0.3.0, artefakten så som den såg ut efter designcykel 3.

6.1 Teknisk stack

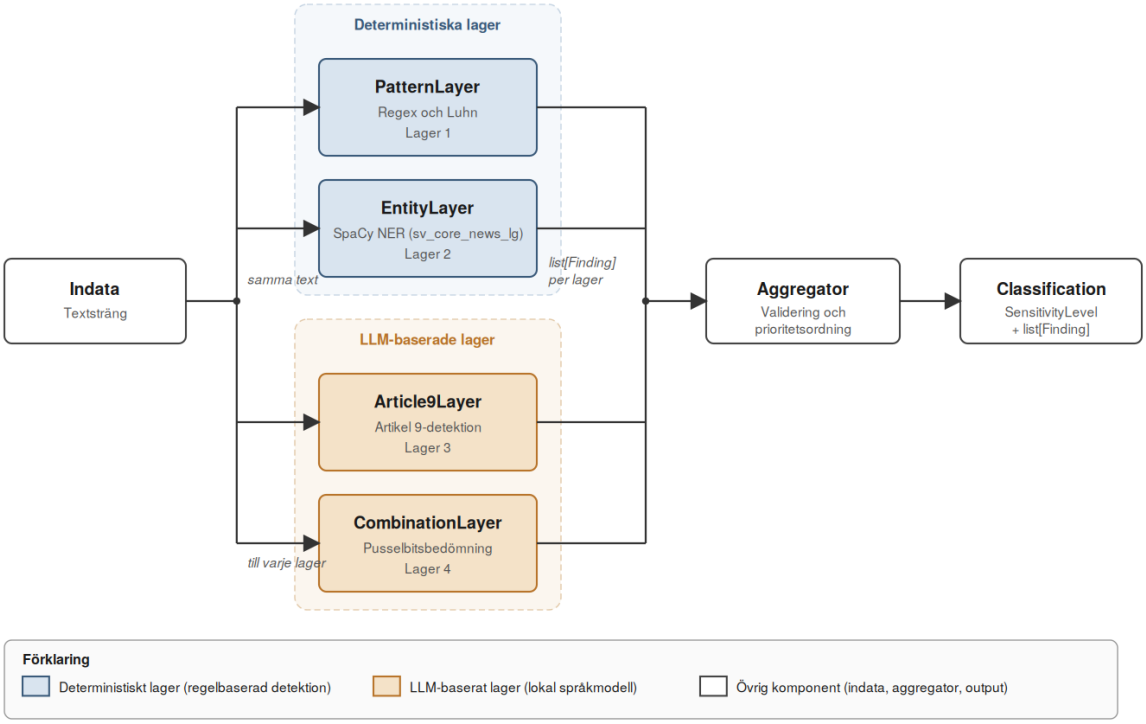
Den tekniska stacken växte fram under genomförandet snarare än vid metodvalet, eftersom de flesta verktygsbesluten fattades när respektive komponent implementerades. Artefakten kräver Python 3.11 eller senare, en nedre gräns som sätts av beroendepaketens versionskrav. Versionshantering sker i Git med GitHub som kodvärd, och arbetet styrs via GitHub Projects. Beroenden hanteras i pyproject.toml med Pythons inbyggda venv, och testning sker med pytest. Lager 1 använder enbart standardbiblioteket: re för regex-matchning, en Luhn-implementation (ISO/IEC 7812-1:2017) för personnummer och betalkort, och en mod97-kontroll (ISO 13616-1:2020) för IBAN. Inga tredjepartsbibliotek behövs i lagret. Lager 2 använder spaCy (Honnibal, Montani, Van Landeghem & Boyd 2020) med den svenska modellen sv_core_news_lg (Explosion AI u.å.). Large-varianten valdes eftersom artefakten arbetar mot svensk fritext, där den större modellens noggrannhet på namn-, plats- och organisationsdetektion motiverar det ökade resursbehovet jämfört med de mindre svenska alternativen.

Lager 3 och 4 körs på en lokal språkmodell. Exekveringen sker via Ollama (Ollama u.å.) med modellen qwen3:14b (Qwen Team 2025), som anropas över HTTP med deterministisk inställning (temperatur 0,0) och strukturerad JSON-output. Valet av lokal drift motiveras av dataskyddsskäl och av V4:s krav på lokal infrastruktur; den fullständiga motiveringen med teoretiskt och empiriskt stöd redovisas i Sektion 5.4.2 och formaliseras som DP3 i kapitel 8. Ett LLMProvider-protokoll skiljer de två lagren från den konkreta modellimplementationen, vilket gör det möjligt att byta provider via en miljövariabel. Utöver den lokala providern finns två molnprovidrar implementerade för utvecklings- och jämförelseändamål; de är dokumenterade som icke-produktion eftersom data då lämnar lokal infrastruktur. Prompterna till de två lagren versioneras som YAML-filer och konstrueras enligt etablerad metod (Brown et al. 2020; Wei et al. 2022; Liu et al. 2023; He et al. 2024).

Aggregatorn och artefaktens domänmodell använder inga tredjepartsbibliotek. Detsamma gäller utvärderingsmodulen, där precision, recall, F1 och konfusionsmatris beräknas direkt utifrån standarddefinitionerna (Opitz 2024) utan ML-bibliotek. Demonstrationsgränssnittet är byggt med Dash (Plotly u.å.) och läser förgenererade JSON-snapshots i stället för att köra en LLM-baserad utvärdering live, eftersom en full körning tar flera minuter. Kvalitetskontrollen har skett genom pytest och manuell kodgranskning; automatiserad linting och continuous integration har valts bort, en medveten avgränsning för ett arbete vars enda formella distribution är inlämningen.

6.2 Klassificerare

Internt består artefakten av en pipeline med fyra detektionslager och en aggregator. Pipelinen distribuerar samma originaltext till varje aktivt lager, och lagren körs oberoende av varandra utan att något lager läser ett annat lagers utfall. Den parallella organisationen gör det möjligt att isolera fel till ett enskilt lager, vilket har varit en förutsättning för det per-lager-baserade förbättringsarbetet i designcykel 2 och 3. Figur 2 visar pipeline-strukturen.



Figur 2: Pipeline-strukturen. Indatatexten distribueras parallellt till fyra detektionslager, och lagrens fynd aggregeras till en Classification.

De fyra lagren skiljer sig åt i metod och täcker tillsammans de delar av GDPR som artefakten hanterar. PatternLayer detekterar formellt strukturerade artikel 4-uppgifter, alltså personnummer, betalkort, IBAN, e-post och telefonnummer, med reguljära uttryck och kontrollsiffervalidering. EntityLayer bygger på spaCys svenska modell och extraherar personnamn, platser och organisationer. Article9Layer identifierar GDPR:s särskilda kategorier enligt artikel 9, alltså uppgifter om hälsa, etniskt ursprung, religiös eller politisk övertygelse, fackmedlemskap, biometri, genetik och sexuell läggning. CombinationLayer bedömer pusselbitseffekten enligt skäl 26 och letar efter situationer där enskilt icke-identifierande signaler som yrke, plats och organisation tillsammans pekar ut en specifik individ.

Varje fynd bär ett source-fält som identifierar både producerande lager och underliggande regel. PatternLayer markerar sina fynd som pattern.X, EntityLayer som entity.spacy_PRS och liknande, Article9Layer som article9.halsodata med flera, och CombinationLayer antingen som context.{signal} för enskilda signaler eller som context.kombination för det aggregerade kombinationsfyndet. Source-fältet ligger till grund för artefaktens spårbarhet och gör per-lager-rapporteringen i utvärderingsmodulen möjlig.

Pipelinens sista steg är aggregatorn, som väger samman lagrens fynd till den färdiga klassificeringen. Den klassificeringen bär tre värden: identifierbarhet, som anger om en fysisk

person är direkt identifierbar via ett artikel 4-fynd, indirekt identifierbar via ett validerat kombinationsfynd, eller inte identifierbar alls; dataskyddsklass, som anger om texten innehåller en särskild kategori enligt artikel 9; och en känslighetsnivå som inte är en egen dimension utan ett härlett värde ur de två andra. Den härledda nivån gör att artefakten kan ge en nyanserad bedömning tillsammans med en enkel sammanfattning, lämpad för den konfigurerbara granskningsprioritering V1 efterfrågade i designcykel 2. Aggregatorns interna behandling beskrivs i Sektion 6.3.3 och dimensionernas härledning i Sektion 6.3.4.

En integration som anropar pipelinen direkt, utan demonstrationsgränssnittet, får tillbaka ett Classification-objekt serialiserat som JSON. Figur 3 nedan visar utdatan för en kort text med en hälsouppgift kopplad till ett sjukhus, en av de fördefinierade exempeltexter som demonstrationsgränssnittet laddar via exempelknappen för artikel 9: "*Patienten har diagnostiserats med diabetes typ 2 och behandlas med metformin sedan 2024. Uppföljning sker på Sahlgrenska Universitetssjukhuset*".


```
{
  "findings": [
    {
      "category": "article9.halsodata",
      "start": 14,
      "end": 48,
      "text_span": "diagnostiserats med diabetes typ 2",
      "confidence": 0.99,
      "source": "article9.halsodata",
      "metadata": null,
      "evidence_basis": "no_support_required"
    },
    {
      "category": "context.organisation",
      "start": 109,
      "end": 142,
      "text_span": "Sahlgrenska Universitetssjukhuset",
      "confidence": 0.98,
      "source": "context.organisation",
      "metadata": {
        "deduplicated_sources": [
          "entity.spacy_ORG"
        ]
      },
      "evidence_basis": "no_support_required"
    }
  ],
  "sensitivity": "low",
  "active_layers": [
    "pattern",
    "entity",
    "article9",
    "combination"
  ],
  "overlapping_findings": [],
```

```
  "identifiability": "none",
  "data_class": "special",
  "weakest_evidence_basis": "no_support_required"
}
```

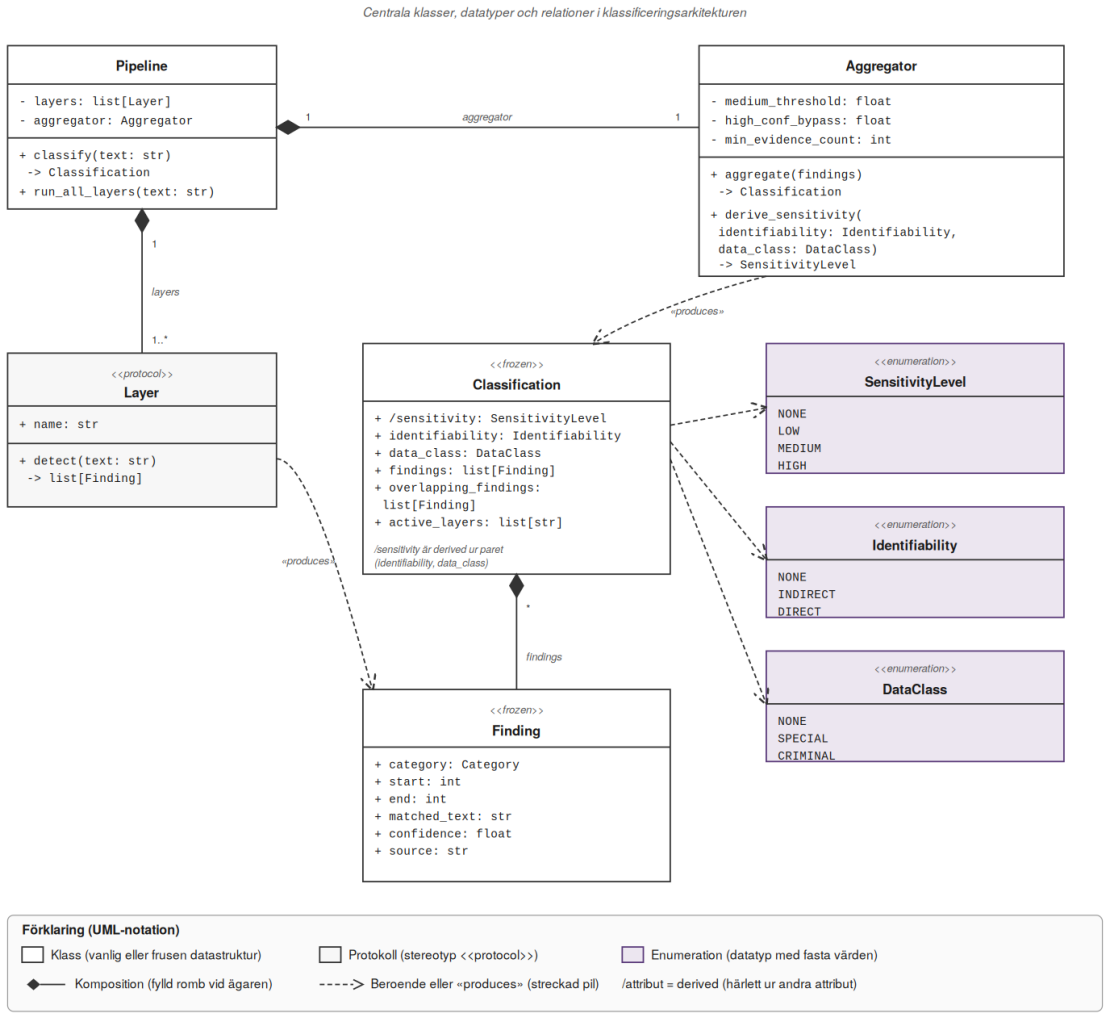
Figur 3: Serialiserad Classification för exempeltexten ovan, producerad mot kommithash a4ee592.

Utdatan illustrerar dimensionsseparationen. Article9Layer har identifierat diabetesdiagnosen som en hälsouppgift enligt artikel 9, vilket sätter data_class till SPECIAL. Organisationsfyndet bär context-prefix och pekar inte i sig ut en fysisk person, och eftersom inget artikel 4-fynd förekommer blir identifiability NONE. Paret (NONE, SPECIAL) ger känslighetsnivån LOW enligt aggregatorns härledningstabell. JSON-utdatan kommer från en enskild körning mot en specifik kommithash, på samma sätt som utvärderingens snapshots är knutna till versionshistoriken. Eftersom två av lagren använder en språkmodell är enskilda fyndvärden som konfidens och spannordning inte strikt deterministiska mellan körningar, men dimensionsutfallet är det: härledningstabellen är en ren funktion av de två dimensionerna och mappar alltid (NONE, SPECIAL) till LOW oavsett mindre variation i de underliggande fynden.

6.3 Arkitekturbeskrivningar

Detta avsnitt besvarar studiens första delfråga om vilken arkitekturell lösning som möjliggör automatisk klassificering av textinnehåll enligt GDPR. Beskrivningen följer Gregor och Jones (2007) syn på principer för form och funktion som en abstrakt ritning över IT-artefakten, och representeras med UML-klassdiagram för att tydliggöra klasser, ansvar och relationer. Beskrivningen kompletterar Sektion 6.2, där artefakten beskrivs ur ett användarperspektiv, genom att redovisa de arkitekturella val som möjliggör det observerade beteendet och som ligger till grund för designprinciperna i Sektion 8.

6.3.1 Övergripande klassdiagram



Figur 4: Centrala klasser, datatyper och relationer i klassificeringsarkitekturen.

Figur 4 visar systemets centrala klasser och deras relationer. Pipeline-klassen är arkitekturens orkestrator och håller en lista av lager samt en aggregatorinstans. När en text klassificeras itererar Pipeline över sin lagerlista, anropar varje lagers detect-metod med originaltexten och samlar de returnerade fynden i en gemensam lista. Den listan skickas till Aggregator, som producerar det slutliga Classification-objektet. Pipeline har inget eget tillstånd mellan anrop och inga sidoeffekter utöver de fynd den genererar.

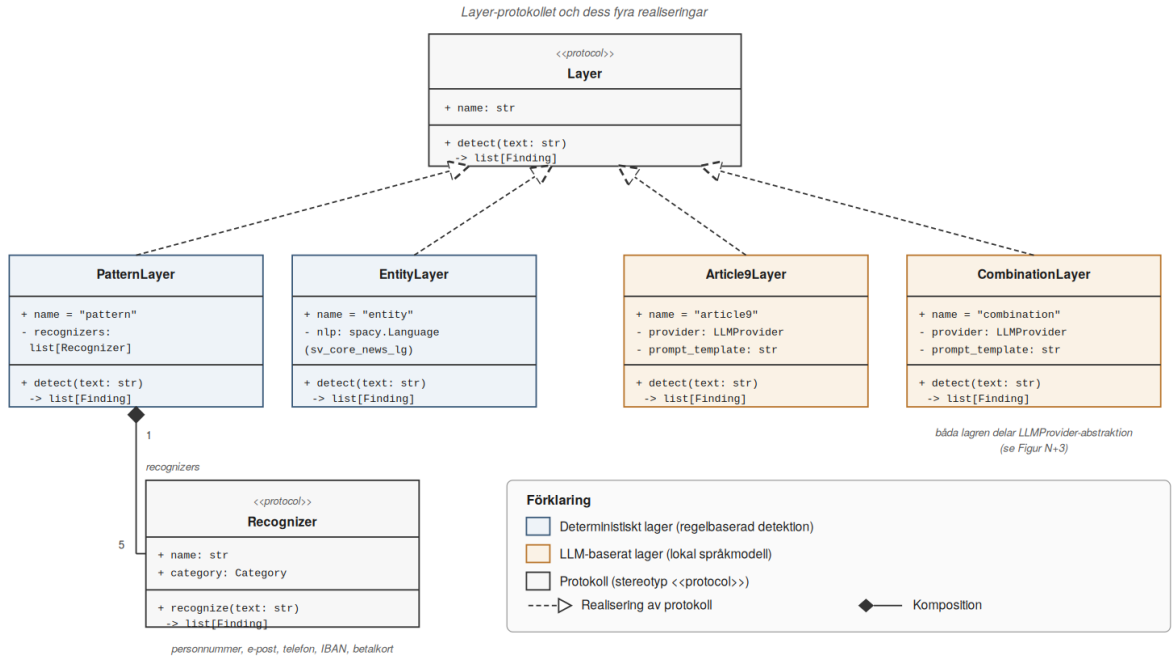
Layer är ett protokoll, inte en konkret klass. Det specificerar två krav: ett namnattribut av typen sträng och en detect-metod som tar en text och returnerar en lista av Finding-objekt. Pipeline interagerar med sina lager enbart via detta protokoll, vilket innebär att vilken klass som helst som uppfyller kontraktet kan delta i pipelinen utan att Pipeline-koden behöver ändras. PatternLayer, EntityLayer, Article9Layer och CombinationLayer är de fyra konkreta implementationer som ingår i v0.3.0.

Finding är systemets minsta informationsbärare. Den innehåller en kategori (instans av Category-enum), textspannets start- och slutposition, det matchade textavsnittet, en konfidens i intervallet 0,0 till 1,0, och ett source-fält som identifierar producerande lager och regel. Finding-klassen är fryst (immutable) vilket gör att fynden kan delas mellan komponenter utan risk för oavsiktlig modifiering.

Classification är aggregatorns output och innehåller sex fält. De tre primära är en SensitivityLevel, ett Identifiability-värde och ett DataClass-värde. Därutöver bär objektet med sig den fullständiga listan av Finding-objekt som producerats av lagren, en lista av överlappande fynd för spårbarhet, samt namnen på de lager som varit aktiva i klassificeringen. Sensitivity-fältet är inte en egen domändimension utan ett härlett värde från paret (identifiability, data_class) via en ren modulnivåfunktion vars utformning beskrivs i Sektion 6.3.4. Dimensionernas enum-värden och den empiriska motiveringen bakom modellens utformning behandlas närmare i Sektion 6.3.4. Även Classification är frusen.

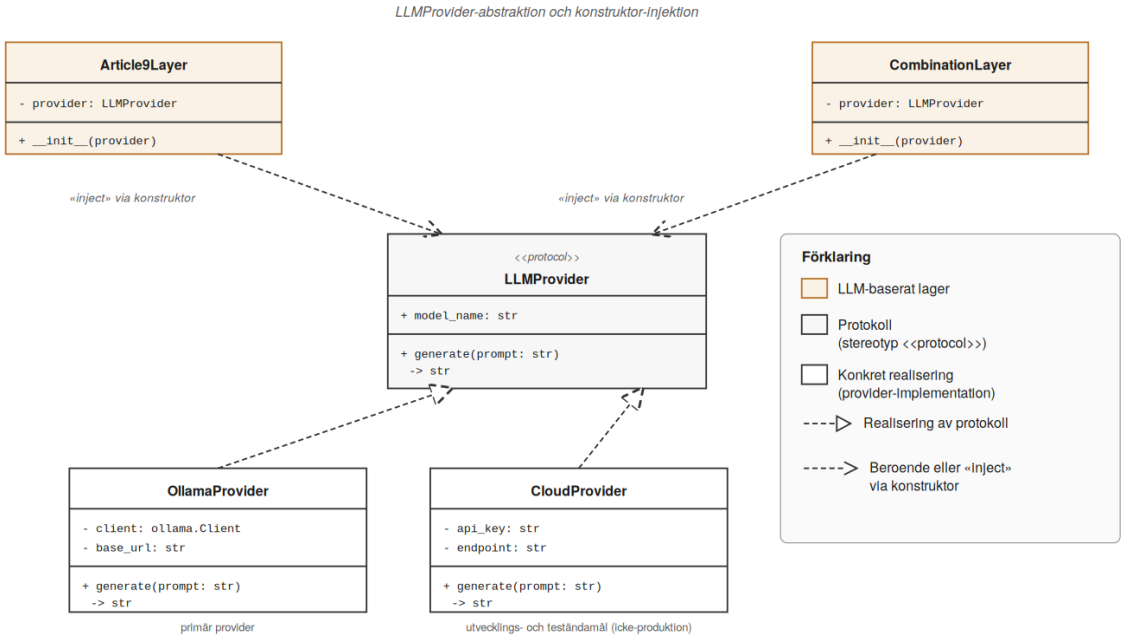
Aggregator är den klass som omsätter den samlade fyndlistan till ett Classification-objekt. Den deltar inte i detektionen och hör därför inte till lagerstrukturen. Aggregatorns interna behandling beskrivs i Sektion 6.3.3.

6.3.2 Lagerprotokollet och dess realisering



Figur 5: Layer-protokollet och dess fyra realiseringar.

Figur 5 visar de fyra konkreta lagren och deras gemensamma arvskontrakt mot Layer-protokollet. De fyra lagren skiljer sig dramatiskt i intern uppbyggnad. PatternLayer består av fem recognizers som var och en implementerar ett eget Recognizer-protokoll och i sin tur uppfyller olika detektionsstrategier (regex för e-post och telefon, regex plus Luhn-validering för personnummer och betalkort, regex plus mod97 för IBAN). EntityLayer är en tunn omslagsklass kring SpaCys statistiska modell sv_core_news_lg och mappar modellens entitetstyper (PRS, LOC, ORG) till motsvarande Category-värden. Article9Layer och CombinationLayer delar en LLMProvider-instans och skiljer sig åt i prompts, parsning av modellsvar och valideringskedjor. Trots de olika interna strukturerna är det ingen skillnad i hur Pipeline interagerar med dem. Den enhetligheten är arkitekturens primära kvalitet.



Figur 6: LLMProvider-abstraktion. OllamaProvider för lokal exekvering, CloudProvider för utvecklings- och teständamål (icke-produktion).

Figur 6 visar LLMProvider-abstraktionen, som skiljer Article9Layer och CombinationLayer från den konkreta språkmodellsimplementationen. Den definierar en generate-metod som tar prompt-text och returnerar modellens svar som strukturerad output. Två konkreta providers finns implementerade: OllamaProvider för lokal exekvering och en konfigurerbar molnprovider för utvecklings- och teständamål. Cloud-providern är dokumenterad som icke-produktion. Lagerklasserna instansierar inte sin LLMProvider själva utan tar emot den via konstruktorn (dependency injection), vilket gör att samma lagerklass kan köras mot olika providers utan kodändringar. Det är genom denna mekanism som DP3 om lokal språkmodellexekvering med utbytbar provider realiseras arkitekturellt (se Sektion 8).

6.3.3 Aggregatorn och härledning av klassificering

Aggregatorn är den klass som omsätter den samlade fyndlistan till en klassificering. Till skillnad från detektionslagren bär aggregatorn inget detektionsansvar och anropar ingen språkmodell. Dess uppgift är mekanisk: att rensa fyndlistan från redundans, att härleda två oberoende dimensioner ur den filtrerade listan, och att mappa dessa dimensioner till en sammanvägd känslighetsnivå enligt en deterministisk tabell. Den funktionella avgränsningen mellan detektion i lagren och beslut i aggregatorn ligger till grund för DP4 (tvåstegsdetektion av kombinatorisk identifierbarhet) som formaliseras i Sektion 8.

Behandlingen sker i fem sekventiella steg, varav det andra är aktivt enbart när aggregatorn körs i cross_validating-läge.

I det första steget rensas fyndlistan genom två innehållsregler. Inneslutningsregeln tar bort telefonnummer-fynd vars span överlappar med IBAN-fynd, eftersom IBAN-recognizern kräver mod97-kontrollsiffervalidering och därmed är striktare än telefonregexen. Same-category-deduplicering avlägsnar överlappande fynd inom samma kategori genom att behålla det med högst konfidens; vid lika konfidens bevaras det som kommer först i input-listan, vilket gör beteendet deterministiskt och oberoende av lagerordning. Det borttagna fyndets source-fält

propageras till det behållna fyndets metadata, vilket bevarar spårbarhet samtidigt som matcharens en-till-en-logik nedströms inte räknar parallella detektioner från olika lager som dubbeldetektion.

I det andra steget appliceras evidensvägningspasset (aktivt i cross_validating-läge, behandlas närmare nedan). I det tredje steget identifieras överlappande fynd via _find_overlaps för att möjliggöra spårbarhet av cross-category-överlapp utan att modifiera fyndlistan.

I det fjärde steget bestäms två separata dimensioner ur den filtrerade listan. Identifiability sätts till DIRECT om listan innehåller minst ett artikel 4-fynd, till INDIRECT om listan innehåller ett validerat kombinationsfynd men inget artikel 4-fynd, och till NONE annars. Valideringen av kombinationsfyndet kräver antingen att kombinationslagrets konfidens överstiger en hög-konfidens-bypasströskel, eller att minst två stödjande spans korresponderar med fynd från Lager 1 eller Lager 2 alternativt förekommer ordagrant i originaltexten. DataClass sätts till SPECIAL om listan innehåller minst ett artikel 9-fynd, och till NONE annars. En tredje strukturell kategori CRIMINAL är reserverad för framtida artikel 10-detektion men är inte produktionssatt i v0.3.0; kolumnen finns med i härledningstabellen som markör för att utbyggnaden inte kräver omdesign av aggregatorn. Den empiriska motiveringen för dimensionsseparationen, samt intressentmaterialet från designcykel 2 som ligger till grund för designvalet, behandlas i Sektion 6.3.4.

I det femte steget mappas paret (identifiability, data_class) till en känslighetsnivå enligt den deterministiska härledningstabellen i Tabell 14.

Identifiability \ DataClass	**NONE**	**SPECIAL**	**CRIMINAL**
NONE	NONE	LOW	LOW
INDIRECT	LOW	MEDIUM	MEDIUM
DIRECT	LOW	HIGH	HIGH

Tabell 14: Härledningstabell för känslighetsnivå.

Tabellens nio celler är inte godtyckligt satta utan konstruerade för att samtidigt uppfylla fyra krav. Trohet mot GDPR:s kategoriska struktur innebär att de tre nivåerna på varje axel motsvarar lagtextens distinktioner snarare än en glidande skala. Monotonicitet innebär att känslighetsnivån ökar icke-strikt med båda dimensionerna, så att ett tillskott av identifierbarhet eller dataskyddsklass aldrig sänker utfallet. Den juridiska reservationen av HIGH innebär att den högsta nivån ges enbart åt det material som artikel 83.4 och 83.5 graderar strängast, vilket i tabellen är direkt identifierbarhet i förening med en särskild eller brottsrelaterad kategori. Fail-safe-konsekvensen visar sig i att anonym text om en känslig kategori klassas LOW och inte NONE, så att materialet flaggas för granskning även när ingen identifierbar person påträffats. Utfallet per kombination är därför deterministiskt och följer både lagtextens struktur och artefaktens fail-safe-orientering.

Härledningsfunktionen är medvetet placerad på modulnivå snarare än som metod på Aggregator-klassen. Dess utfall beror enbart på de två inmatade dimensionerna, inte på aggregatorns interna trösklar eller tillstånd. Det innebär att samtliga nio kombinationer kan enhetstestas oberoende av aggregator-instansiering, vilket gör mappningen auditerbar och oberoende av kalibrering. Den arkitekturella konsekvensen är att tröskelkalibrering enbart kan påverka dimensionsbestämningen i det fjärde steget, inte själva sensitivity-härledningen i det femte. Det är en designkonsekvens som diskuteras närmare i Sektion 7.1.4 i samband med observationen att aggregatorns trösklar är prestandaneutrala på fynd-nivå.

Tre konfigurerbara trösklar styr valideringen av kombinationsfynd. medium_threshold (default 0,7) anger lägsta konfidens för att ett context.kombination-fynd över huvud taget ska beaktas. high_confidence_bypass (default 0,85) är den konfidensnivå över vilken evidence-kravet kringgås. min_evidence_count (default 2) är det antal stödjande spans som krävs vid normal validering. Trösklarna är konstruktor-parametrar och kan justeras utan kodändring; defaultvärdena etablerades i designcykel 2 och behölls efter designcykel 3:s kalibreringsundersökning.

Aggregatorn körs som default i cross_validating-läge sedan designcykel 3. Skillnaden mot det tidigare legacy-läget ligger i evidensvägningspasset, som tillämpar en deklarativ beslutstabell på varje fynd och annoterar dess evidensgrund i ett evidence_basis-fält. Fältet kan anta tre värden: structural_support när fyndet stöds av minst två oberoende detektioner från Lager 1 eller Lager 2, high_confidence_no_support när fyndet passerar via hög-konfidens-bypassen utan strukturellt stöd, och no_support_required när stödkrav inte är arkitektoniskt tillämpligt (gäller artikel 9-fynd där Lager 3 är den enda möjliga producenten). Klassifikationsutfallet är byte-identiskt mellan de två lägena; skillnaden är att cross_validating-läget gör fail-safe-passagen explicit spårbar i utvärderingsdata och i intressentdemos. Den arkitekturella konsekvensen är en uppgradering av *Privacy by Design* från en tyst tröskelpassage till en granskbar evidensgrund, vilket adresserar GDPR artikel 5.2 om ansvarsskyldighet utan att ändra recall- eller precisionsbeteende.

Två arkitekturella val i dimensionsbestämningen förtjänar att lyftas separat eftersom de operationaliserar designfilosofin i konkret kod. Det första är att isolerade context.*-fynd från enskilda signaler, utan ett tillhörande aggregerat kombinationsfynd, inte höjer identifierbarhetsbedömningen på egen hand. Korrigeringen infördes efter designcykel 1:s utvärdering och bevarar context-prefixets semantik som markör för "inte personuppgift i sig, men relevant i kombination". Utan korrigeringen skulle ett ensamt organisationsnamn eller en isolerad yrkesangivelse höja sensitivity till LOW eller MEDIUM, vilket motsäger GDPR skäl 26:s logik om identifierbarhet genom kombination av uppgifter.

Det andra valet är att hög-konfidens-bypassen tillämpar *Privacy by Design* (Cavoukian 2009) , som föreskriver att personuppgifter skyddas automatiskt som standard, i linje med kravet på inbyggt dataskydd i GDPR artikel 25. Bypassen realiserar principen som en fail-safe-mekanism. Vid valideringsosäkerhet höjs identifierbarhetsbedömningen och sänks aldrig. Ett falskt negativt utgör ett allvarligare fel än ett falskt positivt eftersom det riskerar att missa en faktisk personuppgift. Bypassen är därmed inte en eftergift mot språkmodellens auktoritet, utan en mekanism för att säkerställa att artefakten inte kasserar ett potentiellt korrekt identifierbarhetsclaim på grund av att strukturellt stöd inte är arkitektoniskt tillgängligt. Sedan cross_validating-läget aktiverades som default är fyndets evidensgrund explicit annoterad via evidence_basis-fältet enligt resonemanget ovan, vilket gör att fail-safe-aktiveringen kan skiljas

från strukturellt verifierade fynd i utvärdering och rapportering. Principen formaliseras i DP1 i Sektion 8.1.

6.3.4 Klassificeringsobjektets dimensioner och deras härledning

Classification-klassens två domändimensioner är utformade utifrån en empirisk observation från designcykel 2:s naturalistiska utvärdering, där tre intressenter konvergerade kring att identifierbarhet och dataskyddsklass utgör två separata frågor (se Sektion 5.4.2 och Sektion 7.2.3). Observationen ledde till att klassificeringsobjektet utökades med två separata enum-fält i designcykel 3 (se Sektion 5.5.2).

Identifiability fanns ursprungligen i en fyra-nivåig form (NONE, LOW, MEDIUM, HIGH) men reducerades under cykeln till tre kategoriska nivåer: NONE, INDIRECT och DIRECT. Reduktionen motiverades av en empirisk observation att den fyra-nivåiga skalan blandade konfidens (hur säker artefakten är på fyndet) med kategori (hur direkt identifierande fyndet är), två semantiskt olika storheter. Den reducerade skalan binder identifiability strikt till kategori: DIRECT motsvarar ett artikel 4-fynd där en fysisk person pekas ut direkt, INDIRECT ett validerat context.kombination-fynd där pusselbitseffekten enligt skäl 26 aktualiseras, och NONE frånvaron av båda.

DataClass fanns ursprungligen i en fyra-nivåig form (NONE, ORDINARY, SPECIAL, CRIMINAL) men reducerades motsvarande till tre nivåer: NONE, SPECIAL och CRIMINAL. ORDINARY-nivån togs bort eftersom den i praktiken var en konsekvens av identifierbarhet utan känsligt material snarare än en självständig dataegenskap. CRIMINAL bibehölls som passiv strukturell markör för det framtida artikel 10-lagret i enlighet med Open-Closed-principen (Martin 2003), trots att ingen detektion av artikel 10-data är implementerad i v0.3.0.

Sensitivity är inte en självständig domändimension utan ett härlett värde från paret (identifiability, data_class). Separationen mellan de två juridiskt grundade dimensionerna och den härledda känslighetsnivån gör att den preciserade klassificeringen kan kommuniceras tillsammans med en pedagogisk sammanfattning utan att representationerna blandas ihop. Härledningsfunktionen och dess fullständiga tabell (Tabell 14) behandlas i Sektion 6.3.3.

Det tidigare mechanism_used-fältet på Classification togs bort i designcykel 3 eftersom klassifikationen nu kommuniceras helt av paret av identifiability och data_class. Information om vilken aggregator-mekanism som producerade ett kombinationsfynds validering bevaras istället i fyndlistans source-fält per Finding, vilket håller spårbarheten intakt utan att duplicera information på Classification-nivå.

6.3.5 Tillämpade arkitekturmönster

Fem av de mönster som introducerades i Sektion 4.2 är realiserade i systemet och formaliseras här som de kernel theories som motiverar designen. Tre av dem, *Layers*, *Pipes and Filters* och *Strategy*, strukturerar systemet på arkitekturnivå. *Composite* tillämpas lokalt i kombinationslagrets output, och spårbarhetsmönstret är tvärgående och realiseras genom hela fyndkedjan.

Layers-mönstret (Buschmann et al. 1996) ligger till grund för uppdelningen i fyra detektionslager där varje lager hanterar en distinkt detektionsmetodologi. Mönstret valdes framför en monolitisk klassificerare av två skäl. För det första utvecklas detektionsmetoder för

olika GDPR-kategorier i olika takt och med olika empiriskt underlag, vilket gör att en enhetlig implementation hade krävt simultan mognad i alla detektionsstrategier. För det andra är per-lager-utvärdering en förutsättning för det datadrivna förbättringsarbete som dokumenterats i Sektion 5.4.2. Båda skälen förutsätter en arkitekturell separation som tillåter lager att utvärderas isolerat, och Layers-mönstret är den standardlösning som realiserar separationen. Tillämpningen följer mönstrets uppdelning i distinkta abstraktionsnivåer, men inte dess strikta hierarki där ett lager betjänar lagret ovanför och delegerar nedåt. Detektionslagren körs i stället parallellt och oberoende, en organisation som hör till Pipes and Filters-mönstret. De två mönstren kompletterar därmed varandra: *Layers* motiverar uppdelningen i abstraktionsnivåer, Pipes and Filters dess parallella och ovetande exekvering.

Pipes and Filters-mönstret (Buschmann et al. 1996) realiseras i den parallella pipelinen där varje lager tar emot samma originaltext och producerar fynd oberoende av andra lager. Den parallella varianten skiljer sig från den klassiska sekventiella formen där varje filter tar föregående filters output som indata. Den parallella organisationen är ett medvetet val: eftersom lagrens fynd ska aggregeras snarare än propageras hade en sekventiell kedja inte tillfört något, men hade riskerat att fel i ett tidigt lager påverkar nedströms detektion. Den arkitekturella konsekvensen är att inget lager behöver känna till de andras existens, vilket bevarar separationen från Layers-mönstret också i runtime-flödet.

Strategy-mönstret (Gamma et al. 1994) realiseras genom Layer-protokollet och PatternLayers underliggande Recognizer-protokoll, som båda enkapsulerar en algoritmfamilj bakom ett gemensamt gränssnitt så att klienter kan växla mellan implementationer utan att ändra sin egen kod. Pipeline använder mönstret för att hantera fyra olika detektionslager som om de vore en enhetlig klass, och PatternLayer använder det internt för sina fem recognizers. Mönstret prövades i designcykel 2 genom två oberoende händelser. Det ursprungligen planerade Lager 3 delades till de två separata lagren Article9Layer och CombinationLayer utan att kringliggande kod behövde ändras, och CombinationLayer byttes vid en isoleringsövning av aggregatorlogiken ut mot en deterministisk teststubb som kunde delta i pipelinen utan att Pipeline eller Aggregator modifierades. Båda händelserna utgör arkitektonisk evidens för utbytbarhet och formaliseras i Sektion 8.2 som DP2.

Composite-mönstret (Gamma et al. 1994) tillämpas i CombinationLayers output. Det aggregerade context.kombination-fyndet uppträder mot aggregatorn som ett enskilt Finding-objekt men består semantiskt av flera underliggande signaler. Mönstret tillåter aggregatorn att hantera kombinationsfyndet enhetligt med övriga fynd utan att känna till dess sammansatta natur, samtidigt som de individuella signalerna bevaras i fyndlistan för spårbarhet. Den dubbla representationen är central för aggregatorns valideringskedja. Identifierbarhetsbedömningen lyfts baserat på det aggregerade fyndet men inte baserat på de individuella signalerna ensamma, vilket håller context-prefixets semantik intakt. Att aggregatorn väger lagrens fynd mot varandra i stället för att lita på ett enskilt lager vilar på samma logik som motiverar den lagerbaserade arkitekturen. Eftersom ingen enskild detektionsteknik räcker (Sektion 3.2), behandlas inte heller ett enskilt lagers utfall som tillräckligt i sig. Korsvalideringen är på så sätt konvergensargumentet uttryckt på aggregatornivå, där samstämmighet mellan oberoende detektionsmetoder stärker tilltron till ett fynd medan utebliven samstämmighet sänker den.

Spårbarhetsmönstret (Barbudo Carrasco 2025; Thaldar 2025) realiseras genom att varje klassificeringsbeslut kan följas bakåt från det slutliga Classification-objektet till det enskilda lager och den regel som producerade ett fynd. Varje Finding bär ett source-fält på formen lager.regel, en exakt textuell lokalisering via start, slut och textspann, samt en konfidens. Detta

utgör den metadata som Barbudo Carrasco (2025) beskriver, alltså dokumentation av fyndets ursprung. För det aggregerade kombinationsfyndet bevaras därutöver paradata i fyndets metadata: kombinationslagrets resonemang, hur det förutsagda spannet validerades mot originaltexten, och, via fältet evidence_basis, vilken av aggregatorns valideringsmekanismer som godkände fyndet. Spårbarheten är därmed inte en efterhandsloggning vid sidan av klassificeringen, utan inbäddad direkt i de objekt klassificeringen producerar, i linje med den integritetsbevarande spårbarhet Thaldar (2025) beskriver. Mönstret utgör artefaktens tekniska svar på GDPR:s princip om ansvarsskyldighet (artikel 5.2) och formaliseras i Sektion 8.5 som DP5.

7 Artefaktutvärdering

Detta kapitel utvärderar artefakten Aegis och besvarar studiens andra och tredje delfråga. Först redovisas den tekniska prestandan över de tre designcyklerna, mätt genom den artificiella utvärderingen, vilket besvarar delfrågan om artefaktens tekniska prestanda. Därefter redovisas verksamhetsrepresentanternas bedömning enligt FEDS-kriterierna nytta, ändamålsenlighet och organisatorisk passform, vilket besvarar delfrågan om hur artefaktens nytta, ändamålsenlighet och organisatoriska passform bedöms. De två utvärderingsformerna kompletterar varandra: den artificiella ger ett mått på teknisk tillförlitlighet som inte är öppet för efterhandstolkning, medan den naturalistiska fångar hur artefakten uppfattas i en organisatorisk kontext.

7.1 Teknisk prestanda

Detta avsnitt besvarar studiens andra delfråga om artefaktens tekniska prestanda och bygger på den artificiella utvärderingen som genomförts efter respektive designcykel. Mätningarna utgår från en konfusionsmatris på entitetsnivå enligt definitionerna i Sektion 2.5.2. Recall används som primärt mätvärde i enlighet med den fail-safe-orientering som vägleder artefakten: missad känslig data bedöms som en allvarligare felklassificering än överflaggning. Precision och F1 redovisas som sekundära mätvärden för att göra systemets benägenhet för överflaggning läsbar över designcyklerna. Det tekniska spåret är huvudsakligen summativt men bör läsas som indikativt snarare än definitivt, eftersom testkorpusens omfattning (159 texter i designcykel 2 och 3) gör enskilda per-kategori-utfall känsliga för enstaka fel.

7.1.1 Resultat över designcyklerna

Tabell 15 sammanfattar de aggregerade utfallen från respektive designcykels slutliga utvärderingskörning. För designcykel 2 och 3 är talen hämtade ur de versionerade snapshot-filer som producerats inför respektive naturalistisk utvärderingssession och är därmed reproducerbara mot specifika kommithashar i artefaktens utvecklingshistorik. Utfallet från designcykel 1 är dokumenterat i projektets utvecklingslogg och reproducerbart genom en live-körning av utvärderingen mot datasetet, eftersom den versionerade snapshot-rutinen infördes först i designcykel 2.

Cykel	Version	Dataset (antal texter)	TP	FP	FN	Precision	Recall	F1
1	v0.1.1	70	82	9	3	90,11 %	96,47 %	93,18 %
2	v0.2.0	159	208	117	25	64,00 %	89,27 %	74,55 %
3	v0.3.0	159	213	44	20	82,88 %	91,42 %	86,94 %

Tabell 15: Aggregerade utvärderingsresultat per designcykels slutliga snapshot.

Progressionen reflekterar pipelinens växande omfång snarare än en monoton förbättring av samtliga mätvärden. I designcykel 1 var endast Lager 1 och Lager 2 aktiva, vilket innebar att artefakten primärt arbetade mot strukturerade artikel 4-uppgifter där checksummevalideringen ger nära perfekt precision. När Lager 3 och Lager 4 introducerades i designcykel 2 fördubblades

testdatasetet och två LLM-baserade detektionsstrategier tillfördes, vilket förklarar precisionsfallet från 90 till 64 procent medan recall bibehölls. Designcykel 3:s riktade förbättringsarbete inom befintlig arkitektur återhämtade precisionen genom riktade åtgärder på pipeline- och aggregatornivå och ett modellbyte i Lager 3 och Lager 4 från qwen2.5:7b-instruct till qwen3:14b. Lyftet är precision-drivet och recall-bibehållande, konsistent med designprincipen att recall prioriteras över precision.

Lyftet i designcykel 3 fördelar sig på två separerbara interventioner. Med samma modell som i designcykel 2 (qwen2.5:7b-instruct) gav pipeline- och aggregatorarbetet en precision på 75,18 procent och en F1 på 82,33 procent, en ökning med 11,18 respektive 7,78 procentenheter. Det efterföljande bytet till qwen3:14b lyfte precisionen till 82,88 procent och F1 till 86,94 procent, ytterligare 7,70 respektive 4,61 procentenheter. Pipeline- och aggregatorarbetet står alltså för den större delen av lyftet medan modellbytet bidrar med ett substantiellt tillskott, en uppdelning som är direkt relevant för probe-frågan om i vilken grad prestandataket är modell- snarare än uppgiftsbundet.

Eftersom Lager 3 och Lager 4 anropar en språkmodell är pipelinens utfall inte strikt deterministiskt mellan körningar. En reproduktion av designcykel 2:s konfiguration på samma korpus gav dock identiska TP och FN och en skillnad på endast sex FP (117 mot 123) med oförändrad recall. Variationen mellan körningar är därmed liten i förhållande till de skillnader på tiotals FP som skiljer designcyklerna åt, vilket gör att en enskild snapshot är representativ för de slutsatser som dras här.

7.1.2 Per-lager-precisionsbidrag

Tabell 16 bryter ner designcykel 3:s utfall per detektionslager. Talen rapporteras på lager-nivå, vilket innebär att ett predikterat fynd attribueras till det lager som producerade det via source-fältet. Per-lager-recall är 100 procent eftersom recall mäts mot kategoriernas facit och varje kategori bara kan produceras av ett lager. Ett missat facit-fynd räknas som total FN för pipelinen, inte som FN på lager-nivå.

Lager	TP	FP	Precision
Lager 1 (PatternLayer)	68	0	100 %
Lager 2 (EntityLayer)	39	11	78,00 %
Lager 3 (Article9Layer)	38	3	92,68 %
Lager 4 (CombinationLayer)	68	30	69,39 %

Tabell 16: Per-lager-resultat för v0.3.0 (snapshot 2026-05-16).

En metodologisk reservation måste föras innan dessa tal tolkas som mått på lagrens fullständiga prestanda. Utvärderingsskriptets per-lager-mätning aggregerar TP och FP per lager via fyndens source-fält, men aggregerar inte motsvarande FN. Per-lager-recall blir därför strukturellt 100

procent (formellt definierad som TP genom TP plus noll) och per-lager-F1 är följaktligen helt precision-driven. Talen i tabellen återspeglar därmed lagrens precisionsbidrag, inte deras fullständiga diskriminationskraft. Mätinstrumentbegränsningen är dokumenterad som öppen punkt för framtida arbete.

En andra punkt rör hur Tabell 16 förhåller sig till per-kategori-noteringarna i Sektion 7.1.3. De två tabellerna delar upp samma 213 sanna positiva enligt olika nycklar. Per-lager-tabellen fördelar TP och FP efter fyndets source-fält, som anger vilket lager som producerade prediktionen, medan per-kategori-tabellen fördelar TP efter den förväntade kategorin i facit. En enskild träff kan därför hamna i rader som inte motsvarar varandra mellan de två tabellerna. Tydligast gäller det adresser. En adress som entitetslagret känner igen som platsentitet bär source-fältet entity.spacy_LOC och matchas via den aliasingregel som infördes i designcykel 3 (se Sektion 5.5.2) mot ett förväntat adressfynd. Träffen räknas som sann positiv under article4.adress i per-kategori-tabellen men under entitetslagret i per-lager-tabellen, och en adress som i stället fångas av en kombinationslagersignal bokförs under kombinationslagret. Per-lager-talen för entitets- och kombinationslagret rymmer därmed adressträffar som per-kategori-tabellen redovisar som artikel 4-data. Det följer av att per-lager-måttet fördelar fynd efter producerande lager och inte efter logisk GDPR-domän, och tabellen ska läsas i det ljuset.

PatternLayer producerar inga falska positiva alls, eftersom dess recognizers antingen kontrollsiffervaliderar (personnummer, IBAN, betalkort) eller arbetar mot format med låg matchningstvetydighet (e-post, telefonnummer). Article9Layers tre FP är en substantiell förbättring mot designcykel 2, där artikel 9-prompten triggade på vaga formuleringar och stod för en stor del av FP-volymen. EntityLayers elva FP fördelar sig på tre där personnamnsfiltret inte täcker, fyra där LOC-taggen ger context.plats i stället för article4.adress, och fyra där ORG-taggen ger context.organisation. CombinationLayer är den största FP-källan på lager-nivå, fördelad över de fyra kontextkategorierna enligt Sektion 7.1.3.

7.1.3 Per-kategori-noteringar

Tabell 17 redovisar utfallet per kategori för v0.3.0. Kategorin etniskt ursprung saknas i tabellen eftersom testkorpusen inte innehåller facit-fynd för den och qwen3:14b inte producerade någon prediktion i kategorin. Talen bör läsas mot kategoriernas storlek. Flera kategorier vilar på få facit-fynd, vilket gör att ett enskilt fel förskjuter precision eller recall med tiotals procentenheter. Per-kategori-siffrorna är därför indikativa snarare än stabila estimat, och tolkningen nedan vilar på riktningen i utfallet, inte på exakta procenttal.

Kategori	TP	FP	FN	Precision	Recall	F1
article4.adress	14	0	1	100,00 %	93,33 %	96,55 %
article4.betalkort	6	0	0	100,00 %	100,00 %	100,00 %
article4.email	19	0	0	100,00 %	100,00 %	100,00 %

article4.iban	10	0	1	100,00 %	90,91 %	95,24 %
article4.namn	32	3	1	91,43 %	96,97 %	94,12 %
article4.personnummer	18	0	0	100,00 %	100,00 %	100,00 %
article4.telefonnummer	15	0	0	100,00 %	100,00 %	100,00 %
article9.biometrisk_data	6	1	0	85,71 %	100,00 %	92,31 %
article9.fackmedlemskap	6	2	0	75,00 %	100,00 %	85,71 %
article9.genetisk_data	5	0	2	100,00 %	71,43 %	83,33 %
article9.halsodata	4	0	3	100,00 %	57,14 %	72,73 %
article9.politisk_asikt	5	0	1	100,00 %	83,33 %	90,91 %
article9.religios_overtygelse	6	0	0	100,00 %	100,00 %	100,00 %
article9.sexuell_laggning	6	0	0	100,00 %	100,00 %	100,00 %
context.kombination	8	6	1	57,14 %	88,89 %	69,57 %
context.organisation	21	9	6	70,00 %	77,78 %	73,68 %
context.plats	14	17	0	45,16 %	100,00 %	62,22 %
context.yrke	18	6	4	75,00 %	81,82 %	78,26 %

Tabell 17: Per-kategori-resultat för v0.3.0 (snapshot 2026-05-16). Kategorin article9.etniskt_ursprung saknar facit-fynd i testkorpusen (se Bilaga B.2) och ingår därför inte i tabellen.

På kategorinivå framträder en tydlig skiktning som följer detektionsstrategiernas natur. PatternLayer-kategorierna når full precision, och den enda recall-missen är ett IBAN-fynd som är korrekt mod97-validerat men har förskjuten formatering. Article4.namn bärs av det filter

som infördes i designcykel 2 för SpaCys tendens att klassificera enstaka förnamn utan efternamn som personnamn, och article4.adress lyfts av designcykel 3:s aliasingregel som matchar LOC-taggens context.plats mot förväntad article4.adress, en distinkt förbättring jämfört med designcykel 2 där adresskategorin var artikel 4:s svagaste på precision.

Inom artikel 9 speglar utfallet modellbytets effekter. Religiös övertygelse och sexuell läggning når full precision och recall efter modellbytet till qwen3:14b, mot designcykel 2 där sexuell läggning låg på 66,67 procents recall och religiös övertygelse på 83 procents F1. Politisk åskådning, biometriska data och fackmedlemskap ligger på full eller nära full recall med en mindre precisionskostnad. Hälsodata och genetisk data är de återstående svaga kategorierna. Båda har full precision men missar facit-fynd genom indirekta formuleringar som promptens few-shot-exempel inte fångar. Avsaknaden av facit-fynd för etniskt ursprung är en begränsning i datasetet snarare än i artefakten och adresseras i Sektion 7.1.4.

Kombinationskategorierna fördelar sig olika från artikel 9-mönstret. Context.plats är den enskilt största felkällan i v0.3.0 med sjutton falska positiva, 38,6 procent av samtliga FP i pipelinen. Merparten kommer från CombinationLayer, där modellbytet medförde en lokal regression där qwen3:14b överpredikterar vardagliga substantiv som platsangivelser i en utsträckning som qwen2.5:7b-instruct inte gjorde. De återstående fyra kommer från EntityLayers LOC-tagg och är inte modellberoende. CombinationLayer-andelen är dokumenterad i designcykel 3:s utvärdering som en genuin modellöverprediktion, inte ett matcher- eller facit-fel. Context.organisation och context.yrke är en blygsam förbättring mot designcykel 2:s utgångsläge, konsekvent med I-1:s skärpning av kombinationslagrets prompt. Context.kombination, det aggregerade pusselbitsfyndet, är fortsatt generöst i sin överproduktion men missar sällan genuina pusselbitsförekomster. Sammantaget är kombinationskategorierna fortfarande de svagaste delarna av pipelinen på precision-axeln, medan recall-prestandan bibehålls i linje med designcykel 1:s ursprungliga prioritering.

7.1.4 Kvarstående begränsningar

De per-kategori-utfallen pekar ut tre källor till mätbara begränsningar efter designcykel 3:s förbättringsarbete. Den största är context.plats-överproduktionen, sjutton FP eller 38,6 procent av samtliga, vars källfördelning och modellberoende behandlas i Sektion 7.1.3. Den andra är att context.organisation och context.yrke tillsammans står för femton FP, främst genom kombinationslagrets liberalitet i bedömningen av yrkes- och organisationsangivelser som identifierande pusselbitar. Den tredje är Article9Layers recall-gap för hälsodata och genetisk data, där indirekta formuleringar inte fångas av promptens few-shot-exempel. Varken designcykel 3:s promptexperiment, som bland annat riktade sig mot hälsodata och rullades tillbaka efter regression, eller modellbytet till qwen3:14b lyfte de två kategorierna. Att recall-gapet motstod både en prompt- och en modelländring pekar mot en uppgiftsbunden snarare än enbart prompt- eller modellbunden begränsning. En kompletterande observation rör testkorpusens täckning. Kategorin etniskt ursprung saknar facit-fynd i datasetet och kan därför inte prövas empiriskt, vilket är en lucka i utvärderingsunderlaget snarare än i artefakten, eftersom Article9Layers prompt täcker samtliga åtta artikel 9-kategorier inklusive etniskt ursprung (se Bilaga C).

Aggregatorns tre konfigurerbara trösklar (medium_threshold 0,7, high_confidence_bypass 0,85, min_evidence_count 2) ligger kvar på de defaultvärden som etablerades i designcykel 2. Designcykel 3 undersökte möjligheten att kalibrera dessa empiriskt mot V1:s precisionsriktmärke. Kalibreringen gav ett nullresultat. Samtliga prövade

tröskelkonfigurationer producerade identiska TP, FP och FN, och precisionen lyftes inte mot riktmärket. Förklaringen är arkitektonisk och behandlas i Sektion 5.5.2 och Sektion 6.3.3. Trösklarna styr Classification.identifiability nedströms, medan matchningen mot facit sker på finding-nivå innan aggregatorn kör. Avsnittet utgör därmed en arkitekturell observation snarare än en kvarvarande kalibreringsuppgift och refererades närmare i Sektion 5.5.2.

7.2 Verksamhetsrepresentanternas bedömning

Detta avsnitt besvarar studiens tredje delfråga om hur verksamhetsrepresentanter bedömer artefaktens nytta, ändamålsenlighet och organisatoriska passform. Analysen följer de tre utvärderingskriterier som lyfts fram i FEDS-ramverket (Venable, Pries-Heje & Baskerville 2016): nytta (är systemet användbart för intressentens behov?), ändamålsenlighet (fungerar systemet som avsett?) och organisatorisk passform (passar systemet in i intressentens verksamhet?). Materialet utgörs av de naturalistiska utvärderingssessionerna med V1, V2 och V4 efter respektive designcykel, totalt nio sessioner.

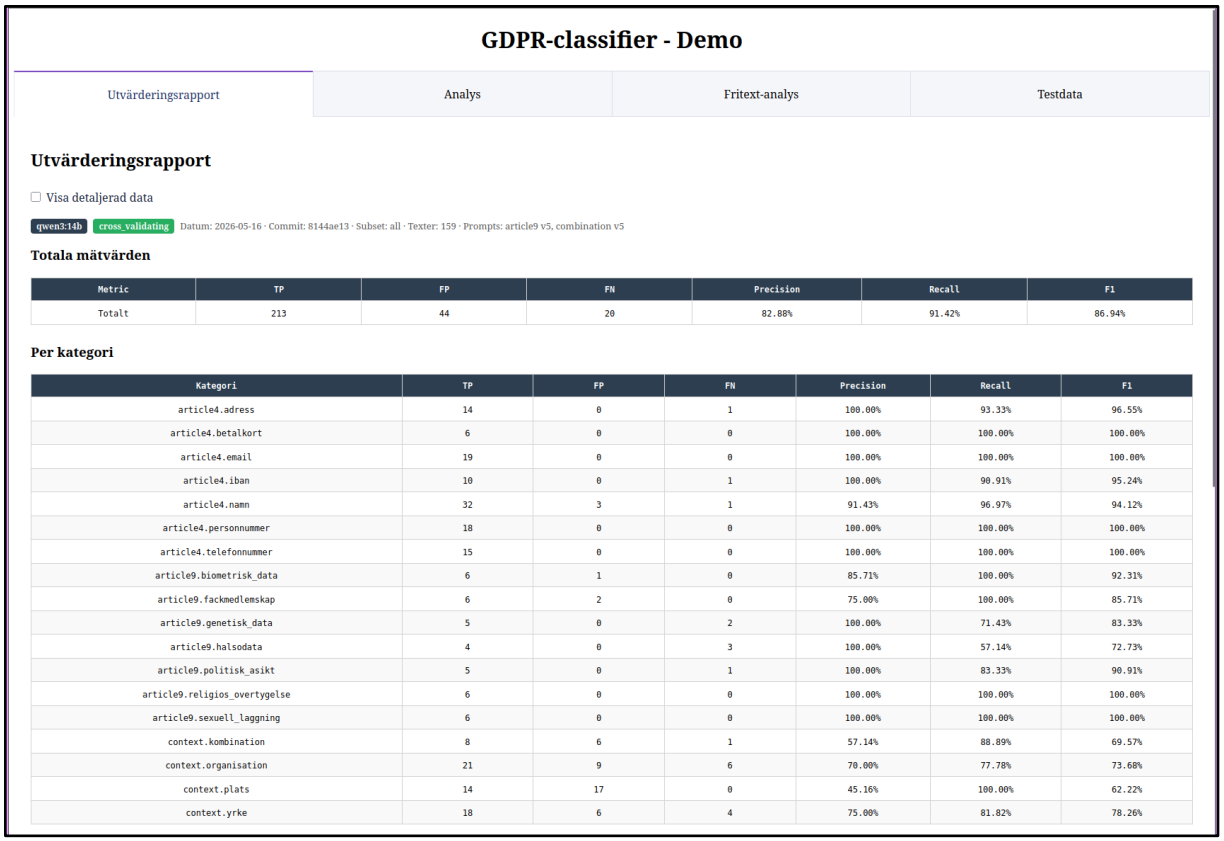
Analysen är strukturerad longitudinellt över de tre designcyklerna inom respektive FEDS-tema, snarare än separat per cykel. Det longitudinella perspektivet är konsistent med ADR:s fas reflektion och lärande (Sein et al. 2011) och låter läsaren följa hur intressentfeedbacken har format artefakten över studiens gång. Konvergens och divergens mellan de tre verksamheterna utgör de analytiska linserna: vad alla är överens om utgör råmaterial för designprinciperna i Sektion 8, vad de inte är överens om visar var organisatorisk kontext bestämmer utfallet.

En metodologisk anmärkning är på sin plats. Fyra verksamheter deltog i studien som helhet. Tre av dem (V1, V2 och V3) medverkade i problematiseringsfasen, medan V4 kom in från och med designcykel 1 (se Tabell 7 i Sektion 5.1). V3 återkom inte efter problematiseringsfasen, och V4 deltog i samtliga tre designcyklers utvärderingar. De tre verksamheter som genomförde alla utvärderingssessioner var därför V1, V2 och V4. Underlaget för kapitel 8 representerar därmed tre verksamheter: en privat IT-organisation, en privat IT-organisation i SME-segmentet, och en offentlig förvaltning. Skillnaderna i organisationstyp är värdefulla för analysen eftersom de möjliggör observationer om hur samma artefaktegenskap bedöms olika beroende på organisatorisk kontext.

7.2.1 Demonstrationsgränssnitt

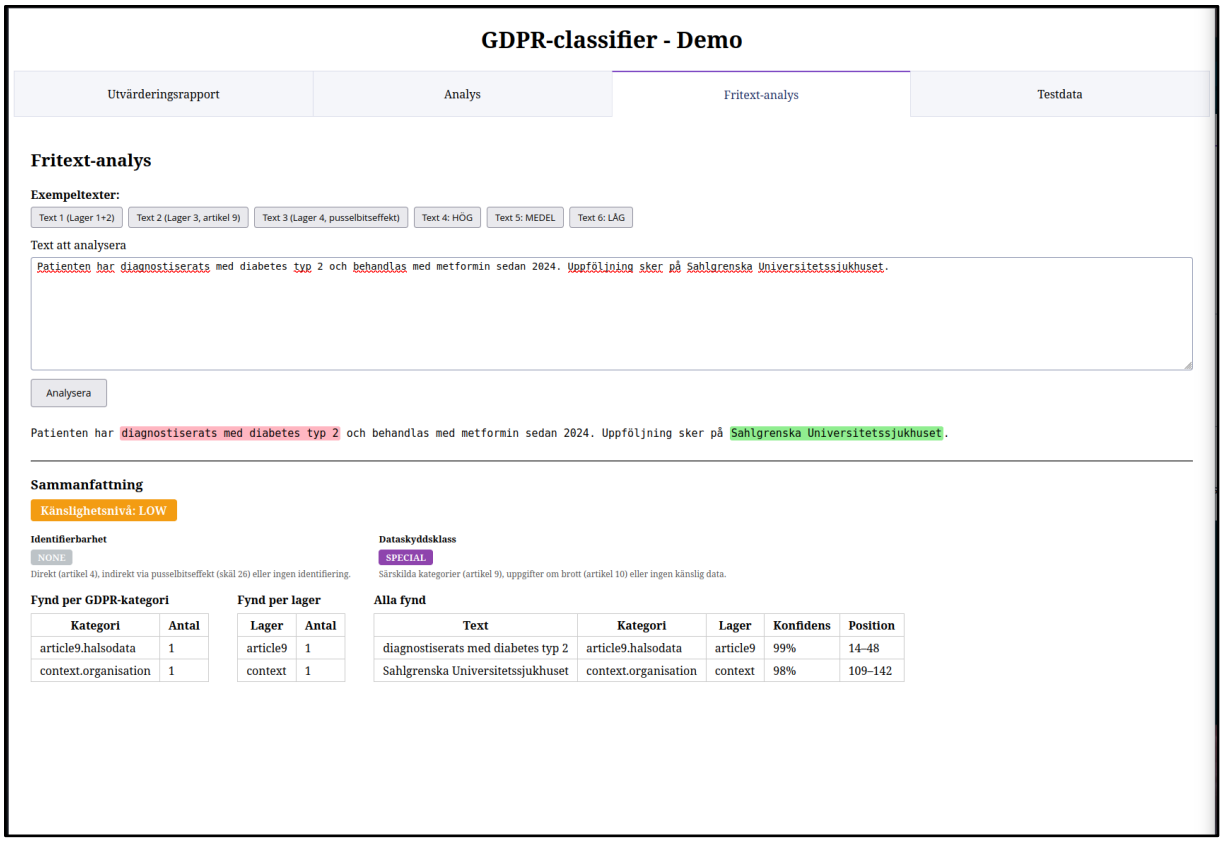
Den intressentbedömning som analyseras i de följande avsnitten har inhämtats genom demonstrationer av artefakten via ett dedikerat gränssnitt byggt i Dash. Gränssnittet är inte en del av klassificeraren som artefakt utan ett presentationsskikt som anropar samma pipeline-instans. Intressenterna har därmed bedömt klassificeraren genom gränssnittet, inte gränssnittet i sig, och den distinktionen avgränsar vad FEDS-analysen i Sektion 7.2.2 till 7.2.5 hanterar.

Gränssnittet består av två vyer. Rapportvyn visar utvärderingsresultaten från det förkalkylerade testdatasetet med konfusionsmatris och per-kategori-metriker (se Figur 7). Vyn bygger på ett versionerat snapshot för att undvika att en intressentsession ska behöva vänta in en full LLM-baserad utvärderingskörning. Det material som rapportvyn visualiserar är samma artificiella utvärderingsdata som analyseras kvantitativt i Sektion 7.1.



Figur 7: Rapportvyn i demonstrationsgränssnittet visar per-kategori-metriker från det förkalkylerade testdatasetet.

Fritextvyn klassificerar en intressent-inmatad text live mot pipelinen och visualiserar varje fynd med markering, kategori, lager och underliggande regel (se Figur 8). Varje markering är klickbar och avslöjar source-fältet som ligger bakom fyndet. Det är i fritextvyn som artefaktens spårbarhet realiseras i visuell form, och samma spårbarhetsegenskap återkommer i Sektion 8.5 när DP5 formaliseras. De texter som användes under demonstrationerna redovisas i Bilaga D.



Figur 8: Fritextvyn i demonstrationsgränssnittet klassificerar inmatad text i realtid mot pipelinen.

De två vyerna inbjuder till olika typer av intressentbedömning. Rapportvyn väcker frågor om aggregerad teknisk prestanda och har framför allt gett feedback som rör ändamålsenlighet, alltså recall, precision och felfördelning över kategorier. Fritextvyn med klickbara markeringar väcker frågor om hur ett enskilt klassificeringsbeslut kan motiveras och har framför allt gett feedback som rör nytta och organisatorisk passform, alltså granskningsbarhet och förtroende. Den medieskillnaden förklarar delvis tyngdpunkten i återkopplingen per tema, och utgör samtidigt en begränsning i demonstrationsupplägget, eftersom intressenternas bedömningar är formade av vilken vy som varit aktiv under respektive del av demonstrationen.

7.2.2 Nytta

Temat undersöker om artefakten är användbar för intressenternas faktiska behov.

Behovets reella förekomst

Utgångspunkten är problematiseringsfasen där samtliga tre verksamheter bekräftade behovet av att klassificera känslig data i ostrukturerad text, oavsett om den efterföljande hanteringen handlar om att styra vidare, maska eller flagga. Behovet har fortsatt bekräftats genom utvärderingarna i en mer specifik form. V1 beskrev under designcykel 2 audit-funktionalitet och spårbar härledning som "standardefterfrågan" hos kunder i system med granskningsmoment. V2 formulerade det som att "det är ändå det som är känsligt, det är ändå steg ett att hitta det".

Designcykel 3 bekräftade behovet ytterligare och gav det en konkret form. V1:s dataskyddsansvarige lyfte fritextfält i ett äldre verksamhetssystem som dagens anonymisering

inte når, vilket är ett av de mest konkreta enskilda användningsfallen i utvärderingsmaterialet. V2 och V4 bekräftade behovet men knöt det till förutsättningar: V2 betonade att artefaktens nytta står och faller med granskningsbördan, och V4 att systemet är användbart givet rätt användningsfall. Behovsbilden är därmed stabil över alla tre designcyklerna, medan frågan har förskjutits från om behovet finns till under vilka förutsättningar artefakten möter det.

Utökad känslighetsskala

Känslighetsskalan har bedömts av intressenterna genom två designcykler, och bedömningen beskriver en sammanhängande båge snarare än en serie fristående observationer. Designcykel 2 utökade skalan med en MEDIUM-nivå som triggas av kombinationslagrets aggregerade fynd. Ingen av de tre intressenterna avfärdade nivån som onödig, men de konceptualiserade den olika. V1 såg den som direkt operationaliserbar för konfiguration och prioritering: "för de här nivåerna så ignorerar vi false positives på nivå låg och medium, medans vi manuellt kollar på hög". V2 menade att personuppgifter alltid är känsliga, att variationen ligger i konsekvensen, och att pusselbitseffekten höjer allvarsgraden enbart genom kopplingen till någonting med konsekvens. V4 ifrågasatte etiketten och menade att en bedömning på MEDIUM säger något om identifierbarhet snarare än känslighet: "Det var därför jag reagerar lite när ni säger känslighetsnivå, för då förstår jag inte vilken vågskål vi tittar på". Den samlade signalen från designcykel 2 var att artefakten pressar samman två separata dimensioner, identifierbarhet och känslighet, i ett enda värde.

Designcykel 3 var artefaktens svar på den signalen. Klassificeringsobjektet utökades med två separata dimensioner, identifierbarhet och dataskyddsklass, och känslighetsnivån omdefinierades till ett härlett värde ur de två. Designcykel 3:s naturalistiska utvärdering kunde därför för första gången bedöma uppdelningen i praktiken. På den punkten är intressenterna entydiga. Alla tre bekräftade att separationen av identifierbarhet och dataskyddsklass fångar den distinktion de lyft i designcykel 2, och V4 var mest uttrycklig om att de två blir tydligare när de visas var för sig. V2 omsatte uppdelningen i ett konkret nyttovärde och beskrev den som ett underlag för triagering, alltså för att lägga de säkra fallen åt sidan och rikta mänsklig granskningstid mot de osäkra.

Designcykel 3 tillförde samtidigt en ny invändning, och den riktar sig inte mot uppdelningen utan mot den härledda känslighetsnivån som väger samman de två dimensionerna till en skala. Kritiken är konvergent och pekar särskilt på LOW-nivån. V1:s mjukvaruarkitekt påpekade att information som inte kan kopplas till en person faller utanför GDPR helt, och att kombinationen ingen identifierbarhet och särskild kategori därför inte hör hemma på samma härledda nivå som personuppgifter utan känsligt innehåll. V2 gjorde samma invändning och föreslog en egen icke-GDPR-kategori i stället för att överbelasta LOW. V4 pekade på att de kategorier som hamnar på LOW har olika rättslig karaktär, och att ett brottsrelaterat fall utan funnen identifierbarhet kan behöva manuell granskning trots LOW-klassificeringen. Ingen av de tre efterfrågade fler nivåer. V1:s mjukvaruarkitekt varnade tvärtom för att fler härledda nivåer gör beslutet svårare, och V4 föreslog att den härledda skalan tas bort till förmån för en visuell representation av de två dimensionerna.

Bedömningen över de två cyklerna ger därmed ett tudelat resultat för nyttan. Uppdelningen i två dimensioner är en förbättring som intressenterna bekräftar och som V2 kan omsätta i ett konkret granskningsarbetsflöde. Den sammanvägda känslighetsnivån ovanpå de två dimensionerna drar däremot åt andra hållet, eftersom den återinför just den hopslagning som uppdelningen var avsedd att lösa. Det är en observation på problemklassens nivå och utgör en del av det empiriska underlaget för DP6.

Motiveringstexten och spårbarheten
Designcykel 2 introducerade att kombinationsfynd presenteras med en motivering som visar vilka signaler som ingår i bedömningen. Bedömningen var konvergent. Alla tre bekräftade att motiveringen har värde för mänsklig granskning men inte räcker för automatiserat beslutsfattande. V1 strukturerade analysen tydligast genom att skilja på två användarkontexter: "Det är inte bara att du sitter och granskar sådan här data, det betyder inte nödvändigtvis att du är expert på regelverken, och det är där som modellen kan komma in och hjälpa dig". V2 lyfte att det som saknas för autonomt agerande är "relevans och konsekvenser". V4 nyanserade efter textlängd och menade att visuell markering räcker för korta texter medan längre texter kräver anpassad presentation.

Utvärderingen i designcykel 3 bekräftade att motiveringen fortfarande har värde men flyttade tyngdpunkten från dess innehåll till dess presentation. V1:s mjukvaruarkitekt gav ett kontextberoende svar: i ett automatiserat flöde som bearbetar data behöver motiveringen inte vara utförlig, men som mellanlager, exempelvis innan ett dokument sparas, är utförligheten det som låter användaren veta vad som ska åtgärdas. V1 tillförde också en arkitekturell synpunkt med bäring på DP5, att motiveringen bör loggas i en separat datakälla snarare än lagras tillsammans med den bearbetade texten. V2 bekräftade värdet men återförde bedömningen till presentationen och menade att reasoning-fältet som hovertext är otydligt för en icke-teknisk användare och behöver ett presentationslager som översätter det. V4 menade att motiveringen fortfarande är viktig, möjligen i en förändrad roll, och föreslog att den visas som en beskrivning direkt under identifierbarhetsvärdet i stället för enbart vid hover.

Bedömningen över de tre designcyklerna bekräftar designvalet att exponera systemets resonemang och utgör den empiriska rationale-komponenten i DP5 om spårbar härledning av klassificeringsbeslut. Den lägger samtidigt en gräns. Redan designcykel 2 visade att spårbarheten ska stödja en mänsklig granskare snarare än ersätta granskningen, och designcykel 3 skärper gränsen ytterligare: motiveringen och spårbarheten är nödvändiga men inte tillräckliga som användarstöd, utan förutsätter antingen en läsare som kan värdera dem eller ett presentationslager som översätter dem. Det är en observation som problematiserar DP5 i dess nuvarande form.

7.2.3 Ändamålsenlighet

Temat undersöker om artefakten faktiskt lyckas med det den är avsedd att göra, bedömt genom intressenternas perspektiv snarare än genom de kvantitativa mätvärdena som redovisats i Sektion 7.1.

Identifieringsförmåga
Bedömningen av systemets generella förmåga är konvergent men nyanserad. Samtliga bekräftar att artefakten gör rätt saker och att riktningen är korrekt. Den viktigaste samstämmiga observationen efter designcykel 2 är att pusselbitseffekten lyfts av samtliga som det viktigaste tillägget sedan designcykel 1. Det bekräftade i efterhand beslutet att tidigarelägga kombinationslagret, sedan den naturalistiska utvärderingen i designcykel 1 pekat ut pusselbitseffekten som artefaktens centrala tekniska lucka.

Inom konvergensen finns en gradering som korrelerar med organisationstyp. V1 ger den mest positiva bedömningen efter designcykel 2: "nu när ni har pusselbitseffekten så får du ju en mycket högre nivå av förmåga att identifiera en person". V2 är mer försiktig och betonar att

fynden "kan vara väldigt viktiga" men att pusslet är "nyckeln att knäcka". V4 är mest reserverad men inte avvisande på de tekniska måtten. Hen bedömde att systemet "gör rätt saker" och att recall och precision var "ganska bra", och förlade sin reservation till om pusselbitsproblemet låter sig lösas inom studiens ram (se Sektion 5.4).

Skillnaden i bedömningston korrelerar med organisationskontext. V1 (mjukvaruarkitekt i privat IT- och logistikorganisation) bedömer artefakten på dess egna villkor. V4 (AI-strateg i offentlig förvaltning) bedömer mot integrationskrav i en specifik infrastruktur. V2 (informationssäkerhetskonsult i SME) ligger däremellan. Korrelationen är inte ett problem utan en observation om att samma artefakt bedöms från olika perspektiv beroende på organisatorisk kontext.

Designcykel 3:s utvärdering visade en mer samlad bild. Samtliga tre intressenter uppfattade en tydlig förbättring sedan designcykel 2 och bekräftade att ingen regression skett. Den gradering som korrelerade med organisationstyp jämnades därmed delvis ut, eftersom alla tre var positiva till utvecklingen. V4, som var mest reserverad i designcykel 2, beskrev den sammanställda presentationen som mer lättläst, även om hen inte kunde peka ut exakt vad som gav effekten. V2 bedömde utvecklingen som tydligt positiv men formulerade om sin bedömning till ett designförslag, att paketera artefakten i två versioner där den första hanterar det säkra artikel 4-materialet och en senare version tar sig an pusselbitslagret och artikel 9, där osäkerheten sitter. Den utvärderande linsen skiljer sig fortfarande åt mellan verksamheterna, men i designcykel 3 riktas den mot presentation och paketering snarare än mot grundförmågan. Den upplevda förbättringen kommer av designcykel 3:s pipelineförbättringar och modellbyte; den tröskelkalibrering som cykeln också undersökte gav ett nullresultat och påverkade inte mätvärdena.

Kombinationslogiken och pusselbitseffekten
Kombinationsbedömningen är designcykel 2:s primära artefaktbidrag och förtjänar djupare behandling. Konvergensen är tydlig. Alla tre bekräftar att kombinationslogiken är meningsfull och att exemplet illustrerar ett verkligt problem. Alla erkänner samtidigt att systemet ännu inte kan avgöra binärt om en person faktiskt är identifierbar.

Divergensen är konceptuellt informativ. De tre konceptualiserar pusselbitseffekten olika. V1 ser det som specificitet kontra känslighet och föreslår att specificitet bör visas som en separat dimension bredvid känslighet. V4 ser det som identifierbarhet kontra känslighet och invänder mot att de två blandas i en enda skala: "Jag ser liksom som tvåstegsraket: ett, kan vi förstå vem personen är ... och sen har vi det andra som är information om dens data, är den känslig på något sätt". V2 ser det som sannolikhet gånger konsekvens: "Det är inte förrän du sätter den i kombination med någonting annat. Däremot, det är ju den pusselbitseffekten som är det sårbara egentligen".

Alla tre landar i att kombinationen är avgörande, men placerar den i olika konceptuella ramverk. Den konceptuella divergensen är inte ett implementationsproblem utan en designfråga om vilken dimension klassificeringen mäter.

Designcykel 3 hanterade frågan genom en designändring. Den konceptuella divergensen operationaliserades genom att klassificeringsobjektet delades upp i två separata dimensioner, identifierbarhet och dataskyddsklass. Designcykel 3:s naturalistiska utvärdering bekräftade att uppdelningen fångar den distinktion de tre lyft, och V4 var mest uttrycklig om att de två dimensionerna blir tydligare när de visas var för sig. Själva kombinationsdetektionen, att en

pusselbitsbedömning sker i ett eget lager, ifrågasattes inte av någon. Den invändning som kvarstår i designcykel 3 riktar sig inte mot detektionen utan mot hur klassificeringsutfallet representeras, närmare bestämt mot den härledda känslighetsnivån som väger samman de två dimensionerna. Den invändningen behandlas under temat nytta och i formuleringen av DP6. Detektion och representation är därmed konceptuellt åtskilda: kombinationslogiken bekräftas som en fråga om ändamålsenlighet, medan representationsfrågan förblir öppen.

Precision kontra recall
Designcykel 2 introducerade en arkitekturellt motiverad sänkning av precision (från cirka 90 procent i designcykel 1 till runt 64 procent efter precisionsförbättringsspåret) som följde av att lagerstacken utökades med språkmodellsbaserade detektionslager. Recall bibehölls. Bedömningen är konvergent: samtliga bekräftar att recall är viktigare än precision i artefaktens användningskontext.

Divergensen ligger i var den acceptabla precisionsgränsen går. V1 ger ett konkret kvantitativt riktmärke: "Någonstans runt 80 skulle jag säga nog, brytpunkten går, för vad som skulle vara acceptabelt". V2 formulerar asymmetrin i kostnadstermer: "False positives blir ju en kostnad ... Men det är nog ännu värre om den skulle säga att någonting är OK som inte är OK. Den måste ju träffa rätt". V4 reducerar resonemanget till sin enklaste form: "Det är ju ett större problem att missa helt, för då får man ju ändå gå igenom hela texten".

I designcykel 3 höjdes precisionen från 64,0 till 82,9 procent samtidigt som recall bibehölls, vilket innebär att V1:s riktmärke om cirka 80 procent nåddes. Lyftet kom av cykelns fyra pipelineförbättringar och bytet av lokal språkmodell, inte av den tröskelkalibrering som också prövades och som gav ett nullresultat. Intressenternas bedömning av utfallet var inte enhetlig. V1 besvarade inte frågan som ett fast tröskelvärde utan som något användningsberoende: vid en bekräftelsedialog innan en text skickas vidare räcker en lägre precision eftersom beslutet ändå fattas manuellt, medan ett system som bearbetar data utan mänsklig mellanhand kräver högre. V1:s dataskyddsansvarige tillade att recall vid permanent långtidslagring i praktiken måste ligga nära 100 procent, eftersom den juridiska risken ligger i att behålla data som inte får behållas. V4 bedömde att artefakten ligger på rätt sida av gränsen men efterlyste mer transparens kring hur säker en enskild bedömning är, särskilt för indirekt identifierbarhet. För V2 ställdes precisionsfrågan aldrig i den form intervjuguiden angav, eftersom demonstrationen inleddes med uppgiften att precisionen ligger över 80 procent och V2 inte ombads validera den brytpunkten. Någon V2-bedömning av 80-procentsnivån finns därför inte från designcykel 3. Sammantaget bekräftar designcykel 3 prioriteringsriktningen, recall före precision, medan frågan om exakt var den acceptabla precisionsgränsen går förblir användningsberoende snarare än ett fast tal.

Bedömningen utgör den empiriska rationale-komponenten i DP1 (recall-prioritering som fail-safe). Den bekräftar att designvalet att prioritera recall är förankrat i intressenternas faktiska behov, inte enbart i Privacy by Design-principen (Cavoukian 2009) eller i den anonymiseringslitteratur som motiverar att recall väger tyngre (Pilán et al. 2022).

7.2.4 Organisatorisk passform

Temat undersöker om artefakten passar in i intressenternas verksamheter, både infrastrukturellt och i arbetsflödet. Temat innehåller den tydligaste konvergensen i hela utvärderingsmaterialet, framför allt kring lokal exekvering, men designcykel 3 breddade det med frågor om driftskala och om vilken användarroll artefakten är avsedd för.

Lokal språkmodellexekvering
Designcykel 2 introducerade lokal exekvering av Article9Layer och CombinationLayer via Ollama. Bedömningen är enhälligt positiv. Samtliga svarade entydigt att lokal drift är att föredra, utan reservationer. Konvergens av denna styrka är ovanlig i kvalitativ data och förtjänar att betonas analytiskt.

Motiveringarna skiljer sig i ton men inte i riktning. V1 lyfter risken med leverantörsändringar: "En leverantör säger att ja, men vi gör all vår processing i EU. Men sen ändrar de sina terms of service utan att du kanske märker det, och helt plötsligt så kör de datan i Asien". V2 pekar på spårbarhetsbristen hos molnleverantörer: "Om vi skickar upp till en molnlösning så har inte vi koll på hårdvaran ... och då helt plötsligt så blir det helt andra spårbarhetssyften". V4 svarar kortast och pekar på att deras organisation redan har ett on-prem-beräkningskluster som de hade använt.

Skillnaden i motivering är substantiell. Samma designval motiveras från tre olika perspektiv: juridisk risk (V1), säkerhetstekniskt resonemang (V2), och infrastrukturell pragmatism (V4). Att samma val har stöd från flera perspektiv ökar generaliserbarheten av principen och utgör en av de starkaste empiriska grunderna för DP3 (lokal språkmodellexekvering med utbytbar provider).

Designcykel 3 bekräftade preferensen för lokal drift men preciserade vad "lokal" innebär. Frågan om driftskala visade att ingen av intressenterna såg framför sig en installation på slutanvändarnas klienter. V1 beskrev att ett sådant system skulle köras på verksamhetens serverinfrastruktur, och skilde mellan verksamhetstyper: en organisation av deras egen typ har serverkapacitet, medan mindre verksamheter och offentlig förvaltning oftare har eftersatt hårdvara på klientsidan, vilket gör modellvalet till en annan fråga för dem. V2 tog tydligt avstånd från edge computing och installation på varje dator, både av resursskäl och för att varje installation blir en sårbarhetsyta som måste versionshanteras, och förordade drift i en virtuell miljö. V2 tillförde också en observation som tidigare inte fångats: eftersom de flesta mejlkorgar redan ligger på server eller i molnet är det där artefakten behöver fungera, inte på lokal klienthårdvara. Designcykel 3 förskjuter därmed innebörden av lokal exekvering från lokal hårdvara till organisationsintern kontroll, vilket är en precisering snarare än en revidering av det empiriska underlaget för DP3.

Modelluppgraderingen till den större lokala språkmodellen bedömdes som operativt hanterbar. V1 menade att den extra beräkningskostnaden är lätt att rättfärdiga givet precisionssiffrorna, och att skillnaden mellan den mindre och den större modellen i praktiken avgör om systemet är användbart i ett automatiseringssammanhang, men påpekade att ett modellval kräver ett referensfall att utgå från. V4 bekräftade att den egna organisationen redan har en lokal AI-plattform inom sin infrastruktur, och att den operativa avvägningen handlar om var modellen körs, på central infrastruktur snarare än på enskilda arbetsstationer. För V2 ställdes modellfrågan inte separat, eftersom den gick upp i resonemanget om resurser och kapacitet.

Saknade designaspekter
Frågan om vad systemet missar gav distinkt olika feedback från de tre intressenterna i designcykel 2, vilket är värdefullt eftersom det pekar ut tre olika utvecklingsspår snarare än ett gemensamt. V1 föreslår specificitet som separat visad dimension och konstruerar en beslutsmatris kring den. V2 lyfter konsekvensanalys som den saknade komponenten och kopplar tillbaka till sin riskanalysmodell. V4 rekommenderar pragmatisk avgränsning av

pusselbitsproblemet och testning med större modell via API för att separera modellegenskaper från uppgiftens svårighet.

Designcykel 3 förhöll sig till de tre spåren på olika sätt. V1:s förslag om att visa specificitet som en separat dimension operationaliserades genom uppdelningen av klassificeringsobjektet i identifierbarhet och dataskyddsklass, och är därmed det spår som mest direkt omsattes i artefakten. V4:s rekommendation att pröva pusselbitsproblemet med en större modell följdes genom jämförelsen mot en större molnbaserad modell (Claude Opus 4.7, se Sektion 5.5), som låg endast marginellt över qwen3:14b och därmed visade att artefaktens prestandatak ligger nära den lokala modellens kapacitet. V2:s spår, en uttrycklig konsekvensanalys, byggdes inte som en egen komponent. Dataskyddsklass-axeln fångar delvis det V2 beskrev som konsekvens, men en självständig riskvägning av sannolikhet mot konsekvens ligger utanför artefaktens nuvarande omfattning och hör till framtida arbete.

Designcykel 3 lyfte samtidigt en aspekt som de två tidigare cyklerna inte hade ställt på sin spets, nämligen vilken användarroll artefakten är avsedd för. Frågan om hur en slutanvändare utan djup GDPR-kompetens ska kunna värdera systemets utfall gav den tydligaste konvergensen i designcykel 3:s material gällande organisatorisk passform. Samtliga tre menade att rollen avgör risken. Specialiserade roller inom exempelvis vård och HR förväntas ha kompetensen och uppfatta utfallet som ett förslag, medan risken ligger hos generalistroller som kundtjänst, där tidspress kan leda till att utfallet behandlas som facit. V4 bekräftade risken för automation bias direkt och menade att lösningen kräver både en designdel och en utbildningsdel, konkret en utförlig beskrivning och ett konfidensvärde så att systemet inte framstår som en svart låda. V2 placerade ansvaret för GDPR-kompetens utanför artefakten, hos den verksamhetsansvariga, och såg lösningen i ett presentationslager som översätter utfallet samt i tydliga förbehåll. Aspekten är ett organisatoriskt fit-villkor snarare än en teknisk brist, och den problematiserar DP5 genom att visa att spårbarhet och motivering är nödvändiga men inte tillräckliga som användarstöd.

På den avslutande frågan om intressenterna skulle kunna tänka sig att använda systemet gav ingen av de tre ett rakt ja eller nej. V1 lyfte att verksamhetens data till stor del är strukturerad och redan har lösningar, och att det som saknas för ett beslut är statistik över tids- och maskinkostnad vid storskalig genomsökning. V2 bedömde att det avgörande är resurser, särskilt den fysiska granskningsbördan, och att för många falska positiva blir en arbetsmiljöbelastning. Slutomdömet var att artefakten är en god grund att bygga vidare på, uttryckligen en prototyp och inte en produkt. V4 menade att systemet med rätt användningsfall går att använda, och att det som saknas inte är kärnfunktionen utan inramningen, alltså hur varje enskild bedömning presenteras för en användare. Sammantaget bekräftar designcykel 3 att artefakten passar in i den infrastrukturella kravbilden men att den organisatoriska passformen i arbetsflödet förutsätter ett tydligare svar på vem som ska använda utfallet och hur det presenteras.

7.2.5 Syntes

De tre föregående underavsnitten visar att artefakten möter ett reellt organisatoriskt behov (nytta), lyckas med det den är tekniskt avsedd att göra (ändamålsenlighet), och passar in i den infrastrukturella kravbilden för verksamheter med GDPR-prioritet (organisatorisk passform). Intressenternas bedömningar utgör tillsammans med den arkitekturella analysen det empiriska underlaget för de designprinciper som formaliseras i Sektion 8.

Det empiriska underlagets styrka varierar mellan principerna. DP3 om lokal språkmodellexekvering har den starkaste stängningen, genom enhällig konvergens från

samtliga tre intressenter över alla tre designcyklerna, och designcykel 3 preciserade dessutom dess innebörd från lokal hårdvara till organisationsintern kontroll. DP1 om recall-prioritering har solid stängning genom konvergens i prioriteringsriktningen; designcykel 3 visade att divergensen inte gäller riktningen utan var den acceptabla precisionsgränsen går, och att den gränsen är användningsberoende snarare än ett fast tal. DP2 om utbytbarhet bekräftas inte av intressentmaterialet utan av arkitekturella händelser, vilket är förväntat för en princip vars validering ligger i kodbasen; designcykel 3:s modellbyte, som genomfördes utan ingrepp i pipeline eller lager, är ytterligare ett sådant fall. DP4 om tvåstegsdetektion av kombinatorisk identifierbarhet har konvergent stöd för att kombinationslogiken är meningsfull, och designcykel 3 bekräftade detektionen samtidigt som frågan om hur utfallet ska representeras fördes över till DP6. DP5 om spårbar härledning och DP6 om tvådimensionell representation behandlas separat nedan, eftersom designcykel 3 påverkade dem mer än de övriga.

Designcykel 3:s utvärdering motbevisade ingen princip. För DP1, DP2, DP3 och DP4 bekräftade och preciserade den i huvudsak det mönster som designcykel 1 och 2 hade etablerat. Två principer skärptes däremot på ett sätt som går utöver bekräftelse. DP6 fick sin kärna bekräftad, eftersom samtliga tre intressenter bekräftade att uppdelningen i identifierbarhet och dataskyddsklass fångar den distinktion de lyft i designcykel 2, men samma utvärdering riktade konvergent kritik mot den härledda känslighetsnivån som väger samman de två dimensionerna. DP6:s tvådimensionella kärna är därmed empiriskt stängd medan dess derivatkomponent är ifrågasatt. DP5 problematiserades på ett liknande sätt. Spårbarhet och motivering bekräftades som värdefulla men bedömdes samstämmigt som nödvändiga men inte tillräckliga som användarstöd, vilket pekar mot att principens rationale behöver omfatta ett presentationslager och organisatorisk kompetens. Designcykel 3:s bidrag till det empiriska underlaget är därför inte främst nya bekräftelser utan två preciseringar på problemklassens nivå, och båda förs vidare till formuleringen av DP5 och DP6.

8 Designprinciper

Detta avsnitt besvarar studiens fjärde delfråga om vilka designprinciper som kan formuleras för en IT-artefakt som klassificerar textinnehåll utifrån GDPR:s känslighetskategorier. Principerna är studiens kunskapsbidrag i den mening som Sein et al. (2011) beskriver som *Generalized Outcomes*: de abstraherar de situerade lärdomarna från BIE-cyklerna till lösningskoncept som kan tillämpas i andra projekt inom samma problemklass.

Härledningen av principerna vilar på de tre underlagskällor som anges i Sektion 2.5.4. Den arkitekturella analysen i Sektion 6.3 har identifierat de mönster och mekanismer som strukturerar artefakten och utgör principernas mekanismkomponent. Loggbokens dokumenterade designbeslut bidrar med den teoretiska motiveringen, alltså förankringen i kernel theory och GDPR. Den empiriska analysen i Sektion 7.2 har identifierat de intressentbedömningar som motiverar varför dessa val är värdefulla i den organisatoriska kontexten. Sammanfogningen sker här genom Gregor, Chandra Kruse och Seidels (2020) *Design Principle Schema*, som tillhandahåller en explicit struktur för att förena mekanism och rationale i en preskriptiv formulering.

Av de arkitekturella val och empiriska observationer som dokumenterats i studien har sex principer bedömts ha tillräcklig empirisk stängning för att formaliseras. Urvalet har baserats på två kriterier: principerna ska ha teoretisk förankring i etablerad kernel theory eller juridisk text, och de ska ha empirisk förankring antingen genom intressenternas utvärderingsutsagor eller genom arkitekturella händelser under utvecklingen. Principer vars rationale enbart vilar på teoretisk argumentation utan empirisk stängning har utelämnats, liksom principer som främst utgör mekanismer underordnade någon av de sex. Dessa underordnade mekanismer är dokumenterade som designbeslut under studiens gång och kan formaliseras i framtida arbete om empiriskt material motiverar det.

Principerna presenteras i en ordning som följer artefaktens logiska konstruktion. DP1 anger den övergripande designfilosofin om recall-prioritering. DP2 specificerar det arkitekturella ramverket genom utbytbarhet via lagerprotokollet. DP3 hanterar det viktigaste organisatoriska kravet om lokal exekvering. DP4 beskriver designcykel 2:s tekniska huvudbidrag om kombinatorisk identifierbarhet. DP5 binder ihop principerna genom kravet på spårbarhet som genomsyrar samtliga lager. DP6 formaliserar designcykel 3:s mest substantiella konstruktionsbidrag genom tvådimensionell representation av juridisk klassificering.

8.1 Designprincip 1: Design för recall-prioritering som fail-safe

DP1 formaliserar artefaktens designfilosofi om att missad känslig data utgör ett allvarligare fel än överflaggning. Principen är inte ett teknikval utan ett metriskt åtagande som styr samtliga underordnade designbeslut. Tabell 18 sammanfattar principen enligt Gregor, Chandra Kruse och Seidels (2020) schema.

Struktur	**Komponenter**
Syfte, implementerare och användare	Utvecklare (implementerare) konstruerar en klassificerare som maximerar identifieringen av potentiellt känsligt innehåll (syfte), till nytta för dataskyddsansvariga och informationssäkerhetsroller i en personuppgiftsansvarig

Struktur	Komponenter
	organisation (användare).
Kontext	GDPR-reglerad behandling av ostrukturerad text där missad känslig data utgör potentiellt lagbrott och överflaggning utgör en hanterbar administrativ kostnad.
Mekanismer, Aktörer	(M1) Recall som primärt mätvärde i kvantitativ utvärdering, med precision som sekundärt mätvärde med definierad acceptanströskel. (M2) Tolerant span-matchning vid utvärdering och konservativ tröskelhantering vid klassificeringsosäkerhet. Aktörer: utvecklaren vid tröskelkalibrering, klassificeringspipelinen vid drift.
Motivering	Asymmetrisk kostnad mellan falska negativa och falska positiva (Pilán et al. 2022). Operationaliserar GDPR artikel 25 om dataskydd som standard (Cavoukian 2009). Empiriskt bekräftad av samtliga tre intressenter: V1 angav cirka 80 procents precision som acceptabel undre gräns, V2 beskrev falska negativa som värre än falska positiva eftersom systemet måste träffa rätt, V4 formulerade det som att en granskning av flaggade träffar är hanterbar medan en missad text kräver fullständig genomläsning.

Tabell 18: Designprincip för recall-prioritering som fail-safe

Principen har styrt konkreta designval under designcyklerna. Ett tydligt exempel är att precisionsförbättringsspåret i designcykel 2 avslutades efter omgång 3, eftersom ytterligare optimering bedömdes ge avtagande avkastning och riskerade att sänka recall. Samma princip styr aggregatorns hantering av valideringsosäkerhet, där sensitivity höjs och aldrig sänks vid otydliga fynd. På iterationsnivå är samma logik synlig som ett återkommande mönster: vid varje arkitekturförändring som tillfört nya detektionslager har lägre precision accepterats för att bevara recall, varefter precisionen har återhämtats genom riktat förbättringsarbete med recall-baslinjen som hårdvillkor.

8.2 Designprincip 2: Design för utbytbarhet via smalt lagerprotokoll

DP2 formaliserar artefaktens arkitekturella grundprincip om att detektionslager ska kunna ersättas eller utökas utan att omkringliggande pipeline och aggregator behöver ändras. Principen följer av *Layers*-, *Pipes and Filters*- och *Strategy*-mönstren som beskrevs i Sektion 6.3.5 men sträcker sig längre genom att precisera vilka egenskaper protokollet ska ha för att utbytbarheten ska realiseras i praktiken. Tabell 19 sammanfattar principen enligt Gregor, Chandra Kruse och Seidels (2020) schema.

Struktur	Komponenter
Syfte, implementerare och användare	Utvecklare (implementerare) bygger detektionskomponenter som kan ersättas eller utökas utan

Struktur	Komponenter
	att ändra omkringliggande pipeline eller aggregator (syfte) till nytta för andra utvecklare som vidareutvecklar systemet (användare).
Kontext	En flerstegspipeline där detektionsmetoder utvecklas i olika takt och där forskningsartefakten förväntas vidareutvecklas över flera designcykler.
Mekanismer, Aktörer	(M1) Lagerprotokoll med smal kontaktyta i form av detect(text) -> list[Finding] plus name: str. (M2) Source-fält i varje Finding som identifierar producerande lager och regel, vilket gör fyndets ursprung explicit i aggregatorn och utvärderingen. (M3) Kombinationslogik och valideringsmekanismer placeras i aggregatorn snarare än i lagren, vilket håller lagrens ansvar avgränsat. Aktörer: pipeline, aggregator, tester.
Motivering	Pipes and Filters-mönstret (Buschmann et al. 1996). Strategy-mönstret (Gamma et al. 1994). *Single Responsibility Principle* (Martin 2003). Empiriskt demonstrerad i två oberoende fall under designcykel 2: uppdelningen av det ursprungligen planerade Lager 3 till Article9Layer och CombinationLayer utan ändringar i Pipeline eller Aggregator, samt stubb-substitutionen där en deterministisk stubb byttes in för CombinationLayer utan friktion i konsumerande komponenter.

Tabell 19: Designprincip för utbytbarhet via smalt lagerprotokoll

Principens praktiska bärighet visade sig i två arkitekturella händelser under designcykel 2. När det ursprungligen planerade Lager 3 delades upp i Article9Layer och CombinationLayer enligt *Single Responsibility Principle* krävdes inga ändringar i Pipeline eller Aggregator, eftersom båda nya lagren följde det befintliga protokollet och kunde pluggas in utan friktion. I ett separat substitutionsexperiment byttes CombinationLayer ut mot en deterministisk stubb som matchade mot en hårdkodad ordlista. Pipeline körde igenom utan modifikation och Aggregatorn behandlade stubbens fynd identiskt med originallagrets. Att samma protokoll bär både utbyggnad av ett nytt lager och utbyte mot en alternativ implementation är vad principen kräver.

Skillnaden mellan DP2 och de underliggande arkitekturmönstren ligger i preskriptionen. Mönstren beskriver en återkommande lösning på ett återkommande problem, medan DP2 anger vad en designer av en liknande artefakt ska göra för att uppnå utbytbarhet i den specifika kontexten av GDPR-klassificering. Den empiriska valideringen av DP2 ligger därför i kodbasens utveckling snarare än i intressentmaterialet, vilket är förväntat för en princip som handlar om interna arkitekturegenskaper snarare än användarupplevda kvaliteter.

Den praktiska konsekvensen är att artefakten är öppen för anpassning utan ändringar i pipeline eller aggregator. Ett befintligt lager kan ersättas med en variant som är bättre kalibrerad för en specifik domäns terminologi, och nya lager kan adderas för GDPR-kategorier som ligger utanför nuvarande scope, exempelvis ett artikel 10-lager för brottmålsuppgifter.

8.3 Designprincip 3: Design för lokal språkmodellexekvering med utbytbar provider

DP3 formaliserar det organisatoriska krav som visade sig vara mest entydigt i intressentmaterialet. Samtliga tre intressenter föredrog lokal drift utan reservationer, vilket är anmärkningsvärt eftersom triangulering är avsedd att pröva konsistens snarare än att förutsätta att källorna ger samma bild (Patton 1999). Principen är artefaktens tydligaste exempel på att en arkitekturell konstruktion (LLMProvider-abstraktionen) realiserar ett krav som inte enbart är tekniskt utan dataskyddsrättsligt. Tabell 20 sammanfattar principen enligt Gregor, Chandra Kruse och Seidels (2020) schema.

Struktur	**Komponenter**
Syfte, implementerare och användare	Utvecklare (implementerare) tillåter analys av känslig text utan tredjelandsöverföring (syfte) till nytta för dataskyddsansvariga i organisationer med strikt suveränitetskrav (användare).
Kontext	Organisationer som omfattas av GDPR och som av juridiska, tillsynsmässiga eller policymässiga skäl inte kan eller vill skicka känsliga texter till molnbaserade AI-tjänster utanför EU.
Mekanismer, Aktörer	(M1) LLMProvider-abstraktion med lokal Ollama-exekvering som primär provider. (M2) Konfigurerbar växling till molnprovider för utveckling och test, dokumenterad som icke-produktion. (M3) Strukturerad prompt-konstruktion enligt etablerad metod (Brown et al. 2020; Wei et al. 2022; Liu et al. 2023; He et al. 2024). Aktörer: LLMProvider-implementationer, lokal hårdvara, alternativt extern API-tjänst i utvecklingsmiljö.
Motivering	GDPR artikel 44 och 46 om tredjelandsöverföring. Karras et al. (2025) dokumenterar GDPR-implikationer av molnbaserad LLM-exekvering. Mishra, Pagare & Sharma (2025) visar att lokala modeller är konkurrenskraftiga på klassificering kombinerat med span-extraktion. Empiriskt stöd: samtliga tre intressenter föredrog lokal drift utan reservationer. V1 lyfte risken att leverantörer ändrar terms of service och flyttar processing utanför EU. V2 pekade på bristen på spårbarhet hos molnleverantörer. V4 hade redan etablerat ett on-prem-beräkningskluster, vilket gjorde lokal exekvering till en infrastrukturellt naturlig lösning.

Tabell 20: Designprincip för lokal språkmodellexekvering med utbytbar provider

Den enhälliga konvergensen i intressentmaterialet motiverades dock från tre olika perspektiv: juridisk risk (V1), säkerhetstekniskt resonemang (V2) och infrastrukturell pragmatism (V4). Att samma designval har stöd från flera distinkta perspektiv är en form av

perspektivtriangulering (Patton 1999) och ökar generaliserbarheten av principen. DP3 är därmed inte enbart relevant för organisationer som delar exakt samma organisatoriska kontext som de tre samarbetsverksamheterna utan kan rimligen tillämpas i en bredare klass av GDPR-reglerade organisationer.

8.4 Designprincip 4: Design för tvåstegsdetektion av kombinatorisk identifierbarhet

DP4 formaliserar designcykel 2:s tekniska huvudbidrag: att kombinatorisk identifierbarhet, det vill säga pusselbitseffekten i GDPR skäl 26, ska detekteras i ett eget arkitekturellt skikt snarare än härledas i efterhand. Principen följer av att enskilt icke-identifierande signaler kan peka ut en specifik person när de förekommer tillsammans, vilket var den centrala saknade funktionen i designcykel 1 och motiverade beslutet att tidigarelägga kombinationslagret till designcykel 2. Tabell 21 sammanfattar principen enligt Gregor, Chandra Kruse och Seidels (2020) schema.

Struktur	**Komponenter**
Syfte, implementerare och användare	Utvecklare (implementerare) detekterar identifierbarhet via kombinationer av enskilt icke-identifierande signaler (syfte) till nytta för organisationer som behandlar texter där indirekt identifiering är vanligare än direkt (användare).
Kontext	Texter där ingen enskild uppgift är en personuppgift i artikel 4-mening men där flera uppgifter som var för sig inte identifierar någon tillsammans kan peka ut en specifik person, i enlighet med GDPR skäl 26. De kombinationer som prövats i studien utgörs av yrke, organisation och plats, men principen avser kombinatorisk identifierbarhet generellt och är inte bunden till just de signaltyperna.
Mekanismer, Aktörer	(M1) CombinationLayer producerar individuella signal-fynd och ett aggregerat kombinationsfynd. (M2) Aggregatorn validerar kombinationsfyndet genom att kräva strukturellt stöd från minst två fynd i Lager 1 eller Lager 2 vars spans överlappar med kombinationsfyndets span. (M3) En hög-konfidens-bypass tillåter att evidenskravet kringgås när lagrets egen konfidens överstiger tröskeln, i enlighet med fail-safe-principen som formaliseras i DP1. Aktörer: CombinationLayer, aggregator.
Motivering	GDPR skäl 26 om bedömning av identifierbarhet. CombinationLayer exponeras mot pipelinen via samma Layer-protokoll som övriga lager, vilket är den Strategy-instans (Gamma et al. 1994) som DP2 vilar på, medan valideringssteget och hög-konfidens-bypassen tillämpar den fail-safe-logik som DP1 formaliserar. Empiriskt stöd: pusselbitseffekten lyftes av samtliga tre intressenter i designcykel 1 som den centrala saknade funktionen, vilket motiverade beslutet att tidigarelägga kombinationslagret till

Struktur	Komponenter
	designcykel 2. Designcykel 2:s naturalistiska utvärdering bekräftade designens relevans: V1 beskrev pusselbitslagret som den avgörande förbättringen sedan designcykel 1, V2 betonade att kombinationen är det sårbara, V4 erkände problemets reella förekomst i offentlig förvaltning.

Tabell 21: Designprincip för tvåstegsdetektion av kombinatorisk identifierbarhet

Intressenternas konceptualisering av kombinationsbedömningen divergerade trots konvergensen kring att kombinationen är avgörande, och de tre verksamheterna ramade in distinktionen från var sin begreppsapparat (se Sektion 7.2.3). Divergensen är en designfråga om hur klassificeringen ska representeras, inte ett tecken på att principen i sig är felaktig. DP4 formaliserar det som faktiskt finns konvergens om: att kombinatorisk identifierbarhet ska detekteras i ett eget lager med tvåstegsmekanik av aggregerat fynd plus validering. Frågan om hur klassificeringsutfallet sedan ska representeras adresseras separat i DP6, eftersom detektion och representation utgör konceptuellt distinkta designval.

8.5 Designprincip 5: Design för spårbar härledning av klassificeringsbeslut

DP5 formaliserar den GDPR-specifika principen att varje klassificeringsbeslut ska kunna härledas till de specifika lager, regler och fynd som producerade det. Principen är den mest juridiskt förankrade av de sex och utgör samtidigt den arkitekturella ryggraden som binder ihop övriga principer. Utan spårbarhet skulle utbytbarhet (DP2), kombinationsbedömning (DP4) och fail-safe-logik (DP1) bli oprövbara. Tabell 22 sammanfattar principen enligt Gregor, Chandra Kruse och Seidels (2020) schema.

Struktur	Komponenter
Syfte, implementerare och användare	Utvecklare (implementerare) konstruerar systemet så att varje klassificeringsbeslut kan härledas till de specifika lager, regler och fynd som producerade det (syfte) till nytta för granskare, revisorer och dataskyddsansvariga (användare).
Kontext	GDPR-efterlevnadssammanhang där artikel 5.2 ställer krav på ansvarsskyldighet (accountability) och organisationer behöver kunna motivera klassificeringsbeslut i revisioner och inför tillsynsmyndighet.
Mekanismer, Aktörer	(M1) Source-fält per Finding som identifierar producerande lager och regel. (M2) Evidence_basis-fält per Finding som anger om fyndet får påverka dimensionsbestämningen via strukturellt stöd, hög konfidens utan stöd, eller inte kräver stöd alls. (M3) Bevarande av samtliga fynd i Classification.findings, inklusive överlappande och kontextuella fynd som inte triggar sensitivity-höjning

Struktur	Komponenter
	ensamma, så att granskaren ser systemets fullständiga underlag. (M4) Ett presentationsskikt exponerar härledningen från fynd via mekanismer till klassificeringsutfall för granskaren. Demonstrationsgränssnittet är en sådan realisering. Aktörer: detektionslagren, aggregatorn och presentationsskiktet.
Motivering	GDPR artikel 5.2 om ansvarsskyldighet. Barbudo Carrasco (2025) om metadata för dataursprung i AI-system. Thaldar (2025) om inbäddad spårbarhet. Empiriskt stöd: V1 angav att motiverings- och audit-funktionalitet är "standardefterfrågan" hos kunder i system med granskningsmoment. Samtliga tre intressenter bekräftade att motiveringen i sin nuvarande form har värde för mänsklig granskning men inte räcker för automatiserat beslutsfattande, vilket bekräftar att spårbarheten ska stödja en granskare snarare än ersätta granskningen.

Tabell 22: Designprincip för spårbar härledning av klassificeringsbeslut

Intressenternas samstämmiga bedömning att spårbarhet inte räcker för autonomt agerande utan kräver mänsklig granskning är en viktig avgränsning av DP5. Principen säger att klassificeringen ska vara spårbar, inte att klassificeringen ska vara autonomt verkställbar. Den distinktionen kan tyckas subtil men är väsentlig för hur artefakten positionerar sig i en granskningsprocess.

V1 nyanserade spårbarhetens funktion genom att skilja mellan två granskarkontexter, där granskaren antingen är dataskyddsexpert eller domänexpert. Spårbarheten fyller olika roller i de två fallen: för dataskyddsexperten fungerar den som verifikationsstöd, för domänexperten som regelverkspedagogik. Designcykel 3:s naturalistiska utvärdering följde upp den observationen och visade att rollskillnaden ställer krav på hur spårbarheten presenteras. V2 påpekade att motiveringen som hovertext är otydlig för en icke-teknisk användare och behöver ett presentationsskikt som översätter den, och V4 föreslog att motiveringen visas som en beskrivning direkt under identifierbarhetsvärdet snarare än enbart vid hover. V1 tillförde en arkitekturell synpunkt och menade att motiveringen bör loggas i en separat datakälla snarare än lagras tillsammans med den bearbetade texten. Intressenternas bedömning redovisas i sin helhet i Sektion 7.2.2.

Designcykel 3:s utfall preciserar DP5:s räckvidd. Den preskriptiva kärnan står fast. Varje klassificeringsbeslut ska kunna härledas till de lager, regler och fynd som producerade det, och mekanismerna M1 till M3 levererar den spårbarheten på artefaktnivå. Vad designcykel 3 lade till är att spårbarhetsdatan i sig är nödvändig men inte tillräcklig som användarstöd. Det räcker inte att spårbarheten finns i klassificeringsobjektet, den måste också nå den avsedda granskaren i en form som rollen kan använda, och för en generalistroll utan dataskyddskompetens är ett översättande presentationsskikt en förutsättning snarare än en bekvämlighet. Principens rationale omfattar därför också presentationen av spårbarheten, inte enbart dess existens. Hur

det presentationsskiktet bäst utformas ligger utanför detta arbetes scope och hör till framtida arbete.

8.6 Designprincip 6: Design för tvådimensionell representation av juridisk klassificering

DP6 formaliserar designcykel 3:s centrala konstruktionsbidrag: att klassificering enligt GDPR ska representeras som ett par av kategoriska dimensioner (identifierbarhet och dataskyddsklass) snarare än som en sammanvägd känslighetsskala, med en härledd känslighetsnivå som UI-abstraktion ovanpå de två dimensionerna. Principen växte fram ur designcykel 2:s naturalistiska utvärdering där tre intressenter med olika fackbakgrund konvergerade kring observationen att de två dimensionerna är juridiskt och operativt distinkta. Tabell 23 sammanfattar principen enligt Gregor, Chandra Kruse och Seidels (2020) schema.

Struktur	**Komponenter**
Syfte, implementerare och användare	Utvecklare (implementerare) representerar klassificeringsresultatet som ett par av separata kategoriska dimensioner för identifierbarhet och dataskyddsklass (syfte), till nytta för dataskyddsansvariga som behöver kunna agera olika beroende på vilken juridisk grund som aktualiseras (användare).
Kontext	GDPR-reglerad klassificering där artikel 4 (direkt identifiering), skäl 26 (indirekt identifiering), artikel 9 (särskilda kategorier) och artikel 10 (uppgifter om lagöverträdelser) utgör juridiskt distinkta kategoriska tillstånd snarare än punkter på en glidskala, och där en endimensionell känslighetsskala kollapsar denna distinktion till ett enda värde.
Mekanismer, Aktörer	(M1) Två separata enum-fält på klassificeringsobjektet med kategoriska värden som speglar lagtextens distinktioner: Identifiability {NONE, INDIRECT, DIRECT} och DataClass {NONE, SPECIAL, CRIMINAL}. (M2) Aggregatorlogik som mappar artikel 4-fynd till DIRECT, validerade kombinationsfynd till INDIRECT och artikel 9-fynd till SPECIAL, där DIRECT prioriteras över INDIRECT vid samtidig förekomst. (M3) Ren modulnivåfunktion derive_sensitivity(identifiability, data_class) -> SensitivityLevel som mappar paret till en härledd känslighetsnivå via en deterministisk tabell (se Sektion 6.3.4), total över de nio kombinationerna och monoton i båda dimensionerna. (M4) Sensitivity bevaras som UI-abstraktion för konfigurerbar granskningsprioritering snarare än som självständig domändimension. Aktörer: aggregator, klassificeringsobjekt, derive_sensitivity-funktionen, granskande personal.

Struktur	Komponenter
Motivering	GDPR artikel 4, skäl 26, artikel 9 och artikel 10 är kategoriska distinktioner i lagtexten, inte glidskalor. GDPR artikel 83.4 och 83.5 motiverar reservationen av HIGH-utfall för direkt identifierat artikel 9- eller artikel 10-material. Privacy by Design (Cavoukian 2009), som dataskyddsförordningens artikel 25 lagfäster, operationaliseras strukturellt genom härledningstabellens fail-safe-celler där anonym text om känsliga kategorier flaggas LOW snarare än NONE. Empiriskt stöd: tre intressenter med olika fackbakgrund konvergerade i designcykel 2:s naturalistiska utvärdering kring att identifierbarhet och känslighet är två separata frågor. V1 formulerade distinktionen som specificitet kontra känslighet, V4 som identifierbarhet kontra känslighet, V2 som sannolikhet gånger konsekvens inom en riskanalysram. Konvergensen från tre olika begreppsapparater är empirisk evidens för att distinktionen är en egenskap hos problemklassen snarare än en lokal preferens.

Tabell 23: Designprincip för tvådimensionell representation av juridisk klassificering

Principens kategoriska struktur är inte godtycklig utan följer av att GDPR:s juridiska konstruktion arbetar med distinkta tillstånd. Artikel 4 definierar direkt identifiering, skäl 26 indirekt identifiering, artikel 9 särskilda kategorier och artikel 10 uppgifter om lagöverträdelser. Att modellera dessa som kvantitativa skalor (LOW, MEDIUM, HIGH för identifierbarhet) blandar konfidens (hur säker artefakten är) med kategori (vilket juridiskt tillstånd som föreligger), två semantiskt olika storheter. Den kategoriska modellen är en empirisk lärdom från designcykel 3, där den ursprungliga fyra-nivåiga formen reducerades till tre kategoriska nivåer per dimension (se Sektion 6.3.4).

Härledningstabellen är konstruerad för att uppfylla fyra bindande krav samtidigt: trohet mot GDPR:s kategoriska struktur, monotonicitet (sensitivity ökar icke-strikt med båda dimensionerna), juridisk reservation av HIGH för material som kräver mest granskning enligt artikel 83.4 och 83.5, och fail-safe-konsekvens där anonym text om känsliga kategorier flaggas för granskning utan att överskrida den juridiska klassifikationen. Att en enda derivatfunktion samtidigt uppfyller fyra olika krav från olika källor (juridisk struktur, presentationslogik, sanktionsstruktur, dataskyddsprincip) är ett konkret exempel på det Gregor och Jones (2007) beskriver som integrationen av principer för form och funktion: form (paret av enums) och funktion (granskningsprioritering) realiseras genom samma arkitekturella mekanism. Härledningstabellens fyra konstruktionskrav rör dess interna konsistens. Huruvida en härledd skala över huvud taget bör läggas ovanpå de två dimensionerna är en separat fråga, och den prövades först i designcykel 3:s naturalistiska utvärdering.

Designcykel 3:s naturalistiska utvärdering bekräftade principens kärna och problematiserade dess derivatkomponent. Samtliga tre intressenter bekräftade att uppdelningen i identifierbarhet och dataskyddsklass fångar den distinktion de lyft i designcykel 2, vilket ger den tvådimensionella representationen stöd i naturalistisk utvärdering och inte enbart i designcykel

2:s observation. Samma utvärdering riktade däremot konvergent kritik mot den härledda känslighetsnivån, särskilt LOW-nivån, där intressenterna invände att kategorier med olika rättslig karaktär hamnar på samma nivå. Ingen efterfrågade fler nivåer, och V4 föreslog att den härledda skalan tas bort till förmån för en visuell representation av de två dimensionerna. Intressenternas bedömning redovisas i sin helhet i Sektion 7.2.2.

Designcykel 3:s utfall preciserar vad DP6 förbinder sig till. Principens preskriptiva kärna är att klassificeringen ska representeras som två separata kategoriska dimensioner som hålls isär och visas var för sig, eftersom en sammanvägning av dem återinför just den hopslagning som intressenterna invände mot. Den härledda känslighetsnivån är en mekanism, M3 och M4, en presentationsbekvämlighet för konfigurerbar granskningsprioritering, och inte en del av den preskriptiva kärnan. Designcykel 3 bekräftade kärnan men lämnade derivatkomponenten omdiskuterad. En artefakt som realiserar DP6 är därför fri att utelämna den härledda skalan helt, i linje med V4:s förslag, så länge de två dimensionerna hålls åtskilda och synliga. Hur en sammanfattande nivå bäst härleds, eller om den bör härledas alls, är en öppen designfråga som detta arbete inte avgör.

9 Diskussion och slutsatser

Studiens syfte var att generera designkunskap om hur svensk fritext automatiskt kan identifieras och klassificeras enligt GDPR:s känslighetskategorier, ett syfte som forskningsfrågan konkretiserade som frågan om hur en IT-artefakt kan designas för ändamålet. Forskningsfrågan delades i fyra delfrågor, och var och en har behandlats i ett eget kapitel. Den tekniska prestandan (delfråga 2) och verksamhetsrepresentanternas bedömning enligt FEDS-kriterierna (delfråga 3) redovisades i kapitel 7, den arkitekturella lösningen (delfråga 1) i kapitel 6 och designprinciperna (delfråga 4) i kapitel 8. Det här kapitlet härleder inte delfrågornas svar på nytt utan tolkar de samlade resultaten, alltså vad de betyder i relation till tidigare forskning, vilket kunskapsbidrag de utgör och var deras giltighet är begränsad.

Kapitlet inleds med en tolkning av resultaten mot den forskning som litteraturgenomgången identifierade. Därefter redogörs för studiens artefaktuella, teoretiska och empiriska bidrag och för vad de innebär för praktiker, för forskare och ur ett etiskt och hållbarhetsmässigt perspektiv. Sedan reflekteras hur den valda forskningsansatsen bar studien i praktiken, och studiens trovärdighet bedöms mot etablerade kvalitetskriterier. Kapitlet behandlar därefter studiens begränsningar och förslag på fortsatt forskning, och avslutas med de slutsatser som besvarar forskningsfrågan.

9.1 Resultaten i relation till tidigare forskning

Litteraturgenomgången identifierade tre begränsningar i tidigare arbete, nämligen att de studier som tar GDPR:s juridiska kategorier på allvar är bundna till specifika dokumenttyper, att hybridarkitekturernas lagerindelning inte motiveras av förordningens juridiska struktur, och att det saknas formaliserade designprinciper för problemklassen. Det här avsnittet diskuterar hur studiens resultat förhåller sig till de tre begränsningarna och till fältet i övrigt.

Den första begränsningen gällde räckvidd. Tidigare arbeten som hanterar GDPR:s kategorier arbetar på avgränsade dokumenttyper, Pilán et al. (2022) på engelska rättsfall, Lorè et al. (2023) på italienska myndighetsdokument och Löbner et al. (2025) på CV:n i Europass-format. Aegis konstruerades och utvärderades i stället på generell organisatorisk fritext, alltså mejl, chattmeddelanden och interna dokument utan fast struktur. Resultatet visar att en lagerbaserad arkitektur bär även i den mindre förutsägbara textdomänen, men inte utan kostnad. Mishra, Pagare & Sharma (2025) rapporterar en precision på 94,7 procent på ett syntetiskt dataset som efterliknar finansiella dokument, medan Aegis efter designcykel 3 låg på knappt 83 procent. Skillnaden ska inte läsas som att Aegis presterar sämre i absolut mening, utan som att en bredare och mindre strukturerad textdomän ger ett svårare klassificeringsproblem. Recall, som studien prioriterar, låg över 89 procent i samtliga tre designcykler. Aegis bekräftar därmed att den hybrida lagerarkitekturen generaliserar bortom de avgränsade dokumenttyper där den tidigare prövats, och preciserar samtidigt vad den generaliseringen kostar i precision.

Den andra begränsningen gällde arkitekturens juridiska motivering. Litteraturen visar samstämmigt att kombinationen av regelbaserad detektion och NER fungerar tekniskt, men ingen av de granskade studierna lät GDPR:s struktur bestämma lagerindelningen. Aegis utgår från den distinktionen. Lager 1 och 2 hanterar artikel 4-data, som har en deterministisk och strukturerad form, medan Lager 3 hanterar artikel 9-data, som förekommer implicit och kontextuellt och kräver semantisk analys. Den artificiella utvärderingens per-lager-resultat ger empiriskt stöd för att uppdelningen motsvarar en verklig skillnad i svårighetsgrad, där det regelbaserade mönsterlagret når den högsta precisionen, medan det kombinationslager som gör

den mest tolkande bedömningen bär flest falska positiva. Lager 4, som detekterar pusselbitseffekten enligt skäl 26, isolerar dessutom en bedömning som tidigare arbeten antingen utelämnar eller väver in i den allmänna detektionen. Studiens arkitektur tillför därför inget tekniskt nytt, eftersom hybridpipelines redan är etablerade. Bidraget ligger i att ge en etablerad teknik den juridiska motivering som litteraturen hittills saknat.

Ett av de tydligaste empiriska resultaten rör valet av lokal språkmodell. Karras et al. (2025) dokumenterar de dataskyddsrättsliga implikationerna av molnbaserad språkmodellexekvering, vilket utgör ett argument för lokal exekvering. Designcykel 3:s jämförelse mot en större molnbaserad modell ger ett konkret datapunkt till den bilden. Molnmodellen låg endast marginellt över den lokala qwen3:14b, vilket innebär att lokal exekvering i den här uppgiften inte medför någon påtaglig prestandakostnad. Det stärker det dataskyddsrättsliga argumentet för lokal drift, eftersom suveränitetskravet kan tillgodoses utan en mätbar precisionsförlust. Samtidigt bekräftar arbetet Karras et al. (2025) observation att språkmodeller hallucinerar och därigenom urholkar tilliten till automatiserade system. Hallucinerade signaler förekom i kombinationslagret och hanterades genom att de loggas och hoppas över i stället för att avbryta klassificeringen, en strukturerad hantering snarare än ett antagande om att modellen alltid producerar välformad utdata.

Spårbarheten i Aegis ansluter till en forskningslinje utanför den rent tekniska detektionslitteraturen. Barbudo Carrasco (2025) och Thaldar (2025) behandlar dokumentation av dataursprung som en förutsättning för granskningsbarhet och regelefterlevnad. Aegis operationaliserar det genom ett source-fält i varje fynd som anger producerande lager och regel. Den naturalistiska utvärderingen lade däremot till något som den litteraturen inte fångar. Barbudo Carrasco och Thaldar argumenterar för att spårbarhet möjliggör ansvarsskyldighet, men intressenterna i studien visade att spårbarheten i sig är nödvändig men inte tillräcklig som användarstöd, och att den för en granskare utan dataskyddskompetens förutsätter ett presentationsskikt som översätter den. Studiens resultat bekräftar alltså spårbarhetens värde men preciserar att värdet realiseras först tillsammans med en presentationsform anpassad till granskarens roll.

Den tredje begränsningen gällde avsaknaden av formaliserad designkunskap. Designvetenskaplig forskning har tillämpats i angränsande problemklasser, av Bergström, Karlsson och Åhlfeldt (2021) på organisatorisk informationsklassificering och av Li et al. (2022) på GDPR-efterlevnad i IT-infrastruktur, men utan textanalytisk komponent, och Löbner et al. (2025) bygger en prototyp med förankring i designvetenskaplig litteratur men formulerar inga generaliserbara principer. Studiens sex designprinciper adresserar den luckan direkt. Hit hör också representationsfrågan. Pilán et al. (2022) skiljer mellan direkta identifierare, kvasiidentifierare och konfidentiella attribut, en indelning som överlappar med artikel 4 och artikel 9 men inte är strukturerad enligt förordningens egen distinktion. Aegis tvådimensionella modell, som skiljer identifierbarhet från dataskyddsklass, låter representationen följa lagtextens kategoriska struktur i stället för en teknisk bekvämlighetsindelning, och den är formulerad som en designprincip snarare än som ett implementationsval.

Sammantaget överträffar studiens resultat inte tidigare arbete på de mätvärden där en jämförelse är möjlig, och det är heller inte studiens anspråk. Aegis bekräftar den samstämmiga slutsatsen i litteraturen att ingen enskild teknik räcker och att lagrade kombinationer krävs. Bidraget ligger i att föra den etablerade arkitekturen till en ny textdomän, ge den en juridisk motivering och formalisera den resulterande designkunskapen. I Gregor och Hevners (2013) termer är detta

närmast *exaptation*, alltså en känd klass av lösningar tillämpad på ett problem som tidigare inte adresserats på det sättet, snarare än uppfinning av en ny teknik.

9.2 Studiens kunskapsbidrag

Studiens kunskapsbidrag är av tre slag, artefaktuella, teoretiska och empiriska bidrag. Ågerfalk och Karlsson (2020) skiljer dessa tre åt och knyter det artefaktuella bidraget särskilt till intervenerande forskningsansatser som Action Design Research, samtidigt som de framhåller att ett artefaktuellt bidrag normalt vilar på ett empiriskt bidrag som motiverar och styrker det. De tre svarar mot olika delar av forskningsfrågan. Det artefaktuella bidraget, klassificeraren och dess arkitektoniska representation, behandlas i Sektion 9.2.1 och svarar mot delfråga 1 om den arkitekturella lösningen. Det teoretiska bidraget, de sex designprinciperna och den tvådimensionella representationsmodellen, behandlas i Sektion 9.2.2 och svarar mot delfråga 4 om designprinciperna. Det empiriska bidraget, utvärderingsresultaten över de tre designcyklerna, behandlas i Sektion 9.2.3 och svarar mot delfråga 2 om teknisk prestanda och delfråga 3 om verksamhetsrepresentanternas bedömning.

De tre bidragen ligger på olika abstraktionsnivåer (Gregor & Hevner 2013). Det artefaktuella bidraget är en situerad instans, det teoretiska är abstraktionen av den instansen till lösningskoncept oberoende av kodbasen, och det empiriska är den kunskap om artefaktens beteende och mottagande som underbygger de två andra och samtidigt har ett självständigt värde.

Inget enskilt tekniskt element i artefakten är nytt. Regelbaserad mönsterigenkänning, entitetsigenkänning och språkmodellbaserad analys är alla etablerade, och resultaten i Sektion 9.1 bekräftade att den lagrade hybridarkitekturen är fältets samstämmiga lösning. Det studien tillför ligger i kombinationen och i motiveringen. Ingen av de granskade studierna förenar en integrerad artikel 4- och artikel 9-taxonomi, ett eget lager för pusselbitseffekten enligt skäl 26, en lagerindelning som motiveras av förordningens juridiska struktur och formaliserade designprinciper, tillämpat på svensk generell fritext. Av de enskilda resultaten ligger den tvådimensionella representationsmodellen närmast en självständig nyhetsgrad, eftersom den representationsfråga den löser inte är strukturerad enligt förordningens distinktion i den litteratur studien bygger på. Bidraget är därmed en ny sammansättning och en ny motivering av kända komponenter, inte en ny teknik.

9.2.1 Artefaktuellt bidrag

Det artefaktuella bidraget är klassificeraren Aegis i version 0.3.0 tillsammans med den arkitektoniska representation som dokumenterar den. Artefakten beskrevs tekniskt och funktionellt i kapitel 6, och syftet här är inte att upprepa den beskrivningen utan att precisera vad som utgör ett kunskapsbidrag och på vilken nivå.

Aegis är i Gregor och Hevners (2013) mening en situerad instansiering, alltså en konkret artefakt som löser ett problem i en bestämd kontext. Bidraget på den nivån är att artefakten demonstrerar att en lagerindelad klassificerare faktiskt kan ta emot ostrukturerad svensk text och returnera en klassificering enligt GDPR:s känslighetskategorier. Litteraturgenomgången visade att tidigare arbeten antingen arbetar på avgränsade dokumenttyper eller saknar förankring i förordningens juridiska struktur, och Aegis visar att de fyra lagren, deterministisk mönsterigenkänning, entitetsigenkänning, språkmodellbaserad artikel 9-detektion och kombinatorisk pusselbitsbedömning, kan köras mot samma originaltext och tillsammans

producera ett sammanhållet klassificeringsutfall. Värdet ligger i den demonstrerade genomförbarheten, inte i någon enskild teknisk komponent, eftersom komponenterna var för sig är etablerade.

Instansen är samtidigt knuten till val som styrts av studiens kontext och tidsram. Den svenska spaCy-modellen, den lokala språkmodellen qwen3:14b och de empiriskt satta tröskelvärdena är instansbundna. Det artefaktuella bidraget i en mer överförbar mening är därför inte den specifika kodbasen utan lösningskonceptet den instansierar, alltså en lagerindelad klassificeringspipeline där deterministisk och språkmodellbaserad detektion körs mot samma text och där utfallet representeras tvådimensionellt. Den abstraktionen redovisades i formaliseringsfasen och är det som är avsett att bäras vidare. Distinktionen mellan instans och koncept är väsentlig för hur bidraget ska värderas, eftersom en annan implementation med andra modellval skulle vara en annan instans av samma koncept.

Till det artefaktuella bidraget hör också den arkitektoniska representationen. Arkitekturen är dokumenterad som UML-klassdiagram, och klassdiagrammet är inte enbart en illustration av den färdiga koden utan en representation av lagerstrukturen och relationerna mellan komponenterna på en nivå som är läsbar oberoende av programmeringsspråk. Representationen besvarar delfråga 1 om den arkitekturella lösningen, och den fungerar som en abstrakt ritning av artefakten i den mening Gregor och Jones (2007) beskriver, vilket gör konceptet återanvändbart. En läsare som vill konstruera ett system i samma problemklass kan utgå från klassdiagrammet utan att behöva läsa Aegis kodbas.

Bidragets gränser hör till beskrivningen av det. Aegis är en forskningsprototyp, vilket V2 konstaterade uttryckligen i designcykel 3, och studien gör inte anspråk på en validerad produktionsfärdig artefakt eller en heltäckande GDPR-efterlevnadslösning. Artefakten är utvärderad på ett egenkonstruerat testdataset och med tre verksamheter, och dess direkta överförbarhet är därmed begränsad. Det artefaktuella bidraget ska läsas mot den mognadsnivån, alltså som en fungerande instans som demonstrerar genomförbarhet och bär ett överförbart lösningskoncept, inte en färdig produkt. Artefaktens roll i forskningsbidraget är indirekt då den är den situerade instans ur vilken det teoretiska och det empiriska bidraget abstraheras.

9.2.2 Teoretiskt bidrag

Det teoretiska bidraget är den designkunskap som abstraherats ur arbetet med artefakten, nämligen sex designprinciper och den tvådimensionella representationsmodell som en av dem formaliserar. Principerna formulerades enligt Gregor, Chandra Kruse och Seidels (2020) schema och redovisas i sin helhet i kapitel 8. Syftet här är inte att upprepa dem utan att klargöra vad de bidrar med, på vilken nivå och med vilken empirisk tyngd.

Designprinciper är i Gregor och Hevners (2013) mening designkunskap på en abstraktionsnivå över den situerade artefakten. Där det artefaktuella bidraget är en instans som löser ett problem i en bestämd kontext, är en designprincip ett preskriptivt påstående om vad en konstruktör av en liknande artefakt bör göra för att uppnå en viss egenskap. De sex principerna är därför inte en sammanfattning av Aegis utan ett försök att formulera den överförbara lärdomen av att ha byggt och utvärderat artefakten över tre designcykler. De utgör tillsammans begynnande designteori för problemklassen automatisk GDPR-klassificering av ostrukturerad fritext, ett område där litteraturgenomgången visade att formaliserad designkunskap saknas.

De sex designprinciperna kan tillsammans med artefaktens arkitekturella representation placeras i den anatomi för designteori som Gregor och Jones (2007) anger, och den placeringen ger innebörd åt uttrycket begynnande designteori. Gregor och Jones beskriver en fullständig designteori som åtta komponenter. Dessa är syfte och avgränsning, konstrukt, principer för form och funktion, artefaktens föränderlighet, testbara propositioner, justificatory knowledge, principer för implementation och en *expository instantiation*. Designprinciper motsvarar den tredje komponenten, principer för form och funktion (Gregor, Chandra Kruse & Seidel 2020). I denna studie bärs den komponenten av de sex principerna tillsammans med det UML-klassdiagram som representerar artefaktens arkitektur (Sektion 2.5.1, 6.3). Studien levererar därutöver flera av de övriga komponenterna: ett syfte och en avgränsad problemklass, de konstrukt som klassificeringsmodellen vilar på, en artefaktföränderlighet i form av en arkitektur öppen för nya detektionslager, den *justificatory knowledge* som kapitel 4 redogör för, och artefakten Aegis själv som den konkreta instansiering Gregor och Jones benämner *expository instantiation*. Testbara propositioner föreligger däremot endast i begynnande form, eftersom designprinciperna är preskriptiva påståenden som ännu inte prövats utanför studien, och principer för implementation har inte formaliserats. Det är denna delvisa täckning som gör att bidraget ska läsas som begynnande designteori snarare än som en fullständig sådan. Att formulera en fullständig IS-designteori för problemklassen ligger utanför studiens ram, vilket anges redan i Sektion 1.6.

Principerna skiljer sig från de kernel theories de vilar på, och den skillnaden är central för att de ska räknas som ett bidrag. DP2 om utbytbarhet vilar på Pipes and Filters-mönstret, Strategy-mönstret och *Single Responsibility Principle*, men mönstren beskriver en återkommande lösning i allmänhet medan DP2 anger vad en konstruktör konkret ska göra för att uppnå utbytbarhet i den specifika kontexten av GDPR-klassificering. På samma sätt vilar DP1 på *Privacy by Design* men översätter den principen till ett mätbart åtagande om recall, och DP4 vilar på skäl 26 men formaliserar en arkitektonisk mekanism, ett eget detektionslager med tvåstegsvalidering, som lagtexten i sig inte föreskriver. Bidraget ligger i den preskriptiva översättningen från etablerad teori och juridik till konkret designvägledning för en problemklass där den översättningen inte gjorts tidigare.

Den enskilda princip som ligger närmast en självständig teoretisk kontribution är DP6 och den tvådimensionella representationsmodell den formaliserar. Modellen säger att klassificering enligt GDPR bör representeras som två separata kategoriska dimensioner, identifierbarhet och dataskyddsklass, som hålls isär i stället för att vägas samman till en endimensionell känslighetsskala. Bidraget är att representationen följer förordningens egen kategoriska struktur. Litteraturgenomgången visade att tidigare arbeten antingen behandlar personuppgifter odifferentierat eller använder indelningar, som Pilán et al. (2022) direkta identifierare, kvasiidentifierare och konfidentiella attribut, som inte är strukturerade enligt förordningens distinktion. Tvådimensionsmodellen är dessutom studiens färskaste resultat, eftersom den växte fram ur en konvergerande intressentreaktion i designcykel 2 och prövades i designcykel 3.

Det empiriska underlaget för principerna varierar, och den variationen hör till bidraget snarare än undergräver det. Hur stödet fördelar sig princip för princip redovisas i Sektion 7.2.5, från DP3 om lokal exekvering med det starkaste stödet till DP5 och DP6 som fick sina kärnor bekräftade men samtidigt en komponent vardera problematiserad. Att redovisa den variationen, snarare än att presentera de sex principerna som lika säkra, är en del av den designkunskap arbetet bidrar med, eftersom det talar om för en framtida konstruktör vilka principer som är robust underbyggda och vilka som är preliminära.

Det teoretiska bidraget besvarar delfråga 4 om designprinciperna för ett system av det här slaget. Bidragets räckvidd är samtidigt avgränsad på samma sätt som i Sektion 9.5.2. Principerna är abstraherade ur en studie med tre verksamheter och ett syntetiskt svenskspråkigt testdataset, och de har inte prövats empiriskt utanför arbetet. De ska därför läsas som begynnande designteori, alltså som lösningskoncept med empiriskt stöd men utan den breda validering en fullt utvecklad designteori förutsätter. Vägen mot en sådan validering hör till framtida forskning.

9.2.3 Empiriskt bidrag

Det empiriska bidraget är den kunskap om artefaktens beteende och mottagande som genererades under utvärderingen. Det består av två delar, de artificiella mätresultaten över tre designcykler och de naturalistiska FEDS-fynden, och de svarar mot delfråga 2 om teknisk prestanda respektive delfråga 3 om verksamhetsrepresentanternas bedömning. Till skillnad från det artefaktuella och det teoretiska bidraget, som är konstruktioner, är det empiriska bidraget observationer, och dess värde ligger i att de är dokumenterade så att de kan prövas och byggas vidare på.

Den artificiella utvärderingen bidrar med en uppmätt prestandaprofil för en lagerbaserad GDPR-klassificerare på svensk fritext. Profilen är inte ett enskilt tal utan en utveckling över tre cykler. Designcykel 1 nådde hög precision på enbart artikel 4-data med de två deterministiska lagren. Designcykel 2 utökade artefakten med språkmodellbaserad artikel 9-detektion och pusselbitsbedömning, vilket sänkte precisionen till omkring 64 procent medan recall behölls. Designcykel 3 förde precisionen tillbaka till knappt 83 procent, fortfarande med bibehållen recall över 89 procent. Den utvecklingen är i sig ett empiriskt fynd: den visar att tillägget av tolkande lager har en mätbar precisionskostnad, och att kostnaden är delvis återvinningsbar genom riktat förbättringsarbete. Att kurvan redovisas i sin helhet, inklusive det mellanliggande fallet, snarare än bara som ett slutvärde, är en del av bidraget, eftersom det dokumenterar en avvägning som en framtida konstruktör annars skulle behöva återupptäcka.

Inom den artificiella utvärderingen ryms också två fynd på lagernivå. Det första är att de fyra lagren bär olika precisionsbörda, där det deterministiska mönsterlagret är mest exakt och det mest tolkande kombinationslagret bär flest falska positiva, vilket ger empiriskt stöd åt att den juridiskt motiverade lagerindelningen motsvarar en verklig skillnad i svårighetsgrad. Det andra är recall-gapet för hälsodata och genetisk data, två artikel 9-kategorier som varken ett promptexperiment eller ett byte av språkmodell lyfte, vilket pekar mot en uppgiftsbunden snarare än enbart prompt- eller modellbunden svårighet. Båda fynden är negativa eller begränsande, och de redovisas eftersom de informerar framtida arbete.

Den naturalistiska utvärderingen bidrar med dokumenterad kunskap om hur verksamhetsrepresentanter bedömer en artefakt av det här slaget. De enskilda FEDS-fynden redovisas i Sektion 7.2, och deras tyngd ligger i att de är knutna till specifika designcykler och därmed spårbara till den punkt i utvecklingen där de uppstod. Som empiriskt bidrag är det främst tre mönster som bär: att preferensen för lokal exekvering var enhällig och motiverad från tre olika perspektiv, att recall genomgående prioriterades före precision medan den acceptabla precisionsgränsen förblev användningsberoende, och att spårbarhet bedömdes som nödvändig men inte tillräcklig som användarstöd. Att dessa mönster framträdde konsistent över tre verksamheter och tre designcykler är vad som gör dem till ett bidrag och inte enbart enskilda iakttagelser.

Ett av de empiriska fynden fungerade som vändpunkt i designarbetet. I designcykel 2 reagerade tre intressenter med olika fackbakgrund samstämmigt på att artefakten pressade samman identifierbarhet och känslighet i ett enda värde, och de gjorde det med tre skilda begreppsapparater, specificitet kontra känslighet, identifierbarhet kontra känslighet, och sannolikhet gånger konsekvens. Att en konvergerande observation nåddes från tre olika håll var det empiriska underlag som motiverade tvådimensionsmodellen i designcykel 3. Fyndet är ett exempel på hur den naturalistiska utvärderingen genererade designkunskap som de artificiella mätvärdena inte kunde ha gett, och det illustrerar växelverkan mellan empiri och konstruktion som ADR:s BIE-fas bygger på.

Det empiriska bidragets värde är samtidigt bundet till hur det togs fram. Mätresultaten gäller ett egenkonstruerat syntetiskt testdataset på svenska, och de naturalistiska fynden bygger på tre verksamheter. Resultaten är därför inte utan vidare generaliserbara till andra testkorpusar eller till en bredare population av organisationer, vilket diskuteras närmare i Sektion 9.5.2. Inom de gränserna utgör de en dokumenterad referenspunkt, alltså konkreta siffror och bedömningar som ett efterföljande arbete i samma problemklass kan jämföra sig mot, och en sådan referenspunkt saknades i den litteratur studien byggde på, eftersom de tidigare arbetena gäller andra textdomäner och andra språk.

9.3 Implikationer

Medan Sektion 9.2 redogjorde för vad studiens bidrag är, behandlar det här avsnittet vad bidraget innebär. Implikationerna delas upp efter vem de angår. Först behandlas vad bidraget betyder för praktiker, alltså för de organisationer och yrkesroller som skulle kunna använda eller bygga vidare på artefakten. Därefter behandlas vad det betyder för forskare i samma problemklass. Avslutningsvis vidgas perspektivet till de etiska och hållbarhetsmässiga implikationerna, med en ekonomisk, en social och en miljömässig dimension. Eftersom bidraget är en demonstration av genomförbarhet och en uppsättning designkunskap, inte en färdig produkt, bedöms implikationerna mot den mognadsnivån.

9.3.1 Implikationer för praktiker

Det artefaktuella bidragets praktiska implikation är att automatisk GDPR-klassificering av generell organisatorisk fritext visas vara genomförbar med lokala medel. Behovet är reellt, vilket den naturalistiska utvärderingen bekräftade genom samtliga tre designcykler. Det tydligaste enskilda exemplet kom från V1:s dataskyddsansvarige i designcykel 3, som pekade ut fritextfält i ett äldre verksamhetssystem som dagens anonymisering inte når. För en personuppgiftsansvarig organisation med den typen av ostrukturerad text innebär artefakten att ett klassificeringssteg kan automatiseras som annars förutsätter manuell genomläsning. Implikationen är samtidigt avgränsad. V2 beskrev i designcykel 3 artefakten uttryckligen som en prototyp och inte en produkt, och studien gör inte anspråk på något annat. Det artefaktuella bidraget är därför en demonstrerad genomförbarhet, inte en lösning färdig att driftsättas. V2:s förslag att paketera artefakten stegvis, med en första version för det säkra artikel 4-materialet och en senare för pusselbitsbedömningen och artikel 9 där osäkerheten är störst, pekar ut en rimlig väg från prototyp mot praktisk användning.

Inom det artefaktuella bidraget är en implikation specifikt knuten till kombinationslagret. Manuell granskning och enkla nyckelordsbaserade verktyg fångar direkta identifierare men missar systematiskt indirekt identifierbarhet, alltså fall där ingen enskild uppgift är en personuppgift men kombinationen pekar ut en person. Att den bedömningen sker i ett eget lager

innebär att artefakten flaggar en kategori av känslighet som de enklare alternativen lämnar oupptäckt. Intressenterna bekräftade i designcykel 1 och 2 att det är just den bedömningen som är svår och samtidigt viktig, vilket gör pusselbitslagret till den del av artefakten som tydligast adresserar ett behov som befintliga arbetssätt inte möter.

Det teoretiska bidragets praktiska implikation är av ett annat slag. En designprincip är inte en färdig lösning, men för den som ska konstruera ett liknande system fungerar de sex principerna som konkret konstruktionsvägledning, exempelvis att detektionslager bör nås genom ett smalt protokoll eller att klassificeringsutfallet bör hållas tvådimensionellt. Bidraget tjänar på den punkten praktiken som vägledning inför konstruktion snarare än som en artefakt redo att tas i bruk. Det empiriska bidragets praktiska implikation ligger i vad utvärderingsresultaten betyder för en verksamhet som överväger en sådan artefakt. FEDS-fynden visar att en organisation realistiskt kan förvänta sig hög täckning av känsligt innehåll men en precisionsnivå som ännu kräver mänsklig efterkontroll, och att den acceptabla precisionsgränsen är ett beslut verksamheten själv måste fatta utifrån hur klassificeringen ska användas. Det är i sig en praktisk vägledning: artefaktens lämplighet beror på om den ska maska, flagga eller styra vidare, och den bedömningen kan en verksamhet göra först mot sitt eget användningsfall.

9.3.2 Implikationer för forskare

Medan i Sektion 9.3.1 vände sig till den som ska använda eller bygga vidare på artefakten, vänder sig det här avsnittet till forskare i samma problemklass. Det bidrag som talar mest direkt till dem är det teoretiska. Designvetenskaplig forskning har tillämpats på närliggande problem, men för automatisk GDPR-klassificering av ostrukturerad fritext saknades formaliserad designkunskap, vilket litteraturgenomgången visade. Studiens sex designprinciper ger en utgångspunkt i det tomrummet. Att de är formulerade enligt Gregor, Chandra Kruse och Seidels (2020) schema gör dem forskningsbara, eftersom en princip som är nedbruten i mekanism, kontext och motivering kan konfronteras med en ny kontext och antingen hålla eller revideras. Implikationen för en forskare är att principerna är avsedda att prövas, inte att tas för givna, och att den variation i empiriskt stöd som Sektion 7.2.5 redovisar princip för princip talar om var en prövning är mest motiverad.

En andra implikation rör de uppmätta resultaten. Den artificiella utvärderingen över tre designcykler ger fältet en referenspunkt för en textdomän och ett språk som tidigare arbeten inte täcker. Pilán et al. (2022), Lorè et al. (2023) och Löbner et al. (2025) rapporterar prestanda på rättsfall, italienska myndighetsdokument respektive CV:n, så en forskare som bygger en motsvarande artefakt för svensk generell organisatorisk fritext hade inga jämförbara siffror att förhålla sig till. Aegis tillför sådana, inklusive det mellanliggande precisionsfallet i designcykel 2. Att hela kurvan finns dokumenterad, och inte bara ett slutvärde, gör att avvägningen mellan recall och precision kan läsas av i stället för att återupptäckas.

En tredje implikation är metodologisk. Studien parade en artificiell och en naturalistisk utvärdering, och de två formerna fångade olika saker. Tvådimensionsinsikten, som blev designcykel 3:s mest centrala omtag, växte fram ur tre verksamhetsrepresentanters samstämmiga reaktion i en demonstration. Ingen konfusionsmatris hade kunnat producera den. För en forskare som utformar utvärderingen av en juridiskt grundad klassificeringsartefakt är det ett konkret argument för att tekniska mätvärden inte räcker, och för att en intressentbaserad bedömning hör hemma inne i designcykeln snarare än efter den. Det stärker den roll FEDS (Venable, Pries-Heje & Baskerville 2016) ger den naturalistiska utvärderingen.

Den fråga som tydligast inbjuder till fortsatt teoretiskt arbete är den tvådimensionella representationsmodellen. Den följer förordningens kategoriska struktur i stället för en teknisk indelning, och om den ansatsen håller bortom den här studien är en öppen fråga. Vilka konkreta studier det leder till behandlas i Sektion 9.7.

9.3.3 Etiska och hållbarhetsmässiga implikationer

De forskningsetiska överväganden kring informerat samtycke, anonymisering och hantering av material redovisas i Sektion 2.6.4, och den reflektion som följer av att Action Design Research är en intervenerande ansats förs i reflektionen över metodens genomförande. Det här avsnittet ser istället på vad artefakten och studien innebär ekonomiskt, socialt och miljömässigt, de tre dimensioner som brukar samlas under begreppet hållbarhet.

Den ekonomiska implikationen följer av att artefakten automatiserar ett klassificeringssteg som annars kräver manuell genomläsning. V1:s dataskyddsansvarige pekade i designcykel 3 ut fritextfält i ett äldre verksamhetssystem som dagens anonymisering inte når, och att gå igenom sådan text för hand är kostsamt i specialisttid. Artefakten kan sänka den kostnaden, men vinsten är avgränsad. Precisionsnivån gör att mänsklig efterkontroll fortfarande behövs, så artefakten flyttar arbete snarare än tar bort det, och lokal exekvering förutsätter egen hårdvara i stället för en molntjänst, vilket är en kostnad i sig. Till den ekonomiska bilden hör också att en missad känslig uppgift kan bli dyr, genom sanktionsavgifter eller incidentkostnader. Den recall-prioritering artefakten bygger på är därför också ett sätt att hantera ekonomisk risk.

Den sociala implikationen rör de individer vars uppgifter finns i texten. De möter aldrig systemet, men det är deras integritet som står på spel, och artefaktens förmåga att fånga kombinatorisk identifierbarhet adresserar en känslighet som manuell granskning och nyckelordsverktyg systematiskt missar. Samtidigt finns en risk åt andra hållet. Intressenterna lyfte *automation bias*, alltså att en granskare litar för mycket på ett automatiserat utfall. En klassificerare som framstår som auktoritativ kan invagga en granskare i falsk trygghet, och då blir spårbarheten och det presentationsskikt som verksamhetsrepresentanterna efterlyste inte bara en användbarhetsfråga utan en skyddsfråga. Lokal exekvering har en social sida också: att uppgifterna stannar inom organisationen och inte överförs till tredje land är både ett rättsligt och ett förtroendemässigt värde.

Den miljömässiga implikationen är den som studien har minst underlag för att uttala sig om. Lager 3 och 4 anropar en språkmodell per text, och språkmodellinferens har en energikostnad som studien inte har mätt. Artefakten bygger ändå medvetet på en resurssnål linje: de två första lagren använder beräkningsmässigt billig regex och spaCy, och valet av en mindre lokal modell framför en stor molnmodell motiverades tekniskt men har sannolikt också en lägre energiförbrukning per körning. Den jämförelsen är dock inte kvantifierad, och en egentlig bedömning av artefaktens miljöavtryck förutsätter en mätning som ligger utanför studiens ram.

9.4 Reflektion över metodens genomförande

Sektion 2.6 i metodkapitlet motiverade valet av Design Science Research och Action Design Research innan arbetet inleddes. Det här avsnittet ser i stället tillbaka på metoden som den faktiskt genomfördes, vilket är vad ADR:s tredje fas, reflektion och lärande, föreskriver som en löpande aktivitet. Reflektionen rör hur den valda ansatsen bar studien, var den höll och var den inte gjorde det.

ADR:s iterativa kärna fungerade som avsett. Tre BIE-cykler genomfördes, var och en avslutad med en artificiell och en naturalistisk utvärdering vars resultat formade nästa cykels problemformulering. Konstruktionen följde alltså inte en rät linje från färdig artefakt till utvärdering, utan en serie korta varv där designen och de tre verksamheternas behov vävdes samman. Det tydligaste utslaget av den logiken var omformuleringen av studiens fokus tidigt i arbetet. Arbetet utgick ursprungligen från en AI-gateway som skulle dirigera prompter till en lokal eller en molnbaserad modell beroende på hur känslig informationen var, men under problematiseringsfasens samtal med tre verksamheter visade det sig att den dirigeringen var en instans av ett mer grundläggande behov. Alla tre behövde klassificera känslig text, oavsett om resultatet sedan skulle styras vidare, maskas eller flaggas. Att gå från instans till klass var en praktikdriven omformulering av problemet, och den följde ADR:s princip om *Practice-Inspired Research* (Sein et al. 2011) snarare än ett avsteg från planen.

Parningen av artificiell och naturalistisk utvärdering visade sig vara metodens starkaste enskilda drag, eftersom de två utvärderingsformerna fångade olika saker. Den artificiella utvärderingen gjorde regressioner synliga på ett sätt som intervjuer inte kan. Precisionsfallet i designcykel 2, från omkring 90 till runt 64 procent, framträdde direkt i konfusionsmatrisen och gick inte att tolka bort. Den naturalistiska utvärderingen fångade i sin tur det som mätvärdena var blinda för. Pusselbitseffekten identifierades som den centrala tekniska luckan av intressenterna i designcykel 1, inte av någon metrik, och tvådimensionsinsikten växte fram ur tre verksamhetsrepresentanters samstämmiga reaktion i designcykel 2. Ingen av de två observationerna hade kunnat genereras av den andra utvärderingsformen.

En reflektion rör hur långt interventionen faktiskt nådde. Action Design Research är en intervenerande ansats, men interventionen i den här studien tog formen av demonstration och intressentbedömning inom designcyklerna, inte av att artefakten driftsattes i en deltagande verksamhets löpande arbete. Att räckvidden stannade där följer av två förhållanden, och båda är principiella snarare än en brist i genomförandet. Det första är att Aegis har prototypmognad och är en komponent vars utfall ett nedströms system är tänkt att använda, inte ett färdigt program redo att tas i drift. Det andra är att en prövning i skarp drift skulle kräva att artefakten kördes mot verksamheternas egen känsliga text, och hur sådan text lagligt får hanteras är en olöst fråga som studien själv pekar ut som fortsatt forskning i Sektion 9.7. Den avgränsade interventionen är därmed en följd av artefaktens mognadsnivå och av dataskyddsrättsliga villkor, inte av att den naturalistiska utvärderingen utformats för snävt. Upplägget är förenligt med FEDS, som behandlar utvärdering som ett spann från artificiell till naturalistisk och placerar demonstration inför verkliga intressenter mot den naturalistiska änden utan att kräva full driftsättning.

Flera saker gick inte enligt plan, och de redovisas här eftersom ADR:s reflektionsprincip behandlar avvikelser som resultat snarare än som brister att tona ned. En av de fyra verksamheterna, V3, deltog i problematiseringsfasen men återkom inte för utvärdering, vilket gör att det naturalistiska underlaget vilar på tre verksamheter i stället för fyra. Vad bortfallet betyder för underlagets bredd behandlas i Sektion 9.6. Tidsplanen höll inte heller fullt ut. Designcykel 2 inleddes ungefär en vecka senare än ursprungsplanen angav, en förskjutning som kunde absorberas men som minskade utrymmet i de senare cyklerna.

Två experiment i designcykel 3 gav inte de utfall som förväntades, och deras negativa resultat blev metodologiskt informativa. Designcykelns problemformulering pekade ut aggregatorns tre trösklar som empiriskt outprövade och planerade en kalibrering av dem. Kalibreringen gav ett nollresultat: trösklarna stannade på de värden som etablerats i designcykel 2, och de

precisionsförbättringar cykeln ändå uppnådde kom av pipelinearbete och ett byte av lokal språkmodell. Det andra experimentet var en förstärkt promptversion riktad mot artikel 9-lagrets svagaste kategorier, vilken inducerade strukturell regression och rullades tillbaka. Inget av utfallen var det planerade, men båda blev empiriska fynd. Nollresultatet visar att tröskelkalibrering är arkitekturellt verkningslös vid den nuvarande skalan, och promptåterställningen visar att kategoriernas svaghet är uppgiftsbunden snarare än enbart prompt- eller modellbunden. ADR:s reflektionsprincip gör att sådana utfall hör hemma i rapporten, inte utanför den.

En metodbegränsning blev synlig först under analysarbetet. Den per-lager-baserade delen av den artificiella utvärderingen visade sig fördela fynd efter det lager som producerade dem och sakna falska negativa helt, eftersom ett uteblivet fynd inte bär något producerande lager. Per-lager-måttet är därför ett precisionsmått per produktionslager och inte ett recall-mått per logisk GDPR-domän. Begränsningen upptäcktes inte vid utvärderingens konstruktion utan när resultaten skulle tolkas, och den hanteras genom en uttrycklig metodologisk reservation i resultatkapitlet i stället för genom en omkonstruktion av instrumentet.

Avslutningsvis kräver ADR som intervenerande ansats en reflexiv anmärkning. Studien observerade inte tre verksamheter på avstånd utan demonstrerade en artefakt för dem och bjöd in dem att bedöma den. De begreppsramar intressenterna använde, V1:s specificitet, V4:s identifierbarhet och V2:s sannolikhet gånger konsekvens, framkallades i en situation som författarna hade utformat. Det ogiltigförklarar inte materialet, men det innebär att den naturalistiska datan är samproducerad snarare än insamlad, och den dubbla forskarroll som Sektion 2.6 identifierade på förhand var verksam genom hela utvärderingen. De korrektivmekanismer som var avsedda att hålla den rollen i schack bedöms systematiskt i Sektion 9.5.1 som en del av studiens trovärdighet.

9.5 Studiens trovärdighet

Sektion 2.6 motiverade valet av forskningsansats innan arbetet inleddes, och Sektion 9.4 såg tillbaka på hur Action Design Research bar studien i praktiken. Det här avsnittet bedömer i stället studiens kvalitet systematiskt mot en uppsättning kriterier. Eftersom studiens empiriska underlag till stor del är kvalitativt, intervjuer och demonstrationer med tre verksamheter, struktureras bedömningen efter de fyra etablerade kvalitetskriterier för kvalitativ forskning som Creswell och Poth (2018) beskriver, trovärdighet (credibility), överförbarhet (transferability), pålitlighet (dependability) och bekräftelsebarhet (confirmability). Var och en svarar mot ett kriterium från den kvantitativa traditionen, intern validitet, extern validitet, reliabilitet och objektivitet, men är omformulerat för forskning där resultaten växer fram ur tolkning snarare än mätning.

Ramverket fångar inte allt. Studien har också ett artificiellt utvärderingsspår med kvantitativa mätvärden, och för den delen är kriterierna inte fullt ut skrivna. Där det är relevant, framför allt under pålitlighet, behandlas därför den artificiella mätningen på sina egna villkor, inklusive att språkmodellbaserade lager inte ger strikt deterministiska utfall. Kriterierna används alltså som genomgående struktur för kvalitetsbedömningen, men med en uttrycklig reservation för att en del av studiens resultat är av ett slag de inte är gjorda för.

9.5.1 Trovärdighet

Trovärdighet motsvarar i ramverket det som i kvantitativ forskning kallas intern validitet, alltså frågan om studiens slutsatser är en rimlig återgivning av det som faktiskt undersökts. För den här studien är det främsta hotet mot trovärdigheten den dubbla forskarroll som följer av att Action Design Research är en intervenerande ansats. Författarna var samtidigt artefaktens konstruktörer och dess utvärderare, vilket medför en risk att utvärderingsdata omedvetet tolkas till den egna designens fördel. Hur den rollen spelade ut genom arbetet behandlas i Sektion 9.4. Det här avsnittet ser i stället på de mekanismer som var avsedda att hålla risken i schack.

Den starkaste av dem är att den artificiella utvärderingen inte tillåter efterhandstolkning. Mätvärdena kommer ur en mätning mot ett fast facit, och ett utfall kan inte skrivas om i efterhand. Precisionsfallet i designcykel 2, från omkring 90 till runt 64 procent, är ett konkret exempel: det framträdde direkt i konfusionsmatrisen och rapporterades som det var, trots att det var ett ofördelaktigt resultat. Att ett sådant fall finns redovisat i sin helhet, och inte tonats ned, är i sig ett tecken på att den artificiella mätningen rapporterats snarare än tolkats.

Trovärdigheten vilar också på triangulering. Studien parade två utvärderingsformer, en artificiell och en naturalistisk, och de fångade olika saker, så att den enas svaghet delvis täcktes av den andra. Den naturalistiska datan bygger dessutom på tre verksamheter med olika sektorstillhörighet och fackbakgrund, och när en observation återkom från tre håll, som tvådimensionsinsikten i designcykel 2 gjorde, vilar den på mer än en enskild källa. Patton (1999) benämner den formen perspektivtriangulering. Tolkningen av intervjumaterialet gjordes därtill gemensamt av båda författarna, vilket innebär att ingen enskild läsning av en session står oemotsagd, och testdatats facit togs fram genom oberoende granskning av båda annoterarna mot en annoteringsguide. Ingen av mekanismerna tar bort den dubbla forskarrollen, men tillsammans gör de att studiens fynd är förankrade i mer än författarnas egen bedömning.

9.5.2 Överförbarhet

Överförbarhet motsvarar i ramverket det som i kvantitativ forskning kallas extern validitet eller generaliserbarhet, alltså frågan om i vilken mån studiens resultat håller utanför den kontext de tagits fram i. Kriteriet skiljer sig från de övriga tre genom var ansvaret ligger. Studien kan inte själv avgöra hur långt dess resultat bär, utan uppgiften är att beskriva kontexten tillräckligt utförligt för att en läsare ska kunna bedöma om den liknar den egna. Det här avsnittet samlar därför de kontextvillkor som avgör hur långt designkunskapen kan föras vidare.

Bidragets räckvidd bedöms bäst som överförbarhet snarare än som generaliserbarhet. Studien bygger på tre verksamheter och ett egenkonstruerat testdataset och gör inga anspråk på statistisk representativitet för en population. Det anspråk som görs är analytiskt: designkunskapen kan bäras vidare till kontexter som i relevanta avseenden liknar de studerade. Den abstraktionen är en del av metoden, eftersom ADR:s avslutande fas formalisering av lärande innebär just att situerad kunskap från designcyklerna lyfts till lösningskoncept för en problemklass (Sein et al. 2011).

Artefakten och designprinciperna är överförbara i olika grad. Artefakten är en situerad instans, utvärderad med tre verksamheter och på ett syntetiskt svenskspråkigt testdataset, och dess direkta överförbarhet är därför begränsad. En annan organisation skulle möta andra texttyper, andra språkliga mönster och andra trösklar. Designprinciperna är den del av bidraget som är avsedd att överföras, och ADR:s avslutande fas gör abstraktionen från instans till princip till en del av metoden. Hur långt en enskild princip bär beror på vad dess stöd vilar på. DP3 om lokal

exekvering har den bredaste räckvidden, eftersom samma designval motiverades från tre olika perspektiv, juridiskt, säkerhetstekniskt och infrastrukturellt, och de skälen är inte knutna till en enskild verksamhets situation. Principer vars stöd är smalare, eller vars empiriska underlag problematiserades i designcykel 3, är på motsvarande sätt mer kontextbundna. Den variationen redovisas princip för princip i Sektion 7.2.5.

Samma kontextvillkor som metodreflektionen i Sektion 2.6.2 lyfter avgränsar hur långt designkunskapen är överförbar. Det empiriska underlaget är tre verksamheter, valda för kontextbredd men inte för täckning av alla sammanhang där GDPR-klassificering är relevant, och det syntetiska testdatasetet gör att artefaktens beteende på autentisk text är oprövat. Till det kommer att artefakten har prototypmognad och att testdatan är svenskspråkig. Dessa villkor sätter gränsen. Överföringen är rimligast till kontexter som liknar de studerade, alltså GDPR-reglerade organisationer som arbetar med svensk organisatorisk fritext, och svagare ju längre från den kontexten ett tänkt användningsfall ligger. Designprinciperna ska därför läsas som begynnande designteori i Gregor och Hevners (2013) mening, alltså som lösningskoncept med empiriskt stöd men utan den breda validering en färdig designteori kräver. Vad en sådan validering skulle kräva behandlas i Sektion 9.7.

9.5.3 Pålitlighet

Pålitlighet motsvarar i ramverket det som i kvantitativ forskning kallas reliabilitet, alltså frågan om studiens tillvägagångssätt är stabilt och dokumenterat så att processen kan följas och i princip upprepas. För en designvetenskaplig studie där artefakten växer fram över flera cykler ligger tyngden på att utvecklingsförloppet är spårbart, inte på att en mätning ger exakt samma värde varje gång.

Den artificiella utvärderingens pålitlighet vilar på att varje mätning utgår från ett versionerat snapshot knutet till en bestämd kommithash. En rapporterad siffra kan därför härledas till en exakt kodversion och ett exakt testdataset, och en senare körning kan ställas mot samma utgångsläge. Eftersom lager 3 och 4 anropar en språkmodell är utfallet inte strikt deterministiskt mellan körningar, inte ens vid temperatur noll. Den begränsningen hanteras öppet snarare än döljs. En reproduktionskörning inför den naturalistiska utvärderingen i designcykel 2 gav identisk recall och en variation på sex fynd i antalet falska positiva, vilket är litet i förhållande till skillnaderna mellan designcyklerna. Variationen finns alltså, men den är liten nog att inte påverka slutsatserna, och den är redovisad så att en läsare kan väga in den.

Utvecklingsprocessens pålitlighet vilar i sin tur på loggboken. Designbeslut fördes in löpande med alternativ som övervägdes, motivering och koppling till GDPR-krav eller empiriskt stöd, och de redovisas för läsaren i genomförande- och arkitekturkapitlen. Det gör att en läsare kan följa varför artefakten ser ut som den gör och inte bara hur den ser ut. Till samma sak hör att studiens metoder är förankrade i etablerade ramverk, FEDS för utvärderingen, Kvale och Brinkmann för intervjuerna och Gregor, Chandra Kruse och Seidel för formaliseringen av designprinciper, och att tillämpningen av dem dokumenteras i stället för att beskrivas i allmänna ordalag. En kvarstående svaghet är att loggboken är ett internt arbetsdokument som inte bifogas, vilket innebär att den fullständiga beslutskedjan är spårbar för författarna men för läsaren bara genom det urval som rapporten återger.

9.5.4 Bekräftelsebarhet

Bekräftelsebarhet motsvarar i ramverket det som i kvantitativ forskning kallas objektivitet, alltså frågan om resultaten är förankrade i studiens material snarare än i författarnas

förförståelse. Kriteriet ligger nära pålitligheten, men medan pålitlighet rör om processen är stabil och dokumenterad rör bekräftelsebarhet om slutsatserna går att leda tillbaka till data. För en intervenerande ansats där författarna också är konstruktörer är just den frågan central.

Det tydligaste stödet för bekräftelsebarhet är att studiens slutsatser är knutna till spårbart material. De artificiella mätvärdena kommer ur körningar mot ett versionerat testdataset och kan härledas till en bestämd kodversion, och de naturalistiska fynden är knutna till specifika designcykler och utvärderingssessioner. Designprinciperna är inte fritt formulerade utan abstraherade ur dokumenterade designbeslut, och deras empiriska stöd redovisas princip för princip i Sektion 7.2.5, även där stödet är svagt. Att den variationen redovisas öppet, i stället för att de sex principerna presenteras som lika säkra, är i sig ett uttryck för bekräftelsebarhet, eftersom det låter en läsare se hur långt materialet faktiskt bär varje princip.

Samma egenskap finns inbyggd i artefakten. Varje fynd bär ett source-fält som anger vilket lager och vilken regel som producerade det, vilket gör att en klassificering kan härledas till sin grund i stället för att behöva tas på förtroende. Den spårbarheten är samtidigt ett av studiens designresultat och ett stöd för dess egen bekräftelsebarhet, eftersom den gör utvärderingens utfall granskningsbara på fyndnivå.

Två förhållanden begränsar bekräftelsebarheten. Det första är att den naturalistiska datan är samproducerad. Intressenterna bedömde en artefakt som författarna konstruerat och demonstrerat, och de begreppsramar de använde framkallades i en situation som författarna utformat, vilket behandlas närmare i Sektion 9.4. Materialet är därmed inte insamlat under neutral observation, och det bör vägas in när de naturalistiska fynden tolkas. Det andra är att loggboken, som utgör den primära kedjan från observation till designbeslut, är ett internt dokument som inte bifogas. För läsaren är bekräftelsebarheten därför så stark som rapportens egen redovisning av besluten, inte starkare.

9.6 Begränsningar

De begränsningar som redovisas här är delvis nämnda på sina respektive ställen i rapporten. Syftet med avsnittet är att samla dem och bedöma vad de sammantaget betyder för hur studiens resultat bör läsas. Begränsningarna grupperas efter om de rör studiens underlag, artefakten och mätningen, eller resultatens generaliserbarhet.

Den första gruppen rör underlaget. Den naturalistiska utvärderingen bygger på tre verksamheter. Fyra verksamheter rekryterades, men V3 deltog endast i problematiseringsfasen och återkom inte för utvärdering, vilket innebär att den naturalistiska basen är mindre än planerat. De tre kvarvarande täcker privat sektor i två storleksordningar och offentlig förvaltning, men ett bortfall på en av fyra är en reell begränsning av hur brett intressentmaterialet kan sägas spegla problemklassen. Antalet intervjupersoner är dessutom litet i absolut mening, vilket är vanligt i Action Design Research men som ändå begränsar hur långt de naturalistiska fynden kan generaliseras. De tre verksamheterna rekryterades därtill inom ett geografiskt avgränsat område snarare än spritt över landet. Det innebär att studiens tal om en svensk kontext vilar på ett regionalt koncentrerat underlag, och att eventuella regionala särdrag i hur verksamheter ser på dataskydd inte kan skiljas från det som är gemensamt för svensk kontext i stort. En andra underlagsbegränsning är att testdatan är syntetisk. Datasetet konstruerades för studien enligt en hybridmetod med språkmodellsgenererade kandidater och manuell granskning, och innehåller ingen autentisk verksamhetstext. Syntetisk data ger kontroll över innehåll och annotering men fångar inte nödvändigtvis den variation, de stavfel och de

domänspecifika formuleringar som förekommer i verklig organisatorisk text, och de uppmätta mätvärdena gäller därför strikt taget artefaktens prestanda på den konstruerade testdatan.

Den andra gruppen rör artefakten och mätningen. Artefakten är en forskningsprototyp, vilket V2 konstaterade uttryckligen i designcykel 3, och den är inte en validerad produktionsfärdig lösning. Den är utvecklad och testad på svenskspråkig text och dess detektion bygger på en svensk språkmodell, en svensk spaCy-modell och svenska mönster, vilket gör att resultaten inte utan vidare överförs till andra språk. Mätningen har en metodologisk begränsning som blev synlig först under analysarbetet. Den per-lager-baserade delen av den artificiella utvärderingen fördelar fynd efter producerande lager och saknar falska negativa, eftersom ett uteblivet fynd inte bär något producerande lager, och per-lager-måttet är därför ett precisionsmått per produktionslager snarare än ett recall-mått per logisk GDPR-domän. Begränsningen hanteras genom en uttrycklig reservation i resultatkapitlet men kvarstår som en egenskap hos mätinstrumentet. En ytterligare begränsning på artefaktnivå är att tröskelkalibreringen i designcykel 3 gav ett nollresultat, vilket innebär att de tre konfigurerbara trösklarna står kvar på empiriskt oprövade värden från designcykel 2, och att artefaktens känslighet för trösklarnas inställning därmed inte är kartlagd.

En särskild begränsning rör artikel 9-detektionens täckning. Recall för hälsodata och genetisk data ligger under nivån för de övriga kategorierna, och varken ett riktat promptexperiment eller ett byte av språkmodell lyfte de två kategorierna. Det innebär att artefakten på den nuvarande mognadsnivån har en känd och kvarstående svaghet för en del av artikel 9-taxonomin, och att den fail-safe-princip studien bygger på, att inte missa känslig data, alltså inte är fullt realiserad för de kategorierna.

En besläktad begränsning rör kombinationslagrets täckning. De kombinationer som prövades i utvärderingen rör sig kring yrke, organisation och plats, medan GDPR skäl 26 omfattar en öppen mängd uppgifter som tillsammans kan möjliggöra identifiering. Kombinationslagrets mekanism är inte bunden till just de signaltyperna, men det empiriska stödet för DP4 gäller därför själva mekanismen, att kombinatorisk identifierbarhet detekteras i ett eget lager med validering, och inte bredden av kombinationstyper. Hur väl detektionen håller för andra slags kombinationer än de prövade är inte belagt inom studien.

Den tredje gruppen rör generaliserbarhet och följer av de två föregående. Underlaget av tre verksamheter, det syntetiska svenskspråkiga testdatasetet och artefaktens prototypmognad gör att resultaten inte utan vidare är överförbara till andra organisationer, textkorpusar eller språk. Vad som ändå är överförbart, och under vilka kontextvillkor, behandlas i Sektion 9.5.2.

Sammantaget pekar begränsningarna åt samma håll. Studiens resultat är giltiga inom en avgränsad ram, tre verksamheter, syntetisk svensk text och en artefakt med prototypmognad, och de ska läsas som en demonstration av genomförbarhet och en uppsättning preliminär designkunskap snarare än som validerade och brett generaliserbara resultat. Den ramen är förenlig med arbetets karaktär och syfte, men den avgör vad resultaten kan och inte kan användas till, och flera av begränsningarna pekar direkt mot det fortsatta arbete som behandlas i nästa avsnitt.

9.7 Framtida forskning

De uppslag som redovisas här följer av studiens begränsningar och av fynd som pekade utöver det egna arbetets ram. De är ordnade efter hur nära de ligger studiens resultat, från direkta

uppföljningar av kvarstående problem till bredare frågor som arbetet öppnat men inte kunnat behandla.

Det mest närliggande uppslaget är en empirisk prövning av designprinciperna utanför studien. De sex principerna är abstraherade ur ett arbete med tre verksamheter och har inte prövats i någon annan kontext, och deras status som begynnande designteori förutsätter att de testas. En sådan prövning kan ske genom att andra konstruktörer tillämpar principerna när de bygger ett system i samma problemklass, eller genom att principerna konfronteras med verksamheter som inte deltagit i den här studien. Först genom en sådan prövning kan det avgöras vilka principer som håller bortom det underlag de härleddes ur.

Ett andra uppslag följer av att testdatan var syntetisk. En utvärdering av artefakten mot autentisk verksamhetstext skulle visa om den uppmätta prestandan håller när indata innehåller den variation, de stavfel och de domänspecifika formuleringar som syntetisk data inte fångar. Ett sådant arbete kräver att frågan om hur känslig autentisk text kan hanteras inom ramen för dataskyddsförordningen löses, vilket i sig är en metodologisk fråga värd att behandla.

Ett tredje uppslag rör tröskelkalibreringen. Designcykel 3:s kalibrering gav ett nollresultat, och de tre konfigurerbara trösklarna står därför kvar på oprövade värden. Orsaken var arkitektonisk, utvärderingen matchar fynd mot facit innan aggregatorn fattar sitt beslut (se Sektion 7.1.4), vilket innebär att trösklarnas verkan bara kan kartläggas med ett utvärderingsupplägg som mäter klassificeringsutfallet i stället för fynden. Framtida arbete kan konstruera ett sådant upplägg och därmed avgöra hur känslig artefakten är för trösklarnas inställning. Nollresultatet är i sig ett fynd, men det lämnar frågan om trösklarnas verkan obesvarad snarare än stängd.

Ett fjärde uppslag rör artikel 9-detektionens svaga kategorier. Recall för hälsodata och genetisk data motstod både ett promptexperiment och ett byte av språkmodell, vilket pekar mot en uppgiftsbunden svårighet. Framtida forskning kan undersöka vad den svårigheten består i, om den kan adresseras med en annan detektionsstrategi än few-shot-prompting, exempelvis finjustering på kategorispecifik data, och om den är en egenskap hos kategorierna själva eller hos hur de uttrycks i text. Eftersom studien bygger på en fail-safe-princip är en kategori med systematiskt svag recall ett problem som förtjänar riktad uppföljning.

Ett femte uppslag följer av designprincipernas och artefaktens språkbundenhet. Hela artefakten är konstruerad för svenska, och framtida arbete kan undersöka hur lösningskonceptet överförs till andra språk och rättsliga kontexter. GDPR gäller hela unionen, men de språkliga resurserna skiljer sig åt, och en flerspråkig prövning skulle visa vilka delar av arkitekturen som är språkoberoende och vilka som måste konstrueras om per språk.

Två uppslag följer av den naturalistiska utvärderingen snarare än av en mätbar begränsning. Det första är presentationsskiktet. Designcykel 3 visade samstämmigt att artefaktens spårbarhet och motivering är nödvändiga men inte tillräckliga som användarstöd, och att en granskare utan dataskyddskompetens behöver ett skikt som översätter klassificeringsutfallet. Hur ett sådant skikt bör utformas, och hur det förhåller sig till risken för automation bias som intressenterna lyfte, ligger utanför den här studiens omfång och är en designfråga i egen rätt. Det andra är den konsekvensanalys som V2 efterlyste. Artefaktens dataskyddsklass-dimension fångar delvis vad V2 beskrev som konsekvens, men en självständig vägning av sannolikhet mot konsekvens byggdes aldrig, och hur en sådan riskbedömning skulle integreras med en GDPR-klassificerare är ett uppslag som studien identifierade men inte kunde behandla.

Ett avslutande och mer öppet uppslag rör den härledda känslighetsskalan. Designcykel 3:s utvärdering riktade konvergent kritik mot att de två dimensionerna vägs samman till en skala, och V4 föreslog att skalan tas bort till förmån för en visuell representation. Studien har lämnat frågan öppen, och framtida arbete kan undersöka om en sammanfattande nivå bör härledas alls, och i så fall hur, eller om en tvådimensionell representation utan sammanvägning tjänar granskaren bättre. Det är en fråga om hur juridisk klassificering bäst presenteras för en mänsklig bedömare, och den är bredare än den enskilda artefakten.

9.8 Slutsatser

Studiens syfte var att generera designkunskap om hur en IT-artefakt kan designas för att automatiskt identifiera och klassificera svensk fritext enligt GDPR:s känslighetskategorier. Forskningsfrågan delades i fyra delfrågor som besvarats i var sitt kapitel, och det här avsnittet samlar svaren.

Delfråga 1. Vad är den arkitekturella lösningen av ett sådant system?
Den arkitekturella lösningen (delfråga 1) är en lagerindelad klassificeringspipeline där fyra detektionslager körs mot samma originaltext: deterministisk mönsterigenkänning och entitetsigenkänning för artikel 4-data, språkmodellbaserad detektion för artikel 9-data, och ett kombinationslager som bedömer pusselbitseffekten enligt skäl 26. Lagerindelningen följer förordningens juridiska struktur snarare än en rent teknisk uppdelning, och klassificeringsutfallet representeras tvådimensionellt som identifierbarhet och dataskyddsklass med känslighetsnivån som ett härlett värde.

Delfråga 2. Vad är den tekniska prestandan av en sådan artefakt?
Den tekniska prestandan (delfråga 2) mättes över tre designcykler. Recall, som artefakten prioriterar, låg över 89 procent i samtliga tre cykler. Precisionen rörde sig från omkring 90 procent när enbart de deterministiska lagren var aktiva, ned till 64 procent när de tolkande lagren tillfördes, och tillbaka till knappt 83 procent efter designcykel 3:s förbättringsarbete. Utvecklingen visar att tillägget av språkmodellbaserade lager har en mätbar precisionskostnad, och att den kostnaden är delvis återvinningsbar genom riktat arbete på pipeline och modellval.

Delfråga 3. Hur bedömer verksamhetsrepresentanter artefaktens nytta, ändamålsenlighet och organisatoriska passform?
Verksamhetsrepresentanternas bedömning (delfråga 3) var att artefakten möter ett reellt behov och att den tvådimensionella representationen fångar en distinktion de själva lyft. Bedömningen var samstämmig på tre punkter: lokal exekvering föredras, recall är viktigare än precision även om den acceptabla precisionsgränsen är användningsberoende, och spårbarhet är nödvändig men inte tillräcklig som användarstöd utan ett presentationslager anpassat till granskarens roll. Artefakten bedömdes som en fungerande prototyp och en god grund att bygga vidare på, inte som en färdig produkt.

Delfråga 4. Vad är designprinciperna för ett sådant system?
Designprinciperna (delfråga 4) utgörs av sex principer som abstraherats ur arbetet med artefakten över de tre designcyklerna. De är formulerade som begynnande designteori för problemklassen automatisk GDPR-klassificering av ostrukturerad fritext, ett område där formaliserad designkunskap saknades. Deras empiriska tyngd varierar, och variationen redovisas öppet eftersom den talar om vilka principer som är robust underbyggda och vilka som är preliminära.

Huvudfråga. Hur kan en IT-artefakt designas för att automatiskt identifiera och klassificera svensk fritext baserat på juridiskt definierade känslighetskategorier enligt GDPR?

Sammantaget visar studien att en IT-artefakt kan designas för att automatiskt identifiera och klassificera svensk fritext enligt GDPR:s känslighetskategorier, och att en lagerindelad arkitektur bär uppgiften även i en mindre strukturerad textdomän än de tidigare arbeten prövat. Kunskapsbidraget är artefaktuellt, teoretiskt och empiriskt: en körbar klassificerare med en arkitekturell representation, sex designprinciper med en tvådimensionell representationsmodell, och en dokumenterad prestanda- och bedömningsprofil över tre designcykler. Resultaten är giltiga inom en avgränsad ram, tre verksamheter, ett syntetiskt svenskspråkigt testdataset och en artefakt med prototypmognad, och ska läsas som en demonstration av genomförbarhet och en uppsättning preliminär designkunskap snarare än som validerade och brett generaliserbara resultat.

Den fortsatta forskning som arbetet pekar mot är framför allt en empirisk prövning av designprinciperna utanför studien och en utvärdering av artefakten mot autentisk verksamhetstext, tillsammans med de mer specifika uppslag som behandlas i Sektion 9.7.

Referenser

Anderson, R. J. (2020). *Security Engineering: A Guide to Building Dependable Distributed Systems*. 3 uppl. Indianapolis, IN: Wiley.

Anghel, C., Anghel, A. A., Pecheanu, E., Cocu, A., Istrate, A. & Andrei, C. A. (2025). Diagnosing Bias and Instability in LLM Evaluation: A Scalable Pairwise Meta-Evaluator. *Information*, 16(8), s. 652.
doi:10.3390/info16080652

Anthropic (u.å.). *Choose a permission mode*. Claude Code Docs. https://code.claude.com/docs/en/permission-modes [2026-05-24].

Arksey, H. & O'Malley, L. (2005). Scoping studies: towards a methodological framework. *International Journal of Social Research methodology*, 8(1), s. 19–32. doi:10.1080/1364557032000119616

Artstein, R. & Poesio, M. (2008). Inter-coder agreement for computational linguistics. *Computational Linguistics, 34(4)*, s. 555–596.
doi:10.1162/coli.07-034-R2

Barbudo Carrasco, L. (2025). Mitigating Bias and Advocating for Data Sovereignty: The Role of Metadata and Paradata in Ethical AI-Driven Information Systems. *Journal of Library Metadata*, 25(3), s. 185–200.
doi:10.1080/19386389.2025.2515766

Bender, E. M. & Friedman, B. (2018). Data Statements for Natural Language Processing: Toward Mitigating System Bias and Enabling Better Science. *Transactions of the Association for Computational Linguistics*, 6, s. 587–604.
doi:10.1162/tacl_a_00041

Bergström, E., Karlsson, F. & Åhlfeldt, R.-M. (2021). Developing an information classification method. *Information and Computer Security*, 29(2), s. 209–239.
doi:10.1108/ICS-07-2020-0110

Bhati, D., Fnu, N., Bandaru, D. S., Weber, M. & Gajera, I. D. (2026). Mapping the LLM Landscape: A Cross-Family Survey of Architectures, Alignment Methods, and Benchmark Performance. *AI*, 7(4), s. 142–165.
doi:10.3390/ai7040142

Braun, V. & Clarke, V. (2006). Using thematic analysis in psychology. *Qualitative Research in Psychology*, 3(2), s. 77–101.
doi:10.1191/1478088706qp063oa

Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I. &

Amodei, D. (2020). Language Models are Few-Shot Learners. I: *Advances in Neural Information Processing Systems*. Curran Associates, Inc., s. 1877–1901.

Buschmann, F., Meunier, R., Rohnert, H., Sommerlad, P. & Stal, M. (1996). *Pattern-Oriented Software Architecture: A System of Patterns*. Chichester: Wiley.

Cavoukian, A. (2009). *Privacy by Design: The 7 Foundational Principles*. Toronto, Canada: Information and Privacy Commissioner of Ontario.

Cavoukian, A., Taylor, S. & Abrams, M. E. (2010). Privacy by Design: essential for organizational accountability and strong business practices. *Identity in the Information Society*, 3(2), s. 405–413.
doi:10.1007/s12394-010-0053-z

Chaplia, O. & Klym, H. (2025). Private Microservice with Retrieval-Augmented Generation and Embedded LLM. *Baltic Journal of Modern Computing*, 13(3), s. 720–739.
doi:10.22364/bjmc.2025.13.3.09

Creswell, J. W. & Poth, C. N. (2018). *Qualitative Inquiry and Research Design: Choosing Among Five Approaches*. SAGE Publications.

Europaparlamentets och rådets förordning (EU) 2016/679 av den 27 april 2016 om skydd för fysiska personer med avseende på behandling av personuppgifter och om det fria flödet av sådana uppgifter och om upphävande av direktiv 95/46/EG (allmän dataskyddsförordning) (EUT L 119, 4.5.2016, s. 1–88). https://eur-lex.europa.eu/legal-content/SV/TXT/?uri=CELEX:32016R0679

Explosion AI (u.å.). *Swedish · spaCy Models Documentation*. Swedish. https://spacy.io/models/sv#sv_core_news_lg [2026-05-18].

Gamma, E., Helm, R., Johnson, R. & Vlissides, J. (1994). *Design Patterns: Elements of Reusable Object-Oriented Software*. Reading, MA: Addison-Wesley.

Google (2026). *Gemini Developer API | Gemma open models*. Google AI for Developers. https://ai.google.dev/ [2026-05-18].

Gregor, S., Chandra Kruse, L. & Seidel, S. (2020). Research Perspectives: The Anatomy of a Design Principle. *Journal of the Association for Information Systems*, 21(6), s. 2. doi:10.17705/1jais.00649

Gregor, S. & Hevner, A. R. (2013). Positioning and Presenting Design Science Research for Maximum Impact. *MIS Quarterly*, 37(2), s. 337–355.

Gregor, S. & Jones, D. (2007). The Anatomy of a Design Theory. *Journal of the Association for Information Systems*, 8(5), s. 312-323,325-335.

He, L., Zhang, H., Liu, J., Sun, K. & Zhang, Q. (2024). Zero-Shot Relation Triplet Extraction via Knowledge-Driven LLM Synthetic Data Generation. I: Huang, D.-S., Si, Z., & Zhang, C. (red.) *Advanced Intelligent Computing Technology and Applications*. Singapore: Springer Nature, s. 329–340.

Henriques, L., Guimarães, N. & Jorge, A. (2026). LLM–Based Framework for Synthetic Data Generation in Portuguese Clinical NER. I: Valente de Oliveira, J., Leite, J., Rodrigues, J., Dias, J., & Cardoso, P. (red.) *Progress in Artificial Intelligence*. Cham: Springer Nature Switzerland, s. 335–347.

Hevner, A. R. (2007). A Three Cycle View of Design Science Research. *Scandinavian Journal of Information Systems*, 19(2), s. 87-92.

Hevner, A. R., March, S. T., Park, J. & Ram, S. (2004). Design Science in Information Systems Research. *MIS Quarterly*, 28(1), s. 75–105.
doi:10.2307/25148625

Honnibal, M., Montani, I., Van Landeghem, S. & Boyd, A. (2020). spaCy: Industrial-strength Natural Language Processing in Python.

Huntley, G. (2025). *Ralph Wiggum as a "software engineer"*. Geoffrey Huntley. https://ghuntley.com/ralph/ [2026-05-24].

Integritetsskyddsmyndigheten (2025). *Integritetsskyddsmyndigheten | IMY*. https://www.imy.se/verksamhet/dataskydd/det-har-galler-enligt-gdpr/introduktion-till-gdpr/ [2026-05-10].

ISO 13616-1:2020. *Financial services - International bank account number (IBAN) - Part 1: Structure of the IBAN*. International Organization for Standardization (ISO).
ISO/IEC 7812-1:2017. *Identification cards - Identification of issuers - Part 1: Numbering system.* International Organization for Standardization (ISO) och International Electrotechnical Commission (IEC).

Johannesson, P. & Perjons, E. (2014). *An Introduction to Design Science*. Cham: Springer Nature.

Karras, A., Theodorakopoulos, L., Karras, C., Theodoropoulou, A., Kalliampakou, I. & Kalogeratos, G. (2025). LLMs for Cybersecurity in the Big Data Era: A Comprehensive Review of Applications, Challenges, and Future Directions. *Information, 16(11), Artikel 957.*
doi:10.3390/info16110957

Kojima, T., Gu, S. (Shane), Reid, M., Matsuo, Y. & Iwasawa, Y. (2022). Large Language Models are Zero-Shot Reasoners. *Advances in Neural Information Processing Systems*, 35, s. 22199–22213.

Kvale, S. & Brinkmann, S. (2015). *InterViews: learning the craft of qualitative research interviewing*. 3 uppl. Los Angeles: Sage Publications.

Li, Z. S., Werner, C., Ernst, N. & Damian, D. (2022). Towards privacy compliance: A design science study in a small organization. *Information and Software Technology*, 146, s. 106868.
doi:10.1016/j.infsof.2022.106868

Lison, P., Pilán, I., Sanchez, D., Batet, M. & Øvrelid, L. (2021). Anonymisation Models for Text Data: State of the art, Challenges and Future Directions. I: Zong, C., Xia, F., Li, W., &

Navigli, R. (red.) *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Presenterad vid ACL-IJCNLP 2021, Online: Association for Computational Linguistics, s. 4188–4203.

Liu, P., Yuan, W., Fu, J., Jiang, Z., Hayashi, H. & Neubig, G. (2023). Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing. *ACM Computing Surveys*, 55(9), s. 1–35.
doi:10.1145/3560815

Lorè, F., Basile, P., Appice, A., de Gemmis, M., Malerba, D. & Semeraro, G. (2023). An AI framework to support decisions on GDPR compliance. *Journal of Intelligent Information Systems*, 61(2), s. 541–568.
doi:10.1007/s10844-023-00782-4

Luhn, H. P. (1960). *Computer for verifying numbers*. United States Patent and Trademark Office: US2950048A, 1960-08-23.

Löbner, S., Serna, J., Tronnier, F., Tesfay, W. & Rannenberg, K. (2025). Mitigating Bias in Recruitment: A Practical Approach to CV De-identification Considering Privacy Sensitive Information. I: Coppens, B., Volckaert, B., Naessens, V., & De Sutter, B. (red.) *Availability, Reliability and Security*. Cham: Springer Nature Switzerland, s. 174–192.

March, S. T. & Smith, G. F. (1995). Design and natural science research on information technology. *Decision Support Systems*, 15(4), s. 251–266.
doi:10.1016/0167-9236(94)00041-2

Martin, R. C. (2003). *Agile software development: principles, patterns, and practices*. Upper Saddle River, NJ: Prentice Hall.

Mishra, K., Pagare, H. & Sharma, K. (2025). A hybrid rule-based NLP and machine learning approach for PII detection and anonymization in financial documents. *Scientific Reports*, 15(1), s. 22729–27.
doi:10.1038/s41598-025-04971-9

Myers, M. D. & Newman, M. (2007). The qualitative interview in IS research: Examining the craft. *Information and Organization*, 17(1), s. 2–26.
doi:10.1016/j.infoandorg.2006.11.001

Ollama (u.å.). *Ollama*. https://ollama.com [2026-05-18].

Opitz, J. (2024). A Closer Look at Classification Evaluation Metrics and a Critical Reflection of Common Evaluation Practice. *Transactions of the Association for Computational Linguistics*, 12, s. 820–836.
doi:10.1162/tacl_a_00675

Patton, M. Q. (1999). Enhancing the quality and credibility of qualitative analysis. *Health Services Research*, 34(5 Pt 2), s. 1189–1208.

Patton, M. Q. (2015). *Qualitative research & evaluation methods: integrating theory and practice*. 4 uppl. Thousand Oaks: SAGE Publications, Inc.

Peffers, K., Tuunanen, T., Rothenberger, M. A. & Chatterjee, S. (2007). A Design Science Research Methodology for Information Systems Research. *Journal of Management Information Systems*, 24(3), s. 45–77.

Petrolini, M., Cagnoni, S. & Mordonini, M. (2022). Automatic Detection of Sensitive Data Using Transformer- Based Classifiers. *Future Internet*, 14(8), s. 228. doi:10.3390/fi14080228

Pilán, I., Lison, P., Øvrelid, L., Papadopoulou, A., Sánchez, D. & Batet, M. (2022). The Text Anonymization Benchmark (TAB): A Dedicated Corpus and Evaluation Framework for Text Anonymization. *Computational Linguistics*, 48(4), s. 1053–1101. doi:10.1162/coli_a_00458

Plotly (u.å.). *Dash Documentation & User Guide | Plotly*. https://dash.plotly.com/ [2026-05-18].

Qwen Team (2025). *Qwen Studio*. https://qwen.ai/blog?id=qwen3 [2026-05-18].

Sein, M., Henfridsson, O., Purao, S., Rossi, M. & Lindgren, R. (2011). Action Design Research. *Management Information Systems Quarterly*, 35(1), s. 37–56.

Shi, J., Guo, Q., Liao, Y., Wang, Y., Chen, S. & Liang, S. (2024). Legal-LM: Knowledge Graph Enhanced Large Language Models for Law Consulting. I: Huang, D.-S., Si, Z., & Zhang, C. (red.) *Advanced Intelligent Computing Technology and Applications*. Singapore: Springer Nature, s. 175–186.

Sokolova, M. & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), s. 427–437. doi:10.1016/j.ipm.2009.03.002

Thaldar, D. (2025). Data visiting governance: a conceptual framework. *Human Genomics*, 20(1), s. 11. doi:10.1186/s40246-025-00864-0

Venable, J., Pries-Heje, J. & Baskerville, R. (2016). FEDS: a Framework for Evaluation in Design Science Research. *European Journal of Information Systems*, 25(1), s. 77–89. doi:10.1057/ejis.2014.36

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q. V. & Zhou, D. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *Advances in Neural Information Processing Systems*, 35, s. 24824–24837

Wieringa, R. J. (2014). *Design Science Methodology for Information Systems and Software Engineering*. Berlin, Heidelberg: Springer Nature.

Ågerfalk, P. J. & Karlsson, F. (2020). Artefactual and empirical contributions in information systems research. *European journal of information systems*, 29(2), s. 109–113.

doi:10.1080/0960085X.2020.1743051

Bilaga A - Annoteringsguider

A.1 Annoteringsguide för Article9Layer (Lager 3)

1. Syfte och avgränsning

Guiden definierar vilka textavsnitt som ska klassificeras som artikel 9-data vid manuell granskning av testdataset. Den användes vid konsensus-granskning av LLM-genererade kandidater och utgjorde auktoritativ referens vid avvikelser mellan granskarna. Avgränsningen följer artefaktens lagerstruktur. Artikel 4-data (namn, personnummer, kontaktuppgifter) hanteras av Lager 1 och Lager 2. Pusselbitseffekten hanteras av Lager 4 enligt en separat guide (A.2). Övriga integritetskänsliga personuppgifter som löneuppgifter, lagöverträdelser och skyddad identitet ligger utanför Article9Layers scope.

2. Juridisk grund

Artikel 9.1 GDPR förbjuder behandling av personuppgifter som avslöjar ras eller etniskt ursprung, politiska åsikter, religiös eller filosofisk övertygelse, fackmedlemskap, genetiska uppgifter, biometriska uppgifter för identifiering, hälsa, samt sexualliv eller sexuell läggning. EU-domstolens dom i mål C-184/20 (OT-domen, 1 augusti 2022, ECLI:EU:C:2022:601) preciserar i punkt 123 att även uppgifter som indirekt via slutledning avslöjar känslig kategori omfattas av artikel 9.1. Domens paradigmatiska exempel är att namnuppgifter om make eller sambo kan avslöja sexuell läggning.

Tre frågor avgör om en passage är artikel 9-data:

1. Handlar uppgiften om en specifik fysisk person?
2. Avslöjar uppgiften, direkt eller via rimlig slutledning, något om personens egenskap eller tillstånd?
3. Är personen identifierad eller identifierbar i sammanhanget?

Endast om svaret är ja på alla tre är det artikel 9-data. Generella förhållanden, organisationsfakta och projekt är inte artikel 9-data även om kategoriord förekommer i texten.

3. Kategorier

Kategori	Definition	Ingår	Ingår inte
Hälsa	Diagnoser, symptom, sjukdomshistoria, funktionshinder, hälsovårdskontakt som avslöjar hälsofråga	"Anders är sjukskriven sedan måndag"; "Maria går till företagshälsan"	"Anna arbetar som sjuksköterska"; "Vi utvecklar en hälsoapp"

Etniskt ursprung	Direkt eller indirekt angivelse via kulturell, språklig eller härkomstbaserad markör	"Ahmed tillhör tigrinya-folket"; "Familjen har bott i samebyn i tre generationer"	"Per är svensk medborgare"; "Anna kommer från Stockholm"
Politisk åsikt	Partimedlemskap, kandidatur, direkta ställningstaganden, politisk aktivism om specifik person	"Lars är medlem i Socialdemokraterna"; "Han röstade nej i folkomröstningen"	"Vi måste tänka på politiska aspekter"; "Hon arbetar med miljöpolitik"
Religiös övertygelse	Religionstillhörighet, församlingsmedlemskap, religiös praktik eller attribut kopplade till specifik person	"Fatima bär hijab"; "Hon är medlem i Sankt Eriks katolska församling"	"Vi har en julgran i lobbyn"; "Anders ska gifta sig i kyrkan" (kulturellt default i Sverige)
Fackmedlemskap	Medlemskap, förtroendeuppdrag, fackrelaterad aktivitet kopplad till namngiven person	"Joakim är medlem i Unionen"; "Anna är vald till skyddsombud"	"Vi har kollektivavtal med Unionen"; "Föreningens fackmedlemmar bör informeras"
Genetisk data	DNA-analyser, gentester, genetisk sjukdomsrisk om specifik person	"Erik har en genetisk predisposition för bröstcancer"; "Sjukdomen är ärftlig i hennes familj"	"Vi forskar på genetisk variation"; "Det ligger i släkten att vi blir lärare"
Biometrisk data	Biometri använd för identifiering av specifik person (fingeravtryck, ansiktsigenkänning, irisskanning)	"Anders fingeravtryck registrerades i passersystemet"; "Annas face-ID fungerar bra"	"Vi använder ansiktsigenkänning för inloggning"; "Bilder från övervakningskameran sparas"
Sexuell läggning	Direkt angivelse, indirekt avslöjande via partner eller bostadssituation, HBTQ-engagemang om specifik person	"Hans man hämtade honom"; "Anders bor med sin pojkvän"; "Hon är aktiv i RFSL"	"Annas make ringde" (hetero-default avslöjar inte); "Anna är jurist på en HBTQ-organisation"

Tabell A.1: De åtta kategorierna i artikel 9.1 GDPR med definition och avgränsningsexempel.

4. Övergripande gränsdragningsprinciper

Sex principer löser merparten av gränsfallen och tillämpas i tur och ordning.

Princip 1. Artikel 9 gäller en identifierad eller identifierbar fysisk person. Generella kategoridiskussioner är inte artikel 9-data oavsett ordval.

Princip 2. Uppgiften måste avslöja personens egenskap eller tillstånd, antingen direkt eller via rimlig slutledning enligt OT-domen.

Princip 3. Yrke är inte tillstånd. En sjuksköterska har inte hälsodata om sig själv genom sitt yrke. En facklig ombudsman som själv är fackmedlem är gränsfall som avgörs i kontext.

Princip 4. Geografi och nationalitet är inte etnicitet. Hemvist, ursprungsland och medborgarskap är inte automatiskt etniskt ursprung; etnicitet kräver kulturell, språklig eller härkomstbaserad markör.

Princip 5. System är inte data om person. Att en organisation använder biometriska eller hälsosystem är inte artikel 9-data om en specifik individ. Först när systemet kopplas till en namngiven person blir uppgifterna artikel 9.

Princip 6. Default-antaganden avslöjar inte. Uppgifter som överensstämmer med samhällets default (heteronorm, sekularitet i Sverige för kyrkligt giftermål) avslöjar inget i lagens mening. Bara avvikelser från default avslöjar.

5. Tillämpning vid granskning

Granskaren läser hela texten och identifierar vilka personer som nämns samt vilka uppgifter som framkommer om dem. För varje passage som kan vara artikel 9-data tillämpas de tre frågorna från sektion 2. Vid tvekan används principerna i sektion 4. Om bedömningen fortfarande är oklar markeras passagen som diskussionsfall och tas upp i konsensus-mötet. Det vanligaste felet i LLM-genererade kandidater är att kategoriord nämns utan att verklig artikel 9-data finns; sådana fynd stryks.

6. Begränsningar

Guiden är en operativ tolkning baserad på lagtexten i artikel 9.1 GDPR, IMY:s vägledning om känsliga personuppgifter, och EU-domstolens dom i mål C-184/20 (OT-domen). Den är inte juridisk auktoritet och ersätter inte juridisk granskning vid faktisk behandling av artikel 9-data. Rättspraxis efter OT-domen som kan ytterligare precisera tolkningen av indirekt avslöjande har inte beaktats systematiskt. Branschspecifika tolkningar från IMY för vård, skola eller arbetsliv kan precisera eller modifiera den allmänna tolkning som guiden använder.

7. Källor

Europaparlamentets och rådets förordning (EU) 2016/679 (GDPR), artikel 9.1.

EU-domstolens dom av den 1 augusti 2022 i mål C-184/20, OT mot Vyriausioji tarnybinės etikos komisija (ECLI:EU:C:2022:601). Stora avdelningen.

Integritetsskyddsmyndigheten (IMY). Introduktion till GDPR och Känsliga personuppgifter. imy.se.

A.2 Annoteringsguide för CombinationLayer (Lager 4)

1. Syfte och avgränsning

Guiden definierar vilka textavsnitt som ska klassificeras som pusselbitseffekt vid manuell granskning av testdataset. Den användes vid konsensus-granskning av LLM-genererade kandidater och utgjorde auktoritativ referens vid avvikelser mellan granskarna. Avgränsningen följer artefaktens lagerstruktur. Direkta personuppgifter enligt artikel 4 (personnummer, e-post, telefonnummer, IBAN, kortnummer) hanteras av Lager 1. Personnamn och fullständiga adresser hanteras av Lager 2. Artikel 9-data hanteras av Lager 3 enligt en separat guide (A.1). Det som annoteras enligt denna guide är textavsnitt som i kombination kan göra en individ identifierbar utan att direkta identifierare förekommer.

2. Juridisk grund

GDPR skäl 26 fastställer att man vid bedömning av om en uppgift är personuppgift ska ta hänsyn till "alla hjälpmedel [...] som, antingen av den personuppgiftsansvarige eller av en annan person, rimligen kan komma att användas för att direkt eller indirekt identifiera den fysiska personen". Artikel 4.1 definierar personuppgift som varje upplysning som avser en identifierad eller identifierbar fysisk person, där identifierbarhet kan ske direkt eller indirekt via en eller flera faktorer som är specifika för individens identitet.

EU-domstolens dom i mål C-582/14 (Patrick Breyer mot Bundesrepublik Deutschland, ECLI:EU:C:2016:779) klargjorde att även information som kräver att flera källor kombineras kan utgöra personuppgift. Domstolen slog fast att detta inte kräver att identifieringen är möjlig för den personuppgiftsansvarige ensam, utan räcker med att den är möjlig genom kombination av tillgängliga uppgifter. Detta stödjer pusselbitseffektens centrala antagande att signaler vars enskilda informationsvärde är lågt kan, i kombination, möjliggöra identifiering. IMY:s vägledning framhåller att en uppgift i kombination med andra uppgifter kan knytas till en person, vilket motsvarar de tre signaltyper som CombinationLayer detekterar.

3. Signaltyper och specificitetsnivåer

CombinationLayer detekterar tre signaltyper. Varje signal annoteras som ett individuellt fynd med diskret minimalt spann; sammansatta spans tillåts endast för aggregat-fyndet. Varje signal kategoriseras i en av tre specificitetsnivåer baserat på hur mycket den smalnar av populationen.

Signaltyp	Låg specificitet	Mellan specificitet	Hög specificitet
Yrke	Generiska titlar och vanliga yrken: "anställd", "lärare" (utan ämne), "ekonom", "ingenjör"	Specialiserade yrken och generella chefsroller: "barnmorska", "skatterevisor", "avdelningschef"	Seniora eller unika roller: "VD", "rektor", "hovrättsdomare", "lärare i klassisk arabiska"

Plats	Storstadsområden över 200 000 invånare och regioner: Stockholm, Göteborg, Skåne	Städer 30 000–200 000 invånare: Borås, Linköping, Helsingborg	Orter under 30 000 invånare och stadsdelar: Hjo, Linnéstaden, Majorna
Organisation	Riksomfattande myndigheter och multinationella företag: Skatteverket, IKEA, Volvo Cars-koncernen	Regionala aktörer och kommunala förvaltningar: Borås Stad, Sahlgrenska Universitetssjukhuset	Enskilda enheter och små företag: Hvitfeldtska gymnasiets musiklinje, Café Java på Linnégatan

Tabell A.2: Signaltyper och specificitetsnivåer för CombinationLayer.

Utöver de tre signaltyperna används narrativ specificitet som bedömningsdimension. Den annoteras inte som egen signal men ingår i identifierbarhetsbedömningen. Låg narrativ specificitet innebär att texten saknar ledtrådar utöver signalerna. Mellan narrativ specificitet innefattar en tidsmarkör eller demografisk detalj utan unik händelse, exempelvis "den nyanställde som började i höstas". Hög narrativ specificitet innefattar händelsereferenser eller kombinationer som markant smalnar av populationen, exempelvis "den nya HR-chefen som rekryterades efter omorganisationen i augusti".

4. Identifierbarhetsbedömning

Bedömningen är binär och avgör om aggregat-fyndet `context.kombination` ska annoteras. Granskaren identifierar först alla signaler enligt sektion 3 och bedömer specificitetsnivå per signal samt narrativ specificitet. Därefter tillämpas fyra regler i prioritetsordning; första matchande regel avgör utfallet.

Regel A. Minst två signaler med hög specificitet, oavsett signaltyp, ger `is_identifiable=true`. Exempel: "VD på Hvitfeldtska gymnasiets musiklinje" (yrke hög + organisation hög).

Regel B. Tre eller fler signaler med minst mellan specificitet, varav minst en mellan eller hög, ger `is_identifiable=true`. Exempel: "barnmorska på Borås Stads förlossningsavdelning i Borås" (yrke mellan + organisation mellan + plats mellan).

Regel C. Två signaler med minst mellan specificitet i kombination med hög narrativ specificitet ger `is_identifiable=true`. Exempel: "den nya barnmorskan som började i augusti på Borås förlossningsavdelning".

Regel D. Alla andra kombinationer ger `is_identifiable=false`. Detta inkluderar isolerade signaler och kombinationer av enbart lågspecifika signaler.

Om någon av reglerna A–C utlöses annoteras `context.kombination` med ett sammansatt textspann som täcker kombinationen från första till sista signalen. Om Regel D gäller annoteras endast de individuella signalerna utan aggregat-fynd.

5. Tillämpning vid granskning

Granskaren läser hela texten och identifierar alla signaler med signaltyp, textspann och specificitetsnivå. Span-precision är kritisk: alla textspann måste vara exakta substrings av originaltexten utan omgivande skiljetecken. Vid osäkerhet om signaltyp prioriteras organisation före plats och plats före yrke. Sammansatta organisationsnamn som "Volvo Cars Skövde" annoteras som ett spann (organisation), inte två. Vid oenighet mellan granskarna löses avvikelsen mot guidens kriterier, inte via subjektiv kompromiss. Om guiden är otydlig på punkten dokumenteras otydligheten som öppen fråga och guiden revideras inför nästa cykel.

6. Begränsningar

Specificitetskategoriseringen baseras på pragmatiska storlekströsklar för invånarantal och organisationsstorlek snarare än empiriskt validerade gränser. Narrativ specificitet är guidens mest subjektiva dimension och inter-rater agreement förväntas vara lägre på den dimensionen än på de tre signaltyperna. Kombinationsreglerna är deduktivt formulerade utan empirisk validering. Guiden täcker inte fall där pusselbitseffekten uppstår genom kombination med externt kända fakta, exempelvis "min granne som vann lotteriet förra månaden" där grannskapet är extern kunskap. Sådana fall ligger utanför CombinationLayers scope eftersom de inte kan detekteras enbart från textinnehållet.

7. Källor

Europaparlamentets och rådets förordning (EU) 2016/679 (GDPR), skäl 26 och artikel 4.1.

EU-domstolens dom av den 19 oktober 2016 i mål C-582/14, Patrick Breyer mot Bundesrepublik Deutschland (ECLI:EU:C:2016:779).

Integritetsskyddsmyndigheten (IMY). Personuppgiftsbegreppet. imy.se.

Bilaga B - Data statements

Dataseten för designcykel 2 dokumenteras enligt Bender och Friedman (2018), "Data Statements for Natural Language Processing". Ramverket valdes eftersom det strukturerat redovisar ursprung, språklig karaktär, annoterarnas bakgrund, texternas egenskaper och kända begränsningar för annoterade NLP-dataset. Sektion B.1 redovisar egenskaper som är gemensamma för båda dataseten, B.2 och B.3 redovisar datasetspecifika egenskaper, och B.4 sammanfattar kända begränsningar.

B.1 Gemensamma egenskaper

Språk. Svenska (sv-SE), formell och semiformell rikssvensk skriftspråklig text. Texterna efterliknar arbetsplatskommunikation: e-post, chattmeddelanden, interna anteckningar och ärendeloggar. Regionala dialekter och sociolekter förekommer inte systematiskt.

Speaker demographic. Inte tillämpligt. Texterna är syntetiskt genererade av en språkmodell och representerar inga verkliga avsändare.

Annotator demographic. Två svensktalande studenter i sista terminen av kandidatprogrammet Systemarkitektur med inriktning mot programutveckling vid Högskolan i Borås. Båda har genomgått samma grundutbildning i GDPR och datavetenskap. Granskningen genomfördes oberoende av varandra mot annoteringsguiderna (Bilaga A.1 respektive A.2), och avvikelser löstes via guidens kriterier utan subjektiv kompromiss.

Recording quality. Inte tillämpligt. Skriftlig text, ingen ljud- eller bildinspelning.

Datasekretess. Texterna är syntetiska och innehåller inga uppgifter om verkliga personer. Organisationsnamn som förekommer är offentligt kända exempel (exempelvis Skatteverket, Volvo Cars, Sahlgrenska Universitetssjukhuset) och används utan koppling till identifierbara individer.

B.2 Artikel 9-datasetet

Curation rationale. Datasetet konstruerades för att möjliggöra systematisk utvärdering av Article9Layers förmåga att detektera direkt uttryckta särskilda kategorier av personuppgifter enligt artikel 9.1 GDPR. En hybridmetod besläktad med Pilán et al. (2022) tillämpades, dock i en annan modalitet: medan Pilán et al. pre-annoterar verklig text med ett NER-verktyg genereras kandidatmaterialet här syntetiskt av en lokal språkmodell (FAS A) och granskas därefter oberoende av två annoterare med konsensuskrav (FAS B).

Text characteristics. Slutdatasetet innehåller 52 texter: 40 positiva och 12 negativa kontroller. Texterna är 105 till 440 tecken långa (medel 212, median 202; positiva 120 till 440, negativa 105 till 217) och innehåller sammanlagt 44 positiva fynd, varav fyra texter innehåller fler än ett fynd. Fördelningen per kategori redovisas i Tabell B.1.

Kategori	Texter	Fynd

article9.halsodata	5	7
article9.etniskt_ursprung	0	0
article9.politisk_asikt	6	6
article9.religios_overtygelse	6	6
article9.fackmedlemskap	6	6
article9.biometrisk_data	6	6
article9.genetisk_data	5	7
article9.sexuell_laggning	6	6
Summa positiva	**40**	**44**

Tabell B.1: Fördelning av artikel 9-kategorier i slutdatasetet.

Granskningsutfall. På de 50 kandidater där båda annoterarna avgav ett definitivt beslut var den strikta enigheten 32 av 50 (64,0 procent). De 12 negativa kontrollerna hade fullständig enighet mellan annoterarna. Konsensusarbetet gav 31 behållna, 5 justerade och 24 strukna kandidater. Tre kategorier (politisk åsikt, religiös övertygelse, sexuell läggning) blev kritiskt underrepresenterade och kompletterades med 16 manuellt genererade kandidater med direkt span-verifiering. En fjärde kategori, etniskt ursprung, gick till noll behållna kandidater då samtliga sex underkändes mot annoteringsguidens princip om att geografi och nationalitet inte avslöjar etnicitet (Bilaga A.1, Princip 4). Kategorin kompletterades inte manuellt och saknar därmed facit-fynd i datasetet.

Generering. Kandidaterna genererades med gemma2:9b via lokal Ollama-instans (temperatur 0,7). Annoteringsguiden injicerades i prompten med kategorispecifika definitioner och gränsdragningsexempel. En tidigare genereringsomgång med qwen2.5:7b-instruct kasserades på grund av systematiska kategoriförväxlingar och icke-idiomatisk svenska.

B.3 CombinationLayer-datasetet

Curation rationale. Datasetet konstruerades för att möjliggöra utvärdering av CombinationLayers förmåga att bedöma pusselbitseffekten enligt GDPR skäl 26. Datasetet täcker fyra strukturella celler enligt annoteringsguiden (Bilaga A.2): tydligt identifierbara kombinationer (Cell 1), gränsfall (Cell 2), negativa kontroller utan signaler (Cell 3) och negativa kontroller med signaler men utan identifierbarhet (Cell 4).

Text characteristics. Slutdatasetet innehåller 27 texter, fördelade enligt Tabell B.2. Texterna är 81 till 270 tecken långa (medel 157, median 155) och innehåller 46 individuella signaler plus 9 aggregat-fynd av typ context.kombination. Samtliga aggregat har is_identifiable=true.

Cell	Texter	Detalj
Cell 1 (identifierbara)	9	Regel A: 4, Regel B: 3, Regel C: 2
Cell 2 (gränsfall)	5	-
Cell 3 (inga signaler)	6	-
Cell 4 (signaler utan identifierbarhet)	7	-
Summa	**27**	

Tabell B.2: Fördelning av strukturella celler i kombinationsdatasetet.

De 46 individuella signalerna fördelar sig på 22 yrke (3 hög, 13 mellan, 6 låg specificitet), 14 plats (1, 5, 8) och 10 organisation (5, 4, 1).

Granskningsutfall. Strikt enighet på beslutsnivå var 22 av 29 (75,9 procent). Konsensusarbetet gav 25 behållna kandidater, varav 21 justerades, och 4 strukna. Två kompletterande Regel C-texter konstruerades manuellt med direkt span-verifiering för att täcka cellens krav om narrativ specificitet.

Generering. Samma generering som artikel 9-datasetet (gemma2:9b via Ollama, temperatur 0,7), med separata körningar per cell-och-regel-kombination. Annoteringsguiden injicerades med versionsspårbarhet via guidens kommithash.

B.4 Kända begränsningar

Saknad kategori. Article9Layers prestanda för article9.etniskt_ursprung kan inte mätas mot detta dataset eftersom kategorin saknar facit-fynd. Konsekvensen för utvärderingen diskuteras i rapportens 7.1.3 och 7.1.4.

Cirkularitet hanterad genom modellfamilje-asymmetri. Genereringsmodellen (gemma2:9b, Google DeepMind) tillhör en annan modellfamilj än utvärderingsmodellen för Article9Layer och CombinationLayer (qwen2.5:7b-instruct under designcykel 2, qwen3:14b under designcykel 3, båda Alibaba). Asymmetrin innebär att utvärderingsmodellen inte bedömer sina egna genereringar, vilket motverkar self-preference-bias; den potentiella, oprövade risken att en utvärderingsmodell är partisk mot modeller med liknande arkitektur lyfts av Anghel et al. (2025).

Cell 2-cirkularitet. Gränsfallen i CombinationLayer-datasetet genererades automatiskt, inte manuellt konstruerade. Eftersom både genererings- och utvärderingsmodellen har sett guidens regler finns en cirkularitetsrisk i den efterföljande tröskelkalibreringen. Begränsningen accepterades pragmatiskt och dokumenteras som potentiell förbättring för framtida arbete.

Datavolym. Dataseten är små i jämförelse med modern NLP-praxis (52 plus 27 texter). Utvärderingen är därför formativ snarare än summativ och ger indikation om prestanda och underlag för designbeslut, inte statistiskt robusta mått. Detta är konsistent med studiens DSR-positionering där datasetet är instrument för designkunskap, inte slutgiltig benchmark.

Narrativ specificitet som subjektiv dimension. Annoteringsguidens dimension narrativ specificitet är guidens mest tolkningsberoende komponent. Inter-rater agreement förväntas vara lägre på den dimensionen än på de tre signaltyperna.

Aggregat-spans följer mekanisk regel. Aggregat-fynden (context.kombination) följer en min/max-regel där spannet täcker textintervallet från första till sista signal. Detta innebär att Regel C-bedömningar vars identifierbarhet drivs av narrativ specificitet får aggregat-spans avgränsade till signalpositionerna även när den narrativa kontexten ligger utanför dessa.

Bilaga C - Promptversioner

Bilagan dokumenterar de produktionsaktiva prompts som användes i designcykel 3:s slutmätning för de två LLM-baserade lagren i Aegis, återgivna ordagrant från de versionerade YAML-filerna i repot. Metodologin för promptkonstruktion (probabilistisk mekanism enligt Liu et al., 2023; few-shot enligt Brown et al., 2020; chain-of-thought enligt Wei et al., 2022; komponentbaserad grundstruktur enligt He et al., 2024) redovisas i Sektion 4.1.4. Versionshistoriken och iterativa förfiningar dokumenteras i Sektion 5.4.2 (designcykel 2) och Sektion 5.5.2 (designcykel 3, inklusive v6-experimentet och rollback för Article9Layer).

Promptarna versioneras som YAML-filer i `gdpr_classifier/prompts/article9/` respektive `gdpr_classifier/prompts/combination/`. Varje fil innehåller ett metadata-block samt en system_prompt och fem komponenter som assembleras vid inferens till promptobjektet: task_instruction, context, reasoning_instructions, examples och output_format. För att möjliggöra fullständig reproducerbarhet redovisas samtliga delar ordagrant nedan inklusive alla few-shot-exempel.

C.1 Article9Layer v5

Metadata

- Version: v5
- Skapad: 2026-05-03
- Källor: Liu et al. (2023), Brown et al. (2020), He et al. (2024), Karras et al. (2025), Petrolini, Cagnoni & Mordonini (2022)
- Anteckning: v5 inför strängare negativa gränsfall för halsodata. Vaga fraser ("sökt för besvär", "dina besvär"), subjektiva humörobservationer och yrkesroller inom vård klassas inte som halsodata.

System prompt

> Du är en GDPR-klassificerare vars uppgift är att identifiera direkt uttryckta artikel 9-kategorier i svensk text. Din uppgift är ENBART att extrahera explicita omnämnanden av dessa kategorier. Du ska INTE bedöma om personen är identifierbar (det görs i ett annat steg) och du ska INTE detektera artikel 4-data (som namn, adress, kontaktuppgifter).

Task instruction

> Din uppgift är att hitta och kategorisera explicita omnämnanden av följande artikel 9-data i texten:
>
> - halsodata: Information om en persons fysiska eller psykiska hälsotillstånd, diagnoser, symptom, behandlingar, sjukvårdsbesök eller medicinering. Innefattar även yrkesskada/arbetsskada och matförgiftning om de anges som medicinskt tillstånd hos en person. INTE halsodata: att "ringa in sjuk" utan medicinsk detalj, att arbeta inom vård som yrkesroll, vaga fraser utan specificerad diagnos eller sjukdom ("sökt för samma besvär", "dina besvär"), subjektiva observationer om humör eller energinivå ("verkar lite låg i energi", "verkar trött"), eller yrkesroller inom sjukvård (sjuksköterska, läkare). Det är den behandlade personens hälsodata som

räknas, inte yrkesutövarens närvaro.

- genetisk_data: Genetiska uppgifter från DNA-analys, genetiska tester eller ärftlighetsutredningar. Innefattar genetisk risk/predisposition, nedärvda tillstånd och kromosomavvikelser. VIKTIGT: En genetisk predisposition eller risk (t.ex. "risk att utveckla X", "predisponering för Y", "ärftlig sjukdom") är genetisk_data, INTE halsodata, även om sjukdomen i sig är en hälsofråga.

- etniskt_ursprung: Ras eller etniskt ursprung. VIKTIGT: Ett arabiskt, afrikanskt eller utländskt klingande namn i sig utgör INTE ett etniskt ursprung-fynd. Religiöst utövande (moské, kyrka, synagoga, fredagsbön) är religios_overtygelse, INTE etniskt_ursprung, även om personen har ett namn som antyder ett visst ursprung.

- politisk_asikt: Politiska åsikter eller partitillhörighet.

- religios_overtygelse: Religiös eller filosofisk övertygelse, inklusive religiöst utövande och religiös tillhörighet. Religiöst utövande och religiös tillhörighet (deltagande i moské, kyrka, fredagsbön, synagoga, tempel, etc.) är alltid religios_overtygelse, oavsett om personens namn antyder ett visst etniskt ursprung.

- fackmedlemskap: Medlemskap i fackförening eller betalning av fackavgift.

- biometrisk_data: Biometriska uppgifter för att unikt identifiera en person. Extrahera den faktiska biologiska datapunkten: fingeravtryck, ansiktet (specifik persons ansikte), röstavtrycket, retina, iris. INTE en systembeskrivning: "det nya biometriska låssystemet", "ansiktsigenkänningskameran", "biometrisk inloggning" är tekniska lösningar och extraheras inte om inte texten också nämner den faktiska biologiska datapunkten separat. Biometrisk_data kan förekomma även utan att en namngiven person kopplas till uppgiften (t.ex. "Vi använder fingeravtryck för inpassering").

- sexuell_laggning: Sexuellt liv eller sexuell läggning. Innefattar BÅDE explicita omnämnanden OCH tydliga implicita indikationer som framgår av kontexten, exempelvis: referens till en persons samkönade partner (t.ex. "sin flickvän" om personen är en kvinna, "sin pojkvän" om personen är en man, "sin man/fru" i samkönat sammanhang), deltagande i Pride-paraden som HBTQ+-identitet, eller samkönat äktenskap/vigsel.

Om du hittar sådana data, måste du returnera den EXAKTA strängen från originaltexten som "text_span". Hitta inte på egna fraser, och inkludera inte onödig kontext. Gör ingen parafrasering.

Context

Enligt GDPR Artikel 9 gäller ett generellt förbud mot behandling av särskilda kategorier av personuppgifter (känsliga uppgifter). Du ska enbart leta efter direkt information som faller inom dessa kategorier. Tänk på "pusselbitseffekten": ibland kan indirekt information tillsammans utgöra känsliga uppgifter, men ditt uppdrag är ENDAST att göra en DIREKT detektion av det som står uttryckligen eller tydligt framgår av kontexten. Försök inte kombinera information för att dra slutsatser.

Reasoning instructions

Läs igenom texten noggrant. Identifiera alla explicita (eller tydligt implicita) omnämnanden av de 8 artikel 9-kategorierna. För varje omnämnande, extrahera den exakta textsträngen ("text_span") från originaltexten. Skapa en lista med fynd enligt det angivna JSON-schemat. Om texten saknar artikel 9-data, returnera en tom lista.

Few-shot examples

Promptens 19 few-shot-exempel återges nedan ordagrant i formatet input, output, rationale.

Exempel 1. Input: "Patienten uppger att hon har varit medlem i Svenska kyrkan sedan barnsben, och har på sistone haft problem med diabetes typ 2."

Output:


```
{
   "findings": [
     {
       "category": "religios_overtygelse",
       "text_span": "medlem i Svenska kyrkan",
       "confidence": 0.95
     },
     {
       "category": "halsodata",
       "text_span": "diabetes typ 2",
       "confidence": 0.99
     }
   ]
 }
```


Rationale: Texten innehåller tydliga omnämnanden av religiös övertygelse ("medlem i Svenska kyrkan") och hälsodata ("diabetes typ 2").

Exempel 2. Input: "Sven Svensson bor på Storgatan 1 och kan nås på sven@example.com."

Output:

```
{
   "findings": []
}
```

Rationale: Texten innehåller enbart namn och adress (artikel 4-data). Ingen artikel 9-data finns. Därför returneras en tom lista.

Exempel 3. Input: "Johanna arbetar som sjuksköterska på akademiska sjukhuset i Uppsala."

Output:

```
{
   "findings": []
}
```

Rationale: Att arbeta som sjuksköterska är en yrkesroll och innebär inte i sig att personen har några specifika hälsodata eller är patient. Ingen artikel 9-data.

Exempel 4. Input: "Det genetiska testet visade att du har en predisponering för diabetes typ 2, men det betyder inte att du kommer att insjukna."

Output:

```
{
   "findings": [
    {
      "category": "genetisk_data",
      "text_span": "en predisponering för diabetes typ 2",
      "confidence": 0.97
    }
  ]
}
```

Rationale: En genetisk predisposition som framkommer via genetiskt test klassificeras som genetisk_data, inte halsodata, även om sjukdomen i sig är en hälsofråga. Texten anger explicit att det rör sig om ett genetiskt test.

Exempel 5. Input: "Anna jobbade som genetisk rådgivare på ett privat företag. En klient, Lars, hade genomgått en genetisk analys och fick besked att han har en högre risk att utveckla Parkinsons sjukdom än genomsnittet."

Output:

```
{
   "findings": [
     {
       "category": "genetisk_data",
       "text_span": "har en högre risk att utveckla Parkinsons
sjukdom än genomsnittet",
       "confidence": 0.96
     }
   ]
 }
```

Rationale: Genetisk risk/predisposition (från genetisk analys) klassificeras som genetisk_data. Anna är yrkesperson, inte patient, och hennes roll skapar inte halsodata. Lars genetiska risk är det känsliga fyndet.

Exempel 6. Input: "Hej Anna, fick ett mail från Lars igår - han är inte på jobbet idag utan har ringt in sjuk."

Output:

```
{
   "findings": []
}
```

Rationale: Att "ringa in sjuk" är en arbetsrelaterad handling utan specifik medicinsk information. Ingen diagnos, symptom eller behandling anges. Detta är inte halsodata.

Exempel 7. Input: "Hej Johan, Lycka till på din vigsel imorgon! Hoppas dagen med Marcus blir allt ni har drömt om."

Output:

```
{
   "findings": [
     {
       "category": "sexuell_laggning",
       "text_span": "din vigsel imorgon! Hoppas dagen med
Marcus",
       "confidence": 0.90
     }
   ]
 }
```

Rationale: Det framgår tydligt av kontexten att Johan (ett manligt namn) och Marcus ska gifta sig, vilket indikerar en samkönad relation och därmed sexuell läggning.

Exempel 8. Input: "Hej Lars! Jag såg att du var med på Pride-paraden i Stockholm igår. Var det kul?"

Output:

```
{
   "findings": [
     {
       "category": "sexuell_laggning",
       "text_span": "Pride-paraden",
       "confidence": 0.85
     }
   ]
 }
```

Rationale: Deltagande i Pride-paraden är en tydlig indikation på HBTQ+-identitet eller stöd för HBTQ+-rörelsen och klassificeras som sexuell läggning.

Exempel 9. Input: "Han röstade på Vänsterpartiet i förra valet."

Output:

```
{
   "findings": [
     {
       "category": "politisk_asikt",
       "text_span": "röstade på Vänsterpartiet",
       "confidence": 0.98
     }
   ]
 }
```

Rationale: Explicit omnämnande av politisk åsikt och röstbeteende.

Exempel 10. Input: "Ahmed har meddelat att han är aktiv i den lokala moskéförsamlingen."

Output:

```
{
   "findings": [
     {
       "category": "religios_overtygelse",
       "text_span": "aktiv i den lokala moskéförsamlingen",
       "confidence": 0.95
     }
```

```
    ]
  }
```

Rationale: Aktivt deltagande i en moskéförsamling är religiöst utövande och klassificeras som religios_overtygelse oavsett personens namn. Personens namn (Ahmed) indikerar inte etniskt ursprung i sig. Att klassa detta som etniskt_ursprung vore ett fel.

Exempel 11. Input: "Det nya biometriska låssystemet registrerar det inte alltid Annas ansikte korrekt."

Output:

```
{
  "findings": [
    {
      "category": "biometrisk_data",
      "text_span": "Annas ansikte",
      "confidence": 0.92
    }
  ]
}
```

Rationale: Den faktiska biometriska datapunkten är "Annas ansikte". "Det nya biometriska låssystemet" är en systembeskrivning och extraheras inte som text_span.

Exempel 12. Input: "Vi använder fingeravtryck för att säkra inpasseringen till serverrummet."

Output:

```
{
  "findings": [
    {
      "category": "biometrisk_data",
      "text_span": "fingeravtryck",
      "confidence": 0.90
    }
  ]
}
```

Rationale: Fingeravtryck är en biometrisk datapunkt även om ingen namngiven person kopplas till den. Det räcker att biometrisk data behandlas för att klassificera som biometrisk_data.

Exempel 13. Input: "Han lämnade mötet tidigt för att hinna med fredagsbönen."

Output:

```
{
   "findings": [
     {
       "category": "religios_overtygelse",
       "text_span": "fredagsbönen",
       "confidence": 0.93
     }
   ]
 }
```


Rationale: Fredagsbön är ett islamiskt religiöst utövande och klassificeras som religios_overtygelse.

Exempel 14. Input: "Maria är sjukskriven efter en arbetsskada och Kalle drabbades av matförgiftning under resan."

Output:


```
{
   "findings": [
     {
       "category": "halsodata",
       "text_span": "arbetsskada",
       "confidence": 0.88
     },
     {
       "category": "halsodata",
       "text_span": "matförgiftning",
       "confidence": 0.92
     }
   ]
 }
```


Rationale: Arbetsskada och matförgiftning är medicinska tillstånd som anges hos namngivna personer och klassificeras som halsodata.

Exempel 15. Input: "Hej, jag har sökt för samma besvär hos er tidigare."

Output:


```
{
```

```
  "findings": []
}
```

Rationale: En vag klagan ("sökt för samma besvär") utan angiven diagnos, symptom eller medicinsk information är inte halsodata. Frasen beskriver ett besöksmönster, inte ett hälsotillstånd.

Exempel 16. Input: "Jag förstår att dina besvär är besvärliga och att du vill ha hjälp snabbt." Output:

```
{
  "findings": []
}
```

Rationale: "Dina besvär" är en pronominell referens utan medicinsk information, ingen diagnos, sjukdom eller symptom anges. Det är inte halsodata.

Exempel 17. Input: "Hon verkar lite låg i energi idag, kanske behöver hon en kopp kaffe." Output:

```
{
  "findings": []
}
```

Rationale: En subjektiv observation om humör eller energinivå ("verkar lite låg i energi") är inte ett medicinskt hälsotillstånd. Ingen diagnos eller symptom anges. Det är inte halsodata.

Exempel 18. Input: "Lars har ringt in sjuk och kommer inte till jobbet idag."

Output:

```
{
  "findings": []
}
```

Rationale: Att ringa in sjuk är en arbetsrelaterad handling utan medicinsk detalj. Ingen diagnos, symptom eller behandling anges. Det är inte halsodata.

Exempel 19. Input: "Sjuksköterskan på intensivvården vid Sahlgrenska tog emot patienten vid ankomst."

Output:

```
{
  "findings": []
}
```

Rationale: Sjuksköterskan nämns i sin yrkesroll, och hennes närvaro och funktion är inte hälsodata. Det är den behandlade personens hälsodata som räknas, och texten anger inga sådana uppgifter om patienten. Ingen artikel 9-data.

Output format

Svara ENBART i följande JSON-format:

```
{
  "findings": [
    {
      "category": "<en av: halsodata, etniskt_ursprung,
politisk_asikt, religios_overtygelse, fackmedlemskap,
biometrisk_data, genetisk_data, sexuell_laggning>",
      "text_span": "<exakt strängcitat från originaltexten>",
      "confidence": <float 0.0 till 1.0>
    }
  ]
}

VIKTIGT: Om det inte finns några fynd SKA "findings" vara en tom
lista: {"findings": []}
```

C.2 CombinationLayer v5

Metadata

- Version: v5
- Skapad: 2026-05-12
- Källor: Liu et al. (2023), Brown et al. (2020), Wei et al. (2022), He et al. (2024), Karras et al. (2025)
- Anteckning: v5 skärper negativa exempel mot verb- och passivkonstruktioner ("leddes av", "protokollfördes av", "eskaleras till") som tidigare hallucinerades som yrke trots blocklista i v4. Förstärkt personnamnsförbud med explicit negativt exempel. Två empiriskt identifierade organisationshallucineringsmönster tillagda: e-postadresser och e-postdomäner samt avdelningar och delarbetsplatser (vårt kontor, huvudkontoret, IT-avdelningen). Behåller v4:s system_prompt, context och output_format ordagrant.

System prompt

Du är en GDPR-bedömare vars uppgift är att identifiera om indirekt information i svensk text kan göra en individ identifierbar. Du ska fokusera på "pusselbitseffekten" enligt skäl 26 i GDPR. Det innebär att uppgifter som i sig inte är personuppgifter (t.ex. yrke, organisation eller plats) tillsammans kan göra att en specifik person kan identifieras. Du MÅSTE svara på och hantera svensk text. Det är extremt viktigt att svensk språkkonsistens upprätthålls.

Task instruction

Identifiera kontextsignaler ("yrke", "plats", "organisation") och bedöm om de tillsammans gör en individ identifierbar utan direkta personuppgifter.

Extrahera följande signaltyper ENBART om de uppfyller kriterierna nedan:

- yrke: En specifik yrkesroll, titel eller funktion (t.ex. "rektor", "systemutvecklare", "enhetschef"). INTE ett yrke: personnamn, relationsord (pojkvän, flickvän, kollega, kund), verb eller passiva konstruktioner ("leddes av", "protokollfördes av", "eskaleras till", "noterade", "är inte på jobbet"), skadetyper eller händelser ("arbetsskada", "händelsen"), religiös aktivitet, fackmedlemskap.

- plats: En namngiven ort, stad, adress eller specifik geografisk plats (t.ex. "Eskilstuna", "Vasagatan 12"). INTE en plats: generiska platsbeteckningar utan namn ("konferensrummet", "flygplatsen", "kyrkan", "sjukhuset", "kontoret", "lagret") om de inte är del av ett unikt, namngivet ställe.

- organisation: Ett specifikt namngivet företag, myndighet, förening eller namngiven arbetsplats (t.ex. "Sahlgrenska Universitetssjukhuset", "Skatteverket", "IF Metall"). INTE en organisation: generiska ord som "företaget", "jobbet", "kontoret", "Vi", "kund", "kollegor", "arbetsplatsen", "receptionen", "banksektorn", "avdelningen", "konferensen". Ej heller giltiga organisationssignaler: e-postadresser och e-postdomäner ("ekonomi@foretaget.se", "exempel.com", "no-

reply@bolaget.se"), dessa hanteras av Lager 1 som direkta identifierare, inte av Lager 4 som organisationssignaler. Ej heller giltiga organisationssignaler: avdelningar och delarbetsplatser utan eget företagsnamn ("Bokningsavdelningen", "IT-avdelningen", "huvudkontoret", "vårt kontor", "ett privat företag", "HR-notat", "fabriken i Borås"), dessa är generiska företagsbeståndsdelar och saknar tillräcklig specificitet för identifiering.

ABSOLUT FÖRBUD - personnamn som text_span: Personnamn (förnamn, efternamn eller fullständiga namn som "Erik Johansson", "Therese Magnusson", "Karin Holm", "Lars Berg", "Lars", "Anna") får ALDRIG extraheras som text_span för någon signal, inte ens om kontexten antyder att personen har en yrkesroll eller en kopplad organisation. Personnamn är direkta identifierare som hanteras av andra lager och de är INTE kontextsignaler av typen yrke/plats/organisation. Extrahera istället den separata yrkesrollen, platsen eller organisationen som omnämns i samma mening, om en sådan finns.

Ej heller giltiga signaler - fraser och meningar som inte är renodlade yrkesroller, platsnamn eller organisationsnamn: "protokollfördes av", "leddes av", "eskaleras till", "Tack för att du tog upp det på mötet igår", "fackföreningsmedlemmar", "insändare i Aftonbladet där du skriver", "registrerar inte Annas ansikte korrekt", dessa är INTE yrke-, plats- eller organisations-signaler.

Context

Enligt GDPR Skäl 26 ska man ta hänsyn till alla medel som rimligen kan komma att användas för att identifiera en fysisk person. Detta kallas pusselbitseffekten: även om texten saknar direkta personuppgifter (som namn eller personnummer) och känsliga uppgifter (som hälsodata), kan en kombination av kontextsignaler peka ut en individ. Observera: Din uppgift är INTE att hitta direkta personuppgifter (Lager 1 och 2 gör detta) eller känsliga uppgifter (Lager 3 gör detta). Ditt fokus är kontextsignaler.

Reasoning instructions

Följ dessa steg noggrant för din bedömning:

1. Identifiera alla kontextsignaler (yrke, plats, organisation) i texten som uppfyller kriterierna ovan. Ignorera generiska ord, personnamn, relationsord, verb- och passivkonstruktioner, e-postadresser och avdelningar utan eget företagsnamn, dessa är INTE giltiga signaler, även om de förekommer intill information som kunde antyda identifierbarhet. Se de negativa exemplen nedan.

2. Notera den exakta textsträngen ("text_span") för varje giltig signal. Kontrollera: är text_span ett personnamn, en e-postadress, eller en verb-/passivkonstruktion? Isåfall, ta INTE med det. Extrahera istället yrkesrollen, platsen eller organisationen som omnämns i samma mening, om en sådan finns.

3. Bedöm om kombinationen av signaler är tillräckligt unik för att identifiera en person i en realistisk kontext.

4. Formulera en kort motivering (chain-of-thought) kring varför pusselbitarna räcker (eller inte räcker) för identifikation.

5. Producera din JSON-output enligt schemat.

Few-shot examples

Promptens 9 few-shot-exempel återges nedan ordagrant.

Exempel 1. Input: "Min chef på lagret i Eskilstuna trakasserar mig."

Output:

```
      {
         "individual_signals": [
           {"signal": "yrke", "text_span": "chef", "confidence":
0.95},
           {"signal": "plats", "text_span": "Eskilstuna",
"confidence": 0.99}
         ],
         "combination": {
           "is_identifiable": true,
           "text_span": "chef på lagret i Eskilstuna",
           "confidence": 0.92,
           "reasoning": "Kombinationen av yrkesrollen (chef) och den
specifika staden (Eskilstuna) gör individen identifierbar för någon
med lokalkännedom. 'Lagret' är ett generiskt platsbeskrivande ord
och utgör inte en giltig organisation-signal."
         }
       }
```

Rationale: Texten visar tydligt hur yrke och plats kombineras för att skapa identifierbarhet (pusselbitseffekten). "Lagret" är generiskt och extraheras inte som signal, det framgår av definitionen att generiska platsbeteckningar utan egennamn inte är giltiga signaler.

Exempel 2. Input: "Många jobbar som lärare i Stockholm."

Output:

```
      {
         "individual_signals": [
           {"signal": "yrke", "text_span": "lärare", "confidence":
```

```
0.99},
          {"signal": "plats", "text_span": "Stockholm",
"confidence": 0.99}
        ],
        "combination": {
          "is_identifiable": false,
          "text_span": "",
          "confidence": 0.0,
          "reasoning": ""
        }
      }
```

Rationale: Signalerna yrke och plats finns, men eftersom yrket är mycket vanligt och staden är väldigt stor, räcker inte detta för identifikation.

Exempel 3. Input: "Igår träffade jag en anställd på Skatteverket."

Output:

```
    {
        "individual_signals": [
          {"signal": "organisation", "text_span": "Skatteverket",
"confidence": 0.98}
        ],
        "combination": {
          "is_identifiable": false,
          "text_span": "",
          "confidence": 0.0,
          "reasoning": ""
        }
      }
```

Rationale: Organisation nämns, men enbart en myndighet med många anställda räcker inte för identifikation.

Exempel 4. Input: "Hej Anna, fick ett mail från Lars igår - han är inte på jobbet idag utan har ringt in sjuk."

Output:

```
    {
        "individual_signals": [],
        "combination": {
          "is_identifiable": false,
```

```
      "text_span": "",
      "confidence": 0.0,
      "reasoning": ""
    }
  }
```


Rationale: Personnamnen Anna och Lars är inte kontextsignaler av typen yrke/plats/organisation. "Jobbet" är ett generiskt ord och utgör inte en giltig organisation-signal. Inga giltiga kontextsignaler finns i texten.

Exempel 5. Input: "Ring Karin Holm på 070-123 45 67 för mer info om projektet i Malmö."

Output:


```
{
  "individual_signals": [
    {"signal": "plats", "text_span": "Malmö", "confidence":
0.99}
  ],
  "combination": {
    "is_identifiable": false,
    "text_span": "",
    "confidence": 0.0,
    "reasoning": ""
  }
}
```


Rationale: Plats (Malmö) är en giltig signal. Personnamnet och telefonnumret detekteras av andra lager. En stad utan specifikt yrke eller organisation räcker inte för identifikation via pusselbitseffekten.

Exempel 6. Input: "Den nya enhetschefen som tillträdde i januari efter omorganisationen vid Sahlgrenska Universitetssjukhuset har redan introducerat nya rutiner."

Output:


```
{
  "individual_signals": [
    {"signal": "yrke", "text_span": "enhetschefen",
"confidence": 0.95},
    {"signal": "organisation", "text_span": "Sahlgrenska
Universitetssjukhuset", "confidence": 0.99}
  ],
  "combination": {
    "is_identifiable": true,
```

```
          "text_span": "enhetschefen som tillträdde i januari efter
omorganisationen vid Sahlgrenska Universitetssjukhuset",
          "confidence": 0.90,
          "reasoning": "Kombinationen av en specifik roll
(enhetschef som tillträdde i januari) vid ett specifikt sjukhus
(Sahlgrenska) gör individen identifierbar för den som har viss
kännedom om sjukhuset."
        }
      }
```

Rationale: Specifik yrkesroll, specifik namngiven organisation och tidpunkt ger tillräcklig identifierbarhet.

Exempel 7. Input: "Erik Johansson är ny rektor vid skolan i Umeå. Therese Magnusson har tagit rollen som ekonomichef."

Output:

```
    {
       "individual_signals": [
         {"signal": "yrke", "text_span": "rektor", "confidence":
0.95},
         {"signal": "plats", "text_span": "Umeå", "confidence":
0.99}
        ],
        "combination": {
          "is_identifiable": true,
          "text_span": "rektor vid skolan i Umeå",
          "confidence": 0.88,
          "reasoning": "Specifik yrkesroll (rektor) vid namngiven
plats (Umeå) ger tillräcklig identifierbarhet. Personnamnen Erik
Johansson och Therese Magnusson extraheras INTE som signaler - de
är direkta identifierare, inte kontextsignaler."
        }
      }
```

Rationale: Personnamn är ALDRIG giltiga text_span för yrke/plats/organisation, de hanteras av andra lager. Enbart yrkesroll och plats extraheras som signaler.

Exempel 8. Input: "Mötet leddes av avdelningschefen och protokollfördes av sekreteraren. Ärendet ska eskaleras till ledningsgruppen."

Output:

```
{
   "individual_signals": [],
   "combination": {
     "is_identifiable": false,
     "text_span": "",
     "confidence": 0.0,
     "reasoning": ""
   }
 }
```

Rationale: Verb- och passivkonstruktioner som "leddes av", "protokollfördes av" och "eskaleras till" är INTE yrkesroller, även om de står intill yrkesbeskrivande ord. De yrkesord som följer ("avdelningschefen", "sekreteraren", "ledningsgruppen") saknar individuerande tillägg (namn, specifik organisation eller plats), så ingen giltig kombinationssignal föreligger. Notera särskilt: extrahera ALDRIG verbfrasen som text_span för yrke.

Exempel 9. Input: "Skicka fakturan till ekonomi@foretaget.se. Vårt kontor på huvudkontoret hanterar reklamationer via IT-avdelningen."

Output:

```
{
   "individual_signals": [],
   "combination": {
     "is_identifiable": false,
     "text_span": "",
     "confidence": 0.0,
     "reasoning": ""
   }
 }
```

Rationale: E-postadressen "ekonomi@foretaget.se" är en direkt identifierare och hanteras av Lager 1, inte som organisationssignal av Lager 4. "Vårt kontor", "huvudkontoret" och "IT-avdelningen" är generiska företagsbeståndsdelar utan eget företagsnamn och uppfyller inte definitionen av organisation. Inga giltiga kontextsignaler finns.

Output format

Svara ENBART i följande JSON-format:

```
{
  "individual_signals": [
    {
      "signal": "<en av: yrke, plats, organisation>",
      "text_span": "<exakt strängcitat från originaltexten>",
```

```
      "confidence": <float 0.0 till 1.0>
    }
  ],
  "combination": {
    "is_identifiable": <bool>,
    "text_span": "<sammanhängande textavsnitt som täcker
kombinationen från första till sista signalen i texten>",
    "confidence": <float 0.0 till 1.0>,
    "reasoning": "<kort CoT-motivering varför kombinationen är
identifierande (eller inte)>"
  }
}
```

VIKTIGT: "individual_signals" kan vara en tom lista [] om inga giltiga signaler finns. Om "is_identifiable" är false är "text_span", "confidence" och "reasoning" valfria eller tomma.

Bilaga D - Utvärderingssessioner

Bilagan dokumenterar de demomanus och intervjuguider som användes vid de naturalistiska utvärderingssessionerna efter respektive designcykel. Sessionerna följde FEDS naturalistisk formativ utvärdering (Venable et al. 2016) med tre kriterier i fokus: nytta (utility), ändamålsenlighet (efficacy) och organisatorisk passform (fit with the organization). Intervjuerna strukturerades som semistrukturerade forskningsintervjuer enligt Kvale och Brinkmann (2015), där varje tematiskt block inleddes med en introductory question, följdes upp med specifying questions och fördjupades med probing questions. Genomförandet följde Myers och Newmans (2007) riktlinjer för kvalitativa intervjuer inom informationssystemsforskning. Intervjuguiden reviderades mellan designcyklerna i enlighet med ADR:s fas reflektion och lärande (Sein et al. 2011): frågor som besvarats tillfredsställande utelämnades, frågor som behövde fördjupas reviderades, och nya frågor introducerades för det som var specifikt nytt i den aktuella cykeln. Demonstrationen och intervjun utgjorde en sammanhängande session om cirka 30 minuter, där demon (cirka 10 minuter) gav konkret underlag för den efterföljande intervjun (cirka 15 till 20 minuter).

Demomanusen och intervjuguiderna användes som strukturerande guider, inte som manuskript. Författarna höll sig till punkterna men anpassade formulering och fördjupningsgrad till respektive session.

D.1 redovisar demomanusen per designcykel. D.2 redovisar intervjuguiderna per designcykel.

D.1 Demomanus

Designcykel 1 (v0.1.1)

Demon var cirka 10 minuter och strukturerades i tre delar.

Minut 0 till 3 - Kvantitativa resultat (rapport-vy). Artefakten klassificerar text enligt GDPR-kategorier i tre lager: mönsterigenkänning, namngiven entitetsigenkänning, och kontextuell analys (det sistnämnda ej implementerat i denna iteration). Utvärderingen på testdatasetet gav recall 96 procent och precision 90 procent totalt. Recall prioriteras framför precision av juridiska skäl. Strukturerad data med kontrollsiffror (personnummer, IBAN, betalkort) når 100 procent recall och precision.

Minut 3 till 8 - Fritext-demo live (fritext-vy). Två texter matades in.

Text 1 - fungerande detektion:

> Hej Supporten, Jag har problem med min inloggning. Mitt personnummer är 850101-1236. Kan ni återkomma till anna.svensson@mail.se eller ringa på 070-123 45 67? Mvh Anna

Demonstrerade att Lager 1 (regex plus Luhn-validering) detekterar personnummer, e-post och telefonnummer, samt att Lager 2 (SpaCy NER) detekterar namnet Anna. Spårbarheten per fynd visades genom att varje markering anger källalager och regel.

Text 2 - känd begränsning som motiverar iteration 2:

> Volvo AB har registrerat IBAN SE35 5000 0000 0549 1000 0003.

Demonstrerade att IBAN detekteras korrekt av Lager 1 och att Volvo AB klassas som organisation (context.organisation). Om bolagsformen tas bort fångas inte längre organisationen. Telefon-recognizern matchar dessutom delar av IBAN-strängen, ett känt arkitektoniskt problem som adresseras i iteration 2 med en inneslutningsregel.

Minut 8 till 10 - Övergång till intervju. Iteration 1 utgör teknisk bas; syftet med intervjun var att samla formativ återkoppling inför iteration 2. Inspelningsmedgivande inhämtades.

Designcykel 2 (v0.2.0)

Demon var cirka 10 minuter och strukturerades i fyra delar.

Minut 0 till 1 - Inramning. Sedan iteration 1 har artefakten utökats med två nya lager: Lager 3 som detekterar direkt uttryckta artikel 9-data och Lager 4 som bedömer pusselbitseffekten enligt GDPR skäl 26. Båda lagren körs med lokal språkmodell (qwen2.5:7b-instruct via Ollama).

Minut 1 till 3 - Kvantitativa resultat (rapport-vy). Recall bibehållen kring 89 procent. Precision sjönk från 90 procent till cirka 64 procent som arkitekturell konsekvens av att systemet nu försöker fånga mer komplex känslighet. Designprincipen att missad känslig data (FN) är allvarligare än överflaggning (FP) bibehölls.

Minut 3 till 9 - Live-demonstration av tre texter (fritext-vy).

Text 1 - Lager 1 plus 2:

> Hej Supporten, jag har problem med min inloggning. Mitt personnummer är 850101-1236. Kan ni återkomma till anna.svensson@mail.se eller ringa på 070-123 45 67? Mvh Anna

Klassificering HIGH. Samma text som iteration 1, demonstrerade att baseline-funktionen kvarstår.

Text 2 - Lager 3 (Article9Layer):

> Patienten har diagnostiserats med diabetes typ 2 och behandlas med metformin sedan 2024. Uppföljning sker på Sahlgrenska Universitetssjukhuset.

Klassificering HIGH. Demonstrerade att Lager 3 detekterar hälsodata (diagnos och medicinering som artikel 9-kategoriuppgifter) utan att namn eller personnummer förekommer i texten. Något regex eller NER aldrig hade fångat. Förmågan att leda uppgifterna till en specifik person ligger utanför artefaktens scope.

Text 3 - Lager 4 (CombinationLayer):

> Den nya rektorn på Hvitfeldtska gymnasiets musiklinje fick utmärkelsen i fjol efter sitt arbete med ensembleundervisning.

Klassificering MEDIUM (ny nivå i iteration 2). Demonstrerade att Lager 4 identifierar tre kontextsignaler (roll, organisation, avgränsande detalj) och att kombinationen pekar ut en specifik person. Motiveringsfältet visade modellens resonemang kring varför signalerna tillsammans skapar identifierbarhet. Texten kopplade till V1:s pusselbitslucka från iteration 1.

Minut 9 till 10 - Övergång till intervju. Inspelningsmedgivande inhämtades vid behov.

Designcykel 3 (v0.3.0)

Demon var cirka 10 minuter och strukturerades i fyra delar.

Minut 0 till 1 - Inramning. Tre substantiella förändringar sedan iteration 2: klassificeringen visar nu identifierbarhet och dataskyddsklass som två separata axlar (uppföljning på V1:s, V4:s och V2:s synpunkter), precisionen har gått från 64 procent till 75 procent på samma modell och 83 procent på en uppgraderad modell (qwen3:14b), och det probe-arbete V4 föreslog i iteration 2 har genomförts.

Minut 1 till 3 - Kvantitativa resultat (rapportvy). Recall 91 procent, precision 83 procent med produktionsmodellen qwen3:14b. En av drivarna bakom precisionsförbättringen är matcher-aliasing mellan article4.adress och context.plats vid utvärderingen.

Minut 3 till 9 - Live-demonstration av sex texter (fritext-vy). Texterna delades upp i två uppsättningar. De första tre återanvände iteration 2:s texter för direkt jämförelse av designutvecklingen mellan cyklerna. De sista tre var nya, längre och mer naturalistiska texter som täcker tvådimensionsrepresentationens utfallsrymd starkare.

Text 1 - klassiska personuppgifter, (DIRECT, NONE):

> Hej Supporten, jag har problem med min inloggning. Mitt personnummer är 850101-1236. Kan ni återkomma till anna.svensson@mail.se eller ringa på 070-123 45 67? Mvh Anna

Identifierbarhet DIRECT, dataskyddsklass NONE, härledd känslighetsnivå LOW. Samma fynd som i iteration 1 och 2 men nu uttryckta i två dimensioner. Visar varför texten är LOW, inte bara att den är det.

Text 2 - artikel 9 utan namn, (NONE, SPECIAL):

> Patienten har diagnostiserats med diabetes typ 2 och behandlas med metformin sedan 2024. Uppföljning sker på Sahlgrenska Universitetssjukhuset.

Identifierbarhet NONE, dataskyddsklass SPECIAL, härledd känslighetsnivå LOW. Direkt svar på V4:s iteration 2-synpunkt att hälsodata utan personkoppling inte är ett GDPR-fall men ändå värt att markera. Tidigare klassades texten som HIGH eftersom artikel 9 alltid triggade högsta nivån. Detektion och klassificering är nu åtskilda.

Text 3 - pusselbitseffekten, (INDIRECT, NONE):

> Den nya rektorn på Hvitfeldtska gymnasiets musiklinje fick utmärkelsen i fjol efter sitt arbete med ensembleundervisning.

Identifierbarhet INDIRECT, dataskyddsklass NONE, härledd känslighetsnivå LOW. Samma kontextsignaler och motivering som iteration 2 men nu med separerad identifierbarhetsbedömning, vilket är vad V1, V2 och V4 indirekt efterfrågade.

Text 4 - sammansatt HR-ärende, (DIRECT, SPECIAL), knappetikett "Text 4: HÖG":

Internt HR-ärende 2026-0418, sammanställning inför uppföljningsmöte

Medarbetare: Karin Lindqvist, anställd som logistiksamordnare sedan 2019. Kontaktuppgifter enligt personalsystemet: karin.lindqvist@nordstromlogistik.se, mobil 070-413 88 21.

Bakgrund: Karin har varit sjukskriven på heltid sedan den 3 mars efter att företagshälsovården ställt diagnosen utmattningssyndrom. Två rehabiliteringssamtal har hållits. Karin uppger att hon under perioden även genomgått utredning för en kronisk inflammatorisk tarmsjukdom och att hon medicinerar dagligen, samt att hon av hälsoskäl behöver slippa nattskift.

Vid det senaste samtalet nämnde Karin att hon och hennes fru planerar att flytta närmare arbetsplatsen för att korta restiden. Hon bad också om att få gå ifrån en eftermiddag i månaden för möten i den lokala församling där hon är aktiv, och önskade ledigt för att fira en högtid med familjen i mitten av maj.

Chefens bedömning och planerad åtgärd dokumenteras separat. Ärendet följs upp vid nästa möte.

Identifierbarhet DIRECT, dataskyddsklass SPECIAL, härledd känslighetsnivå HIGH. Demonstrerade kombinationen av direkt identifierare (namn, e-post, telefonnummer) och artikel 9-data i flera kategorier: hälsodata (utmattningssyndrom, kronisk inflammatorisk tarmsjukdom, daglig medicinering), sexuell läggning ("hennes fru") och religiös övertygelse ("den lokala församling där hon är aktiv"). Textens längd verifierar också att kontextfönsterfixen håller hela analysen.

Text 5 - visselblåsarrapport med pusselbitar, (INDIRECT, SPECIAL), knappetikett "Text 5: MEDEL":

Visselblåsarrapport, inkommen 2026-05-09 via extern rapporteringskanal, anonym anmälare

Anmälan rör påstådda missförhållanden i en offentlig verksamhet. Anmälaren har valt att inte uppge namn eller kontaktuppgifter.

Personen som anmälan gäller namnges aldrig i underlaget, men beskrivs enligt följande: hen är regionens enda barnkardiolog, arbetar vid Region Bergslagens enhet i Degerfors och har enligt anmälaren suttit i den lokala fackklubbens styrelse de senaste fyra åren. Anmälaren uppger vidare att personen var sjukskriven under hösten och att flera kollegor kände till orsaken.

Anmälaren beskriver ett upprepat agerande som anmälaren menar avviker från verksamhetens rutiner. Ingen brottsrubricering anges.

Notering från mottagningsfunktionen: underlaget innehåller inga direkta identifikationsuppgifter, men kombinationen av yrkesroll, arbetsgivare och ort är ovanligt specifik.

Identifierbarhet INDIRECT, dataskyddsklass SPECIAL, härledd känslighetsnivå MEDIUM. Demonstrerade att pusselbitar (regionens enda barnkardiolog, Region Bergslagens enhet i Degerfors, fackklubbens styrelse) tillsammans gör personen indirekt identifierbar trots att inga

direkta identifikationsuppgifter förekommer. Texten kombinerar identifierbarhetsbedömningen via Lager 4 med artikel 9-detektion (fackmedlemskap, indirekt hälsoinformation).

Text 6 - anonymiserad fallbeskrivning, (NONE, SPECIAL), knappetikett "Text 6: LÅG":

> Anonymiserad fallbeskrivning, internt utbildningsmaterial i bemötande
>
> En patient i 50-årsåldern söker vård för återkommande ledvärk och trötthet. Patienten har sedan tidigare en autoimmun diagnos och behandlas med immundämpande läkemedel. Av anteckningen framgår att patienten nyligen kommit till Sverige, att tolk anlitades och att patienten uppger att liknande besvär är vanliga i släkten.
>
> Vårdcentralen i Hjo remitterade patienten vidare till sjukhuset i Skövde för utredning. Uppföljning planeras i samband med en kommande patientutbildning på konferensen i höst.
>
> Fallet används enbart i utbildningssyfte. Inga namn, personnummer eller kontaktuppgifter förekommer, och beskrivningen är medvetet generell så att ingen enskild person kan identifieras.

Identifierbarhet NONE, dataskyddsklass SPECIAL, härledd känslighetsnivå LOW. Demonstrerade att artikel 9-data (autoimmun diagnos, immundämpande läkemedel) detekteras korrekt utan att texten klassas som identifierbar, eftersom inga direkta identifierare förekommer och kontextsignalerna inte är tillräckligt specifika för pusselbitsbedömning.

Minut 9 till 10 - Övergång till intervju. Probe-arbetet och modellbytet togs upp i intervjun, inte i demon.

D.2 Intervjuguider

Intervjuerna pågick cirka 15 till 20 minuter och strukturerades i tre teman enligt FEDS-kriterierna. Varje fråga är taggad med FEDS-kriterium och Kvale-typ. Probing-uppmaningar var förberedda för fördjupning vid intressanta svar.

Guiden reviderades mellan designcyklerna i enlighet med ADR:s fas reflektion och lärande (Sein et al. 2011): frågor som besvarats tillfredsställande utelämnades, frågor som behövde fördjupas reviderades, och nya frågor introducerades för det som var specifikt nytt i den aktuella cykeln.

Designcykel 1

Intervjun innehöll nio huvudfrågor fördelade över tre teman, plus intressentspecifika kompletteringsfrågor (två till tre stycken per intervju). Räknat med cirka 90 sekunder per fråga inklusive probing.

Tema 1: Utility (cirka 5 minuter).

F1. [FEDS: utility | Kvale: introductory] Kan du beskriva hur ni idag hanterar information som kan innehålla personuppgifter i er verksamhet?

Probing vid kort svar: Vilka konkreta arbetsmoment involverar den här typen av hantering?

F2. [FEDS: utility | Kvale: specifying] Vilka typer av texter eller dokument är mest kritiska för er att få rätt på när det gäller att identifiera personuppgifter?

Probing: Kan du ge ett konkret exempel från det senaste kvartalet där ni behövde göra den här typen av bedömning?

F3. [FEDS: utility | Kvale: direct] Om ni föreställer er artefakten ni just sett integrerad i er verksamhet, var i arbetsflödet skulle den passa bäst?

Probing: Vad skulle behöva vara uppfyllt för att den skulle kunna användas på riktigt?

Tema 2: Efficacy (cirka 5 minuter).

F4. [FEDS: efficacy | Kvale: introductory] Hur bedömer ni systemets förmåga att identifiera personuppgifter i de texter vi visade?

Probing: Fanns det något som överraskade er, positivt eller negativt?

F5. [FEDS: efficacy | Kvale: specifying] Vi visade att systemet ibland flaggar text som inte är en personuppgift (falska positiva) och att det i sällsynta fall kan missa känsliga data (falska negativa). Kan du säga mer om vad konsekvensen blir när felbilden inträffar?

F6. [FEDS: efficacy | Kvale: specifying] Finns det texttyper eller format ni hanterar regelbundet som ni tror att systemet skulle missa eller hantera dåligt?

Probing: Vad är det i formatet som gör det svårt?

Tema 3: Fit with organization (cirka 5 minuter).

F7. [FEDS: fit | Kvale: introductory] Vilka regulatoriska eller organisatoriska krav påverkar hur ni får hantera personuppgifter i er verksamhet?

Probing: Finns det saker ni inte kan göra, även om tekniken skulle tillåta det?

F8. [FEDS: fit | Kvale: direct] Om ni skulle välja att använda ett system som det vi visat, skulle ni lita på att det fattade rätt beslut automatiskt, eller skulle det kräva en människa som granskar utdatat?

Probing: Vad skulle behöva uppfyllas för att ni skulle lita på systemet autonomt?

F9. [FEDS: fit | Kvale: interpreting + structuring] Vi har hittills pratat om systemets förmåga och om hur det skulle passa in hos er. Är det något vi inte har berört som är viktigt för att ni skulle kunna bedöma ett sådant här system? Finns det frågor ni tycker att vi borde ha ställt?

Probing: Är det något ni tagit för givet som vi kanske missar?

Intressentspecifika kompletteringsfrågor. Två frågor per intressentprofil. Integrerades naturligt i tema 2 eller 3 där de passade.

V1 (privat IT): **C1.** [FEDS: utility | Kvale: specifying] Ni nämnde tidigare att det ofta är två eller fler dataelement i kombination som gör en person identifierbar. Hur skulle ett system behöva hantera den typen av pusselbitseffekt för att vara användbart för er? **C2.** [FEDS: fit | Kvale: specifying] Hur hanterar ni idag balansen mellan att undvika att lagra personuppgifter och att faktiskt kunna leverera era tjänster?

V2 (privat IT, SME): **T1.** [FEDS: utility | Kvale: direct] Ni har DLP-system (Data Loss Prevention) men beskrev dem som för kostsamma för SME. Var skulle en klassificerare som den vi visat kunna komplettera eller ersätta delar av det behovet? **T2.** [FEDS: fit | Kvale: specifying] NIS2-direktivet ställer nya krav på spårbarhet och AI-hantering. Hur påverkar det hur ni skulle kunna introducera ett system som det här?

V4 deltog i iteration 1:s utvärderingssession utan motsvarande dokumenterade intressentspecifika kompletteringsfrågor i guiden. De generiska huvudfrågorna F1 till F9 användes som de var.

Designcykel 2

Intervjun innehöll åtta huvudfrågor fördelade över tre teman, plus en intressentspecifik fråga per intervju. Guiden reviderades från iteration 1 enligt följande: F1 till F3 och F7 till F8 från iteration 1 utelämnades helt eftersom de besvarats tillfredsställande i föregående cykel. Nya frågor introducerades för iteration 2:s nya lager (Article9Layer, CombinationLayer), den fyrgradiga känslighetsskalan, motiveringens roll och den lokala LLM-exekveringen.

Tema 1: Efficacy (cirka 7 minuter).

F1. [FEDS: efficacy | Kvale: introductory] Hur bedömer ni systemets förmåga att identifiera personuppgifter i de tre texter vi visade?

Probing: Var det något specifikt lager som överraskade er, positivt eller negativt?

F2. [FEDS: efficacy | Kvale: specifying] I texten om diabetesdiagnosen identifierade systemet hälsodata utan att någon person nämns vid namn. Hur bedömer ni det utfallet?

Probing: Är det här en typ av identifiering ni hade saknat tidigare?

F3. [FEDS: efficacy | Kvale: specifying] Texten om personen på Hvitfeldtska gymnasiet innehöll inga klassiska personuppgifter, men systemet bedömde den som medelkänslig eftersom kombinationen pekar ut en specifik person. Hur ser ni på det resonemanget?

Probing: Känner ni igen liknande pusselbits-situationer ur er egen verksamhet?

F4. [FEDS: efficacy | Kvale: specifying] Vi har gått från cirka 90 procents precision i iteration 1 till runt 64 procents nu, alltså mer text som flaggas felaktigt. Recall är bibehållen, vi missar inte mer än tidigare. Hur ser ni på den avvägningen i er kontext?

Probing: Skulle ni hellre ha en mindre alarmerande klassificerare som missar mer, eller en mer alarmerande som sällan missar?

Tema 2: Utility (cirka 4 minuter).

F5. [FEDS: utility | Kvale: direct] Systemet har nu fyra känslighetsnivåer istället för tre: ingen, låg, medel och hög. Är en sådan fyrgradig skala meningsfull i er verksamhet?

Probing: Skulle ni hantera ett MEDIUM-utfall annorlunda än ett HIGH-utfall?

F6. [FEDS: utility | Kvale: specifying] När systemet bedömde gymnasie-texten som känslig motiverade det också varför, alltså vilka signaler som kombinerades. Var den motiveringen användbar för er, eller hade ni behövt mer för att lita på utfallet?

Probing: Vad hade behövts för att ni skulle agera direkt på det automatiska beslutet utan egen granskning?

Tema 3: Fit with organization (cirka 4 minuter).

F7. [FEDS: fit | Kvale: specifying] Lager 3 och 4 körs med en lokal språkmodell, ingen data lämnar systemet. Förändrar det er bedömning av integrerbarheten jämfört med om systemet hade använt en molnbaserad AI-tjänst?

Probing: Vilka invändningar mot AI-komponenten kvarstår, om några?

F8. [FEDS: fit | Kvale: interpreting + structuring] Vi har pratat om systemets nya lager och hur de skulle passa hos er. Är det något vi inte har berört som är viktigt för att ni ska kunna bedöma ett sådant här system?

Probing: Något ni tagit för givet som vi kanske missar?

Intressentspecifika kompletteringsfrågor. En fråga per intressent, kalibrerad mot återkopplingen från iteration 1.

V1: I iteration 1 betonade ni att kombinationen namn, adress och telefon är det centrala för er, snarare än enskilda fält, och att längre dokument vore mer realistiska än korta exempel. Hur fångar Lager 4 den kombinationsproblematiken nu, baserat på vad ni såg?

V2: Ni beskrev DLP-system som för kostsamma för SME och föreslog en banner i mejlkorgen som ett enkelt integrationsvärde. Lokal LLM som tekniskt val är ett konkret kostnadssvar. Påverkar det hur realistisk en sådan integration känns för er?

V4: Texten om diabetespatienten liknar de incidentrapporter ni beskrev där patientidentifierbar information ibland smyger in trots att den inte ska vara med. Hur bedömer ni Article9Layer:s förmåga att fånga just sådan implicit hälsoinformation?

Designcykel 3

Intervjun innehöll tio huvudfrågor fördelade över tre teman, plus en intressentspecifik probe-fråga riktad till V4. Guiden reviderades från iteration 2 enligt följande: F2 till F4 från iteration 2 utelämnades (Article9Layer och CombinationLayer hade redan bedömts), nya frågor

introducerades för tvådimensionsoperationaliseringen, den förbättrade precisionen mot V1:s 80-procentsbrytpunkt, modellbytet till qwen3:14b, och slutanvändarperspektivet. Varje fråga DP-taggas för spårbarhet mot studiens designprinciper.

Tema 1: Efficacy (cirka 8 minuter).

F1. [FEDS: efficacy | Kvale: introductory] Hur bedömer ni systemets förmåga att klassificera de texter vi visade nu, jämfört med vad ni såg i iteration 2?

Probing: Är det någon enskild förändring som gör störst skillnad för er bedömning?

F2. [FEDS: efficacy | Kvale: specifying] Systemet visar nu identifierbarhet (DIRECT, INDIRECT, NONE) dataskyddsklass (NONE, SPECIAL, CRIMINAL) som två separata axlar i stället för en sammanvägd känslighetsskala. Fångar den uppdelningen den distinktion som ni tidigare lyfte i iteration 2?

Probing: Stämmer det med hur ni faktiskt skulle tänka när ni granskar en flaggad text?

F3. [FEDS: efficacy | Kvale: specifying] SensitivityLevel finns kvar men som ett härlett värde ovanpå de två dimensionerna. Vid (DIRECT, SPECIAL) ger derivatfunktionen HIGH, vid (INDIRECT, SPECIAL) ger den MEDIUM, vid (NONE, SPECIAL) ger den LOW. Är de gränsdragningarna rimliga ur er kontext, eller skulle ni dragit gränserna någon annanstans?

Probing: Finns en kombination i tabellen där ni hade velat ha en annan klassificering?

F4. [FEDS: efficacy | Kvale: direct] I förra utvärderingen angav V1 ungefär 80 procent precision som brytpunkt för acceptabelhet, kvalificerat på datavolym. Vi når 75 procent med default-modellen och 83 procent med den uppgraderade. Är vi över eller under det ni hade i tankarna?

Probing: Hur ska volym-kvalificeringen läsas i förhållande till de två talen?

Tema 2: Utility (cirka 7 minuter).

F5. [FEDS: utility | Kvale: direct] När ni nu ser identifierbarhet och dataskyddsklass separat, skulle ni handla olika beroende på vilken kombination som dyker upp? Till exempel mellan (DIRECT, NONE) och (INDIRECT, SPECIAL)?

Probing: Vad skulle ni faktiskt göra annorlunda mellan de två fallen?

Probing V2: Du pratade senast om risk och konsekvens, ser du att denna uppdelning hade varit ett bättre stöd i den bedömningen?

F6. [FEDS: utility | Kvale: specifying] Systemet motiverar fortfarande sina bedömningar via CombinationLayers reasoning-fält. Med två dimensioner att bedöma snarare än en, har motiveringens roll förändrats för er bedömning?

Probing: Är det någon dimension där ni vill ha mer eller mindre motivering än ni får idag?

Tema 3: Fit with organization (cirka 6 minuter).

F7. [FEDS: fit | Kvale: direct] Tidigare iterationer bekräftade att lokal exekvering är ett krav för samtliga tre verksamheter. Det vi inte berört är skalan: vi har enbart kört på enskilda datorer, men i en skarp driftsituation skulle ni rimligen köra mot en större självhostad modell på er egen infrastruktur. Är det den deployment-bilden ni har i åtanke, eller ser ni andra varianter?

Probing: Finns det värde i att kunna koppla mot en betydligt större modell, så länge den är inom er egen miljö?

Probing V4: Ert on-prem-kluster, vad är realistisk modellstorlek där?

Probing V1: Ni har egen infrastruktur, hade ni hostat en gemensam modell-tjänst eller per-team?

Probing V2: I SME-segmentet, är on-prem-hosting av en större modell realistiskt eller blir det laptop-skalan ni faktiskt jobbar med?

F8. [FEDS: fit | Kvale: specifying] Produktionsmodellen är nu qwen3:14b efter probe-arbetet, en uppgradering från qwen2.5:7b. Det kräver mer beräkningsresurs lokalt. Är det en relevant operativ förändring för er, eller spelar det ingen roll så länge modellen kör innanför era brandväggar?

Probing V1: Påverkar storleken er bedömning av drift och deployment?

Probing V4: Ert on-prem-kluster klarar det utan vidare, antar jag, men finns det andra organisatoriska implikationer?

Probing V2: I SME-segmentet är hårdvarukostnad en realfaktor, hur landar 14B vs 7B där?

F9. [FEDS: fit | Kvale: specifying] Tanken med artefakten är att den ska kunna integreras i befintliga arbetsflöden, exempelvis mejlkorg, ärendesystem eller journalsystem. Personen som faktiskt möter systemets utfall i sin vardag, exempelvis en sjuksköterska som loggar i journalen, har inte nödvändigtvis djup GDPR-kompetens. Hur tänker ni att användaren ska kunna avgöra om systemets bedömning är korrekt eller inte?

Probing: Vem i organisationen behöver den kompetensen, slutanvändaren eller någon i bakgrunden?

Probing: Riskerar systemet att uppfattas som "facit" snarare än "förslag" om motiveringen är skriven på GDPR-språk?

Probing: Är det en designfråga eller en utbildningsfråga?

F10. [FEDS: fit | Kvale: specifying] Vi har gått igenom tre iterationer nu. Skulle ni kunna tänka er att använda systemet? Om nej, vad är det mest kritiska som saknas för att det skulle vara möjligt?
Probing: Är det funktionalitet, integration mot befintliga system, kalibrering mot ert specifika datamaterial, eller något annat?

Intressentspecifik probe-fråga (V4).

[FEDS: efficacy | Kvale: specifying]. Probe-utfallet ändrade sig efter att utkastet skrevs. Den slutliga bilden: qwen3:14b når 82,88 procents precision och Claude Opus 4.7 ligger 0,26 procentenheter över i precision (0,91 procentenheter i F1). Marginalen är försumbar. Detta indikerar att taket är delvis uppgiftsbundet snarare än enbart modellbundet, eftersom steget från qwen3:14b till en större molnmodell ger nästan ingenting medan det tidigare bytet från qwen2.5 till qwen3:14b lyfte artikel 9-kategorierna. Hur tolkar ni det resultatet givet att ni i iteration 2 föreslog probet just för att separera modell från uppgift?

Probing: Innebär det att fortsatt förbättring kräver promptarbete eller finetuning snarare än modellbyte?

Probing: Hur landar slutsatsen att lokal modell är empiriskt tillräcklig i er offentlig-förvaltning-kontext där molnval ändå inte är aktuellt?



HÖGSKOLAN
I BORÅS

Besöksadress: Allégatan 1 · Postadress: 501 90 Borås · Tfn: 033-435 40 00 · E-post: registrator@hb.se · Webb: www.hb.se