Diskussioner om våld i sociala medier

En metod för att mäta förekomsten av diskussioner om våld på olika digitala plattformar

Bisell, Evelina
Rosenqvist, Kim

Institutionen för data- och systemvetenskap

Examensarbete 15 hp
Data- och systemvetenskap
Data- och systemvetenskap I, II & III (90 hp)
Höstterminen 2022
Handledare: Lisa Kaati
English title: Discussions of violence on social media



Stockholms universitet

Sammanfattning

Möjligheten för individer att uttrycka sig på internet har underlättat för det fria ordet, som är en demokratisk grundsten i vårt samhälle. Baksidan av detta mynt är att alltmer våldsam radikalisering sker runt om på digitala plattformar. I digitala miljöer sprids idag våldsbejakande propaganda där våldsverkare hyllas som hjältar, våld mot fienden rättfärdigas, och instruktioner om hur attentat kan genomföras delas. För socialt utsatta individer som får sin verklighetsförankring i dessa våldsbejakande digitala miljöer kan världsuppfattningen ändras till den grad att de till slut själva väljer att utföra grova våldsdåd. Att kunna identifiera digitala plattformar där diskussioner om våld är mer vanligt förekommande kan därför ge en första indikation på vilka sidor som riskerar att potentiellt främja våldsutövning. Tidigare forskning om hotbedömning genom textanalys har främst fokuserat på att identifiera individer som utgör ett hot. Mindre utrymme har ägnats åt att utveckla metoder som istället kan identifiera gemenskaper som utgör ett hot för individen. Det saknas idag applicerbara och validerade metoder som genom automatiserad textanalys kan mäta diskussioner om våld på digitala forum.

Arbetets forskningsmål var att skapa en metod som ska kunna mäta förekomsten av våld i diskussioner på digitala plattformar, och tillämpar metodramverket designforskning. Genom både kvalitativa och kvantitativa metoder skapades en ordlista över en mängd våldsuttryck som används på flera samtida sociala medier. Programkod utvecklades för att automatiskt kunna räkna antalet förekommande våldsuttryck i en given textsamling.

Genom tidigare tillgänglig data från flera olika forum utfördes en testning och utvärdering av metoden. Resultaten visar att våldsuttryck var upp till 100 gånger mer vanligt förekommande på vissa av de mer kända högerextrema forumen jämfört med mer generella diskussionsforum. Spektrumet är i linje med vad som initialt skulle kunna förväntas utifrån karaktären på dessa olika forum och indikerar därmed att metoden levererar realistiska resultat. En djupare kvalitativ analys av inläggen skulle vara nödvändig för att identifiera hur stor del av de identifierade våldsuttrycken tas upp i diskussioner med en positiv inställning till våld.

Nyckelord: Textanalys, automatisk detektering, våld, sociala medier, design science, metod

Abstract

Individuals being able to express themselves on the internet has been a boon to free speech, a democratic pillar to our community. The backside of this is that an increasing amount of violent radicalization is happening all over social media. At this moment, propaganda that praises violence is being spread on digital platforms, where violent perpetrators are praised as heroes, violence against "the enemy" is justified, and instructions on how to perform violent attacks are being spread. Socially vulnerable individuals repeatedly exposed to violent social communities can have their worldview change so drastically that they end up committing violent crimes. That is why identifying digital platforms where discussions about violence are more commonly occurring could give a first indication of which sites pose a higher risk of promoting violent attacks. Previous research on threat assessment through text analysis has mainly focused on detecting warning behaviours in radicalised individuals. Less room within this area of research has been given to developing methods that instead identify communities that can pose a risk to the individual. Therefore, there is a lack of applicable and validated methods that can measure discussions of violence on social media through automated text analysis.

The research goal of this thesis was to create a method that can measure the occurrence of violent discussions on digital platforms using the method framework Design Science. A list of violent words and expressions commonly used on social media was created with qualitative and quantitative methods. Code was then developed to automatically count the number of occurrences of these expressions in a given text.

Testing and evaluation of the method were carried out with data previously made available from several forums. The results show that violent expressions occurred up to 100 times more often on some of the more known right-wing extremist forums than on more general discussion forums. The resulting spectrum aligns with what one initially could expect to find by judging the character of these forums and therefore indicates that the method delivers accurate results. A deeper qualitative analysis of the posts would be necessary to identify how many of the identified violent expressions appeared in discussions with a positive attitude toward violence.

Keywords: Text analysis, automatic detection, violence, social media, design science, method

Synopsis

Bakgrund	Forskning har visat på att socialt isolerade och utsatta individer som vistas i våldsbejakande miljöer kan påverkas till att själva utföra våldsdåd genom att deras syn på våld förändras. Denna studie berör detta säkerhetshot inom digitala plattformar och ryms inom området för systemanalys och säkerhet.
Problem	I tidigare forskning har verktyg och metoder för hotbedömning genom automatiserad textanalys utvecklats. Tillförlitligheten och applicerbarheten i dessa metoder varierar, och fokus har varit på att identifiera och hotbedöma individer snarare än gemenskaper. Det saknas idag en metod som mäter förekomsten av våld i diskussioner i moderna sociala medier.
Frågeställ-ning	I denna uppsats är frågeställningen uttryckt som ett forskningsmål. Syftet med uppsatsen är att skapa en metod som kan mäta förekomsten av våldsuttryck i diskussioner på digitala plattformar.
Metod	Detta arbete förhåller sig till metodramverket designforskning och har tillämpat Design Science i framtagandet av en artefakt. Artefakten är en metod som ska kunna mäta förekomsten av våldsuttryck i diskussioner på digitala plattformar. En blandning av kvantitativa och kvalitativa metoder har tillämpats, där utvecklingen av artefakten främst skett via kvalitativ datainsamling och analys, men där utvärderingen av artefakten haft kvantitativa inslag.
Resultat	Resultatet visar på att våldsuttryck var upp till 100 gånger mer vanligt förekommande i forum med en känd högerextrem koppling jämfört med mer allmänna diskussionsforum. Våldsuttrycket "rape" var kraftigt överrepresenterat i incelsforum, medan "murder" var det vanligaste våldsuttrycket i nationalistiska och vit makt-forum.
Diskussion	Spridningen av antalet våldsuttryck i de olika dataseten, samt de identifierade våldsorden i respektive dataset indikerar att artefakten levererar det den är tänkt att göra. En kvalitativ granskning av resultaten för att bedöma hur stor del av våldsuttrycken som är våldsbejakande skulle vara intressant att göra för framtida forskning.

Tack

Tack till vår handledare och expert på textanalys och hotbedömning, Lisa Kaati.

Innehållsförteckning

1 Introduktion **1**

1.1 Problem 2

1.2 Forskningsmål 3

1.3 Avgränsningar 3

1.4 Uppsatsstruktur 4

2 Utökad bakgrund **5**

2.1 Våld som påverkar 5

2.2 Skapande av ordlistor 6

3 Metod **9**

3.1 Metodramverk 9

3.2 Forskningsstrategi 10

3.2.1 Val av strategi 10

3.2.2 Alternativ strategi 10

3.3 Metod för datainsamling 11

3.3.1 Val av datainsamlingsmetod 11

3.3.2 Alternativ metod 11

3.4 Metod för analys 11

3.4.1 Val av analysmetod 11

3.4.2 Alternativ metod 12

3.5 Forskningsetiska aspekter 13

4 Problem och krav **14**

4.1 Beskriva problem 14

4.2 Definiera krav 14

4.3 Metodtillämpning 15

5 Artefakten **16**

5.1 Utveckling och metodtillämpning 16

5.2.1 Ordlistan 16

5.2.1.1 Insamling från tidigare ordlista 16

5.2.1.2 Annotering från digitala plattformar 17

5.2.1.3 Term Set Expander 17
5.2.2 Koden 18
6 Demonstration och utvärdering 20
6.1 Beskrivning av artefakten 20
6.2 Metodtillämpning 20
6.3 Resultat 22
7 Diskussion 27
7.1 Resultatanalys 27
7.2 Begränsningar 28
7.3 Etiska aspekter 29
7.4 Slutsats 29
7.5 Fortsatt forskning 30
Litteraturförteckning 31
Bilagor 34
A Ordlista med våldsuttryck 34
B Ordlista med avfärdade våldsuttryck 36
C Programmeringskod från artefakten (Python) 38
D Utvalda trådar på forum 39
E Reflektionsdokument Kim Rosenqvist 40
F Reflektionsdokument Evelina Bisell 42

Figurer

Figur 1 Metodramverket för forskning inom Design science (Johannesson och Perjons 2014) 9

Figur 2 Stapeldiagram av det genomsnittliga antalet våldsuttryck per 100 000 ord på dataset från olika forum 23

Figur 3 Stapeldiagram över de 10 mest förekommande våldsuttrycken i utvärderingen av artefakten 23

Figur 4 Stapeldiagram över de 10 mest förekommande våldsuttrycken på Blackpill 24

Figur 5 Stapeldiagram över de 10 mest förekommande våldsuttrycken på Non Cucks United 24

Figur 6 Stapeldiagram över de 10 mest förekommande våldsuttrycken på Gates of Vienna 25

Figur 7 Stapeldiagram över de 10 mest förekommande våldsuttrycken på Ni**ermania 25

Figur 8 Stapeldiagram över de 10 mest förekommande våldsuttrycken på Mumsnet, Bitcoin, Sims4 och Bodybuilding 25

Tabeller

Tabell 1 Tabell med beskrivning av data som använts vid utvärderingen av artefakten 21

Tabell 2 Tabell över antal matchade ord från ordlistan på dataset från olika forum 22

Förkortningar

IDE	"Integrated Development Environment"; en typ av mjukvara och utvecklingsmiljö som används vid programmering.
Incel	"Involuntary celibate"; En man som lever i "ofrivilligt celibat" och som i regel klandrar kvinnor och samhället för deras brist på sexuell aktivitet (Kaati, Shrestha och Akrami, 2022).
TSE	"Term Set Expander"; ett digitalt verktyg som letar potentiellt likartade uttryck utifrån ett ords specifika semantiska kontext i ett givet dataset (Kaati 2022).
Go ER	"Go Elliot Rodger", ett slang för att begå massmord. Elliot Rodger, som definierade sig som incel, dödade 6 personer och skadade 14 i ett våldsdåd innan han tog sitt eget liv.

1 Introduktion

Digitala plattformar och sociala medier har tagit en allt större plats i den allmänna opinionsbildningen och är ett viktigt medium för medierapportering om händelser runt om i världen (Liu och Dong, 2022). Även om en majoritet av medlemmar på olika forum och sociala medier använder kommunikation och sökandet efter information på ett harmlöst och konstruktivt sätt så har internet idag även blivit en grogrund för radikalisering, våldsbejakande propaganda och skadlig informationsdelning (Conway, 2012; Kleinberg, van der Vegt och Gill, 2021).

På internetbaserade forum sprids våldsbejakande extremistisk propaganda, uppmaningar om att begå attentat och instruktioner om hur attentat kan genomföras (Säkerhetspolisen, 2022). Forum som exempelvis 4-chan har bidragit till tillväxt och fortplantning av högerextrema åsikter (Hine et al., 2017). Flera attentat med kopplingar till extremism har visat att gärnings-mannen varit aktiv på likasinnade digitala plattformar inför attacken - antingen i syfte att dela med sig av egna åsikter och planer, eller för att inspireras av andras (Shrestha, Kaati och Cohen, 2020). Forskning har visat att en våldsam kontext med kontinuerlig påverkan kan ge upphov till att andra inspireras och skrider till handling (Lövkrona och Nilsson, 2015; Pröitz, Langeland och Mainsah, 2021; Shrestha, Kaati och Cohen, 2020).

Att systematiskt kunna övervaka aktivitet på digitala plattformar i syfte att identifiera individer och forum som kan utgöra ett hot har på senare tid blivit allt viktigare (Grover och Mark, 2019; Shrestha, Kaati och Nazar, 2016). Mängden information som finns tillgänglig på digitala plattformar gör dock manuella sökningar resurskrävande, för att inte säga omöjliga (Scrivens, Davies och Frank, 2018). Alltmer forskning sker kring automatiserad textanalys och metoder för att identifiera potentiellt våldsamt beteende har redan utvecklats. På grund av varierande felmarginal och tillförlitlighet i dessa metoder (Cohen et al., 2014; Grover och Mark, 2019) så finns det idag ett fortsatt behov av att utveckla metoder och verktyg som kan sålla i en större mängd data.

Individer som kontinuerligt besöker digitala plattformar där våld är ett vanligt inslag i diskussionerna kan hypotetiskt sänka sin tröskel för våldsutövning (Langman, 2017). Att kunna identifiera digitala plattformar där våldsuttryck är mer vanligt förekommande i diskussioner kan därför ge en första indikation på vilka sidor som potentiellt riskerar att främja våldsutövning. Denna uppsats kommer fokusera på att mäta förekomsten av våld i diskussioner på digitala plattformar.

1.1 Problem

Ett problem som uppmärksammats på senare tid är att det sker en radikalisering av individer som deltar i virtuella gemenskaper på digitala plattformar (NCT, 2022). Då både våldsbejakande propaganda och radikalisering alltmer sker på digitala plattformar behövs mer forskning och kompletterande metoder för att kunna identifiera det som utgör ett hot mot samhället och dess invånare (Kaati, Shrestha och Sardella, 2016).

Nationellt centrum för terrorhotbedömning (NCT, 2022) ser det som sannolikt att digitala plattformar kommer att bidra till en ökad tillväxt av framförallt de mer löst organiserade och primärt internetbaserade delarna av de våldsbejakande extremistmiljöerna under 2022. En viktig faktor att ta hänsyn till är att individer som tar del av våldsrelaterat material och uppmaningar till att begå våldsdåd i digitala miljöer kan sänka sin våldströskel. Rättfärdigande och uppmaningar till våld kan ha en stor social och psykologisk påverkan på de som tar del av budskapet. Särskilt de individer som av olika anledningar är frustrerade eller socialt utsatta och får sin primära verklighetsförankring i våldsbejakande miljöer.

Tidigare forskning om hotbedömning genom textanalys har generellt fokuserat på att identifiera individer som utgör en ökad risk för att begå våldshandlingar, mindre fokus har funnits på vilka digitala plattformar som riskerar att påverka individen. Metoder och verktyg har utvecklats där primärt maskininlärningsmodeller ska kunna identifiera svaga lingvistiska signaler för olika varningsbeteenden. Tillförlitligheten i dessa metoder är dessvärre antingen varierande eller inte fullt ut validerade. Det saknas idag applicerbara och validerade metoder för att göra tillförlitliga hotbedömningar av samtida sociala medier, med syfte att avgöra vilka digitala miljöer som potentiellt kan utgöra en grogrund för våldsbejakande radikalisering (Grover och Mark, 2019; Pröitz, Langeland och Mainsah, 2021). Att analysera i vilken omfattning våld diskuteras på olika forum eller subforum skulle kunna vara en del i en större hotbedömning av olika digitala miljöer.

Syftet med denna uppsats är att ta fram en metod för att mäta omfattningen av diskussioner om våld i ett samtida internetsamhälle, där språket kontinuerligt utvecklas och där en specifik jargong gör det svårt för att förstå vad som diskuteras för den som inte är insatt. Det här arbetet bygger på tidigare forskning av Shrestha, Kaati och Akrami (2021) om hotbedömning av individers kommunikation. Men syftet med denna studie är att ta fram en metod som mäter förekomsten av våldsuttryck i diskussioner på digitala plattformar, och som på sikt kan användas för att göra hotbedömningar av digitala plattformar.

1.2 Forskningsmål

Frågeställningen i denna uppsats är uttryckt som ett forskningsmål (Johannesson och Perjons, 2014). Målet med det här arbetet är att ta fram en metod som ska mäta förekomsten av våldsuttryck i kommunikation på samtida sociala medier. Syftet är att metoden på sikt ska kunna användas som en del i en större hotbedömning, för att ge en indikation på i vilka digitala forum som diskussioner om våld är mer vanligt förekommande.

1.3 Avgränsningar

Våld är ett mångfacetterat begrepp och ett ytterst komplicerat fenomen som utmanar vår uppfattningsförmåga (Bildjuschkin et al., 2021). Enligt WHO definieras våld som:

> The intentional use of physical force or power, threatened or actual, against oneself, another person, or against a group or community, that either results in or has a high likelihood of resulting in injury, death, psychological harm, maldevelopment or deprivation. (Krug et al., 2002, s. 1084)

Definitionen av våld i denna uppsats har tagit inspiration av hur WHO valt att definiera våld, och lyder enligt följande:

> *Ett uttryck för avsiktlig fysisk kraft som kan leda till eller innebär en avsevärd fysisk skada för en annan människa eller människogrupp.*

Den reviderade definitionen har justerats för att passa med arbetets forskningsmål och problem och syftar till att definiera ett uttryck snarare än en konkret handling. Definitionen specificerar även att våldsuttryckets budskap ska beskriva en grövre form av fysiskt våld som riktas mot en annan part. Genom denna avgränsning kunde "mildare" och tvetydiga våldsuttryck, som "slap" och "kick" uteslutas. Det bedömdes kunna minska antalet falsk-positiva träffar, där våldsuttryck hade identifierats i diskussioner som egentligen inte handlade om våld. Även vissa ord som trots allt beskriver grövre våld har exkluderats, då ordet i hög grad används i andra sammanhang än våld. Exempel på sådana ord är "torture", som i flera sammanhang används för att beskriva något tråkigt eller utmattande, och "execution", som även betyder exekvering i datasammanhang.

Metoden gör inte någon analys om huruvida diskussionerna är positiva, negativa eller neutrala till våldsutövande, utan mäter endast förekomsten av antal våldsuttryck. Metoden är dock ämnad för att appliceras på moderna sociala medier och inte på till exempel brottsutredningar eller patientjournaler, där våld mer uteslutande tas upp i neutral eller negativ bemärkelse. Språket kommer även vara begränsat till att endast omfatta engelska ord, med fokus på

samtida internetjargong, och kommer enbart analysera skriven text. Bilder, ljud- och videoklipp ryms inte inom ramarna för denna metod.

1.4 Uppsatsstruktur

Strukturen på uppsatsen har följt IMRAD (Introduction, Method, Results, Discussion), vilket är en etablerad norm för organisering av innehåll i empiriska forskningsartiklar inom både natur- och samhällsvetenskap. Däremot har vissa modifikationer gjorts i strukturen av uppsatsen för att passa upplägget av Design Science-artiklar, vilka föreslås av Johannesson och Perjons (2014). En justering som kan vara viktig för läsaren att känna till, är att metodtillämpningen delats upp efter respektive aktivitet inom Design Science, i kapitel 4, 5 och 6.

2 Utökad bakgrund

2.1 Våld som påverkar

Lövkrona och Nilsson (2015) anser att våld är en kulturell företeelse och att våldsutövning är något som vi lär oss. De menar också att hur vi ser på våld beror på den specifika situationen och den relationella kontexten, det vill säga på vem som utövar våld och mot vem, när, hur och varför. Enligt Lövkrona och Nilsson (2015) skapas individens syn på vad som är våld och hur pass rättfärdigat det är utifrån den kontext som utgör individens omgivning. Våldsverkare har i intervjuer ansett deras våldshandlingar som något positivt, där våldet framstått som rättfärdigt och ett legitimt verktyg för att bemästra en viss situation (ibid.).

Forskning har visat att många individer som känner sig ensamma, utstötta, eller till och med avskydda, kan hitta en ny gemenskap på internet där de snabbt får en social gemenskap som kan tillfredsställa olika känslomässiga behov (Jaki et al., 2019; Fernquist, et al., 2020). Detta fenomen behöver inte per automatik betyda någonting negativt eller hotfullt, då flera digitala gemenskaper har såväl konstruktiva som harmlösa syften och innehåll. Men vad händer med verklighetsuppfattningen för socialt isolerade individer när de kontinuerligt engagerar sig i digitala gemenskaper där hat och våld är vanligt förekommande? Langman (2017) menar att individer som saknar en förankring och gemenskap i det verkliga livet istället skapar sitt sammanhang och sin världsbild genom digitala plattformar. Han förklarar i sin studie att individer som exponeras mot tidigare våldsdåd inte per automatik innebär en kausalitet till att de själva kommer utföra våldsdåd. Men individer som redan är frustrerade, isolerade och har börjat rättfärdiga våldshandlingar kan lätt påverkas och sporras av en fortsatt kontinuerlig exponering mot våld. Langman (2017) menar också att genom exponering mot och i sällskap av våldsbejakare så ökas individens mentala rättfärdigande av våldshandlingar, vilket även överensstämmer med Lövkrona och Nilssons (2015) slutsatser. Varje gång någon i omgivningen överskrider tröskeln så blir den lägre för individen som går i liknande tankar. Tabut kring att åsamka andra fysisk skada bryts ner. Granskar man individer som utfört uppmärksammade våldsdåd på egen hand, som masskjutningar, så har dessa individer ofta varit socialt isolerade (Langman, 2017). Det är även alltmer förekommande att dessa våldsverkare också har varit aktiva på internet innan de agerat, inte minst på digitala plattformar (Shrestha, Kaati och Cohen, 2020).

Som nämnt tidigare så finns det dock ett flertal digitala forum där innehållet präglas av våldsbejakande propaganda och i allmänhet hatiskt ordspråk. Analyser av innehållet på incelsforum, som riktar sig mot personer som lever i "ofrivilligt celibat", har visat på en stor del hatiskt innehåll mot framför allt kvinnor (Pröitz, Langeland och Mainsah, 2021; Fernquist et al., 2020).

Högernationalistiska vit makt-forum, likt Stormfront, har också innehåll med en noterbar hatisk attityd mot kvinnor, men likväl mot individer från andra kulturer, etniciteter och politiska åsikter (Baele, Brace och Coan, 2021).

Våldsbejakande individer har också tenderat till att uppmana andra på olika digitala plattformar till att utföra våldsdåd, för att bidra till eller att engagera i det ofta högre syfte som kollektivet står för, och slå mot den yttre fienden (Cohen et al., 2014). Tidigare våldsutövare målas dessutom upp som hjältar på digitala plattformar med likasinnade, och blir på så vis förebilder som kan inspirera nya våldsutövare i jakten på tillhörighet och acceptans (Pröitz, Langeland och Mainsah, 2021). Eller som Chayka (2022) uttrycker det i sin artikel om hur internet möjliggör masskjutningar:

> In some ways, the forces that encourage mass shooters are bleakly similar to those that fuel the careers of any influencers, drawing passive content consumers into the orbit of particularly vocal posters. (para. 4)

Hawkes (1971) myntade redan på 70-talet den så kallade self-excited contagion model, som bygger på att händelser den senaste tiden ökar sannolikheten för att en liknande händelse sker igen i framtiden. Denna modell har applicerats i forskning inom flera olika områden, till exempel inom gängvåld och finansmarknad. Liu och Dong (2022) har applicerat teorin på rapporteringen om masskjutningar på sociala medier. Enligt tidigare studier så finns det en koppling mellan nyhetsrapporteringar om våldsdåd och nya liknande handlingar. I de experiment som utfördes av Liu och Dong (2022) så visar resultaten att spridningen av åsikter på sociala medier har en övertygande smittsam effekt på masskjutningar.

2.2 Skapande av ordlistor

En stor del av kunskapsbasen för skapandet av ordlistan inom denna studie hämtades från tidigare forskning, som likt detta arbete behövt skapa ordlistor i samband med automatisk textanalys.

Van der Vegt et al. (2021) har i deras forskning skapat "the grievance dictionary", som går ut på att genom psykolingvistisk textanalys identifiera varningsbeteenden hos individer som kan innebära ett hot. Deras forskning hade visserligen ett annat syfte jämfört med denna uppsats, men den har flera viktiga inslag i framtagandet av ordlistor som är värdefulla för forsknings-målet i detta arbete. Metoden för utvecklingen av ordlistan för "the grievance dictionary" (van der Vegt et al., 2021) beskrevs enligt följande:

1. Experter inom hotbedömning fick inledningsvis svara på vilka textkategorier som de anser är av vikt att leta efter vid en hotbedömning.

2. Utifrån valda kategorier från föregående steg fick mastersstudenter inom lingvistik skicka in förslag på ord inom respektive kategori.
3. Digitala verktyg användes för att utöka den ordlista som skapats i steg två, genom att dels lägga till så kallade "kognitiva synonymer", dels lägga till ord som kodats som letar efter semantiska samband mellan ord i den kontext de påträffas i.
4. En enkät skickades ut till medlemmar på forskningsplattformen Prolific Academic, där betalda deltagare fick bedöma hur väl orden i ordlistan passade den kategori de tillhörde.

Den slutgiltiga ordlistan användes därefter för att mäta förekomsten av varningsbeteenden i våldsverkares manifest och foruminlägg om harmlösa hobbys. Deras resultat föreslår att det går att statistiskt se skillnader i innehåll av varningsbeteenden mellan dessa grupper. Däremot var det svårare att säkerställa skillnader när ordlistan testades mot någon som skrivit om deras frustration på grund av obesvarad kärlek, jämfört med någon som formulerat ett direkt hot till en politiker. Andra liknande metoder för textanalys har också visat svårigheter i att bedöma ironiska uttalanden, som tenderat att ge falska utslag för varningsbeteenden. Flera falska höga värden för olika hotfulla varningsbeteenden kan alltså framkomma i texter, som vid en kvalitativ granskning inte anses innehålla reella hot. Därför konstateras automatiserade textanalyser likt dessa inte kunna användas som ett enskilt verktyg för att identifiera varningsbeteenden utan en kompletterande mänsklig analys. Van der Vegt et al. (2021) konstaterade även att deras ordlista hade kunnat förbättras genom att inkludera deltagare som hade en djupare kunskap om miljön som ordlistan är tilltänkt att användas inom, för att få en djupare förankring i samtida sociala medier.

Shrestha, Akrami och Kaati (2020) har också forskat på hur olika varningsbeteenden hos individer kan identifieras genom psykolingvistisk automatiserad textanalys. De har dock haft ett större fokus på att inkludera den forumspecifika jargongen än van der Vegt et al. (2021). Shrestha, Akrami och Kaati (2020) skapade sina ordlistor, för respektive kategori av varnings-beteenden, genom följande metod:

1. Skapa en tydlig definition av vad som ska mätas eller undersökas.
2. Specificera vilken miljö eller kontext som ordlistan ska användas för.
3. Undersök miljön genom att läsa och analysera det språk som används.
4. Skapa en preliminär lista av nyckelord som bedöms viktiga för det du vill mäta.
5. Skapa en ordinbäddning av den miljö du avser mäta. Därigenom förses ord som är semantiskt likvärdiga de nyckelord som framtagits i steg fyra.
6. Exkludera de ord i steg fem som inte relaterar till den definition som framtagits i steg ett, och lägg till de som passar.
7. Repetera steg 5-6 en gång till, men var denna gång mer liberal med vilka ord som inkluderas i ordlistan.

8. Låt minst två utomstående granskare, gärna experter inom området, granska ordlistan i relation till definitionen och svara på om respektive ord bör inkluderas, samt om några ord saknas.
9. Undersök granskarnas svar och revidera listan om så anses lämpligt.

Deras forskning utgick i steg 5 från ordinbäddade set från incelsforum och radikala nationalistiska plattformar. Verktyget kunde alltså ge förslag på forumspecifika uttryck och synonymer, som potentiellt kan ha använts för samma budskap som nyckelorden i listan från steg 4. Shrestha, Akrami och Kaati (2020) testade de slutgiltiga ordlistorna genom att mäta förekomsten av orden i dels manifest skrivna av tidigare våldsverkare, och dels mot kontrollgrupper bestående av innehåll från generella diskussionsforum och bloggar. Deras resultat visade på att manifest skrivna av våldsverkare innehöll en högre grad av ord från flera av kategorierna för varningsbeteenden, dock inte alla. De drar slutsatsen att mer utvärdering av deras forskning behöver genomföras, för att säkerställa tillförlitligheten och precisionen av metoden.

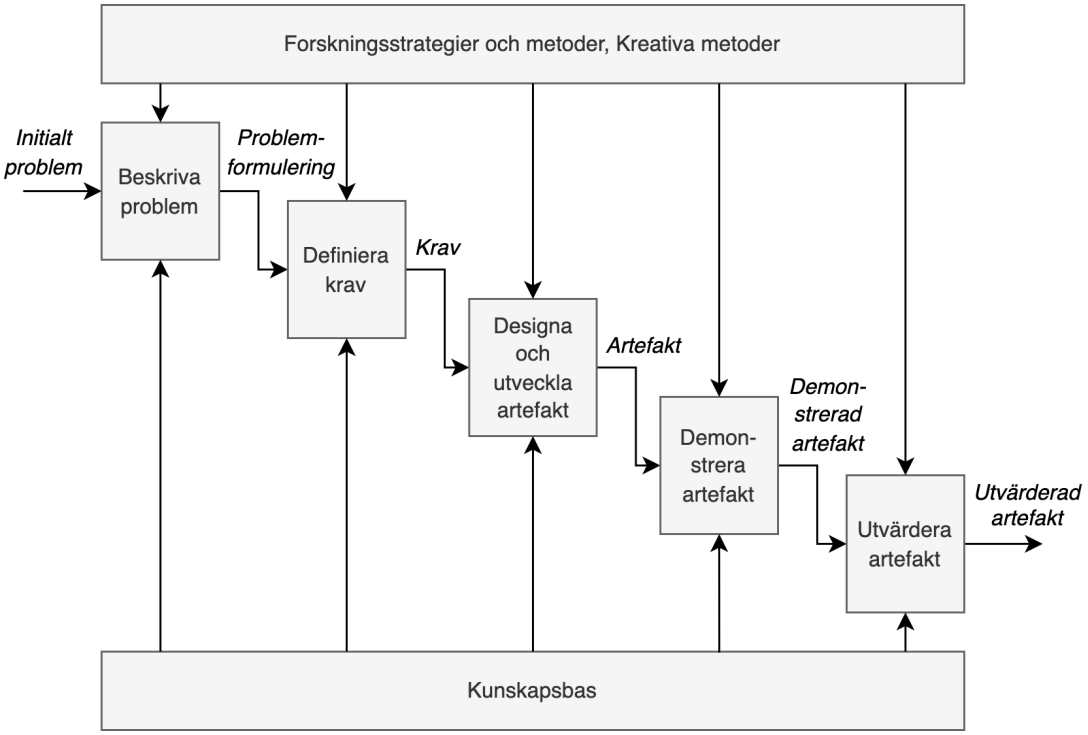
Både van der Vegt et al. (2021) och Shrestha, Akrami och Kaati (2020) har poängterat vikten av fortsatt forskning inom textanalys, där genomförandet, likt deras egna, bör vara transparent och tillgängligt för utomstående granskning.

3 Metod

3.1 Metodramverk

Detta projekt anammar forskningsfältet designforskning, som i kontrast till empirisk forskning inte enbart beskriver, förklarar och förutsäger fenomen i världen. Målet är att skapa en artefakt i form av en metod för att mäta förekomsten av våldsuttryck i diskussioner på digitala plattformar, och för att göra detta användes Design Science (Johannesson och Perjons, 2014).

För att visualisera metodramverket på ett kompakt men omfattande sätt så använder Johannesson och Perjons (2014) en modell, se figur 1. Den visar att framtagandet av en artefakt kan beskrivas i fem olika huvudaktiviteter, där respektive aktivitets output blir nästa aktivitets input (ibid.).



Figur 1 Metodramverket för forskning inom Design science (Johannesson och Perjons 2014)

Som figuren visar så kan olika forskningsstrategier, datainsamlingsmetoder och analysmetoder behöva implementeras i respektive aktivitet. Utöver detta ges även möjlighet att varje aktivitet innehåller flera olika, eller inga, vetenskapliga forskningsstrategier och metoder. Allt beroende på vilken typ av artefakt som ska skapas och vilka behov som föreligger i respektive aktivitet (Johannesson och Perjons, 2014).

3.2 Forskningsstrategi

3.2.1 Val av strategi

I uppsatsen implementerades Mixed methods som övergripande forskningsstrategi. Det tillämpades alltså på samtliga aktiviteter inom Design Science- ramverket, och var ledande genom hela arbetet.

Utgångspunkten i Mixed methods är att en kombination av kvalitativa och kvantitativa metoder behöver användas för ett och samma forskningsmål (Denscombe, 2010). Inom Design Science ställs ofta krav på flexibilitet mellan strategier och metoder inom de olika aktiviteterna (Johannesson och Perjons, 2014). Med det som bakgrund, och att forskningsmålet för denna uppsats indikerade att både kvalitativa och kvantitativa metoder behövde användas, ansågs blandade metoder vara det mest lämpliga valet av forskningsstrategi. Blandade metoder anses vidare även vara en passande strategi när syftet med en studie är att skapa nya digitala och tekniska verktyg (Denscombe, 2010).

3.2.2 Alternativ strategi

En alternativ strategi för att mäta förekomsten av våld i diskussioner på digitala plattformar skulle kunna varit fallstudie. En fallstudie är en forskningsstrategi som syftar till att generera mer djupgående kunskaper om ett fenomen som undersöks, och i förlängningen generalisera teoriutveckling (Denscombe, 2010). Genom att gå in och granska ett forum på djupet hade det varit möjligt att med en kvalitativ textanalys bedöma hur många gånger som våldsuttryck förekommer i ett våldsbejakande sammanhang. Utifrån de tidsramar som getts för detta arbete hade det emellertid inte varit rimligt att kunna utvärdera metoden på flera olika digitala plattformar, då det hade varit alltför resurskrävande. För att möjliggöra en automatiserad metod skulle en mycket mer avancerad maskininlärningsmodell behövt utvecklats, vilket också inte ansågs vara rimligt inom ramen för detta arbete.

Eftersom denna studie gått ut på att skapa en metod som ska kunna mäta *förekomsten* av våldsuttryck i diskussioner på sociala medier, så borde en fallstudie inte ge de bästa förutsättningarna. En fallstudie hade varit bättre lämpad om forskningsmålet varit av mer kvalitativ karaktär, där bakomliggande budskap i inlägg med våldsuttryck hade varit av mer central betydelse.

3.3 Metod för datainsamling

3.3.1 Val av datainsamlingsmetod

I denna uppsats valdes dokument (Denscombe, 2010) som datainsamlingsmetod för samtliga aktiviteter. I de inledande aktiviteterna "förklara problem" och "definiera krav" användes publicerade dokument i form av böcker, vetenskapliga artiklar och föreläsningar som kunskapsbas. För att skapa den vetenskapliga grunden som är en viktig del inom design science (Johannesson och Perjons, 2014) så behövdes en faktainsamling med tidigare forskning, framför allt inom textanalys och våld på digitala plattformar. Även i aktiviteterna "designa och utveckla artefakt", "demonstrera artefakt" samt "utvärdera artefakt" valdes dokument som datainsamlingsmetod. Eftersom forskningsmålet är att mäta innehåll på digitala plattformar ansågs det mest relevant att empiriskt material och data för utvärdering samlas in från samma miljö som senare ska mätas.

3.3.2 Alternativ metod

En annan metod för insamling av data för att bygga upp en lista av våldsuttryck hade varit att använda enkäter (Denscombe, 2010). Inom aktiviteten "designa och utveckla artefakt" hade enkäter kunnat användas för att samla in förslag på våldsord från individer, som är verksamma på olika digitala plattformar. På så sätt hade en bredare uppfattning av våldsuttryck kunnat samlas in, med mindre risk för bias. Det hade däremot krävts ytterligare resurser för att få tag i ett lämpligt urval av deltagare för genomförandet, vilket inte bedömdes som rimligt givet förutsättningarna för denna studie.

Att byta ut dokument som insamlingsmetod till enbart enkäter bedömdes inte gynna forskningsmålet för denna uppsats, då det ansågs kunna begränsa mängden viktig data som kunde samlas in. Visserligen ökar risken för bias när författarna fäller avgörandet för vad som bedöms som våldsamt, men ordlistan över våldsuttryck är inte skapta utifrån författarnas förmåga att själva komma på och formulera våldsuttrycken, utan är annoterade ur empiriskt material från den miljö där metoden ska appliceras.

3.4 Metod för analys

3.4.1 Val av analysmetod

Inom ramen för Design Science har ett par olika analysmetoder behövt tillämpas i några av aktiviteterna inom metodramverket.

I "designa och utveckla artefakt" behövde en kvalitativ analys av innehållet från digitala plattformar utföras i två omgångar från olika dataset, där målet var att identifiera och annotera ord som matchar definitionen av våldsuttryck. Den typen av dataanalys omfattas inte av de generella vetenskapliga metoder som berör innehållsanalys av kvalitativ data, även om det finns vissa inslag som överensstämmer med metoden (Denscombe, 2010). Johannesson och Perjons (2014) hävdar dock att aktiviteten "designa och utveckla artefakt" skiljer sig från de övriga aktiviteterna inom design science, då dessa aktiviteter inte främst försöker svara på frågor. Aktivitetens huvudsakliga syfte är skapandet av en artefakt, vilket vetenskapliga metoder inte alltid är anpassade för och anpassningar kan därför behöva göras.

För aktiviteterna "demonstrera artefakt" och "utvärdera artefakt" tillämpades en kvantitativ analysmetod. Eftersom forskningsmålet går ut på att mäta ett fenomen så är en kvantitativ analysmetod relevant, då resultat kan presenteras i form av siffror (Johannesson och Perjons, 2014). Eftersom utvärderingen behövde utföras på flera olika dataset så användes deskriptiv statistik i form av diagram och tabeller för att kunna presentera en överskådlig och jämförbar bild över resultaten (Johannesson och Perjons, 2014). Resultaten kunde därefter analyseras för att se om artefakten uppfyller forskningsmålet.

3.4.2 Alternativ metod

En alternativ metod, som hade varit intressant i aktiviteterna "demonstrera artefakt" och "utvärdera artefakt", hade varit att utföra en diskursanalys. Det är ett tillvägagångssätt för att analysera kvalitativ data där man fokuserar på den underförstådda innebörden och budskapet av texten eller bilden (Denscombe, 2010). En sådan analysmetod hade kunnat möjliggöra en djupare kvalitativ analys av de inlägg med våldsuttryck som identifierats genom ordlistan.

Genom att använda en diskursanalys på data från digitala plattformar hade en analys kunnat utföras på hur stor del av inläggen som hade en bakomliggande våldsam attityd eller åsikt. Det hade funnits en större möjlighet att presentera ett resultat med enbart våldsbejakande innehåll, genom att eliminera falsk-positiva träffar. De resultat som presenterats med deskriptiv statistik i denna uppsats kan likväl ha innehållit träffar där den bakomliggande meningen är en negativ eller neutral inställning till våld.

En nackdel med en diskursanalys är dock att det skulle krävts större resurser i form av tid för att på djupet analysera kontexten och det bakomliggande budskapet av den data som identifierats. Eftersom artefakten förväntas kunna utvärderas genom att jämföra olika plattformar sinsemellan bedöms inte en diskursanalys som realistisk att genomföra inom de ramar som getts för denna uppsats. En diskursanalys skulle varit mer relevant att genomföra om forskningsmålet varit av mer kvalitativ karaktär, där syftet snarare gått ut på att analysera *hur* våld diskuteras och uttrycks på digitala plattformar, och då

utvärderas mot en mindre mängd data.

3.5 Forskningsetiska aspekter

Inom social forskning finns några fundamentala etiska koder som är viktiga att ta hänsyn till. Dessa härstammar ur den mest grundläggande principen där ändamålet inte helgar medlen inom sökandet efter kunskap. Forskare har alltså inte rätt att använda vilka medel som helst för att genomföra en studie (Denscombe, 2010).

En av de fyra etiska koder som Denscombe (2010) nämner är att forskarna ska undvika bedrägeri och agera med vetenskaplig integritet i sin forskning. Vad gäller denna uppsats kan man alltid diskutera en möjlig bias när det gäller att bedöma uttryck för våld, som visserligen har en definition men som också är ett begrepp som utmanar vår uppfattningsförmåga (Bildjuschkin et al., 2021). Inom ramarna för detta projekt så har viss hänsyn tagits för att minimera subjektiva uppfattningar kring våldsuttryck. Tvetydiga ord har blivit granskade av en utomstående expert inom textanalys, för att ordlistan inte enbart skulle vara förankrad i författarnas kvalitativa bedömning. I övrigt har tillvägagångssättet för att skapa ordlistan beskrivits noggrant i metodtillämpningen. Både förkastade och utvalda våldsuttryck är dessutom tillgängliga i arbetets bilagor, och därmed öppet för granskning av andra.

Forskningen ska även följa lagar och förordningar, dessutom ska individernas deltagande vara frivilligt samt baserat på samtycke (Denscombe, 2010). Ett vanligt förekommande bekymmer i forskning inom sociala medier, som även berör denna uppsats, är insamlandet av data från deltagare som inte gett samtycke till att delta i studien. Den generella ståndpunkten är dock att medlemmar på digitala plattformar har behövt samtycka till användarvillkoren, där det i regel står att en tredje part har åtkomst till den data som publiceras (Townsend och Wallace, 2016). Det material som använts i denna studie har hämtats från sidor där inloggning inte behövs för att få tillgång till innehållet. Ingen data har hämtats från lösenordskyddade sidor eller privata grupper.

Deltagarnas intressen ska också skyddas, vilket är starkt knutet till forskningsintegriteten. Individer som deltagit i en studie ska inte riskera att kunna identifieras och på så vis påverkas av studiens publicering (Denscombe, 2010). I denna uppsats har inga uppgifter om personers identiteter använts eller lagrats och behöver således inte hanteras enligt GDPR. Medlemmar på digitala plattformar använder i regel alias, och även om försök skulle göras till att koppla ett alias till en specifik individ är detta svårt, för att inte säga omöjligt (Townsend och Wallace, 2016).

4 Problem och krav

4.1 Beskriva problem

Som nämnts i tidigare kapitel så har en del forskning inom hotbedöming genom textanalys redan genomförts. Fokus har varit att genom psykolingvistisk automatiserad textanalys identifiera signaler för varnings-beteenden, främst hos specifika individer (Grover och Mark, 2019). Dessa metoder har haft en viss felmarginal då kvalitativa analyser visat att maskin-inlärningsmodellen som genomfört textanalysen inte har kunnat urskilja till exempel skämtsamt innehåll eller ironiska formuleringar. Den enskilda metod som tagits fram för att identifiera gemenskaper istället för individer är dessutom utformad för ett specifikt subforum, och är inte tillgänglig för andra att applicera på nya dataset. Då radikalisering mot våldsbejakande extremism är ett pågående problem så finns det ett behov att identifiera de miljöer där våld i diskussioner är vanligt förekommande. Att mäta bruket av våldsuttryck på sociala medier kan därför, som tidigare nämnt, fungera som ett komplement i en framtida hotbedömning. En sådan applicerbar metod saknas idag och utgör därför grunden till problemformuleringen.

En utmaning i en sådan metod är att lyckas fånga in den forumspecifika lingvistiska jargongen. Ofta har sociala gemenskaper utvecklat ett eget gruppspråk med synonymer för att benämna olika, för gemenskapen, centrala objekt och handlingar (Cohen, 2014). De ordlistor som har använts hittills i metoder för textanalys har vid granskning helt eller delvis saknat samtida forumspecifik förankring (van der Vegt et al., 2021; Shrestha, Akrami och Kaati, 2020), och har därmed med stor sannolikhet missat en del hatiskt eller våldsamt innehåll i sin textanalys. Det är därför av vikt att samla in empirisk data från den miljö som metoden ska tillämpas i.

4.2 Definiera krav

Artefakten som har skapats i detta arbete är en metod. Metoden går ut på att kunna mäta förekomsten av våldsuttryck i diskussioner på digitala plattformar. För att kunna mäta förekomsten av våldsuttryck behövde artefakten bestå av en representativ ordlista. Likt steg 1 i Shrestha, Akrami och Kaatis (2020) forskning, som presenterades i avsnitt 2.1, behövs därför en tydlig definition våldsuttryck. Utan en tydlig definition skulle sämre förutsättningar finnas för att artefakten mäter det den är skapad för. Ordlistan behöver även innehålla de forumspecifika uttryck som används för att beskriva våld, som kan skilja sig beroende på vilken miljö man utgår ifrån (ibid.).

Artefakten skulle skapas för att automatiskt mäta antal våldsuttryck från en ordlista i ett dataset, därmed krävdes algoritmer i form av programkod ut-

vecklas. Artefakten blir dock beroende av att en användare väljer vilket dataset som ska analyseras, för att kunna appliceras på ny data i framtiden. För att enkelt kunna jämföra resultat mellan olika digitala plattformar behövde artefakten kunna presentera ett genomsnittligt värde på hur många våldsuttryck som identifierats per 100 000 ord i ett dataset. Därmed behövde antal identifierade våldsuttryck samt totalt antal ord i datasetet finnas med i algoritmen. För eventuell felsökning och en fördjupad analys skulle artefakten även presentera vilka unika våldsuttryck som påträffats i datasetet, samt hur många gånger dessa nämns.

4.3 Metodtillämpning

I detta avsnitt kommer vi beskriva hur valda strategier och metoder har använts. De kommer presenteras utifrån de inledande två aktiviteterna i figur 1; "beskriva problem" och "definiera krav", som genomförts ovan.

Utgångspunkten var att skapa en bred vetenskaplig bas genom en kvalitativ datainsamling som skulle ligga till grund för att artefakten skapas i rätt kontext och till ett korrekt och betydelsefullt ändamål. Genom att göra en grundorsaksanalys (Johannesson och Perjons, 2014) kunde forskningsmålet definieras tydligare. Följande kategorier kunde lyftas ut som viktiga forskningsområden och nyckelord att utforska djupare:

- Våld som begrepp
- Våld på digitala plattformar
- Automatisk textanalys
- Hotbedömning
- Skapande av ordlistor

Därefter började sökningen efter tidigare forskning och vetenskap i sökverktyg online och i vetenskapliga databaser som Google scholar, ScienceDirect och Taylor & Francis Online. För validitetskontroll av artiklar, böcker och föreläsningar kontrollerades att publikationerna kunde hittas i vetenskapliga databaser samt att de citerats i andra vetenskapliga publikationer (Denscombe, 2010).

En kvalitativ analys av de insamlade vetenskapliga publikationer genomfördes, där relaterad och relevant tidigare forskning annoterades som kunskapsbas för arbetet. För att kunna säkerställa att tidigare kunskapsbidrag synliggörs och kan följas upp så har all insamlad kunskap och forskning som använts i uppsatsen refererats till och citerats i enlighet med forskningsetiska principer (Denscombe, 2010).

5 Artefakten

5.1 Utveckling och metodtillämpning

5.2.1 Ordlistan

I aktiviteten "designa och utveckla artefakt" användes kvalitativa datainsamlingsmetoder och analysmetoder, samt en del icke-vetenskaplig praxis. En stor del av artefaktens utveckling bestod av att skapa en ordlista, där det slutgiltiga resultatet återfinns i Bilaga A. Utvecklingen skedde i flera steg där kvalitativ data samlades in och analyserades iterativt i flera omgångar, och där inspiration från processen hämtades från dels Shrestha, Akrami och Kaatis (2020) forskning om Digital-7, samt van der Vegts et al. (2021) forskning om "The grievance dictionary".

5.2.1.1 Insamling från tidigare ordlista

En första datainsamling av kvalitativ data från dokument gjordes av ordlistan för våld från Shrestha, Akrami och Kaatis (2020) forskning. Ordlistan valdes som urval då den innehåller flera allmänt vedertagna våldsord och kunde därför utgöra en grund för artefaktens ordlista.

Det insamlade materialet låg därefter till grund för en första dataanalys, då våldsord som inte passade detta arbetes definition av våld behövde exkluderas från ordlistan. Metoden kan liknas vid en kvalitativ innehållsanalys men följer inte alla steg som definierar den vetenskapliga metoden. Analysen av ordlistan gjordes individuellt av uppsatsens två författare. De ord som båda författare hade bedömt passade definitionen sparades i artefaktens ordlista. De ord som båda författarna i sina respektive dataanalyser hade avfärdat och inte bedömt matcha definitionen av våldsuttryck sparades i en separat lista med avfärdade ord. Det slutgiltiga resultatet av denna lista återfinns i Bilaga B. Syftet med att spara förkastade våldsuttryck var att kunna agera transparent vid granskning av resultatet, som förespråkats i tidigare forskning (van der Vegt et al., 2021; Shrestha, Akrami och Kaati, 2020). De ord som enbart en av de två författarna hade avfärdat sparades i en separat tillfällig ordlista. För att få ett annat perspektiv på dessa ord togs de upp i diskussion med en utomstående expert inom hotbedömning och textanalys, som fick ge sin bedömning på orden. De ord som experten efter en diskussion bedömde matchade definitionen och forskningsmålet lades till i artefaktens ordlista, övriga lades till i listan över avfärdade våldsuttryck.

I detta moment lades 43 ord till i artefaktens ordlista. 78 ord lades till i listan med avfärdade våldsuttryck, varav 73 ord hade avfärdats direkt av båda författarna, och övriga 5 efter diskussion med en utomstående expert.

5.2.1.2 Annotering från digitala plattformar

För att få en djupare förståelse och för att förankra ordlistan i den specifika jargong som sociala medier präglas av, gjordes en kvalitativ analys av den avsedda miljön genom att granska innehåll på digitala plattformar. För att öka sannolikheten att kunna söka upp trådar med potentiellt våldsamt innehåll valdes tre forum ut, som i tidigare forskning och utredningar visat sig engagera individer med en våldsbejakande attityd; incels.is, stormfront.org och 4chan.org/pol/. I respektive tre forum valdes minst 100 inlägg ut för granskning, via ett utforskande urval av diskussionstrådar. Urvalet gjordes på premissen att tråden behövde innehålla ett inledande inlägg med hatiska eller hotfulla budskap, samt att tråden omfattar minst 20 inlägg för att kunna representera en tillräckligt aktiv diskussion. Hyperlänkar till de trådar som datainsamlingen resulterade i återfinns i bilaga D. Materialet som samlades in kan likställas med onlinedokument som datainsamlingsmetod, och låg därefter till grund för en innehållsanalys. Utöver att bekanta sig med miljön så annoterades även våldsuttryck ur det insamlade materialet individuellt av författarna, likt tillvägagångssättet i föregående moment. De ord som båda författarna hade annoterat lades till i artefaktens ordlista. Övriga ord, som endast en av författarna hade annoterat, sparades i en separat tillfällig lista. Denna lista skickades till samma utomstående expert för bedömning. De ord som experten efter diskussion bedömde matchade definitionen och forskningsmålet lades till i artefaktens ordlista, övriga lades till i listan över avfärdade våldsuttryck.

I detta moment annoterades totalt 20 unika ord, varav 8 hade valts ut av båda författarna. Övriga 12 ord togs upp i diskussion med utomstående expert, där 4 ord avfärdades. Av de 16 ord som bedömdes matcha definitionen kunde 8 av dessa redan återfinnas i den ursprungliga ordlistan. Efter detta moment utökades därmed ordlistan med 8 ord till att bestå av totalt 51 ord. Listan över avfärdade ord utökades med 4 ord till att totalt bestå av 82 ord.

5.2.1.3 Term Set Expander

I den tredje och sista iterationen av datainhämtning och analys användes verktyget Term Set Expander (TSE) i flera repetitioner för datainsamling i form av onlinedokument. Verktyget innehåller olika dataset från digitala plattformar med engelska som primärt språk. Respektive dataset kommer från följande plattformar: Reddit, Stormfront, Gab, Incels, Daily Stormer, Incels.co, Looksmax.me, Lookism.net, 4-chan, 8-kun och Twitter. Verktyget låter en användare registrera ett ord eller en lista av ord, samt välja vilket dataset (forum), som ordet ska kartläggas mot. TSE returnerar därefter ord som potentiellt kan inneha samma bakomliggande budskap i det dataset som valts. I enkla termer kan man beskriva verktyget som en budskapsgenerator i en given kontext. Funktionen speglar det som gjordes i steg 5 i Shrestha, Akrami och Kaatis (2020) forskning (se avsnitt 2.2). Orden som TSE returnerade kan likställas med en lista av kvalitativ data, som låg till grund för

ytterligare en kvalitativ innehållsanalys, där ordens överensstämmelse med definitionen för våldsuttryck bedömdes.

Eftersom ordlistan behövde vara väl förankrad med den forumspecifika jargongen för att kunna uppfylla forskningsmålet, så valdes fem av de elva dataseten i TSE som urval; Incels, 4chan/pol/, 8kun, Daily Stormer och Reddit. De fyra förstnämnda forumen kan klassificeras som extrema i sin karaktär, utifrån tidigare granskningar av innehåll (Kaati, Shrestha och Akrami 2022; Baele, Brace och Coan 2021). Likt tidigare två moment utfördes analysen individuellt av båda författarna. Genom att mata in den hittills ackumulerade ordlistan av våldsuttryck i TSE utgick även respektive författare från samma grunddata. Följande steg utfördes därefter:

1. Ett forum valdes som dataset i TSE och en kopia av den tidigare ackumulerade ordlistan med våldsuttryck registrerades.
2. TSE gav därefter förslag på nya ord. De föreslagna ord som författaren bedömde matchar definitionen av våld sparades i den kopierade ordlistan. Ord som inte bedömdes matcha definitionen avfärdades utan att sparas.
3. Om nya ord lades till i steg 3 så kördes den ackumulerade ordlistan om i samma dataset igen, och upprepades tills dess att inga nya föreslagna ord sparades.
4. Steg 1-3 upprepades på resterande fyra dataset.

När alla dataset var genomlysta så hade båda författarna gått igenom över 6 500 föreslagna ord vardera. Respektive författare sammanfogade därefter sina annoterade ord från alla fem dataset till en sammanställd ordlista, där dubbletter rensades bort. Likt de tidigare momenten av dataanalys så jämfördes slutligen författarnas båda ordlistor. Ord som förekom i båda ordlistor ersatte artefaktens befintliga ordlista. De ord som endast förekom i en av författarnas listor sparades i en separat tillfällig lista. Denna tillfälliga lista skickades till experten inom hotbedömning och textanalys. De ord som experten efter diskussion bedömde matchade definitionen och forskningsmålet lades till i artefaktens ordlista, övriga lades till i listan över avfärdade våldsuttryck. I ett sista steg så lades olika suffix till för samtliga ord i artefaktens ordlista.

I detta moment lades 176 ord inklusive olika suffix till i ordlistan över våldsuttryck, som till slut landade på 227 ord. Efter diskussion med utomstående expert lade 97 ord till i listan över avfärdade ord, som till slut landade på 179 ord.

5.2.2 Koden

För att metoden som ska mäta förekomst av våldsuttryck i en text skulle kunna fungera automatiskt behövde även programmeringskod utvecklas för själva textanalysen. Algoritmerna som skrevs jämför hur många gånger ord ur

ordlistan kan identifieras i en annan textfil. För att detta skulle gå så konverteras all text i valt dataset till små bokstäver för att identifieringen av ord i ordlistan inte skulle vara "case sensitive". Dessutom har alla specialtecken och siffror förutom mellanslag rensats bort, så att t.ex. "rape." blir "rape" och "mass-murder" blir "massmurder", vilket är en felaktig hopskrivning som är vanligt förekommande online och därför finns med i ordlistan. För en möjlighet till eventuell felsökning och framtida djupare analys utvecklades även kod för att kunna presentera hur många gånger ett unikt våldsuttryck identifierats i datasetet. För att kunna presentera ett genomsnittligt användande av våldsord skrevs även en algoritm som räknade ut ett genomsnitt på hur många våldsuttryck som identifierats i datasetet. Koden som innehåller samtliga av dessa algoritmer skrevs i programmeringsspråket Python, med hjälp av IDEn PyCharm CE, och finns i Bilaga C.

6 Demonstration och utvärdering

6.1 Beskrivning av artefakten

Artefakten består dels av programkod, dels av en ordlista som innehåller 227 olika våldsuttryck. Med hjälp av algoritmer i programmeringskod mäter den förekomsten av ordlistans innehåll i ett - av användaren - valt dataset. Den presenterar därefter data på:

- Antal identifierade våldsuttryck
- Antal genomsökta ord i datasetet
- Genomsnittligt antal träffar per 100 000 ord
- Vilka våldsuttryck som identifierats samt hur många gånger

6.2 Metodtillämpning

I de avslutande aktiviteterna "demonstrera artefakt" och "utvärdera artefakt" syns varför en blandning av kvantitativa och kvalitativa metoder användes som forskningsstrategi. I dessa aktiviteter behövde nämligen kvantitativa metoder användas för att kunna utvärdera artefakten och därmed säkerställa att forskningsmålet blivit uppfyllt.

För utvärderingen av artefakten bedömdes den miljö som artefakten är tilltänkt att användas i som ett relevant urval av data, det vill säga samtida sociala medier. En datainsamling gjordes från 20 olika plattformar, som Kaati, Shrestha och Akrami (2022) använde för utvärdering i deras forskning av toxiskt språk. Se beskrivningar av de forum data samlades in från och som användes i utvärderingen i Tabell 1.

Forum/miljö	Beskrivning
8kun	Ett forum sammanbyggt av användarskapade trådar där bilder är vanligt förekommande
Airliners	Ett forum för diskussioner om flygteknik och flygplan
Alternate history	Ett forum för diskussioner om alternativ historia
Bitcoin	Ett forum för diskussioner om bitcoin
Blackpill	Ett diskussionsforum för incels
Bodybuildning forum	Ett forum för diskussioner om träning och muskelbyggande
Gates of Vienna	En anti-muslimsk bloggportal med kommentarsfält
Incels.co	Ett diskussionsforum för incels
Incels.is	Ett diskussionsforum för incels
Incels.net	Ett diskussionsforum för incels
Lookism	Ett diskussionsforum för incels med fokus på utseende
Looksmaxxing forum	Ett diskussionsforum för incels med fokus på utseende
Looksmax.org	Ett diskussionsforum för incels med fokus på utseende
Looks theory	Ett incelforum med fokus på teorier om hur utseende påverkar attraktion
Mumsnet	Ett diskussionsforum om famljeliv och barn
Ni**ermania	Ett diskussionsforum med nedsättande skämt och rasistiska kommentarer om mörkhyade personer
Non Cucks United	Ett diskussionsforum för incels
Sims 4	Ett diskussionsforum för spelet The Sims
Stormfront	En av de mest kända diskussionsforumen för vit makt-rörelsen
The Suicide Project	Ett diskussionsforum för historier om desperation och depression

Tabell 1 Tabell med beskrivning av data som använts vid utvärderingen av artefakten

För att kunna utvärdera artefaktens förmåga att mäta våldsuttryck användes data både från forum med sedan tidigare känt hatiskt innehåll samt mer generella forum-miljöer. För att forskningsmålet ska uppnås, det vill säga att metoden fungerar, så borde resultatet kunna visa en noterbar skillnad av antal förekommande våldsord i dessa olika miljöer. Utifrån tillgängligt urval av dataset kunde 20 separata experiment utföras i utvärderingen, ett för varje dataset.

Respektive dataset laddades upp i artefakten och programkoden exekverades. Utifrån resultatet skapades deskriptiv statistik, i form av stapeldiagram samt tabeller. Detta möjliggjorde en enklare komparativ analys av genomsnittligt antal träffar mellan de olika dataseten. Det gjorde även presentationen av resultatet mer överskådligt för läsaren.

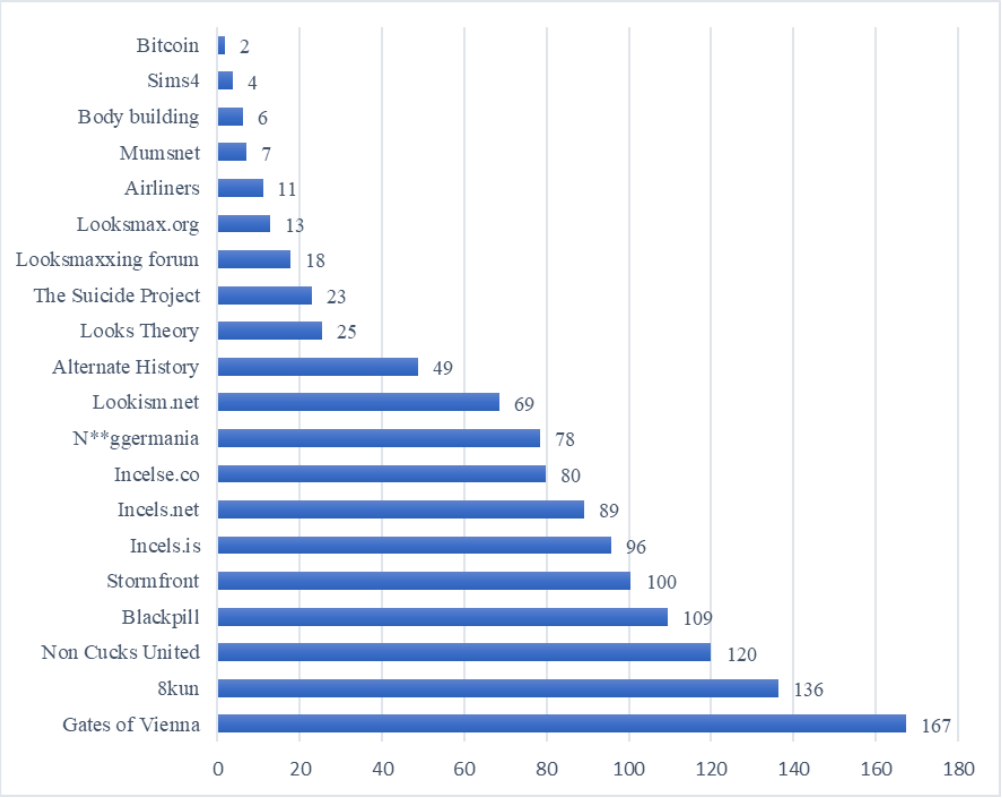
6.3 Resultat

Utifrån de 20 experiment som utfördes i utvärderingen av artefakten hade Gates of Vienna och 8kun det högsta genomsnittliga bruket av våldsamma ord, med 167 respektive 136 våldsuttryck. I andra änden av spektrumet fanns forumsidor om Bitcoin och The Sims 4, med 2 respektive 4 våldsuttryck. Vid en jämförelse mellan högst och lägst förekomst av våldsord så innehöll Gates of Vienna cirka 100 gånger fler våldsuttryck än ett Bitcoin-forum.

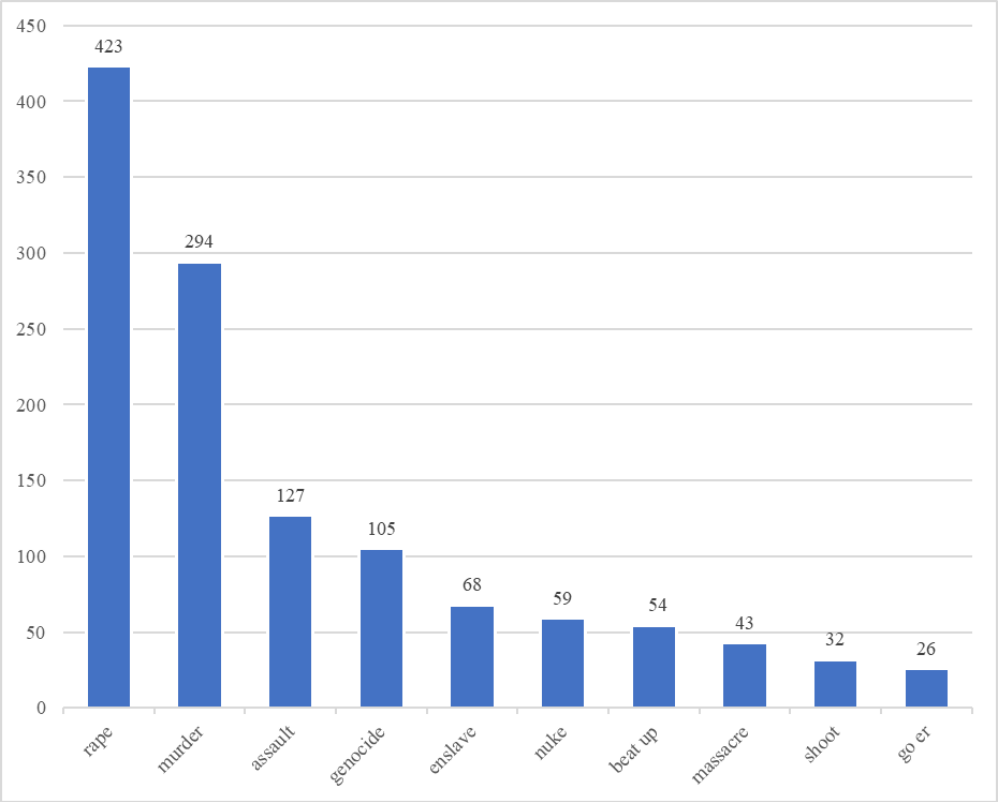
I Tabell 2 presenteras statistik från respektive experiment, med storleken (antal ord) på datasetet, antal identifierade våldsuttryck, samt genomsnittet av antal våldsuttryck per 100 000 ord, avrundat till två decimaler.

Namn på forum	**Ord i dataset**	**Våldsuttryck**	**Våldsuttryck per 100 000 ord**
Gates of Vienna	107592	180	167,30
8kun	131974	180	136,39
Non Cucks United	150029	180	119,98
Blackpill	79536	87	109,38
Stormfront	195039	196	100,49
Incels.is	84609	81	95,73
Incels.net	90908	81	89,10
Incels.co	47647	38	79,75
Ni**ermania	119845	94	78,43
Lookism.net	65588	45	68,61
Alternate History	322008	157	48,76
Looks theory	67000	17	25,37
The Suicide Project	291245	67	23,00
Looksmaxxing Forum	90006	16	17,78
Looksmax.org	69924	9	12,87
Airliners	153764	17	11,056
Mumsnet	141941	10	7,05
Bodybuilding	130897	8	6,11
Sims 4	339250	13	3,83
Bitcoin	180397	3	1,66

Tabell 2 Tabell över antal matchade ord från ordlistan på dataset från olika forum



Figur 2 Stapeldiagram av det genomsnittliga antalet våldsuttryck från ordlistan per 100 000 ord på dataset från olika forum

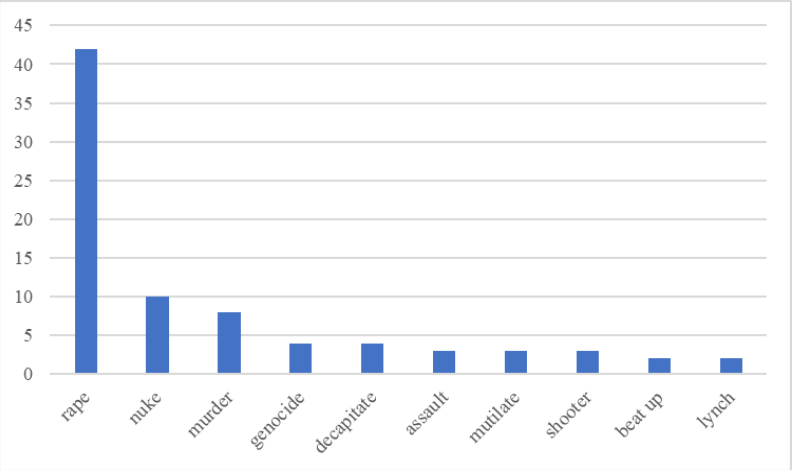


Figur 3 Stapeldiagram över de 10 mest förekommande våldsuttrycken i utvärderingen av artefakten

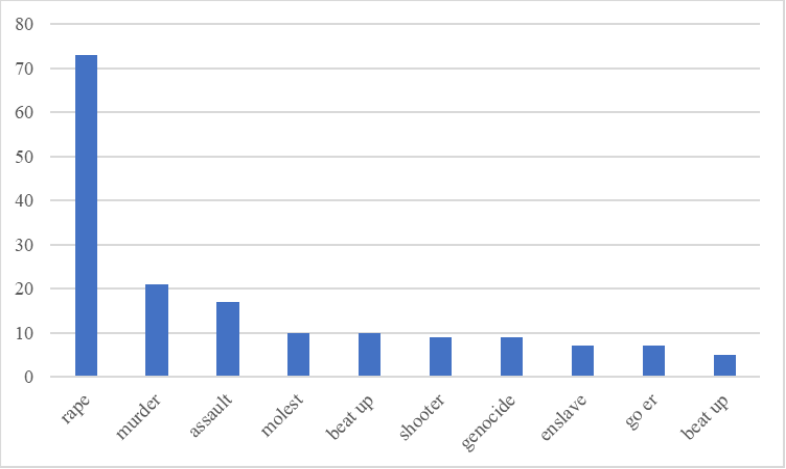
I figur 2 visas ett stapeldiagram över respektive experiments genomsnittliga antal våldsord per 100 000 ord i datasetet, avrundat till närmaste heltal.

För att kunna se fördelningen över de vanligast förekommande vålduttrycken så adderades ord som fått träffar med olika suffix ihop till ett sammanfattande ord; "murdered", "murdering" och "murder" blev till exempel sammanställt till "murder". Figur 3 visar de 10 våldsuttryck som var mest förekommande när träffarna från alla 20 experiment lades ihop.

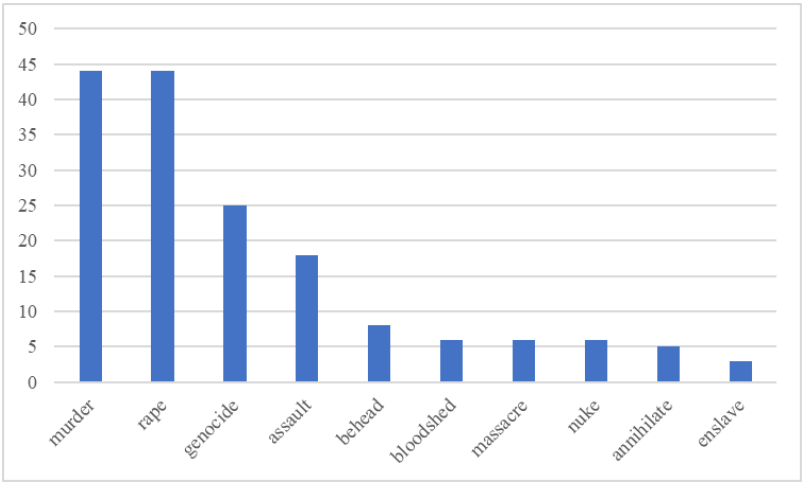
För att närmare granska hur våldsuttrycken eventuellt skiljer sig mellan de olika forumen och miljöerna gjordes även en granskning av de 10 mest förekommande våldsuttrycken i respektive dataset. I Figur 4, 5, 6 och 7 finns ett urval av denna statistik, från nationalistiska forum och incelsmiljöer. Där har liknande ord med olika suffix - likt i Figur 3 - adderats till ett gemensamt ord för att enklare kunna presentera de vanligaste förekommande uttrycken. I Figur 8 finns även en sammanställning över de 10 mest förekommande våldsuttrycken i de fyra forum som enligt utvärderingen hade lägst genomsnitt av antal våldsuttryck. I det diagrammet har resultaten från Mumsnet, Sims 4, Bitcoin och Bodybuilding sammanställts.



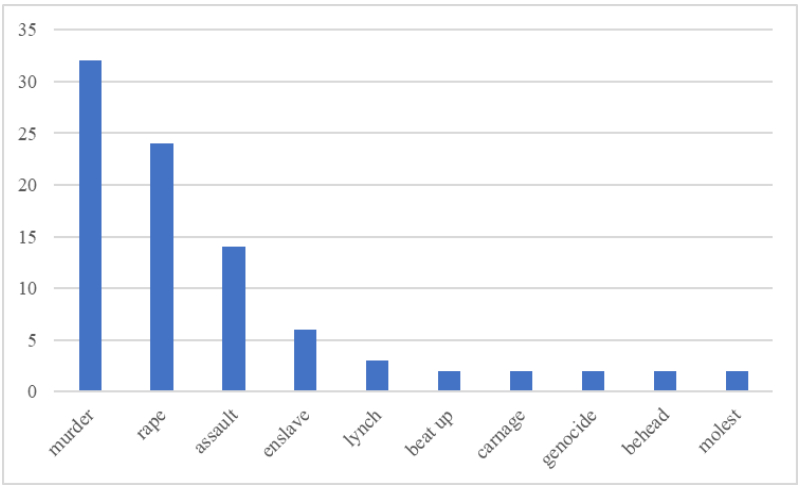
Figur 4 Stapeldiagram över de 10 mest förekommande våldsuttrycken på Blackpill



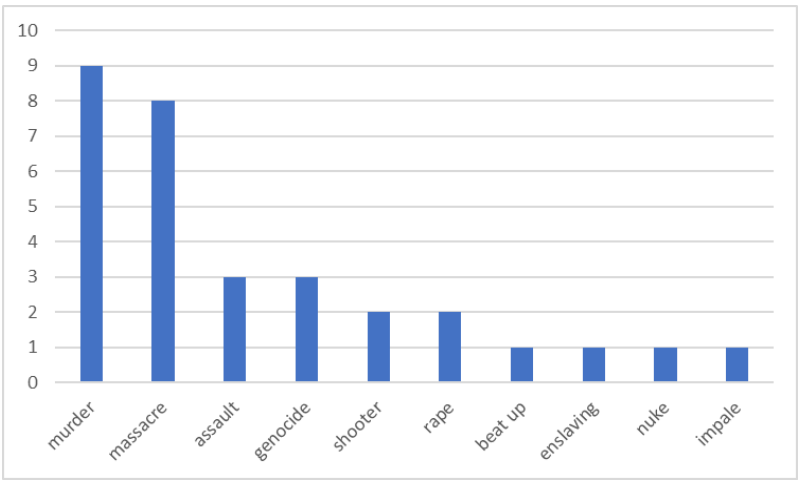
Figur 5 Stapeldiagram över de 10 mest förekommande våldsuttrycken på Non Cucks United



Figur 6 Stapeldiagram över de 10 mest förekommande våldsuttrycken på Gates of Vienna



Figur 7 Stapeldiagram över de 10 mest förekommande våldsuttrycken på Ni**ermania



Figur 8 Stapeldiagram över de 10 mest förekommande våldsuttrycken på Mumsnet, Bitcoin, Sims 4 och Bodybuilding

Det som blir synligt i denna statistik är att forum som är riktade mot incels har en klart högre andel förekomst av uttrycket "rape", inklusive ordets olika suffix. De mer högernationalistiska forumen har en större spridning där uttryck som "murder" och "assault" används i högre grad. Även på dessa sidor tillhör dock "rape" i regel ett av de tre mest använda uttrycken. Granskar man de forum som haft lägst genomsnittligt bruk av våldsuttryck så återfinns även "murder", men också "massacre", som mer vanligt förekommande vålds-uttryck utifrån ordlistan.

7 Diskussion

7.1 Resultatanalys

Spridningen av antal våldsuttryck i de olika dataseten och fynden av identifierade våldsord i respektive dataset indikerar att artefakten levererar det den är tänkt att göra. Spektrumet är i linje med vad som initialt skulle kunna förväntas utifrån karaktären på de olika utvalda forumen. De mer generella forumen, såsom Bitcoin, Sims4 och Mumsnet ligger på den lägre skalan av våldsuttryck. Följt av incelsforum med ett större fokus på utseende och skönhetsideal, snarare än hat mot kvinnor. På den högre skalan varvas mer extrema incelsforum med de mer nationalistiska och högerextrema forumen.

Vid en granskning av artefaktens systemtekniska funktioner så möter dessa de krav som ställts. Den mäter och presenterar hur många ord som analyserats, antal träffar, genomsnittligt antal träffar av 100 000, samt hur många gånger varje uttryck förekommit i datasetet.

Med tanke på att ingen annan forskning hittats som likt denna mäter våldsuttryck ur en ordlista på olika samtida sociala medier, kan resultaten inte fullt ut jämföras med likvärdiga fynd. Däremot gjorde Kaati, Shrestha och Akrami (2022) en mätning av toxiskt språk på samma data som i utvärderingen av denna metod. I deras utvärdering fick Ni**ermania högst utslag på 62% toxiskt språk, medan Gates of Vienna enbart fick 8% utslag. Resultatet från utvärderingen i detta arbete visar i stället på en nästan omvänd relation. Gates of Vienna, som blivit omnämnd som den sida där Anders Breivik hämtade sin inspiration inför terrordådet i Norge 2011 (Robinson, 2011), fick i utvärderingen det högsta genomsnittet med 167 våldsuttryck. Ni**ermania hade i stället endast ett genomsnitt på 78 våldsuttryck, som var strax över det genomsnittliga medelvärdet på 60 våldsuttryck per 100 000 ord. Då denna metod enbart mäter våldsuttryck och inte har med toxiskt språk, kan det ge en nyanserad bild över plattformar där diskussioner inte identifierats som särskilt toxiska, men där innehållet ändå verkar ha ett större fokus på våld.

Att uttrycket "rape", med olika suffix, framkom som ett av de vanligast förekommande orden är ett förväntat resultat med tanke på att urvalet innehåller flera forum med kopplingar till incels. Tidigare forskning har konstaterat att dessa forum har flera medlemmar som besitter och explicit uttrycker ett hat mot kvinnor (Pröitz, Langeland och Mainsah, 2021; Fernquist et al., 2020). Även den kvalitativa datainsamlingen från incels.is visade på medlemmarnas lättsamma syn på just våldtäkter, se länk till forumtråd "rape isn’t that bad" under incels.is i Bilaga D.

I de högernationalistiska och rasistiska forumen var "rape" fortfarande ett av de mest använda orden, men där fanns en större spridning av våldsuttryck som

inte hade en sexuell koppling. Att forum som Stormfront och 8kun ligger högt i skalan av genomsnittligt antal våldsuttryck är något som kunde förväntas utifrån tidigare studier på dessa forum, som konstaterat att innehållet präglas av extrema åsikter med stark koppling till rasism och vit makt (Figea, Kaati och Scrivens, 2016; Baele, Brace och Coan, 2021).

Våldsuttrycken "murder" och "massacre" var de mest vanligt förekommande orden i forum som fick lågt genomsnitt på våldsuttryck. Eftersom orden tas ur sin kontext är det inte möjligt att utvärdera huruvida inläggen är våldsbejakande eller om våldsuttrycken tas upp i negativ eller neutral bemärkelse. Men om ett antagande görs att diskussionerna som förs på dessa forum inte är positiva till våld, så kan det även indikera att ord som "murder" och "massacre" generellt skulle kunna innehålla en hög felmarginal, om syftet är att mäta diskussioner med positiv inställning till våld. För att kunna besvara en sådan frågeställning skulle dock en djupare kvalitativ granskning av inläggen med identifiera våldsuttryck behöva genomföras, vilket tyvärr inte ryms inom detta arbete.

7.2 Begränsningar

I den här studien har vi använt oss av en metod baserad på ordlista för att identifiera våldsuttryck. Ordlistor är den enklaste formen av textanalys och har därför ett flertal tillkortakommanden.

Vår artefakt visar inte den semantiska innebörden av uttrycket eller i vilken kontext det används i. Det går alltså inte att med enbart denna statistiska data utvärdera huruvida diskussionerna är positiva, negativa eller neutrala till våld. För att avgöra hur pass effektiv den är i att med precision kunna identifiera forum där diskussioner om våld kan anses som en risk för individer, det vill säga våldsbejakande propaganda, så krävs en djupare kvalitativ granskning av inläggen med identifierade våldsuttryck.

Det är viktigt att poängtera att även om vi använt oss av mer avancerade textanalys metoder som exempelvis maskininlärning så har automatiserade metoder för textanalys ännu inte nått den nivå av avancerad artificiell intelligens som kan motsvara eller överträffa mänsklig kompetens och analys (Shrestha, Akrami och Kaati, 2020). Resultaten från automatiserad textanalys behöver generellt kompletteras med en manuell och mänsklig kvalitativ granskning innan några definitiva slutsatser kan dras kring resultaten.

Då framtagandet av ordlistan har utförts av författarna till denna uppsats och i konsultation med en utomstående expert finns en grad av subjektivitet i uppfattningen om och valet av våldsuttryck. Med det i åtanke skulle det vara svårt för någon annan med samma datainsamling att till fullo kunna återskapa resultatet i detalj. Det är dock tänkbart att en liknande spridning av genomsnittligt antal våldsuttryck skulle kunna uppnås i en liknande studie,

med tanke på forumens karaktär samt den tydliga skillnaden i förekomsten av våldsuttryck mellan de olika dataseten i denna studie.

Eftersom publika digitala plattformar som är kopplade till våldsbejakande vänsterextremism och våldsbejakande islamistisk extremism är begränsat har framför allt data från free speech plattformar och ideologiska plattformar kopplade till högerextremism använts för framtagandet av artefakten. Detta kan leda till att artefaktens förmåga att upptäcka våldsuttryck är mer begränsad på plattformar med kopplingar till vänsterextremism och islamistisk extremism.

De dataset som användes i utvärderingen är enbart ett urval av den data som finns på forumen som de hämtats från vid en specifik tidpunkt. Det är svårt att dra en slutsats på hur pass representativt urvalet är för det totala innehållet på dessa forum, och hur resultatet hade sett ut om all tillgänglig data samlats in. Vidare kan det inte uteslutas att innehållet är fångat i sin ursprungliga form, då innehållet kan ha modifierats eller redigerats. Flera forum har aktiva moderatorer som utifrån plattformens policy kontinuerligt rensar trådar och inlägg med innehåll som går mot sidans policy (Denscombe, 2010). Utifrån problemformuleringen, där våld i diskussioner nämns som en risk för andra att ta del av, är dock en eventuell rensning av våldsbejakande innehåll inte något som påverkar slutsatsen, då raderade våldsuttryck inte skulle kunna innebära en ökad risk för andra individer. Däremot kan resultaten om hur vanligt våld är i diskussioner på olika forum eventuellt vara påverkat. Framför allt i forum med mer generell karaktär, eftersom de i regel har en mycket starkare moderering än högernationalistiska forum likt Stormfront, eller välkänt låg-modererade sidor som t.ex. 4chan och 8kun där många extrema högernationalistiska idéer spridits (Kaati, Shrestha och Nazar, 2022).

7.3 Etiska aspekter

Denna studies resultat har inga direkta konsekvenser för eller inverkan på samhället i stort. Syftet för studien och artefaktens tilltänkta funktion är dock omdiskuterad då den inbegriper ett mål att kunna övervaka och eventuellt inskränka det fria samtalet på internet (Grover och Mark, 2019).

För de individer som publicerat materialet som använts i datainsamlingen för de olika stegen i att utveckla och utvärdera artefakten finns minimal till obefintlig förhöjd risk för att ta skada av detta arbete. Dels är data hämtad från redan publikt tillgängligt material, dels är resultaten av studien avidentifierade, dels är de alias som går att spåra från den datainsamling som finns tillgänglig i Bilaga D inte knutna till individer som kan identifieras.

7.4 Slutsats

Resultatet av detta arbete och den artefakt som utvecklats är en metod som kan identifiera våldsuttryck i diskussioner på sociala medier, då utvärderingen visar på en realistisk spridning utifrån forumens generella karaktär och miljö.

För att kunna användas som ett framtida komplement i hotbedömning av digitala plattformar krävs dock en mer kvalitativ granskning av inläggen med identifierade våldsuttryck, för att analysera hur stor del av våldsuttrycken som tas upp i positiv eller våldsbejakande bemärkelse.

7.5 Fortsatt forskning

Då syftet med artefakten är att den på sikt ska kunna användas som ett komplement i hotbedömningar av digitala plattformar hade det varit motiverat att göra en semantisk analys på inläggen med identifierade våldsuttryck. Det hade då varit möjligt att få ett realistiskt resultat över förekomst av faktiska våldsbejakande uttryck snarare än enbart uttryck som beskriver våld. Det hade kunnat möjliggöra en eventuell vidareutveckling av ordlistan, där identifierade ord som i hög grad inte används i våldsbejakande syften förkastas och därmed förbättrar artefaktens precision i eventuella hotbedömningar.

Det hade också varit intressant att vidareutveckla Liu och Dongs (2022) forskning om hur rapporteringen av masskjutningar i sociala medier påverkar andra till våldsdåd, men istället utforska *hur* våld i sociala medier påverkar andra individer. Att individen har en flexibel tröskel för inställning till våld har tidigare påvisats (Lövkrona och Nilsson, 2015), men vilka faktorer som är avgörande samt hur stor påverkan exponering mot våld i diskussioner på sociala medier har i våldsbejakande radikalisering är ännu inte på djupet utforskat.

Referenser

Baele, S. J., Brace, L. och Coan, T. G. (2021). Variations on a Theme? Comparing 4chan, 8kun, and Other chans' Far-Right "/pol" Boards. *Perspectives on Terrorism* 15(1): 65-80. https://www.jstor.org/stable/26984798#metadata_info_tab_contents (Hämtad 2022-11-27)

Bildjuschkin, K., Ewalds, H., Hietamäki, J., Kettunen, H., Koivula, T., Mäkelä, J., Nipuli, S., October, M., Peltonen, J. och Siukola, R. (2021). *Ordlista över våldsbegrepp*. Institutet för hälsa och välfärd. Nätpublikation https://urn.fi/URN:ISBN:978-952-343-706-7

Chayka, K. (2022). The online spaces that enable mass shooters. *The New Yorker.* https://www.newyorker.com/culture/infinite-scroll/the-online-spaces-that-enable-mass-shooters (Hämtad 2022-11-28)

Cohen, K., Johansson, F., Kaati, L. och Clausen Mork, J. (2014). Detecting Linguistic Markers for Radical Violence in Social Media. *Terrorism and Political Violence* 26(1): 246-256. https://doi.org/10.1080/09546553.2014.849948

Conway, M. (2012). From al-Zarqawi to al-Awlaki: The Emergence and Development of an Online Radical Milieu. *CTX: Combating Terrorism Exchange* 2(4). https://core.ac.uk/download/pdf/147603165.pdf

Denscombe, M. (2010). *The Good Research Guide for Small Scale Research Projects* (4th ed.). Buckingham: Open University Press.

Fernquist, J., Pelzer, B., Cohen, K., Kaati, L. och Akrami, N. (2020). *Hope, cope & rope - Incels i digitala miljöer*. FOI memo 7040. Totalförsvarets forskningsinstitut. https://www.foi.se/rest-api/report/FOI%20Memo%207040

Figea, L., Kaati, L. och Scrivens, R. (2016). Measuring online affects in a white supremacy forum. *I 2016 IEEE Conference on Intelligence and Security Informatics (ISI)*, 85–90. https://ieeexplore.ieee.org/document/7745448

Grover, T. och Mark, G. (2019). Detecting Potential Warning Behaviors of Ideological Radicalization in an Alt-Right Subreddit. *I Thirteenth International AAAI Conference on Web and Social Media*. München, Tyskland, 11-14 Juni, 193-204. https://doi.org/10.1609/icwsm.v13i01.3221

Hawkes, A. G. (1971). Point spectra of some mutually exciting point processes. *Journal of the Royal Statistical Society: Series B* (Methodological) 33(3): 438-443.

Hine, G. E., Onaolapo, J., De Cristofaro, E., Kourtellis, N., Leontiadis, I., Samaras, R., Stringhini, G. och Blackburn, J. (2017). Kek, Cucks, and God Emperor Trump: a measurement study of 4chan's politically incorrect forum and its effects on the web. I *Proceedings of the Eleventh International AAAI Conference on Web and Social Media*. Montréal, Québec, Canada, 15–18 maj, 10. https://aaai.org/ocs/index.php/ICWSM/ICWSM17/paper/view/15670

Jaki, S., De Smedt, T., Gwóźdź, M., Panchal, R., Rossa, A. och De Pauw, G. (2019). *Online hatred of women in the Incels. me forum: linguistic analysis and automatic detection.* J Lang Aggr Confl 7(2): 240– 268. https://doi.org/10.1075/jlac.00026.jak

Johannesson, P. och Perjons, E. (2014). *An Introduction to Design Science*. Switzerland: Springer International Publishing.

Kaati, L. (2022). *Term Set Expander. Semantic similarities in digital environments.* Institutionen för data- och systemvetenskap. Stockholms Universitet.

Kaati, L., Shrestha, A. och Akrami, N. (2022). A Machine Learning Approach to Identify Toxic Language in the Online Space. *I 2022 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining (ASONAM)*. Istanbul, Turkey, 10-13 november. https://www.researchgate.net/publication/331857893_A_Machine_Learning_Approach_to_Comment_Toxicity_Classification

Kaati, L., Shrestha, A. och Sardella, T. (2016). Identifying Warning Behaviors of Violent Lone Offenders in Written Communication. *I 2016 IEEE 16th International Conference on Data Mining Workshops (ICDMW)*. Barcelona, Spain, 12-15 december. https://doi.org/10.1109/ICDMW.2016.0152

Kleinberg, B., van der Vegt, I. och Gill, P. (2021). The temporal evolution of a far-right forum. *Journal of Computational Social Science* 4: 1–23. https://doi.org/10.1007/s42001-020-00064-x

Krug, E., Mercy, J., Dahlberg, L. och Zwi, A. (2002). The world report on violence and health. *Lancet*. 360: 1083–1088. https://doi.org/10.1016/S0140-6736(02)11133-0

Langman, P. (2017). *Role models, contagions, and copycats: An exploration of the influence of prior killers on subsequent attacks.* https://schoolshooters.info/role-models-contagions-and-copycats-exploration-influence-prior-killers-subsequent-attacks (Hämtad 2022-11-27)

Liu, D. och Dong, Z. S. (2022). Exploring the Contagion Effect of Social Media on Mass Shootings. *Computers & Industrial Engineering* 172(1). https://doi.org/10.1016/j.cie.2022.108565

Lövkrona, I. och Nilsson, G. (2015). Vad är våld. *Svensk etnologisk tidsskrift.* 3-4(6): 44-52. https://www.umu.se/globalassets/organisation/fakulteter/humfak/institutionen-for-kultur--och-medievetenskaper/forskning/kp/kp-3-4-2015---for-webben.pdf#page=46 (Hämtad 2022-11-25)

NCT, Nationellt Centrum för Terrorhotbedömning. (2022). *Helårsbedömning 2022 - sammanfattning.* https://www.sakerhetspolisen.se/download/18.650ed51617f9c29b5523af/1650635357383/NCT-Helarsbedomning-2022.pdf (Hämtad 2022-12-11)

Pröitz, L., Langeland, F. och Mainsah, H. (red.). (2021). *From boyhood to radicalised masculinity: A rapid research response from the International Symposium on Incels*. Steigen: Nora Forlag.

Robinson, E. (2011). Anders Behring Breivik and the influence industry of rage. *Washington Post*. https://www.washingtonpost.com/opinions/anders-behring-breivik-and-the-influence-industry-of-rage/2011/07/25/gIQASd2WZI_story.html (Hämtad 2022-12-15)

Scrivens, R., Davies, G. och Frank, R. (2018). Searching for signs of extremism on the web: an introduction to Sentiment-based Identification of Radical Authors. *Behavioral Sciences of Terrorism and Political Aggression* 10(1): 39-59. https://doi.org/10.1080/19434472.2016.1276612

Shrestha, A., Akrami, N. och Kaati, L. (2016). Linguistic Analysis of Lone Offender Manifestos. *I 2016 IEEE International Conference on Cybercrime and Computer Forensic (ICCCF)*. Vancouver, Canada, 12-14 Juni. https://doi.org/10.1109/ICCCF.2016.7740427

Shrestha, A., Akrami, N. och Kaati, L. (2020). Introducing digital-7: Threat assessment of individuals in digital environments. *I 2020 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining (ASONAM)*. Virtuell, 7-10 December, pp. 720–726. https://web.ntpu.edu.tw/~myday/doc/ASONAM2020/ASONAM2020_Proceedings/pdf/papers/114_142_720.pdf

Shrestha, A., Kaati, L. och Cohen, K. (2020). Extreme adopters in digital communities. *Journal of Threat Assessment and Management, 7*(1-2), 72–84. https://doi.org/10.1037/tam0000143

Säkerhetspolisen. (2022). *Ensamagerande gärningspersoner*. https://www.sakerhetspolisen.se/hoten-mot-sverige/terrorism-och-extremism/ensamagerande-garningspersoner.html (Hämtad 2022-11-25)

Townsend, L. och Wallace, C. (2016). *Social media research: A guide to ethics.* University of Aberdeen. https://www.gla.ac.uk/media/media_487729_en.pdf

van der Vegt, I., Mozes, M., Kleinberg, B. och Gill, P. (2021). The Grievance Dictionary: Understanding threatening language use. *Behavior Research Methods 53*(5): 2105-2119. https://doi.org/10.3758/s13428-021-01536-2

Bilagor

Bilaga A - Ordlista med våldsuttryck

acid attack	boiling alive	cannibalized	genocides	manslaughter	opens fire
acid attacked	boils alive	cannibalizing	genociding	mass execution	rape
acid attacking	brains blown out	carnage	go er	mass executions	raped
acid attacks	brutal beatings	death by stoning	goes er	massacre	rapes
acid throw	brutally beat	death camp	going er	massacred	raping
acid throwed	brutally beaten	death camps	guerrilla warfare	massacres	sexually abuse
acid throwing	brutally beating	death shower	gun down	massacring	sexually abused
acid throws	brutally beats	death showers	gunfire	massmurder	sexually abuses
acidfacing	bum rush	death squad	gunned down	massmurdered	sexually abusing
annihilate	bum rushed	death squads	gunning	massmurdering	shooter
annihilated	bum rushes	decapitate	gunning down	massmurders	shooters
annihilates	bum rushing	decapitated	guns down	missile attack	shootout
annihilation	bum rushings	decapitates	heads chopped off	missile attacking	skin alive
annihilations	bumrush	decapitating	holocausted	missile attacks	skinned alive
assault	bumrushed	enslave	holocausting	missile strike	skinning alive
assaulted	bumrushes	enslaved	honorkill	missile strikes	skins alive
assaulting	bumrushing	enslaves	honorkilled	missile striking	snipe
assaults	bumrushings	enslaving	honorkilling	molest	sniped
assrape	buried alive	eradicate	honorkills	molested	sniping
assraped	buries alive	eradicated	immolate	molesting	sodomize
assrapes	burn alive	eradicates	immolated	molests	sodomized
assraping	burn down cities	eradication	immolates	mow down	sodomizes
assrapings	burned alive	ethnic cleansing	immolating	mowed down	sodomizing
avenge	burned down cities	ethnic cleansings	impale	mowing down	stone to death
avenged	burning alive	ethnically cleanse	impaled	mows down	stoned to death
avenges	burning down cities	ethnically cleansed	impales	murder	stones to death
avenging	burns alive	ethnically cleanses	impaling	murdered	stoning to death
beat up	burns down cities	ethnically cleansing	incapacitate	murdering	

beating up	burnt alive	firebombed	incapacitated	murders	
beats up	bury alive	firebombing	incapacitates	mutilate	
behead	burying alive	forcibly fuck	incapacitating	mutilated	
beheaded	buttrape	forcibly fucked	knifed	mutilates	
beheading	buttraped	forcibly fucking	knifing	mutilating	
beheadings	buttrapes	forcibly fucks	lobotomize	mutilation	
beheads	buttraping	gangrape	lobotomizing	nuke	
bloodshed	buttrapings	gangraped	lynch	nuked	
bludgeoned	cannibalise	gangrapes	lynched	nukes	
bludgeoning	cannibalised	gangraping	lynches	nuking	
boil alive	cannibalising	genocide	lynching	opened fire	
boiled alive	cannibalize	genocided	lynchings	opening fire	

Bilaga B - Ordlista med avfärdade våldsuttryck

abuse	complete extermination	homicide	rebellion	terrorist act
acid face	conquer	honor kill	remove kebabs	terrorist attack
acidface	cull	injure	repay	terrorize
air raid	deadly	injuring	revolt	their heads chopped off
air strike	deadly weapon	invade	rightfully executed	thermonuclear war
airstrike	defeat	islamic terror	school shooters	torment
antagonize	deluge	kidnap	school shooting	tortured
apocalypse	destroy	kidnapping	seig heil	traumatize
arm yourself	destroying	kike terror	sexual assault	uncuck
arson	devastate	killed	sexually assault	unleash
assailant	die	killing	sexually molesting	victimize
assassin	died	lethal	shatter	war
assassinated	dies	mass murder	shoot	warfare
assfucked	disempower	mass shooters	shot	wars
attack	dismantle	mass shooting	should be steralized	weaken
badly beaten	drone strike	maul	should commit suicide	whacked
barrage	drop dead	melee	sieg heil	wipe out
bash	drown	mortal	slain	wound
before strangling her	eliminate	must be killed	slap	wounded
beheaded by	emasculate	must be purged	slaughtered	wounding
bereave	erase	nuclear holocaust	slay	
besiege	euthanize	obliterated	slayer	
black flag	execute	onslaught	slayin	
bloodthirsty	execution	open fire	slays	
blow up	executions	overpower	slew	
bludgeon	exploded	overtake	smack	
bomb	explosion	overthrow	smite	
bombardment	exterminate	physical damage	sodomizer	
bomber	extinction	physically fight	spiked	
bore	extinguish	poison	stabbed	

brutally murdered	fatal	poisoned	stabbing	
buttfucked	fatal shooting	poisoning	stabs	
castrate	felony	punish	steralize them	
chastise	gunshots	purge	strangling	
child molester	hanged	rampage	strung up	
child molesting	hate crime	rapists	suicide	
choke	hatefuck	ravage	suicide bomb	
crucify	heil	ravaged	terminate	
combat	heil hitler	raycis	terror act	
committing genocide	homocide	rebel	terror attack	

Bilaga C - Programmeringskod från artefakten (Python)

```
import re

def program():
	filename = input("Enter dataset text file name: ")
	dataset_handler = open(filename, "r")
	dataset_raw = dataset_handler.read()
	dataset = re.sub('[^A-Za-z ]+', '', dataset_raw).lower()

	wordlist_handler = open("wordlist.txt", "r")
	wordlist_raw = wordlist_handler.readlines()
	wordlist = [" "+word.strip()+" " for word in wordlist_raw]

	words = count_words(dataset)
	matches = count_matches(dataset, wordlist)
	average = calculate_average(words, matches)
	frequency = count_frequency(dataset, wordlist)

	print(f"Number of words in dataset: {words} \n"
		f"Number of matches with wordlist: {matches}\n"
		f"Average number of violent words: {average}\n"
		f"Times each word appeared in the dataset: {frequency}")

	dataset_handler.close()
	wordlist_handler.close()

def count_words(dataset):
	dataset_list = dataset.split()
	return len(dataset_list)

def count_matches(dataset, wordlist):
	count = 0
	for word in wordlist:
		count = count + dataset.count(word)
	return count

def calculate_average(words, match):
	return (match / words) * 100000

def count_frequency(dataset, wordlist):
	word_frequency = {}
	for word in wordlist:
		if dataset.count(word) != 0:
		word_frequency[word] = dataset.count(word)
	return word_frequency

if __name__ == '__main__':
	program()
```

Bilaga D - Utvalda trådar på forum

Incels.is

- https://incels.is/threads/rape-isnt-that-bad.410436/ 45 inlägg
- https://incels.is/threads/discord-foid-saw-my-video-lied-about-not-finding-me-ugly-and-then-mentioned-she-found-me-ugly-in-group-chat-and-posted-my-pic.425807/ 25 inlägg
- https://incels.is/threads/inceltear-poster-has-a-53-manlet-friend-who-is-nice-to-women-still-gets-no-sex.425624/ 35 inlägg

Stromfront.org

- https://www.stormfront.org/forum/t770189/ 164 inlägg

4chan.org/pol/

- https://boards.4chan.org/pol/thread/406538825 84 inlägg
- https://boards.4chan.org/pol/thread/406531588 144 inlägg

Bilaga E - Reflektionsdokument
Kim Rosenqvist

Med visst stöd från handledaren har jag och min studiekollega självständigt navigerat genom de vetenskapliga metoder och den litteratur som krävts för att bygga upp och slutföra ett examensarbete. De självkritiska aspekterna i arbetet finns med, inklusive den etiska diskussionen. Samtliga moment har utförts, och även om bra alltid kan bli bättre så anser jag att detta examensarbete motsvarar de lärandemål som är uppsatta för examenskursen.

De mål som jag bedömer att detta examensarbete uppfyllt särskilt väl är dels förankringen i den vetenskapliga litteraturen, samt metodtillämpningen av det valda vetenskapliga ramverket. Vad gäller förankringen i den vetenskapliga litteraturen så har vi inte enbart lyckats skapa en bred grund av relaterad forskning, utan även identifiera kunskapsluckor som saknades i området av automatisk textanalys. Den tidigare forskning som är använd i uppsatsen anser jag presenteras för läsaren på ett naturligt och sammanhängande sätt, från introduktion, genom problemformulering och vidare till fördjupad bakgrund. Där argument med hänvisning till litteratur är sammanvävd med det allmänna budskapet i den löpande texten.

Vidare så anser jag även att tillämpningen av designforskning genomfördes särskilt väl, med tanke på förutsättningarna för denna studie. Inte nog med att metodramverket krävde fokuserade studier för att skapa den kunskapsgrund som krävs, så anser jag att metodtillämpningen är väl genomförd och beskriven. Tillämpningen av designforskning, som i vårt fall omfattade flera steg med blandade metoder, var utmanande att sammanfatta i ett examensarbetet givet de ramar som finns för arbetets längd. Det var dessutom utmanande att synkronisera strukturen för designforskning med IMRAD. Jag tror att avsnittet om metod och metodtillämpning sammantaget kan ha blivit mer omfattande än genomsnittet sett till andra uppsatser, men givet den blandning av metoder som krävdes för att genomföra studien så anser jag att vi trots allt lyckades väl med balansen.

Det som jag bedömer hade kunnat få mer utrymme i uppsatsen vore dels att behovet av vidare kunskapsutveckling (med utgångspunkt från det egna arbetet) hade kunnat diskuteras lite mer utförligt med några konkreta förslag. Vi hade eventuellt även kunnat explicitgöra validitet och generaliserbarhet i diskussionen, även om detta ändå genomsyrar den argumentation som förs. Dessa är visserligen nämnda, men kan möjligtvis ha blivit mer tydligt påpekade.

Planeringen av arbetet gjordes initialt delvis felaktigt, där de arbetsdagar som krävs som förberedelse inför bokat slutseminarium inte var inkluderade. Det var däremot inga problem att justera detta vid ett senare skede. Utkastet för

slutversionen var trots allt publicerat cirka en vecka innan deadline för registrering inför slutseminarium, och hade dessutom föregåtts av några dagars korrekturläsning.

Detta arbete relaterar till data- och systemvetenskap då det berör området systemanalys och säkerhet. Forskningsfrågan är nära knuten till säkerheten i det digitala samhället, då den anknyter till analys av potentiellt våldsbejakande innehåll. Vidare har studiens artefakt till viss del skapats med hjälp av programmeringskod (Python). Programmeringskurser har således varit till viss nytta i detta examensarbete. Varken jag eller min studiekollega har dock gått specifika kurser inom informationssäkerhet. Metodkurserna har däremot gett en stabil generell bas för det vetenskapliga genomförandet, vilket har genomsyrat hela studiens upplägg och utförande.

Personligen har examensarbetet lett till att jag har fått ett ökat intresse för hotbedömning och automatisk textanalys. I skrivande stund är jag inte helt säker på om jag kommer kunna nyttja några konkreta förvärvade kunskaper i den anställning som nu väntar mig efter avslutad utbildning. Men att däremot ha behövt söka efter samt kritiskt granska information i ett specifikt syfte är en erfarenhet och utökad kompetens som är värdefull att ha i alla tjänsteyrken.

Jag är personligen - sammanfattningsvis - mycket nöjd med genomförandet av detta examensarbete. Med hjälp av vår handledare formulerade vi initialt en forskningsfråga som var väldigt intressant. Dessvärre, som nämnt ovan, så var såväl forskningsfrågan som det nödvändiga vetenskapliga metodramverket okänt område för både mig och min studiekollega. Men att trots detta få fram ett arbete som möter mina egna högt ställda krav på kvalitet, med tid tillgodo för deadline inför slutseminarium, så är jag stolt över prestationen. Samarbetet med studiekollegan har fungerat bra från början till slut, där vi inte bara kompletterat varandras brister utan även skapat ett konstruktivt samtalsklimat, där vi både vågat ifrågasätta och berömma varandras infallsvinklar och förslag.

Bilaga F - Reflektionsdokument
Evelina Bisell

Det finns alltid sätt att förbättra ett skriftligt arbete, men jag anser att vi har lyckats väl med att uppfylla samtliga betygskriterier för en kandidatuppsats. Under arbetets gång har vi försökt jobba utifrån kravanvisningarna för att se till att samtliga avsnitt uppfyller målen. Genom detta arbetssätt har vi kunnat undvika att av misstag helt glömma vissa betygskrav. Men utifrån den feedback vi fått från peer reviews och opponering så har vi sett att vissa delar inte har nämnts tillräckligt ingående eller tydligt, och då gått tillbaka och lagt till eller omformulerat där det behövts. Handledare och examinator har också hjälpt till med mycket konstruktiv feedback som har lett till att samtliga avsnitt setts över, förbättrats och förkortats gång på gång. På grund av detta så har vi till slut lyckats nå en mycket högre kvalitet på vårt arbete än vad jag någonsin kunnat förvänta mig vid dess start.

Jag anser att vi lyckats särskilt väl med skapandet av vår artefakt. För att vara en enkel ordlista och kod som räknar träffar, så har vi genom vår metodtillämpning och alla genomgångna steg lyckats skapa något som ger förvånansvärt bra och intressanta resultat. Jag tror det är ett resultat av den stora kunskapsbas vi samlat in och utgått från när vi bestämt hur vi skulle gå tillväga, samt allt det arbete som lagts ner på varje individuellt steg i utvecklingsprocessen för att skapa något med så hög validitet som möjligt. Det är alltså stegen vetenskaplig förankring (då vi samlat in denna kunskapsbas) och metodtillämpning (hur vi utvecklat artefakten) som är de delar i betygskriterierna som jag tycker vi lyckats särskilt väl med.

Mindre nöjd är jag med vissa delar inom diskussionen. Det kan vara för att den skrevs sist, och därför är det avsnitt som vi har gått igenom minst gånger. I opponeringen så var det också en av de delar vi mottog kritik på. Att vi inte tillräckligt explicit, samt med referenser, diskuterat begränsningarna i termer av reproducerbarhet, validitet, reliabilitet, generaliserbarhet, vidareförbarhet, trovärdighet, etc.. Jag tycker dock att vi har diskuterat validitet, reproducerbarhet och trovärdighet på ett sätt som är lämpligt för det metodramverk, de metodval och den metodtillämpning vi haft. Dock utan att nämna dessa explicit eller referera till kurslitteraturen, då vi inte såg det som ett krav. Men jag kan därför se att det finns flera möjligheter till förbättring på detta avsnitt.

Tidsplanen som skapades i början av arbetet var mer övergripande och behövde justeras under arbetets gång, men alla steg kunde ändå genomföras i god tid. Vi hade ett stort stöd från vår handledare under arbetets gång gällande de olika inlämningarna och när de behövde vara klara. Om vi inte haft det så

hade vi troligtvis behövt göra en mer detaljerad plan, och tagit större eget ansvar genom att kollat upp så att vi följde den vecka för vecka.

Jag har gått kurspaketen Data och -systemvetenskap I, II, och III, samt fristående kurser inom t.ex. Matematik, dataspelsutveckling och Japanska. Jag fick användning av mina kurser inom programmering och matematik vid skapandet av artefakten. Men mest hjälp fick jag av den METOD-kurs jag gick precis innan kandidatarbetet. Den förberedde mig tyvärr inte för Design Science eller de strategier och metoder vi använde oss av, men hjälpte med hur en vetenskaplig artikel ska skrivas samt med att lära mig om många olika forskningsstategier, metoder och vetenskapliga termer.

Jag vet ännu inte om jag kommer ta en master, eller vad jag kommer att jobba med i framtiden, men erfarenheten av att ha varit med och skrivit ett kandidatarbete tror jag definitivt kommer att visa sig värdefullt.

Jag känner mig väldigt nöjd med det som min skrivpartner och jag lyckats åstadkomma, och jag tror inte det skulle ha kunnat bli så bra utan vårt samarbete. Våra styrkor har legat på olika håll så vi har kompletterat varandra väl, och jag har känt ett otroligt stöd arbetet igenom.