AI-drivet beslutsstöd för MDR-klassificering:

En chattbot för riskklassificering av medicintekniska produkter

Axel Davidsson
Ellen Davidsson

Kandidat examensarbete i
Datavetenskap
Höstterminen 2025
Handledare: Paul Johannesson
Institutionen för Data-
och Systemvetenskap



Stockholms universitet

Sammanfattning

Introduktion MDR:s förordning för medicintekniska produkter inom EU syftar till att säkerställa en god patientsäkerhet genom transparens och strikta krav. Förordningen har skapat problem för tillverkare, då komplexiteten i regelverket kräver ökade resurser. Konsekvenserna inkluderar fördröjd marknadsintroduktion och dyra kostnader. Denna uppsats undersöker hur AI kan användas som beslutsstöd utifrån MDR:s regelverk. Författarna har utvecklat en prototyp av en AI-baserad chattbot som ska kunna utföra en riskklassificering utifrån MDR.

Forskningsmål Studien har som mål att utveckla och utvärdera hur korrekt en AI-baserad chattbot utför riskklassificering av en medicinteknisk produkt enligt MDR.

Metod En designvetenskaplig studie genomfördes där en artefakt, i form av en prototyp av en AI-baserad chattbot, utvecklades med en iterativ ansats. Först genomfördes en litteraturgenomgång för att förstå problemområdet. Från litteraturgenomgången formulerades krav för artefakten. Chattboten utvecklades med Python och LangGraph ramverket. Utvärdering skedde genom en ex-post utvärdering med ett stratifierat randomiserat urval av produkter från EUDAMED:s databas. Testobjekten jämfördes med chattbotens genererade riskklass för att mäta procentuell korrekthet.

Resultat Resultatet är en prototyp av en utvecklad chattbot som utvecklats utifrån framtagna krav. Resultatet visar att artefakten kan bedöma riskklasser med 70% korrekthet. Artefaktens korrekthet varierar mellan de olika riskklassgrupperna. Högst korrekthet uppkom i den lägsta och högsta riskklassen.

Diskussion Studien indikerar potential med användning av AI-baserade beslutsstöd i regelstyrda miljöer, med komplement av mänsklig expertis. I reglerade miljöer är spårbarhet och transparens viktigt, därför ses potential för fortsatta studier inom hybrid arkitektur som möjliggör mänsklig granskning under klassificeringen istället för att endast använda AI.

Abstract

Introduction The new MDR regulation for medical devices in EU aims to ensure safety for patients through transparency and strict requirements. This has created challenges for manufacturers of medical devices, as the complexity of the regulatory framework requires increased resources. The consequences include delayed market introduction and high costs. This thesis examines how AI can be used as a decision support tool based on the MDR framework. The authors have developed a prototype of an AI-based chatbot designed to perform risk classification according to the MDR.

Research Goal The study aims to develop and evaluate the accuracy of an AI-based chatbot in performing risk classification of a medical device according to the MDR.

Method A Design Science Research study was conducted in which an artifact, a prototype of an AI-based chatbot, was developed using an iterative approach. A literature review was conducted to understand the problem area and to identify requirements. The chatbot was developed using Python and the LangGraph framework. Evaluation was carried out on a stratified randomized sample of products from the EUDAMED database. The test objects were compared with the risk classes generated by the chatbot to measure the percentage of correctness.

Results The study resulted in an artefact, a developed chatbot made from formulated requirements. The study results show that the chatbot can assess risk classes with 70% accuracy. The artifact's classification accuracy varies across different risk class groups. The highest accuracy was observed in the lowest and highest risk classes.

Discussion The study indicates potential of AI-based decision support systems in regulated environments, when complemented by human expertise. In regulated environments, traceability and transparency are crucial. We see potential for continued research into hybrid architectures that allow for a 'human in the loop' during the classification phase, rather than relying solely on AI.

Tack

Vi vill tacka Paul Johannesson för sin tid och sitt engagemang. Vi hade inte kunnat genomföra studien utan dig. Vi vill även tacka varandra för ett gott samarbete och slutligen rikta ett tack till våra föräldrar för all uppmuntran under studietiden.

Förkortningar

Förkortning	Beskrivning
AI	Artificiell Intelligens
LLM	Large Language Models
MDR	Medical Device Regulation
ML	Maskininlärning
IVDR	In Vitro Diagnostic Regulation
EU	Europeiska Unionen
EUDAMED	European Database on Medical Devices
API	Applikationsprogramgränssnitt
DSS	Decision Support Systems
DSR	Design Science Research

Tabeller

1 Härledning och kategorisering av krav 18
2 Utvärdering av kravuppfyllnad 26
3 Kvantitativa Resultat: Urval av testfall 28

Bilaga A – Kvantitativa Resultat: Samtliga testfall 42
Bilaga B - Kodexempel LangGraph 50

Innehåll

Sammanfattning **i**

Abstract **ii**

Tack **iii**

Förkortningar **iv**

Tabeller **v**

Innehåll **vi**

1 Introduktion **1**
1.1 Syfte och problembeskrivning 2
1.2 Forskningsmål 3
1.2.1 Avgränsningar 3

2 Utvidgad bakgrund **4**
2.1 Artificiell Intelligens 4
2.1.1 Agent 5
2.2 LangChain och LangGraph 5
2.3 Decision Support Systems 6
2.4 European Database on Medical Devices 6
2.5 Regelverk för medicintekniska produkter 7
2.5.1 Medical Device Regulations 7
2.5.2 Riskklassificering enligt MDR 7
2.6 Befintligt IT-stöd för MDR 8

3 Metod **9**
3.1 Metod 9

3.1.1 Forskningsstrategi . . . 9
3.1.2 Datainsamling . . . 10
3.2 Problemanalys . . . 11
3.3 Kravframtagning . . . 12
3.4 Design och Utveckling . . . 12
3.4.1 Utvecklingsprocess . . . 12
3.5 Utvärdering . . . 13
3.5.1 Datakällor för analys . . . 13
3.5.2 Dataanlys . . . 14
3.5.3 Etiska Överväganden . . . 14
3.5.4 AI deklaration . . . 15

4 Resultat **16**
4.1 Kravhärledning . . . 16
4.2 Design och Utveckling . . . 21
4.2.1 Verktyg . . . 22
4.2.2 Beskrivning av LangGraph . . . 22
4.2.3 Chattbotens tillstånd (State) . . . 22
4.2.4 Grafdesign / LangGraph-flöde . . . 23
4.3 Utvärdering av artefakten . . . 25
4.3.1 Kvantitativa Resultat . . . 27

5 Diskussion **29**
5.1 Resultatdiskussion . . . 29
5.1.1 Jämförelse med andra verktyg . . . 30
5.2 Metoddiskussion . . . 31
5.2.1 Reliabilitet . . . 32
5.2.2 Intern validitet . . . 32
5.2.3 Extern validitet och Generaliserbarhet . . . 33
5.3 Resultatetik . . . 34
5.4 AI-baserade beslutsstöd i regelstyrda miljöer . . . 34
5.5 Framtida studier . . . 35

Litteratur **41**

Bilaga A **42**

Bilaga B **50**

1

Introduktion

Medical Device Regulation (MDR), Europeiska Unionens förordning om medicintekniska produkter, trädde i kraft 2017 med mer avancerade och utförliga krav på tillverkning och tillhandahållande av medicintekniska produkter [10].

Riskklassificering av medicintekniska produkter inom EU baserad på MDR sker genom ett logiskt regelsystem bestående av 22 regler (Annex VIII). Reglerna tar hänsyn till den medicintekniska produktens attribut och eventuella direkta och indirekta risker för hälsan. Reglerna kombineras på olika sätt för att avgöra en produkts riskklass, exempelvis utvärderas grad av invasivitet och lokal eller systemisk effekt av produkten[9].

Relaterat till förordningen finns databasen European Database on Medical Devices (EUDAMED) som innehåller data om medicintekniska produkter[8]. EUDAMED syftar till att ge en samlad och aktuell bild av medicintekniska produkter tillhandahållna inom EU, vilket möjliggör ett enklare och bättre informationsutbyte mellan EU:s medlemsländer. [8].

MDR har påverkat marknadsintroduktionen av medicintekniska digitala produkter, särskilt för små till medelstora företag (SME) [34]. SME inom EU upplever idag utmaningar och brist på resurser för att uppfylla krav enligt MDR, och vittnar om att regelverket ofta upplevs som komplext och svårt att tolka [16]. Förordningen har bidragit till att en större andel medicintekniska digitala produkter har blivit klassificerade i högre riskklasser, vilket ställer krav på ett certifierat kvalitetsledningssystem samt omfattande klinisk evidens [34]. Detta har medfört att vissa SME har valt att upphöra med produktionen, senarelägga lansering av nya produkter eller lämna EU-marknaden till förmån för andra regioner [36].

AI-baserade hjälpmedel har enligt forskningen varit ett effektivt stöd för att hantera komplex information[14]. AI erbjuder innovativa lösningar inom hälso- och sjukvården [1] [23]. Ett exempel på detta är effektiv hantering av regulatoriska processer, där AI har visats sig vara lämpligt för att bearbeta och sammanfatta omfattande texter och redovisa detta på ett begripligt sätt[37][14]. Denna studie placerar sig främst inom AI-baserade beslutsstödssystem.

1.1 Syfte och problembeskrivning

I en rapport utgiven av MedTech Europe beskrivs att antalet SME som väljer att lansera nya produkter inom EU har minskat med 19% sedan MDR:s införande [21]. Vidare beskrivs att kostnader för att upprätthålla en certifiering av en medicinteknisk produkt under en 5-års period har ökat med 50% sedan införandet. Fortsättningsvis att av nytillkomna kostnader har tillverkare lagt 90% på interna personalkostnader för att upprätthålla teknisk dokumentation och ledningssystem, endast 10% av kostnader går till avgifter för certifiering [21]. Detta visar att manuell tolkning av komplexa regelverk idag kräver stora resurser och expertkunskap.

Forskning visar att AI-chattbotar som hjälpmedel i juridiskt kontrollerade miljöer kan bidra till mer effektiv informationsinhämtning och underlätta hantering av data [4]. LLM-modeller har även visat sig vara ett bra verktyg för att hämta information ur ett regelverk, men att bristfällig och felaktig information kan delges vid riskklassificering[23].

Det finns idag befintliga hjälpmedel vid riskklassificering utifrån MDR. Europeiska kommissionens Medical Device Cordination Group har publicerat en särskild vägledning för att stödja riskklassificering[9]. Stöd finns även i form av interaktiva guider(Wizards)[29], statisk vägledning som PDF-baserade beslutsträd[9] men även AI-baserade verktyg som hjälper företag med riskklassificering och rådgivning [11]. Dessa hjälpmedel utgör olika former av beslutsstödssystem.

Syftet med studien är att undersöka hur väl ett AI-baserat beslutsstöd fungerar för riskklassificering utifrån MDR. Detta genom att utveckla en prototyp i form av en chattbot som ger styrd informationsinhämtning genom naturlig konversation. Sedan används Gemini-2.5-flash-lite för riskklassificering. Studiens huvudsakliga fokus relaterar till AI-baserade beslutsstödssystem, tillämpad inom riskklassificering av medicintekniska produkter inom EU. Forskning som undersöker hur en utvecklad chattbot utför en transparent informationsinhämtning tillsammans med en LLM för risklassificering enligt MDR, validerat mot EUDAMED-data, saknas idag. Då en användare beskriver en medicinteknisk produkt i naturligt språk och systemet ansvarar för att

extrahera rätt attribut, kan detta sänka kunskapströskeln för SME:er som inte är regulatoriska experter. Genom användarinteraktionen kan den insamlade informationen presenteras, vilket ökar transparens som ofta efterfrågas vid AI användning.

1.2 Forskningsmål

Studien har som mål att utveckla och utvärdera hur korrekt en AI-baserad chattbot utför riskklassificering av en medicinteknisk produkt enligt MDR.

1.2.1 Avgränsningar

Studien behandlar enbart riskklassificering enligt EU:s förordning MDR Annex VIII [10]. Chattboten riktar sig till användare som är icke-experter och ej besitter djup kunskap om riskklassificering eller juridiska krav utifrån MDR. Chattboten ska endast ge rekommendationer och underlätta beslutsfattande och inte ersätta regulatorisk expertis. Den utvecklade chattboten syftar till att vara en prototyp och inte ett färdigt verktyg. AI-chattboten bygger på en LLM och i studien används endast Gemini-2.5-flash-lite modell.

2

Utvidgad bakgrund

Detta kapitel syftar till att ge en teoretisk och teknisk bakgrund för att förstå den utvecklade chattboten samt dess tillämpningsområde som beslutsstöd.

Kapitlets första del behandlar AI, beslutsstödssystem, agenter och det tekniska ramverket som ligger till grund för implementationen av prototypen. Senare delen av kapitlet berör tillämpningsområdet med grundläggande information om Medical Device Regulations, riskklassificeringsregler samt EU:s centrala databas, EUDAMED, som utgör kontexten prototypen ska användas i.

2.1 Artificiell Intelligens

Under de senaste åren har användningen och skapandet av chattbotar ökat, drivet av den växande kommersialiseringen och populariteten av Large Language Modeller (LLM)[37].Införandet av funktionalitet såsom funktionsanrop ger en LLM möjligheten att anropa en tredjepart (exempelvis ett API) för att på ett mer deterministiskt sätt leverera korrekt information [33]. Ytterligare ses AI-system där grupper av AI-modeller samarbetar i olika roller för att åstadkomma uppgifter tillsammans[4]. En LLM fungerar som en så kallad 'black-box', det finns problem kring att förstå hur den resonerar internt och svaren går inte alltid att lita på. Detta problem är tydligt vid användning av LLM:er i en juridisk och medicinsk miljö, där transparens är viktigt[37]. Dock möjliggör LLM:er integrering av kunskap och hantering av komplex information och kan trots sina begränsningar vara värdefulla att använda vid beslutsfattande i regelstyrda miljöer [14].

LLM:er erbjuder förståelse av vanligt skrivet språk och är därför ett intressant alternativ för medicinsk juridisk klassificering, där input är skriven i naturligt språk. AI-baserade chattbotar som använder sig av LLM:er kan användas i regelstyrda eller juridiska miljöer och kan fungera väl som assistenter genom att hjälpa vid informationshämtning och hantering av juridiska frågor[4].

Trots att LLM-modeller har bevisats effektiva att utföra en stor mängd olika uppgifter kan det vara så att de ej fungerar väl i strikta domäner som kräver hög pålitlighet. Detta då LLM-modeller kan 'hallucinera', vilket innebär att de ger felaktig och påhittad information [38]. För att hantera detta problem kan agenter användas, utformade med en förmåga att anropa externa verktyg för att utföra en handling[40]. Det innebär exempelvis att en LLM anropar en deterministisk funktion och detta kan ge större pålitlighet i utdatat.

2.1.1 Agent

Det beskrivs i forskning att en LLM-baserad agent tar möjligheterna med en LLM längre då det går att integrera dem i mer komplicerade flöden, där en agent exempelvis kan använda externa verktyg för att bearbeta data [42].

En agent klarar av att vara en autonomt fungerande enhet som utför förutbestämda uppgifter och planerar. De förstår tidigare input från system eller användare och planerar uppgifter och utför sina handlingar baserat på givna instruktioner eller input [6] [40].

Det finns flera utmaningar med användning av agenter i miljöer där känslig data förekommer. Utmaningarna berör hot som kan påverka agentens funktionalitet, exempelvis manipulation av indata eller bristande kontroll över agentens beteende [6]. Ramverk som optimerar och förenklar utvecklingen av agenter har skapats, vilka stödjer komplex interaktion, tillståndshantering och säkra verktygsanrop vilket möjliggör praktisk implementering av agenter.

2.2 LangChain och LangGraph

LangChain och LangGraph är tekniska ramverk som kan användas för att skapa arbetsflöden med agenter[39][18]. Ramverken möjliggör skalbarhet och modularitet. Detta innebär exempelvis att olika agenter kan samverka för att utföra komplexa uppgifter på ett spårbart sätt [27].

LangChains arkitektur skapar möjligheter för utvecklare att snabbt skapa prototyper och experimentera med olika LLM-modeller eller arbetsflöden. [27]. LangGraph

utökar LangChains funktionalitet genom en graf-orienterad arkitektur, där interaktioner med en agent representeras som noder med olika tillstånd i en riktad graf. Noderna utgörs av bearbetningssteg och kanterna visar möjliga övergångar baserat på modellens beslut. Detta möjliggör loopar, förgrening samt parallel exekvering av flera agenter [27] [39].

I vår studie används LangGraph för att möjliggöra strukturerad och effektiv informationsinsamling för den utvecklade AI-chattboten.

2.3 Decision Support Systems

Decision Support Systems (DSS) beskrivs i litteratur som ett begrepp uppkommet ur tidigare Management Informations Systems. DSS finns flera definitioner som kan sammanfattas till att det är ett system som hjälper en beslutsfattare att lösa ostrukturerade eller semistrukturerade och oprogrammerade problem [3]. DSS kan exempelvis vara ett interaktivt datorbaserat system skapat för att stödja beslutsfattande i komplexa miljöer[19].

Teori om Decision Support menar att beslutsfattande kan delas in i tre centrala aspekter: *intelligence*, *design* och *choice*. Aspekterna innefattar identifiering och tolkning av problem, utformning av olika lösningsalternativ samt val och värdering av det valda alternativet [19].

MDR riskklassificering är ett form av beslutsfattande som är komplext, regelbaserat och svårtolkat för en icke-expert. Denna typ av beslutsfattande kan med fördel hjälpas av ett DSS. Den utvecklade chattbotten syftar till att tillämpas som ett DSS, för att underlätta beslutsfattande med ett strukturerat och spårbart system genom LangGraph.

2.4 European Database on Medical Devices

European Database on Medical Devices (EUDAMED) är en central plattform för lagring och hantering av data relaterad till medicintekniska produkter för att säkerställa att den Europeiska Unionens förordningar följs [8]. EUDAMED har utformats för att ge stöd till implementationen av MDR (Medical Device Regulation) samt IVDR (In Vitro Diagnostic Regulation) [8] [32]. MDR och IVDR är två förordningar som syftar till att förbättra säkerhet, prestanda och översikt av medicintekniska produkter inom EU. EUDAMED är en viktig plattform som hjälper till att stödja förordningarnas efterlevnad genom att tillhandahålla information gällande medicintekniska produkter, tillverkare och den aktuella marknaden inom EU[32] [8] [10].

EUDAMED är under utveckling och implementeras gradvis, vilket synliggör komplexiteten av att digitalisera regulatoriska processer inom EU[8].

2.5 Regelverk för medicintekniska produkter

2.5.1 Medical Device Regulations

Medical Device Regulation (MDR) för medicintekniska produkter (Regulation (EU) 2017/745). [10] är en förordning som tillkom 2017 för att skapa strikta krav för registrering, överblick och spårbarhet av medicintekniska produkter inom EU [32]. Klassificering av medicintekniska produkter enligt MDR sker i olika stadier av en produkts livscykel, både vid utvecklingen samt efter lansering på marknaden för att säkerställa fortsatt säkerhet[7].

MDR syftar till att säkerställa hög säkerhet för människors hälsa, god kvalitet av medicintekniska produkter och främja innovation och utveckling på marknaden för medicintekniska produkter inom EU[10] [16].

2.5.2 Riskklassificering enligt MDR

Riskklassifikation utifrån MDR utgår från flera olika riktlinjer såsom grad av invasivitet, funktion, varaktighet eller kontakt med människokroppen [9], som tillsammans syftar till att bedöma huruvida den medicintekniska produkten utgör en potentiell risk för en patients hälsa vid händelse av att en produkt har ett funktionsfel[7].

Det finns fyra olika riskklassificeringar utifrån MDR [9]:

- Klass **I**
- Klass **IIA**
- Klass **IIB**
- Klass **III**

Riskklasserna tar hänsyn till det avsedda användningsområdet och produktens inneboende risker[9].Av dessa klasser är l **I** den lägsta riskklassen [7].

Klassificering av medicintekniska produkter enligt MDR baseras på 22 regler som presenteras i MDR bilaga VIII, kapitel III [9]. Reglerna utgör grunden av beslutsflöden som i studien ska användas av den skapade chattboten.

2.6 Befintligt IT-stöd för MDR

I forskning beskrivs att riskklassificering av medicintekniska produkter utifrån MDR i dagsläget ofta sker manuellt och kräver expertgranskning [15]. Det finns dock en samling av olika verktyg på marknaden som kan underlätta riskklassificering. Wizard-verktyg såsom Practical RA [29] är ett webb-baserat, interaktivt verktyg som kan underlätta riskklassificering och ge värdefull information till en användare om riskklassificeringsregler. AI-baserade verktyg såsom FormlyAI [11] kan underlätta compliance, genomföra risklassificering och ge mänsklig rådgivning utifrån bland annat MDR och IVD. EU-kommissionens officiella stöd finns genom Medical Device Coordination Group (MDCG) [9]. Detta är en statisk PDF med illustrerade beslutsträd för att synliggöra och underlätta tolkning av riskklassificeringsreglerna.

Trots befintliga verktyg upplevs MDR regelverket fortfarande som komplext med utrymme för tolkning. Det är därför värt att undersöka om en chattbot kan utföra en transparent, systematisk informationsinsamling och sedan med hjälp av en LLM genomföra en korrekt riskklassificering.

3

Metod

3.1 Metod

3.1.1 Forskningsstrategi

Forskningsstrategin som tillämpats är Design Science Research (DSR)[17]. Detta valdes eftersom studien avser att undersöka och förstå ett problemområde för att sedan skapa en artefakt som kan generera ny kunskap inom ämnesområdet. En artefakt i en DSR-studie syftar till att lösa ett praktiskt problem utifrån en forskningsfråga [24]. I forskning beskrivs att en designstudie genomförs genom ett iterativt förhållningssätt och består av problemförståelse, definiering av krav, design och utveckling av en artefakt samt utvärdering [17].

Studien baserades på en litteraturgenomgång av tidigare forskning och relevanta regelverk för problemförståelse, varefter systemkrav togs fram, och artefakten utvecklades och utvärderades med en artificiell utvärdering utifrån sin korrekthet.

Studien fokuserade på utveckling av artefakten men till en del också på kravhantering [17, Kapitel 4.4].

En DSR-studie bedöms som lämpligt, då forskningsfrågan, kräver en prototyp som omsätter reglerna i praktisk funktionalitet.

En forskningsstrategi som övervägdes var en Case Study. Denna metod används för att ge en djup, nyanserad bild av ett ämne i en given kontext[17]. Denna alternativa metod ansågs vara olämplig då det bedömdes vara svårt att samla in data från verksamheter och användare som riskklassificerar produkter enligt MDR.

3.1.2 Datainsamling

Som datainsamlingsmetod genomfördes en litteraturgenomgång. Data om medicintekniska produkter i EUDAMED:s databas användes även för generera testobjekt till utvärderingen.

En alternativ datainsamlingsmetod var semi-strukturerade intervjuer. Detta hade varit ett sätt att samla in information från användare som arbetar med riskklassificering enligt MDR. Metoden hade kunnat bidra till ökad förståelse av problemområdet. Intervjuer med intressenter hade även varit värdefullt vid kravinsamling i utvecklingsprocessen. Författarna ansåg att det var svårt och resurskrävande att finna relevanta användare samt att resultaten skulle kunna vara svåra att generalisera, beroende på den intervjuade populationens storlek. Till följd av detta samt begränsad tid och resurser för studien valdes denna datainsamlingsmetod bort.

Litteraturgenomgång

En scoping review-liknande litteraturgenomgång genomfördes med ett pragmatiskt urval för att identifiera forskning relevant för studiens syfte och problemområde. Relevanta artiklar behandlade områden så som: Arkitektur för AI-agenter, riskklassificering utifrån MDR, AI och riskklassificering utifrån MDR, MDR och EUDAMED, LLM och agenter, LLM:er som beslutssstöd i reglerade miljöer.

Inklusionskriterier var artiklar utgivna de senaste fem åren, på svenska eller engelska, inklusive artiklar som var peer-reviewed och preprints. Detta val motiveras av den snabba utvecklingstakten inom artificiell intelligens och LLM:er [37]. Implementeringen av MDR och databasen EUDAMED är en pågående process i nutid, vilket gör nyligen publicerade källor relevanta. Teorin bakom AI-agenter har en äldre historia men fokus i studien var moderna tillämpningar av AI system. Detta följdes med undantag för litteratur som behandlade grundläggande teoretiska begrepp såsom 'Design Science Research' [17], 'Requirements Engineering'[28]. Officiella dokument såsom MDR:s förordning [10] och hjälpdokument för förordningen [9].

Exklusionskriterier var forskning utgiven på andra språk samt artiklar som ej berörde ämnet utifrån givna teman.

Urvalet utfördes initialt i Google Scholar då databasen anses ha en god tvärvetenskaplig räckvidd. Andra databaser användes inte till följd av tidsbegränsning, något som kan ha skapat ett urvalsbias. Relevans bedömdes efter läsning av abstract för utvalda titlar och granskades av båda författarna.

Sökningar som genomförts i Google Scholar:

- MDR AI

- MDR chatbot
- MDR EUDAMED
- AI chatbot regulatory settings
- MDR risk chatbot
- AI decision support systems
- Langgraph LLM
- AI LLM

Litteraturens trovärdighet kategoriserades i tre kategorier baserat på utgivare och om granskning utförts.

Kategori I - litteratur utgiven av en officiell organisation eller lagar. I detta fanns litteratur såsom MDR:s förordning[10], MDCG:s hjälpdokument [9], information om EUDAMED:s databas [8] samt utgiven litteratur om forskningsmetodik och kravhantering [17] [24] [28].

Kategori II - litteratur som var peer-reviewed och publicerad i en vetenskaplig tidsskrift. Dessa artiklar har genomgått granskning. Artiklar som valdes var publicerade via exempelvis Nature Medicine [37], ACM [6] , JMIR Medical Informatics [36], BMC Health Services Research [16], The AAPS Journal [1] och Frontiers in Medicine [13].

Kategori III - litteratur som var preprints eller rapporter, som inte var granskade och hade lägre evidens. Här inkluderades opublicerade artiklar från plattformen 'arXiv' [14] [39] [42]. Även webbplatser inkluderades[32] [29]. Detta på grund av den snabba utvecklingen inom forskningsområdet gällande AI-agenter och LLM:er.

MDR:s regelverk för klassificering, bilaga VIII [10] innehållandes 22 regler för riskklassificering av medicintekniska produkter granskades för att identifiera vilka parametrar prototypen behövde få information om för att kunna resonera kring riskklassificering. Detta utgjorde en grund för artefaktens beslutsflöde. MDCG:s hjälpdokument användes även för ökad förståelse av MDR:s förordning och riskklassificeringsreglerna[9].

3.2 Problemanalys

Litteraturgenomgången ligger till grund för problemförståelsen.

3.3 Kravframtagning

Litteraturgenomgången ligger till grund för kravframtagningen. Kraven är även motiverade av de formulerade målen.

3.4 Design och Utveckling

I denna studie består artefakten av en instansiering, detta då en prototyp i form av en AI-baserad chattbot har skapas som använder Gemini-2.5-flash-lite som LLM [12]. Chattboten använder MDR:s Annex VIII tjugotvå regler för informationsinhämtning och senare utförs riskklassificering med hjälp av Gemini-2.5-flash-lite. Medicintekniska produkter ur EUDAMED:s databas används som testobjekt för utvärdering av systemet.

3.4.1 Utvecklingsprocess

Utvecklingen av prototypen genomfördes i en agil iterativ process där varje steg utvecklades, testades och sparades i versionshanteringssystemet Git. Detta för att ge en överblick och historik över systemet samt vilka krav som uppfyllts enligt kravspecifikationen.

Som utvecklingsmiljö användes VS Code tillsammans med ett AI-hjälpmedel copilot för att ge stöd i utvecklingen[22]. Python valdes som programmeringsspråk då många bibliotek, inklusive LangGraph finns implementerade [31]. Python används i stor omfattning för datahantering och integration med AI-system. Som språkmodell har Gemini-2.5-flash-lite valts som en avvägning på grund av kostnad för tokengenerering [12]. LLM:en används i huvudsak för att kunna tolka användarens naturliga språk och resonera kring vilken av MDR:s regler som ska tillämpas. En större LLM skulle kunna ha ett bättre språkligt resonemang och påverkat korrektheten, men då denna modell ändå ansågs ha en tillräckligt hög prestanda för studien ansågs det rimligt.

Till en början så implementerades en chattbot med verktygsanrop för att uppdatera en inre checklista. Denna inre checklista skulle fungera som en referens där alla frågor som behövde bli, samt alla frågor som redan hade blivit besvarade, skulle sparas och på så sätt skulle chattboten kunna samla all information som behövdes från användaren tills all nödvändig information var extraherad via en iterativ naturlig språkprocess.

Snart insåg vi dock begränsningarna med LLM:s och AI, och dess problem med koherens i längre sammanhang. När checklistan blev längre så tappade chattboten bort sig.

Från tidigare forskning visas att deterministisk styrning av chattboten med hjälp av en graf där noder representerar tillstånd där varje nod fokuserar på en specifik del [27] [39], var ett bättre alternativ för att samla information. Grafen fungerar därför som ett deterministiskt programmatiskt flöde där frågor ställs iterativt och grafens tillstånd uppdateras därefter. Detta nyttjar chattbotens möjlighet till naturlig konversation med en icke-expert samtidigt som flödet och den inre checklistan kontrolleras separat [2].

3.5 Utvärdering

Utvärderingen som utfördes var en *Ex post* -utvärdering, vilket innebär att artefakten utvärderas efter att prototypen utvecklats. [17]. En artificiell utvärdering användes, där artefakten testades i en kontrollerad miljö och inte i den verkliga världen [17] för att utvärdera korrekthet. En kompletterande metod, *Informed Argument*, användes även för att illustrera de framtagna kravens grad av uppfyllande kvalitativt genom att ge en motivering till dessa [17].

Utvärderingsmetoden som genomfördes var en datasimulering [17], där dem utvalda 20 medicintekniska produkternas riskklassificeringar från EUDAMED:s databas jämfördes med prototypens genererade risklass. Syftet var att utföra en logisk validering genom att mäta chattbotens korrekthet.

3.5.1 Datakällor för analys

För att kunna mäta vad en korrekt klassificering innebär har fastställda riskklassificeringar av medicintekniska produkter ur EUDAMED:s databas använts. För detta användes ett publikt, begränsat API av EUDAMED:s databas, delat av en tredjepart via GitHub [26]. Endast publikt tillgänglig dokumentation och öppna API:er var använda, vilket innebar att datamängden av medicintekniska produkter från EUDAMED var begränsad.

Fullständig data samlades in för tjugo stycken testobjekt. Detta utfördes genom ett stratifierat urval [24]. Detta innebar att data för hundra stycken medicintekniska produkter togs fram ur varje riskklass I, IIa, IIb och III. Därefter skedde ett randomiserat urval i varje riskklass för att få fram fem slutgiltiga produkter vars riskklass jämfördes med vår chattbots utdata. Syftet med ett slumpmässigt urval var att öka utvärderingens tillförlitlighet. Fördelningen mellan riskklasserna var icke-proportionell, men

för att prototypen i så hög utsträckning som möjligt skulle få applicera flera unika vägar och regler vid riskklassificering i utvärderingen var detta ett medvetet val. Tjugo stycken produkter ansågs vara tillräckligt för att få ett stickprov av regeltäckning samt bredd av riskklasser.

3.5.2 Dataanlys

Data analysen syftade till att kvantifiera artefaktens logiska korrekthet.

Kvantitativ Analys: Korrekthet

Artefaktens korrekthet mäts genom beräkning av procentuell korrekthet i förhållande till testobjekts faktiska riskklass från EUDAMED:s databas.

$$ProcentuellKorrekthet = \frac{Antalkorrektariskklassificeringar}{Totalaantalettestfall} \times 100$$

Resultatet presenteras som en andel korrekta riskklassificeringar totalt. En tabell visar även resultat per testobjekt med LLM:ens motivering.

3.5.3 Etiska Överväganden

Studien sker enligt Vetenskapsrådets riktlinjer för god forskningssed (2024). Studien hanterade inga känsliga personuppgifter eller data. Vidare krävdes inget samtycke eller anonymitet.

Författarna har enligt riktlinjerna vidtagit åtgärder för att uppnå en ärlig och ansvarsfull informationsspridning genom tydlig källhänvisning och tydlig information vid egna antaganden, tolkningar eller värdering av information i studien[41].

Användning av AI som beslutsstöd i en reglerad miljö kommer med etiska utmaningar, felaktig information kan ge förödande konsekvenser för patientsäkerheten. MDR är lagstadgat, vilket innebär att riskklassificering i praktiken måste bli korrekt. För att möta dessa dilemman vill vi vara tydliga med att den utvecklade artefakten endast är en prototyp och inte kommer komma till användning i faktiskt verkliga sammanhang.

Riktig produktdata från EUDAMED:s databas har använts för utvärderingen, men eftersom datat är offentligt och inga personuppgifter använts så anses det inte finnas några etiska risker med detta.

Vidare så utvärderades prototypen utan användartester genom en datasimulering. Etiska dilemman såsom bristande objektivitet, felaktiga antaganden eller förvrängda resultat är något som har försökt minimeras genom att vara så transparenta som möjligt gällande felkällor och resultat.

3.5.4 AI deklaration

ChatGPT-5 användes som ett kompletterande verktyg i datainsamlingen för att identifiera relevant forskning[25]. ChatGPT gavs en prompt: "Kan du ge oss forskning och litteratur på hur AI-agenter kan agera beslutsstöd vid riskklassificering utifrån MDR:s förordning". Litteratur som genererades, verifierades genom att artikeln söktes upp i den publicerade tidskriften, lästes och granskades på samma sätt som i datainsamlingen.

Vidare användes ChatGPT-5 som hjälpmedel vid utvärderingen för att besvara frågor gällande en medicinteknisk produkts egenskaper. Detta genom att information om testobjektet från EUDAMED:s databasg samt prototypens genererade fråga vid riskklassificering gavs som input.

ChatGPT-5 har även använts för att ge förslag och idéer för språkliga förbättringar av redan skriven text av författarna, för bättre flyt och ordval. Detta har gjorts genom att ChatGPT-5 har instruerats att agera kritisk läsare och komma med feedback på tydligare formuleringar eller ordval.

4

Resultat

Resultatet består av den utvecklade artefakten, en AI-baserad chattbot, samt utvärdering av dess korrekthet vid riskklassificering enligt MDR.

4.1 Kravhärledning

Tre övergripande mål skapades för att motivera de framtagna kraven[17]. Dessa tre mål var:

- Mål 1: Ökad korrekthet av riskklassificering utifrån MDR
- Mål 2: Minska den kognitiva bördan för icke-experter
- Mål 3: Ökad effektivitet av riskklassificering

Kraven togs fram från litteraturgenomgången, MDR:S bilaga VIII och tekniska begränsningar som upptäcktes under prototyputvecklingen. Kraven sorterades och gavs ett unikt ID för spårbarhet [28].

Chattboten har inriktats på informationsinhämtning från användaren. Eftersom antalet parametrar som ska hämtas från användaren är stort, har det tagits i beaktning vad som krävs för att få chattboten att behålla sin kontext. Tidigare forskning har beskrivit att när system förlitar sig på endast en LLM, ökar risken för ofullständighet och hallucinationer, vilka är felaktigheter[23]. Forskningen identifierade särskilt tekniskt svaga svar och bristande fullständighet vid användning av kommersiella LLM-chattbotar för MDR-relaterade uppgifter[23]. Därav har ett antal krav tagits fram som

behandlar hur chattboten ska interagera med en användare vid informationsinsamling av den medicintekniska produkten och hur chattboten sedan ska behålla insamlad information.

Aspekter angående förklarbarhet och formell validering vid användning av LLM är ett eget forskningsfält och detta har inte valts som huvudsaklig inriktning vid utformandet av chattboten.

Tabell 1: Härledning och kategorisering av krav

Krav-ID	**KravTyp**	**Kravbeskrivning**	**Stakeholder**	**Motivering**	**Spårbarhet och Källor**
01	Funktionellt krav	Systemet ska kunna samla in information i naturlig text utifrån MDR när en användare beskrivit en del av sin produkt	Slutanvändare	Nödvändigt för att påbörja en informationsinsamling av från en användare	Mål 1 [3] [4][40]
02	Funktionellt krav	Systemet ska kunna göra skillnad på vilken insamlad information som är relevant för en riskklassificering	Slutanvändare	För att säkerställa att chattboten används i rätt syfte och förstår riskklassificeringsreglerna	Mål 1 [38] [14] [9]
03	Funktionellt krav	Systemet ska kunna komma ihåg information som samlats in från användaren	Slutanvändare	För att möjliggöra deterministiskt flöde och spårbarhet	Mål 2 [27] [42][1]
04	Funktionellt krav	Systemet ska kunna identifiera en relevant riskklassificeringsregel utifrån MDR när en användare givit information gällande en medicinteknisk produkt	Slutanvändare	För att komma in i riskklassificeringsflödet	Mål 1 [10][38][14]
05	Funktionellt krav	Systemet ska kunna ställa en fråga och sedan vänta på svar från en användare	Slutanvändare	För att föra en turbaserad konversation	Mål 3 [27][42][2]
06	Funktionellt krav	Systemet ska kunna ta emot en fråga om tidigare begärd information från en användare	Slutanvändare	För att kunna förtydliga oklar information till en användare	Mål 1, Mål 2 [19][2][4]
07	Funktionellt krav	Systemet ska kunna omformulera informationen när detta efterfrågas av en användare	Slutanvändare	För att möjliggöra att korrekt informationsinsamling	Mål 2 [2][19]

Tabell 1 (Forts.): Härledning och kategorisering av krav

Krav-ID	KravTyp	Kravbeskrivning	Stakeholder	Motivering	Spårbarhet och Källor
08	Funktionellt krav	Systemet ska kunna visa en riskklass och en motivering i textform för en användare när fullständig information om en medicinteknisk produkt har givits som input.	Slutanvändare	För att kunna utföra riskklassificering enligt reglerna i MDR	Mål 2 [3][14]
09	Funktionellt krav	Systemet ska ställa följdfrågor utifrån riskklassificeringsreglerna till en användare tills fullständig input har givits	Slutanvändare	För att säkerställa korrekt input för användning vid riskklassificering	Mål 1 [10][9][27][38]
10	Funktionellt krav	Systemet ska kunna motivera riskklassificering av en medicinteknisk produkt när en användare ställer en fråga	Slutanvändare	För att kunna leverera en slutgiltig riskklass med förklarad information	Mål 1, Mål 2 [14][3][13][1]
11	Icke-funktionellt implementeringskrav	Systemet ska utvecklas med Python version 3.12 och LangGraph ramverket	Utvecklare	För att säkerställa reproducerbarhet och transparens	Mål 3 [18]
12	Funktionellt krav	Systemet ska kunna föra en turbaserad konversation om en medicinteknisk produkt med en användare	Slutanvändare	För att kunna ge och samla in nödvändig information för att genomföra riskklassificering	Mål 1, Mål 3 [40][2][4]
13	Icke-funktionellt Prestandakrav	Systemet ska ta max 10 sekunder att svara på en fråga ställd av en användare	Utvecklare	För att säkerställa god prestanda och effektivitet	Mål 3 [19][42]

Tabell 1 (Forts.): Härledning och kategorisering av krav

Krav-ID	KravTyp	Kravbeskrivning	Stakeholder	Motivering	Spårbarhet och Källor
14	Funktionellt krav	Systemet ska kunna motivera en riskklassificering med en beskrivning av riskklassen, beskrivning av produkten och anledning till riskklassen	Slutanvändare	För att kunna agera beslutsstöd och ge information	Mål 2 [14][3]
15	Funktionellt krav	Systemet ska lagra en användares svar internt och använda dessa svar för riskklassificering av en medicinsk produkt	Utvecklare	För ökad transparens och ökat förutbestämt flöde vid riskklassificering	Mål 2 [27][38] [39] [6]
16	Funktionellt krav	Systemet ska kunna ge generell information om en riskklass utifrån regler i MDR till en användare	Slutanvändare	För att agera kunskapsstöd och underlätta förståelse av MDR	Mål 2 [9][10][37] [1]
17	Funktionellt krav	Systemet ska kunna hämta information från EUDAMEDs databas för att få information om befintliga medicintekniska produkter	Slutanvändare	För att EUDAMED används i utvärdering och är en del av tillämpningsområdet för studien	Mål 1 [32][8]
18	Funktionellt krav	Systemet ska vid ett internt fel kunna meddela en användare om detta och logga felet	Slutanvändare, Utvecklare	För att kunna spåra var implementationen brister	Mål 2 [27] [42][28] [38]

4.2 Design och Utveckling

Arkitekturen i AI-chattboten är grafbaserad och uppbyggd av ett antal noder representerat i kod som klasser. Varje nod representerar en del av MDR Annex VIII:s regler. Processen börjar med en *triage-nod* som samlar in grundläggande information från en användare. Sådan information behandlar exempelvis om enheten är invasiv, icke-invasiv, aktiv eller en mjukvara. Baserat på given information avgör *triage*-noden vilka noder som kommer fortsätta exekveras. Detta görs genom att *triage*-noden skapar en dynamisk lista med följande noder. Dessa noder är: *Invasiv-noden*, *NonInvasive-noden*, *Software-noden*, *Acitve-noden* och *SpecialRules-noden*. De är uppbyggda med logik och fält utifrån riskklassificeringsreglerna. Noderna innehåller olika fält med relevant information som ska hämtas från användaren för att senare uppdatera ett gemensamt *State*, som är baserat på MDR regler. Detta *State* används sedan som input till LLM för klassificering. I Figur 4.1 ses en övergripande modell över implementationen.

När systemet identifierar användarens input används funktionen `with_structured_output()`, som kommer från LangChains bibliotek. Den ser till att en viss struktur följs på LLM:ens output, för att returnera exempelvis endast `true` eller `false`. Detta möjliggör uppdatering av ett fält i taget i `State`. Validering av LLM:s svar kontrollerar att nod-schemat följs och sker med biblioteket *Pydantics* [30] *BaseModel* klass. Detta är ett sätt att skapa mer kontrollerat och deterministiskt användade av LLM:s.

Chattboten läser in användarens input, undersöker om det är efterfrågat svar eller om användaren begär ytterligare information i form av förtydliganden kring frågan. Chattboten fortsätter att ställa frågor för varje fält som har definierats i respektive nod. När alla frågor har ställts klart för en nod går den vidare till nästa nod i den skapade listan eller till klassificeringsnoden.

En routerlogik styr flödet mellan noderna i *LangGraph*. Detta innebär att efter att *triage*-noden skapas en lista med alla noder som behöver besökas för att samla information. Fortsättningsvis så säkerställer även router-logiken att processen avslutas när all relevant information har samlats in och chattboten kan ge en riskklass till användaren. Vi har försökt implementera chattboten på ett sätt som möjliggör flexibelt flöde, som är skalbart och enkelt att förstå. I Kodlista 4.1 ses implementationen för triage-noden.

Listing 4.1: Python-klass för triage-noden.

```
class TriageNode(BaseModel):
    device_name: Optional[str] = Field(None, description="Name of the device")
```

```
    is_invasive: Optional[bool] = Field(None, description="Does it penetrate the
         body?")
    is_active: Optional[bool] = Field(None, description="Does it rely on energy
        (electricity/battery)?")
    is_software: Optional[bool] = Field(None, description="Is the device
        STANDALONE software (e.g., mobile app, AI model)? Set to FALSE if it is
        a physical device that happens to contain embedded software/firmware.")
    duration: Optional[Duration] = Field(None, description="How long will it
        contact the body? TRANSIENT = under 60 minutes, SHORT_TERM = under 30
        days, LONG_TERM = over 30 days. Return ONLY one of: TRANSIENT,
        SHORT_TERM, LONG_TERM")
```

4.2.1 Verktyg

Verktyg som har används är Python 3.12 [31], LangGraphs ramverk[18], Gemini-2.5-flash-lite[12] och EUDAMED:s API [26].

4.2.2 Beskrivning av LangGraph

LangGraph är det ramverk som har använts för att implementera systemets logik i form av en rad distinkta noder [18]. I denna arkitektur avgör ett internt tillstånd (State) vilken väg exekveringen tar genom grafens noder. I Bilaga B visas ett grundläggande exempel på hur en graf definieras.

4.2.3 Chattbotens tillstånd (State)

Inre tillstånd implementeras som en Python-klass med fält. I 4.2 visas en del av klassen *State* som har attribut relaterade till *triage* och *non-invasive* -noden. Dessa fält har plockats fram genom att analysera MDR:s riskklassificerings regler samt genom att se exempel på data från EUDAMED. Även här används Pydantics *BaseModel* som validering när ett nytt *State* -objekt initieras i koden för att kontrollera informationsinsamlingen

Listing 4.2: Python-klass för chattbotens inre tillstånd (State).

```
class State(BaseModel):
    # --- System ---
    messages: Annotated[list, operator.add] = Field(default_factory=list)
    pending_nodes: List[str] = Field(default_factory=list)
    triage_complete: bool = False

    # --- Triage ---
```

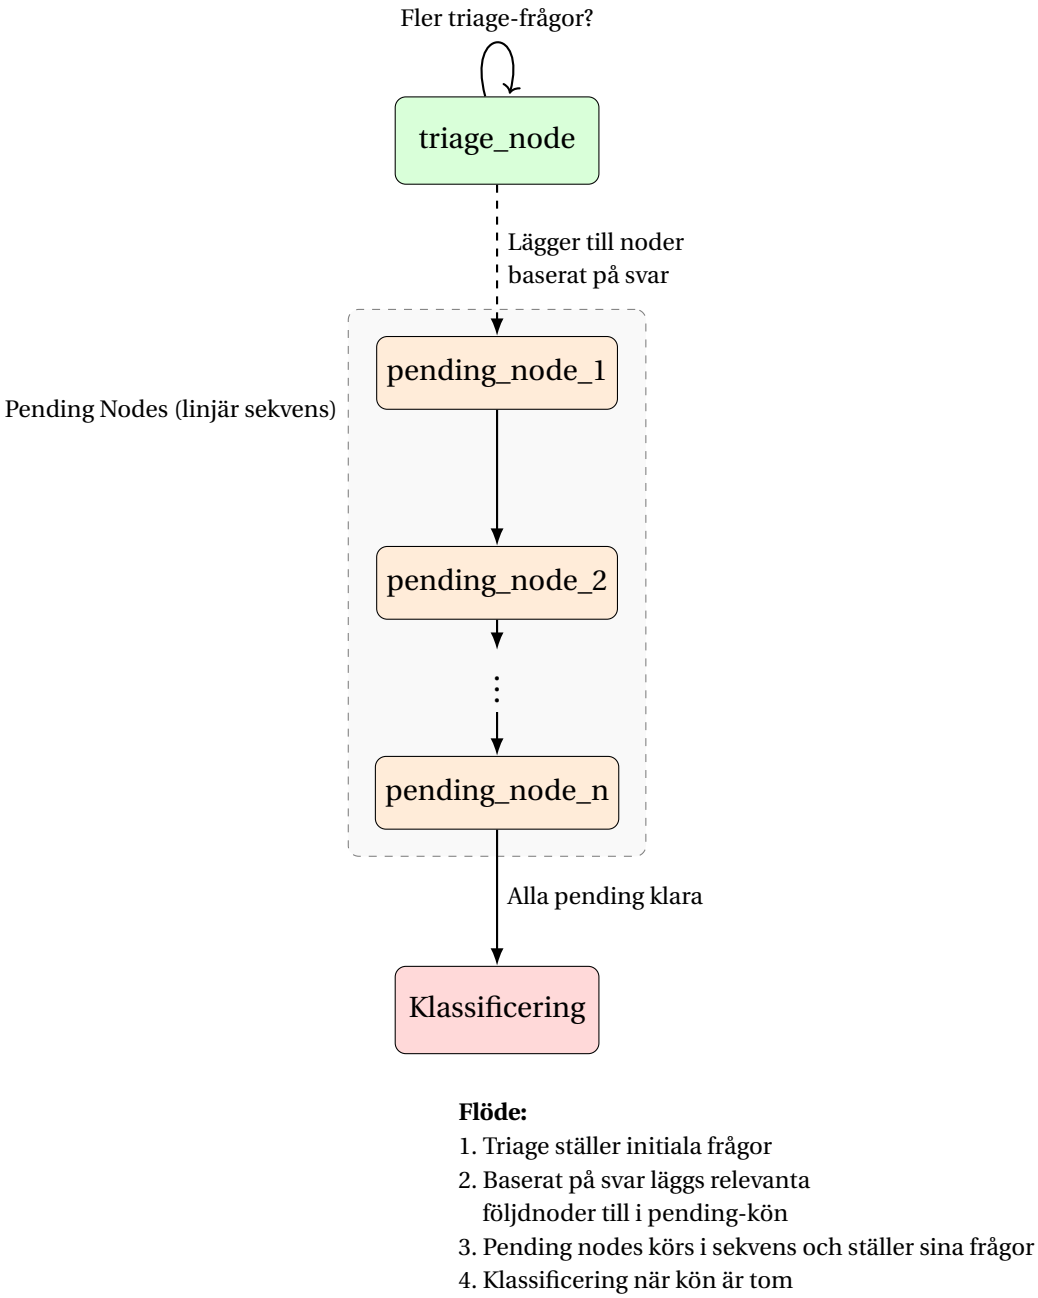
```
    device_name: Optional[str] = None
    is_invasive: Optional[bool] = None
    is_active: Optional[bool] = None
    is_software: Optional[bool] = None
    duration: Optional[Duration] = None

    # --- Non-Invasive (Rules 2, 3, 4) ---
    channels_fluids_for_infusion: Optional[bool] = None
    is_blood_bag: Optional[bool] = None
    modifies_fluids_for_body: Optional[bool] = None
    is_simple_processing: Optional[bool] = None
    contacts_injured_skin: Optional[bool] = None
    wound_use_type: Optional[WoundUseType] = None
```

Denna klass används genom grafen för att hålla reda på var i grafen programmet befinner sig och var exekvering ska gå härnäst.

4.2.4 Grafdesign / LangGraph-flöde

I nedan figur visas en överblick av hela artefakten från *triage*-noden och den dynamiska listan för informationsinsamling till klassificering med hjälp av LLM.



Figur 4.1: Översikt av chattbotens arkitektur med LangGraph-flöde

4.3 Utvärdering av artefakten

Utvärderingen av prototypen består av en empirisk ex-post utvärdering samt metoden informerad argumentation (informed argument) [17].

Tabell 2: Utvärdering av kravuppfyllnad

Krav-ID	**Status**	**Motivering och kommentar**
01	Uppfyllt	Visades i testerna, då implementationen och användning av LLM möjliggjorde detta.
02	Delvis	Nodstrukturen möjliggjorde ett relevant flöde av frågor.
03	Uppfyllt	Designval, *State*-funktion och noder säkerställde lagring av input.
04	Ej Uppfyllt	Vi har inte implementerat regelbaserad riskklassificering, endast LLM '*black-box*' klassificering
05	Uppfyllt	Implementation med chattboten möjliggjorde detta
06	Delvis	LLM har tolkat användarens input och valt rätt funktionsanrop vid flera tillfällen
07	Delvis	Chattbotens implementation med en LLM som har funktionsanrop, att en fråga ska förtydligas, möjliggjorde detta
08	Delvis	Enligt de empiriska testerna visade chattboten en riskklass i de flesta fall men hamnade även vid enstaka fall i en evighetsloop, motivationen för riskklass var inte tillförlitlig
09	Uppfyllt	Möjliggörs med *State*-klass och logik som ser till att alla fält var ifyllda
10	Delvis	Motivering av riskklass utfördes med LLM anrop, men följdfrågor kunde ej ställas
11	Uppfyllt	Chattboten utvecklades med Python 3.12 och LangGraph
12	Uppfyllt	Chattboten samt LangGraph möjliggjorde turbaserad konversation
13	Uppfyllt	Systemet tog inte längre än 10 sekunder
14	Delvis	LLM möjliggjorde detta, däremot gav systemet inte någon produktinformation eller beskrivning av riskklassen annat än motiveringen
15	Uppfyllt	*State*-funktionen hanterade intern lagring av input som användes i riskklassificeringen
16	Ej uppfyllt	Detta var inte implementerat
17	Ej uppfyllt	Chattboten kunde inte själv hämta information från EUDAMED via API, detta behövde göras manuellt
18	Delvis	Testfallet med evighetsloopen bevisade att alla logiska fel inte loggades. *State*-objektet loggades genom hela chattinteraktionen

4.3.1 Kvantitativa Resultat

Resultatet som gavs var att chattboten utförde en korrekt klassificering till 70%.

Antalet testobjekt som blev korrekt riskklassificerade i respektive riskklass:

- Riskklass I: 5/5
- Riskklass IIa: 2/5
- Riskklass IIb: 3/5
- Riskklass III: 4/5

I tabell 3 visas två stycken utvalda testfall. I det första fallet ser vi att artefakten klassificerat rätt. I det andra fallet har den underklassificerat betydligt. Alla tjugo testfall finns i Bilaga A.

Tabell 3: Kvantitativa Resultat: Urval av testfall

ID	**Produkt / Testfall**	**Referens Riskklass**	**Chattbotens Riskklass**	**Korrekt?**
00198953024096	Portrait™ Central Viewer Application (Portrait CVAXB)	IIb	IIb	Ja **Reasoning**: The device is software that monitors vital physiological parameters (Rule 11). Furthermore, the software is intended to be used for monitoring for the purpose of immediate danger monitoring and influences treatment decisions, and the software risk level is Death or Irreversible.
08588009045427	OCUflash® Forte Eye Drops	IIb	I	Nej **Reasoning**: The device is not invasive, not active, and does not fall under any of the higher-class rules. It contacts injured skin, but it is not intended for wound closure or directly managing the wound healing process. Therefore, it falls under the general rule for non-invasive devices.

5

Diskussion

5.1 Resultatdiskussion

Svaret på forskningsfrågan var att chattboten kunde utföra en delvis korrekt riskklassificering, 70% korrekthet av 20 testobjekt. Procentuell korrekthet utifrån varje riskklass:

- Riskklass I: 100% korrekthet
- Riskklass IIa: 40% korrekthet
- Riskklass IIb: 60% korrekthet
- Riskklass III: 80% korrekthet

100% korrekt riskklassificering i riskklass I kan indikera att det är enklare att riskklassificera en produkt som tillhör en lägre riskklass. En möjlig förklaring är att regelverket är mindre komplext och tydligare, vilket kan minska risken för att chattboten gör feltolkningar i riskklass I. Även testobjekten i riskklass I kan i vissa fall vara enklare att förstå, med färre gränsfall. Detta kan ha bidragit till att chattbotens frågor kunde besvaras mer korrekt, vilket kan ha genererat korrekta riskklasser i större utsträckning.

Utfallet i riskklass IIa och IIb var relativt lika. En möjlig förklaring kan vara att gränsen mellan dessa två riskklasser är otydlig i regelverket samt att flera samtidiga regler behöver beaktas vid riskklassificering. Testobjekten i riskklass IIa och IIb är även mer komplicerade att förstå, vilket kan göra det svårt att ge korrekt information till chattboten. Dessa faktorer tillsammans kan ha genererat fel riskklassificering. Det förekom även att chattboten hamnade i en evighetsloop och ej kunde generera någon riskklass

i ett av testfallen i risklass IIa, vilket gör resultaten svårare att tyda och skulle kunna antyda både tekniska utmaningar och logiska utmaningar i regelverket.

Chattboten presterade mer korrekt igen i den högsta riskklassen III, vilket kan förklaras av att regelverket för den högsta riskklassen är mer restriktivt och tydligt, vilket gav ett minskat utrymme för inkorrekt riskklassificering. Testobjekten var komplicerade att förstå även i riskklass III men regelverket är strikt för klass III, och det kan vara en förklaring att resultatet blev mer korrekt i denna klass.

Resultatet varierar stort inom de olika riskklasserna, vilket speglar komplexiteten i MDR:s regelverk. Resultaten är även i hög utsträckning beroende av adekvat produktinformation.

I riskklass IIa genomförde chattboten två stycken överklassificeringar, i riskklass IIb en underklassificering och i riskklass III en underklassificering. Chattboten genomförde alltså lika många överklassificeringar som underklassificeringar till högre respektive lägre riskklasser, som innebär olika risker med olika allvarlighetsgrad. En överklassificering är felaktigt och innebär en ökad administrativ börda för en tillverkare [9]. Detta kan bidra till en ökad ekonomisk barriär för innovation av medicintekniska produkter då det kan finnas ökade kostnader för certifiering vid marknadsintroduktion. En underklassificering får stora negativa konsekvenser, där patientsäkerheten äventyras, vilket kan få förödande konsekvenser för både individ och samhälle och motstrider MDR:s syfte i stort.

Sammanfattningsvis indikerar studien en potential för AI-baserade DSS, men att tillförlitligheten beror på flera faktorer. Resultaten 70% korrekthet kan indikera att ett AI-baserat beslutsstödssystem i form av en chattbot kan ses som ett hjälpverktyg eller komplement för att ge stöd vid riskklassificering, snarare än vara ett autonomt riskklassificeringssystem som konsekvent utför korrekt riskklassificering. En 70% korrekthet belyser att systemet kräver mänsklig expertis, då fel riskklassificeringar skulle få betydande regulatoriska och säkerhetsmässiga konsekvenser.

5.1.1 Jämförelse med andra verktyg

I jämförelse med befintliga MDR-verktyg, exempelvis RA-Wizard [29] möjliggör vår utvecklade chattbot användarinteraktion under informationsinsamlingen för produkten. Detta innebär att en användare kan ställa frågor till chattboten och få direkta svar, exempelvis förtydligande kring en viss fråga som chattboten ställt. Fortsättningsvis innehåller RA-wizarden mycket information som kan vara svårt för en användare att överblicka. Däremot är en wizard mer pålitlig, då det finns tydliga osäkerheter med användning av AI. Säkerheten, stabiliteten och pålitligheten av en wizard har i kontexten stora fördelar. För att kompensera för opålitligheten kring AI använder LLM:en

funktionsanrop med datavalidering. Dessa agerar *guardrails*, ett sätt att försöka kontrollera output från LLM:en vid informationsinsamlingen. Detta säkerställer att *State* -objektet innehåller korrekta angivna fält. Vidare kan den insamlade informationen granskas av användaren innan chatboten går vidare. Detta ger en möjlighet för så kallad *human-in-the-loop* -funktionalitet, men den har inte blivit implementerad i denna artefakt, dock finns funktionalitet att avbryta körningen om användaren ser att den insamlade informationen är fel.

FormlyAI [11] ett befintligt AI-verktyg och en plattform för stöd av regulatoriska frågor såsom MDR, erbjuder användare beslutsstöd och kunskap. Denna plattform är mogen och har en bredare omfattning i området. Således är plattformen mycket mer välutvecklad. Trots detta ansåg vi ändå att utveckling av prototypen var lämplig för att mäta korrektheten av ett AI-baserat beslutsstöd när informationsinsamlingen för riskklassificering skedde på ett transparent sätt.

5.2 Metoddiskussion

Den valda studien Design Science Research med artefaktutveckling ansågs lämplig för att besvara forskningsfrågan. Potentiella negativa konsekvenser med vald forskningsansats är att den utvecklade chattboten är en prototyp med begränsad funktionalitet. Ökad tid och ökade resurser hade möjliggjort en mer välutvecklad implementation, men kunde inte genomföras inom ramarna för uppsatsen. Däremot ansåg vi ändå att prototypen var tillräcklig för att kunna besvara forskningsfrågan och bidra till problemområdet.

Den valda datainsamlingsmetoden var en litteraturgenomgång. Metoden ansågs lämplig då det gav en förståelse för problemområdet genom sammanställning av tidigare forskning på ett effektivt sätt, då det var svårt att finna experter inom området med given tidsåtgång, samt att det största bidraget i studien var själva utvecklingen av artefakten, de framtagna kraven men framförallt artefakten i sig. Negativa aspekter av vald datainsamlingsmetod var att en expert för MDR:s ramverk saknades. Om studien hade inkluderat en annan empirisk datainsamlingsmetod, så som kvalitativa intervjuer utöver den genomförda litteraturgenomgången, skulle MDR:s regelverk kunna förstås bättre. I sin tur hade detta kunnat medfört en större förståelse för problemområdet och då bidragit till studien i sin helhet. Däremot ansågs en litteraturgenomgång vara lämplig med sina fördelar med tidseffektivitet och oberoende av externa aktörer som bidrag till problemförståelsen.

Design och utveckling av artefakten kan ha påverkats till följd av avsaknad av expertkunskap som hade kunnat möjliggjort en ökad förståelse av det logiska flödet i chattboten med de olika tillstånden och noderna utifrån riskklassificeringsreglerna.

Däremot skedde den tekniska implementationen utifrån författarnas uppfattning av MDR regelverket med hjälp av AI, vilket var relevant för att besvara forskningsfrågan. Experthjälp hade möjligen bidragit med kunskap som hade kunnat möjliggöra en tydligare implementation av regelverket i chattboten och bidragit till ökad korrekthet och tillförlitlighet av prototypen. Samtidigt ansågs de använda verktygen som tillräckliga för studien och artefaktutvecklingen.

Ex-post utvärderingsmetod tillsammans med "informed argumentför utvärdering av kravuppfyllnad gav en bild av hur designprocessen gått till vid artefaktutvecklingen. Den utvärderingsmetoden som valdes för att testa artefakten, hade svagheter i form av att det inte fanns tillgång till produktexperter. Trots detta ansågs denna utvärderingsmetod mest lämplig då den var tidseffektiv, detta då bidraget till forskningsfrågan i stor del bestod av just design och utveckling av artefakten. Positivt med vald metod var att testobjekten gick att mäta direkt med etablerade riskklasser i EUDAMED:s databas. I utvärderingen valdes fem stycken testobjekt per riskklass med ett randomiserat urval från EUDAMED:s databas. Att samma antal produkter valdes i respektive riskklass var för att säkerställa att samtliga klasser representerades i urvalet för att kunna möjliggöra jämförelse av prototypens korrekthet mellan olika riskgrupper.

5.2.1 Reliabilitet

När utvärderingen av artefakten genomfördes så försökte bias att undvikas genom att göra ett slumpmässigt urval av medicintekniska produkter ur EUDAMED:s databas.

För att uppnå transparens och tillförlitlighet har officiella dokument från MDR använts som källa i studien. De tekniska ramverken använda vid utvecklingen av chattboten är även tillgängliga för allmänheten. Litteraturen insamlad för problemförståelse och kravformulering har kategoriserats och genomgått urvalskrierium av båda författare för att försöka minska bias och öka tillförlitligheten.

Utvecklingsprocessen dokumenteras genom GitHub med tillgänglig versionshistorik för ökad reproducerbarhet.

5.2.2 Intern validitet

Ett hot mot intern validitet är prototypens begränsade funktionalitet som medförde tekniska problem vid riskklassificering, exempelvis hamnade chattboten i en evighetsloop vid ett testfall. Eftersom att artefaktens logik baserats på författarnas tolkning av regelverket, med hjälp av chatGPT[25], finns risker att information kan har feltolkats. När LangGraphs 'State' har byggts upp för att representera de regler som

finns i MDR:s Annex VIII är det möjligt att detta ej representerar regellogiken på ett fullständigt sätt.

I utvärderingen fanns tjugo testfall, vilket begränsar de generella slutsatser som kan dras från utvärderingen och deras statistiska signifikans. Endast fem objekt ur varje riskklass valdes. Detta kan ha medfört att en tillfällighet vid testerna fick ett oproportionerligt stort utslag i resultatet.

I utvärderingen fanns flera felkällor. Användningen av AI utgör ett stort hot. ChatGPT tillsammans med författarnas egen kunskap om medicintekniska produkter använts för att kunna besvara frågor ställda av artefakten vid riskklassificeringen. Avsaknad av produktexperter kan ha påverkat resultatet negativt då bristande produktkunskap är en stor felkälla vid riskklassificering. Användning av ChatGPT som stöd kan ha medfört interaktionsbias, genom att författarna själva bestämde när förtydligande frågor i ren text skulle ställas i utvärderingen. Detta skulle kunna ha strukturerats med regelbundet genom att exempelvis i ett visst intervall bett chattboten om förtydligande. Efter informationsinsamlingen genom chattboten har informationen skickats till en LLM(Gemini-2.5-flash-lite) som ett sista steg i LangGraph grafen. Här uppstår hot såsom avsaknad av spårbarhet och risken för hallicunationer som felkällor.

Dessa hot på grund av användningen av LLM och dess hallucinationer, har försökt hanteras genom implementering med LLM som nyttjar funktionsanrop.

Utvärderingsmetoden, en ex-post artificiell utvärdering användes för att i högre utsträckning möjliggöra en god intern validitet genom att artefakten testas i en kontrollerade miljö. Studien har använt en kvantitativ utvärdering för att svara på forskningsfrågan. Då den genererade riskklassen för testobjekten jämförs med deras befintliga riskklass i EUDAMED:s databas, har graden av korrekthet gått att mäta på ett tillförlitligt sätt. Detta bidrar till en god intern validitet av utvärderingen.

5.2.3 Extern validitet och Generaliserbarhet

Det fanns hot mot extern validitet då artefakten ej testas i en verklig kontext. Hot mot extern validitet försökte minskas genom att använda ett randomiserat urval i utvärderingen för att få produkter som representerar samtliga riskklasser.

Positivt med detta val är att alla riskklasser testas i samma utsträckning och resultaten inte endast avser produkter som tillhör riskklasser som har hög förekomst i EUDAMED. Negativa aspekter kan vara att urvalet av testobjekt inte återspeglar fördelningen av riskklasser i EUDAMED och resultaten kan inte generaliseras till hela mängden av produkter i EUDAMED. Samtidigt valdes urvalet då det möjliggjorde utvärdering av korrekthet under likvärdiga förutsättningar för de olika riskgrupperna.

En begränsning av studien är att tester uteslutande utfördes med fokus på MDR:s regelverk, vilket innebär att resultaten, 70% korrekthet, inte direkt kan säkerställas för andra regelstyrda miljöer med annan struktur. Detta begränsar den externa validiteten till MDR-kontexten. Trots att resultaten är specifika för denna kontext, kan dem ändå indikera på att liknande lösningar skulle kunna vara tillämpbara i strikta miljöer med liknande logiska beslutsträd.

Till följd av ovan diskuterade felkällor, kan resultatet av studien ses som en indikation för artefaktens prestation.

5.3 Resultatetik

Studien som behandlar riskklassificering av medicintekniska produkter enligt MDR kan få flera etiska och samhälleliga konsekvenser. Felaktig riskklassificering kan påverka patientsäkerheten, vilket är ett stort etiskt dilemma och något som bör tas i beaktande då detta kan vara farligt för både individ och samhället. Regulatoriska krav behöver även uppfyllas, något som äventyras om felaktig riskklassificering görs.

Studien har visat att AI-baserade beslutsstöd i denna juridiskt strikta kontext kan användas som ett stöd men att komplettering med mänsklig expertis krävs för säker användning. Det finns etiska risker med att ha en för stor tillit till automatiserade system, om dess begränsningar inte tydligt framkommer. Som tidigare diskuterat finns risker med AI, som med felaktig användning kan få negativa konsekvenser. I detta sammanhang finns det regulatoriska ansvaret hos tillverkaren av produkten i slutändan och kan inte i sin helhet överlåtas till ett AI-baserat system.

En reproducerbar implementation med deterministisk informationsinhämtning i denna regelstyrda miljö kan erbjuda ökad transparens och förståelse, och på det sättet öka tillit för hur beslut om riskklassificering fattas. Detta kan få positiva konsekvenser, så som mer effektiva regulatoriska processer men även främjande av innovation av medicintekniska produkter, i synnerhet för SME.

5.4 AI-baserade beslutsstöd i regelstyrda miljöer

I MDR:s regelverk finns flera olika logiska flöden. Baserat på tidigare given information ställer chattboten en viss följd av frågor. Detta kräver en komplicerad och omfattande logik för korrekt funktionalitet. Detta väcker frågan om vilken roll AI spelar i sammanhanget. Hade ett beslutstödssystem utan AI kunnat vara mer detaljerat, till och med mer lämpligt enligt MDR:s riskklassificeringsregler?

Ett regelbaserat system utan AI skulle kunna ha ett mer deterministiskt beteende och varit fullskaligt transparent [5]. Ett sådant stabilt system kan tänkas vara optimalt

för en regelstyrd miljö, där säkerhet och tillförlitlighet är centralt. Däremot är riskklassificering utifrån MDR ett område som ständigt utvecklas vilket innebär att regelbaserade beslutsstöd kan bli rigida och svåra att underhålla i en föränderlig marknad. Här möjliggör AI i högre utsträckning flexibilitet för beslutsfattande i dessa miljöer [5].

Användning av AI vid beslutsfattande, som möjliggör användarinteraktion och flexibilitet, innebar även i MDR:s kontext att chattboten kunde omformulera eller tydliggöra informationen i regelverket för en användare. Dessa fördelar kan vara bidragande anledningar till varför användning av AI möjliggör enklare beslutsfattande, till skillnad från ett system utan AI. Då vissa regler kan behöva tolkas, på grund av att de är vaga, kan AI vara ett stöd i MDR-kontexten. Däremot finns det även nackdelar, där användning av AI som beslutsstödssystem kan resultera i automationsbias. Detta innebär att användare litar för mycket på AI, som kan generera felaktiga svar, vilket kan få stora negativa konsekvenser[20]. Tidigare forskning har föreslagit att vissa delar av ett regelverk i en strikt miljö skulle kunna vara regelstyrda, medans AI:s styrka genom mönsterigenkänning och texttolkning kan användas där det finns nyanser och svaret är mer svårtolkat[5]. Detta resonemang skulle även kunna tillämpas kontexten av riskklassificering utifrån MDR.

Till skillnad från att bara använda AI och prompta den för att utföra en riskklassificering, skiljer sig vår artefakt genom att prototypen har utvecklats för att på ett strukturerat sätt samla in den relevanta informationen som en AI behöver för att sedan kunna riskklassificera utifrån MDR. I sin helhet har studien undersökt hur en prototyp som använder sig av deterministiskt informationsinsamlande kombinerat med AI-baserad interaktion kunnat användas i MDR:s strikta regelverk.

Det blir tydligt att det finns både begränsningar med användning av AI i form av minskad transparens och pålitlighet men även möjligheter med flexibilitet, användarinteraktion och föränderlighet i en regelstyrd miljö. Forskning beskriver framtida möjligheter med en hybrid användning av både AI och regelbaserade system i dessa miljöer [5].

5.5 Framtida studier

Forskning beskriver hur AI-baserade DSS är tydligt beroende av expertkunskap och kunskapsbaserade regelverk för att kunna möjliggöra intelligent beslutsfattande i olika industriella miljöer. [35]. Vidare beskrivs hur det finns utmaningar med användning av AI och transparens, förklarbarhet, etik och tillförlitlighet [35].

Användningen av *Explainable AI* kan forskas vidare på för att se hur användningen av AI-baserat beslutsfattande kan göras med tillförlitligt och transparent[35]. Hybridlösningar av expertkunskap tillsammans med AI skulle kunna vara vägen framåt för att säkerställa god effektivitet och prestanda. Dock beskrivs att den mänskliga kunskapen nödvändig för att säkerställa att beslutsfattandet går att tillämpa i verkliga strikta miljöer[5].

För framtiden då det skulle kunna finnas möjligheter att utöka funktionaliteten för chattboten att hantera otydliga klassificeringsfall där MDR:s Annex VIII-regler är vaga i en viss situation.

Litteratur

[1] Muhammad Ajmal, Muhammad Adeel Raheem och Jamil Khan. ”Innovative Approaches in Regulatory Affairs: Leveraging Artificial Intelligence and Machine Learning for Efficient Compliance and Decision-Making”. I: *The AAPS Journal* 27.1 (2025), s. 12–25. DOI: 10.1208/s12248-024-01006-5. URL: https://link.springer.com/article/10.1208/s12248-024-01006-5.

[2] Russell Beale. *Dialogic Pedagogy for Large Language Models: Aligning Conversational AI with Proven Theories of Learning*. 2025. arXiv: 2506.19484 [cs.CL]. URL: https://arxiv.org/abs/2506.19484.

[3] Robert H. Bonczek, Clyde W. Holsapple och Andrew B. Whinston. *Foundations of Decision Support Systems*. Academic Press, 1981. ISBN: 978-0121130501.

[4] Jiaxi Cui m. fl. *Chatlaw: A Multi-Agent Collaborative Legal Assistant with Knowledge Graph Enhanced Mixture-of-Experts Large Language Model*. 2024. arXiv: 2306.16092 [cs.CL]. URL: https://arxiv.org/abs/2306.16092.

[5] Giovanni De Gasperis och Sante Dino Facchini. ”A comparative study of rule-based and data-driven approaches in industrial monitoring”. I: *arXiv* arXiv:2509.15848v1 (2025). DOI: 10.48550/arXiv.2509.15848. URL: https://arxiv.org/abs/2509.15848.

[6] Zehang Deng m. fl. ”AI Agents Under Threat: A Survey of Key Security Challenges and Future Pathways”. I: *ACM Computing Surveys* 57.7 (febr. 2025), s. 1–36. ISSN: 0360-0300. DOI: 10.1145/3716628. URL: https://doi.org/10.1145/3716628.

[7] MedTech Europe. *MedTech Europe's Facts & Figures 2025*. 4 sept. 2025. URL: https://www.medtecheurope.org/about-the-industry/facts-figures/ (hämtad 2025-11-04).

[8] European Commission. *EUDAMED — European Database on Medical Devices*. Accessed: 2025-11-07. 2025. URL: https://ec.europa.eu/tools/eudamed/#/screen/home.

[9] European Commission, Medical Device Coordination Group. *MDCG 2021-24: Guidance on Classification of Medical Devices*. Tekn. rapport. Accessed: 2025-11-07. European Commission, okt. 2021. URL: https://health.ec.europa.eu/system/files/2021-10/mdcg_2021-24_en_0.pdf.

[10] European Union. *Regulation (EU) 2017/745 of the European Parliament and of the Council of 5 April 2017 on medical devices, OJ L 117, 1–175*. 5 april 2017. URL: https://eur-lex.europa.eu/eli/reg/2017/745/oj/eng (hämtad 2025-11-04).

[11] FormlyAI. *FormlyAI – Your Virtual Chief Regulatory Officer*. Webbplats för MDR/IVDR-compliance, dokumentgenerering och klassificeringsverktyg. 2025. URL: https://www.formly.ai/ (hämtad 2025-11-27).

[12] Google Cloud. *Gemini 2.5 Flash Model Overview*. https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash. Accessed: 2025-12-03. 2024. URL: https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash.

[13] Yu Han, Aaron Ceross och Jeroen Bergmann. "More than red tape: exploring complexity in medical device regulatory affairs". I: *Frontiers in Medicine* 11 (2024). Accessed: 2025-11-20, s. 1415319. DOI: 10.3389/fmed.2024.1415319. URL: https://www.frontiersin.org/journals/medicine/articles/10.3389/fmed.2024.1415319/full.

[14] Yu Han, Aaron Ceross och Jeroen H. M. Bergmann. "AI for Regulatory Affairs: Balancing Accuracy, Interpretability, and Computational Cost in Medical Device Classification". I: *arXiv preprint arXiv:2505.18695* (maj 2025). Accessed: 2025-11-10. DOI: 10.48550/arXiv.2505.18695. URL: https://arxiv.org/abs/2505.18695.

[15] Yu Han, Aaron Ceross och Jeroen H. M. Bergmann. "Toward Automated Regulatory Decision-Making: Trustworthy Medical Device Risk Classification with Multimodal Transformers and Self-Training". I: *arXiv preprint arXiv:2505.00422* (maj 2025). Accessed: 2025-11-20. URL: https://arxiv.org/abs/2505.00422.

[16] Lasse Huusko m. fl. "Medical device regulation (MDR) in health technology enterprises – perspectives of managers and regulatory professionals". I: *BMC Health Services Research* 23.1 (2023), s. 1001. DOI: 10.1186/s12913-023-09316-8. URL: https://link.springer.com/article/10.1186/s12913-023-09316-8.

[17] Paul Johannesson och Erik Perjons. *An Introduction to Design Science*. 1st. Cham: Springer International Publishing, 2014. ISBN: 9783319106328.

[18] LangChain Inc. *langgraph*. https://pypi.org/project/langgraph/. PyPI package, version 1.0.3, released Nov 10, 2025. Accessed: 2025-11-21. 2025.

[19] Shaofeng Liu m. fl. ”Integration of decision support systems to improve decision support performance”. I: *Knowledge and Information Systems* 22.3 (2010), s. 261–286. DOI: 10.1007/s10115-009-0192-4. URL: https://link.springer.com/article/10.1007/s10115-009-0192-4.

[20] Farah Magrabi m. fl. ”Artificial Intelligence in Clinical Decision Support: Challenges for Evaluating AI and Practical Implications”. I: *Yearbook of Medical Informatics* 28.01 (2019), s. 128–134. DOI: 10.1055/s-0039-1677903. URL: https://www.thieme-connect.com/products/ejournals/pdf/10.1055/s-0039-1677903.pdf.

[21] MedTech Europe. *Survey Report: Analysing the Availability of Medical Devices and In Vitro Diagnostics on the EU Market Under the MDR and IVDR*. Tekn. rapport. Retrieved December 28, 2025. MedTech Europe, jan. 2025. URL: https://www.medtecheurope.org/wp-content/uploads/2025/01/mte_report_ivdr_mdr_2024-v7.pdf.

[22] Microsoft. *Visual Studio Code - Editing. Redefined.* Utvecklingsmiljö (IDE). 2025. URL: https://code.visualstudio.com/ (hämtad 2025-12-03).

[23] Suhail Muzaiek. ”Exploring the use of large language models in registering medical device software: A qualitative study from the perspectives of legal experts in the European Medical Devices Regulation”. Master’s thesis. Examensarb. Stockholm, Sweden: KTH Royal Institute of Technology, 2024. URL: https://www.diva-portal.org/smash/get/diva2:1905605/FULLTEXT01.pdf (hämtad 2026-01-12).

[24] Briony J. Oates, Marie Griffiths och Rachel McLean. *Researching Information Systems and Computing*. 2nd. London: SAGE Publications Ltd, 2022. ISBN: 9781529732696.

[25] OpenAI. *ChatGPT*. Version GPT-5.1. Large language model. 2025. URL: https://chatgpt.com (hämtad 2025-12-03).

[26] OpenRegulatory. *EUDAMED API (unofficial)*. https://openregulatory.github.io/eudamed-api/. GitHub repository: https://github.com/openregulatory/eudamed-api. 2025.

[27] Karthik Pelluru. ”LangChain & LangGraph in Production: Architectures for Multi-Agent LLM Systems”. I: *Journal of Data & Digital Innovation (JDDI)* 2.3 (juli 2025), s. 1–9. URL: https://datalensjourna.com/index.php/JDDI/article/view/35/41 (hämtad 2025-11-11).

[28] Klaus Pohl och Chris Rupp. *Requirements Engineering Fundamentals: A Study Guide for the Certified Professional for Requirements Engineering Exam – Foundation Level*. 2. utg. Rocky Nook, 2015. ISBN: 9781937538774.

[29] Practical RA. *MDR Device Classification Wizard*. Online tool for EU MDR medical device classification under Regulation (EU) 2017/745. 2025. URL: https://www.practicalra.com/mdr-device-classification-wizard/ (hämtad 2025-11-27).

[30] pydantic contributors. *pydantic: Data validation using Python type hints*. GitHub repository; open-source Python library for data validation and settings management. 2025. URL: https://github.com/pydantic/pydantic.

[31] Python Software Foundation. *Python 3.12.0 Release Notes*. https://www.python.org/downloads/release/python-3120/. Accessed: 2025-12-03. 2023. URL: https://www.python.org/downloads/release/python-3120/.

[32] RegDesk. *Understanding EUDAMED and its impact on medical device compliance*. Accessed: 2025-11-04. Febr. 2025. URL: https://www.regdesk.co/blog/understanding-eudamed-and-its-impact-on-medical-device-compliance/.

[33] Timo Schick m. fl. "Toolformer: Language models can teach themselves to use tools". I: *Advances in Neural Information Processing Systems* 36 (2023), s. 68539–68551.

[34] Andreas A. Schmitz m. fl. "Impact of Rule 11 on the European Medical Software Landscape: Analysis of EUDAMED and Further Databases Three Years After MDR Implementation". I: *Therapeutic Innovation & Regulatory Science* 59.2 (2025), s. 365–378. DOI: 10.1007/s43441-025-00747-5. URL: https://link.springer.com/article/10.1007/s43441-025-00747-5.

[35] Mohsen Soori m. fl. "AI-Based Decision Support Systems in Industry 4.0, a review". I: *Journal of Economy and Technology* (2024). Review article. URL: https://www.sciencedirect.com/science/article/pii/S2949948824000374.

[36] Līga Svempe. "Exploring Impediments Imposed by the Medical Device Regulation EU 2017/745 on Software as a Medical Device". I: *JMIR Medical Informatics* 12 (2024), e58080. DOI: 10.2196/58080. URL: https://medinform.jmir.org/2024/1/e58080/.

[37] Arun James Thirunavukarasu m. fl. "Large language models in medicine". I: *Nature Medicine* 29 (2023), s. 1930–1940. DOI: 10.1038/s41591-023-02448-8.

[38] J. Wang och Z. Duan. *Controlling Large Language Model Hallucination Based on Agent AI with LangGraph*. Cambridge Open Engage. Preprint, Cambridge University Press. 2025. URL: https://www.cambridge.org/engage/api-gateway/coe/assets/orp/resource/item/677c7fbafa469535b905cace/original/controlling-large-language-model-hallucination-based-on-agent-ai-with-lang-graph.pdf.

[39] Jialin Wang och Zhihua Duan. ”Intelligent Spark Agents: A Modular LangGraph Framework for Scalable, Visualized, and Enhanced Big Data Machine Learning Workflows”. I: *arXiv preprint arXiv:2412.01490* (2024). Accessed: 2025-11-11. DOI: 10.48550/arXiv.2412.01490. URL: https://arxiv.org/abs/2412.01490.

[40] Lei Wang m. fl. ”A survey on large language model based autonomous agents”. I: *Frontiers of Computer Science* 18.6 (2024), s. 186345.

[41] Vetenskapsrådet. *God forskningssed 2024*. Tekn. rapport. ISBN 978-91-89845-08-4. Vetenskapsrådet, 2024. URL: https://www.vr.se/analys/rapporter/vara-rapporter/2024-10-02-god-forskningssed-2024.html (hämtad 2025-11-10).

[42] Asaf Yehudai m. fl. *Survey on Evaluation of LLM-based Agents*. 2025. arXiv: arXiv:2503.16416 [cs.AI]. URL: https://arxiv.org/abs/2503.16416.

Bilaga A

Bilaga A - Kvantitativa resultat

ID	**Produkt / Testfall**	**Referens Riskklass**	**Chattbotens Riskklass**	**Korrekt?**
26936662606053	Nonsterile X-Ray Detectable Lap Sponges	I	I	Ja **Reasoning**: The device is a nonsterile surgical sponge. Rule 1 states that all non-invasive devices are Class I unless other rules apply. Since the device is invasive, but not surgically invasive, and does not fall under any other rule, it is Class I.
00768627011570	Norco Ortho-Foam Flex Finger Spring Orthotic, Large	I	I	Ja. **Reasoning**: The device is not invasive, active, or a software. It is intended to be used for a short term duration. It does not fall under any of the other specific rule categories. Therefore, it falls under the general rule for non-invasive devices
40639070005554	Medical Bed	I	I	Ja **Reasoning**: The medical bed is an active device (powered) and is not invasive. It does not fall under any of the higher classification rules. Rule 1 states that all non-invasive devices are Class I unless another rule applies

Tabell 1 (Forts.): Kvantitativa Resultat: Riskklassificering

ReferensID	**Produkt / Testfall**	**Referens Riskklass**	**Chattbotens Riskklass**	**Korrekt?**
04048486005931	Lumbar Orthosis	I	I	Ja **Reasoning**: The device is a non-invasive device and does not fall under any of the higher classification rules. Rule 1 states that all non-invasive devices are Class I unless other rules apply.
08055774395489	Surgical Tweezers	I	I	Ja **Reasoning**: The surgical tweezers are non-invasive (as defined by the MDR), and contact injured skin. Rule 5 states that all devices intended for use specifically for the following purposes: (a) to control, monitor, diagnose or treat a disease; (b) to control, monitor, diagnose, or compensate for an injury or disability; (c) for the investigation, replacement or modification of the anatomy or of a physiological process; are classified as Class I.

Tabell 1 (Forts.): Kvantitativa Resultat: Riskklassificering

ReferensID	**Produkt / Testfall**	**Referens Riskklass**	**Chattbotens Riskklass**	**Korrekt?**
00850024232181	Navina Fecal Incontinence Insert, Starter Pack	IIa	IIa	Ja **Reasoning**: The device is invasive (enters the body via an orifice), intended for transient use, and is not a surgical instrument. It is used for fecal incontinence, which is a condition of the lower gastrointestinal tract. Rule 8 applies to devices that enter the body via an orifice, other than the oral or nasal cavity, and are intended for transient use.
05060429710323	LMA® Supreme	IIa	IIa	Ja **Reasoning** The LMA® Supreme is an airway management device. It is invasive (enters the body via an orifice), and intended for transient use. Rule 6 states that all devices intended to administer medicinal products by inhalation are class IIa, except if they are covered by other rules. Since this device is not for inhalation, and is intended for transient use, it falls under Rule 6, which states that all other invasive devices for transient use are class IIa.

Tabell 1 (Forts.): Kvantitativa Resultat: Riskklassificering

ReferensID	**Produkt / Testfall**	**Referens Riskklass**	**Chattbotens Riskklass**	**Korrekt?**
08431057000844	Custom pack for central venous catheter	IIa	Bugg	Nej, systemet hamnar i en loop och ställer samma fråga
08431057008107	LUMINOR X-Pandable™ Embolization Coil System	IIa	III	Nej. **Reasoning**: The device is implantable and intended to come into direct contact with the central nervous system (CNS) or the heart.
06972125711359	4D volume probe	IIa	IIb	Nej, -**Reasoning**: * **Rule 11:** Applies because the device is active and emits radiation. * **Rule 12:** Applies because the device administers energy and the energy is hazardous. * Since both rules apply, the device is classified as IIb.
08588009045427	OCUflash® Forte Eye Drops	IIb	I	Nej **Reasoning**: The device is not invasive, not active, and does not fall under any of the higher-class rules. It contacts injured skin, but it is not intended for wound closure or directly managing the wound healing process. Therefore, it falls under the general rule for non-invasive devices.

Tabell 1 (Forts.): Kvantitativa Resultat: Riskklassificering

ReferensID	**Produkt / Testfall**	**Referens Riskklass**	**Chattbotens Riskklass**	**Korrekt?**
08435539233247	Vulkan External Hex NP Implant 3.30x08	IIb	IIb	Ja **Reasoning**: The device is an implantable device (Rule 16). It is surgically invasive and intended to remain in place for a long term. Therefore, it falls under Class IIb.
09556807403526	My. Siza Classic 69	IIb	Bugg	Artifakten fastnar i en evighetsloop
06936666511434	Radiofrequency surgery electrode, single-use	IIb	IIb	Ja **Reasoning**: The device is an active device (administers energy) intended to be used to treat a patient via an orifice (other than the mouth or nose) and is not intended to diagnose or monitor. The energy administered is hazardous. Therefore, it falls under Rule 11.
00198953024096	Portrait™ Central Viewer Application (Portrait CVAXB)	IIb	IIb	Ja **Reasoning**: The device is software that monitors vital physiological parameters (Rule 11). Furthermore, the software is intended to be used for monitoring for the purpose of immediate danger monitoring and influences treatment decisions, and the software risk level is Death or Irreversible.

Tabell 1 (Forts.): Kvantitativa Resultat: Riskklassificering

ReferensID	**Produkt / Testfall**	**Referens Riskklass**	**Chattbotens Riskklass**	**Korrekt?**
00643169339243	Replace Select Tapered implantat	III	III	Ja. **Reasoning**: The device is implantable and intended to be in contact with the body for a long term. It is surgically invasive and does not fall under any of the other more specific rules. Therefore, it falls under Rule 8, which classifies all implantable devices as Class III unless another rule applies.
06956014463482	SYNTRA™ Shun Ski trails	III	III	Ja. **Reasoning**: The device is surgically invasive and intended to come into direct contact with the central nervous system.
06971642801864	Bioresorbable polyglycolic acid suture with needle, PGLA	III	III	Ja. **Reasoning**: The device is an implantable device (Rule 14). It is a bioresorbable suture, which is surgically invasive and undergoes chemical change and is absorbed in the body.

Tabell 1 (Forts.): Kvantitativa Resultat: Riskklassificering

ReferensID	**Produkt / Testfall**	**Referens Riskklass**	**Chattbotens Riskklass**	**Korrekt?**
08050391091929	Femoral Head	III	III	Ja **Reasoning**: The device is an implantable device intended to come into direct contact with the heart or central nervous system or a device that is intended to administer and/or remove medicinal products. Since the device is an implantable device and does not contact the heart or CNS, we look at Rule 14
08050507910311	Ceramic femoral heads, total hip replacement	III	IIb	Nej **Reasoning**: The device is an implantable device (femoral head) intended to come into direct contact with the body. It is not covered by any of the more specific rules (1, 8, 9, 10, 11, 12, 13). Therefore, it falls under Rule 14, which applies to all implantable devices that are not covered by other rules.

Bilaga B

```
from langgraph.graph import StateGraph, START, END

# Definiera noder
def mock_llm_node(state):
    return {"messages": ["Hello world"]}

# Bygg grafen
builder = StateGraph(dict) # Dict som internal state
builder.add_node("mock_llm", mock_llm_node)

# Skapa kanter
builder.add_edge(START, "mock_llm")
builder.add_edge("mock_llm", END)

graph = builder.compile()
```

I detta exempel agerar konstanten `START` som en ingångspunkt där exekveringen inleds, medan `END` fungerar som en slutpunkt där grafen avslutas och returnerar resultatet. Noden, här benämnd `mock_llm`, innehåller den funktion som exekverar logiken.

Centralt i LangGraph är det Statesom skickas genom alla noder. Detta objekt fungerar som systemets korttidsminne och uppdateras kontinuerligt beroende på nodernas output. För denna prototyp definierades en typad struktur för att hålla reda på konversationen och insamlad data:

```
from typing import TypedDict, List

class AgentState(TypedDict):
    messages: List[str] # Historik av konversationen
    product_info: str # Insamlad produktdata
    next_step: str # Variabel fr styrning genom graf
```

För att möjliggöra dynamiska beslut, där systemet går till olika noder beroende på 'State', används villkorliga kanter (Conditional Edges). Dessa gör det möjligt för grafen att inspektera det nuvarande tillståndet och dynamiskt välja nästa nod. Nedan visas hur en sådan kant läggs till i grafen:

```
# Addera till en villkorlig kant noden 'node_a'
workflow.add_conditional_edges(
    "node_a", # vilken nod
    route_decision, # Funktionen som routar vidare mellan kanter
)
```

Denna villkorliga kant styrs av en routing-funktion. Denna funktion läser av `AgentState` och returnerar namnet på nästa nod som ska köras. Ett förenklat exempel på denna logik visas nedan:

```
def route_decision(state: AgentState):
    # Om vi saknar produktinformation, till question-noden
    if not state.get("product_info"):
        return "ask_question_node"

    # Annars, vidare till klassificering
    else:
        return "classify_node"
```

Genom denna struktur kan systemet växla mellan att ställa följdfrågor och att utföra en slutgiltig analys, beroende på hur komplett den insamlade informationen är.